


Hizalama Algoritmaları


- Canlılığın temeli genetik dizilerde saklanır.
- Bu dizilerin anlamlarının anlaşılması çoğu biyoenformatik çalışmasının temelini oluşturur.
- Bu anlamlandırma için genetik dizilerin hizalanması en önemli işlemlerden birisidir.
- Genlerin işlevlerinin ortaya çıkarılması, evrimsel süreç boyunca korunan bölgelerin tespiti, kanser gibi genetik hastalıklarda değişen bölgelerin belirlenmesi gibi pek çok önemli araştırmada genetik dizileri karşılaştırmamız gerekir.
- Aşağıdaki resimde insan, fare, köpek gibi farklı canlıların genetik dizilerinin karşılaştırmalı bir analizi gösterilmekte.
- Bu analizde benzer genlerin ve bölgelerin tespiti yukarıda bahsettiğimiz araştırma türleri için kullanılabilir.
- Bunun yanı sıra ilaç araştırmalarında da insan öncesi safhalarda ilaçların etkili olduğu genlerin deney yapılacak hayvanlar ve insanlarda birbirine ne kadar benzediği önem taşımaktadır.

Hizalama Algoritmaları


Mouse: 44610-63075-88302
Chick: 13923-22581-15808
Chimp: 22991-37076-25507
Human: 23046-37138-25550
Dog: 25476-39113-27909
Rat: 38684-54344-41706
Puffer: 4934-18805-6038
Zebra: 70-70391-1249



:Human:Chimp:Dog:Mouse:Rat:Chicken



:Human:Chimp:Dog:Mouse:Rat




Mouse: 44610-63075-88302
Chimp: 22991-37076-25507
Human: 23046-37138-25550
Dog: 25476-39113-27909
Rat: 38684-54344-41706

Hizalama Algoritmaları

- Dizi hizalama işleminin yoğun kullanıldığı alanları aşağıdaki başlıklarda özetleyebiliriz.
- **DNA/Protein Sekanslarının benzerlik ve homoloji tespiti amacıyla kıyaslanması**
- Homoloji çoğu zaman gen benzerliği ile karıştırılsa da gen benzerliğinden farklı olarak sayısal değil sözel bir kavramdır.
- Somutlaştırmak gerekirse iki gen ya homologdur ya da değildir.
- Örneğin, iki gen %80 benzerdir diyebilirken, iki gen %80 homologdur diyemeyiz.
- Homoloji genelde iki temel değişimden kaynaklanır. Türleşme (speciation) ve kopyalaşma (duplication).
- Türleşme sonucu oluşan genler ortalog, kopyalaşma sonucu oluşan genler paralog olarak adlandırılır.
- Bu iki kavramı aşağıdaki şekilde daha net görebiliriz.

Hizalama Algoritmaları



Hizalama Algoritmaları

- **Gen/Protein fonksiyon tahmini**
- Dizi benzerliği proteinlerin fonksiyonlarının tahmininde sıkça kullanılan bir yöntemdir.
- **Filojenik (Evrimsel İlişki) ağaçlarının oluşturulması**
- Evrimsel ilişkileri tanımlayan filojenik ağaçlar oluşturulurken de dizi benzerliğinden ve dolayısı ile hizalama skorları kullanılır.
- **Protein motiflerinin bulunması**
- Proteinlerin ikincil yapılarının tahmininde farklı protein bölgelerinin (residue) dizi benzerliğinden yola çıkılarak proteinlerin ikincil yapıları tahmin edilmektedir.
- **Shotgun Sekans analizi için birleştirme işlemleri**
- Shotgun sekanslama sırasında çok sayıda kısa DNA dizisi okunur.
- Bu dizilerin birleştirilmesi için gen hizalama algoritmalarından faydalanılır.

Hizalama Nedir ?

- Hizalama (alignment) en az iki gen veya protein dizisinde aynı hizada bulunan dizi elemanlarının karşılıklı olarak nasıl hizalanacağını araştırılmasıdır.
- Bu işlem sırasında iki dizi gerekirse boşluklar kullanılarak eşit uzunlukta olacak biçimde hizalanabileceği gibi (global hizalama), dizilerin sadece belirli bir kısmı da hizalanabilir (yerel hizalama).
- Bu iki tür hizalamayı aşağıdaki şekillerde görebiliriz;

Hizalama Nedir ?

Local Alignment

Target Sequence

5' ACTACTAGATTACTTACGGATCAGGTACTTTAGAGGGCTTGCAACCA 3'

||||| ||||| ||||| ||||| ||||| ||||| ||||| |||||

Query Sequence

5' TACTCACGGATGAGGTACTTTAGAGGC 3'

Global Alignment

Target Sequence

5' ACTACTAGATTACTTACGGATCAGGTACTTTAGAGGGCTTGCAACCA 3'

||||| ||||| ||||| ||||| ||||| ||||| ||||| |||||

5' ACTACTAGATT-----ACGGATC--GTACTTTAGAGGGCTAGCAACCA 3'

Query Sequence

Hizalama Nedir ?

- Buradan yola çıkarak hizalama işleminin daha matematiksel bir tanım yapabiliriz.
- $x = x_1, x_2 \dots x_M$ ve $y = y_1, y_2 \dots y_N$ şeklinde iki dizi ise, hizalama boşlukların x dizisinde $0, \dots, M$ ve y dizisi için $0, \dots, N$ indislerine her iki dizideki harflerin karşısında bir harf veya boşluk bulanacak biçimde atanmasıdır.
- Global hizalamada bu işlem tüm diziyi kapsayacak biçimde yapılırken, yerel hizalamada belirli bir bölgeyi kapsayacak biçimde gerçekleştirilir.

DNA'nın değişimi

- Hizalama algoritmaları (bir açıdan da) DNA dizilerinin değişimini tahmine çalışır ve en olası biçimini bulmayı hedefler.
- Bu değişimlerin farklı sebepleri olabilir.
- Bunların başında tek nokta değişimleri (nucleotide substitutions) gelir.
- Bu değişimler kopyalama veya kimyasal kaynaklı olabilir.
- Küçük insersiyonlar ve delesyonlarda sıkça görülen bir başka değişim kaynağıdır.
- Daha büyük boyutlu değişimlerde DNA üzerinde görülse de (kopya sayısı değişimi, translokasyon, inversiyon vb.) bunlar büyük boyutlarından dolayı hizalama algoritmaları tarafından fark edilmesi çok zor olan değişimlerdir.

Boşlukların Önemi ve Skorlama

- İki basit nükleotit dizisini hizalamaya çalışmakla başlayalım, AGGCTAGTT ve AGCGAAGTTT.
- Birinci alternatifimiz;
- AGGCTA-GTT-
- AG-CGAAGTTT
- olsun. Burada 7 doğru eşleşme, 1 hatalı eşleşme ve 3 boşluk bulunmaktadır.
- İkinci alternatifimiz ise;
- AGGC-TA-GTT-
- AG-CG-AAGTTT
- olsun. Bu hizalamada ise 7 doğru eşleşme, 0 hatalı eşleşme ve 5 boşluk bulunmaktadır.
- Bunlardan hangisini tercih etmeliyiz?

Boşlukların Önemi ve Skorlama

- Açıkça görülüyor ki tercih yapabilmek için bir skarlama sistemine ihtiyacımız var.
- Bu skarlama sistemi her bir, doğru eşleşme, yanlış eşleşme ve boşluk için bir skor vermeli ve bunların toplamı ile toplam skoru elde etmeli.
- Örneğin, bir skarlama algoritması, m doğru eşleşmeler için s yanlış eşleşmeler için ve d boşluklar için verilen skoru temsil etme üzere aşağıdaki biçimde yazılabilir.
- $F = (\text{doğru eşleşme sayısı}) \times m - (\text{yanlış eşleşme sayısı}) \times s - (\text{boşluk sayısı}) \times d$

Boşlukların Önemi ve Skorlama

- Bu noktada sadece matematik değil biyoloji ile de bu probleme yaklaşmalıyız.
- Örneğin aşağıdaki gibi ardışık bir delesyon işlemi,
 - AATCTATA
 - AA--GATA
- aşağıdaki biçimde, pek çok defa oluşan delesyonlardan,
 - AATCTATA
 - AA-G-ATA
- çok daha olasıdır.
- Bu durumu matematiksel olarak yeni açılan boşluklar için -3 puan verirken, devam eden boşluklar için -1 puan vererek gösterebiliriz.
- Skorlama algoritmaları geliştirilirken bu ve benzeri pek çok durum dikkate alınmalıdır.

Boşlukların Önemi ve Skorlama

- Bu noktada bir diğer alternatif yaklaşımda değişiklik sayısının kullanılması olabilir.
- En düşük değişiklik uzaklığı (minimal edit distance) adı verilen bu algoritma bir diziyi diğerine hizalamak için yapılan toplam değişiklik sayısını dikkate alır.
- Her bir yapılan değişiklik için bir ceza skoru uygulayan algoritma sonucunda en az ceza skoru alan hizalama seçilir.

Proteinler için Skorlama Matrisleri

- DNA eşleşmeleri için genel geçer skorlar kullanabiliyoruz, ancak proteinleri oluşturan amino asitlerin hizalanmasında farklı kimyasal, fiziksel ve evrimsel şartlar göz önünde bulundurulmalıdır.
- Örneğin alanin aminoasit ile valin mi yoksa lizin mi hizalanmalıdır?
- Alanin ve valin küçük ve hidrofobiktir, lizin ise büyük ve suyu çeken bir yapıdadır.
- Bu durum göz önüne alındığında doğada ilk değişimin daha çok görüldüğü söylenebilir.
- Bu değişimlerin görülme sıklıklarından yola çıkarak skorlama matrisleri tanımlanabilir.
- PAM (Percent Accepted Mutation) ve BLOSUM (BLOck SUBstitution Matrix) bu işlem için en çok kullanılan matrislerdir.
- Aşağıda PAM matrisinin bir örneği yer almaktadır.

Proteinler için Skorlama Matrisleri

- Bu örnekte de görüldüğü üzere kimi yanlış eşleşmeler negatif değer alırken, kimileri de pozitif değerler almaktadır.
- Ayrıca aynı aminoasitlerin eşleşmeleri de farklı değerler ile ifade edilmektedir.
- Örneğin W-W eşleşmesi en yüksek puan olan 17 değeri alırken A-A eşleşmesi 2 değerini almaktadır.
- PAM matrisinin numarasında yer alan 1.0 puan, bir proteindeki amino asit dizisinde %1 lik değişime sebep olan evrim miktarına karşılık gelmektedir.
- PAM(X) şeklinde numaralandırılan matrisdeki, X birbirine evrimsel olarak yakın proteinlerin X miktarda evrimsel çeşitlilik içerdiği varsayımı ile matrisin hazırlandığını gösterir.
- Örneğin PAM1, protein dizileri arasındaki beklenen değişim miktarının %1 olduğunu gösterir.

Proteinler için Skorlama Matrisleri

- BLOSUM ise değişim gözlemlerinin frekanslarından yola çıkar.
- Bu frekanslar yerel hizalama bloklarındaki değişim miktarını gösterir.
- BLOSUM(X) biçiminde tanımlanan skorlamada X, matrisin oluşturulduğu sekansların maksimum benzerlik yüzdesini tanımlar.
- Örneğin BLOSUM62 matrisini oluşturan sekanslar en fazla %62 benzerlik içerir.
- Her iki matrisinde skorları bu değişimlerin görülme sıklıklarının, değişimlerin rastgele olma olasılığına ($1/20$) oranından (log odds ratio) yola çıkarak hesaplanır.

Proteinler için Skorlama Matrisleri

PAM

Global hizalamalar ile oluşturulmuştur.

Az miktarda veri ile oluşturulmuştur.

Global hizalamalarda ve evrimsel olarak yakın homologlarında daha iyi sonuç verir.

Yüksek numaralı versiyonları daha az benzeyen dizileri hizalamak için optimize edilmiştir

BLOSUM

Yerel hizalamalar ile oluşturulmuştur.

Büyük miktarda veri ile oluşturulmuştur.

Yerel hizalamalarda daha başarılıdır. Evrimsel olarak uzak homologlarında daha iyi sonuç verir.

Düşük numaralı versiyonları daha az benzeyen dizileri hizalamak için optimize edilmiştir

Proteinler için Skorlama Matrisleri

Table 1 - The log odds matrix for 250 PAMs (multiplied by 10)

[illegible]