

Yarı-Global Hizalama

- Global hizalamada iki dizinin baştan sona tüm elemanlarını hizalamız gerektiğini görmüştük.
- Ancak özellikle uzunlukları farklı dizileri hizalarken başlangıçtaki ve sondaki boşluklar aşağıdaki örnekteki gibi biyolojik olarak önemli olmayabilir.

AATCTATA
--TCT---

Yarı-Global Hizalama

- Bu amaçla baştaki ve sondaki boşlukları dizinin içindeki boşluklardan farklı değerlendirmemiz gerekir.
- Örneğin bu boşlukların önemsizliğini, söz konusu boşluklar için 0 puan uygulayabiliriz.
- Bir başka deyişle, ilk ve son, satır ile sütunda açtığımız her boşluk için uygulayacağımız boşluk cezası 0 olacaktır.
- Bunu, aşağıdaki biçimde formülize edebiliriz, a satır, b sütun sayısı olmak üzere, C(a,b) matrisinde, boşluklar için;

$$C(i,1) = \sum s(0,-), 1 \leq i \leq a$$

$$C(1,j) = \sum s(-,0), 1 \leq j \leq b$$

$$q_{diag} = C(i-1, j-1) + S(i, j)$$

$$q_{up} = C(i-1, j) + g$$

$$q_{left} = C(i, j-1) + g$$

Yarı-Global Hizalama

- $g=0$, eğer $i=a$ veya $j=b$ ise


		A	C	A	C	T	G	A	T	C	G
0	0	0	0	0	0	0	0	0	0	0	0
A	0	1	0	1	0	0	0	1	0	0	0
C	0	0	2	1	2	1	0	0	1	1	0
A	0	1	1	3	2	2	1	1	0	1	1
C	0	0	2	2	4	3	2	1	1	1	1
T	0	0	1	2	3	5	4	3	2	1	1
G	0	0	0	1	2	3	6	6	6	6	6

Yerel Hizalama

- Elimizde uzun bir DNA sekansı bulunduğunu varsayalım (örneğin 4000 bp).
- Bunun içinden 200 bp lik bir bölgenin, 12.5 Mbp uzunluğundaki bir maya genomundaki bir dizi ile eşleştirmeyi düşünelim.
- Bu durumda ne global hizalama ne de yarı-global hizalama bu eşleşmeyi bulabilmemiz için bize yardımcı olmayacaktır.
- Global hizalama baştan sona (her iki dizi için de) tüm diziyi eşleştirmeye çalışırken, yarı-global hizalama ise 4000 bp'lik dizinin tamamını arayacaktır 12.5 Mbp'lik dizi içinde.
- Bu durum için bize gereken her iki dizide de sadece belirli bölgeleri eşleştiren bir algoritmadır.
- Örneğin x ve y gibi iki dizide sadece belirli bölgeler eşleşiyorsa bu bölgelerin skorlama tablosu üzerinde gösterimi de, tablonun herhangi bir noktasında başlayıp başka bir noktasında bitecek biçimde olacaktır;

Yerel Hizalama


x = aaaacccccgggtta
y = tccccggaaccaacc



Yerel Hizalama

- Peki böyle bir durum için global hizalama algoritmamızı nasıl değiştirmemiz gerekir?
- Aşağıdaki şekilde bu sorunun cevabını bulabiliriz.
- Yarı-global hizalamada olduğu gibi ilgilenmediğimiz, yani bize negatif skor üreten eşleşmelere 0 puan verebiliriz.
- Ancak bu kez sadece başlangıç ve bitiş sütunlarına değil dizi içerisindeki tüm negatif skorlar için bu işlemi gerçekleştireceğiz.
- Böylece tablodaki en yüksek skordan başlayarak, aynı global hizalamada olduğu gibi 0 a doğru geriye takip işlemi uyguladığımızda yerel hizalama algoritmamızı bitirmiş olacağız.

Yerel Hizalama



Yerel Hizalama

- Bu değişikliği $F(a,b)$ eşleşme skoru olmak üzere aşağıdaki biçimde formülize edebiliriz;

$$\begin{aligned}
 & - F(i,0) = 0 \\
 & - F(0,j) = 0 \\
 & - F(i,j) = \max [0, \\
 & \quad F(i,j-1) + s(-,B(j)), \\
 & \quad F(i-1,j) + s(A(i,-), \\
 & \quad F(i-1,j-1) + s(A(i),B(j))]
 \end{aligned}$$

Yerel Hizalama

- Aşağıdaki örnek tabloda, doğru eşleşme 4, yanlış eşleşme 2 ve boşluklar -1 ile skorlansın.
- Bu durumda E Q L L K A L E F K L ve K V L E F G Y şeklinde iki dizi için tablomuzu şekildeki biçimde doldurabilir ve bunun sonucunda yine devam eden tablolarda gösterilen alternatif yerel hizalamaları elde ederiz;

Yerel Hizalama

- E Q L L K A L E F K L										
-	0	0	0	0	0	0	0	0	0	0
K	0	0	0	0	0	4	3	2	1	0
V	0	0	0	0	0	3	2	1	0	3
L	0	0	0	4	4	3	2	6	5	4
E	0	4	3	3	3	2	1	5	10	9
F	0	3	2	2	2	1	0	4	9	14
G	0	2	1	1	1	0	0	3	8	13
Y	0	1	0	0	0	0	0	2	7	12

- E Q L L K A L E F K L										
-	0	0	0	0	0	0	0	0	0	0
K	0	0	0	0	0	4	3	2	1	0
V	0	0	0	0	0	3	2	1	0	3
L	0	0	0	4	4	3	2	6	5	4
E	0	4	3	3	3	2	1	5	10	9
F	0	3	2	2	2	1	0	4	9	14
G	0	2	1	1	1	0	0	3	8	13
Y	0	1	0	0	0	0	0	2	7	12

- E Q L L K A L E F K L										
-	0	0	0	0	0	0	0	0	0	0
K	0	0	0	0	0	4	3	2	1	0
V	0	0	0	0	0	3	2	1	0	3
L	0	0	0	4	4	3	2	6	5	4
E	0	4	3	3	3	2	1	5	10	9
F	0	3	2	2	2	1	0	4	9	14
G	0	2	1	1	1	0	0	3	8	13
Y	0	1	0	0	0	0	0	2	7	12

Yerel Hizalama

- Aşağıdaki tabloda üç protein için farklı proteinlerle yapılan hizalama hesaplama skorlarını görebilirsiniz.
- Proteinler kendileriyle veya benzer proteinlerle hizalandıkları durumlarda, global hizalama ile daha yüksek skorlar elde edilirken,
- Birbirine uzak proteinler için yarı-global ve yerel hizalama skorları daha yüksektir.

Yerel Hizalama

PIR Entry				Similarity Score		
				Global		Local
				End Penalty	No End Penalty	
HBHU	vs	HBHU	Hemoglobin beta-chain—human	725	725	725
		HAHU	Hemoglobin alpha-chain—human	314	320	322
		MYHU	Myoglobin—Human	121	164	166
		GPYL	Leghemoglobin—Yellow lupin	8	28	43
		LZCH	Lysozyme precursor—Chicken	-107	16	32
		NRBO	Pancreatic ribonuclease—Bovine	-124	16	31
		CCHU	Cytochrome c—Human	-160	10	26
MCHU	vs	MCHU	Calmodulin—Human	671	671	671
		TPHUCS	Troponin C, skeletal muscle	395	430	438
		PVPK2	Parvalbumin beta—Pike	-57	103	115
		CHHUH	Calpain heavy chain—Human	-2085	89	100
		AQJFNV	Aequorin precursor—Jelly fish	-65	48	76
		KLWWM	Calcium binding protein—Scallop	-89	45	52
QRHULD	vs	EGMSG	Epidermal growth factor precursor	-591	475	655

Yerel Hizalama

- Bahsettiğimiz hizalama algoritmaları $O(mn)$ zaman ve alan karmaşıklığına sahiptir ki bu lineer artışı ile oldukça iyi bir değerdir.
- Hatta tam eşleşme yerine iki dizinin sadece uzaklığının hesaplanması $O(\max(m,n))$ karmaşıklığına sahiptir.
- Diğer taraftan hesaplama zamanını artırarak, gereken alanı azaltan hizalama algoritmaları da bulunmaktadır (Hirschberg, JACM 1977).
- Bütün bu düşük zaman ve alan karmaşıklığına rağmen 1 Megabaz boyunda iki genomun hizalanması için toplamda; $4 \cdot 10^6 \cdot 10^6 = 4 \text{ T}$ byte alan gerekmekte ve saniyede 1 Milyon işlem yapan 1 Ghz lik bir işlemci ile 10^{12} eşleşme yapılması yaklaşık 10 gün zaman gerektirmektedir.