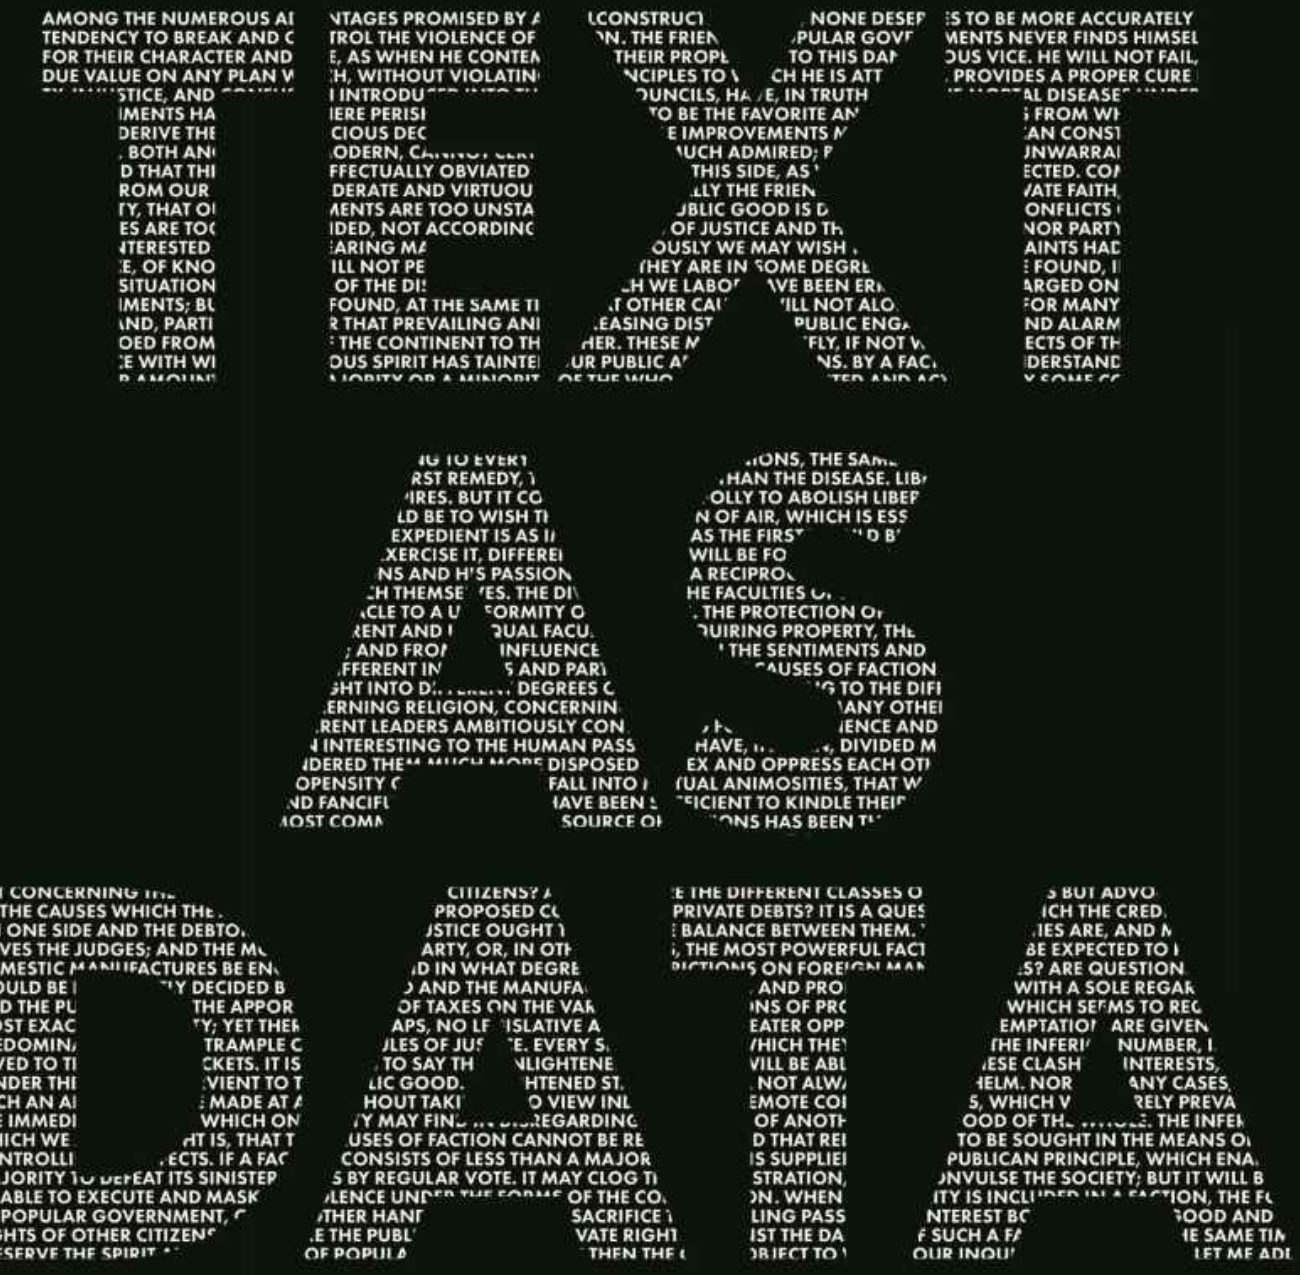


A New Framework for Machine Learning and the Social Sciences

Justin Grimmer | Margaret E. Roberts | Brandon M. Stewart

Doclingo https://www.doclingo.ai

Veri olarak Metin

Doclingo https://www.doclingo.ai

Veri olarak Metin

Makine Öğrenmesi ve Sosyal Bilim ler için Yeni Bir Çerçeve

JUSTIN GRIMMER
MARGARET E. ROBERTS
BRANDON M. STEWART

PRINCETON ÜNİVERSİTESİ BASIN
Princeton ve Oxford

Doclingo https://www.doclingo.ai

Telif Hakkı © 2022, Princeton University Press

Princeton University Press, yazarlarımızın bize emanet ettiği telif hakları ve fikri mülkiyetin korunmasına ka rarlıdır. Telif hakkı, bilginin ilerlemesini ve bütünlüğünü teşvik eder. Bu kitabın yetkili bir baskısını satı n alarak ifade özgürlüğünü ve fikirlerin küresel değişimini desteklediğiniz için teşekkür ederiz. Eğer kita bın herhangi bir kısmını herhangi bir biçimde çoğaltmak veya dağıtmak isterseniz, lütfen izin alın.

Bu eserden materyal çoğaltma izni talepleripermissions@press.princeton.e
du adresine gönderilmelidir.

Princeton University Press tarafından yayımlanmıştır
41 William Caddesi, Princeton, New Jersey 08540
99 Banbury Yolu, Oxford OX2 6JX

press.princeton.edu

Tüm Hakları SaklıdırIS

BN (bez kapak) 978-0-691-207544ISB
N (ciltsiz / karton kapak) 978-0-691-
207551ISBN (e-kitap) 978-0-691-20799

5Sürüm 1.0

Britanya Kütüphanesi Yayın İçi Kataloglama Verisi mevcuttur

Editörler: Meagan Levinson ve Jacqueline Delaney
Üretim: Erin Suydam
Halkla İlişkiler: Kate Hensley (ABD) ve Charlotte Coyne (İngiltere)

Doclingo https://www.doclingo.ai

Terese'ye
-JG

David'e
-DAHA

Candi ve Jerry'ye
-BMS

Doclingo https://www.doclingo.ai

İçindekiler

Önsöz xvii
Önkoşullar ve Gösterimler xvii
Bu Kitap için Kullanımlar xvii
Bu Kitap Ne Değildir xix

BÖLÜM I ÖN HAZIRLIKLAR 1

BÖLÜM 1 Giriş 3
1.1 Bu Kitap Sosyal Bilimleri Nasıl Bilgilendiriyor 5
1.2 Bu Kitap Dijital Beşeri Bilimleri Nasıl Bilgilendiriyor 8
1.3 Bu Kitap Veri Bilimini Sanayi ve Hükümette Nasıl Bilgilendiriyor 9
1.4 Bu Kitaba Bir Rehber 10
1.5 Sonuç 11

BÖLÜM 2 Sosyal Bilim Araştırmaları ve Metin Analizi 13
2.1 Keşif 15
2.2 Ölçüm 16
2.3 Çıkarım 17
2.4 Sosyal Bilimlerin Tekrarlayıcı ve Birikimli Bir Süreç Olarak 17
2.5 Metin Analizine Agnostik Bir Yaklaşım 18
2.6 Keşif, Ölçüm ve Nedensel Çıkarım: Çin Hükümeti'nin Sosyal Medyayı Sansürlemesi
2.7 Metin Analizinin Altı İlkesi
2.7.1 Sosyal Bilim Teorileri ve Önemli Bilgiler Araştırma Tasarımı İçin Temel Olmaktadır
2.7.2 Metin Analizi İnsanların Yerini Almaz—Onları Tamamlar
2.7.3 Sosyal Bilim Teorilerini İnşa Etmek, Geliştirmek ve Test Etmek Tekrar ve Birikim Gerektirir
2.7.4 Metin Analizi Yöntemleri Dilden Genellemeler Elde Eder

Doclingo https://www.doclingo.ai

2.7.5 En İyi Yöntem Göreve Bağlıdır
2.7.6 Doğrulamalar Temel Olup Teori ve Göreve Bağlıdır

2.8 Sonuç: Metin Verisi ve Sosyal Bilim

BÖLÜM II SEÇİM VE TEMSİL33

BÖLÜM 3Seçim ve Temsil İlkeleri35
3.1 İlke 1: Soruya Özgü Korpus Oluşturma35
3.2 İlke 2: Değerlerden Arındırılmış Korpus Oluşturma Yoktur36
3.3 İlke 3: Metni Temsil Etmenin Doğru Bir Yolu Yoktur37
3.4 İlke 4: Doğrulama38
3.5 Birlik Konuşmaları38
3.6 Federalist Yazılarının Yazarlığı39
3.7 Sonuç40

BÖLÜM 4Belgelerin Seçimi41
4.1 İlgilenilen Nüfuslar ve Büyüklükler42
4.2 Dört Tür Yanlılık43
4.2.1 Kaynak Yanlılığı43
4.2.2 Teşvik Yanlılığı44
4.2.3 Ortam Yanlılığı44
4.2.4 Alım Yanlılığı45
4.3 "Bulunan Veri" Üzerine Düşünceler46
4.4 Sonuç46

BÖLÜM 5Kelime Torbası48
5.1 Kelime Torbası Modeli48
5.2 Analiz Birimini Seçin49
5.3 Tokenleştirme50
5.4 Kompleksiteyi Azalt52
5.4.1 Küçük Harf Yap52
5.4.2 Ünlem İşaretlerini Kaldır52
5.4.3 Durak Kelimeleri Kaldır53
5.4.4 Eşdeğer Sınıflar Oluştur (Lemmatize/Stem) 54
5.4.5 Sıklığa Göre Filtrele55
5.5 Belge-Özellik Matrisini Oluştur55
5.6 Varsayılanları Yeniden Düşünmek57
5.6.1 Federalist Yazılarının Yazarlığı57

Doclingo https://www.doclingo.ai

5.6.2 Önişleme Karşısındaki Ölçek Argümanı58
5.7 Sonuç59

BÖLÜM 6 Çoklu Dağılım Dili Modeli60
6.1 Çoklu Dağılım61
6.2 Temel Dil Modelleme63
6.3 Düzenleme ve Düzleştirme66
6.4 Dirichlet Dağılımı66
6.5 Sonuç69

BÖLÜM 7 Vektör Uzayı Modeli ve Benzerlik Ölçüleri70
7.1 Benzerlik Ölçüleri70
7.2 Mesafe Ölçüleri73
7.3 tf-idf Ağırlığı75
7.4 Sonuç77

BÖLÜM 8 Kelimelerin Dağıtılmış Temsilleri78
8.1 Neden Kelime Gömme79
8.2 Kelime Gömme Tahmini81
8.2.1 Kendinden Denetim İçgörüsü81
8.2.2 Kelime Gömmede Tasarım Seçenekleri81
8.2.3 Gizli Anlamsal Analiz82
8.2.4 Sinirsel Kelime Gömme82
8.2.5 Önceden Eğitilmiş Gömme84
8.2.6 Nadir Kelimeler84
8.2.7 Bir İllüstrasyon85
8.3 Kelime Gömülerinin BelgeDüzeyine Toplanması86

8.4 Doğrulama87
8.5 Bağlamsal Kelime Gömüleri88
8.6 Sonuç89

BÖLÜM 9Dil Dizilerinden Temsiller90
9.1 Metin Yeniden Kullanımı90
9.2 Konuşma Parçaları Etiketleme91
9.2.1 Görselleştirmeyi İyileştirmek İçin İfadeler Kullanma92
9.3 Adlandırılmış Varlık Tanıma94
9.4 Bağımlılık Analizi95
9.5 Daha Geniş Bilgi Çıkarma Görevleri96
9.6 Sonuç97

Doclingo https://www.doclingo.ai

BÖLÜM III KEŞİF99

BÖLÜM 10 Keşif İlkeleri103
10.1 İlke 1: Bağlamın Önemi103
10.2 İlke 2: Gerçek Doğru Yok104
10.3 İlke 3: Yöntemi Değil, Kavramı Yargıla105
10.4 İlke 4: Ayrı Veriler En İyisidir106
10.5 ABD Kongresi'ni Kavramsallaştırma106
10.6 Sonuç109

BÖLÜM 11 Ayrımcı Kelimeler111
11.1 Karşılıklı Bilgi112
11.2 Kavga Kelimeleri115
11.3 Hayali Tahmin Problemleri118
11.3.1 Standartlaştırılmış Test İstatistikleri Ayrım Ölçüleri Olarak 118
11.3.2 χ 2 Test İstatistikleri118
11.3.3 Çok Değişkenli Ters Regresyon121
11.4 Sonuç121

BÖLÜM 12 Kümeleme123
12.1 *k*-Ortalamalı Kümeleme124
12.2 Kümeleme için Temsiller127
12.3 Kümeleme Yaklaşımları127
12.3.1 Bir Kümeleme Yönteminin Bileşenleri128
12.3.2 Kümeleme Yöntemlerinin Tarzları130
12.3.3 Olasılıksal Kümeleme Modelleri132
12.3.4 Algoritmik Kümeleme Modelleri134
12.3.5 Olasılıksal ve Algoritmik Kümeleme Arasındaki Ba ğlantılar137
12.4 Seçimler Yapmak137
12.4.1 Model Seçimi137
12.4.2 Dikkatli Okuma140
12.4.3 Küme Sayısını Seçme140
12.5 Kümeleme'nin İnsan Tarafı144
12.5.1 Yorumlama144
12.5.2 Etkileşimli Kümeleme144
12.6 Sonuç145

BÖLÜM 13 Konu Modelleri147
13.1 Gizli Dirichlet Tahsisi147

Doclingo https://www.doclingo.ai

13.1.1 Çıkarım149
13.1.2 Örnek: Kongre Basın Bültenlerinde Yangın Hibeleri için Kredi Talep Etme Keşfi 149
13.2 Konu Modellerinin Çıktısını Yorumlama151
13.3 LDA'ya Yapı Entegre Etme153
13.3.1 Yukarıdan, Bilinen YaygınlıkKovaryantlar ile Yapı154
13.3.2 Yukarıdan, Bilinen İçerikKovaryantlar ile Yapı154
13.3.3 Aşağıdan, BilinenKovaryantlar ile Yapı156
13.3.4 Yapının Ekstra Kaynakları157
13.4 Yapısal Konu Modelleri157
13.4.1 Örnek: Radikal Söylemin Bileşenlerini Keşfetme159
13.5 Konu Modellerini Etiketleme159
13.6 Sonuç160
BÖLÜM 14 Düşük Boyutlu Belge Gömme162
14.1 Temel Bileşen Analizi163
14.1.1 Ana Bileşenlerin Etiketlenmesi için Otomatik Yöntemler 164
14.1.2 Ana Bileşenlerin Etiketlenmesi için Manuel Yöntemler 164
14.1.3 Senato Basın Bültenlerinin Ana Bileşen Analizi 164
14.1.4 Ana Bileşen Sayısının Seçimi 165
14.2 Klasik Çok Boyutlu Ölçekleme167
14.2.1 Klasik MDS'nin Uzantıları168
14.2.2 Klasik MDS'yi Senato Basın Bültenlerine Uygulama 168
14.3 Sonuç169
BÖLÜM IV ÖLÇÜM171
BÖLÜM 15 Ölçüm İlkeleri173
15.1 Kavramdan Ölçüme174
15.2 İyi Bir Ölçüm Neyi Oluşturur174
15.2.1 İlke 1: Ölçülerin net hedefleri olmalıdır175
15.2.2 İlke 2: Kaynak materyali her zaman

Doclingo https://www.doclingo.ai

belirlenmiş ve ideal olarak kamuya açık hale getirilmiş175
15.2.3 İlke 3: Kodlama süreci açıklanabilir ve yeniden üretileb ilir olmalıdır175
15.2.4 Prensip 4: Ölçüm doğrulanmalıdır175
15.2.5 İlke 5: Sınırlamalar araştırılmalı, belgelenmeli ve iletilmelid ir.
izleyici176
15.3 Keşif ve Ölçümü ÖrnekBölmeleri ile Dengeleme176

BÖLÜM 16 Kelime Sayma178
16.1 Anahtar Kelime Sayma178
16.2 Sözlük Yöntemleri180
16.3 Sözlük Yöntemlerinin Sınırlamaları ve Doğrulamaları 181
16.3.1 Sözlüklerin Ötesine Geçmek: Kelime Skorları182
16.4 Sonuç183

BÖLÜM 17 Denetimli Sınıflandırmaya Genel Bakış184
17.1 Örnek: Tartışmalı Yönetim185
17.2 Bir Eğitim Seti Oluştur186
17.3 Denetimli Öğrenme ile Belgeleri Sınıflandır186
17.4 Performansı Kontrol Et187
17.5 Ölçüyü Kullanma187
17.6 Sonuç188

BÖLÜM 18 Bir Eğitim Setini Kodlama189
18.1 İyi Bir Eğitim Setinin Özellikleri190
18.2 Elle Kodlama190
18.2.1 1: Bir kod kitabı belirleyin191
18.2.2 2: Kodlayıcıları seçin191
18.2.3 3: Kodlanacak belgeleri seçin191
18.2.4 4: Kodlayıcıları yönetin192
18.2.5 5: Güvenilirliği kontrol edin192
18.2.6 Saptırmayı Yönetme192
18.2.7 Örnek: Haberi Yapmak192
18.3 Kitle Kaynak Kullanımı193
18.4 Bulunan Verilerle Denetim195
18.5 Sonuç196

BÖLÜM 19 Denetimli Öğrenme ile Belgeleri Sınıflandırma197

Doclingo https://www.doclingo.ai

19.1 Naif Bayes198
19.1.1 Naif Bayes'teki Varsayımlar Neredeyse Kesinlikle Yanlış200
19.1.2 Naif Bayes Üretken Bir Modeldir200
19.1.3 Naif Bayes Doğrusal Bir Sınıflandırıcıdır201
19.2 Makine Öğrenmesi202
19.2.1 Sabit Temel Fonksiyonlar203
19.2.2 Uyarlanabilir Temel Fonksiyonlar205
19.2.3 Nicelendirme206
19.2.4 Rastgele Örneklerle Denetimli Öğrenme Üzerine Son Düşünceler 207
19.3 Örnek: Cihad Puanlarını Tahmin Etme207
19.4 Sonuç210

BÖLÜM 20 Performansı Kontrol Etme211
20.1 Altın Standart Verilerle Doğrulama211
20.1.1 Doğrulama Seti212
20.1.2 Çapraz Doğrulama213
20.1.3 Altın Standart Verinin Önemi213
20.1.4 Süregelen Değerlendirmeler214
20.2 Altın Standart Verisi Olmadan Doğrulama214
20.2.1 Yerine Geçen Etiketler214
20.2.2 Kısmi Kategori Tekrarı215
20.2.3 Uzman Olmayan İnsan Değerlendirmesi215
20.2.4 Dış Bilgi ile Uyum215
20.3 Örnek: Cihad Puanlarını Doğrulama216
20.4 Sonuç217

BÖLÜM 21 Keşif Yöntemlerini Yeniden Kullanma219
21.1 Denetimsiz Yöntemler, İnceliklerden Daha İyi Ölçme Eğilimindedir 219
21.2 Örnek: Diferansiyel Kelime Oranları ile Ölçeklendirme220
21.3 Ölçüm için Denetimsiz Yöntemlerin Yeniden Kullanımı için Bir İş Akışı221
21.3.1 1: Veriyi Böl223
21.3.2 2: Modeli Uygula223
21.3.3 3: Modeli Doğrula223
21.3.4 4: Test Verisine Uygula ve Yeniden Doğrula225
21.4 Ölçüm için Denetimsiz Yöntemlerin Yeniden Kullanımındaki En dişeler225
21.4.1 Endişe 1: Yöntem her zaman bir

Doclingo https://www.doclingo.ai

sonuç döndürür226
21.4.2 Endişe 2: Tahmin stratejilerindeki belirsiz farklılıklar226
21.4.3 Endişe 3: Anlaşılması zor hiperparametrelere duy arlılık227
21.4.4 Endişe 4: Sonuçlardaki Dengesizlik227
21.4.5 İstikrarı Yeniden Düşünmek228
21.5 Sonuç229

BÖLÜM V ÇIKARIM231

BÖLÜM 22 Çıkarım İlkeleri233
22.1 Tahmin233
22.2 Nedensel Çıkarım234
22.2.1 Nedensel Çıkarım Yerleri Tanımlama İlk235
22.2.2 Tahmin, Olacak Sonuçlarla İlgilidir, Nedensel Çıkarım Müdahalelerden Gelen Sonuçlarla İlgilidir235
22.2.3 Tahmin ve Nedensel Çıkarım Farklı Doğrulamalar Gerektirir236
22.2.4 Tahmin ve Nedensel Çıkarım Özelliklerini Farklı Kullanma Farklı237
22.3 Tahmin ve Nedensel Çıkarımı Karşılaştırma238
22.4 Tahmin ve Nedensel Çıkarımda Kısmi ve Genel Denge238
22.5 Sonuç240

BÖLÜM 23 Tahmin241
23.1 Tahminin Temel Görevi242
23.2 Tahmin ve Ölçüm Arasındaki Benzerlikler ve Farklılıklar243
23.3 Tahminin Beş İlkesi244
23.3.1 Tahmin edici özellikler sonucu neden olmak zorunda değil dir244
23.3.2 Çapraz doğrulama her zaman tahmin gücünün iyi bir ölçüs ü değildir244
23.3.3 Ortalama olarak daha doğru olmak her zaman daha iyi değildir ortalama246
23.3.4 Tahmin için modellerin yorumlanmasının pratik bir değeri olabilir 247
23.3.5 Tahminin uygulanması zor olabilir

Doclingo https://www.doclingo.ai

politika yapımına249
23.4 Veri Olarak Metin Kullanarak Tahmin: Örnekler249
23.4.1 Kaynak Tahmini253
23.4.2 Dilsel Tahmin254
23.4.3 Sosyal Tahmin256
23.4.4 Şu An Tahmini257
23.5 Sonuç259

BÖLÜM 24 Nedensel Çıkarım259
24.1 Nedensel Çıkarıma Giriş260
24.2 Tahmin ve Ölçüm ile Nedensel Çıkarım Arasındaki Benzerlikler ve F arklılıklar263
24.3 Metin ile Nedensel Çıkarımın Temel İlkeleri263
24.3.1 Nedensel çıkarımın temel sorunları, metinle çalışırken bile devam etmektedir263
24.3.2 Tedavi ve sonuç kavramsallaştırmamız, metinle nedens el çıkarımın kritik bir bileşeni olmaya devam etmektedir 264
24.3.3 Metinle nedensel çıkarım yapmanın zorlukları, ardışık bi lime olan ihtiyacı vurgulamaktadır264

24.4 Haritalama Fonksiyonu266
24.4.1 *g ile Nedensel Çıkarım*267
24.4.2 Tanımlama ve Aşırı Uydurma268
24.5 Metin ile Nedensel Çıkarımlar Yapma İş Akışları269

24.5.1 Belgeleri İncelemeye Bakmadan Önce *g* Tanımlayın269
24.5.2 Bir Eğitim/Test Ayrımı Kullanma269
24.5.3 Ardışık Deneyler Yapma271
24.6 Sonuç271

BÖLÜM 25 Metin Sonuç Olarak272
25.1 Göç Üzerine Bir Deney272
25.2 Başkanlık Kamu Çağrılarının Etkisi275
25.3 Sonuç276

BÖLÜM 26 Metin Tedavi Olarak277
26.1 Trump'ın Tweet'lerini Kullanan Bir Deney279
26.2 Bir Aday Biyografisi Deneyi281
26.3 Sonuç284

BÖLÜM 27 Metin olarak Karıştırıcı285

Doclingo https://www.doclingo.ai

27.1 Metin Karıştırıcılar için Regresyon Ayarlamaları287
27.2 Metin için Eşleştirme Ayarlamaları290
27.3 Sonuç292

BÖLÜM VI SONUÇ295

BÖLÜM 28 Sonuç297
28.1 Sosyal Bilimlerde Metni Veri Olarak Nasıl Kullanılır298
28.1.1 Sosyal Bilim Görevlerine Odaklanma298
28.1.2 Sosyal Bilimlerin Yinelemeli ve Sıralı Doğası Sciences 298
28.1.3 Model Şüpheciliği ve Makine Öğrenmesinin Sosyal Bilimlere Uygulanması299
28.2 Metin Verisinin Ötesinde İlkelerimizi Uygulamak299
28.3 Sosyal Bilim Metodolojisinde Yaratım ve Yıkım Döngüsünden Kaçınmak300

*Teşekkürler*303
*Kaynakça*307
*Dizin*331

Doclingo https://www.doclingo.ai

Önsöz

Son on yılda, veri olarak metin yöntemleri sosyal bilimler, dijital beşeri bilimler ve sanayide popülaritesini artırmıştır. Bol miktarda veri, yeni yöntemler ve azal an hesaplama maliyetleri, belgelerdeki değerli verileri açığa çıkarmayı giderek daha mümkün hale getirmiştir. Daha fazla veri, daha iyi yöntemler ve daha hızl ı bilgisayarlar yönündeki bu eğilimler yalnızca artacaktır. Ancak, bu araçların s osyal bilimlerde geçerli çıkarımlar yapmak için uyarlanması gerekmektedir.
Bu kitap, bu ilerlemeleri kullanarak hem şimdi hem de gelecekte insan dav ranışları hakkında çıkarımlar yapma rehberidir.

Doclingo https://www.doclingo.ai

Önkoşullar ve Gösterimler

Okuyucuların bu kitaba çeşitli teknik geçmişler ve ilgi alanlarıyla gelmesi muh temeldir. Mümkün olduğunca geniş bir kitleye hitap etmek için, yalnızca lineer re gresyon bilgisine sahip olduğumuzu varsayıyoruz. Görünüşte oldukça farklı tekni klerin ortak yönlerini vurgulamak için, mümkün olduğunca ortak bir gösterim sis temine bağlı kalıyoruz ve bunu bir liste halinde özetliyoruz.

Doclingo https://www.doclingo.ai

Notasyon Listesi

- N: belge sayısı
- i: belgelerin indeksi
- M: bir belgede bulunan token sayısı
- m: belgede bulunan tokenlerin indeksi
- J: toplam özellik sayısı
- j: özelliklerin indeksi
- K: toplam bileşen sayısı
- k: bileşenlerin indeksi
- D i: belge i için metin, biçimlendirme veya ilgi çekici herhangi bir ek bilgi içeren soyut bir temsil
- W: N × J belge-özellik matris
- W i ,: belge i row belge-özellik matrisinde
- W , j: belge-özellik matrisinin sütunu j
- W i j: W hücresi i ve sütun j
- Z: gizli değişkenlere kelime düzeyinde atama
- π: N × K matris belge ağırlıkları/yüklemeleri gizlideğişkenler üzerinde tanımlayan
- π i k: belge i'nin özellik k *üzerindeki ağırlığı/yüklemesi*
- μ: tahmin edilen merkez, faktör veya diğer merkezi eğilim ölçüsü
- g: metin alanından (metin bir sonuçsa y i, metin bir tedavi ise t i olarak gösterilir) temsil alanına haritalayan bir fonksiyon, genellikle K uzunlukta bir vektördür
- y i: hedef etiket/ölçü/durum
- X: N × P boyutunda metin dışı meta veriler ve genel kovaryatlar matrisi
- X i: belge için genel kovaryatların bir vektörü i (virgül, X s
- ŷ i: y i için tahmin veya uyumlu değer
- β: sonraki analizlerden regresyon katsayıları
- λ: bağlayıcılık parametresi veya bağlama oranı, bağlama göre değişir
- σ 2: varyans
- p (·): genel bir belirtilmemiş olasılık dağılımı
- ϕ: diğer tüm rahatsızlık parametreleri
- I: eğitim setindeki belgeler için indeks, veya örnek içinde
- O: test setindeki belgeler için indeks, veya örnek dışında

Doclingo https://www.doclingo.ai

Bu Kitabın Kullanımları

Bu, esasen metni veri olarak kullanırken dikkate alınması gereken araştırma tasarımı ve faktörler hakkında bir kitaptır. Üç geniş kullanım senaryosu öngörüyoruz.

Bir Derste. Kitabın daha önceki taslaklarını kendi ileri lisans ve lisansüstü derslerimizde kullandık. Bu öğrencilerin birçoğunun makine öğrenmesi yöntemleri veya hesaplamalı teknikler konusunda az bir deneyimi var. Bu okuyucular için kitabımız, metni veri olarak kullanma tekniklerine bir giriş sağlamakta ve bu tekniklerin sosyal bilimlerde çıkarım yapmak için nasıl uygulanacağına dair bir bakış sunmaktadır. Böyle bir ders, doğal olarak araştırma yolculuğumuzu takip ederek düzenlenmiştir: temsil, keşif, ölçüm ve çıkarım. Her bölümde birkaç örnek yöntemle açıklama yapıyoruz, ancak derslerin bu kitabı, ek yöntemlerin veya eğitmenin tercih ettiği dildeki en son yazılım uygulamalarının detaylarına daha derinlemesine bir dalışla tamamlayacağını bekliyoruz.

Veri olarak Metin'in Ne Yapabileceğine Dair Birleştirici Bir Bakış. Bazı okuyucular, kendi çalışmalarından veya ilgili makaleleri okumaktan dolayı veri olarak metin teknikleriyle tanışık olabilirler. Kitabımız, veri olarak metin yöntemlerinin üstesinden gelebileceği birçok görevi özetlemekte ve bu heyecan verici literatürle etkileşim kurmak için bir başlangıç noktası sunmaktadır. Sadece bir görevi keşfetmek isteyenler için, dünya görüşümüzü ve her bölümün nasıl bir araya geldiğine dair bir his için Bölüm 2'yi okumayı öneriyoruz.

Araştırma İlkeleri Bildirisi. Belki de en önemlisi, bu kitabı sosyal bilimlerde makine öğrenimi yöntemlerinin kullanımı hakkında bir bildiri olarak görüyoruz. Makine öğrenimi ve veri olarak metin yöntemleriyle tanışık olan araştırmacılar için, kitabımız sosyal bilim görevlerini nasıl organize edeceğimiz ve bu görevleri nasıl değerlendireceğimiz hakkında bir bakış sunmaktadır. Makine öğrenimi konusunda geniş bir geçmişe sahip okuyucular bile, bu araçları araştırma tasarımıyla entegre etme konusunda yeni en iyi uygulamalar bulabilirler. Araştırma tasarımı hakkındaki düşüncelerimizin çoğu Bölüm 2'de ve ilkelerle ilgili bölümlerde (3, 10, 15 ve 22) yoğunlaşmıştır.

Doclingo https://www.doclingo.ai

Bu Kitap Ne Değildir

Veri olarak metin, hızla gelişen bir alandır ve en son teknoloji kol ayca değişebiliraltı ay içinde. Bu kitap, sosyal verilerle soruları yanıt lamak için metinleri kullanma araştırma tasarımına odaklanmakta dır; en son yöntemlerin veya yazılım uygulamalarının teknik detayl arına değil. Hemen çalıştırabilecekleri kod parçaları veya belirli bir t ekniğin teknik özelliklerine derinlemesine bir dalış isteyen okuyucu ların hayal kırıklığına uğrayabileceğini anlıyoruz. Ekstra teknik mat eryali derinlemesine kapsayan bir ders kitabı arayanlar için, makin e öğrenmesi için Murphy (2021) ve Bishop (2006); doğal dil işleme ve metinle makine öğrenmesi için Eisenstein (2019), Aggarwal (201 8) ve Jursfsky ile Martin (2009); ve uygulamaya başlamak için Silge ve Robinson (2017) ile yönlendirmekteyiz. Deneyimlerimize göre, k od ve teknik detaylar için bu tür harika kaynaklar zaten mevcuttur, ancak sosyal bilimlerde araştırma ve karar verme için önemli olanı açıklayan daha az kaynak bulunmaktadır.Bu kitapta amacımız, met ni veri olarak kullanma çabalarımızın temelini oluşturan çıkarım m antığını vurgulamaktır; sosyal dünyayı öğrenmek için.

Doclingo https://www.doclingo.ai

BÖLÜM I

Ön Hazırlıklar

Doclingo https://www.doclingo.ai

BÖLÜM 1

Giriş

Bu, metinlerin ve dilin insan davranışları hakkında çıkarımlar yapmak için kullanı mına dair bir kitaptır. Metni veri olarak kullanma çerçevemiz, sosyal bilim araştır malarını bilgilendirmekten, dijital beşeri bilimler alanındaki araştırmacılara rehb erlik sunmaya, sanayideki sorunlara çözümler sağlamaya ve hükümetin karşılaştı ğı sorunları ele almaya kadar geniş bir kitleye yöneliktir. Bu kitap, dilin sosyal etk ileşimin önemli bir bileşeni olması nedeniyle, çok çeşitli akademisyenler ve uygul ayıcılar için geçerlidir; yasaların nasıl kaydedildiği, dini inançların nasıl ifade edild iği ve tarihi olayların nasıl raporlandığıdır. Dil ayrıca bireylerin temsilcilere şikaye tlerini iletmesi, organizatörlerin protestoya katılmaları için vatandaşlarına seslen mesi ve reklamcıların tüketicileri ürünlerini satın almaya ikna etmesi için de kulla nılır. Ancak, nicel sosyal bilim araştırmaları, metinleri şaşırtıcı bir şekilde az kulla nmıştır - ta ki yakın zamana kadar.

Metinler, ölçekle çalışmanın zorluğu nedeniyle sınırlı bir şekilde kulla nıldı. İnsanların yazdığı ve söylediği her şeyi toplamak ve transkribe et mek için net bir yol olmadığı için belgeleri edinmek zordu. Metinler edi nilebilse bile, milyarlarca kelimeyle dolu belge koleksiyonlarını okumak imkansız derecede zaman alıcıydı. Ve okumak mümkün olsa bile, metinl eri ilgili kategorilere organize etmek veya ilgi alanındaki kavramların va rlığını ölçmek genellikle imkansız bir görev olarak algılanıyordu.

Şaşırtıcı bir şekilde, metinler sosyal bilimlerin kanıt temeli içinde merkezi bir rol o ynamadı. Ve metinler kullanıldığında, kullanım ya küçük veri setlerinde ya da büy ük, iyi finanse edilmiş araştırma ekiplerinin ürünü olarak gerçekleşti.

Son zamanlarda, büyük metin koleksiyonlarını analiz etmenin maliyetinde dramatik bir değişim oldu. Sosyal bilimciler, dijital beşeri bilimler akademisyenleri ve endüstri profesyonelleri artık belgeler koleksiyonlarını rutin olarak kullanıyorlar. Milyonlarca sosyal medya mesajı, milyarlarca kelime ve dünyanın en büyük fiziksel kütüphanelerinden daha büyük kitap koleksiyonları kullanan makaleleri görmek yaygın hale geldi. Bu değişimin bir kısmı teknolojik oldu. İnternetin hızlı genişlemesiyle, metinler edinilmesi çok daha kolay hale geldi. Aynı zamanda, hesaplama gücü arttı—dizüstü bilgisayarlar, daha önce sunucuların gerektirdiği hesaplamaları gerçekleştirebiliyordu. Değişimin bir kısmı da metodolojikdi. Önce bilgisayar bilimlerinde ve hesaplamalı dilbilimde, daha sonra sosyal bilimler ve dijital beşeri bilimlerde gelişen bir literatür, metinlerin ölçekli analizini ve organizasyonunu kolaylaştıran araçlar, modeller ve yazılımlar geliştirdi.

Doclingo https://www.doclingo.ai

ve hesaplamalı dilbilim, ve daha sonra sosyal bilimler ve dijital beşeri bil imler—ölçekli metinlerin analizi ve organizasyonunu kolaylaştıran araçl ar, modeller ve yazılımlar geliştirdi.

Hemen hemen tüm büyük ölçekli metin analizi uygulamaları sosyal bilimlerde , ya bilgisayar bilimlerinde ilk geliştirilen algoritmaları ya da bu gelişmelere yakın bir şekilde inşa edilenleri kullanmaktadır. Örneğin, siyasi bilim alanında birçok makale—kendi makalelerimiz de dahil—konu modellerine (Blei, Ng ve Jordan, 20 03; Quinn ve diğ., 2010; Grimmer, 2010; Roberts ve diğ., 2013) dayanmakta veya belge sınıflandırması için denetimli öğrenme algoritmaları kullanmaktadır (Joach ims, 1998; Jones, Wilkerson ve Baumgartner, 2009; Stewart ve Zhukov, 2009; Pan ve Chen, 2018; Barberá ve diğ., 2021). Sosyal bilimciler de metodolojik katkılar kendileri ve bu kitapta yeni tür görevleri başarmak iç in tasarlanmış birçok yeni modeli sergileyeceğiz. Bu katkıların birçoğu so syal bilimlerden bilgisayar bilimlerine akmıştır. Oylama kayıtlarını analiz e tmek için kullanılan istatistiksel modeller, örneğin Madde Yanıt Teorisi m odelleri, artık birkaç bilgisayar bilimi makalesinde kullanılmaktadır (Clinto n, Jackman ve Rivers, 2004; Gerrish ve Blei, 2011; Nguyen ve diğ.) 2015). Sosyal bilimciler, bilgisayar bilimcilerin araçlarını ve tekniklerini sosyal bilim sorularına geniş bir şekilde uyarlamıştır.

Ancak, bilgisayar bilimi ve ilgili alanlardan bilgi transferi, metin verisi modellerinin nasıl uygulandığı, nasıl doğrulandığı ve çıktılarının nasıl yo rumlandığı konusunda kafa karışıklığı yaratmıştır. Bu kafa karışıklığı, ak ademik bilgisayar bilimi görevlerinin sosyal bilimler, dijital beşeri biliml er ve hatta sanayinin bazı bölümlerindeki görevlerden farklı olmasında n kaynaklanmaktadır. Bilgisayar bilimcileri genellikle (ama sadece değil!) bilgi retrieval, öneri sistemleri ve benchmark dil görevleriyle ilgilenirke n, farklı bir topluluk "metin verisi" kullanarak sosyal bilimler, edebiyat v e tarih gibi daha önce incelenmiş fenomenler hakkında bilgi edinmekle ilgilenmektedir. Amaçlardaki bu farklılıklara rağmen, metin verisi uygul ayıcıları kendi çalışmalarını yaparken bilgisayar bilimi literatüründen ge len rehberliği refleksif bir şekilde benimseme eğiliminde olmuşlardır. Bi lgisayar bilimi literatüründen modelleri seçmek, değerlendirmek ve do ğrulamak için kullanılan varsayılan yöntemlerin ve uygulamaların kör bi r şekilde ithal edilmesi istenmeyen sonuçlara yol açabilir.

Bu kitap, "metin verisi"ni sosyal bilim görevleri ve sosyal bilim problemle ri için nasıl ele alacağımızı gösterecektir. Bu perspektifin, dijital beşeri bilim ler, sanayi ve hatta ana akım bilgisayar bilimi gibi sosyal bilimlerin ötesinde faydalı olabileceğini düşünüyoruz. Argümanımızı sosyal bilim araştırmaları nın temel görevleri etrafında organize ediyoruz: keşif, ölçüm, tahmin ve ne densel çıkarım. Keşif, yeni kavramsallaştırmalar yaratma sürecidir.

Doclingo https://www.doclingo.ai

ya da dünyayı organize etmenin yolları. Ölçüm, kavramların verilere bağlandığı süreçtir, bu da bize bu kavramların gerçek dünyadaki yaygınlığını tanımlama imkanı verir. Bu ölçümler daha sonra bazı müdahalelerin etkisi hakkında nedensel bir çıkarım yapmak veya gelecekteki değerleri tahmin etmek için kullanılır. Bu görevler bazen makine öğrenimi kitaplarını organize etmenin alışıldık yolunu tanımlayan bilgisayar bilimi görevleriyle ilişkilidir. Ancak göreceğimiz gibi, denetimli ve denetimsiz gibi belirli algoritma türleri arasında yapılan alışıldık ayrımlar, bu araçların sosyal bilim görevlerini başarmak için nasıl kullanıldığını gizleyebilir.

Sosyal bilimlerde veri olarak metin yöntemlerini geliştirme ve uygulama konusundaki deneyimimize dayanarak, araştırmaya sıralı, yinelemeli ve tümevarım bir yaklaşım vurguluyoruz. Deneyimimiz, sosyal bilimlerde en çok, kavramlarımızı ve ölçümlerimizi yinelemeli olarak rafine ettiğimizde, yeni verilere maruz kaldıkça tanımlarımızı geliştirdiğimizde öğreniyoruz. Ayrıca, kanıtlarımızı sıralı bir şekilde değerlendirdiğimizde, önceki çalışmaların sonuçlarını doğrulayıp, yeni hipotezler test ettiğimizde ve nihayetinde gelecekteki çalışmalar için hipotezler ürettiğimizde en çok öğreniyoruz. Gelecek çalışmalar bu modeli sürdürerek, önceki çalışmaların bulgularını doğrulamakta, önceki spekülasyonları test etmekte ve yeni hipotezler üretmektedir. Sürecin sonunda, kanıtlar bir araya getirilerek sonuçlar özetlenir ve ne öğrenildiği netleştirilir. Önemli olan, bu sürecin tek bir makale veya kitap bağlamında değil, işbirlikçiler topluluğu arasında gerçekleşmesidir.

Bu tümevarım yöntemi, araştırmaya yaklaşmak için ilkeli bir yol sunar ve incelenen sürecin evrilen anlayışına güçlü bir vurgu yapar. Bu anlayışa teori diyoruz—sosyal sürecin sistematik yönlerinin açıklamaları. Bu, resmi teori, politik/sosyolojik teori ve genel konu alanı uzmanlığını kapsayan kasıtlı olarak geniş bir tanımdır. Bu kitabın merkezinde, akademisyenlerin metinlerden insan davranışı hakkında çok şey öğrenebileceği, ancak bunu yapmanın, bu metinlerin üretildiği bağlamla etkileşimi gerektirdiği argümanı bulunmaktadır. Sosyal bilimler bağlamının derin bir anlayışı, araştırmacıların daha önemli ve etkili sorular sormalarını, çıkardıkları ölçümlerin geçerli olmasını sağlamalarını ve çalışmalarının pratik ve etik sonuçlarına daha dikkatli olmalarını sağlayacaktır.

Bu kitabı şimdi yazıyoruz çünkü metin verilerinin kullanımı kritik bir noktadadır. Daha fazla akademisyen, araştırmaları için metin verisi yöntemlerini benimsedikçe, sosyal bilimlerde metin verisi kullanımının bilgisayar bilimlerindeki kullanımından nasıl farklı olduğunu açıklamak için bir kılavuz gereklidir. Böyle bir kılavuz olmadan, bilgisayar bilimi dışındaki araştırmacılar, sorunları çözerken yanlış uygulama riskiyle karşı karşıya kalabilirler.

Doclingo https://www.doclingo.ai

algoritmalar, yanlış miktarları doğrulamak ve nihayetinde elde ettikleri kan ıtlarla haklı çıkarılmayan çıkarımlar yapmak.

Metinlere odaklanmamızın nedeni, bunların makine öğrenmesindeki son gelişmeleri ö ğrenmek için mükemmel bir araç olmalarıdır. Bu kitapta sosyal bilimler araştırmalarını na sıl organize edeceğimizle ilgili yaptığımız argüman, metinlerin ötesine geçmektedir. Gerçekten de, yaklaşımımızı genel olarak sosyal bilimler için yararlı görüyoruz, a ncak özellikle araştırmacıların büyük ölçekli verileri kullanarak yeni kategoriler ke şfettiği, bunların yaygınlığını ölçtüğü ve ardından dünyadaki ilişkilerini değerlend irdiği her uygulamada.

Doclingo https://www.doclingo.ai

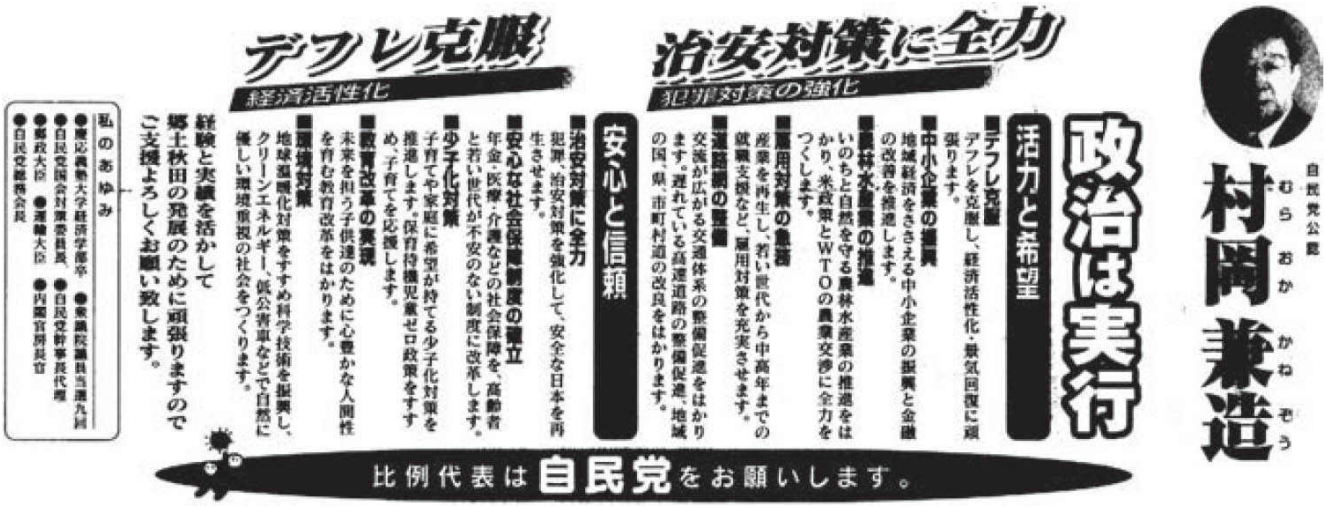
1.1 Bu Kitap Sosyal Bilimleri Nasıl Bilgilendiriyor

Bu kitabın merkezi bir argümanı, metin olarak veri araştırmasının amacının bi lgisayar bilimi çalışmalarının hedeflerinden farklı olduğudur. Neyse ki, bu fark, di ğer alanlarda ilk geliştirilen birçok araç ve fikrin metin olarak veri problemlerine uygulanamayacak kadar büyük değildir. Ancak, bu, o modelleri uygulamaktan ne öğrendiğimiz konusunda daha dikkatli düşünmemiz gerektiği anlamına gelir.

Davamızda bize yardımcı olmak için, siyasi bilimci Amy Catalinac'ın (Catalina c, 2016*a*) metinleri kullanışını düşünün - seçim bölgesi yapısının siyasi adayları n davranışını nasıl etkilediğine dair çığır açan bir gösterim. Bu kitaba odaklanıy oruz çünkü metinler, analizi gerçekleştirmek için kullanılan algoritmanın farklı bir disiplinden gelmesine rağmen, sosyal bilimler açısından net, kesin ve etkili bir şekilde kullanılmaktadır. Ve önemli olarak, kullanılan doğrulama yöntemi b elirgin bir şekilde sosyal bilimsel ve kapsamlıdır.

Catalinac'ın çalışması bir bulmacayla başlıyor: Japon politikacıları neden 1 997'den sonra ulusal güvenlik ve dış politikaya bu kadar fazla dikkat ayırdı? 1997, II. Dünya Savaşı'ndan sonra askeri ve dış politika tartışmalarının kulla nımına getirilen önemli sosyal, politik ve hükümet kısıtlamalarına rağmen? Catalinac (2016*a*), Japon yasama organlarının nasıl seçildiğindeki 1 994 reformunun bu değişikliği açıkladığını savunuyor çünkü bu, po litikacıların karşılaştığı teşvikleri temelde değiştirdi. 1994 reformun dan önce, Japon yasama organları, her bölgenin birden fazla aday tarafından temsil edildiği bir sistemle seçiliyordu ve her parti, her bölgede çoğunluğu elde etmeye çalışarak birkaç aday çıkarıyordu. Aynı partiden birden fazla aday, ideolojik konularda birlikte rekabe t edemediği için, temsilciler mümkün olduğunca bölgeye en fazla y erel etki yaratan harcamaları—örneğin bir köprü inşası için—sağla yarak oy toplamaya çalışıyordu. 1994 sonrası yeni reform sistemi, ç ok üyeli bölgeleri ortadan kaldırdı ve bunları paralel bir sistemle de ğiştirdi: tek üyeli bölgeler—seçmenlerin bir adaya oy kullandığı—v e tüm ülke için temsilciler—seçmenlerin bir partiye oy kullandığı ve seçilen yetkililerin partinin listesinden seçildiği.Bu yeni sistem, par tilerin üyeleri üzerinde daha sıkı ideolojik disiplin uygulamasına ola nak tanıdı ve seçmenlerin tercihleri bireysel kişiliklerden ziyade par ti platformları hakkında daha az olmaya başladı. Böylece, argüman devam ediyor, reform yasama organlarının teşviklerini değiştirdi. Yerel konulara, yani yerel harcamalara odaklanmak artık dış politika gibi ulusal konulara odaklanmaktan daha az avantajlıydı.

Doclingo https://www.doclingo.ai



Şekil 1.1. 2003 yılından Kanezo Muraoka'nın bir aday manifestosu örneği, Şekil 3.7 Catalinac (2016*a*) kaynaklıdır.

Argüman, yineleme ve tümevarım yoluyla ilerlemektedir. Seçim kuralları ndaki değişikliğin seçim stratejisi üzerindeki etkisini anlamaya başlamak için, Catalinac orijinal bir veri seti topladı. 7,497 Japon Diet adayı manifestosu. Manifestolar, onun çalışması için neredeyse ideal veri dir: adaylar ve seçmenler için önemlidir, adayların kontrolündedir ve seçim kurallarındaki değişiklikten önce ve sonra tüm seçimler için tüm adaylar tarafından mevcuttur. Veri toplama ilkelerini Bölüm 4'te tartışıyoruz, ancak Catalinac'ın örnek çalışması, metin verileriyle çalışmanın en uygun verileri seçmek zorunda olmadığımız anlamına gelmediğini göstermektedir. Aksine, Catalinac, arşiv ziyaretleri yoluyla manifestoları bulmak ve bunları manuel transkripsiyon yoluyla dijitalleştirmek için titiz bir veri toplama sürecine girmiştir. Bu süreç tek başına yıllar almıştır.

Veriler elinde, Catalinac, ampirik bulmacasını araştırmak için ihtiyaç duyduğu verilerindeki kategorileri öğrenmek için tümevarım yaklaşımını kullanmaktadır: Seçim için aday olduklarında seçilmiş yetkililerin neyi tartıştığı. Catalinac, her bir manifestonun hangi konuya ait olduğunu ölçmek ve altında yatan bir konu setini keşfetmek için iyi bilinen bir istatistiksel model olan *cation* (LDA) kullanmaktadır—buna Bölüm 13'te geri döneceğiz. Catalinac'ın tanımladığı gibi,

> Tipik olarak, model iteratif olarak uyarlanır. Araştırmacı bazı konu sayıları belirler; modeli çalıştırır; her bir konunun yüksek olasılıkla ait olduğu kelimeleri ve belgeleri okuyarak çıktıları konuların doğasını belirler; ve bu konuların anlamlı olup olmadığına karar verir.... Benim yaklaşımım da iteratifti ve hipotezle rimle yönlendiriliyordu.

Doclingo https://www.doclingo.ai

(Catalinac, 2016*a*, s. 84)

4. Bölümde açıkladığımız gibi, metin verileri ile keşif, boş bir sayfayla başla mamız anlamına gelmez. Catalinac'ın önceki çalışmaları, niteliksel mülakatl ar ve Japon siyaseti konusundaki uzmanlığı, metinde yaptığı keşifleri şekille ndirmeye yardımcı oldu. Bu ön bilgiyi keşifte kullanabiliriz; teori ve sezgiler kategorilerimizi tanımlamada bir rol oynar, ancak veri de kendisi de öyle.

Catalinac, LDA'dan elde edilen model uyumunu, adayların domuz eti, po litika ve diğer ilgi alanlarıyla ilgili tartışmalarının yaygınlığını ölçmek için kul lanır. Bu kategorileri hangi konuların kapsadığını belirlemek için, Catalinac kapsamlı bir doğrulama sürecine girer. Önemli olan, onun doğrulamaları, L DA'nın köken aldığı bilgisayar bilimlerinde en yaygın olarak gerçekleştirilen doğrulamalar değildir. Bu doğrulamalar, LDA'nın bir dil modeli olarak nasıl işlediğine odaklanma eğilimindedir—yani, bir belgede görünmeyen kelim eleri ne kadar iyi tahmin edebildiğine. Catalinac'ın amacı için, modelin görü nmeyen kelimeleri tahmin edebilmesi önemli değildir—elinde tüm kelimel er var! Bunun yerine, onun doğrulamaları, modelinin ilginç ve sosyal bilims el görevine yararlı bir organizasyon ortaya çıkardığını göstermeye yönelikti r: bölgelerin yapısındaki bir değişikliğin adayların ve seçilmiş yetkililerin da vranışını nasıl etkilediğini değerlendirmek. Catalinac, iki geniş doğrulama t ürü ile ilgilenir.İlk olarak, modelin otomatik olarak keşfettiği belirli konuları n derinlemesine bir analizini yapar, modelin konuya atfettiği yüksek olasılık lı kelimeleri ve modelin her konu ile en uyumlu olduğunu belirttiği manifes toları okur. Bu analiz, okuyucuya bilgisayar tarafından keşfedilen konuların etiketlerinin ve yorumlarının hem geçerli hem de sosyal bilimsel görevine yardımcı olduğunu garanti eder. İkinci olarak, ölçümlerinin Japon siyaseti h akkında iyi bilinen gerçeklerle uyumlu olduğunu gösterir. Bu adım, manife stolardan gelen ölçümlerin öznel olmadığını veya diğer çalışmalarda incele nen süreçten çok farklı bir süreci yansıtmadığını garanti eder. Ayrıca, Catali nac'ın metinlere atfettiği etiketlerin, bu metinlerin içeriğinin geçerli yansım aları olduğuna dair daha fazla kanıt sağlar.

Elbette, Catalinac metinleri sadece kendi başlarına kategorize etmekle ilgilenmiyor—metinlere atanan kategorileri dünyayı öğrenmek için bir veri kaynağı olarak kullanmak istiyor. Özellikle, seçi m reformunun adayların koşarken tartıştıkları konulardaki kaymaya olan nedensel etkisini tahmin etmek istiyor. 1994 Bu amacı gerçekleştirmek için, doğrulanmış modelini ve dikkatli araştırma tasarımını kullanarak, seçim reformunun ortalama adayları domuz etine odaklanmaktan ulusal güvenliğe kaydırdığı iddiasını sürdürmekte.
Bu, nedensel çıkarım için özellikle zorlu bir ortamdır, çünkü reform tüm bölgelerde aynı anda değişiklikler yapmaktadır. 1994 reforml arından sonra ulusal güvenlik tartışmalarında önemli bir artış oldu ğunu pratikte gösterdikten sonra, Catalinac alternatif açıklamaları dışlamaya geçiyor.

Doclingo https://www.doclingo.ai

Ulusal güvenliği tartışması beklenen adaylarda ani bir artış olmadı ğını gösteriyor. Ayrıca, bu artışın partilerdeki ideolojik bir kaymayı yansıttığını da iddia etmiyor. Ve seçmenlerin aniden ulusal güvenli ği önceliklendiren adaylar istediklerine dair hiçbir kanıt olmadığını savunuyor.

Katalinac'ın (2016*a*) kısa incelemesi, sıralamanın, yinelemenin ve tümevarımın n asıl anlamlı ve teorik olarak önemli araştırmalara yol açabileceğini ortaya koymakt adır. Ayrıca, Katalinac, kitap boyunca geri döneceğimiz bir noktayı vurgulamaktadır ; metin olarak veri araştırmaları için doğrulamaların gerekli olduğu ve bilgisayar bil imlerindeki doğrulamalardan oldukça farklı göründüğüdür. Tahmine odaklanmak yerine, metin olarak veri araştırmacıları, modellerinin ilgi alanındaki kavramlara ne kadar iyi içgörüler sağladığına, ölçüm araçlarının belgeleri bu kurallara göre ne ka dar iyi sıraladığına ve doğru nedensel çıkarım veya tahmin için gereken varsayımla rın ne kadar iyi karşılandığına çok daha fazla ilgi duymaktadırlar. Bu noktalar, siyas i bilimin ötesine geçerek, sosyoloji (DiMaggio, 2015; Evans ve Aceves dahil) gibi ins an davranışını inceleyen diğer sosyal bilimcileri de kapsamaktadır.
2016; Fransızca, 2004), ekonomi (Gentzkow, Kelly ve Taddy, 2019), psikoloji (Schwartz ve diğ., 2013), ve hukuk (Livermore ve Rockmore, 2019).

Doclingo https://www.doclingo.ai

1.2 Bu Kitap Dijital Beşeri Bilimlere Nasıl Bilgi Verir

Veri olarak metin yöntemlerini uygulama görüşümüz, sosyal bilimler araştırmal arındaki deneyimimizle geliştirilmiş ve rafine edilmiştir. Ancak, metin olarak veri ya klaşımımızın diğer alanlara da faydalı içgörüler sağlayabileceğini savunacağız. Sosy al bilimlerde veri olarak metin yöntemlerinin meteoritik yükselişiyle paralel olarak, edebiyat, tarih ve beşeri bilimleri daha genel olarak incelemek için hesaplamalı ara çların kullanılmasına yönelik hızla artan bir ilgi olmuştur. Dijital Beşeri Bilimler olar ak adlandırılan bu gelişen alan, sosyal bilimlerde veri olarak metin ile birçok ortak noktaya sahiptir; çünkü bu alan, alandaki klasik soruları yanıtlamak için hesaplama lı araçlardan yararlanmaktadır.

Metin olarak veri yöntemlerinin kullanımı önemli ölçüde finans man çekmiştir ve edebiyat çalışmasına (Jockers,
2013; Piper, 2018; Underwood, 2019). Hesaplama araçları, türlerin doğası nı incelemek için kullanılmıştır (Rybicki ve Eder, 2011), şiirler (Long ve So, 2016), fikirlerin konturları (Berry ve Fagerjord, 2017) ve birçok diğerşey (Moretti, 2013). Bu alanda çalışan akademisyenler, sonuçlarına ulaşmak içinsosyal bilimlerdeki benzer prosedürleri takip eder ve benzer araçlar kullanır. Metinlerinisayılara dönüştürürler ve ardından diğer alanlarda n gelen modeller veya algoritmalaruygulayarak somut sonuçlara ulaşırl ar.

İnsanlık Bilimleri (DH) alanındaki akademisyenler insani bir gelenek ten gelse de, analizlerinin hedeflerinin kitabımızın çerçevesine nasıl u yduğunu göstereceğiz. Sonuç olarak, metni veri olarak kullanma yönt emleriyle geçerli çıkarımlar yapma konusundaki argümanımız, insani alanlardaki hesaplamalı araçların birçok uygulamasını kapsayacaktır. DH ile sosyal bilimler arasındaki önemli bir fark, dijital insani bilimciler in genellikle incelenen belirli metinle ilgili çıkarımlara ilgi duymasıdır; bu, metni başka, daha büyük bir sürecin göstergesi olarak görmekten ziyade. Sonuç olarak, dijital insani bilimler şimdiye kadar araştırma sü recinin keşif ve ölçüm adımlarına odaklanma eğiliminde olmuş, neden sel çıkarımlar veya tahminler yapmaya daha az dikkat etmiştir. Dijital i nsani bilimciler, metinlerindeki organizasyonlar hakkında yeni ve öne mli keşifler yapmak için büyük korpuslarını kullanmaktadırlar. Daha s onra bu miktarların yaygınlığını ölçmek için araçlar kullanırlar, özellikl erin yaygınlığının zamanla nasıl değiştiğini tanımlamak için veya bir k ategorinin zamanla ne kadar iyi tanımlandığını ölçmek için.

Herhangi bir alanda olduğu gibi, dijital beşeri bilimlerin geleceği hakkında önemli bir muhalefe t olmuştur. Bu muhalefetin bir kısmı kitabımızın kapsamının çok ötesinde yer almakta ve beşeri bili mlerin hesaplamalı araçlara açılmasının politik ve epistemolojik sonuçlarına odaklanmaktadır.

Doclingo https://www.doclingo.ai

Bunun yerine, hesaplamalı makalelerde belirlenen “kurallar” ile ilgili di jital beşeri bilimler üzerine diğer eleştirilerle ilgileneceğiz. Bu eleştirm enler, dijital beşeri bilimlerin belirlediği çıkarımsal hedeflere ulaşma k apasitesine sahip olmadığını ve bu nedenle analizin baştan başarısız o lduğunu savunmaktadır. Son zamanlarda öne çıkan bir itiraz, Da (201 9) tarafından gelmektedir; kendisi kendi argümanını şöyle özetlemekt edir,

> Kısacası, mevcut haliyle hesaplamalı edebi analizin sorunu, sağlam olanın (ampirik anlamda) açık olması ve açık olmayanın sağlam olmamasıdır; bu d urum, edebi verilerin doğası ve istatistiksel sorgulamanın doğası göz önün e alındığında kolayca aşılabilecek bir durum değildir.
>
> (Da, 2019, s. 45)

Da (2019)’nın eleştirisi, sonuçların nasıl değerlendirildiğinin kalbine inmekt edir ve bilgisayar bilimlerinden ithal edilen prosedürler ve en iyi uygulamal ara büyük ölçüde dayanmaktadır (eleştirdiği çalışmanın çoğu için de geçerl idir, belirtmek gerekir). Yukarıda savunduğumuz gibi, diğer alanlardan kur alları doğrudan yeni alanlarda metinleri incelemek için ithal etmek subopti mal olabilir. Bilgisayar bilimi ve istatistikten metin tabanlı çıkarımlara doğr udan önerileri ithal ettiğimizde, sorunlu çıkarımlar yapabilir, yanıltıcı öneril erde bulunabilir veya bir alan için hesaplamalı analizin uygulanabilirliği hak kında yanlış değerlendirmeler yapabiliriz.

Ancak Da'nın eleştirisi, dijital beşeri bilimlerdeki birçok çalışmadan ayrıla n yaklaşımımızın önemli bir özelliğini aydınlatmak için yararlı bir karşıtlık su nmaktadır. Bölüm 2'de, metinleri veri olarak ele alan yöntemlere dair daha geniş bir "radikal agnostik" görüşü yansıtan altı temel ilke sunuyoruz. Meti nlerin bir gerçek, içsel organizasyonunu geri kazanmak için metin modeller inin optimize edilmesi gerektiği fikrini reddediyoruz - çünkü, iddia ediyoruz ki, böyle bir organizasyon yoktur. Dijital beşeri bilimlerin çoğunda ve Da'nı n eleştirisinde, istatistiksel modellerin veya algoritmaların, araştırma sorus unun ve tahmin edilen modellerin dışında var olan verilerin ideal bir kateg orileşmesini ortaya çıkardığına dair örtük bir varsayım bulunmaktadır. Bu y aklaşım, beşeri bilimlerdeki birçok teorik çalışma ile çelişmektedir, ancak g örünüşe göre bu, bilgisayar bilimi ve istatistikteki birçok çalışmada motive edici bir varsayım olarak ortaya çıkmaktadır; burada model performansını değerlendirmek için uygun bir kurgu sağlamaktadır.

> Bizim açımızdan, organizasyonlar, verilerin bir araştırma sorusunu yanıtlamak için yararlı bir kategorileşmesini ortaya çıkarmaya yardımcı oluyorlarsa faydalıdır. Eğer iki model metinl eri nasıl kategorize edeceği konusunda anlaşmazlık yaşıyorsa, bunun bir anlamı yoktur.

Doclingo https://www.doclingo.ai

hangisinin diğerinden daha "doğru" olduğunu belirlemek. Örneğin, meti nlerin olumlu veya olumsuz duyguların ifadesine dayalı bir organizasyon unun, metnin konusuna dayalı bir organizasyondan daha doğru olduğun u savunmak istemeyiz. Aksine, bazı organizasyonların belirli bir soruyu el e almak için diğerlerinden daha yararlı olduğunu savunacağız. Örneğin, b ir modelin türü incelemek için özellikle yararlı olduğunu savunabiliriz, çü nkü bu, araştırmacıyı, aksi takdirde imkansız olacak bir kitapların seyrine dair bir içgörüye götüren bir organizasyon sağlar. Bir organizasyona sahi p olduğunuzda, o belirli kategorilemenin en iyi ölçümünü bulabilirsiniz. A rdından, ölçümü kapsamlı bir doğrulama ile test edebilirsiniz.
Ancak, yararlı ve geçerli organizasyonların çokluğu nedeniyle, metinlerin nas ıl organize edilmesi gerektiğine dair "sağlam" bir cevap sunmayan bir yönte m, eleştirmenlerin savunduğundan daha az endişe verici olacaktır. Önemli ol an, bir organizasyon seçildikten sonra doğrulamaların güvenilirliği ve araştır ma sorusunu yanıtlamadaki faydasıdır.

Kitabımız boyunca metin olarak veri yöntemlerinin dikkatli ve düşünceli insani bilimc ilerin yerini almaması gerektiğini vurgulayacağız. Ve dijital beşeri bilimler alanında çıkar ımların, okuyucunun doğrudan dahil olmadığı bir şekilde yapılmasının hiçbir anlamı yok tur. Hesaplamalı yöntemlerin çıkarımları geliştirmek için kullanılmasına yapılan bu vurg u, dijital beşeri bilimler akademisinin rolü hakkında bazı endişeleri hafifletmeye yardım cı olacaktır. Hesaplamalı araçlar, geleneksel akademik çalışma biçimlerinin yerini alma malıdır. İyi kullanıldığında, hesaplamalı araçlar akademisyenler için daha geniş bir bağl am sağlamaya, aksi takdirde manuel olarak tanımlanması imkansız olan kalıpları aydınl atmaya ve genel olarak onları kullanan akademisyenlerin insan çabalarını artırmaya—y erine geçmek yerine—yardımcı olmalıdır.

Doclingo https://www.doclingo.ai

1.3 Bu Kitap, Endüstri ve Hükümette Veri Bilimini Nasıl Bilgilendiriyor

Hesaplamalı araçlar, şirketlerin ürünlerinde metni veri olarak nasıl kullandığını ve hükümetin metni, seçmenlerin görüşlerini temsil etmek için nasıl kullandığını da devrim niteliğinde değiştirmiştir. Bu araçların endüstrideki uygulamaları neredeyse sonsuzdur. Şirketler, kullanıcıların web sitelerinde paylaştığı mesajları daha iyi hedeflenmiş reklamlar yapmak, yeni içerik hakkında önerilerde bulunmak veya bireylerin seçilmiş yetkililerle bağlantı kurmalarına yardımcı olmak için kullanmaktadır. Hükümette, metin olarak veri yöntemlerini kullanarak, bürokratik ajanslarda önerilen kural değişiklikleri hakkında kamuya açık olarak yorum yapan seçmenlerin görüşlerini daha iyi temsil etme şansı vardır veya seçilmiş yetkililere görüşlerini ifade etme fırsatı bulunmaktadır.

Veri olarak metin yöntemlerini endüstriyel ölçekli sorunlara uygularken riskler yüksektir.Belki de veri olarak metin yöntemlerinin en politik olarak hassas uygulaması içerik denetimidir: sosyal medya şirketlerinin (ve bazen hükümetlerin) platformlarında dağıtılan içeriği düzenleme çabasıdır. 2016 ABD seçimlerindeki Rus dezenformasyon kampanyasının ardından, sosyal medya şirketleri, sitelerinden dezenformasyonu tanımlama ve kaldırma, kampanya sırasında meydana gelen dezenformasyonun etkisi hakkında raporlama ve yeni prosedürlerin adil olduğunu ve belirli ideolojileri orantısız bir şekilde hedef almadığını gösterme konusunda artan bir baskı ile karşılaştı. Bu içeriği tanımlamak için kullanılan araçlar bu kitap boyunca yer alacak ve tanıttığımız benzer bir hesaplama kaynakları setine dayanacaktır.

Siyasi hassasiyet sorularının ötesinde, veri olarak metin yöntemlerinin uygulanması, sistemlerin önerileri temelinde harcanacak büyük miktarda para nedeniyle de yüksek risk taşıyacaktır. Örneğin, ticaret firmaları artık yatırımlarını yönlendirmek veya merkez bankalarından içerik hakkında hızlı bir şekilde bilgi edinmek için hesaplama araçları kullanıyor. Veri olarak metin yöntemleri ayrıca ekonominin büyük bir payını temsil eden reklam kararlarını yönlendirmeye de yardımcı olmaktadır. Bu kararları “doğru” almak, birçok iş pratiği için önemlidir.

Kitabımız, bu görevler doğası gereği sosyal bilimler görevleri olduğu için veri bilimcileri için faydalıdır. Yanlış bilgileri veya nefret söylemini bastırmak için içerik moderasyonu, temelde bir ölçüm görevidir. Şirketler, hangi reklamların müşterileri için en büyük satış artışını sağlayacağını belirlediğinde, nedensel çıkarım ile meşguldürler. Ve tüccarlar, belgelerin veya yetkililerin beyanlarının içeriğine dayanarak kararlar aldıklarında, tahmin ile meşguldürler.

Sektörde sosyal bilimlerin her yerde varlığını tanımak esastır,

Doclingo https://www.doclingo.ai

çünkü birçok veri bilimcisi profesyonel eğitimlerini sosyal bilimler dışında alır. Bu alanlar, şirketlerin oluşturduğu devasa veri setleriyle çalışmak için gerekli h esaplama araçlarını sağlama konusunda mükemmel bir iş çıkarıyor, ancak gen ellikle araştırmacıları bu araçların inşa edildiği görevlerin temel tasarım ilkeleri yle tanıştırmada başarısız oluyorlar.

Bu kitap ve aslında organizasyon yapısı, bireysel modellerden ve hesaplama araçlarından dikkati kaldırmak ve keşif ile ölçüm veya tah min ile nedensel çıkarım gibi görevler arasındaki farklara yeniden od aklanmak için tasarlanmıştır. Bu farklılıkları tanımlamak esastır, çün kü farklı görevler, farklı modellerin kullanılmasını, farklı bilgi setlerin in koşullandırılmasını ve sonuçları haklı çıkarmak için farklı varsayım ların gerekli olduğunu ima eder.

Doclingo https://www.doclingo.ai

1.4 Bu Kitaba Bir Rehber

Kitabımız, sosyal bilimler, dijital beşeri bilimler,bilgisayar bilimi, sanayi ve hükü met alanlarını kapsamaktadır. Bu farklı alanlarda metni veri olarak nasıl kullanacağ ımıza dair görüşümüzü iletmek için, kitabımızı farklı bir şekilde organize ediyoruz. Çoğu hesaplamalı sosyal bilimler kitabı, el yazmasını algoritmalar etrafında organiz e ederken, bu kitapta kitabı görevler etrafında organize ediyoruz. Sosyal bilimcileri n metni veri araştırması olarak ele alırken neyin farklı olduğunu vurgulamak için g örevlere odaklanıyoruz. Bu aynı zamanda, aynı algoritmanın farklı görevleri başar mak için nasıl kullanılabileceğini ve bir algoritmanın geçerliliklerinin, o algoritmayı uygularken elde edilen hedefe bağlı olarak nasıl farklılık gösterebileceğini açıklama mıza olanak tanır.

Kitabımızı beş ana görev etrafında organize ediyoruz: temsil, keşif,ölçüm, ta hmin ve nedensel çıkarım. Bu görev temelli odaklanmanın altında, Bölüm 2'de özetlediğimiz bir metin analizi prensipleri seti bulunmaktadır. Orada, metni ve ri olarak çıkarım yapma konusundaki *radikal olarak kayıtsız* yaklaşımımızı açıklı yoruz. Genel olarak, metne uygulanan istatistiksel modellerin geri kazandığı bi r temel yapı olduğu görüşünü reddediyoruz. Aksine, istatistiksel modelleri met in belgelerinin yararlı (ve eksik) özetleri olarak görüyoruz. Bu görüş, modelleri nasıl geçerlilik kazanacağımız, farklı organizasyonlar sunan modelleri nasıl değ erlendireceğimiz ve araştırma sürecindeki insanların rolü hakkında önemli içg örüler sağlar.

2. Bölümde seçim ve temsil konusunu tartışıyoruz: metinleri edinme s üreci ve ardından içeriği nicel olarak temsil etme. Metinleri seçerken, örn ek seçiminde temel ilkeler büyük önem taşır, en uygun şekilde mevcut ol an içeriği seçme eğilimi olsa da. Metinleri temsil ederken, farklı temsil biç imlerinin metinler hakkında nasıl farklı yararlı içgörüler sağladığını ve kit abın gelecekteki modelleri için sahneyi nasıl kurduğunu açıklıyoruz.

3. Bölüm, keşif için bir dizi model tanıtmaktadır. Keşifle, modellerin kavramsallaştı rmaları veya dünyanın organizasyonlarını ortaya çıkarmak ve geliştirmek için kullanıl masını kastediyoruz. Farklı organizasyonları önermek için geniş bir model yelpazesini n nasıl yardımcı olabileceğini gösteriyoruz; bu, araştırmacıların dünyaya dair yeni içg örüler elde etmelerine yardımcı olabilir. İki grubun konuşma biçimleri arasındaki fark lılıkları gösteren kelimeleri ortaya çıkarmak için kullanılan yöntemlerle başlıyoruz. Bu yöntemler, iki farklı siyasi partiden yasama organı üyeleri gibi belge gruplarını karşıla ştırmak veya diğer tümevarımsal yöntemlerden çıkarılan kategorileri etiketlemeye ya rdımcı olmak için kullanılabilir. Ardından, her gözlemi tek bir kategoriye atayan veri b ölme modelleri de dahil olmak üzere keşif için bazı bilgisayar destekli teknikleri tartışı yoruz. Daha sonra, kümeleme yöntemlerinin nasıl çalıştığını açıklıyoruz.

Doclingo https://www.doclingo.ai

karışım modellerine genişletilmesi, her belgeyi farklı kategorilere or antılı olarak atanan olarak temsil eder. Son olarak, verilerdeki temel sürekli değişkenlere ışık tutabilecek daha düşük boyutlu alanlara bel geleri yerleştirme yöntemlerini tanımlıyoruz.

Bölüm 4, ölçüm yaklaşımımızı tanımlar: belgelerin bir dizi kategori içindeki yayg ınlığını değerlendirmek veya önceden belirlenmiş bir spektrum boyunca konumları nı değerlendirmek. İnsan yargısını makine öğrenimi yöntemleriyle birleştirerek, bir eğitim setinde kodlanmış insan anotasyonlarını çok daha büyük bir veri setine nas ıl genişleteceğimizi açıklıyoruz. Ölçüm yaparken, bir keşif yönteminin ilgi alanındak i bir kategoriyi ölçmek için nasıl yeniden kullanılabileceğini açıklıyoruz. Bu ölçümler in her birini doğrulamanın nasıl yapılacağına dair kapsamlı bir tartışma ekliyoruz, h angi yöntemle üretilmiş olursa olsun.

Tanımladığımız kavramlar ve ölçümler üzerine inşa ederek, Bölüm 5, tahmin v e nedensel çıkarım yöntemlerini nasıl uygulayacağımızı açıklar. İlk olarak, metni veri olarak kullanma yöntemlerini kullanarak dünyanın gelecekte nasıl olacağına dair tahminler yapmayı tanımlıyoruz. Farklı türdeki tahmin görevlerini tartışıyoru z ve çıkarım için tehditlerin ortamla nasıl değişebileceğini vurguluyoruz. Sonra, metinlerden elde edilen ölçümleri ya sonuç ya da müdahale değişkeni olarak kull anarak nedensel çıkarımlar yapmayı açıklıyoruz. Metin yöntemleri kullanıldığında ortaya çıkabilecek özel endişeleri açıklıyoruz ve katı bir varsayımlar setinin ne za man karşılandığını değerlendirmek için bir dizi araç sağlıyoruz.

Doclingo https://www.doclingo.ai

1.5 Sonuç

Metin olarak veri araştırmalarında büyük bir potansiyel bulunmaktadır. Büyük miktarda veri, karmaşık modeller ve özel ölçümlerle birlikte, bu yöntemlerin yanlış kullanılma olasılığı da vardır. Metin karmaşıktır ve anlam genellikle ince bir şekilde ortaya çıkar. Risk, akademisyenlerin metin yöntemlerinin neler yapabileceği konusunda aşırı iddialarda bulunmaları durumunda, metin yöntemlerinin kullanılma gerekçesini zayıflatmalarıdır.

Kitabımız, araştırmacılara metin olarak veri yöntemleriyle nelerin mümkün olduğunu ve nelerin mümkün olmadığını anlatan bir rehber olarak tasarlanmıştır. Okuyucuların metin olarak veri yöntemlerinin onlara yardımcı olabileceği muazzam görev setini öğrenmelerine yardımcı olmak istiyoruz. Aynı zamanda, okuyucularımızın metin yöntemlerinin sınırlarını tanımalarına da yardımcı olmak istiyoruz. Bu hedefe bir sonraki bölümde başlıyoruz; burada metin olarak veri araştırmalarına yaklaşımımızı yönlendirecek temel ilkeleri ifade ediyoruz.

Doclingo https://www.doclingo.ai

BÖLÜM 2

Sosyal Bilim Araştırmaları ve Metin Analizi

Sosyal bilimciler, büyük belge koleksiyonlarını analiz etmek için giderek daha fazla hesaplamalı yaklaşımlar kullanmaktadır. Bu veri patlaması ve onu analiz etmek için oluşturulan yeni yöntemler, sosyal bilimlerdeki en heyecan verici son gelişmelerden biridir. Araştırmadaki bu dönüşümler, sosyal bilimcilerin daha önce mümkün olmayan şekillerde teoriler geliştirmelerine ve test etmelerine olanak tanımıştır.

Bu yeni veri kaynaklarını analiz etmek için, sosyal bilimcilerin iddiaları geliştirme ve test etme konusundaki standart tümdengelim yaklaşımını yeniden gözden geçirmemiz gerektiğini bulduk. Sosyal bilimlerde en yaygın süreç—yayınlanmış araştırmalarda belirgin ve lisansüstü öğrencilerine araştırma seminerlerinde iletilen—yazarların herhangi bir veriyi görmeden veya toplamadan önce, test edilebilir önermeler setini türetecekleri net bir teoriye sahip olmaları gerektiğidir. Bu lineer görüşte, araştırmacılar bir şekilde önceden ilgi alanlarını yapılandıran kavramları bilmelidir; ardından, bu kavramların yaygınlığını ölçmek için bir strateji kullanırlar; nihayetinde, belirtilen teorilerinden gözlemlenebilir sonuçları test etmek için bir hipotezler seti ve bir araştırma tasarımı geliştirirler (King, Keohane ve Verba, 1994). Araştırma sürecinin bu anlayışı o kadar yaygındır ki, genellikle iyi araştırma ile eş anlamlıdır.Bu yaklaşımın aşırı bir versiyonu, özellikle yirmi birinci yüzyılın ilk yıllarında belirgin olan, teorinin ve gözlemlenebilir sonuçların, bir proje için toplanan herhangi bir orijinal veriyi incelemeden önce belirlendiğini varsayar ve bu teorinin, aksi takdirde belirsiz olan model parametreleri için mikro temeller sağlayabileceğini öne sürer. Achen (2002) bu (o zamanlar) “yeni stil”i özetlerken, “yeni stil, resmi bir model artı beyaz gürültü hataları ile başlamayı ısrarla savunur” der (Achen, 2002, 441). Bu yaklaşım, araştırmacıları önce teoriyi kullanarak resmi (oyun teorisi) bir model oluşturmaya, ardından tahminler çıkarmaya ve daha sonra bu tahminleri test etmek için veri toplamaya teşvik eder (Granato ve Scioli, 2004, 315). Gerçekten de, her birimiz bu araştırma modelini takip eden birkaç makale yazdık.

Bu standart çıkarımsal yaklaşımın hem içinde hem de dışında birçok erdemi vardır.

Doclingo https://www.doclingo.ai

akademi ve özellikle test edilebilir sonuçları olan bilinen veya yerleşik teoriler olduğunda oldukça güçlü olabilir. Bu, analistlerin anlamaya çalıştıkları feno menin altında yatan mekanistik süreçler hakkındaki inançlarını gözden geçir melerini teşvik eder. Açıkça takip edildiğinde, tümevarım yaklaşımı, araştırm acı takdirinin bir sonucu olarak ortaya çıkabilecek yanlış keşifleri azaltmaya y ardımcı olur. Bu, bir deney gerçekleştirmeden önce hipotezlerin ve analiz pr osedürlerinin ön kayıt sürecinin arkasındaki düşünce sürecidir.

Ancak, araştırmacıları verilerin geldiği zamandan önce geliştirilen teorileri tes t etmek için verileri kullanmaya zorlamak da önemli zayıflıklara sahiptir. Sosyal bi limler alanındaki akademisyenler, nitel araştırmalarda daha indüktif analiz biçiml erinin, tam döngü araştırma tasarımı, temellendirilmiş teori ve iç içe analiz dahil olmak üzere, önemini kabul etmişlerdir (Lieberman, 2005; Glaser ve Strauss, 1967; Chatman ve Flynn, 2005). Deneyimlerimize göre, araştırmacılar genellikle yeni yönler, sorular ve ölçümler keşfetmek için nicel verilerini de kullanab ilirler. Eğer standart çıkarımsal prosedür çok sıkı bir şekilde takip edilirse ve veriler yalnızca en son anda toplanırsa, araştırmacılar kavramlarını gel iştirme, yeni teoriler geliştirme ve yeni hipotezleri değerlendirme fırsatını kaçırabilirler. Verileri analiz ederken büyük bir öğrenme gerçekleşir. Bir araştırma projesi ilgi çekici bir soruyla başlasa bile, genellikle önemli ölçü de farklı bir odakla sona erer. Bu, Gary King, Jennifer Pan ve Margaret Ro berts tarafından yapılan Çin sosyal medyasının analizi gibi kendi projeleri mizden birinde de oldu (King, Pan ve Roberts, 2013). İlk çalışma, ReadMe adlı otomatik metin analizi yöntemini doğrulamayı amaçlıyordu. Verileri i nceledikten ve neyi ölçebileceğini anladıktan sonra yazarlar, araştırmaları nı farklı bir soruya odaklanacak şekilde iteratif olarak geliştirebildiler: Çin hükümetinin sosyal medyayı sansürleme stratejisi nedir? Araştı rmacılar, veriye baktıktan sonra indüktif bir yaklaşımı reddedip sor ularını değiştirmeyi reddetselerdi, önemli bir olguyu keşfetme fırsa tını kaçırırlardı: sansür.

Eğer çok kısıtlayıcı bir şekilde benimsenirse, araştırmaya yönelik dedüktif yaklaş ım analistlerin verilerden ilginç sorular ve ölçüm stratejileri keşfetme fırsatlarını ka çırmalarına yol açar. İndüksiyona karşı duyulan aversion, akademisyenlerin bir dizi ampirik testin sonunda yeni teori geliştirmekten kaçınmalarına da neden olabilir; ç ünkü bu, bir makaledeki sonuçlara dayalı bir model oluşturmak için sonradan bir g erekçe olarak görülebilir.

Hikaye olarak, birçok araştırmacının verilerde ilginç kalıplar ve teoriler indüktif olarak keşfettiğini görüyoruz, anc ak dedüktif araştırma tarzı bu kadar yaygın kabul edildiği için, keşiflerini nasıl yaptıklarına dair tartışmalar yayımlana n makalelerde nadiren vurgulanmaktadır. Araştırmanın nasıl yapıldığına bakılmaksızın, makale yazma standart uygul aması teoriyi, gözlemlenebilir sonuçlarını ve ölçüm stratejisini belirterek başlar; ardından veri seti tanıtılır.

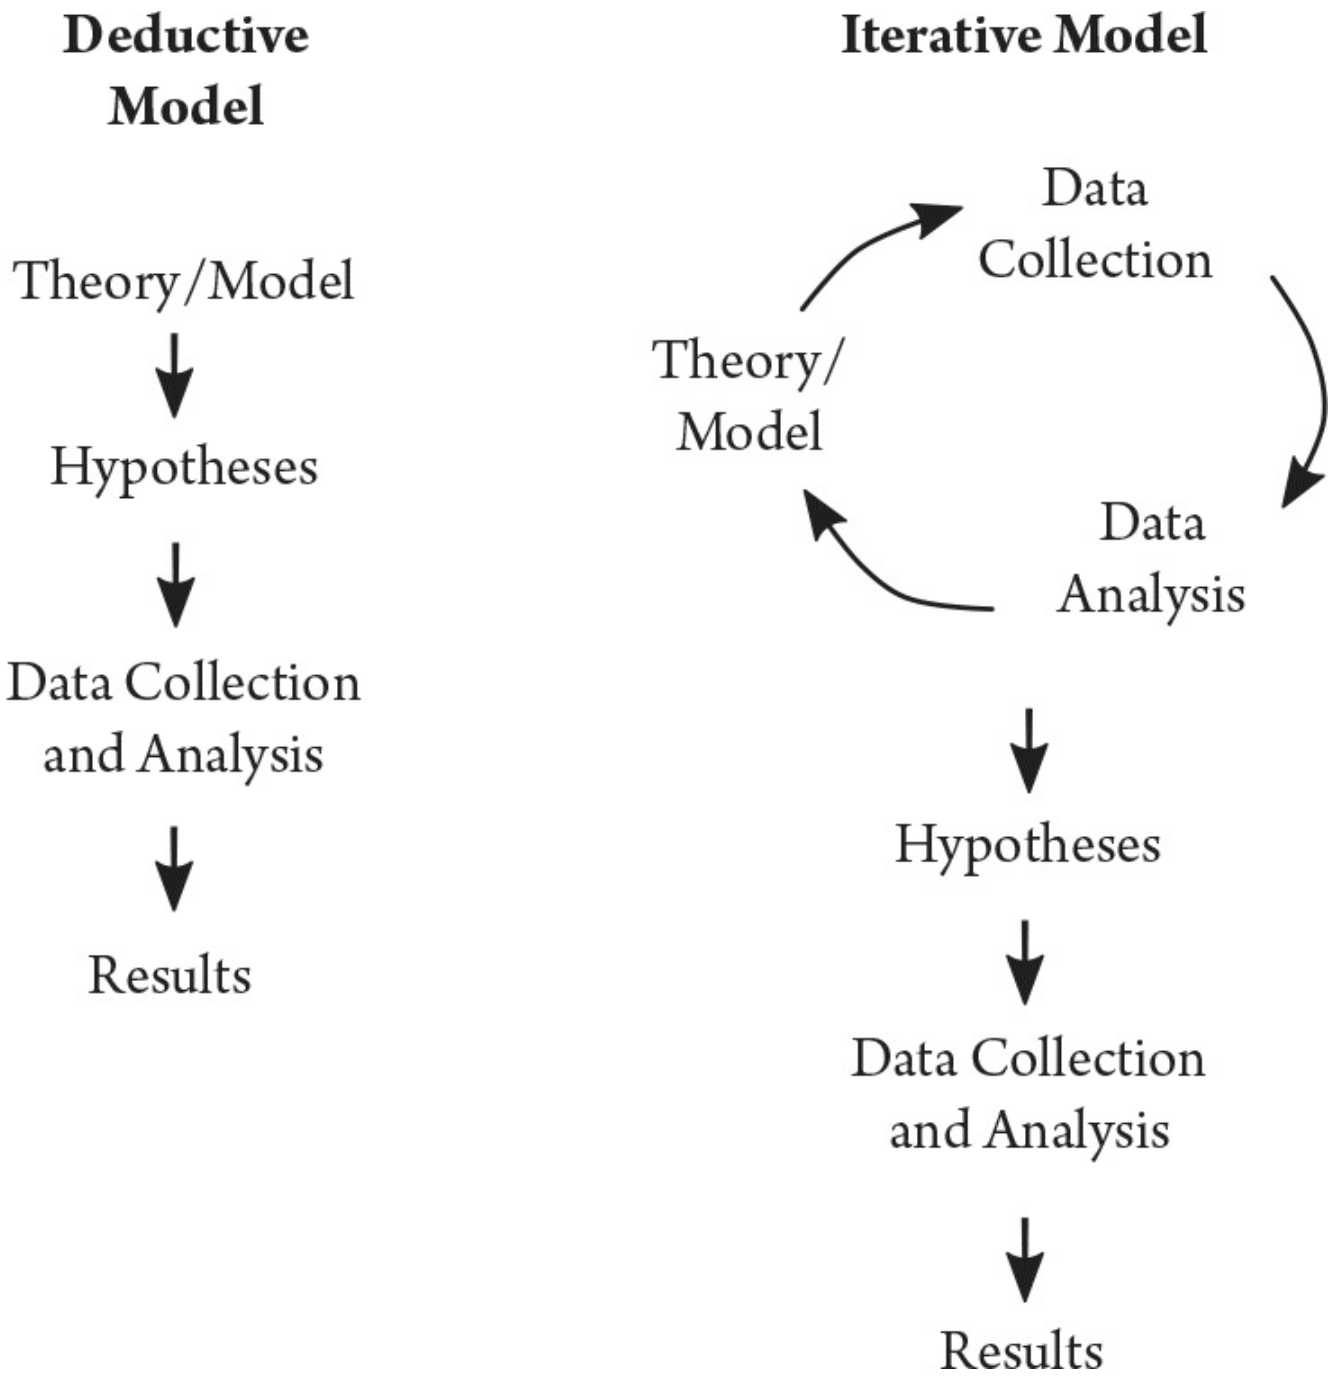
Doclingo https://www.doclingo.ai

Bu, bir araştırmacının—hatta istemeden—bir teoriyi yeni bir veri se tine uygulanıyormuş gibi sunması durumunda çıkarım için bir soru n teşkil eder; oysa aslında aynı veri, ilgilenilen teoriyi geliştirmek ve test etmek için kullanılmaktadır.

İndüksiyonun araştırmadaki rolünü tartışmamak, keşif ve ölçüm yöntemlerini geliştirme yeteneğimizi engeller. Bu, sorunludur çünkü akademisyenler, verileri nden indüktif olarak öğrenme notasyonunu benimsediklerinde teorilerini geliştir me olasılığına sahiptirler. Aşağıda açıkladığımız gibi, araştırmada indüktif bir yakl aşımda doğuştan yanlış bir şey yoktur. Aslında, hayatımızda ve bilimde yaptığımı z birçok önemli öğrenme indüktiftir. Keşif yöntemlerini geliştirmek ve ardından b u keşifleri titizlikle test etmek için düzenli olarak indüksiyonla meşgul olduğumuz u kabul etmek, sosyal bilimi yürütme şeklimizi büyük ölçüde geliştirecektir. Ayrıc a, araştırmada indüksiyonu kullanırken, örneğin aynı veri kümesini hem bir teori yi geliştirmek hem de test etmek için kullanmak gibi hatalardan kaçınmamıza da olanak tanıyacaktır.

Bu kitapta, sosyal bilim araştırmalarının standart çıkarımsal modelinin kurg usunu sürdürmek yerine, araştırma sürecinin döngüsel doğasını vurguluyoruz ve metni veri olarak analiz etmenin en iyi yaklaşımının yinelemeli düşünmek ol duğunu açıklıyoruz (Şekil 2.1). Standart modelde olduğu gibi, ilginç bir soru, iç görü veya belirli bir veri kümesi ile başlıyoruz. Ancak teorilerimizin verileri incel emeden önce tamamen geliştirilmiş olduğunu varsaymak yerine, verileri yinel emeli olarak incelemenin ve teorileri geliştirmenin teorik içgörülerimizi netleşti rmeye yardımcı olduğunu vurguluyoruz. Bu indüktif süreçten sonra, araştırma cı, geliştirilmiş teorileri test etmek için yeni veriler elde etmelidir. Bu yeni veri k ümesi, araştırmacıların sosyal bilimcilerin indüktif araştırma ile ilişkilendirmey e eğilimli olduğu p-hacking, dallanma yolları ve araştırmacı özgürlük dereceler i gibi endişelerden kaçınmasını sağlar.

Doclingo https://www.doclingo.ai



Şekil 2.1. Standart çıkarımsal araştırma modeline (solda) kıyasla araştırmanın yinelemeli modeli (sağda) için akış şemaları

Sosyal bilim araştırmalarında daha fazla tümevarımsal bir modele ihtiyaç duyulması yeni bir durum değildir; metne özgü de değildir. Ancak, metin veri sinin yüksek bilgi içeriği ve zenginliği nedeniyle, bir tümevarım yaklaşımı, ara ştırma projesinin erken aşamalarında - akademisyenlerin sezgilerini formüle ettiği zaman - ve araştırma sürecinin daha sonraki aşamalarında faydalı olabi lir. Ayrıca, keşfi araştırma sürecinin bir parçası olarak açıkça kabul ederek, bu belirli hedefi ve ölçüm ve test hedeflerini takip etmemize yardımcı olan meti n analizi metodolojileri tasarlayabiliriz.

Metni veri olarak analiz etme yöntemlerinin çıkarıma nasıl katkıda bulunabileceğini açıklıyoruz

Doclingo https://www.doclingo.ai

araştırma sürecinin üç aşamasında: keşif, ölçüm ve çıkarım. Bu aşam alardan sonuncusu olan çıkarımda, nedensel çıkarım ve tahmin de d ahiliz. Her aşamaya detaylı bir şekilde geçmeden önce, bir araştırma projesinin faydalı olabilmesi için tüm aşamalardan geçmesi gerekm ediğini vurgulamak istiyoruz. Örneğin, dünyaya bakmanın yeni bir y olunu veya iyi bilinen bir kavram için yeni bir ölçüm öneren bir çalış ma çok faydalı olabilir. Ya da, önemli bir nedensel etkiyi tahmin etm ek veya bir tahminde bulunmak için hazır kavramlar ve ölçümler kull anan bir çalışma, sosyal bilim araştırmalarının hedeflerini açıkça ilerl etir. Ve aşağıda açıkladığımız gibi, araştırma keşiften ölçüme ve anal ize sıralı bir şekilde ilerlemek zorunda değildir. Aksine, çalışmalar ar aştırma sürecinin farklı aşamaları arasında çeşitli sıralarda hareket e debilir. Araştırma sürecini keşif, ölçüm ve çıkarım sırasıyla sunarken, bir çıkarımsal görev ölçümlerimizi yeniden gözden geçirmemize vey a tamamen yeni bir araştırma sorusu keşfetmemize neden olabilir.

Doclingo https://www.doclingo.ai

2.1 Keşif

Araştırma sürecinin en erken aşamalarında, analistler keşfe odakla nır. Keşif sırasında birincil hedef, araştırma sorusunu geliştirmektir. B u, verilerden neyi ölçmek istediğinizi ve çıkarım amacınızı belirleme g örevini içerir. Verilerden neyi ölçmek istediğinizi belirlemek, dünyayı o rganize etmenin bir yolu olan bir kavramsallaştırma geliştirmeyi içerir ; bu, yaşadığımız karmaşık dünyayı anlamamıza yardımcı olur. Kavram sallaştırma, yaşadığımız son derece karmaşık dünyayı incelemek için bir veya iki belirli yönünü basitleştirmeye yardımcı olacaktır. Örneğin, bir dizi sosyal medya gönderisini incelemek istediğinizi varsayalım. Bu gönderilerin hangi yönleri, analiziniz için önemli ve ilginçtir? Konusal i çeriğini, duygu durumunu, okunabilirliğini, bilgilendiriciliğini veya nez aketini mi ölçmek istiyorsunuz? Yoksa, gönderileri organize etmenin f arklı bir kavramı veya yolu ile yakalanabilecek, farkında olmadığınız b aşka önemli bir sosyal medya gönderisi boyutu mı var?

Kullanmak istediğiniz kavramların analizin unsurları olarak hangi aşamada beli rlendiği keşif aşamasında çalışılır.

Metin analizi, belgeler koleksiyonunu organize etmenin yeni yolla rını göstererek kavramsallaştırmalar geliştirmemize yardımcı olur. B u organizasyon, benzer olan ve diğer gruplardan farklı olan metin gr uplarını tanımlamaktan gelebilir. Organizasyon ayrıca, belgeler kole ksiyonu içinde bir temel spektrum tanımlamaktan da gelebilir; bu, bi rbirine yakın olan metinlerin, daha uzak olan metinlerden daha benz er olduğu düşük boyutlu bir veri özetidir. Metin analizi, bu kümeleri n ne anlama geldiğini anlamaya yardımcı olabilir; bu, farklı metin gr uplarını tanımlayan ve tarif eden kelimeleri belirleyerek yapılır. Elbet te, bu yeni organizasyonların hepsi faydalı olmayacak ve araştırmacıl ar, verilerin bağlamı ve literatürdeki mevcut teoriler hakkında bildikl erini kullanarak daha faydalı ve daha az faydalı kavramlar ile verileri kesmenin yollarını ayırt etmek zorunda kalacaklardır.Ancak, belgeler in organize edilmesinin yeni yollarını göstererek, metin analizi sosya l bilimcilerin metinleri farklı bir şekilde okumalarını ve aksi takdirde kaçıracakları metinler arasında bağlantılar kurmalarını teşvik edebili r. Bu kavramsallaştırmalar, araştırma sürecinin ilerleyen aşamaların da tanım, nedensel çıkarım ve tahmin için kullanılabilir.

Keşif, her ne kadar her araştırma projesinin önemli bir parçası olsa da, genellikle s tandart nicel araştırma modelinden dışlanmaktadır. Keşif yöntemleri, araştırma sorul arının çok çeşitli kaynaklardan gelebilmesi nedeniyle, kısmen yeterince geliştirilmemi ştir; bu kaynaklar arasında önceki bir analizin sonuçları, yeni bir veri setini inceleme fı rsatı veya hatta bir araştırma hatası ile ortaya çıkan yeni bir yön bulunmaktadır.

Doclingo https://www.doclingo.ai

Kalitatif metodologlar, yeni verilerden keşfi kolaylaştırmak için açıkç a tasarlanmış teknikler geliştirmiştir; örneğin, temellendirilmiş teori (Glaser ve Strauss, 1967). Araştırma sürecinde keşfin rolünü kabul et mek, gelecekteki keşifleri kolaylaştıran metodolojilerin geliştirilmesi ne olanak tanır ve akademisyenlere araştırmalarının keşif aşamasını yayınlarda açıkça tanımlama yetkisi verir.

Doclingo https://www.doclingo.ai

2.2 Ölçüm

Bir keşif aşamasından, teorik bir modelden veya sezgiden elde edilen kavra mlarla, akademisyenler genellikle belirli kavramların verilerindeki yaygınlığını ölçmek veya bireylerin veya metinlerin bir spektrumda nerede yer aldığını tanı mlamak isterler. Örneğin, Jones, Wilkerson ve Baumgartner (2009), geniş bir p olitika gündemi yelpazesi içinde yer alan yasaların miktarını öğrenmekle ilgilen iyorlardı. En başarılı veri toplama projelerinden ikisi, Politika Gündemleri Proje si ve Karşılaştırmalı Gündemler Projesi, dünya genelindeki parti manifestoların da farklı konuların yaygınlığını ölçmektedir. Diğer projeler belgeleri kategoriler e atar. Örneğin, akademisyenler, olumsuz kampanya reklamlarının seçim katılı mı üzerindeki etkisiyle ilgilenmektedir (Ansolabehere ve Iyengar, 1995). Bunu keşfetmek için, akademisyenlerin reklamlardaki olumsuzlukları güvenilir ve do ğru bir şekilde ölçen yöntemler geliştirmeleri gerekmektedir.

Metin verilerinin yaygınlığı ve ölçüm yöntemlerinin baskınlığı, m etinden miktarları ölçme konusunda giderek daha çeşitli yollarla ve giderek büyüyen koleksiyonlardan ilgi patlamasına yol açmıştır. Yeni ve daha büyük metin kaynakları, ölçümlerin genellikle ayrıntılı olmasını sağlar; bu da, aksi takdirde tespit edilmesi zor olan davra nışlar hakkında içgörüler sunar. Ölçüm, tanım için temel bir bileşen dir: sosyal bilim araştırmalarında sıklıkla göz ardı edilen önemli bir hedeftir. İyi yapıldığında, tanım verilerin değerli özetlerini sağlar; b u da, teorileri bilgilendirebilir, nedensel çıkarımlar için gerekli ölçü mleri sağlayabilir veya dünyanın durumunu karakterize edebilir. B u hedeflere ulaşmak için, araştırmacıların ölçüm yöntemlerinin ger çekten ölçmek istedikleri kavramı veya davranışı tanımladığını göst ermeleri gerekir; yani, ölçümlerini doğrulamaları ve tanımlanan mi ktarların mevcut teorik miktarla ilgili olduğuna dair kanıt sunmaları gerekir. Ölçüm kavramı yansıtmazsa, bu, ölçümü gözden geçirme miz gerektiğinin bir göstergesidir veya bazı durumlarda ölçüm sür eci aracılığıyla kavramı yeniden tanımlamamız gerektiğini gösterir. Her iki durumda da, elde edilen ölçüm, teorik ilgi ve önem taşıyan bir kavramı mümkün olduğunca yakın bir şekilde yansıtmalıdır.

Doclingo https://www.doclingo.ai

2.3 Çıkarım

Bir kavram keşfedildiğinde ve ölçümler oluşturulduğunda, araştırmacılarbu ölç ümleri kullanarak gelecekteki olaylar hakkında tahminlerde bulunabilirler veyabir müdahalenin etkisi hakkında nedensel çıkarımlar yapabilirler. Örneğin, araştırmacı larmetinleri kullanarak hisse senedi fiyatlarının değerlerini veya siyasi çatışmanınm uhtemel olduğu yerleri tahmin edebilirler. Bunlar, mevcut bilgininbugün nasıl yara rlandığını ve yarın ne olacağını anlamamıza yardımcı olduğu içinöngörücü sorulard ır. Araştırmacılar ayrıca bir kampanyada olumsuz bir tutumsergilemenin—bir müd ahale—kampanya hakkında haber kapsamı üzerindekinedensel etkisini değerlendi rebilirler. Ya da belirli türdeki siyasi içeriğinkullanıcıların çevrimiçi forumlardaki etki leşimlerini nasıl etkilediğiyleilgileneceklerdir. Bunlar, bir müdahaleye yanıt olarak d ünyanın nasıl değişeceğinisorduğu için temelde nedensel sorulardır.
Bu kitapta, analizimizde tahmin mi yoksa nedensel çıkarım mı kullandığımıza yakından dikkat edeceğiz ve bu önemli olacak çünkü her durumda araştırma dizaynı için çok farklı yaklaşımlar kullanacağız.

Doclingo https://www.doclingo.ai

2.4 Sosyal Bilimlerin Tekrarlı ve Birikimli Süreci

Deneyimimiz, araştırma sürecinde nerede olduğumuza dikkat etmenin—il gi alanındaki kavramlar hakkında bir keşif yapıp yapmadığımızı veya bu kavr amların yaygınlığını ölçüp ölçmediğimizi ve ardından etkilerini tahmin edip e tmediğimizi—metin verilerinin potansiyelini tam olarak kullanmak için kritik olduğunu göstermektedir. Önemli olan, keşif sürecinde veri analizi ile teori a rasında döngüsel olarak ilerlemek, daha içgörülü araştırma soruları ve ilgi al anındaki kavramlar geliştirmemize yardımcı olacaktır. Metin verileri ile çalışır ken, araştırmacılar metinlerden sosyal bilim teorilerine faydalı bir şekilde ent egre edilebilecek yeni tipolojiler ve kavramlar keşfedeceklerdir. Bu yeni kavr amları belirledikten sonra, belgeleri bu kavramlarla ilişkili kategorilere sınıfla ndırmak, araştırmacıları ölçüm stratejilerine dikkat etmeye zorlar.
Bu iki egzersiz—keşif ve ölçüm—iyi çıkarımlar yapmak için kritik önem e sahiptir, ister tanımlayıcı, ister nedensel, isterse öngörücü olsun.

Ancak en iyi araştırma tasarımına sahip çalışmalar bile bir araştırma sorus u üzerinde son sözü söylememelidir. Bu kitap boyunca, araştırma sürecinin *cumulative* niteliğine de özel bir dikkat gösteriyoruz. Bir çalışma yayımlandık tan sonra, araştırmacılar o çalışmanın bulgularını ilgi alanındaki kavramları v eya soruyu yeniden tanımlamak, ölçüm stratejisini geliştirmek veya yeni bir v eri setinde tahmin veya nedensel çıkarımı tekrarlamak için kullanabilirler. So syal dünya sürekli olarak evrildiği için, sosyal bilim araştırmalarının bu biriki mli niteliği, araştırma yaparken aklımızın öncelikli konusu olmalıdır.

Aslında, bu yinelemeli ve birikimli araştırma sürecinin farkında olmanın met in analizi için o kadar faydalı olduğunu düşünüyoruz ki, kitabı bu sürecin adıml arı etrafında organize ediyoruz. Bu kitapta, araştırma sürecinin her aşamasınd a görevleri başarmak için nasıl kullanılabileceğini açıklamak amacıyla yeni yönt emler tanıtacağız. Bu, metin analizi tekniklerini tanımlayan diğer çalışmaların n asıl organize edildiğinden bir sapmadır; bazıları tarafından yazılan dergi uzunl uğundaki genel bakışları (Grimmer ve Stewart, 2013) içermektedir. Çoğu orta mda, farklı modellerin teknik yetenekleri etrafında organize edilirler; örneğin, modelin nasıl eğitildiği ve modelin istatistiksel bir veri üretim sürecini önerip ö nermediği gibi. Bu organizasyonlar önemlidir ve kitap boyunca tanıttığımız çeş itli yaklaşımların metin analizi yöntemlerinin daha geleneksel tipolojileri içinde nasıl yer aldığını açıklayacağız.

Bu kitabı araştırma sürecinin aşamaları etrafında organize etmeyi seçiyoruz çünkü bir metin koleksiyonuna hangi yöntemin uygulanacağı, bir yöntemin çıktısının nasıl yorumlan acağı ve bir ürünün nasıl doğrulanacağına dair anahtar kararlar burada verilmektedir.

Doclingo https://www.doclingo.ai

yöntemler, araştırma sürecinde nerede olduğumuza bağlıdır. Diğer bir deyişle,m odeller birden fazla amaca hizmet edebilir. Örneğin, belgeleri sınıflandırmak için kullanılabilecek yöntemler—tipik bir ölçüm görevi—aynı zamanda bir grup belge yi karakterize eden kelimeleri ve ifadeleri keşfetmek için de kullanılabilir—bir keş if görevi. Latent Dirichlet Allocation (LDA) gibi bir organizasyonu keşfetmek için t asarlanmış yöntemler, bir ilgi kavramını hızlı bir şekilde ölçmek için yeniden kulla nılabilir. Ancak, bir yöntemin belirli görevi veya amacı, yöntemlerin nasıl yorumla ndığını, doğrulandığını ve uygulandığını güçlü bir şekilde şekillendirir.

Keşif bağlamında aynı istatistiksel modeli ölçüm bağlamından çok f arklı bir şekilde ele alacağız çünkü *görev* farklıdır.

Daha geniş bir çerçevede, kitabı araştırma sürecinin bileşenleri etrafınd a organize ediyoruz çünkü metinleri analiz etmek için kullanılan araçlar de ğişse de, görevler değişmeyecektir. Bu kitabı en son yöntemlerin kapsamlı bir listesi haline getirmeye çalışsaydık, basılmadan önce geçersiz hale gele cekti. Bunun yerine, araştırma sürecinin aşamalarına odaklanıyoruz çünkü her aşamayı nasıl gerçekleştireceğini anlayan sosyal bilimciler, yeni teknikl eri geldikçe benimseyebileceklerdir.

Bu bölümde, sosyal bilim çıkarımları yapmak için metin verilerini nasıl analiz ettiği mizi yönlendiren altı temel ilkeyi tanıtıyoruz. Kısmen, bu ilkeler temel istatistiksel özel liklerden ve metin verisi kullanan araştırmacıların, metin dışı veriler için geliştirilmiş a raştırma tasarımlarının nasıl performans gösterdiğine dair içgörülerden gelmektedir. Ancak içgörülerimiz, birçok akademik, endüstriyel ve kar amacı gütmeyen ortamda o nlarca metin analizi projesi yürütme deneyimimizden de gelmektedir. Dolayısıyla, ara ştırmaya nasıl baktığımızla ilgili bir meta nokta olarak, metin analizi araştırması yapm a konusundaki ilkelerimiz tümevarımsal olarak öğrenilmiştir.

Doclingo https://www.doclingo.ai

2.5 Metin Analizine Agnostik Bir Yaklaşım

Öne sürdüğümüz altı temel ilke, metin analizini sosyal bilim çıkarımları yapmak için kullanma konusundaki agnostik yaklaşımımızı yansıtmaktadır. Agnostik derken, genel görüşümüzün birçok durumda metin-veri yöntemleriyle hedef alacak "gerçek" değerlerin olmadığı veya bir korpusun tüm uygulamaları için kullanılabilecek en iyi model in olmadığı anlamına geldiğini kastediyoruz. Bu görüşün sonuçları sayısız, derin ve bu kitapta tartıştığımız hemen hemen tüm görevleri kapsamaktadır. Örneğin, agnostik görüşümüz, tüm modellerimizden elde ettiğimiz bulguların kalitesini nasıl değerlendireceğimiz konusunda rehberlik sağlar, aynı temel görevi yerine getirmek için modeller arasında nasıl seçim yapacağımızı bilgilendirir ve daha doğru bir model için bulguları birleştirmenin ne zaman makul olduğunu ve model birleştirmenin ilgi çekici ana içeriği ne zaman gizleyeceğini önerir.

Bizim agnostik görüşümüz, metin analizi için yapısal bir yaklaşımla en keskin şekilde çelişmektedir. İsimden de anlaşılacağı gibi, yapısal bir yaklaşım, keşif aşamasında bile, altında yatan bir "gerçek" veri üreten sürecin olduğunu öne sürmektedir. Yapısal görüşün en net ve en etkili ifadesi, metinleri ön işleme konusunda farklı yolları düşünmek üzerine içgörülü bir makale olan Denny ve Spirling (2018) de bulunmaktadır. Gördüğümüz gibi, metinlerin altında yatan gerçek bir model veya organizasyon olduğunu varsayarsak, model seçimi gibi problemler çok daha basit hale gelir. Ancak bu yaklaşım, çoğu zaman bizi rahatsız edici bulabileceğimiz varsayımlar yapmaya zorlayacaktır. Örneğin, verilerimizin "doğru" bir organizasyonu veya gerçek bir kategori setinin olduğunu varsaymak zorunda kalabiliriz; bu bazı uygulamalarda pek mantıklı gelmeyebilir.

Bunun nedenini görmek için basit bir örneği düşünelim: Diyelim ki, siyasi adayların kendilerini kamuya nasıl sunduklarını incelemek için kampanya reklamlarını organize etmek istiyoruz. Bazı uygulamalar için, reklamın tonu ile ilgilenebiliriz - reklamın olumlu mu yoksa olumsuz mu olduğu. Diğer zamanlarda, reklamın konusuna ilgi duyabiliriz. Ve halabaşka zamanlarda, metnin daha ayrıntılı organizasyonlarından oluşan kaba konularla bir iç içe kavramsallaştırmanın, sorumuz için en yararlı olduğunu bulabiliriz.

Bu organizasyonların "doğru" olduğu anlamında hiçbir şey yoktur, eğer araştırma sorusunun amacı hakkında daha fazla bilgiye sahip değilsek. Eleştirel olarak, metotlar araştırmacıların farklı organizasyonları keşfetmesine ve belirlemesine yardımcı olabilir, bu da yeni araştırma sorularına, hipotezlere ve siyasi kampanyalar hakkında içgörülere yol açabilir. Bu nedenle, keşif aşamasında, "tutarlı" veya "tarafsız" olamayan yöntemleri tercih edebiliriz çünkü bunlar araştırmacılar için en yararlı içgörüleri sağlar.

Doclingo https://www.doclingo.ai

Araştırma sorusu tanımlandıktan ve araştırmacı ölçüm yapmaya başladıktansonra, bir yöntemin araştırmacının ilgi duyduğu belirli kavramı ne kadar doğrubir şekilde geri kazandığını değerlendirebil iriz. Araştırmacının ölçmeyiseçebileceği belgede birçok farklı şey ol duğu için, gerçek bir veriüretim sürecini yakalayan tek bir model ol duğunu varsaymıyoruz, ancak umarız kiaraştırma sorumuz için ihti yaç duyduğumuzu yakalamamıza yardımcı olacakseçenekler vardır . Diğer bir deyişle, ölçüm için hangi belirli modelinkullanıldığı konu sunda tarafsızız, yeter ki model ilgi alanındaki kavramıdoğru ve gü venilir bir şekilde ölçebilsin. Bu bakış açısı, modellerimizinölçtüğüm üzü iddia ettiğimiz şeyi ölçtüğüne dair kanıt sağlayandoğrulamalar a büyük bir vurgu yapmamıza yol açar. Bu doğrulamalar genellikle dokümanların dikkatli okunmasını, kategori tanımlarıyla kod kitapl arını ve/veyauygulama spesifik kriterleri içerir, model uyumlandır ma tanılamaları yerine,çünkü, tarafsız bakış açımızla tutarlı olarak, model yalnızca yararlı biryaklaşım olarak kabul edilir.

Yapısal görüşle olan karşıtlığı vurgulamak istiyoruz; bu, bu alandaki önemli çalışmalardan uzaklaşmayı amaçlamıyor. Bu ayrımı yapmamızın nedeni, metin analizi tekniklerinin bu kitapta nasıl sunulduğuna dair ö nemli bir farkı vurgulamaktır. Yapısal yaklaşımı sosyal bilimler için yarar lı ve önemli görüyoruz. Sadece, bir "en iyi" kavram setinin bir korpus m etni veya metnin temel organizasyonu için olması gerektiği konusunda hemfikir değiliz.

Bir sonraki bölümde, bir araştırma programının örneğini adım adım i nceleyeceğiz ve keşif, ölçüm ve çıkarımın ayrı adımlarını göstereceğiz. A rdından geri adım atarak, kitabın geri kalanında metin analizi tartışma mızı yönlendirecek altı ilke sunacağız.

Doclingo https://www.doclingo.ai

2.6 Keşif, Ölçüm ve Nedensel Çıkarım: Çin Hükümetinin Sosyal Medyayı Sansürlemesi

Deneyimlerimize göre, araştırma programları genellikle basit bir ürün olarak ortaya çıkmaz, ancak genellikle makalelerde bu şekilde rapor edilir. Makaleler, düşünceli soruların ve belirli hipotezlerin, dünya hakkında dikkatli, veri odaklı olmayan düşünme ve gözlem sonrasında ortaya çıktığını tasvir ederken, gerçeklik, bu soruların ve hipotezlerin genellikle verilerin ilk incelemesinden ortaya çıktığıdır. Bu inceleme genellikle önemli bir arka plan bilgisi ve dünyanın nasıl çalıştığına dair önceden var olan teorilerle yönlendirilir; bu da verileri incelerken teorik bir gerilim veya ampirik bir bulmacanın keşfine yol açar. Böyle bir inceleme, araştırmacının açıklamaya çalıştığı daha önce bilinmeyen bir özellik veya deseni ortaya çıkarabilir. Metin verileri, belgeleri okumanın, içerdikleri olguları derinlemesine keşfetmeye olanak tanıdığı için bu tür incelemelere özellikle uygundur.

Farklı görevlerin nasıl bir araya geldiğini vurgulamak için, metin verisi kullanırken standart bir araştırma sürecine bağlı kalmamanın değerini sergileyen King, Pan ve Roberts (2013) (bundan sonra KPR) gelişimini tanımlıyoruz. Bu makalede, yazarlar teorik olarak ilginç içgörüler elde etmek için başarılı bir şekilde yinelemeli ve ardışık bir süreç kullanıyorlar. KPR'nin başlangıç araştırma gündemi, Çince için otomatik metin analizi araçlarını genişletmekti. Bu amaçla, KPR 1,400'den fazla sosyal medya web sitesinden milyonlarca gönderi indirdi. Araştırmacılar, bu gönderilerin bağlamını daha iyi anlamak için verilerinde kaydedilen URL'leri kullanarak gönderilerin orijinal web sayfalarına geri döndüler. Ancak, sitelere geri döndüklerinde, şaşırtıcı bir şey fark ettiler: birçok gönderi artık kaybolmuştu. Yerine, KPR şimdi içeriğin kaldırıldığını bildiren duyurular buldu - bu, hükümet sansürünün bir göstergesiydi.

Verilerini keşfederek, KPR yanlışlıkla yeni bir araştırma sorusuna rastladı - hükümet sansürünün hedefi neydi? Ayrıca metinleri organize etmenin bir yolunu da keşfettiler: ya sansürlüydü ya da sansürsüz. Sonraki analizlerinde, otoriter rejimlerde sansür olgusuna dair genel bilgilerini kullandılar. Soru, bir milyon sosyal medya gönderisine sahip olmayan bir araştırmacının aklına gelebilirdi, ancak KPR'nin başlangıç veri keşfi, hükümet sansürünü inceleme yaklaşımını ortaya koydu.

KPR'nin nihayetinde ilgilendiği soru nedenseldi: hangi tür sosyal medya paylaşımları hükümet sansürüne neden oldu? Bir hipotez oluşturmak için tekrar verilere döndüler. İlk olarak, sansür açısından farklı hassasiyet derecelerine sahip olacağını düşündükleri konulara göre paylaşımları grupladılar.

Doclingo https://www.doclingo.ai

Ancak konuların sansürde çok fazla değişkenlik göstermediği görül dü. Zaman içinde sansürü bilgisayar destekli bir inceleme, sansür o ranlarının Çin'deki toplu eylem olaylarıyla ilişkili paylaşımlar için ço k daha yüksek olma eğiliminde olduğunu izlenimini verdi.
Bu hipotez, analiz için farklı bir birim - olayı - ve ölçmek için farklı bir a na ilgi miktarını önerdi: olayın toplu eylemle ilişkili olup olmadığı. Kriti k olarak, bu keşif aşaması KPR'ye diğer kavramsallaştırmaların neden sel sorularını yanıtlamak için daha az yararlı olacağına inanma nedeni verdi. Sadece konu değil, aynı zamanda duygu (paylaşımın hükümeti eleştirip eleştirmediği) de sansür kararlarını açıklıyor gibi görünmüyor du. Eğer haklılarsa, bir metni sansürleme kararı, paylaşımın hükümeti eleştirip eleştirmediği ile ilgili olmayacak ve bunun yerine paylaşımın bir protesto olayıyla ilişkili olup olmadığına bağlı olacaktı.

Bu süreç, KPR'nin verilerinin bir alt kümesini ve istatistiksel yöntemlerini na sıl kullandığını, ilgi alanlarını keşfetmek, bir hipotez oluşturmak ve ima edilen k avramsallaştırmayı formüle etmek için göstermektedir. Biz buna *keşif* diyoruz. Keşfi kolaylaştırmak için genel bir süreci Bölüm 3: Keşif'te tanımlayacağız.

KPR daha sonra metinleri kavramsallaştırmalarına göre *ölçmeyi* hedefledi. Yani, belirli bir organizasyon dayattılar ve ardından kate gorilerinin varlığını ve yaygınlığını değerlendirmeye çalıştılar. KPR, 85 farklı konu alanında sosyal medya paylaşımlarındaki patlamalar a dayanarak 87 olayı tanımladı. Her patlamanın toplu eylemle ilgili olup olmadığını manuel olarak kategorize ettiler. Bir paylaşımın sa nsürlenip sansürlenmediğini ölçmek, kendi kayıtlarına dayanarak b asitti. Ancak, paylaşımın hükümete karşı duyarlılığını ölçmek daha az basitti. Sosyal bilim araştırmalarında sıkça olduğu gibi, onların a macı her bireysel belgenin duyarlılığını tanımlamak değil, sansürlü ve sansürsüz kategoriler içinde eleştirel veya destekleyici olan belg elerin oranını tanımlamaktı. Bu görev için, sansürlü paylaşımların h ükümeti destekleyici mi yoksa eleştirici mi olduğunu ölçmek için de netimli bir öğrenme algoritması olan ReadMe'yi (Hopkins ve King, 2010) kullandılar; bunu Bölüm 4: Ölçüm'de ele alıyoruz.Özellikle, K PR paylaşımları örnekledi ve bunları rejime karşı eleştirel veya dest ekleyici olarak elle etiketledi. Ardından, ReadMe'yi kullanarak elle e tiketlenmiş belgelerden tüm paylaşım koleksiyonuna genelleme ya parak hükümeti destekle
yen belgelerin oranını ölçtüler.

Ölçüm elinde, KPR şimdi ilgi alanındaki sosyal bilim nedensel etkisini tah min etme görevine yöneldi: bir gönderinin kolektif eylem hakkında olmasın ın, gönderinin sansürlenme olasılığı üzerindeki ortalama etkisi. Ayrıca,

Doclingo https://www.doclingo.ai

sansür olasılığı üzerindeki duygunun ortalama etkisini tahmin etmek.

KPR, toplu eylem etkinlikleri hakkında patlama şeklinde yapılan paylaşımların son derece yüksek bir oranda sansürlendiğini buldu—hükümetin kamu protestol arıyla ilgilietkinlikler hakkında paylaşımları sansürlediğine dair güçlü bir kanıt. Ay rıca, hükümetinpaylaşımları sansürleme kararının, paylaşımın hükümeti destekle yip desteklemediğiyleesasen ilgisiz olduğunu buldular. Sonuçları, hükümetin san sür kurallarının, rejime karşıçevrimiçi muhalefeti bastırmak için tasarlanmadığını , ancak kitlesel protestolarıönlemek amacıyla oluşturulduğunu gösteriyor. Çalış maları ayrıca, metnin nasılnedensel bir çıkarım yapmak için kullanılabileceğine d air bir örnek sunuyor. Bölüm 5:Çıkarım, metinlerle nedensel çıkarımlar için gene l bir yaklaşımı tanımlıyoruz,metnin müdahale, sonuç veya karıştırıcı olduğu duru mlar dahil.

King, Pan ve Roberts (2013) çalışmasında, KPR gözlemsel verilere day anarak sansürün kolektif eyleme odaklandığını savunmaktadır. Ancak, KPR'nin gözlemsel verileri, otomatik olarak sansürlenen ve asla yayınla nmayan gönderileri zorunlu olarak dışlamıştır. Ayrıca, gönderinin konu sunu doğrudan manipüle edemedikleri için, kolektif eylem tartışmasını n sansüre neden olan metnin bir özelliği olmadığı olasılığı kalmaktadır. İlgili müdahalenin rastgele atanabilme yeteneği (bu durumda, gönderini n konusu) tam sansür sürecini yakalamak ve en güvenilir nedensel çıkarı mları yapmak için kritik öneme sahipti. Bu nedenle, KPR, sansür teorilerin e daha fazla kanıt sağlamak için rastgele bir alan deneyini kullanan ikinci bir çalışma, King, Pan ve Roberts (2014) üretti. Çin genelinde yüz sosyal medya sitesinde hesaplar oluşturdular ve bu sitelere metinler gönderdi, 1) metnin protesto olaylarını mı yoksa protestolarla ilgili olmayan olayları mı tartıştığını ve 2) gönderinin hükümete karşı eleştirel mi yoksa destekl eyici mi olduğunu rastgele değiştirerek. Bu deneysel sonuçlar, gözlemsel sonuçlarla aynı sonuca ulaştı ve protesto ile ilgili konuların sansüre nede n olduğunu daha fazla doğruladı.

KPR'nin Çin hükümetinin tehlikeli konuşmaları kaldırma stratejisi üzerin deki içgörüleri, otomatik metin analizi ile ilgili tamamen farklı bir araştırma sorusuyla başladı. Ancak bu, araştırma tasarımlarının aşırı uyumlu, teorik olmayan veya sosyal bilimler için faydasız olduğu anlamına gelmez. Önemli olarak, verilerin ilk keşfi, o verilerin bir alt kümesine dayanıyordu. Bu, KPR' nin farklı bir desenin ortaya çıkabileceği yeni verileri analiz ederek doğru y a da yanlış olduklarını gösterme fırsatına sahip olmasını sağladı.

Ayrıca, KPR'nin araştırma tasarımında teorinin önemli bir rol oynadığı da dikkate değerdir. Çin hükümetinin belirli gönderileri neden sansürlediğine dair basit bir teorik açıklama il e başladılar. Bu teori, verilerinden ortaya çıkan yeni bir soruyu sormalarına yol açtı.

Doclingo https://www.doclingo.ai

İlk çalışmaları, daha kontrollü bir laboratuvar benzeri ortamda toplanan ve rilerle teorik iddiaları pekiştirmeyi amaçlayan ikinci bir çalışmaya ilham ver di. Son olarak, KPR, makalelerinde hükümet sansürü ile ilgili resmi bir mod eli çözmedi veya test etmedi, ancak sonuçları, diğer araştırmacıların KPR'ni n bulgularını açıklamaya ve bağlamlaştırmaya çalışan yeni resmi, teorik mo deller oluşturmasına ilham verdi (Chen, Pan ve Xu, 2016; Lorenzen, 2014). Önemli olarak, KPR'nin araştırma programı tek bir makalede görünm edi; birden fazla çalışma üzerinden kümülatif olarak geliştirildi ve daha geniş bir akademik topluluk tarafından genişletildi.

KPR'nin deneyimini bir referans olarak kullanarak, bu bölümde metni veri ola rak kullanırken araştırma sürecini tanımlıyoruz. Metin verileri ile çalışırken alınm ası gereken kararlara odaklansak da, argümanımız daha genel olup, ampirik sos yal bilimin nasıl ilerleyebileceğine dair bir modeli aydınlatmaktadır.

Doclingo https://www.doclingo.ai

2.7 Metin Analizi için Altı İlke

Metin analizinin kullanımını yönlendirmek için altı ilke sunuyoruz. Tablo 2.1 her bir ilkenin ifadesini sağlar, ardından aşağıdaki referans bölümlerinde detaylandırıyoruz.

2.7.1 SOSYAL BİLİM TEORİLERİ VE ÖNEMLİ BİLGİLER ARAŞTIRMA TASARIMI İÇİN TEMELDİR

Sosyal bilimin temel amacı, sosyal dünyanın nasıl çalıştığını açıklayan teoriler geliştirmektir. Bunu yapmak için, araştırmacılar teorilerini geliştirmek ve rafine etmek için önemli bilgiler ve ampirik kanıtlar kullanır. "Teori"yi sosyal bilim süreçlerinin sistematik yönlerinin açıklamalarını ifade eden geniş bir terim olarak anlıyoruz. Teori, resmi matematiksel modeller veya yazılı cümleler gibi birçok şekilde ifade edilebilir. Teori, hangi verilerin ilgili olduğunu, sonuçların nasıl yorumlanacağını ve sonuçların dünyanın anlaşılması için neden önemli olduğunu belirlediği için araştırma süreci için önemlidir.

Tablo 2.1. Metin Analizi için Anahtar İlkeler

1) Sosyal bilim teorileri ve önemli bilgiler araştırma tasarımı için temeldir. (Bölüm 2.7.1)
2) Metin analizi insanları değiştirmez - onları destekler. (Bölüm 2.7.2)
3) Sosyal bilim teorilerini oluşturmak, rafine etmek ve test etmek yineleme ve birikim gerektirir. (Bölüm 2.7.3)
4) Metin analizi yöntemleri, dilden genelleştirmeler çıkarır. (Bölüm 2.7.4)
5) En iyi yöntem, göreve bağlıdır. (Bölüm 2.7.5)
6) Doğrulamalar esastır ve teori ile göreve bağlıdır. (Bölüm 2.7.6)

Teorik düşünmenin rolünü görmek için, bir araştırma projesinin başlangıcında başlamak faydalıdır. Bazı durumlarda, akademisyenler, temel kavramları tanımlamış ve hipotezler üretmiş zengin bir teorik literatüre dayanmaktadırlar. Örneğin, olumsuz kampanya reklamlarının etkilerini inceleyen kapsamlı bir literatür bulunmaktadır. Bu literatürde, "olumsuz reklam" tanımı, rakipleri olumsuz terimlerle gösteren reklamlar olarak anlaşılmaktadır. Araştırmacılar, olumsuz reklamların seçmen davranışının çeşitli boyutlarını ve diğer adayların davranışlarını nasıl etkilediğini anlamak için bu kategorileştirmeyi kullanmaktadırlar. Bu durumda, teori, ilgi alanındaki bir kavramı nasıl ölçüleceğini açıklar ve "olumsuz reklamların" diğer reklam türlerinden ölçülebilir şekilde farklı etkileri olduğunu öne sürerek ampirik olarak araştırılması gereken hipotezler önerir.

Doclingo https://www.doclingo.ai

Diğer durumlarda ise, akademisyenler, teorik kavramların çok daha az kesin olduğu veya araştırma sorusunun henüz net bir şekilde ifade edilmediği konuları araştırmaktadırlar. KPR'nin araştırma projesine bu şekilde başladı. Örneğin, KPR'nin 2009'da incelemeye başladığı Çin'deki sosyal medya çalışması, nispeten yeni bir alandı. KPR, kamuoyunun otoriter Çin'de nasıl ifade edildiği konusunda genel bir ilgi konusu geliştirdi. Baskıcı rejimlerdeki vatandaşların siyasi tercihlerini nasıl ifade ettiklerine dair zengin bir literatür bulunmaktadır, ancak bu literatür, vatandaşların sosyal medyada nasıl etkileşimde bulunduğunu anlamaya çalışırken yalnızca sınırlı bir rehberlik sunmaktadır; KPR'nin ilgi alanı verisi budur.

Bu belirsizlik nedeniyle, KPR, çevrimiçi gönderilerdeki geniş temaları anlamalarına yardımcı olmak için verilerinin bir alt kümesini keşfetmek amacıyla metin analizi teknikleri kullandı.

Bu ilk keşif modellerinin çıktısını yorumlamak—modellerin tanımladığı metin kategorileri ve ortaya çıkardıkları eğilimler—araştırma için faydalı olacak şekilde, sosyal medyaya gönderi yaparken aktörlerin karşılaştığı teşvikleri, hükümetin sosyal medya şirketlerinin ne yapabileceğini nasıl kısıtladığını ve Çin'deki çevrimiçi kültürü düşünmeyi gerektirir. İşte burada teori ve maddi bilgi devreye giriyor. KPR, Çin hükümetinin davranışına dair akademik literatürden edindikleri anlayışı, otoriter hükümetlerin kamu ifadesine dair teorik anlayışlarıyla birleştirerek verilerindeki kalıpları açıklayan hipotezler geliştirdi.

Ayrıca, teori ve madde, KPR'nin Çin'de sansürün nasıl gerçekleştiğini incelemek için bir veri setine sahip olduğunu keşfetmesi açısından hayati öneme sahipti. İlk modellerini doğrularken ve yorumlarken, KPR bazı gönderilerin artık mevcut olmadığını fark etti. URL'leri yanlışlıkla saklamadıklarından emin olduktan sonra, KPR, Çin hükümetinin sosyal medya gönderilerini sansürleme uygulamasını yakaladıklarını kabul etti. İstatistiksel ve algoritmik araçların bu veri setini geliştirmeyi mümkün kıldığına dair net bir anlayış var. Ancak, yazarların sorunlarının maddesine dikkat etmeleri gerektiği de bir gerçektir—sansür uygulaması hakkında bilgi sahibi olmaları, bunun nasıl tespit edilebileceği ve kamuoyu ve ifade özgürlüğünü anlamak için neden önemli olduğu konusunda bilgi sahibi olmaları gerekiyordu.

KPR’nin örneği, en büyük metin koleksiyonlarının en sofistike algoritmalarla analiz edilmesinin sosyal bilimcilerin sistematik ilişkiler hakkında teoriler geliştirmelerini ve konularını derinlemesine bilmelerini gerektirdiğini göstermektedir. Gerçekten de, büyük metin koleksiyonlarının ve yeni istatistiksel modellerin saldırısı, teorik akıl yürütmeyi daha az değil, daha önemli hale getiriyor. Aksine, bu büyük veri setleri, araştırmacıların teorik ilişkileri hakkında daha kesin düşünmelerine yardımcı oluyor çünkü verideki artış, genellikle daha önce test etmek için çok az veriye sahip oldukları hipotezleri test etmelerine olanak tanıyor.

Doclingo https://www.doclingo.ai

Bu gerçek—veri, istatistiksel algoritmalar ve öznel bilginin bir ar aya gelmesinin daha derin ve zengin teorik içgörülere yol açması— büyük verinin sosyal bilimcilerin nasıl çalıştığını değiştireceği ve te ori geliştirme ihtiyacını ortadan kaldıracağına dair son açıklamalarl a çelişiyor. Yazarlar, büyük verinin ve makine öğrenimi algoritmala rının "Teorinin Sonu: Veri Selinin Bilimsel Yöntemi Geçersiz Kılacağı "na yol açacağını ilan ettiler (Anderson, 2008). Argüman, büyük veri setlerinin teorik düşünme ihtiyacını ortadan kaldıracağıydı çünkü bir projede teorik çalışmanın yaptığı her şeyi daha fazla veri ile değ iştirebilirdik. Bu açıklamalar yanlıştır, çünkü herhangi bir algoritma nın sağlayabileceği şeyi abartmaktadırlar. Bu yaklaşımların işleyişi i çin gerekli olan bir miktar yorumlayıcı çalışma, basitçe otomatikleşt irilemez (en azından öngörülebilir gelecekte). Bağlamsal bilgi, ayrıc a önemli araştırma soruları sormak ve etik yönergelere uyduğumu zdan emin olmak için de gereklidir.Teorinin sona ereceği ve insanl arın geçersiz olacağına dair açıklamaların tam tersine, bu kitapta ta nıttığımız birçok model yalnızca analistlerin derin ve yakın yorumla masıyla faydalıdır.

2.7.2 METİN ANALİZİ İNSANLARI DEĞİŞTİRMEZ—ONLARI TAMAMLAYARAK DESTEK LER

Metin verisi sosyal bilimlerde zaten yaygındır ve uzun bir süredir böyledir. Yüzyıllardır akademisyenler, dünyayı öğrenmek için kitap ları, yasaları, belgeleri ve mülakat transkriptlerini analiz etmiştir. Ni tel yöntem uzmanları, araştırmacıların metinlerdeki bilgileri güveni lir bir şekilde raporlamasını sağlamak ve araştırmanın şeffaflığını a rtırmak için okuma yöntemlerini geliştirmiştir (Corbin ve Strauss, 1 990; King, Keohane ve Verba, 1994; Caporaso, 1995; Glaser, 2002). Bu yöntemlerin merkezinde, bir metindeki içeriği dikkatlice tükete n, aynı zamanda analiz ve içgörüler ekleyerek bir sonuca ulaşan bir araştırmacı bulunmaktadır. Örneğin, McQueen (2018) büyük siyasi düşünürlerin, Machiavelli, Hobbes ve Morgenthau dahil, kendi za manlarının kıyamet hareketlerinden etkilendiğini savunmaktadır. Z ihinsel tarihini yerleştirmek için, bu düşünürlerin yazdığı bağlamı d aha iyi anlamak amacıyla binlerce belgeyi analiz etmektedir.

Yeni bilgisayar destekli metin analizinin, metinlerin dikkatli ve ya kın okumalarını gereksinimini ortadan kaldırarak bu uzun araştırm a geleneğini değiştirebileceğini düşünmek bir hata olur. Aksine, bil gisayar destekli metin analizi, okuma yeteneğimizi arttırmaktadır.

Yeni metin analizi yöntemleri, okumayı tamamen kaçınmak yerine farklı bir şekilde okumamıza yardımcı olur.

Bu insan çabasının artırılması, analistin keşfetme yeteneğini geliştirir

Doclingo https://www.doclingo.ai

ilginç organizasyonlar, ilgi alanındaki ana büyüklükleri ölçmek, nedensele etkileri tahmin etmek ve tahminlerde bulunmak.

Yeni metin analizi yöntemlerinin neden insan okuyucuları değiştirmek yer ine artırdığını daha iyi anlamak için, Hopkins ve King'in (2010) “saman” benze tmesini kullanıyoruz. Metinlerimizin saman sapları gibi olduğunu varsayalım. Metinlere baktığımızda, gördüğümüz şey saman dolu bir alan. Görevimiz, o alandaki belirli bir saman sapını analiz etmek olabilir. Onun güzelliğini anlam ak, belirli özelliklerini tanımlamak veya rengini karakterize etmek isteyebiliriz . Bu benzetimi metin analizine uygulayabiliriz. Belirli bir şiiri analiz etmek ve dilsel güzelliğini tanımlamak isteyebiliriz, belirli bir metin satırıyla etkileşime geçerek anlamını takdir edebiliriz veya bir yazarın tam mesajını daha iyi anla mak için yazılmamış kelimeleri inceleyebiliriz (Strauss, 1952; Melzer, 2014). İnsanlar genellikle bu tür derin okumada çok yetenekli olsalar da, yeni me tin analizi yöntemleri nadiren bu özel görevde yardımcı olmak için tasarlanmıştır. Tanımladığımız yöntemler genellikle küçük veya izole belgelerin özelliklerini tanımlamakta b aşarısız olur.

Şimdi ayrı bir görevi düşünün. Diyelim ki saman saplarının özelliklerini tan ımlamak ve bunları benzer saman sapları yığınlarına ayırmak istiyoruz. İnsan lar, bu tür bir görev için yetersizdir. Bunun nedeni, küçük aktif hafızalarımızı n olması, aynı görevi bir süre yerine getirirken dikkatimizi dağıtmamız ve tali matları doğru yorumlayamadığımız için hatalar yapmamızdır. Buna karşılık, algoritmalar, iyi tanımlanmış bir hedef fonksiyonu veya bir bilgisayarın kopy alayabileceği insan rehberliği sağlandığında sıralama konusunda son derece iyi çalışır. Metne uygulandığında, bu, bilgisayarların yeni organizasyonlar ke şfettiğinde ve metinleri daha düşük boyutlara sıkıştırdığında iyi çalıştığını im a eder.

Yeni metin analizi yöntemleri, bu nedenle, insanların zorlandığı görevleri başarmak için en iyi şekilde uygundur. Bu kitapta tanımladığımız yöntemler, metinlerin yakın okumalarına rakip değil, tamamlayıcıdır. Örneğin, keşif aşa masında, yeni metin analizi yöntemleri, bilgisayar tarafından keşfedilen orga nizasyonlarla metinlerin yakın okumalarını yönlendirebilir ve destekleyebilir, böylece uzmanlar tarafından yorumlanan yeni kavramların ortaya çıkmasına yardımcı olur. Blaydes, Grimmer ve McQueen (2018), 1000-1600 CE yılları ara sında Müslüman ve Hristiyan ülkelerde yazılmış hükümdarlara yönelik tavsiy elerin büyük bir koleksiyonunu analiz eder. Metinlerin büyük koleksiyonunu analiz etmek için, Blaydes, Grimmer ve McQueen (2018), kaba ve ayrıntılı kon uları keşfeden ve bunları metinlere uygulayan bir yöntem tanıtır. Metinlerin organizasyonunu bir rehber olarak kullanarak, Hristiyan ve Müslüman metin lerde temaların farklı evrimini karakterize ederler. Hristiyan metinlerinde, ya zarlar, dinin bir yer kapladığı bir sekülerleşmenin gerçekleştiğini gösterirler.

Doclingo https://www.doclingo.ai

daha küçük ve daha küçük bir metin payı. Bu arada, Müslüman metinlerd e dini içeriğin payısabit kalmaktadır. Bu kanıtlara dayanarak, yazarlar Mü slüman ve Hristiyan krallıklarıarasındaki ayrışmanın, kısmen adil yönetim için dinin öneminden kaynaklandığınıteorize etmektedirler. Ayrışmayı be lirlemek için, yazarlar hem bilgisayar desteklisıralama sonuçlarına hem d e metinlerin kendi dikkatli okumalarına dayanmaktadırlar.

Yeni metin analizi yöntemleri, bazı araştırma görevlerini daha ucuz hale getirir, bu da daha fazla araştırma projesinin gerçekçi maliyet kısıtlamaları içindemümkün olmasını sağlayarak insan araştırmasını artırır. Bu, özellikle sınıflandırmayöntemle ri için doğrudur. Büyük bir yöntem sınıfı, belgeleri önceden belirlenmişkategori set lerine atamak için kurallar geliştirir. Pahalı ve zaman alıcı manuelkodlama ile uğraş mak yerine, denetimli yöntemler sınıflandırma için gerekli olaninsan müdahalesi m iktarını azaltır. Diğer sınıflandırma yöntemleri ise insankodlamasını tamamen orta dan kaldırır ve bunun yerine belgeleri sınıflandırmak içinproxy'ler kullanır. Denetimli ölçekleme yöntemleri, WordScores (Laver, Benoit ve Garry gibi) 2003), benzer şekilde belgeleri, araştırmacı tarafından önceden belirlenen sabit noktalara sa hip düşük boyutlu bir alana yerleştirir.

Metin üzerine uygulanan makine öğrenimi algoritmaları, açıkça bi r hız avantajına sahiptir. Bu, hala yüksek boyutlu sorunlara yol açabil en nispeten küçük metin koleksiyonları için de doğrudur. Nedenini g örmek için, en ilginç bölümü tanımlamak amacıyla 100 açık uçlu ank et yanıtını sınıflandırmakla ilgilendiğimizi varsayalım—her metni yal nızca bir kategoriye atayan bir organizasyon—belgelerin. Bu, nispet en küçük bir veri kümesidir. Hanna Wallach, bu boyuttaki korpusları "sanatsal veri" olarak adlandırıyor; bu, bir veri kümesinin daha küçü k boyutuna ve metin koleksiyonlarının dikkatli bir şekilde düzenlen mesine bir atıftır. Ancak, bu basit görünen hedefi bu küçük veri küm esinde gerçekleştirmek, yine de devasa bir alan üzerinde bir arama gerektirir. Bir koleksiyondan potansiyel bölümlerin sayısını *er* ile karakterize edebiliriz. Örneğin, iki belgemiz varsa {A , B } o zam an Bell sayısı 2'dir— A B aynı bölüme atanmış ve A , B farklı bölümler e atanmıştır. Üç belge ile Bell sayısı 5'dir— A B C; A , B C ; A B , C ; A C , B ; A , B , C. 100 belge ile Bell sayısı 1 0 1 1 5'tir.6 8—anlaşılmaz der ecede büyük bir sayı. Karşılaştırma için, bilim insanları bilinen evren de yaklaşık 1 0 8 0 atom olduğunu tahmin ediyor. Açıkça, o halde, ya lnızca 100 bel

ge ile hesaplama yöntemlerinin keşfetmemize yardımcı olabileceği gerçekten devasa bir olası organizasyon alanı vardır.

Sonuçta, metin analizi temelde nitel bir görevi yerine getirir: metin k oleksiyonlarından anlam ve analiz çıkarmak. Bu kitapta tanıttığımız yön temler ve araştırma tasarımları, nicel ve nitel ayrımını kapatmaktadır.

Doclingo https://www.doclingo.ai

Kitap boyunca, araştırmacıların metinlerin derinlemesine okunmasını, m etinlerin üretildiği bağlamı ve onları üreten kişileri anlamalarını öneriyor uz. Otomatik metin yöntemleri, istatistiksel ve algoritmik temelleri sayesi nde insanların belgeleri okumasına, düzenlemesine ve analiz etmesine y ardımcı olduğu için faydalıdır. Bu şekilde, teori ile bir arada kullanıldığınd a, yeni metin analizi yöntemleri keşfi hızlandırır, ölçümü daha verimli hal e getirir ve nedensel etkilerin tahminini kolaylaştırır.

2.7.3 SOSYAL BİLİMLER TEORİLERİNİ KURMAK, İYİLEŞTİRMEK VE TES T ETMEK İTERASYON VE BİRİKİM GEREKTİRİR

Yukarıda açıkladığımız gibi, sosyal bilimin amacı sosyal olgular için sağ lam teorik açıklamalar oluşturmaktır. Ancak teori oluşturma, genellikle te orik çıkarımlardan kanıt biriktirmek ve ardından bu çıkarımlara göre teori yi revize etmek kadar basit değildir. Sosyal bilimler teori oluşturmanın ne redeyse tamamen tümevarımsal olduğu algısı, verileri toplamanın, anketl er yapmanın, deneyler gerçekleştirmenin ve deneklerle görüşmenin pah alı olduğu ve düşünmenin görece ucuz olduğu bir dönemin ürünüdür. Düşünmenin maliyeti zamanla nispeten sabit kalırken, veri toplama ve analiz maliyeti düşmüştür. Sonuç olarak, sosyal bilimcilerin—hatta en küçük bütçeler e sahip olanların bile—araştırma sürecinin ilk aşamalarında yeni veri edinimini açık bir parça olarak dahil etmeleri artık pratik hale gelmiştir. Bu, veri için ilk ör neklerin keşif amacıyla kullanılabileceği anlamına gelir; bu da araştırmacıların verilerin nasıl organize edilebileceğine dair yeni yollar bulmalarına yol açabilir. Yeni organizasyonlar yeni ölçümler ve nihayetinde yeni sorular önerir. Bu, bizi yeni araştırma tasarımlarını takip etmeye yönlendirir; bunları da nedensel çıka rımları tahmin etmek veya gelecekte ne olacağına dair tahminler yapmak için k ullanırız.

Önemli bir şekilde, savunduğumuz sosyal bilimlere yönelik yinelemeli ve bir ikimli yaklaşım teorik değildir. Aksine, araştırma sürecinin her aşaması teori tar afından bilgilendirilir. Süreç ayrıca bize yeni teorik açıklamalar geliştirmemize v e ardından bu açıklamaları test etmemize yardımcı olabilir. Örneğin, bir kavra msallaştırma geliştirmek, önceki teorik çalışmaların dünyayı nasıl organize etti ğini ve bir organizasyonun ne ölçüde yeni olduğunu bilmek gerektirir. Ölçümle r, teorik olarak ilgi çeken büyüklüklerle örtüştükleri ölçüde ilginçtir. Tahmin edilen nedensel etkiler, gözlemlenebilir sonuçların bir veri setinde ne ölçüde bulund uğunu ve hangi gözlemlenebilir sonuçların mevcut olmadığını ortaya çıkararak yeni teoriler geliştirmemize ve mevcut teorileri test etmemize yardımcı olabilir.

Verilerden öğrenmek, teorileri güncellemek ve ardından bu revize edilmiş teorileri test etmek, sosyal bilimlerin tipik olarak nasıl öğretildiğinden büyük bir sapmadır. Ancak,

Doclingo https://www.doclingo.ai

aslında sosyal bilimlerin tipik olarak nasıl uygulandığıyla uyumlu olduğunu s avunuyoruz. Sosyal bilimin bu yinelemeli ve birikimli tanımını, sosyal bilim ar aştırmalarının nasıl yapıldığına dair daha doğru bir hesap olarak görüyoruz. Artan şeffaflık, araştırma sürecinin belirli aşamalarında farklı yöntemlerin de ğerini netleştirir ve bireysel araştırma görevlerini desteklemek için yeni yönt emler tasarlamamıza olanak tanır. Örneğin, bu kitapta Bölüm 3' de, sosyal bi limlerde pek dikkat çekmeyen keşif yöntemlerini tanımlıyoruz. Bunun, kısme n, gerçek araştırma başlamadan önce kavramsallaştırmaların nasıl üretildiği ni göz ardı etme eğiliminden kaynaklandığını düşünüyoruz.

Kitap boyunca vurgulayacağımız gibi, araştırmanın yinelemeli doğası, analis tlerin örneklerini bir eğitim setine ve bir test setine ayırmalarını düzenli olarak önermemize yol açar. Araştırma sürecinin neredeyse her aşamasında—keşif, ö lçüm, nedensel çıkarım ve tahmin—örnek ayırmayı teşvik ediyoruz. Keşifte, bel irli bir desenin veya organizasyonun yalnızca bir alt örnekte mi yoksa tüm sett e mi öne çıktığını öğrenmek için bu hayati öneme sahiptir. Ölçümde, bölünmü ş bir örnek kullanımı, nesneleri sınıflandırmak için kullanılan işlevlerin aşırı uyu m sağlamadığını garanti eder ve taze veriler, sınıflandırıcımızın yeni veriler üze rindeki performansını doğru bir şekilde değerlendirebilmemizi sağlar. Bölüm 5: Çıkarımda, makine öğrenimi yöntemlerini nedensel çıkarımda kullanmak için eği tim/test ayrımının gerekli olduğunu gösteriyoruz. Eğitim aşaması, yöntemimizi aya rlamamıza olanak tanır, böylece bazı ilgi sonuçları üzerinde nedensel etki yaratan müdahalelere yol açma olasılığı yüksek kavramsallaştırmalar keşfederiz. Test aşam ası, nedensel etkinin boyutunu güvenilir bir şekilde değerlendirmemizi sağlar ve n edensel çıkarımda sık karşılaşılan bazı sorunlardan kaçınmamıza yardımcı olur. Örnek ayırma, belki de tahmin uygulamalarında en yaygın olanıdır; burada doğrul uğu değerlendirmede hayati bir rol oynar.

Örnek ayırmanın keşif ve ölçüm aşamalarındaki rolü, ampirik analizdeki en büyük endişelerden birini çözmeye yardımcı olduğu için vurgulanmaya değerdir: analistlerin, çoklu test nedeniyle diğer veri setlerine genelleneme yecek sonuçlar keşfetmek için verileri üzerinde büyük sayıda istatistiksel te stler yapacak olmaları. Dedüktif araştırma yaklaşımı, keşfin veri edinilmede n önce tamamlandığını varsaydığı için, bu soruna yönelik mevcut popüler ç özüm, araştırmacıların hipotezlerini bir ön analiz planında kaydetmeleridir. Ancak, örnek ayırma, özellikle metin verileri için daha iyi bir çözüm sunar. Ön analiz planları, genellikle içeriklerini düzenlemek ve sapmaların meyda na geldiğini fark etmek için başkalarının varlığı olduğunda etkili olur. Araştı rmacılar genellikle ön analiz planlarını kontrol etmek için zaman bulamazla r ve mevcut kaynaklar, çalışmaları önceden kaydetmeyi zorlaştırır, bu da ni hai bir makalenin başlangıçtaki ön analiz planıyla bağlantı kurmasını zorlaş tırır. Ön kayıt kaynakları durumu daha da kötüleştirir.

Doclingo https://www.doclingo.ai

bu problemi araştırmacıların ön analiz planlarını değiştirmelerine izin vererek çözme ktedir. Bölünmüşörnekler büyük ölçüde bu tuzaklardan kaçınır çünkü okuyuculara şe ffaftır.

Örnekleri bölme önerisi genellikle iki farklı itirazla karşılanır. İlk itiraz, be lirli bir deneyin çok maliyetli olabileceği ve örneği bölmenin güçteki azalma yı haklı çıkarmadığıdır. Daha ayrıntılı olarak açıkladığımız gibi Bölüm 5: Çıkar ım, güçteki herhangi bir kaybın itirazının örneği bölmemenin risklerinden d aha ağır basmadığını düşünüyoruz. Özellikle payların yüksek olduğu, müdah alelerin pahalı olduğu ve kamu politikası için sonuçların net olduğu duruml arda, tahmin ettiğimiz etkilerde mümkün olan en yüksek güveni sağlamak i stiyoruz. Bölünmüş bir örnek, aşırı uyumun sağlam bir şekilde tespitini sağl arken, aynı zamanda veri temizleme kurallarımızın belirli bir veri kümesinin gerçeklerini dikkate almasını da sağlar. İkinci itiraz, bazı tarihsel verilerin y alnızca bir kez meydana gelebileceği ve bu nedenle bir örneği yalnızca bir kez bölmenin mümkün olabileceğidir. Bazı durumlarda bu doğru olacaktır: bazı olaylar yalnızca bir kez meydana gelir ve bu nedenle bize yalnızca bir veri kümesi (ve dolayısıyla bir örnek bölmesi) sağlar.

Ancak Fowler ve Montagnes (2015) tarafından önerildiği gibi, bu, insanların fark ettiğinde n daha az sıklıkta gerçekleşir, çünkü genellikle incelenebilecek benzer müdahaleler vardır. Örneğin, Healy, Malhotra ve Mo (2010) tarafından yapılan çarpıcı bulguyu inc eliyorlar; üniversite futbolu skorlarının Kongre seçimlerini etkilediğini, Ulusal Futbol Ligi (NFL) oyunlarının etkisini inceleyerek, NFL skorlarının seçim sonu çlarını etkilediğine dair hiçbir belirti bulamadıklarını ortaya koyuyorlar. Bu ilg ili çalışma faydalıdır çünkü Healy, Malhotra ve Mo (2010) içindeki mantık doğ ruysa, NFL oyunlarından benzer bir etki görmeyi bekleriz. Böylece, benzersiz hissettiren tarihi metin koleksiyonları olsa bile, farklı zamanlarda veya farklı y erlerde muhtemelen benzer müdahaleler vardır.

2.7.4 METİN ANALİZİ YÖNTEMLERİ DİLİ GENELLEŞTİRİR

Metin, karmaşık bir veri biçimidir. Amerikan siyasi tarihindeki en büyü k konuşmalardan birini düşünün. Suikastinin eşiğinde, Martin Luther Kin g, Jr., Memphis, Tennessee'de "Dağa Çıktım" başlıklı bir konuşma yaptı. C oşkulu konuşmasında, King hayatına yönelik tehditlerle yüzleşiyor ve keh anet dolu bir beyanla kapanış yapıyor:

> Herkes gibi, uzun bir yaşam sürmek isterim. Uzun ömürlü olmanın bir yeri var. Ama şu anda bununla ilgilenmiyorum. Sadece Tanrı'nın iradesini yerine ge tirmek istiyorum. VeBeni dağa çıkmaya izin verdi. Ve baktım. VeVaadedilmi ş Toprakları gördüm. Belki sizinle oraya ulaşamayacağım. Ama istiyorum

Doclingo https://www.doclingo.ai

bu gece bilmenizi, bizler, bir halk olarak, vaadedilmiş topraklara ulaşacağız!

“Dağın Zirvesine Çıktım” zengin, karmaşık bir metin. Kutsal kitap h ikayelerine, özellikle Çıkış Kitabı'na canlı biratıfta bulunuyor. Kral, ke ndisini Musa ile, siyah izleyicileri Mısır'dan kaçan kölelerle, eşit hakla r ve adalet arayışını isekaçan kölelerin kendi topraklarını bulmasıyla örtük bir şekilde karşılaştırıyor. Konuşmanın gücünün bir kısmı,ne z aman yapıldığı ve kim tarafından yapıldığı ile ilgilidir: suikastinin eşiğ inde, ikonik bir sivil haklar lideri geleceğe dair vizyonunu tartışıyor. Tüm bu bağlam, Kral'ın mesajını anlamak ve konuşmanın Amerika Birleşik Devletle ri (ABD) tarihindeki önemli bir an olmasının nedenini anlamak için önemlidir. Hiçbir metin analizimetodu bu düzeydeki karmaşıklığı ve bağlamı tam olarak yakalamayı umamaz, bunun çoğu metinden bile gelmiyor.

Metin analizi yöntemlerinin amacı, bu karmaşıklığı daha basit bir şeye indirgemek için bir damıtma geliştirmektir. Bunu genellikle m atematik diliyle konuşacağız ve metni yüksek boyutlu olarak adlan dıracağız çünkü her metnin tüm bilgilerini sayılarla temsil edebilec ek bir veri seti birçok, birçok özellik veya sütun gerektirecektir. Bu, sosyal bilimlerdeki birçok yaygın veri setiyle keskin bir tezat oluştur maktadır; burada bir anket katılımcısının geliri, yaşı veya bir konu h akkındaki görüşü gibi özellikler her biri tek bir sayıda saklanabilir. Metin analizi yöntemleri, metindeki yüksek boyutlu bilgiyi daha dü şük boyutlu bir temsile sıkıştırmakla ilgilidir; bu temsil, belirli bir so syal bilim araştırma gündemi için yararlı olan içeriği korur. Bu, bir f ilm eleştirisini olumlu veya olumsuz olarak temsil etmek kadar basi t veya bir yasama tasarısını onlarca kategori boyunca notlandırma k kadar karmaşık olabilir.

Bilgiyi azaltmanın ve yalnızca araştırmacı için ilgili olan metin içeriği ni çıkarmanın birçok nedeni vardır. İlk olarak, bilgiyi damıtmak, metni başka türlü zor olabilecek bir şekilde yorumlanabilir ve genelleştirilebi lir hale getirebilir. Bir metindeki bilgiyi damıtmak, onu başka metinlerl e bazı boyutlarda ilişkilendirmemizi sağlar. Keşif aşamasında, metnin karmaşıklığını azaltmak, belgelerin bir organizasyonunu sağlayabilir v e bu da araştırmacının bu belgeleri okuma şeklini bilgilendirir. Bir ölç üm gerçekleştirirken, bilginin azaltılması, neyi ölçtüğümüzü ve bunun neden ilgi büyüklüğü olarak ilgili olabileceğini anlamamıza olanak tan ır. Örneğin, siyasi yasaları ve oylama kararlarını ideoloji veya partizanlı k gibi tek bir boyuta indirgemek, siyasi kararları özetlemek için son de rece yararlı olabilir.

Metnin boyutunu azaltmanın ikinci bir nedeni istatistiksel

Doclingo https://www.doclingo.ai

özellikler. Metinleri tahmin yapmak, metinlerin bir bireyi nasıl etkilediği ni çıkarmak veya iki metnin benzerliğini belirlemeye çalıştığımızda, tüm metinle çalışmamız mümkün değildir çünkü çok fazla bilgi vardır. Bu b oyutlanma laneti, metin analizi yöntemlerinin birkaç istatistiksel uygula masında kendini gösterebilir. Tahmin yapmaya çalışırken boyutları azal tmazsak, aşırı uyum sağlarız ve tahminlerimiz kötü performans gösterir . Nedensel etkileri çıkarmaya çalışırken boyutları azaltmazsak, ilgi alanı ndaki nedensel etkileri güvenilir bir şekilde tahmin etmek için gerekli te mel bilgilere sahip olamayız. O halde ilerlemenin tek yolu karmaşıklığı a zaltmaktır.

Metnin boyutunu azaltmanın üçüncü bir nedeni, çoğu sosyal bilim teorisi nin nispeten düşük boyutlu kavramlar hakkında olmasıdır. Örneğin, siyaset b ilimi alanındaki birçok teori, siyasi çatışmanın düşük boyutlu bir ideolojik spe ktrum boyunca gerçekleştiğini varsayar (Downs, 1957). Bu teorilerin gözleml enebilir sonuçlarını test etmek için, bu spektrum boyunca bireylerin ölçümler ine ihtiyacımız var. Bunu metin analizi kullanarak yapmanın bir yolu, bir kişin in çevrimiçi paylaşımlarını çok muhafazakâr, muhafazakâr, merkezci, liberal veya çok liberal olarak kategorize etmektir.

Boyutsallığı azaltmanın önemi göz önüne alındığında, bu kitapta ku llandığımız belirli damıtma yöntemini, sahip olduğu özellikleri ve iyi ya da kötü bir iş yapıp yapmadığımızı nasıl bileceğimizi anlamaya odakla nacağız. Kullandığımız damıtmalar birkaç biçim alacaktır. Birçok sosya l bilimci için en tanıdık olanı, belgeleri bir dizi kategoriye elle kodlama k için araştırma asistanları kullanmaktır. Ayrıca birkaç bilgisayar deste kli damıtma yöntemini de tanıtıyoruz. İlk olarak, daha önce görülmem iş belgeleri yerleştiren ve bunları bilinen kategorilere atayan istatistiks el olarak öğrenilen bir damıtma için manuel kodlama örneklerini kulla nıyoruz. İkincisi, bir belge koleksiyonunu alıyor, bunları bir dizi katego riye ayırıyor ve ardından belgeleri kategorilere atıyoruz. Üçüncüsü, bir belge koleksiyonunda mevcut olan tedavileri keşfetmek için bir damıt ma kullanıyoruz. Bu yaklaşımlardan herhangi biri bilgi kaybını gerektir ecektir - ve bu sorun değil. Aslında, sıkıştırma bu çalışmanın amacıdır.

2.7.5 EN İYİ YÖNTEM GÖREVE BAĞLIDIR

Genel hedefimiz her zaman metinleri mümkün olan en faydalı içeriğe damıtmak olsa da, tüm metin analizi görevleri için en iyi olan tek bir yönt em yoktur. Gerçekten de, tek bir görev için bile, faydalı olabilecek birkaç f arklı yöntem olabilir. Ayrıca, ürettiğimiz algoritmaların ve istatistiksel mo dellerin diğer tüm yöntemlerden üstün olduğunu da savunmuyoruz.

Tam tersine, pragmatik, görev odaklı bir yaklaşım benimsiyoruz: araştırmacılar denemelidir

Doclingo https://www.doclingo.ai

birkaç yöntem, performanslarını değerlendirin ve hedeflerine en iyi şekilde ulaşma larına yardımcı olanı seçin.

Farklı metin türleriyle çalışarak farklı görevleri yerine getirmek için deneyimi mize dayanan pragmatik bir yaklaşımı savunuyoruz. Aslında, bu, metin analizi yö ntemlerini kullanma konusundaki agnostik yaklaşımımızın birincil nedenidir. Far klı yöntemlerin performansı, analiz ettiğimiz metin türlerine göre genellikle öne mli ölçüde değişir; bu metinler uzunluk, içerik, resmiyet ve dilbilgisel yapı açısınd an farklılık gösterir. Örneğin, kitap boyunca tartıştığımız konu modellerinin, gaze te makaleleri veya siyasi ya da sosyal elitlerden gelen iyi hazırlanmış açıklamaları analiz ederken konu çıkarımı görevinde son derece iyi performans gösterdiğini deneyimledik. Konu modelleri diğer ortamlarda da iyi çalışabilse de, daha kısa ifa deler veya daha gayri resmi dil ile başa çıkarken performansları dengesiz olabilir. Metinlerin büyük çeşitliliği, herhangi bir yöntemin tüm metin türleri arasında na sıl performans göstereceğini bilmekte zorluk yaratmaktadır.

Metin analizi yöntemlerini uygulamak için görev odaklı bir yaklaşım ı da savunuyoruz çünkü ilgi alanları, metinden ne öğrenmek istediğim ize bağlı olarak değişir. Örneğin, bir metnin konusunu öğrenmekle ilg ileniyorsak, çıkarmak istediğimiz içerik, onun duygusunu öğrenmekle ilgileniyorsak çıkarmak istediğimiz içerikten niteliksel olarak farklıdır. Bir metnin ideolojisini tanımlamak, yazarını tanımlamaktan oldukça farklı dır(stilometri alanından bir görev). Sosyal bilimcilerin metinlerden çıkarm ayı umduğu miktar türleri çeşitlidir ve sürekli olarak büyümektedir.

Görevlerin kendisinde de çeşitlilik vardır. Metinlerin bir organizasyonun u keşfetmek, belgeleri önceden var olan kategorilere sınıflandırmaktan te melde farklıdır; bu da bir metnin nedensel etkisini çıkarmaktan farklıdır. So syal bilimcilerin yöntemlerine koyduğu çok sayıda talep, tüm araştırma sor uları için metin analizini yapmanın tek bir doğru yolu olmadığını garanti ed er. Bu kitapta, farklı seçenekleri sunmaya ve iyi performans göstermesini b eklediğimiz belirli yöntemleri tanımlamaya odaklanıyoruz.

Kullanılacak en iyi yöntemin, mevcut göreve bağlı olmasının bir diğer nedeni, metin verilerine uygulanan yöntemlerin, istatistiğin birçok diğer alanında bulunan istatistiksel teoriden yoksun olma eğilimidir. Bu kitapta tartıştığımız tahminciler için önemli ve derin istatistiksel teorik özellikler vardır; bu, yöntemlerin performansını değerlendirmemize yardımcı olur. Ancak, en teorik olarak iyi geliştirilmiş yöntemlerin bile, yöntemin perfor mansını doğal dil ile ilişkilendiren veya belirli sosyal bilim görevlerine bağ layan çok az teoremi vardır. Bu, metin verisi yöntemlerine kayıtsız bir yakl aşım kullanmanın bir başka ana nedenini temsil eder. Her zaman metnin temsilleri ile çalışırız, konuşulan dilin kendisiyle değil. Yani,

Doclingo https://www.doclingo.ai

Metnin nasıl oluşturulduğunu yöneten yapısal parametrelerin olduğunu varsays ak bile, istatistiksel özellikler, metnin (genellikle çok basitleştirilmiş) bir temsili üz erinde koşullandırılarak kanıtlanmıştır ve sosyal bilimlerdeki kullanımlarımızla ta m olarak örtüşmeyebilecek görevlerle ilgilidir.

Buna göre, genel olarak, verilerimize uyguladığımız yöntemlere olan güvenimiz, o nların istatistiksel özelliklerinin kanıtlarına dayanmamaktadır. Aksine, güvenimiz, yön temlerin gerçek metinlere uygulandığında nasıl performans gösterdiğine dair ampiri k kanıtlara dayanmaktadır: çeşitli sorunlar üzerinde iyi performans gösteren yönteml eri benimseriz. Doğrulama konusunu tartıştığımız bir sonraki bölümde açıkladığımız gibi, bu, metin analizi yöntemlerinin her uygulamasının kapsamlı bir değerlendirme gerektirdiği anlamına gelir, çünkü önceden, yöntemin belirli verilerimizle istediğimiz görevde iyi performans göstereceğinden emin olamayız.

2.7.6 DOĞRULAMALAR TEMELDİR VE TEORİYE VE GÖREVE BAĞLIDIR

Metin analizine yönelik agnostik ve pragmatik yaklaşımımız, dilin kar maşıklığı, görevlerin değişkenliği ve metin analizi yöntemlerinin istatisti ksel özelliklerini doğal dil ile bağlamanın zorluğu nedeniyle esastır. Son uç olarak, doğal dile uygulanan metin analizi yöntemlerini haklı çıkaran çok az (varsa) teorem bulunmaktadır. Bu nedenle, metin analizi yöntem lerinin her uygulaması, modellerimizin ürettiği ölçümlerin özelliklerini d oğrulamamızı gerektirir. Doğrulamalar gereklidir çünkü metin analizi y öntemlerini kullanmanın birincil gerekçesi ampirik kanıtlardır:
Geçmişte benzer sorunlara uygulandığında iyi sonuç veren yöntemler kullanı yoruz. Elbette, üzerinde çalıştığımız veri setinin, yöntemin geçmişte iyi perfor mans gösterdiği diğer metin koleksiyonlarıyla benzer özelliklere sahip olduğ unu düşünebiliriz. Ancak, metin koleksiyonları birçok yönden birbirinden far klı olabilir ve bu farklılıkların bir yöntemin performansını nasıl etkileyebileceğ ini anlamak genellikle zordur; sonuçları doğrulamadan önce.

Metin analizi literatüründeki yöntemler için yapılan çoğu gerekçe ampirik ol duğundan, bir yöntemin belirli bir veri setinde iyi performans gösterdiğini kanı tlamak için doğrulama kritik öneme sahiptir. Ancak, belirlediğimiz kelime anla mında görevi yerine getirmek, nihai hedefimizi gerçekleştirmek için ne gerekli ne de yeterlidir: geçerli bir sosyal bilim çıkarımı yapmak. Bir yöntem belirli gör evde iyi performans gösterebilir, ancak düşük seviyeli ölçümleri bir ilgi birimin e topladığımızda, yanlılık birikerek bazı toplu, birim düzeyindeki davranışların y anlış ölçülmesine neden olabilir. Ve, yöntemimiz doğru birim düzeyinde ölçüml er üretebilse bile, hala ilgi alanımızı ölçtüğümüzü doğrulamamız gerekir. Bu ne denle, araştırma projeleri genellikle birkaç doğrulama adımı içerir.

Doclingo https://www.doclingo.ai

İlk doğrulama, yöntemimizin tasarlandığı belirli görevi doğru bir şekilde yerine getirip getirmediğini değerlendirir. Bu tür bir doğrulama, insan kodlama kararların ı çoğaltma görevimiz olduğu denetimli sınıflandırma yöntemleriyle ve gelecekte bir değişkeni doğru bir şekilde tahmin etme görevimiz olduğu tahminlerle en belirgin şekilde görülür. Her iki görevdeki performansı değerlendirmek için, cevabını bildiğ imiz veriler üzerinde görevi çoğaltabilir miyiz diye soruyoruz? Bölüm 4: Ölçüm, doğrulama veri setlerinin ve çapraz doğrulamanın, yöntemimizin belgeleri katego rilere ne kadar iyi sınıflandırdığını nasıl değerlendirebileceğini tanımlıyoruz. Bölüm 5: Çıkarım, ana analizden çıkardığımız verilerin tahminlerimizin doğruluğunu d eğerlendirmemize yardımcı olabileceği koşulları tartışıyoruz.

Keşif için kullandığımız denetimsiz modelleri değerlendirmek için çeşitli araçlar da geliştirilmiştir (Bölüm 3: Keşif), ölçüm için (Bölüm 4: Ölçüm), ve nedensel çıkarımları kolaylaştırmak için (Bölüm 5: Çıkarım). Budoğrul amalar çeşitli şekillerde çalışır. Bazıları, araştırmacının belirli birkategoride atanan metinleri manuel olarak okumasını ve damıtma sürecindençıkan organizasyonların tutarlı olup olmadığını belirlemesini içerir. Diğerdoğrulamalar, bir kategoriyi veya gizli boyutu gösteren özellikleri inceleyerek,bu özelliklerin tutarlı olup olmadığını v e araştırmacı için tanımlanabilir birilgi büyüklüğüne karşılık gelip gelmediğini değe rlendirmeyi içerir. Başka biryaklaşım, belirli bir metin analizi yönteminin veriye ne kadar iyi uyduğunudeğerlendiren model uyumu için nicel ölçümler kullanmaktır.

Tanımladığımız birçok doğrulama yönteminin ortak bir özelliği, “insanları dön güye dahil etmesi”dir; bu, kısmen otomatikleştirilmiş bir süreçte insan yargısına açıkça dayanır ve iki ana içgörü içerir. İlk olarak, birçok görev için, modelleri insa nların modelin sağladığı bilgiyi nasıl kullandığına dayanarak değerlendirmek isti yoruz. İkincisi, insan bilgisini dahil etmek için, araştırmacıların modeli seçerken k eyfi kriterlerden kaçınmalarını sağlamak için deneyleri dikkatlice tasarlamamız g erekiyor. Bu içgörüleri akılda tutarak, geniş bir metin analizi yöntemleri yelpazesi nden konuların ve kümelerin kalitesini değerlendirmek için deneysel kanıtları na sıl kullanacağımızı açıklıyoruz.

İnceleme gerektiren bir diğer adım, ölçümlerin belgeler arasında nasıl topla ndığıdır. Örneğin, spam için bir e-posta sınıflandırıcınız olduğunu hayal edin; b u sınıflandırıcı bazen spam e-postaları gelen kutunuza alıyor ama çok nadiren önemli bir mesajı spam klasörünüze gönderiyor. Bu, çoğu insanın bir spam filt resinde istediği bir özelliktir, ancak aynı zamanda bir e-postanın spam olmama olasılığının sistematik olarak abartıldığını da gösterir. Eğer bu tahminleri topla yarak spam olan e-postaların toplam oranını değerlendirecek olursak, aldığımı z spam e-postalarının yukarıya doğru yanlı bir tahminini elde ederiz. Böylece, b ireysel sınıflandırmaları değerlendirmekle kalmayıp, aynı zamanda

Doclingo https://www.doclingo.ai

bireysel düzeydeki kararların birleştirilmesinin sistematik yanlılık getirmediğini gösterdi ği, bu durumun da ölçümlerimizi daha az kullanışlı hale getireceği.

Ayrıca, ölçümlerin *yüzey geçerliliği* sağladığını belirlemek de sı klıkla faydalıdır. Yani, en azından, ölçümlerimizin bir konu uzmanın ın denetiminden geçmesini beklemeliyiz. Yüzey geçerliliğini aşmak zordur. *Hipotez geçerliliği* , bir veri kümesinin beklenen bir dizi de sene uyduğunu gösteren bir kanıttır. Bu, ölçümlerimizin kalitesini değerlendirmek için resmi bir mekanizma sağlar. Elbette, bir ölçü mün hipotez doğrulamasını geçememesi ile bir araştırma bulgusu nun arasında bulanık bir sınır olabilir. Olumsuz bir bulguyu açıkla manın zor olacağı kadar açık hipotezler seçmek esastır. Örneğin, S enato basın bültenlerinin konusal sınıflandırmasının doğruluğunu göstermek için Grimmer (2013*b*), komite başkanlarının kendi komi telerinin yetki alanındaki konulara ortalama bir senatörden daha f azla odaklandığını gös
terir. Bu bulgu hem açıktır hem de doğru olmadığı gösterilirse açıklamak zor olacaktır.

Son bir doğrulama, metnin sıkıştırmasına eklediğimiz etiketin, ölçü mün metinden gerçekten neyi yakaladığını yansıttığını değerlendirme ktedir. Etiket *sadakati* değerlendirmesi, belirli bir metin sıkıştırmasını n bir araştırma görevi için geçerliliğini sağlamak açısından esastır. Elle kodlama yaparken veya denetimli bir yöntem kullanırken, sadakat sağla mak için anahtar, kategorilerin kod kitabında nasıl tanımlandığına dair şeffaf lık sağlamaktır ve kodlayıcıların kodlama kurallarına uyduğunu göstermektir. Denetimsiz yöntemler için sadakat gösterimleri daha zorlayıcı olabilir. Bazı teknikler basittir—örneğin, okuyucuya örnek metin sağlamak. Ve her zaman , keşfedilen kategorileri elle kodlama ve denetimli yöntemler kullanarak doğrula mak bir seçenek olarak mevcuttur. Yani, önceden belirlenmiş kategoriler olmada n bir yöntem kullanarak başlangıçta keşfedilen ölçümleri alabiliriz ve ardından b u kategorileri bir araştırmacı tarafından tanımlanan bir kod kitabıyla geri kazana bileceğimizi gösterebiliriz.

Doclingo https://www.doclingo.ai

2.8 Sonuç: Metin Verisi ve Sosyal Bilimler

Bu kitapta, verilerin ve algoritmaların her aşamada kullanıldığı bir araştırma sür ecini savunuyoruz—araştırma sorularının formüle edildiği en erken aşamalardan, nedensel etkilerin tahminine kadar. Elbette, metinleri kategorilere atama, metinler de belirli konuların yaygınlığını ölçme ve nedensel etkileri değerlendirme söz konu su olduğunda bu tür tekniklerin kullanılması standart bir uygulamadır. Ancak, araş tırmacıların bir araştırma projesinin en erken aşamalarında metin verilerini ve algo ritmaları kullanmalarını, araştırma sorularını geliştirmelerini, anahtar kavramlar içi n ölçümler geliştirmelerini ve hipotezler üretmelerini de savunuyoruz. Deneyimimi z, verilerin ve istatistiksel modellerin araştırmamızın en erken aşamalarında bize ya rdımcı olduğunda daha iyi sorular formüle edebildiğimizi, daha iyi teoriler elde ede bildiğimizi ve daha net kavramlar ifade edebildiğimizi göstermiştir.

Bu, metin analizi için heyecan verici bir an. Metin analizi kullanan çalı şma sayısı artıyor ve metin analizi yapma yöntemleri hızla ortaya çıkıyor . Sonuç olarak, burada tanımladığımız bazı yöntemler birkaç yıl içinde g eçerliliğini yitirmiş olabilir. Ancak, bunu genel projemiz için önemli bir sı nırlama olarak görmüyoruz. Sosyal bilim çıkarımı modelimiz, herhangi bir zamanda kullanılan belirli yöntemlere bağlı değildir. Aksine, belirttiğ imiz görevler sosyal bilim projelerinin uzun süredir var olan özellikleridi r. Ve sosyal bilim çıkarımlarının nasıl yapıldığı konusunda şeffaf olma ya klaşımımız, yeni yöntemlerin araştırma sürecinde net bir yere sahip olm asını sağlar. Ayrıca, bu kitabın yazıldığı sırada henüz geliştirilmemiş yön temler bile dahil olmak üzere, yöntemlerin performansını değerlendirm ek için bir dizi doğrulama sağlıyoruz.

Buna ulaşmak için, bir sonraki bölümde metin verilerini analiz etmek için araçları t anıtmaya başlıyoruz. Metni nicel veri olarak temsil etmek için bir dizi yöntemi tanımlı yoruz; bu yöntemler daha sonra keşif, ölçüm ve çıkarım için kullanılabilir.

---

[1]Bu bölümün ve Bölüm 2.5'in bazı kısımları Grimmer, Roberts ve Stewart (2 021)'dan alınmıştır.

Doclingo https://www.doclingo.ai

BÖLÜM II

Seçim ve Temsil

Metni bir veri kaynağı olarak görmeye başladığınızda, sosyal dünyayı ince lemek için yeni fırsatlar her yerde açılır. Şirketler, yatırım kararlarını yönle ndirmek ve müşteri hizmetlerini geliştirmek için şirket kazanç raporlarını ve tüketici şikayetlerini kullanır. Hükümetler, kamu hizmetlerini geliştirm ek için güvenlik denetim raporlarını ve acil durum çağrılarını kullanır. Eko nomistler, Federal Rezerv toplantılarının ve reklamların transkriptleri ara cılığıyla ekonomik büyüme ve pazarlama hakkında içgörüler elde eder. Si yaset bilimcileri, temsil, hesap verebilirlik ve siyasi rekabetle ilgili soruları konuşmalar, basın bültenleri ve tartışmalarla yanıtlar. Sosyologlar, kültür ü ölçer, demografik değişimleri takip eder ve çeşitli toplulukların dijital ay ak izlerini haritalar. Sosyal bilimlerin dışında, tarihçiler geniş tarihsel belg eler arşivlerinden yararlanır, halk sağlığı akademisyenleri elektronik sağlı k kayıtlarını inceler ve İngilizce profesörleri edebiyatın daha geniş kalıplar ını inceler.Bu durumların her birinde, amacımız veriye bir istatistiksel mo del uydurmaktan daha fazlasıdır; belgelerin kaydettiği ve temsil ettiği ins an süreçleri hakkında bir şeyler öğrenmek istiyoruz.

Bu bölümde, metin analizi sürecindeki ilk adımı tartışıyoruz: met nin toplanması ve temsil edilmesi. Bölüm 3: Seçim ve Temsil İlkeler i ile başlayarak, bu bölümdeki diğer bölümler için bir çerçeve sağla yan dört ilke sunuyoruz. Ardından Bölüm
4: Belgeleri Seçme, metin toplama ve örnekleme için ilkesel bir yaklaş ımın neden zorunlu olduğunu araştıran bir çalışmadır. Burada amaç, analiz etmek için bir *korpus* oluşturmaktır—belgelerin toplanması.
Bölüm 5: Kelime Torbası , belgeleri “kelime torbası” modeline dayalı ol arak sayısal olarak temsil etmek için başlangıçta varsayılan bir tarif su nar. Bu basit,yine de güçlü, metinlerin temsili her belgeyi sadece bir k elime sayıları koleksiyonu olarak ele alır—sanki tüm kelimeleri bir tor baya atıpsallamışız gibi, böylece sıraları artık korunmaz. Bu temsil birç ok bilgiyi kaybetse de, birçok görev için son derece etkili olabilir ve yar arlı bir varsayılan yaklaşımdır.

Kelime torbası temsili, çok değişkenli dağılıma dayanan olasılıks al bir modelleme stratejisine uygundur.Bölüm 6: Çok Değişkenli

Doclingo https://www.doclingo.ai

Dil Modeli çok terimli dil modelini tanıtır ve bu model, kitap boyunca ele alacağımız birçok istatistiksel modelin temelini oluşturacaktır. Bölüm 7: Vektör Uzayı Modeli ve Benzerlik Ölçüleri, kelime torbası temsilini bir vektör uzayı olarak yorumlama fikrini tanıtır. Bu, çok terimli modelin istatistiksel modeller için sağladığı temele benzer şekilde, algoritmik modeller için bir temel sağlar.

Bölümler 5–7, kelimelerin birbirine ne kadar benzer olduğu hakkında başlangıçta herhangi bir varsayımda bulunmayan bir kelime temsili kullanır: kedi ve yavru kedi, kedi ve kilise ile aynı derecede farklı olarak ele alınır. Sonraki iki bölüm, kelimeleri anlamamızı artırmak için dış bilgileri nasıl kullanabileceğimizi tartışır. Wikipedia veya internetin Common Crawl gibi büyük metin koleksiyonlarını kullanarak, bazı kelimelerin diğerlerinden daha benzer olduğunu kodlayan dağıtılmış kelime temsillerini öğrenebiliriz. Bu "kelime gömme" işlemleri Bölüm 8: Dağıtılmış Temsiller
Kelimeler. Kelime gömme işlemleri, anlamsal bilgi elde etmek için dış bir korpus kullanırken, Bölüm **9: Dil Sıralamalarından Temsiller**
belgelerden farklı türde bilgileri çıkarmak için kullanılabilecek doğal dil işleme alanındaki çeşitli yaklaşımları özetlemektedir; bu bilgiler arasında kelimelerin bir cümlede oynadığı roller bulunmaktadır. Bu teknikler metin yeniden kullanımı, sözcük türü etiketleme, adlandırılmış varlık tanıma, bağımlılık ayrıştırma ve diğer bilgi çıkarım görevlerini içermektedir.

Belgelerin zaten makine tarafından okunabilir olduğunu varsayıyoruz. Doğal olarak dijital olmayan belgeler, metin resimlerini makinenin okuyabileceği karakterlere dönüştürme süreci olan optik karakter tanıma aracılığıyla makine okunabilir hale getirilebilir. Mükemmel olmasa da, bu teknolojiler, belgeleri elle transkribe etmenin son derece zaman alıcı olacağı büyük korpuslar için metni makine okunabilir hale getirmenin en iyi çözümüdür.

Doclingo https://www.doclingo.ai

BÖLÜM 3

Seçim ve Temsil İlkeleri

Daha önceki bölümlerde tartıştığımız gibi, metin verileri sosyal etkileşimler i, ekonomik işlemleri ve politik süreçleri yansıtır. Bu bilgi zenginliğini ilginç sorular sormak ve yanıtlamak için kullanmak amacıyla, araştırmacının önce ilgi alanındaki korpusu dikkatlice düzenlemesi ve ardından bu belgeleri sa yısal olarak temsil etmesi gerekmektedir. Metinlerde depolanan bilgi mikta rının fazlalığı nedeniyle daha karmaşık olsa da, metni toplama ve sayısal ol arak temsil etme kararları, araştırmacıların ilgi alanındaki diğer sosyal bili m değişkenlerini sayısal olarak temsil etme kararlarına benzer. Bir korpus t oplamak, ilgi alanındaki bir nüfustan bir örnek belirlemeye benzer.
Metni sayısal olarak temsil etmek, sosyal bilimcilerin bir ülkenin ek onomik faaliyetini temsil etmek için GDP gibi bir ölçüt kullanmasın a benzer. Bu kararlar, daha karmaşık olguları analiz edilebilecek sa yılara indirger.

Metinde kodlanmış tüm bilgilerin sorumuz için yararlı olmayacağını belirtmek gerekir.
— Zorluk, hangi bilgilerin ilgili olduğunu ve hangi bilgilerin atılabileceğini belirlemektir.

Bu bölümde, metinleri temsil etmek için birkaç farklı tarifin genel bir görün ümünü sunuyoruz - "kelime torbası" modelinden dağıtılmış temsilere kada r - bireysel araştırma soruları ve görevlerine uyarlanabilir. Genellikle, teori en iyi temsili seçmemize rehberlik edemeyecek ve seçim geniş bir doğrula ma gerektirecektir.

Bu bölüm boyunca vurguladığımız şey, amacımızın dilin tek bir doğru modelini veya tü m araştırma soruları için metnin tek bir doğru temsilini bulmak olmadığını belirtmektir.
Sosyal bilim araştırmacıları olarak, metni değil, onun içinde yansıtılan siyasi, ekonomik ve sosyal süreçleri inceliyoruz. Bu nedenle, metinden elde ettiğimiz bilgi, neyi keşfetmek, ölçmek veya çıkarmak istediğimiz e bağlı olacaktır. Ve bu, araştırmamızın amacına bağlı olacaktır.

Başlangıçta, bir korpusun nasıl toplanacağı ve temsil edileceği k onusunda bilgi veren dört özel ilkeyi vurgulamak için 2. Bölüm'ün altı ilkesinden yararlanıyoruz. Ardından, metnin araştırma odaklı te msilinin etkili olabileceğini gösteren örnekleri tanıtıyoruz.

Doclingo https://www.doclingo.ai

Sosyal olguları ortaya çıkarmak ve tarihsel soruları yanıtlamak.

Doclingo https://www.doclingo.ai

3.1 İlke 1: Soruya Özgü Korpus Oluşturma

> *Bir korpusun kullanışlılığı, araştırmacıların yanıtlamak istediği soru ya ve incelemek istedikleri nüfusa bağlıdır.*

Bir korpusun kullanışlı olup olmayacağı, araştırma sorusuna bağlıdır. Örneğin, Tw itter verilerinin analizi, yalnızca nüfusun küçük bir kısmının platformu kullanması ve b unlardan da azının iklim değişikliği hakkında tweet atması nedeniyle, ABD kamuoyun un iklim değişikliği hakkındaki görüşlerini ölçmek için en doğru yol olmayabilir. Ancak, seçilmiş yetkililerin çevrimiçi olarak seçmenleriyle nasıl etkileşimde bulunduğunu ince lemek veya aktivist grupların konuşmayı nasıl değiştirmeye çalıştığını ölçmek için yararlı bir y ol olabilir.

Araştırma sorusu iyi tanımlandığında, araştırmacılara belgeleri toplam aya başlamadan önce ilgi alanındaki miktarları ve ilgi alanındaki nüfusu if ade etmelerini öneriyoruz. Daha sonra, bir korpusun, ilgilendikleri nüfus u yansıtıp yansıtmadığını ve ilgilendikleri miktarların metinden ölçülüp öl çülemeyeceğini değerlendirerek potansiyel korpusların faydasını değerle ndirebilirler. Bu, yanlı veya eksik korpusların her zaman tamamen atılma sı gerektiği anlamına gelmez. Eksik korpuslar da yararlı olabilir, eğer araş tırmacı eksikliğin kaynaklarını ve sonuçlarını anlıyorsa ve bunları izleyiciy e ifade edebiliyorsa.

Bu kitabın Keşif bölümünde kapsamlı bir şekilde ele aldığımız gibi, araştırm acılarher zaman iyi tanımlanmış bir araştırma sorusuyla bir korpusu keşfetmey e başlamayabilirler. Örneğin, bir araştırmacının elinde bir korpus olabilir ve içi nde ne olduğunu veya neyi ölçebileceğini bilmeyebilir. Korpusu bazı nicel anali zler yaparak ve derinlemesine okumalarla keşfetmek, daha sonra test edilebile cek yeni içgörüler ve teorilere yol açabilir. Bu durumlarda, araştırmacıların sor ularını, miktarlarını ve ilgi alanı nüfuslarını netleştirdikçe, korpus seçim adımını yeniden gözden geçirmelerini ve bir soru belirlediklerinde yeni veriler toplam alarını öneriyoruz.

Doclingo https://www.doclingo.ai

3.2 İlke 2: Değerlerden Arındırılmış Korpus Oluşturma Yoktur

Bir korpusun değerlerden arındırılmış bir şekilde inşa edilmesi mümkün değildir. Hangi b elgelerin dahil edileceğini seçmek etik sonuçlar doğurur.

Bir korpus oluşturmak, temsil ve gizlilikle ilgili etik sorunlara öze l dikkat gerektirir. Bu kitabın bu bölümünde kapsamlı bir şekilde ta rtışacağımız gibi, korpus inşası, bireylerin yazma ve metin verilerini erişilebilir kılma konusundaki kaynaklar ve teşvikler arasındaki far klılıklar nedeniyle ilgi alanı nüfusunu yanlış bir şekilde yansıtabilir. Metinler üretildiğinde bile, kurumsal ve hükümet politikaları veri s aklama ve erişilebilirliği çarpıtabilir. Önceki bölümde tartışılan inter net sansürü durumu, bu tür bir seçimin özellikle aşırı bir versiyonu dur. Araştırmacılar metne odaklandıklarında, genellikle belgeleri ür eten nüfusa odaklanma eğilimindedirler; bu, kabul edilmesi önemli bir odak kaymasıdır. Korpusun nüfusu eşit bir şekilde yansıtamam ası, yanlış sonuçlara ve verilerin alt grupları için modellerin yanlışlı klarına yol açabilir (Olteanu ve diğ., 2019; Tatman, 2017).

Metin korpusları, dilin belge yazarları tarafından kullanıldığı şekliyle tem sil ederve tarafsız bir şekilde değil. Belirli ortamlarda yazarlar, ırksal stereo tipler veya nefret söylemi gibi zararlı diller kullanır. Bazı uygulamalarda, bu dili tanımlamak (örneğin, kaldırmak için) araştırma görevinin kendisinin a macıdır. Diğer uygulamalarda, tahmine dayalı dil modelleri gibi, eğitim veri lerinde zararlı dilin dahil edilmesi, aşağı akış uygulamalarında sorunu sürd ürebilir (Bolukbasi ve diğ., 2016). Kesinlikle adaletsiz sonuçları sürdüren sis temlerin tek nedeni olmasa da, kullanılan veriler sürecin önemli bir parçası olabilir.

Metin sıklıkla kişisel veya tanımlanabilir bilgiler içerir. Bu, iki fark lı türde durumlarda karmaşıklık yaratır. Belgeler, araştırma amaçla rı için açıkça oluşturulduğunda—örneğin, bir ankette açık uçlu bir y anıt için—araştırmacılar, akademik araştırmalarda onay almak, açı kça tanımlayıcı kişisel bilgilerin kaldırılmasını sağlamak ve insan de neklerini zarardan korumak için standart prosedürleri izlemelidir. Bu endişeler, metin verileri diğer hassas verilerle birleştirildiğinde özellikle acildir çünkü metindeki hangi detayların tanımlayıcı olabileceğini bilmek öz ellikle zordur. Lundberg ve diğ. (2019), hassas sosyal veriler için bir gizlilik t ehdit analizi nasıl yapılacağına dair bilgilendirici bir örnek sunmaktadır.

Doclingo https://www.doclingo.ai

Daha sık olarak, belgeler bazı kamu kaynaklarından toplanmakta ve araştırma amacıyla kullanılmak üzere üretilmemekte, genellikle bilgilen dirilmiş onay almak için basit bir yol olmamaktadır. Birçok araştırmacı, yazarın bir belgeyi yayımlamayı seçtiği için, onu araştırma için kullanma nın etik olarak kabul edilebilir olduğunu düşünmektedir. Ancak, sosyal medya çağında kamu ve özel arasındaki ikiliğin gizlilik endişelerini aşırı basitleştirdiğine inanmak için de nedenler olabilir (boyd ve Crawford, 2 012). Nissenbaum (2020), bu konuları "bağlamsal bütünlük" perspektifi nden ele almakta, bu da metnin kamuya açık olup olmadığını değil, ayn ı zamanda yazarlarının bu bilgilere erişileceğini beklediği bağlamsal nor mları da dikkate almaktadır. Etik durum, yalnızca yarı-kamuya açık olan, örneğin kapalı bir Facebook grubu veya bir kayıt formu gerektiren bir e-posta listesi aracılığıyla erişilebilen bilgiler bağlamında daha da karm aşık hale gelmektedir.Salganik (2018, Bölüm 6) bu gizlilik endişelerini d ijital çağda verilerin daha genel bağlamında düşünmek için yay gın çerçeveler hakkında mükemmel bir tartışma sunmaktadır.

Doclingo https://www.doclingo.ai

3.3 İlke 3: Metni Temsil Etmenin Tek Doğru Yolu Yoktur

Her araştırma sorusu için metni temsil etmenin tek bir doğru yolu yoktur.

Korpus araştırma sorusuna bağlı olduğu gibi, temsil de öyledir. Her soru için metni temsil etmenin tek bir doğru yolu yoktur. Bazı durumlarda—aşağıda daha ayrıntılı olarak açıklayacağımız gibi—araştırmacı yalnızca bir kelimeyle ilgilenebilir ve metni temsil etmek, yalnızca o belirli kelimenin metinde yer alıp almadığını gösteren bir göstergeyi içerebilir. Diğer durumlarda, bir araştırmacı metindeki çoğu kelime için göstergeler eklemek isteyebilir, ancak the ve and gibi yaygın kelimeleri hariç tutmak isteyebilir. Diğer durumlarda, ilgi alanındaki tek kelimeler bu yaygın kelimeler olabilir. Diğer sorular için, yalnızca bir kelimenin dahil olup olmadığı değil, aynı zamanda o kelimenin diğer kelimelerle nasıl ilişkili olduğuna dair bir temsil de gerekebilir veya kelimenin kendisi ile bağlamı hakkında bilgi gerekebilir.

Araştırmacıların, metinde ölçmeyi umdukları şey hakkında yeterli bilgi içerecek en basit temsili seçmelerini öneriyoruz.
Araştırmacı hangi miktarı ölçmeye çalışıyor? Bu sosyal fenomen metinde nasıl kendini gösterebilir? Bazı durumlarda, basit bir temsil, araştırmacının yakalamaya çalıştığı fenomeni yeterince yansıtacaktır. Diğer durumlarda, ilgi alanındaki miktarı ölçmek için daha karmaşık bir temsil gerekebilir. Birçok durumda, en iyi temsilin ne olduğunu önceden bilemeyeceğiz. Bu durumlarda, metinden birçok farklı özelliği içeren bir temsil kullanacağız ve ardından, ilgilendiğimiz şeyi ölçen belirli bir ölçüye göre en önemli olanları çıkarmak için bir model kullanacağız.

Doclingo https://www.doclingo.ai

3.4 İlke 4: Doğrulama

> *Bir metin temsilinin çalıştığının en iyi garantisi kapsamlıdoğrul amadır.*

Metni sayılar olarak temsil etmek için yapılması gereken birçok farklı karar vardır. Birçok durumda, bir korpus içinde metni temsil etmenin yollarının sayısı saymak için çok fazla olacaktır. Araştırmacılar, araştırma soruları için "doğru" temsili seçtiklerini nasıl bilecekler?

Burada, araştırmacıların kitap boyunca detaylandırdığımız doğrulamalara kapsamlı bir şekilde güvenmelerini öneriyoruz. Temsilimizin bir ölçüm modelinde çalıştığını, o temsili kullanarak oluşturduğumuz ölçümlerin, sosyal dünya hakkında bildiğimiz doğrulanmış, elle kodlanmış veriler ve gerçeklerle uyumlu olması durumunda bileceğiz. Temsillerin bir tahmin modelinde çalıştığını, yüksek doğruluk elde ettiğimizde bileceğiz. Ve belirli bir temsilin nedensel çıkarımda çalıştığını, deneyi tekrarlayıp aynı sonuçları elde edebildiğimizde bileceğiz. Doğrulamalarımız, ölçümlerimizin, tahminlerimizin ve çıkarımlarımızın çalışmadığını gösteriyorsa, yaklaşımımızı—hem temsilimizi hem de modelimizi—nedenini anlamak için gözden geçirmemiz gerekecek.

Bir araştırma bulgusunun, sosyal bilimlerin diğer alanlarında yaygın bir uygulama olduğu gibi, metnin temsil edilebileceği birçok farklı yola karşı dayanıklı olması gerektiğine inanmıyoruz. Bazı temsiller, farklı görevler için daha uygun olacaktır—daha iyi doğruluk elde etmek veya daha iyi keşifler sağlamak. Eğer bir temsil diğerlerini açıkça geride bırakıyorsa, bulgularımızın birçok farklı temsil üzerindeki dayanıklılığını değerlendirmek gerekli değildir. Bunun yerine, araştırmacıların ölçmekle ilgilendikleri büyüklükler için en iyi temsili bulmak amacıyla dış doğrulamaları kullanmalarını ve sorularına yararlı olmayan temsilleri göz ardı etmelerini öneriyoruz.

Dört ilkemizi ortaya koyduktan sonra, şimdi iki örnek uygulamanın kısa bir önizlemesini sunuyoruz. 4-9. Bölümler boyunca birçok uygulamaya atıfta bulunacağız, ancak bu iki özel uygulamaya birkaç kez geri döneceğiz.

Doclingo https://www.doclingo.ai

3.5 Birlik Konuşmaları / Devlet Birliği Konuşmaları

Bu bölüm boyunca, 236 Birlik Konuşması adresinden oluşan bir korpu s kullanacağız. 1790–2016.[1] Her yıl ABD kamuoyuna verilen yazılı veya sözlü biçimde, Birlik Konuşmaları (SOTU) corpus, ABD yü rütme organının 200 yılı aşkın tarihindeki politika önceliklerinin bir anlık görüntüsünü sağlar.

Birçok çalışma, SOTU korpusunu kullanarak zamanla siyasi konuşmanın doğa sındaki eğilimleri incelemiştir. Örneğin, Rule, Cointet ve Bearman (2015), bu siya si konuşmaların dilindeki değişimleri tespit etmek için çeşitli metin analitik teknik leri kullanmaktadır. Bunu yaparken, SOTU korpusunun söyleminin 1917'den son ra değiştiğini, "Devlet Yönetimi" ve "Siyasi Ekonomi" konularının "Dış İlişkiler" ve "Kamu Politikası" gibi daha geniş tartışmalara dönüştüğünü savunmaktadırlar.

Başka bir örnekte, Benoit, Munger ve Spirling (2019), SOTU konuşmaları nı okunabilirlik bağlamında analiz etmektedir. Metin karmaşıklığını ölçen bi r ölçüt geliştirirler ve bunu SOTU korpusuna uygularlar. Sonuç olarak, kon uşmaların metin karmaşıklığının zamanla önemli ölçüde azaldığını bulurlar . Aynı yıl içinde yazılı ve sözlü biçimde verilen SOTU konuşmalarını karşılaştı rdıklarında, yazılı konuşmalardaki metin karmaşıklığının çok daha yüksek o lduğunu ve başkanların SOTU'yu sözlü biçimde verme olasılığının artmasını n, daha az karmaşıklık eğilimini açıklayabileceğini bulurlar.

Sonraki bölümde, SOTU korpusunu kullanarak metni veri olarak nasıl temsil ed eceğimizi tanıtacağız.

Doclingo https://www.doclingo.ai

3.6 Federalist Yazılarının Yazarlığı

Nicel metin analizinin en erken örneklerinden birinde, Mosteller veWallace (1963), imzasız Federalist Yazılarının yazarlarını tanımla maya çalıştılar. Federalist Yazıları, Alexander Hamilton, John Jay ve James Madison'ın birleşimi tarafından yazılan 85 belgedir. 1700'ler Amerikan Anayasası'nı desteklemek, o zaman tartışma altındaydı. İlk 77 kağıtların Mosteller ve Wallace (1963) için ilgi çekici olduğu ve 1787 ve 1788 yılları arasında New York gazetelerinde Anayasa'nın onaylanmasını desteklemek a macıyla anonim olarak yayımlanmıştır.

Tüm belgeler imzasız olsa da, 85 belgeden 73'ünün yazarlığı tart ışmasızdır. On iki belgenin, ya Hamilton ya da Madison tarafından yazıldığına inanılmaktadır. Ek olarak, üç belgenin ortak olarak yazıl dığı bilinmektedir, ancak hangi yazarın hangi bölümü yazdığı tartış malıdır (Mosteller ve Wallace, 1963). Bu kısmen çünkü yazarlar kendileri çelişkili yazar listeleri sağladılar. Hamilton, öldüğü gün iki gün önce, Aaron Burr ile bir düelloda hangi bireyin her makaleyi yazdığını belirten bir liste sağladı. 1804. Ancak, Madison 1818'de yazarların farklı bir listesini sağladı (Adair, 1944).

Bu kitapta tanımlayacağımız birçok çalışmada olduğu gibi, Most eller'in biyografisine göre, Federalist Yazılar'daki yazarlık sorusunu inceleme fikri, kendisi bir istatistikçi ve bir siyaset bilimci olan Fred erick Williams ile yaptığı bir konuşmadan kaynaklanmıştır.[2] Bu kon uşmadan ilham alan Mosteller ve Wallace (1963), yazarları yazı tarz larına göre ayırt etmeye çalışmak için istatistiksel yöntemler kullan maya karar verdiler, makalelerin içeriği yerine. İki yazarın - Hamilto n ve Madison - belgelerde farklı oranlarda kullandıkları upon, by ve to gibi kelimlerin, onları ayırt eden "filler" kelimler olduğunu gözle mlediler.

Belgeleri, bir belgede ortak yazarlığı ayırt edebilmek için her biri yakla şık 200 kelimeden oluşan metin bloklarına böldüler. Daha sonra, bu blokl ardaki filler kelimelerin kullanımını sayarak metni temsil ettiler. Bugün sa hip olduğumuz teknolojiden farklı olarak, Federalist Yazılar'daki kelimeler i saymak, 1959-1960 yıllarında oldukça zorlu bir iş oldu. Mosteller'in sözle riyle:

> Makaledeki kelimeler, uzun bir kağıt şeridi üzerinde her satıra bir kelime o lacak şekilde yazıldıtape, hesap makinesi şeridi gibi. Sonra makasla şerit, h er bir kayda bir kelime gelecek şekilde kesildi. ... Sayım yapılırken, eğer

Doclingo https://www.doclingo.ai

birisi kapıyı açarsa, kağıt parçaları odanın etrafında uçar.
(Mosteller, 2010, s. 53–54)

Kelimeler nihayet sayıldıktan sonra, yazarlar, dolgu kelimelerini kullanar ak, iki yazar tarafından yazıldığı bilinen mevcut belgeleri kullanarak makale lerin yazarlığını tahmin eden bir istatistiksel model oluşturdu. Temelde, bel irli bir 200 kelimelik pasaj için, model dolgu kelimelerinin ortaya çıkma ora nlarının bilinen Hamilton belgeleriyle mi yoksa bilinen Madison belgeleriyl e mi daha çok benzer olduğunu sorar. Model, bilinmeyen belgelerde yazarl ığı oldukça kesin bir şekilde ayırt eder—tüm 12 bilinmeyen yazarlığı Madison'a atfeder.

Bir metinden bir kelime kesip yığınlara yerleştirme görüntüsünü akıl da tutarak, Mosteller ve Wallace (1963) örneğini, metni temsil etme kon usunda kelimeler torbası yaklaşımının basit bir örneği olarak kullanıyor uz—her belgenin, metin içinde ilgi alanındaki her bireysel kelimenin ne kadar sıklıkla geçtiği ile temsil edildiği yer. Ancak, bu örnek aynı zaman da, bir metni temsil etme kararının tamamen ilgi alanındaki araştırma s orusuna bağlı olduğunu gösterdiği için de faydalıdır. Birçok sosyal bilim araştırma sorusu için, bir metnin "üzerinde" kelimesini içermesi oranı f aydalı bir bilgi değilken, bu özel soru için bu "dolgu kelimeleri" en öne mlisidir.

Doclingo https://www.doclingo.ai

3.7 Sonuç

Bu bölümde, 4-9. Bölümlerde düşüncelerimizi yönlendirecek olan korp us seçim ve temsil ilkelerini ele aldık. Bu ilkeler, 2. Bölümdeki altı ana ilke mizle paralellik göstererek, korpus inşasının soru özel doğasına odaklan makta, araştırmacıları tüm amaçlar için tek bir doğru temsil olduğu düşü ncesinden vazgeçmeye teşvik etmekte ve bunun ışığında doğrulamaya o daklanmaya yönlendirmektedir. Şimdi belgeleri seçmeye (Bölüm 4) geçiy oruz ve ardından metni veri olarak temsil etmek için ilk algoritmamıza (B ölüm 5) geçeceğiz. Birlik Konuşmaları ve Federalist Yazılar örneklerine thr oughout geri döneceğiz.

---

[1]Veri Arnold ve Tilton'dan (2017) elde edilmiştir.

[2]"Kamusal Görüş Araştırmaları Ofisi'nde çalıştığımda... FrederickWilliams ile ta nıştım, bir siyaset bilimci. 1941'de bir gün Fred, 'Tartışmalı *Federalist* yazılarının y azarlık problemi hakkında düşündün mü?' dedi. Orada olduğunu bilmiyordum. *Federalist* yazılar, Hamilton ve Madison'ın bunların yazarlığını iddia ettiği çok daha az.

Doclingo https://www.doclingo.ai

BÖLÜM 4

Belgelerin Seçimi

Metin analizi her zaman analiz edilecek belgelerin seçilmesi süreciyle başlar. Bazen bu seçim, mevcut olma durumuna bağlıdır. Özellikle bir araştırma sorusu geliştirilmeden önce, araştırmacılar belirli bir alanda ilginç fikirler aramaya başlamak için mümkün olduğunca çok belge toplayabilirler. Diğer ortamlarda ise analizinin amacı, belirli bir belge koleksiyonunun içeriğini anlamak olabilir. 2010 yılında sızdırılan 250.000 ABD Dışişleri Bakanlığı kablosu veya Panama Belgeleri'ndeki 11 milyon finansal belge gibi büyük belge setlerinin açıklanmasının hemen ardından, birçok gazeteci ve araştırmacının amacı, bu belirli belge koleksiyonlarını keşfetmekti. Benzer şekilde, Mosteller ve Wallace (1963) tarafından yapılan Federalist Yazılar analizi, bir yazarlık atıfına özgü bir metin korpusuna odaklanmıştır ve bunun ötesindeki diğer belgelere çıkarımda bulunmaz.

Ancak, bu kitapta ele aldığımız birçok örnek, araştırmacıların iyi tanımlanmış bir ilgi sorusuna sahip olduğu veya geliştirdiği ve belirli sorularını yanıtlamak için korpus seçtiği durumlardır. Örneğin, 1. Bölümde tartıştığımız Catalinac (2016), Japonya'da ofis için adayların seçim stratejisinin seçim reformuna nasıl yanıt verdiğini anlamakla ilgileniyordu. Seçim manifestolarının tüm adaylar tarafından aynı formatta hazırlandığı, doğrudan seçmenlere verildiği ve zamanla tasarımlarının değişmediği için bir seçim manifestoları korpusu kullanmaya karar verdi. Bu nedenle, ilgi alanındaki popülasyonu—adayları—ve ayrıca ölçmek istediği şeyi—adayların seçmenleri kendilerine oy vermeye ikna etme stratejisini—temsil etmektedirler.

Diğer durumlarda, araştırmacının hedefi zamanla değişir ve belgelerin toplanması da öyle. Bölüm 2'de açıkladığımız gibi, King, Pan ve Roberts araştırma konularını sansürü ölçmeye değiştirdiklerinde, veri toplama yöntemlerini sansürle ilişkilendirdiklerini düşündükleri anahtar kelimelere dayalı bakalı bir örneğe geçirdiler. Kitap boyunca vurguladığımız gibi, araştırma süreci her zaman araştırma adımları boyunca katı bir doğrusal ilerleme değildir ve korpus oluşturma, araştırmacıların en ilginç soruya ve en ikna edici cevaba doğru iterasyon yaparken birden fazla kez yapılması gerekebilir.

Doclingo https://www.doclingo.ai

en ikna edici cevap.

Bu bölümde, ilgi alanı ve miktarını tartışmaya başlıyoruz. Bir soru, nüfus ve ilgi miktarını belirledikten sonra, bu miktarları ne kadar iyi ölçebileceğiniz, korpusunuzun bu nüfusu ne kadar iyi temsil ettiğine bağlı olacaktır. Daha sonra, belirli bir korpusun belirli bir nüfusu ne kadar yansıttığını etkileyebilecek dört tür yanlılığı inceliyoruz.

Doclingo https://www.doclingo.ai

4.1 İlgilenilen Nüfuslar ve Büyüklükler

Bir korpusun kullanışlılığı, araştırmacıların yanıtlamak istedikleri soruy a ve incelemek istedikleri nüfusa bağlıdır. Verilere derinlemesine inmeksi zin, araştırmacılar neyi ölçebileceklerini veya korpusun uzmanlık alanları ndaki anahtar sorularla nasıl ilişkili olduğunu bilmeyebilirler. Sürecin bu a şamasında, analistler keşif aşamasındadır; metinleri daha iyi anlamak için keşfetmeli, okumalı ve tanımlamalıdırlar. Sonunda, bir araştırma sorusu geliştirecekler ve örneğin ilgi duydukları nüfusu ne kadar iyi yansıttığını y eniden gözden geçireceklerdir; bu genellikle sonraki veri toplama veya ör neğin rafine edilmesini gerektirecektir.

Diğer zamanlarda, araştırmacı ilgi çekici bir soruyla başlar, bu d a metinlerin ilgili olup olmadığını baştan daha net hale getirir. İlgi çekici sorular genellikle bir *ilgi çekici nüfus* ile ilgili veya bunu ima eder. Ö rneğin, ilgi çekici soru "Amerika Birleşik Devletleri'ndeki muhtemel seçmenle r, Başkan hakkında ne düşünüyor?" ise, ilgi çekici nüfus muhtemel seçmenler dir. Soru, elindeki korpusun bu nüfusu yansıtıp yansıtmadığını netleştirir. Bu soruyu yanıtlamak için bir tweet korpusu kullanmak, *sample selection bias* 'a yol açabilir çünkü, diğer nedenlerin yanı sıra, Twitter kullanıcıları muhtem el seçmenlerden önemli ölçüde daha gençtir.

Araştırma sorusu, metinlerin analizde kullanılmak üzere nasıl sıkıştırılac ağı veya özetleneceği konusunda ipuçları verir. Bu özetlere genellikle ilgi ç ekici miktarlar olarak atıfta bulunuruz. İlgi çekici bir miktar, araştırmacı için özel bir öneme sahip olan bir sayısal değerdir (veya değerler setidir). Twitt er örneğinde, bir analist, kullanıcıların belirli bir konu hakkında ne kadar ko nuştuğu veya başkan hakkında ne kadar tweet'in olumlu ya da olumsuz ol duğu ile ilgilenebilir. Nüfus ve ilgi çekici miktarlar, bir korpusun ilgi çekici s oruyu ne kadar iyi yanıtlayabileceğini bilgilendirir. Eğer korpus ilgi çekici n üfusu yansıtmıyorsa veya ilgi çekici miktar korpus içindeki metinlerden hes aplanamıyorsa, o belirli korpusla araştırma sorusunu yanıtlamak zor olaca ktır.

Araştırmacılar, çeşitli nüfuslar, alanlar ve zaman dilimleri üzerine odak lanan sorular sorarlar. Bazı araştırma soruları için, metin verileri, araştır macıların bir ülkenin insanlarının temel görüşlerini, faaliyetlerini veya de mografik özelliklerini yansıtmayı umduğu nüfus anketlerine benzer şekil de kullanılabilir. Örneğin, akademisyenler, Twitter gibi platformlardaki so syal medya verilerini, siyasi görüşlerden (O'Connor ve diğerleri, 2010) fil m tercihlerine (Asur ve Huberman, 2010) kadar her şeyi, grip salgınına (L ampos ve Cristianini, 2010), ve bir nüfustaki kişisel mutluluk

Doclingo https://www.doclingo.ai

(Golder ve Macy, 2011; Dodds ve diğ., 2011). Daha geniş (hem çevrimi çi hem de çevrimdışı) nüfustaki ilgi alanlarının temel miktarlarını doğr u bir şekilde değerlendirmek için, bu analizler çevrimiçi nüfusların çev rimdışı nüfuslardan nasıl farklı olduğunu doğru bir şekilde hesaba kat maya dayanır. Çevrimiçi nüfuslar içinde bile, siyasete dair tartışmalara katılmayı seçenler, eğlence hakkında tartışmalara katılmayı seçenlerd en çok farklı olabilir; bu durum, verilerde konuyu tartışmayan nüfusa genelleme yaparken dikkate alınmalıdır (Barberá ve Rivero, 2015).

Diğer durumlarda, ilgi alanındaki nüfus, tüm nüfusun çok daha küçük bir alt kümesidir. Örneğin, Blaydes, Grimmer ve McQueen (2018), Müslü man ve Hristiyan toplumları arasındaki siyasi düşünce farklılıklarını araştı rmaktadır. Hem İslam geleneğinden hem de Hristiyan Avrupa'dan altıncı yüzyıldan on yedinci yüzyıla kadar siyasi tavsiye metinlerini toplamakta, h em Müslüman hem de Hristiyan siyasi düşünürleri yansıtmayı amaçlama ktadırlar. Yazarların amacı, tüm Müslüman ve Hristiyan yazılarını toplama k ya da bu nüfuslar içindeki bu konularla ilgili tüm düşünceleri yansıtmak değil, bu dönemde siyasi düşünce üzerinde en fazla etkiye sahip olanları yansıtmaktır. Dijital beşeri bilimlerde, analizler belirli bir türdeki tematik eğilimleri keşfetmeye odaklanabilir; örneğin, Danimarkalı hayalet hikayel eri (Abello, Broadwell ve Tangherlini, 2012). Bu durumlarda metinlerin uy gun seçimi, genellikle hayaletler gibi bir konuyu içeren hikayeler ile içerm eyenler arasında ayırt etme yeteneğine dayanacaktır.

Corpus temsili olmasa bile, dikkatli bir analiz, ilgi alanındaki nüfus hakkında geçerli içgörüler sağlayabilir. Gill ve Spirling (2015), Amerika Birleşik Devletleri hükümetinin hangi tür bilgileri gizli tuttuğunu ve hangi tür bilgileri sınıflandır mayı kaldırdığını anlamak için tarihi kayıtlar ve sızdırılan verileri kullanmaktadı r. Elbette, yazarların tüm sınıflandırılmış bilgilere erişimi yoktur; yalnızca sınıfla ndırması kaldırılmış veya sızdırılmış kayıtlara erişebilirler. Ancak, sınıflandırılm amış bilgileri, bir noktada sınıflandırılmış olanlarla karşılaştırarak, yazarlar gizli kalan bazı konu türlerini çıkarabilir ve neyin eksik olabileceği hakkında içgörü sunabilirler.

Doclingo https://www.doclingo.ai

4.2 Dört Tür Yanlılık

Araştırmacılar bir soru, bir nüfus ve ilgi büyüklükleri belirlediklerin de, yani keşif aşamasından ölçüm, nedensel çıkarım veya tahmin aşa masına geçtiklerinde, corpus'larındaki potansiyel örnek seçim yanlılıkl arını dikkatlice düşünmelidirler. Bu bölümde, araştırmacıların bir soru ları ve ilgi alanındaki aday corpus'ları olduğunda dikkate alabilecekleri yaygın örnek seçim yanlılığı kaynaklarının başlangıç kontrol listesini s unuyoruz. Bu yanlılık kaynaklarının hepsi her araştırma sorusuna uyg ulanmayabilir ve kesinlikle dikkate aldığımız bazı faktörler bazı soru tü rlerini yanıtlamak için faydalı olabilir. Ancak, birçok soru ve ilgi nüfusu için, aşağıda belirtilen dört tür örnek seçim yanlılığı, analistler metni s osyal bilim çıkarımı için kullandıklarında sıkça tekrar ortaya çıkmaktad ır.

4.2.1 KAYNAK YANLILIĞI

Metinlerin üretilmesi, toplanması ve derlenmesi pahalıdır. Kaynak yanlılığı, meti nlerin genellikle belgeleri üretmek, kaydetmek ve depolamak için daha fazla kayna ğa sahip nüfusları daha iyi yansıttığı gerçeğine atıfta bulunur. Bu sorun, erişimin, n üfusun tamamının temsil edilmesini engellediği durumlarda özellikle belirgindir. Okuma yazma bilmemek, sınırlı internet erişimi veya giriş engelleri, metinleri inceleyen akad emisyenler için büyük bir nüfus kesimini görünmez hale getirebilir.

Tarihsel etkinlikleri kaydetmek ve korumak maliyetli bir süreçtir ve öne mli kaynaklar gerektirebilir. Olaylar, basın mevcut olduğunda daha fazla ka ydedilme olasılığı taşır (Snyder ve Kelly, 1977; Danzger, 1975). Arşivler, vata ndaşların saklamayı uygun bulduğu belgeleri içerebilir ve ilgi alanındaki nü fusu yetersiz bir şekilde temsil edebilir. Metinler kaybolmuş, yanmış veya s aklanmamış olabilir ve hikayeler asla transkribe edilmemiş olabilir. Metinleri saklama ve koruma yeteneğine sahip topluluklar ve bireyler, bu y eteneklere sahip olmayanlardan çok farklı olacaktır ve bu nedenle tarihsel belgeler daha büyük bir kümenin rastgele bir örneği olarak değerlendirilm emelidir. Örneğin, Pechenick, Danforth ve Dodds (2015), İngilizce metinleri n büyük bir koleksiyonu olan Google Ngrams korpusunun, yirminci yüzyıl b oyunca giderek daha orantısız miktarda bilimsel metin içerdiğini belirtmek tedir.

Devlet belgelerinin mevcudiyeti yerel kaynakları da yansıtabilir. Bazı hüküm etler toplantıları transkribe edecek personel bulundurabilir ve bunları kamuya sunabilir; diğerleri bunu yapamayabilir. Örneğin, ProPublica'da gazeteci olan S andhya Kambhampati, eyaletle bilgi talep etme sürecinden bahsetmektedir.

Doclingo https://www.doclingo.ai

Illinois'dan Bilgi Edinme Yasası aracılığıyla. Bazı ajanslardan gelen belgelerin zaten dijitalleştirilmediğini belirtmektedir. Tarama maliyetleri nedeniyle, bu kayıtların bazıları talep edene sunulamamıştır.[1]

4.2.2 TEŞVİK YANLIĞI

Teşvikler ve stratejik davranışlar, belgelerin üretilmesi vesaklan masını da etkileyebilir; bu sürece teşvik yanlılığı (Herrera ve Kapur, 2007) diyoruz. Sosyal etkileşim performatif bir nitelik taşır (Goffman, 1959) ve bireyle r ilekurumların, kendilerini olumsuz bir ışıkta gösterebilecek kanıtları kaydetmemek v eyasaklamak ya da yok etmek için teşvikleri olabilir. Bireyler, hayatlarının en mutlu ve ya en başarılıyönlerini yansıtan sosyal medya paylaşımları yapma olasılıkları daha yü ksek olabilir. Sosyalmedyadaki etkileşimleri inceleyen araştırmacılar için bu endişe bir sorun olmayabilir, ancakkullanıcıların gerçek duygusal durumlarını ölçmeye çalışanl ar için, bireylerin kendilerini nasılsunmaları sonuçları yanlı hale getirebilir. Benzer şek ilde, politikacılar ve hükümetler,kendilerini zayıflatan haberleri ve sosyal medyayı kal dırmaya zorlayabilir, diğerlerini sansürleyerekveya kendilerini sansürleyerek siyasi ta rtışmaları çerçeveleyebilirler (House, 2015; Boydston, 1991; Gup, 2008; King, Pan ve Roberts, 2013; MacKinnon, 2008).

Şeffaflık yasaları ve girişimleri metinleri araştırmacılar için daha erişilebilir hale getirirken, aynı zamanda etkilenenlerin teşviklerini de değiştirir. Kurum lar içindeki e-posta şeffaflığı, bu kurumların üyelerinin hassas konular hakkın da telefonla konuşmalarına veya tartışmaların kaydedilmediği gayri resmi to plantılar yapmalarına teşvik yaratabilir. Şeffaflık girişimleri, hükümet liderleri nin yanlış adım atmaktan korktukları takdirde siyasi katılımlarını kısıtlamaları na neden olabilir (Malesky, Schuler ve Tran, 2012). Bu girişimler, belirli siyasi bağlamlarda daha olası olabilir; örneğin, Berliner ve Erlich (2015), Meksika'da ki daha fazla siyasi rekabete sahip eyaletlerin, siyasi rekabeti olmayan eyaletl erden daha önce şeffaflık yasaları çıkardığını göstermektedir.

Araştırmacılar belgeleri hükümetin iç işleyişinin bir yansıması olar ak kullanmakla ilgilendiklerinde, belge toplama arkasındaki teşvikler i ve verilerin nasıl erişilebilir hale getirildiği sürecini anlamaya çalışm alıdırlar. Bunun harika bir örneği Cheryl Schonhardt-Bailey'nin *Amerikan Para Politikasını Tartışmak: Bir Metin Analizi*, Federal Açık Pi yasa Komiteleri (FOMC) ve bankacılık üzerine Kongre komitelerinin tra nskriptlerini inceleyerek para politikası yapımında tartışmanın rolünü anlamaya çalışmaktadır (Schonhardt-Bailey, 2013). Schonhardt-Bailey (2013) denetimsiz makine öğrenmesini kullanarak bu transkriptler deki tartışma ve ikna stratejilerini keşfeder ve ölçer. Ancak, daha s onra transkriptlerde yer alan birçok bireyle röportaj yapar.

Doclingo https://www.doclingo.ai

Röportajlarda araştırma sorusuyla ilgili olan birçok soru, transkript lerin neyi temsil ettiğine de ilişkindir—FOMC üyelerinin tartışmaları nda ne kadar samimi olabilecekleri, yorumlarının önceden hazırlan ıp hazırlanmadığı ve transkriptlerin şeffaflığının tartışmalarını nasıl etkilediği (Schonhardt-Bailey, 2013, s. 370).

4.2.3 ORTAM YANLIĞI

Metinlerin kaydedildiği teknolojiler ve ortam türleri, bunlarda yansıtılacak iç erik türlerinde önemli bir rol oynayacaktır; buna *ortam yanlılığı* diyeceğiz. 2017 yılına kadar Twitter, bir tweet'te yalnızca 140 karaktere izin veriyordu, bu da k ullanıcıların konunun daha fazla işlenmesi için kısaltmalar ve bağlantılar kullan malarını zorunlu kılıyordu. Ancak, 140 karakterlerin diller arasında çok farklı anlamları vardır—daha az karakter gerektiren dillerde, örneğin Çince ve Ja ponca, kullanıcılar bir gönderide daha fazla içerik ifade edebilirken, her keli me için birçok karakter gerektiren dillerde, örneğin İngilizce'de (ve özellikle karakter sınırının Kasım ayında iki katına çıktığında) durum böyle değildir. 2017, diğer diller dahil edilmedi). Ayrıca, sosyal medyadaki ifade biçimite knolojilerdeki ilerlemelerle değişiyor. Kullanıcılar resimleri, videoları ve ca nlı yayınlarıentegre edebildikçe, eşlik eden metnin rolü değişiyor. Sosyal medyada metin analiziyleilgilen kullanıcılar, içeriklerini tanımlarken bağla ntılar, resimler ve videolar gibibaşka veri türlerinin farkında olmalıdır ve t eknolojik yeteneklerin zamanla nasıldeğiştiğini göz önünde bulundurmalı dır.

Teknolojinin ve medyanın evrimi, kullanıcılar için farklı kültürler yaratabilir, böylece metin yalnızca platformun bağlamında anlaşılabilir. Snapchat, gönderilerin genellikle yalnızca kısa bir süre erişilebilir olduğu vesonra sında yok edildiği bir sosyal medya platformu, kullanıcılar için Twitter'danfarklı bi r ortam yaratacaktır; çünkü Twitter'da gönderiler kamuya açık ve dahakalıcıdır. Ç evrimiçi platformlar, web sitelerini bireysel kullanıcıların tahmin edilenilgi alanlar ına göre özelleştirdiğinden, kullanıcılar platformdaki içeriği farklıbir deneyimleye bilir ve bu, gönderi davranışlarında yansıyabilir. Araştırmacılar,kullanıcıların platf ormlar arasında ve bireysel platformlar içinde yaşadığı farklıdeneyimlerden kayn aklanabilecek önyargıları dikkate almalıdır; böylece metinlerinnasıl üretildiğini a nlamak için temel veri üretim sürecini anlayabilirler.

Sosyal medya dışındaki metinler de benzer şekilde ortamından etkilenir. Toplantı transkriptleri veya notları, konuşmanın içeriğini yansıtabilir, ancak ses tonu, beden dili veya diğer ifade edilen duyguların biçimlerini yansıtmaz (Schonhardt-Bailey, 2017; Dietrich, Enos ve Sen, 2019). El yazısı notlar

Doclingo https://www.doclingo.ai

çizimler veya karalamalar içerebilir. Metin mesajları, içeriğin merkezinde yer alanemojil eri içerebilir. Mümkün olduğunda, araştırmacılar metinleri orijinalbağlamlarında okum alı ve etkileşimde bulunmalıdır, böylece ilgi alanındaki sosyalolayların ortam tarafından metne nasıl dönüştürüldüğünü anlayabilirler, hattametin analizi araçları yalnızca metni dikkate alıyorsa bile.

4.2.4 GERİ ALIM YANLIĞI

Metinler bazen istatistiksel yöntemler kullanılarak seçildiğinden, geri alım yanlılığıbazen bir korpusun seçimini etkileyebilir. Örneği n, Abello,Broadwell ve Tangherlini (2012) Danimarka hayalet hikay elerini analiz etmek içinhesaplama yöntemleri kullanır. Çalışmaları için, 19. yüzyıl toplayıcısı ve Danimarkalı öğretmen Evald Tang Kristensen tarafından "hayalet hikayeleri" olarak kategorize edilen, el ile toplanmış bir hikaye seti kullanıyorl ar. Böyle bir el ile oluşturulmuş veri setine sahip olmak gerçekten dikkat çekici,bununla birlikte, elbette veri s etine dahil edilenler Kristensen'in kendi sosyal ağına ve kategorilendirme şemasına yansımaktadır.

Alternatif olarak, anahtar kelimelerle küresel bir hayalet hikayeleri listesi elde etmeyi hayal edin.Bunu yapmak için, başlığında hayalet kelimesi geçen her kitabı kütüphaneden seçebilirsiniz, ancak böyle bir strateji hatalarla dolu olacaktır. Hayalet kelimesini içeren bazı kitap başlıkları, hayalet hikayeleriyle hiçbir ilgis i olmayabilir; örneğin, *Aç Hayaletler: Mao'nun Gizli Kıtlığı* Çin'deki kıtlıkla ilgili dir, hayalet hikayeleriyle değil. Benzer şekilde, hayalet kelimesini içermeyen birçok kitap hala hayalet hikayeleri olabilir, *Bir Noel Şarkısı* başlığında hayale t kelimesi olmadan bir hayalet hikayesidir. Bu hatalar ilk başta rastgele görü nse de, genellikle sistematiktir. Hayalet kelimesi analizi bir tür türe yönlendir ebilir, farklı temalara sahip olabilecek hayaletler hakkında kitapları kaçırabilir .

Bu tür anahtar kelime seçimi, metin analizi alanında sık karşılaşılan bir sorundur çünkü araştırmacılar genellikle hayalet hikayeleri gibi belirli bir ilgi popülasyonuna sahiptirler; bu, daha büyük, yönetilmesi zor bir korpu sun alt kümesidir—tüm kitaplar gibi. Sorunu daha da kötüleştiren, insanl arın genellikle akıllarından kelimeleri düşünmekte zorlanmalarıdır. Sınırlı hatırlama, bir analistin seçmek için en önemli kelimelerden bazılarını kaçı rabileceği anlamına gelir. Bir yaklaşım, belgeleri seçme sorununa makine öğrenimini uygulayarak korpus seçiminde hesaplamalı bir yaklaşım beni msemektir; bu, kitabın ölçüm kısmında tanıtacağımız birçok aynı tekniği kullanarak yapılır (King, Lam ve Roberts, 2017; D'Orazio ve diğerleri, 2014; Abello, Broadwell ve Tangherlini, 2012). Yine de, araştırmacılar metinleri nasıl seçtikleri ve bunun hangi nüfusta potansiyel yanlılık lar üretebileceği konusunda şeffaf olmalıdırlar.

Doclingo https://www.doclingo.ai

Anahtar kelimeler teoride belgeleri geri almak için basit bir algoritmadır, an cak gerçeklik genellikle daha karmaşıktır çünkü araştırmacılar sıklıkla verileri s ağlamak için üçüncü taraflara güvenmektedirler. Uygulama Programlama Aray üzleri (API'ler) veya diğer arama işlevleri aracılığıyla veri erişimi, arama sorgula rını sonuçlara dönüştüren şeffaf bir temel süreç içermeyebilir. Bu, bazı arayüzl erin büyük harf kullanımını göz ardı etmesi ve diğerlerinin büyük/küçük harf d uyarlı olması gibi basit nedenlerden kaynaklanabilir. Bazı sistemler yalnızca ilgi li belgenin rastgele bir seçimini veya yalnızca en ilgili seçimi döndürebilir. API'n in belgeleri erişilebilir hale getirme süreci, metnin temsil ettiği nüfusu ve metni n güvenilir bir şekilde yanıtlayabileceği araştırma sorularını etkileyecektir.

Doclingo https://www.doclingo.ai

4.3 “Bulunan Veri” Üzerine Düşünceler

Sıklıkla, metin korpusları “bulunan veri” biçimindedir; bu, daha büyük bir nüfusun amaçlı örneklemesiyle toplanmamış veridir, bunun yerine hükümetler, bireyler veya diğer kurumlar tarafından sağlanmıştır. Hangi verilerin sağlandığı, araştırma tasarımıyla değil, onları üreten kurumların ve bireylerin kaynakları ve teşvikleriyle belirlenir. Bu tür veriler, ilgi alanındaki nüfusu temsil etmeyebileceği için sıkça eleştirilmiştir ve bu da araştırmacıların verilerden hatalı veya hatta tamamen yanlış sonuçlar çıkarmasına neden olmuştur (Harford, 2014).

Bu sınırlamalara rağmen, bir araştırma projesinde verilerin kullanımı, veri erişilebilirliği ile belirlenir ve etik ve yasal kısıtlamalara tabi olmalıdır, bunu Bölüm 3'te tartıştık. Herhangi bir veri seti için, araştırmacılar okuyucuya o veri setinin ilgi alanındaki soruyu yanıtlamak için seçilme mantığını açıkça iletmelidir. Ayrıca, veri setinin içermediği veya temsil etmediği ilgili bilgileri de belirtmelidir.

Doclingo https://www.doclingo.ai

4.4 Sonuç

Belgeleri seçmek, analiz sürecinin kritik bir parçasıdır ancak erişileb ilirlik, ortam ve daha büyük bir koleksiyondan çıkarma yeteneği gibi bi rçok kısıtlamaya tabidir. Temel zorluk, ilgi alanındaki nüfusu temsil ed en bir korpus oluşturmaktır. Elbette, ilgi alanında bir nüfus seçmediys eniz bu oldukça zordur. Twitter'daki duygularla mı yoksa ABD nüfusuy la mı ilgileniyorsunuz? Herkesin siyasi tercihleriyle mi yoksa sadece m uhtemel seçmenlerle mi ilgileniyorsunuz?

Bu zorluklar, zaman veya kaynaklar arasında karşılaştırmalar yapma gerekliliğ i ile daha da kötüleşebilir. Twitter ve Facebook gibi sosyal medya platformları sür ekli olarak politikalarını değiştirmekte, bu da kaynak yanlılığı, teşvik yanlılığı, orta m yanlılığı ve çıkarma yanlılığını sürekli değişen hedefler haline getirmektedir. G erçekten de, fenomenin kendisinin doğası bile değişiyor olabilir (Munger, 2019). Büyük şehirlerin daha fazla kurumsal gazeteleri olabilir ve bu gazeteler daha fazlas oruşturma raporları yapabilir. Bu, yolsuzluğun—bir örnek seçersek—büyük şehirle rdeküçük yerlerden daha fazla mı gerçekleştiği yoksa sadece bunun hakkında dah a fazla mıbilgiye sahip olduğumuz anlamına geliyor? Pratikte gözlemlediğimiz oldu kça yaygın birsorun, çok yıllık bir zaman diliminde belge koleksiyonlarıyla, her zam an daha sonraöncekilerden daha fazla belge olmasıdır.

Bu zorluklar soru-spesifik olup, bir araştırma sorusunu rahatsız ede n zamansal veyakaynak tutarsızlıkları, başka birinin ilgi nesnesi olabili r. Bu sorunların ne kadarsorunlu olabileceği, metinleri analiz etmek içi n kullanılan belirli yönteme de bağlıdır.Bu konuya kitap boyunca geri döneceğiz.

---

[1]Kambhampati, Sandhya. "1,018 Açık Kayıt Talebi Gönderdim ve Öğrendiklerim." ProPublica. 4 Ocak 2018. https://www.propublica.org/article/open-kayıt-talebi-illinois-foia-dersleri

[2]Yazarlar, makalelerinde bu düşünce deneyini ele alıyor ve koleksiyonu daha verimli şekilde keşfetmeye olanak tanıyan istatistiksel yöntemler geliştiriyorlar.

Doclingo https://www.doclingo.ai

BÖLÜM 5

Kelimeler Torbası

Önceki bölümde, yeni bir belge koleksiyonu oluştururken dikkat edilmesi gereken bazı temel önyargıları ele aldık.Metin analizi araçlarını uygulamak için bu belgelere sayısal bir temsil vermemiz gerekiyor. Bu bölümde “kelime torbası” modelini tanıtıyoruz. Bu temsil, çok terimli dil modeli ve vektör uzayı modelinin temellerini sağlar; bunları sırasıyla Bölüm 6 ve 7 de ele alacağız.

Bölüm 3'te tanıttığımız gibi, kelime torbası modelini tanıtmak için Birlik Konuşmaları korpusunu kullanacağız; bu, ABD başkanlarının politika önceliklerinin zamanla nasıl değiştiğini göstermektedir. Bu korpusu, metinleri veri olarak temsil etmenin bir yolunu göstermek için kısmen kullanıyoruz, ancak aynı zamanda sosyal bilimler hakkında derin bir bilgi ile birlikte kullanılan basit nicel analizlerin sosyal bilim araştırmaları için ne kadar güçlü olabileceğini iletmeyi umuyoruz.

Doclingo https://www.doclingo.ai

5.1 Kelime Torbası Modeli

En yaygın metin temsili “kelime torbası” modeli olarak adlandırılır. Temel fikir basittir: her belgeyi, içindeki her kelimenin ne kadar sıklıkla ge çtiğini sayarak temsil edeceğiz.

Örneğin, başkanların imalat sektörüne odaklanmasının zamanla nasıl değiştiğiyle ilgileniyor olabiliriz. Birlik Konuşmaları korpusunda n imalat kelimesini içeren iki cümle alıyoruz. Şimdilik, bu kısa cümlel erin her birini belge olarak ele alalım ve bir matris içinde temsil edeli m.

	undoubtedly	power	congress	seriously	affect	agricultural	manufacturing	interests	france	passage	laws	relating	trade	united	states	make	sure	foreign	company	advantage	american	comes	accessing	financing	new	markets	like	russia
Doc 1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	0	0	0	0	0	0	0	0	0	0	0	0	0
Doc 2	0	0	1	0	0	0	1	0	0	0	0	0	0	0	0	1	1	1	1	1	1	1	1	1	1	1	1	1

Örnek 5.1. İçinde kelime geçen iki örnek cümle SOTU korpusundan imalat.

> Doküman 1: Kongre'nin, Fransa'nın Amerika Birleşik Devletleri ile olan ticar etiyle ilgili yasaların geçişiyle tarımsal ve imalat çıkarlarını ciddi şekilde etkil eme gücüne sahip olduğu şüphesizdir. (Başkan Jackson, 1831) Doküma
>
> n 2: Ve bu Kongre, herhangi bir yabancı şirketin, finansmana veya Rusya gi bi yeni pazarlara erişim söz konusu olduğunda Amerikan imalatına karşı bir avantajı olmamasını sağlamalıdır. (Başkan Obama, 2012)

Bu, her satırın farklı bir belgeyi temsil ettiği ve her sütunun belg eyi temsil etmek için kullandığımız bir özelliği tanımladığı bir belge -özellik matrisidir. Bu, birçok bilgiyi - en önemlisi kelime sırasını - at ar, ancak araştırmacıya belgenin birçok amaç için yararlı olan sade bir temsilini sağlar.

Bir kelime torbasının temel fikri oldukça basit olsa da, yukarıdaki gibi bir temsil oluşturmak için yapılması gereken birçok küçük karar vardır. Bu bölümde kelime torbası modeli için varsayılan bir tarif sunuyoruz

Doclingo https://www.doclingo.ai

ve sonraki bölümlerde daha fazla karmaşıklığı tanıtıyoruz. Toplamda tam tarif şudur:

1. Analiz Birimini Seçin
2. Tokenleştirin
3. Karmaşıklığı Azaltın
   - Küçük Harf Yapın
   - Noktalama İşaretlerini Kaldırın
   - Durdurma Kelimelerini Kaldırın
   - Eşdeğer Sınıflar Oluşturun (Kökleme)
   - Frekansa Göre Filtreleyin
4. Belge-Özellik Matrisini Oluşturun

Doclingo https://www.doclingo.ai

5.2 Analiz Birimini Seçin

Dijitalleştirme işleminden sonra, analistin analiz birimini belirlemesi g erekir. Birçok durumda, analiz birimi belgedir—bazı araştırmacılar, gazet e makalelerinden sosyal medya paylaşımlarına kadar her şeyde konular v e duygular gibi miktarları ölçmek ister. Ancak, bazı durumlarda analiz biri mi belgeye göre daha küçük veya daha büyük olabilir—analist, bir gazete makalesini başlıklar ve paragraflara ayırmak isteyebilir veya bir gün içind e tek bir yazar tarafından yazılan tüm tweetleri birleştirebilir. Örneğimiz i çin, cümleleri analiz birimi olarak kullanacağız çünkü kısa ve bu nedenle a çıklayıcı amaçlar için daha faydalıdır.

Analiz birimini seçerken dikkate alınması gereken üç şey vardır: bölme lojistiği, model ve soru.

Belgeler—özellikle erişimi zor olan belgeler—her zaman ideal ol arak istediğimiz biçimde gelmez. Örneğin, *Chronicling*

Amerika Kongre Kütüphanesi'nden gelen proje, 1789'dan 1963'e kadar olan tarihi gazeteleri toplar ve dijitalleştirir. Bu belgeler, haber kağıdından taranır ve ardından optik karakter tanıma (OCR) teknolojisi kullanılarak dijitalleştirilir. Gazetelerin sütunlar halinde basılması ve haber makalelerinin genelliklesayfalar arasında atlaması nedeniyle, belirli bir haber makalesiyle ilgili metneulaşmak zor dur, bu makale analiz için ilgili birim olsa bile. Bunun yerine,makaleleri ayırmanı n lojistik zorluklarına bir uzlaşma olarak, gazete sayfasınıanaliz edebiliriz (Young, 2012). Metni bölmek istediğimizde, ancak bu bölümlereşit şekilde etiketlenmedi ğinde veya başka bir şekilde tespit edilmesi kolayolmadığında lojistik sorunlar da ortaya çıkar.

İkinci husus, analiz biriminin modeli nasıl etkiledir. Bu konuyu önümüzdekibölü mlerde daha derinlemesine tartışacağız, ancak bazı durumlarda tek bir metnibirço k belgeye ayırmak, bir modelin uyum sağlama hesaplama maliyetiniönemli ölçüde artırabilir veya azaltabilir. Ayrıca, modelin istatistiksel verimliliğinidaha fazla veya d aha az hale getirebilir. Dijital beşeri bilimlerde, araştırmacılarsıklıkla roman gibi uz un metinleri analiz eder ve model uyumlarını geliştirmekamacıyla bunları birkaç yü z kelimelik parçalara ayırırlar (Jockers, 2013).

Son ve en önemli husus, sorunun kendisidir. Ülkelerin ne zaman savaş a gideceği hakkında bir sorusu olan araştırmacılar, analiz birimi olarak ill er yerine ülkeleri veya ülke çiftlerini kullanmalıdır; bir romanın zamanla n asıl değiştiğiyle ilgilenen araştırmacılar ise bireysel bölümler veya cümlel er yerine bir romanı incelemelidir. Bu, hesaplama açısından pratik olan il e ilgi alanındaki soruyu en iyi şekilde ele alan arasında bir çatışma yarata bilir. Bu tür dengelemelerin her zaman belirgin yanıtları yoktur.

Doclingo https://www.doclingo.ai

Bazen model, metnin küçük parçaları üzerinde uyum sağlayabilir ve sonuçlar, soru ile ilgili birimin özelliklerini tahmin etmek için bir araya getirilebilir, ancak modele bağlı olarak bu her zaman basit olmayabilir. Kararlar durum bazında verilmelidir.

Kitabın geri kalanında, anlamayı kolaylaştırmak için analiz birimini - romanlar, paragraflar veya tweetler - genellikle “belge” olarak adlandıracağız. Araştırmacının her zaman analiz birimi olarak tam bir belge kullanmasını beklemediğimizi netleştirmek istiyoruz.

Doclingo https://www.doclingo.ai

5.3 Tokenleştirme

Analiz birimini seçtikten sonra, ikinci adıma, tokenizasyon aşam asına geçmeye hazırız. Analiz birimini seçmek, korpusu ayrı belgel ere ayırmakla ilgiliyken, tokenizasyon bir belgeyi ayrı kelimelere ay ırmakla ilgilidir. İlk örneğimizde, iki kısa cümlemizi (bundan böyle " belgeler") bileşen kelimelerine ayırdık. Kelime torbası modeli, her k elimenin her belgede kaç kez göründüğünü yalnızca saklar. Belged eki her bireysel kelime bir *token* ve bir belgeyi bileşen kelimelerin e ayırma sürecine *tokenizasyon* denir. Daha genel olarak, *tokens* , belgelerimizi saymadan önce ayırdığımız bireysel birimlerdir. Her token belirli bir *type* (bu bağlamda sütunun adı) türündedir. Genel likle *types* kümesine kelime dağarcığı olarak atıfta bulunacağız.

İngilizce'de, farklı kelimeler boşluk ile ayrılır. Bu, bir kod perspektifind en bakıldığında, tokenizasyonun esasen metni boşluklarla bölmek kadar basit olduğu anlamına gelir. Bu yaklaşım çoğu dil için işe yarayacaktır. Ancak, Çince, Japonca ve Lao gibi bazı dillerde, kelimeler boşluklarla ayrıl maz; bunun yerine, kelimeler cümle içindeki bağlamdan okuyucu tarafın dan çıkarılır. Bu diller için, karakterleri bileşen kelimelerine ayırmak üzere bir kelime segmentasyon modeli adı verilen bir modele ihtiyacımız var.

Belgeleri neden kelimelere ayırmayı seçtiğimizi düşünmek önem lidir. Bir uçta belgeleri bireysel harflere ayırabiliriz. Bu, her biri A'da n Z'ye kadar olan 26 olası tür olması avantajına sahip olacaktır (en azından İngilizce'de). Bu, belgenin harf K'nın kendi başına bir anla mı olmadığı için belgenin iyi bir temsilini sağlamaz. Diğer uçta belg eleri bireysel cümlelere ayırabiliriz. Cümleler genellikle tamamlan mış bir fikir içerir, ancak herhangi bir cümle muhtemelen milyonlar ca belgeden oluşan bir korpus içinde bile benzersizdir; yani, çok fa zla tür vardır. Kelimeler, bireysel olarak anlam içerdiği için bir uzlaş madır, ancak sınırlı sayıda tür vardır.

Ancak bazen tek bir kelime bile çok dar olabilir çünkü bazı kavra mlar kelimeleri köprüler. Yaygın bir örnek beyaz evdir; burada ifad e beyaz ve ev olarak ayrıldığında önemli bir anlam kaybolur.

Bu anlamın bir kısmını *n*-gramları kullanarak, özelliklerimiz olarak sıralı bir n kelim e seti olarak geri kazanabiliriz. Tek kelimelere *unigram*, sıralı çiftlere *bigram* ve sıra lı üçlüler için *trigram* diyoruz. Daha yüksek dereceli *n*-gramlar kullanmak, benzersi z türlerin sayısını önemli ölçüde artırır, ancak daha fazla bilgi tutarak metin analizi mize yardımcı olabilir.

Araştırmacılar n-gramları iki şekilde dahil edebilirler. İlk olarak, unigrams yerine veya ek olarak, korpus içinde yer alan iki kelimeden oluşan ardışık setleri dahil edebilirler.

Doclingo https://www.doclingo.ai

Bu, çok büyük bir tür sayısına ve dolayısıyla nihai belge-özellik mat risimizde birçok sütuna yol açacaktır. Benzersiz türlerin sayısını aza ltmanın yollarını Bölüm 5.4.5'te filtreleme üzerine tartışacağız.

Alternatif olarak, araştırmacılar analizlerine faydalı olacağını düşündükle ri belirli bigram ve trigramların bir listesini tutmanın yararlı olabileceğini dü şünebilirler. Örneğin, Rule, Cointet ve Bearman (2015), SOTU konuşmalarını n analizinde ulusal güvenlik ve yerel yönetim gibi bazı çok kelimeli ifadeleri kullanmaktadırlar. Bunu, bir n-gram olarak ele alınan iki kelime arasında bir alt çizgi koyarak görsel olarak belirteceğiz. Çıkarılacak n-gramlar listesi küç ük olduğunda, bu büyük kelime dağarcığı sorununu çözer, ancak bir n-gram listesi gerektirir.

Bir *n*-gram listesini üretmenin yaygın bir yolu (ve ayrıca Rule, Cointet ve Bearman (2015) tarafından benimsenen yaklaşım) istatistiksel testlere day anmaktadır. Birçok varyantı vardır ama ortak bir mantığı paylaşırlar. Bu kel ime çiftinin, bileşen parçalarından ayrı bir anlamı olan bigramlar listesi olu şturmaya çalıştığımızı hayal edin. Bu kelime çiftini görme olasılığını, her bir ini bağımsız olarak görme olasılığına göre kullanabiliriz. Örneğin, beyaz ev görme olasılığı, beyaz ve ev kelimelerini ayrı ayrı görme olasılığına göre yet erince yüksekse, bunu bigramlar listemize ekleriz. Dilin gramer kalıplarına dayanan *n*-gramları tanımlamak için başka stratejiler de vardır. Bunların ta rtışmasını, dilin yapılandırılmış temsilleri üzerine olan Bölüm 9 'a erteleyeli m.

Örnek 5.2. SOTU korpusundan bir cümle için tokenizasyon örneği. United States, bir big ram haline getirmek için United_States olarak dönüştürülür.

Şüphesiz, Kongre'nin, Amerika Birleşik Devletleri ile olan ticaretiyl e ilgili yasaların geçişiyle Fransa'nın tarımsal ve sanayi çıkarlarını ciddi şekilde etkileme gücüne sahiptir.

Kesinlikle, Kongre'nin Fransa'nın Amerika Birleşik Devletleri ile olan ticare tiyle ilgili yasaların geçişiyle tarımsal ve sanayi çıkarlarını ciddi şekilde etki leme gücüne sahip olduğu inkar edilemez.

Örnek 5.2'de, Örnek 5.1'den gelen ilk belgenin nasıl tokenleştirilebileceğini gösteriyoruz. Bir tek token olarak ele almak istediğimiz United States bigramın ı bir n-gram olarak dahil ettik.

Doclingo https://www.doclingo.ai

5.4 Karmaşıklığı Azaltma

Belgelerdeki kelimeler tokenleştirildikten sonra, tarifin dördüncü adımın a hemen geçebilir ve bunları sayıp doküman-özellik matrisimizi oluşturabili riz. Ancak, birçok uygulama için bu, verimli olamayacak kadar büyük bir sö zlükle sonuçlanacaktır. Bu nedenle, bag-of-words modellerinde genellikle k armaşıklığı azaltmak için bazı kelime türlerini bıraktığımız bir aşama vardır. Karmaşıklığı azaltmak, hesaplamalarımızda bize yardımcı olacak ve sonrak i analizleri daha ekonomik hale getirecektir. Bu bölümde beş yaygın adımı tanımlıyor ve her birine giren birçok kararı belirliyoruz. Her aşamada, deva m eden örneğimizi güncelliyoruz.

5.4.1 KÜÇÜK HARFE ÇEVİRME

Tokenleştirme işleminden sonra, bireysel kelimeleri tanımlamanın ilk adımı genellikle t üm büyük harfleri küçük harflerle değiştirmektir. Fikir, "In" kelimesinin çoğu uygulama ve araştırma sorusu için "in" kelimesinden farklı olmadığıdır. Bu stratejinin bir varyasyonu, k elimelerin yalnızca bir cümleye başladıklarında küçük harfe çevrilmesidir.

Orijinal: Kongre'nin, Amerika Birleşik Devletleri ile ticaretiyle ilgili y asaların geçişiyle Fransa'nın tarımsal ve sanayi çıkarlarını ciddi şeki lde etkileme gücünde olduğu şüphesizdir.

Önce Küçük Harf: Kongre'nin, Fransa'nın Amerika Birleşik Devletleri i le olan ticaretiyle ilgili yasaların geçişiyle tarımsal ve imalat çıkarların ı ciddi şekilde etkileme gücünde olduğu şüphesizdir.

Sonra Küçük Harf: kongre'nin, fransa'nın amerika birleşik devletleri i le olan ticaretiyle ilgili yasaların geçişiyle tarımsal ve imalat çıkarları nı ciddi şekilde etkileme gücünde olduğu şüphesizdir.

5.4.2 NOKTALAMA İŞARETLERİNİ KALDIRMA

İkinci adım, tüm noktalama işaretlerini kaldırmaktır. Yine birçok araştırma sor usu için, araştırmacılar genellikle metin içinde kaç tane virgül, kesme işareti veya nokta bulunduğuyla ilgilenmezler ve bu nedenle bunları silmeyi tercih ederler. Araştırmacı ayrıca, diğer kaynaklardan gelen verilerde sıklıkla bulunan biçimle ndirme ipuçlarını ortadan kaldırmak isteyebilir. Örneğin, bölüm başlıkları, sayf a numaraları ve html etiketleri, araştırmanın amacı için önemli olmayabilir ve e ğer öyleyse, analizden önce atılmalıdır. Öte yandan, belirli noktalama işaretleri , örneğin Twitter'daki # sembolü, korunması gereken önemli unsurlar olabilir.

Doclingo https://www.doclingo.ai

orijinal çalışmanın anlamını. Belirli görevler için, örneğin duygu analizi, b u adım dikkatlice yapılmalıdır çünkü yaygın noktalama temelli emoji'ler, ö rneğin :), ve ünlem işaretleri duygu tahmininde güçlü belirleyiciler olabilir . Burada alt çizgiyi kaldırmamaya dikkat ediyoruz çünkü bunu bigram'ı be lirtmek için kullanıyoruz.

Orijinal: Kongre'nin, Amerika Birleşik Devletleri ile ticaretiyle ilgili y asaların geçişiyle Fransa'nın tarımsal ve sanayi çıkarlarını ciddi şeki lde etkileme gücünde olduğu şüphesizdir.

Bir Noktalama İşareti Kaldırmadan Önce: kesinlikle kongrenin gücünde fransa'nın tarımsal ve sanayi çıkarlarını ciddi şekilde etkilemek birleşik_devletler ile ticaretiyle ilgili yasaların geçişiyle.

Noktalama İşareti Kaldırdıktan Sonra: kesinlikle kongrenin gücünde fransa'nın tarımsal ve sanayi çıkarlarını ciddi şekilde etkilemek birleşik_devletler ile ticaretiyle ilgili yasaların geçişiyle

5.4.3 ÖNEMSİZ KELİMELERİ KALDIR

Küçük harfe çevirme ve istenmeyen noktalama işaretlerini kaldır dıktan sonra, belgede kalan tek içerikkelimelerin kendisidir. Analist , önemsiz kelimeleri kaldırmaya karar verebilir—belgelerde kullanıl an yaygın kelimeler, elindeki görev hakkında çok fazla bilgi vermez .[1] İngilizcede, and, the ve that gibi yaygın kelimeler belgelerden kal dırılabilir, böyleceözellik setinin boyutu ve karmaşıklığı azaltılabilir. Önemsiz kelimeleri kaldırmak genelliklekorpusun token'larının son derece yüksek bir kısmını kaldırırken, çok az sayıda tip kaldırır; bu —eğer bu kelimelerçok az veya hiç anlam taşımıyorsa—büyük hes aplama tasarruflarına yol açabilir. Bu, çoğu dildebirkaç kelimenin s on derece yaygın olduğu gerçeğini yansıtır. Fikir, bu token'larbüyü k bir kelime kısmını temsil etse de, yalnızca küçük bir anlam kısmın ı temsil etmeleridir. Birçok dildeki önemsiz k
elime listeleri,yazılı metin analizi araçları sağlayan yazılım paketlerinde mevcuttur.

Orijinal: Kongre'nin, Amerika Birleşik Devletleri ile ticaretiyle ilgili y asaların geçişiyle Fransa'nın tarımsal ve sanayi çıkarlarını ciddi şeki lde etkileme gücünde olduğu şüphesizdir.

Durum Kelime Kaldırma Öncesi: kesinlikle kongrenin gücünde ciddi şekilde fransa'nın tarımsal ve sanayi çıkarlarını etkilemek

Doclingo https://www.doclingo.ai

kanunların geçişi ile birleşik_devletler ile ticareti ile ilgiliDu

rum Kelime Kaldırma Sonrası: kesinlikle güç kongre ciddi etkitarı msal sanayi çıkarları fransa geçiş kanunları ile ilgili ticaretbirleşik_ devletler

5.4.4 EŞDEĞER SINIFLAR OLUŞTUR (LEMMATIZE/STEM)

Tüm harfleri küçük harfe çevirme, noktalama işaretlerini kaldırma ve önemsiz kelimeleri atma, sözlükteki türlerin sayısını önemli ölçüde azaltacaktır. Ancak, birçok kelimenin aynı bilgiyi taşıdığı durumlar hala olabilir çünkü ortak bir kök paylaşırlar. Örneğin aile, aileler ve ailenin (apostrofun muhtemelen atıldığı) hepsi sözlükte farklı türlerdir ama bazı görevler için hepsini ortak bir forma eşlemek etkili olabilir. Bir *lemma* , bir dizi kelimenin eğilimle (yani, durum, sayı, zaman vb. nedeniyle yapılan değişiklikler) ilişkili olduğu kanonik formudur (bir sözlükte bulunabileceği gibi). Lemmatizasyon, kelimeleri lemma'larına eşleme sürecidir. Bu bir eşdeğerlik beyanıdır - amacımız için kelimenin tüm varyantlarını aynı şekilde ele alacağız.

Bazen lemayı tanımlamak oldukça basit olabilir, aile varyantları gibi, ancak aynı zamanda oldukça karmaşık da olabilir. Örneğin, İngilizcede birçok yaygın kelimenin (örneğin, see) düzensiz bir geçmiş zamanı vardır (örneğin, saw). Tam olarak aynı token, konuşma diline bağlı olarak iki farklı lema sahip olabilir. Örneğin, bir yazı parçası writing lema'sına sahipken, yazma eylemi write lema'sına sahip olacaktır. Lemmatizasyon, genellikle bir sözlük kontrolü (saw'ı see'ye eşlemek için) ve konuşma diline etiketleme (writing'in iki lema'sını ayırt etmek için) gerektirdiğinden zahmetli olabilir. İlişkili biçimleri bir araya getiren lemmatizasyona popüler bir yaklaşım stemming'tir. Stemming'de , bir kelimenin sonunu birkaç basit kural kullanarak basitçe atarız. Aile durumunda, yukarıdaki tüm varyantlarımız famili'ye eşlenecektir. Stemming genellikle oldukça etkili ve lemmatizasyondan önemli ölçüde daha hızlı olmasına rağmen, daha karmaşık biçimlere sahip kelimelerle (görme ve yazma örnekleri gibi) başa çıkmada başarısız olur.Stemming bazen iki kelimeyi, oldukça farklı anlamlara sahip olabilecek ortak bir köke de indirebilir, örneğin secure ve securities.

Kesinlikle, Kongre'nin Fransa'nın Amerika Birleşik Devletleri ile ticareti yle ilgili yasaların geçişiyle tarımsal ve imalat çıkarlarını ciddi şekilde etkileme gücünde olduğu tartışmasızdır.

Doclingo https://www.doclingo.ai

Stemming Öncesi: kesinlikle güç kongre ciddi etki tarımsal ima lat çıkarları fransa geçiş yasalar ilgili ticaret amerika_birleşik_d evletleri

Stemming Sonrası: kesin değil güç kongre ciddi etki tarımsal imalat çıka r fransa geçiş yasa ilgili ticaret amerika_birleşik_devletleri

Birçok stemming algoritması, geniş bir yazılım yelpazesinde mevcu ttur; en yaygın olanlardan biri Porter stemming algoritmasıdır (Porter, 1980). Stemming, hız, diller arası erişilebilirlik ve ivme kombinasyo nu nedeniyle lemmatizasyondan hala önemli ölçüde daha popüler dir. Çalıştığınız dile ve mevcut hesaplama kaynaklarına bağlı olarak , lemmatizasyon stemming'e göre daha fazla veya daha az tercih e dilebilir. Her iki durumda da, amaç, bir kelimenin varyantlarını eşd eğer olarak ele alarak doküman-özellik matrisimizdeki tür sayısını azaltarak analizi basitleştirmektir.

5.4.5 SIKLIĞA GÖRE FİLTRELE

Doküman-özellik matrisini oluşturmadan önce karmaşıklığı azaltmanın son adı mı, çok nadir (veya bazen çok yaygın) olan kelimeleri kaldırmaktır. Bir kelime, korp us içinde yalnızca bir kez görünüyorsa, bunu etkili bir şekilde kullanmamız olası de ğildir ve modele bağlı olarak, korpusdan bu tür kelimelerin tamamını kaldırmak ön emli hesaplama tasarrufları sağlayabilir. Dilin özellikleri nedeniyle, bir korpusda ge nellikle bu tür çok nadir kelimeler bulunur.

Diğer durumlarda, inanılmaz derecede yüksek frekansa sahip kelimeleri kaldırma k isteyebiliriz. Her belgede kullanılan bir kelimenin, belgeler arasında ayrım yapmamı za yardımcı olması pek olası değildir. Bunları uygulamaya özel önemsiz kelimeler olar ak düşünmeyi seviyoruz ve genellikle, korpusun belirli bir anahtar kelimenin varlığına göre açıkça seçildiği veya korpusun ortak bir sözlüğe sahip belirli bir konu üzerinde olduğu durumlarda ortaya çıkarlar.

Toplamda, verdiğimiz tarif tokenleştirme, küçük harfe çevirme, nokt alama işaretlerini kaldırma, eşdeğerlik sınıfları oluşturma ve frekansa g öre filtreleme adımlarını içermektedir. Bu adımların hangi sırayla alındı ğı da önemlidir. Örneğin, önemsiz kelimeler tokenleştirmeden önce kal dırılırsa, analist farklı bigramlar ve trigramlar elde edecektir. Analist, ha ngi ön işleme adımlarını alacağına ve hangi sırayla alacağına karar ver mek için en iyi yargısını kullanmalıdır. Ön işlenmiş veriler sonraki analizl erde kullanıldığında, ön işlemenin araştırmacının ilgi alanına ilişkin bilgi leri koruduğundan emin olmak için doğrulama gerekecektir. Biz

Doclingo https://www.doclingo.ai

kitabın ilerleyen bölümlerinde doğrulama hakkında daha kapsamlı konuşacağız.

Doclingo https://www.doclingo.ai

5.5 Doküman-Özellik Matrisi Oluşturma

Artık metni tokenleştirdiğimize ve karmaşıklığını bir nebze azalttığımıza g öre, metni sayısal verilere dönüştürme zamanı geldi. Veri kümeniz içindeki b enzersiz metin birimlerinin sayısını belirtmek için *N* kullanacağız ve bu birim leri indekslemek için *i* kullanacağız. Bu birimleri ön işleme tabi tuttuktan son ra, veri kümeniz içindeki türlerin sayısını belirleyebilirsiniz; bu, sözlüğünüzün boyutudur ve bunu *J* ile belirteceğiz ve *j* ile indeksleyeceğiz. Bunun sonucu, bir doküman-özellik matrisi olarak adlandırdığımız şeydir; buna *W* diyoruz, N × J matrisidir. Bu matrisin her bir elemanı W i j, her türün belgede kaç kez göründüğüdür. Genel olarak, çoğu belge, bir korpus içindeki birçok benzersiz t ürden yalnızca birkaçını içerdiğinden, doküman-özellik matrisi nispeten seyr ektir—yani, çoğunlukla sıfır içerir.

SOTU korpusundan iki örnek cümlemize geri dönüyoruz:

SOTU örnek korpusu

Doc 1: Kongre'nin, Fransa'nın Amerika Birleşik Devletleri ile olan ticareti yle ilgili yasaların geçişiyle tarımsal ve sanayi çıkarlarını ciddi şekilde etk ileme gücünde olduğu şüphesizdir. (Başkan Jackson, 1831)Doc 2: Ve

bu Kongre, herhangi bir yabancı şirketin, finansmana veya Rusya gibi y eni pazarlara erişim söz konusu olduğunda Amerikan sanayisine karşı b ir avantajı olmamasını sağlamalıdır. (Başkan Obama, 2012)

O zaman, yukarıda yaptığımız gibi aynı ön işleme rutininden geçirebili riz.Bu, her biri küçük harfe çevrilmiş, noktalama işaretleri kaldırılmış, öne msiz kelimeler kaldırılmış ve kökleri alınmış iki belge oluşturacaktır.Bunu yaptıktan sonra, korpus içindeki benzersiz türlerin sayısını, *sözlük*, belgel eyebiliriz.Genel olarak, ön işleme tabi tutulduktan sonra, bu üç belgede 2 8 benzersiz kelime bulunmaktadır.*W* , bu nedenle iki satırdan (her belge i çin bir) ve 28 sütundan (her benzersiz kelime için bir) oluşacaktır.

Bu satırların girişleri, her kelimenin her belgede kaç kez göründüğ ünü sayacaktır; aşağıya bakın.

Bir kez *W*'ye sahip olduğumuzda, metni özetlemeye yardımcı olabilecek bi rçok işlem gerçekleştirebiliriz.Başlamak için iki basit örnek alırsak, *W*'nin her sütununu toplarsak, korpus içinde her benzersiz türün ne kadar göründüğü nün bir özetini elde ederiz.

Ya da, doküman-özellik matrisinin her satırını toplayabiliriz, bu da

Doclingo https://www.doclingo.ai

her belgenin (ön işleme sonrası) kaç token içerdiğini bize söyleyecekti r.Bu toplamın maksimumu en uzun belgenin uzunluğu, minimumu is e en kısa belgenin uzunluğu olacaktır.Bu temel örnekler olsa da, bu ki tabın geri kalanında, bu doküman-özellik matrisine benzer temsiller ü zerinde işlemler gerçekleştiren algoritmalar tanımlanmaktadır.

Table 5.1. Document-feature matrix W from two sentences containing the word `manufacturing` from the SOU corpus.

	undoubt	power	congress	serious	affect	agricultur	manufactur	interest	franc	passag	law	relat	trade	unit	state	make	sure	foreign	compani	advantag	american	come	access	financ	new	market	like	russia
Doc 1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	0	0	0	0	0	0	0	0	0	0	0	0	0
Doc 2	0	0	1	0	0	0	1	0	0	0	0	0	0	0	0	1	1	1	1	1	1	1	1	1	1	1	1	1

Table 5.2. Result of summing the columns of W, the document-feature matrix.

undoubt	power	congress	serious	affect	agricultur	manufactur	interest	franc	passag	law	relat	trade	unit	state	make	sure	foreign	compani	advantag	american	come	access	financ	new	market	like	russia
1	1	2	1	1	1	2	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1

Tablo 5.3. W'nin satırlarının toplamının sonucu, do küman-özellik matrisidir.

Dok 1	15
Dok 2	15

Doclingo https://www.doclingo.ai

5.6 Varsayılanları Yeniden Düşünmek

Yukarıda özetlediğimiz varsayılan prosedür, basitçe bir varsayılan p rosedürdür. Tüm durumlar için işe yaramaz ve esasen belgelerin gen el konusunu kapsamak için tasarlanmıştır, SOTU korpusundaki örnekl erde olduğu gibi. Bu prosedürlerden birini veya daha fazlasını terk et mek isteyebileceğiniz iki tür ayar vardır. Birincisi, prosedürlerin proble m türü için uygun olmadığı durumdur ve ikincisi, verilerin yeterince b üyük olduğu ve prosedürlerin zararlı olduğu durumdur.

5.6.1 FEDERALİST KAĞITLARIN YAZARLIĞI

Tanımladığımız varsayılan prosedürün belirli problemler için nasıl uygunsuz olabileceğini görmek için, Bölüm 3'te tanımladığımız Mosteller ve Wallace (196 3)'ın Federalist Kağıtları üzerindeki analizine geri dönüyoruz. Mosteller ve Wall ace (1963), Federalist Kağıtları'nın bilinmeyen yazarlık sorununu ele alıyor; bu belgeler, Amerikan Anayasası'nı desteklemek amacıyla Alexander Hamilton, Jo hn Jay ve James Madison'ın bir kombinasyonu tarafından yazılmıştır.

1700'ler. Birçok makalenin yazarları biliniyor olsa da, 12 belirli makale tartışmalıdır.

Mosteller ve Wallace (1963), Jay, Hamilton ve Madison'ın yazım t arzlarının, özellikle upon, by ve to gibi dolgu kelimeleri kullanımları yla önemli ölçüde farklılık gösterdiğini göstermektedir. Bunlar, kon u hakkında anlamlı içerik taşımadıkları için durak kelimeleri olarak filtreleyeceğimiz kelimelerdir. Ancak bu bağlamda, tam olarak ama ç buydu. Mosteller, otobiyografisinde, “konuyla ilgisi olmayan ve ya zarın küçük veya belki de bilinçsiz tercihlerini yansıtan kelimeler” k ullanmak istediklerini hatırladı” (Mosteller, 2010, s. 56).

Bu tür bir çatışma, varsayılan tarif ile maddi sorun arasında sade ce yazar atıf sorunuyla sınırlı değildir. Her tür sosyal bilimci, varsayı lan tarifin içeriksiz olarak ele alabileceği metin özelliklerinin önemi ni göstermiştir (Biber, 1991; Chung ve Pennebaker, 2007; Breiger, Wagner-Pacifici ve Mohr, 2018). Örneğin, Monroe, Colaresi ve Quinn (2008), cinsiyet zamirleri olan "he" ve "she"nin, ABD Kongre Kayıtları'ndaki kon uşmalarda konuşmacının siyasi partisiyle yüksek derecede ilişkili olduğunu gösterme ktedir. Bu zamirler neredeyse her İngilizce durak kelime listesinde yer aldığından, du rak kelimeleri düşünmeden tamamen çıkarmak, değerli bir içgörüyü kaçırmamıza ne den olabilir. Denny ve Spirling (2018), yukarıda tanımladığımız adımlardaki birçok var yasyonun sonraki analizlerin sonuçlarını etkileyebileceğini göstermektedir.

Doclingo https://www.doclingo.ai

Farklı kombinasyonları test etmenin sonuçların farklı olup olmadığını görmek için ön erilmektedir. Bu argümana kitabın ilerleyen bölümlerinde döneceğiz.



Şekil 5.1. SOTU korpusundaki "manufacturing" kelimesini içeren cümlelerdeki en yaygın kelimelerin kelime bulutları. Sol panel, yalnızca noktalama işaretleri kaldırılmış kelime bulutunu göstermektedir. Sağ panel, varsayılan tarif ile kelime bulutunu göstermektedir. Her iki durumda da, tasarım gereği en yaygın olan "manufacturing" kelimesini kaldırıyoruz.

5.6.2 ÖN İŞLEMEYE KARŞI ÖLÇEK ARGÜMANI

Varsayılan tarifteki adımların çoğu, sözlük boyutunu azaltmaya yöneliktir. Bunun iki temel nedeni vardır: estetik ve verimlilik.

Kelime bulutları oluşturduğumuzda veya model sonuçlarını görselleştirdiğimizde, önemsiz kelimeleri kaldırmamak bu görselleştirmeleri daha az bilgilendirici hale getirebilir. Şekil 5.1 , manufacturing kelimesini içeren SOTU korpus cümlelerinin iki kelime bulutunu göstermektedir. Sol panel, noktalama işaretleri dışında herhangi bir kaldırma işlemi yapmamaktadır ve sağ panel varsayılan tarife uymaktadır. Hemen görüyoruz ki sağ panel, manufacturing kelimesini içeren cümlelerin konuları hakkında çok daha bilgilendiricidir, oysa sol panel of ve the gibi yaygın ve bilgilendirici olmayan kelimeleri vurgulamaktadır. Estetik kaygı önemli bir pratik gerçeklik olsa da, bunu girdilerimizi değiştirmek yerine görselleştirmelerimizi de değiştirerek ele alabiliriz. Örneğin, her zaman önemsiz kelimeleri doküman-özellik matrisimize dahil edebiliriz ama bunları görselleştirmeden açıkça çıkarabiliriz. Kitabın Discovery bölümünde kelimeleri ayırmayı tartıştığımızda, bilgilendirici olmayan kelimelerin karmaşasından daha az etkilenen temsilci kelimeleri bulma meselesine geri döneceğiz.

Doclingo https://www.doclingo.ai

Kelime dağarcığının boyutunu azaltmanın ikinci nedeni, sonraki veri ana lizinin verimliliğidir. Kökleme ve lemmatizasyon, araba ve arabalar gibi iki il işkili kelimenin tam olarak aynı şekilde ele alınabileceği iddiasında bulunm aktadır. Eğer bu kelimeler ortak bir anlama yeterince yakınsa, bu bilgiyi içe rmek faydalı olacaktır çünkü bu, başa çıkılması gereken kelime dağarcığınd a daha az tür anlamına gelir. Ancak, bu tavsiyenin önemi, nispeten az sayıd a belge içeren korpuslara pratik olarak anlaşılabilir bir odaklanmadan kayn aklanmaktadır. Yine de, sosyal bilimciler binlerce belgeden oluşan koleksiy onları analiz etmekten milyonlarca belgeden oluşan koleksiyonları rutin ola rak analiz etmeye geçtiklerinde, herhangi bir sonraki analizin araba ve ara baları aynı şekilde ele almasını belirtmek o kadar önemli olmayabilir çünkü modellerimizin bu ilişkileri kendi başlarına çözmek için yeterli bilgisi vardır. Gerçekten de, iki kelimenin benzer bilgileri ilettiği konusunda yanılabiliriz. Yazarın servetini tahmin ediyorsak, arabalar kelimesinin ortalama olarak ar aba kelimesinden farklı bir anlam taşıyor olması mümkündür.

Alexandra Schofield ve David Mimno'nun son çalışmaları, konu modelleri i çin - tartışacağımız popüler bir model sınıfı olan Discovery'de bu prosedürleri n neredeyse her zaman uygulandığı - varsayılan kök alma ve önemsiz kelime lerin kaldırılmasının, büyük bir korpus olduğunda model performansı için asl ında zararlı olabileceğini belgeledi (Schofield ve Mimno, 2016; Schofield, Mag nusson ve Mimno, 2017). Buradaki daha genel ders, halk bilgeliği ve varsayıl an tariflerde temsil edilen türdeki sezgisel tavsiyelerin her zaman kendi zam anının bir ürünü olduğudur. Topluluğun bu varsayımları yeniden gözden geç irmeye başlaması, metin analizinin bir alan olarak olgunlaştığının bir işareti.

Doclingo https://www.doclingo.ai

5.7 Sonuç

Bu bölümde, metnin bag of words (kelime torbası) temsilinin tem el tarifini adım adım inceledik. Herhangi bir varsayılan tarifin bazı sı nırlamaları olacaktır - ve bunlardan bazılarını önceki bölümde keşfet tik - ancak kelime torbası modeli, bu kadar çok bilgiyi atmasına rağ men şaşırtıcı derecede güçlüdür! Sonraki iki bölümde, kelime torbası temsilinin üzerine yöntemler inşa etmek için iki farklı çerçeve sunac ağız: çok terimli dil modeli ve vektör uzayı modeli.

---

[1]Belirli bir yaygın kelime listesinin hariç tutulması fikrinin, Harold Luhn'un bağlamda an ahtar kelimeler önermesiyle ilgili erken bilgi erişim çalışmalarında ortaya çıktığı görünmek tedir (Luhn, 1960). Barbara Flood, 1961'de biyolojik özetler derlediğini ve dizinleme için ye ni bağlamda anahtar kelimeler yaklaşımını denemeye karar verdiklerini anlatıyor. Manuel olarak gözden geçirmesi için ona tonlarca çıktı verildi ve dizinde "of" ve "in" gibi son derec e yaygın kelimeleri silmeye karar verdi. Bu kelimelerin basılmasını tamamen durduracaklar ı için onlara "durma listesi" adını verdi (Flood, 1999).

Doclingo https://www.doclingo.ai

BÖLÜM 6

Çok Değişkenli Dil Modeli

Bu kitap, iki tür temele sahip modelleri tanımlamaktadır: *olasal vea lgoritmik*. Bu bölümde, son bölümdeki kelime torbası temsilinden yola çıkarak çok değişkenli dağılımı ele alacağız ve bu kitapta incel eyeceğimiz birçok olasılıksal modelin temellerini sağlayacaktır. Bir sonraki bölümde, vektör alanı modeli ile alternatif bir algoritmik çe rçeve sunacağız.

Olasılıksal modellerde—istatistik alanında en yaygın olanlar—verilerin n asıl üretildiği hakkında bir hikaye anlatıyoruz. Bu veri üretim süreci, gözlem lediğimiz verileri kullanarak çıkarabileceğimiz bir dizi bilinmeyen parametr eye veya gözlemlenmeyen gizli değişkenlere dayanmaktadır. Örneğin, Fed eralist Papers örneğini analiz ederken, her yazarın belirli metinlerde farklı oranlarda işlevsel kelimeler ürettiği hakkında bir hikaye anlatacağız. Hikay eyi öne sürdükten sonra, atfedilen Federalist Papers'ı kullanarak bu süreci tersine çevirebilir ve her yazar için bilinmeyen oranları çıkarabiliriz.
Bu, Hamilton veya Madison'un tartışmalı bir makale yazma olasılığını, çı karılan oranlarını gerçek atıfsız metinle karşılaştırarak hesaplamamıza olanak tanır.

Bu modeller, modellerin ne zaman ideal bir şekilde performans göster eceğine dair varsayımların net bir ifadesini sundukları için caziptir (yani, v eri üretim süreci hakkında varsayımlar doğru olduğunda) ve veri üretim s ürecini değiştirerek yeni durumlara kolayca genişletilebilirler. Belki de en önemlisi, bir olasılık modelinin tanımlanması, belirsizliğin optimizasyonu ve nicelendirilmesi için istatistikte bir dizi tarifin erişimini sağlar. Blei (201 4), bu model tarzına erişilebilir bir genel bakış sunar; burada, modellerin inşası, parametrelerin hesaplanması, bulguların eleştirilmesi ve ardından tekrar edilmesi döngüsünü savunur.

Bu olasılıksal temeller, genellikle optimize edilecek bir hedef fon ksiyonu biçiminde bir dizi adım belirleyen algoritmik yaklaşımlara z ıttır. Bu, benzer bir şeyi tanımlamak için farklı bir dil olarak düşünül melidir. Örneğin, birçok model, lineer regresyon gibi, olasılıksal bir perspektiften (normal bir lineer model) veya algoritmik bir perspe ktiften (kare hataların toplamını minimize et) tanımlanabilir. Fark

Doclingo https://www.doclingo.ai

bu iki temel arasındaki ilişki genellikle abartılmaktadır. Bir olasılık modeli objektif bir fonksiyon ve birçok objektif fonksiyon bir algoritmik modeli ima eder.

Multinomial dağılımını tanıtarak başlıyoruz, bu sayım verileri için popüler bir dağılımdır.Daha sonra, kelime dizilerini tahmin eden temel bir olasılıksal dil modelineuygulamasını açıklıyoruz. Bu basit kurulumun nasıl genişletileceğinihiyerarşik bir model inşa ederek gösteriyoruz. Hiyerarşik modeller inşa etmestratejisi, kitabın ilerleyen bölümlerinde yer alacak olasılıksal kümeleme,admixture ve sınıflandırma modellerinin temelini oluşturacaktır.

Doclingo https://www.doclingo.ai

6.1 Multinomial Dağılımı

Metnin bag of words temsilini geliştirdiğimiz önceki bölümle uy umluolasılık dışı bir dil yaratım modeli formüle ederek başlıyoruz. Üç kelimedenoluşan bir sözlük (kedi, köpek, balık) ile oldukça basitl eştirilmiş bir ortamdabaşlıyoruz ve her belge yalnızca bir tekil toke n (yani, bir türün örneği) içeriyor. Her token'ı, yalnızca bir 1 (katego ri belirtir) içeren ve geri kalankısımları boş olan, sözlükle aynı uzunl ukta bir vektörle kodlayacağız. 0. Böylece biz her kelimeyi aşağıdaki vektörlerle temsil ediyoruz, bu vektörler aynı zamanda üç olası benzersiz belgedir:

$$\text{cat} = (1 , 0 , 0) \; \text{dog} = (0 , 1 , 0) \; \text{fish} = (0 , 0 , 1)$$

Bu, makine öğreniminde “one-hot encoding” olarak adlandırılır, ancak sosyal bilimciler “dummy variable” terimiyle daha aşina olabilirler.

Her belge yalnızca bir token uzunluğunda olduğunda, belgeyi bir *categorical distribution*'dan çekim olarak düşünebiliriz . Kategorik dağılım, her kategoriye bir olasılık atar, böylece belge W_i, ~Categorical(μ) olur; burada μ, her bireysel türün olasılığını içeren bir vektördür. Örneğin, kedi belgesinin köpek ve balıktan iki kat daha olası olduğunu varsayalım; elimizde şu vektör var

$$\mu = (.5 , .25 , .25) .$$

Olasılık kütle fonksiyonunu şu şekilde yazabiliriz

$$p (W_i , | \mu) = \prod_{j=1}^{J} \mu_j W_{ij} . \quad (6.1.1)$$

Bu, bir kelimeden daha uzun belgeler durumu için doğal olarak g enelleşir ve multinom dağılımını kullanır. Multinom, token sayısını (y ani, belgenin uzunluğunu) kontrol eden bir tam sayı olan ek bir para metre *M*'ye sahiptir. Böylece W_i, ~ Multinomial(M_i, μ) diyebiliriz ve $M_i = 1$ bu, kategorik dağılıma indirgenir. Bu modelin olasılık kütle fonksiyonu

$$p (W_i , | \mu) = M ! \prod_{j=1}^{J} W_{ij} ! \prod_{j=1}^{J} \mu_j W_{ij} . \quad (6.1.2)$$

Bu dağılımdan bir çekim hala bir vektör olacaktır, ancak şimdi tek bir 1 ve geri kalan 0 yerine, M i'ye toplamı olan tüm negatif olmayan tam sayılar olacaktır.

Doclingo https://www.doclingo.ai

Örneğin, (balık, kedi, balık) belgesi için vektörtemsilini sağlayabiliri z ve bunu daha önce belirttiğimizparametre vektörümüz μ = (. 5 , . 2 5 , . 2 5) ile çekme olasılığını hesaplayabiliriz.Olasılık kütle fonksiy onumuza yerleştirerek.

(balık , kedi , balık) = (1 , 0 , 2) p (balık , kedi , balık | μ) = 3 ! (1 !) (0 !) (2 !) (. 5) 1 (. 2 5) 0 (. 2 5) 2 = . 0 9 3 7 5

Multinomial dağılım altında her kelime, diğer tüm kelimelerden bağıms ız olarak üretilir. Bu, M bağımsız çekim alarak parametre μ ile kategori k dağılımdan çekim yapmaya ve elde edilen one-hotkodlama vektörleri ni toplamaya eşdeğerdir. Bu, sıralamanın önemsiz olduğu ve belgeleri i çerdiği kelimelerin sayısı ile temsil ettiğimizbag of words temsilini eşleş tiren basit bir üretim hikayesi sağlar.

Parametre μ herhangi bir değeri alamaz: J - 1 boyutlu simplex içinde olmalı dır. J - 1 boyutlu simplex, 1'e toplamı olan ve tümü negatif olmayan J değerleri nden oluşan bir vektördür; sezgisel olarak, bu bir oranlar kümesidir. Şekil 6.1 üç kelimelik sözlüğümüz için iki boyutlu simplex'i bir üçgen kullanara k görselleştirir.

ÖZELLİKLER

Bir olasılık modelini belirtmenin avantajı, modelleme varsayımla rının bir sonucu olarak hemen bilinen bir sonuçlar seti ile gelmesid ir. Örneğin, beklenti, varyans ve kovaryans hakkında aşağıdaki özel likler modelden ortaya çıkar:

$$E[W_{ij}] = M_i \mu_j \quad (6.1.3)$$

$$\text{Var}(W_{ij}) = M_i \mu_j (1 - \mu_j) \quad (6.1.4)$$

$$\text{Cov}(W_{ij}, W_{ij'}) = -M_i \mu_j \mu_{j'} \quad (6.1.5)$$

Multinomial model altında, varyans ve kovaryans, ortalamayı belirl eyen parametrelerin sabit fonksiyonlarıdır.

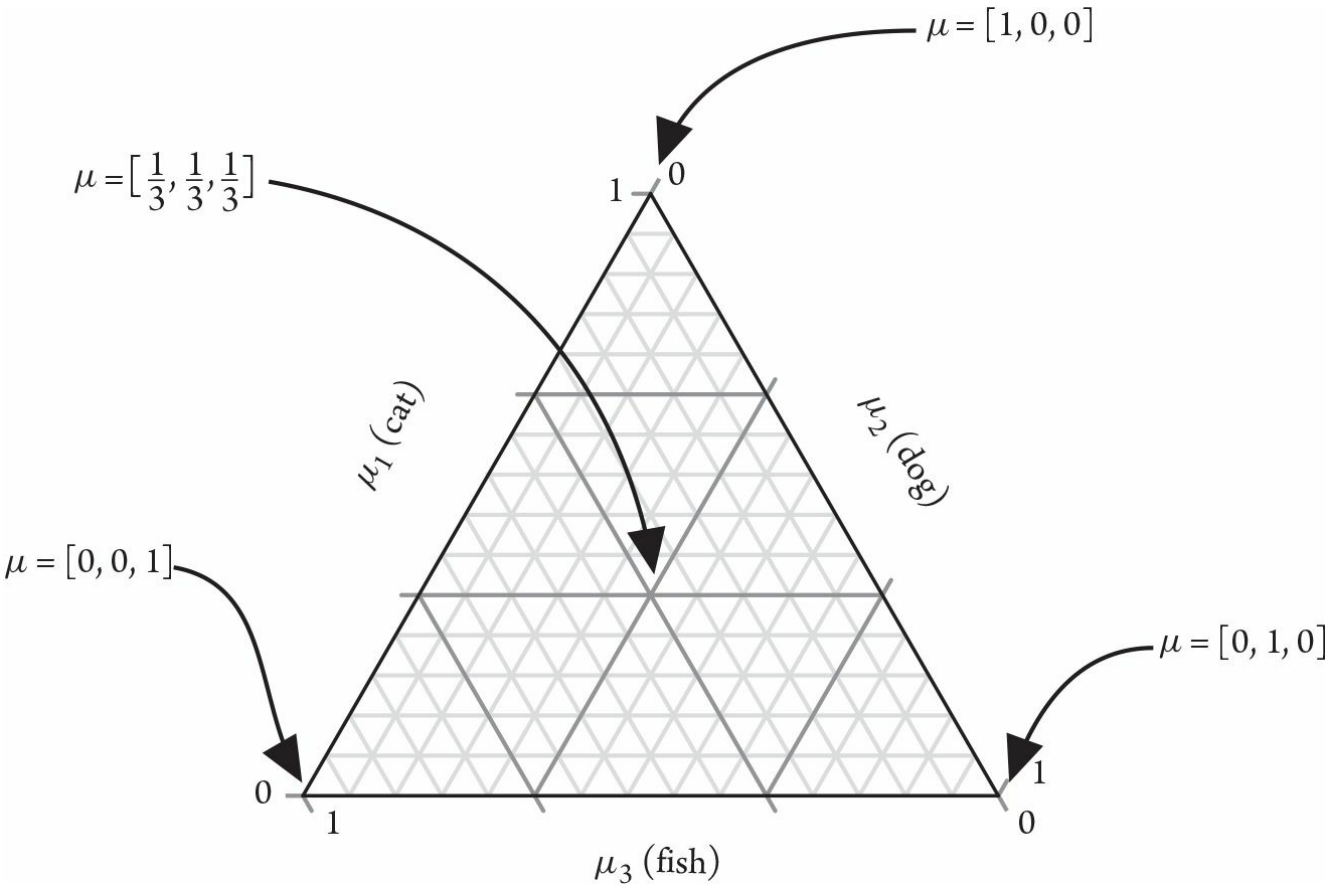
Pratikte genellikle kelime sayıları W i'yi gözlemleriz ve temel param etre μ'yi tahmin etmek isteriz ($M_i = \sum_{j'=1}^{J} W_{ij'}$, belgede bulunan token sayısı olarak etkili bir şekilde gözlemlenir). Olasılık modeli ayrıc a hesaplama için basit yaklaşımlar sağlar. Verilen bir eleman için mak simum olasılık tahmini μ j, kelime j'nin kullanım sayısının toplam toke n sayısına bölünmesiyle elde edilir.

$$\hat{\mu_j} = \frac{W_{ij}}{M_i} \quad (6.1.6)$$

Doclingo https://www.doclingo.ai

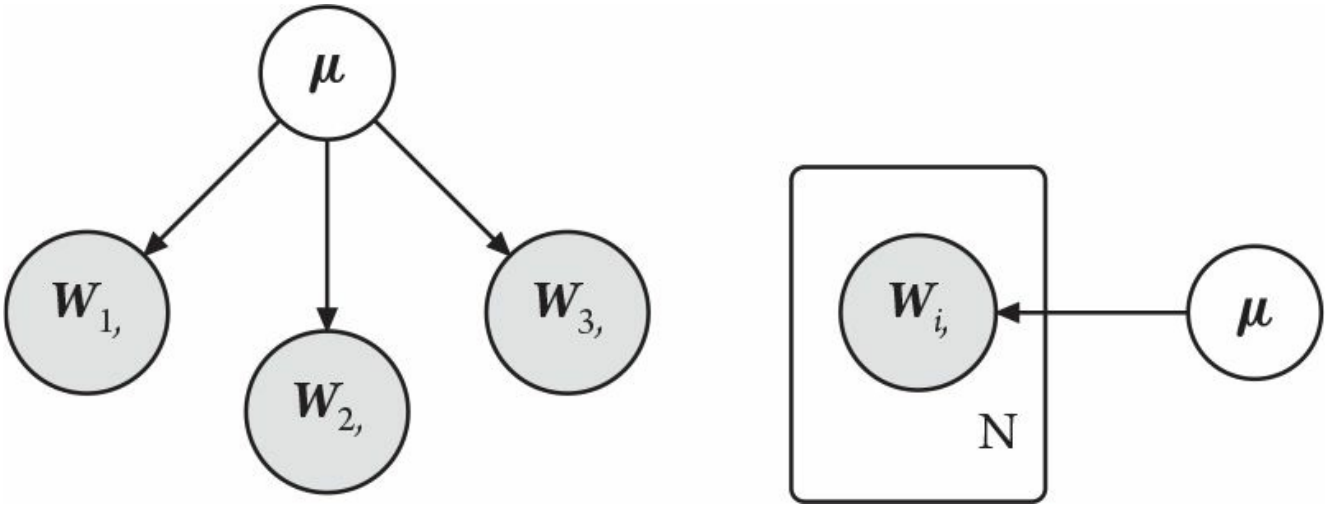
μ, sonsuz uzunluktaki bir belgede kullanılacak her tür kelimenin ora nı olarak yorumlanabilir.

Şimdi N parametre μ'yi paylaşan belgelerimiz olduğunu hayal edin. Y ani, her belge W i , ~ Multinomial (M i , μ). Bu süreci, Şekil 6.2'nin sol pa nelinde gösterilen grafiksel model kullanarak görselleştirebiliriz. Daha ka rmaşık modeller oluşturdukça, notasyon karmaşık hale gelecektir, bu ne denle modeli plaka notasyonu kullanarak temsil edeceğiz (sağ panel). Fiki r, her plakanın tekrarı gösterdiği ve plakanın sağ alt köşesindeki indeksin aynı ilişkileri paylaşan çoğaltılmış düğümlerin sayısını gösterdiğidir. Bu durumda, çünkü W plakanın içinde ve μ plakanın dışında, N doküman oldu ğunu biliyoruz, ancak yalnızca bir parametre μ var. W içeren düğüm, gözlemle nen veriyi belirtmek için gölgelenmiştir.



Şekil 6.1. Bir 2-D simplex. μ her bir elemanı bir kelimeye karşılık gelir (örneğin, μ 1 kedi olasılığını sağlar). Üçgenin içindeki her bir nokta, vektör μ değerine karşılık gelir. Dört bireysel nokta etike tlenmiştir (üç köşe ve merkez).

Doclingo https://www.doclingo.ai



Şekil 6.2. Basit bir multinom dağılımı için grafiksel model ve plaka diyagramı, N = 3.

Her bir token'in multinomda bağımsız olarak çekildiği için, tüm doküm anlar üzerinde toplam alarak tek bir multinom rastgele değişkeni oluştur abiliriz. Yani, Σ i W i , ~ Multinomial (Σ i M i , μ). Model varsayımları altı nda, μ parametresini paylaşan tüm dokümanları μ tahmin etme amacıyl a tek bir büyük doküman olarak ele alabiliriz.

Multinom dağılımı, dokümanların nasıl üretildiği hakkında etkili bir hikaye anlatır. Kelime sayımlarının ortak bir parametre μ ile bir multinom dağılımı ndan kaynaklandığı varsayımı, beraberinde birçok yararlı istatistiksel sonuç getirir. Bir sonraki bölümde bunun bir dil modeli fikriyle nasıl bağlantılı oldu ğunu gösteriyoruz.

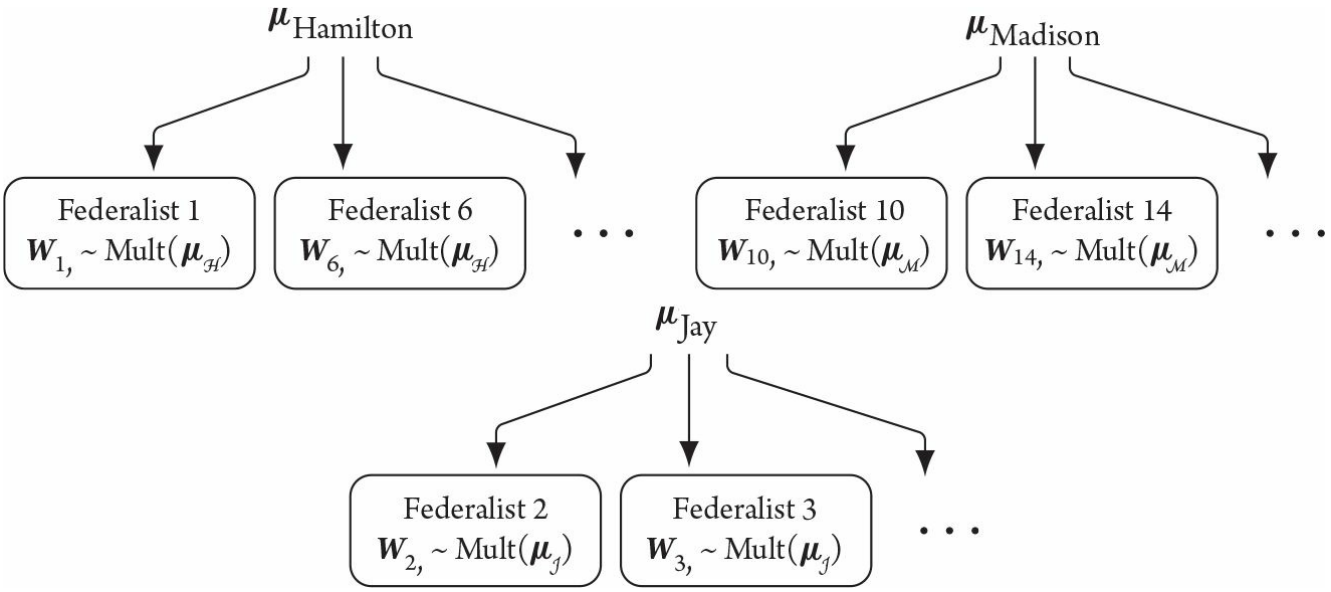
Doclingo https://www.doclingo.ai

6.2 Temel Dil Modelleme

A *dil modeli* , belirli bir parametre setine göre belirli bir token di zisinin gözlemlenme olasılığını atayan bir modeldir. Dil modelleri, daha sonraki bölümlerde ele alacağımız daha karmaşık modellerin temel yapı taşlarıdır. Şu anda, sıralı bir token setinin olasılığını hes apladığımız durumları ele alacağız ve sıralı diziler konusuna daha s onraki bölümlerde döneceğiz.

Tablo 6.1. Her yazar için Federalist Papers'tan ü ç kelimelik sözlüğümüzden kelime sayıları ve ta rtışmalı makalelerden biri olan Federalist #49.

	tarafından	adam	üzerine
Hamilton	859	102	374
Jay	82	0	1
Madison	474	17	7
İhtilaflı Makale	15	2	0



Şekil 6.3. Çok terimli dil modeli için veri üretim sürecini gösteren akış şeması.

Bunun nasıl faydalı olacağını düşünmek için, Mosteller ve Wallace'ın (1963) ihtilaflı Federalist Belg elerin yazarlarını tanımlama çabalarını hatırlayalım. Basitlik açısından, yalnızca üç kelimeden oluşan bi r sözlüğe sahip oldukça basitleştirilmiş bir durumu ele alalım: by, man ve upon. Her yazarın bilinen be lgeleri için kelime sayıları ile ihtilaflı olan Federalist 49 (“Hükümetin Herhangi Bir Departmanının İnsan lara Bir Konvansiyon Yoluyla Başvurmasıyla İhlallerine Karşı Koruma Yöntemi”) verilmektedir.

Doclingo https://www.doclingo.ai

Bu, bizim ham verilerimizdir.

Çok terimli dil modeli, tartışmalı makalenin her yazar tarafından yazılmış olma olasılığını değerlendirmek için bir yol sunar. Her yazarın kendi çok terimli dağılımını kullandığını varsayacağız ve Şekil 6.3'de gösterilen belgeler için bir üretim süreci öne süreceğiz.

Aynı μ parametresine sahip çok terimlilerin toplamı da çok terimlidir, bu nedenle Şekil 6.3 'deki model resmi olarak aşağıdaki gibi yazılabilir (her yazarı, soyadının son harfi ile stilize edilmiş bir alt simge ile gösterir):

$$W_{\mathcal{H}} \sim \text{Çok Terimli}(1335, \mu_{\mathcal{H}}) \quad W_{?} \sim \text{Çok Terimli}(83, \mu_{?}) \quad W_{\mathcal{M}} \sim \text{Çok Terimli}(498, \mu_{\mathcal{M}})$$

Verileri (atfedilen belge koleksiyonu) göz önünde bulundurarak her yazar için yazar spesifik μ değeri tahmin edebiliriz. Bu, tartışmalı makalenin üçünden hangisinden kaynaklandığını hesaplamamıza olanak tanıyacaktır.

Formül 6.1.6'yı uygulayarak, her yazar için μ vektörünü tahmin edebiliriz.

$$\mu_{\mathcal{H}} = (859 + 85 + 9 + 102) / (3741 + 1028 + 59 + 102) / (3741 + 1028 + 59 + 102) = (.64, .08, .28)$$
$$\mu_{\mathcal{J}} = (82 + 8 + 0 + 1) / (821 + 82 + 0 + 1) / (821 + 82 + 0 + 1) = (.99, 0, .01)$$
$$\mu_{\mathcal{M}} = (474 + 47 + 17 + 7) / (1747 + 474 + 17 + 7) / (7474 + 474 + 17 + 7) = (.95, .035, .015)$$

Şimdi, tartışmalı denemenin Hamilton veya diğer yazarların herhangi birinden geldiği olasılığını değerlendirmek istiyorsak, $\mu_{\mathcal{H}}$ 'yi μ ve WTartışmalı için W i olarak formüle edebiliriz.

$$p(W_{\text{Tartışmalı}} \mid \mu_{\mathcal{H}}) = \frac{17!}{(15!)(2!)(0!)}(.64)^{15}(.08)^{2}(.28)^{0} = 0.001$$
$$p(W_{\text{Tartışmalı}} \mid \mu_{?}) = \frac{17!}{(15!)(2!)(0!)}(.99)^{15}(0)^{2}(.01)^{0} = 0$$
$$p(W_{\text{Tartışmalı}} \mid \mu_{\mathcal{M}}) = \frac{17!}{(15!)(2!)(0!)}(.95)^{15}(.035)^{2}(.015)^{0} = 0.077$$

Bu hesaplama, tartışmalı denemenin yazarı olarak Madison'ı açıkça desteklemektedir - Mosteller ve Wallace'ın (1963) ulaştığı aynı sonuca. Bu modelin Jay'e sıfır olasılık atadığını unutmayın - bu, biraz fazla kendine güvenen bir sonuç ve buna birazdan geri döneceğiz.

Burada, her yazar için ayrı bir veri üretim süreci olan bir problem kurduk. Bunları, hangi yazarın belge i yazdığını belirten uzunluğu 3 olan bir one-hot kodlaması olan bir gösterge π i tanıtarak tek bir model altında formüle edebiliriz.

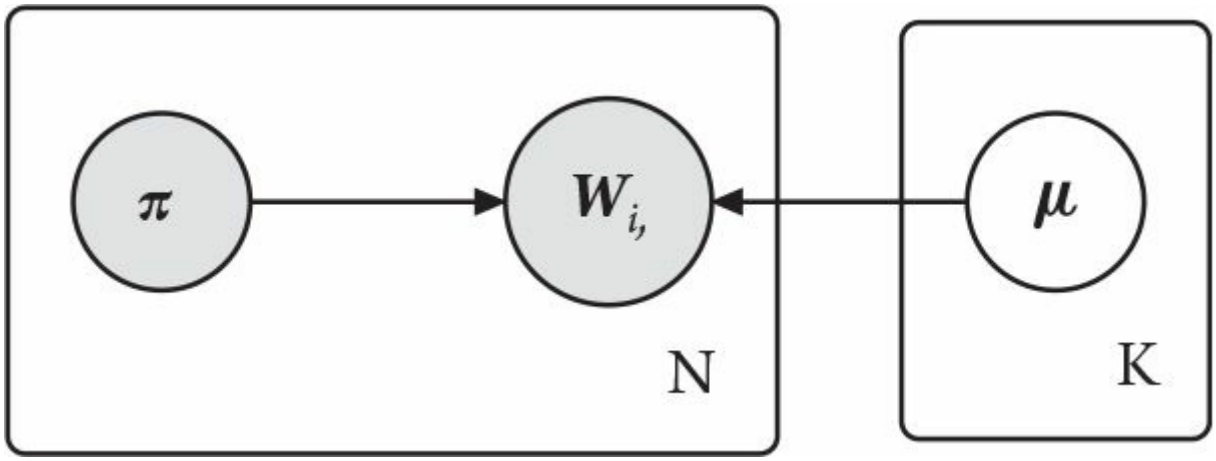
Doclingo https://www.doclingo.ai

Örneğin, Federalist Paper 1, Hamilton tarafından yazıldığı için π 1 = (1 , 0 , 0) olacaktır. Daha sonra tüm μ $\mathscr{H}$, μ᾽ ve μ $\mathscr{M}$ 'yi yan ya na bir matris μ'ye yerleştirebiliriz. Bu, modeli yazmamıza olanak ta nır.

$$W_i, \sim \text{Multinomial}(M_i, \mu\pi_i), \quad (6.2.1)$$

π i'nin μ sütununu seçme etkisi olduğu ve dolayısıylaμ $\mathscr{H}$, μ᾽ ve μ $\mathscr{M}$ içinden hangisin i multinomiyal için kullanacağımızı belirlediği bir durumdur. Bu, Şekil 6.4'teki plaka nota syonu kullanılarak gösterilebilir.

Bu, bileşenin bilindiği bir karışım modelidir (gölgeleme ile göste rildiği gibi). O zaman doğrudan π üzerinde çıkarım yapabiliriz. Tartı şmalı, ama bu yaklaşıma Bölüm 19 denetimli sınıflandırma hakkında konuştuğumuzda geri döneceğiz. Gözlemlenmeyen π ile benzer bir yapı, Bölüm 12'de ele aldığımız bir kümeleme modeli oluşturacaktır.



Şekil 6.4. Gözlemlenen etiketlerle multinomiyal karışım modeli için bir plaka diyagramı.

Doclingo https://www.doclingo.ai

6.3 Düzenleme ve Düzleştirme

Modelin tartışmalı metnin John Jay tarafından yazıldığına sıfır olasılık atama sı yaptığına dikkat edin. Bunun nedeni, John Jay'e atfedilen beş makalede, bir k ez bile "adam" kelimesini kullanmamış olmasıdır; dolayısıyla, μ J , Adam için ma ksimum olasılık tahmini 0'dır. "Adam" kelimesi tartışmalı makalemizde geçtiğin de, Jay'e ait tartışmalı makalenin sıfır olasılık olayı olduğunu sonucuna varıyoru z. Bu, aşırı güçlü bir sonuç gibi görünüyor. Gerçekte, Jay'in daha az belgesi var ve bu nedenle o kelimeyi hiç kullanmamış olmasının sadece şansa bağlı olduğ u daha olası görünüyor, asla o kelimeyi kullanmayacağı değil.

Dilin doğası, nadir kelimelerin oldukça yaygın olduğu anlamına gelir v e bu nedenle bu özel sorun da öyledir. Değerli bir yaklaşım, tahmin edici mize düzenleme eklemektir; bu, tahmini belirli bir değere doğru çeker. D üzenleme, tahminleri belirli bir değere doğru çekmek için modele eklene n veri dışı bir bilgi veya kısıtlamadır. Bu, aşırı uyum sağlamayı önlemeye y ardımcı olabilir; örneğin, Jay'in "adam" kelimesini yazma olasılığının sıfır olduğu sonucuna varmak gibi.

Bu probleme en yaygın yaklaşımlardan biri, her yazar için her kelim e türünün sayısına basitçe sabit bir miktar, *α*, eklemektir. Bu, esasen s ahte veriler ekler ve tahminleri sıfırdan uzaklaştırır. Örnek olarak, α = 1 ayarladığımızı hayal edebiliriz, bu da Jay'in kelime sayılarını (83, 1, 2) hareket ettirir. Bu, "man" kelimesinin olasılığını 0'dan 0.02'ye değiştiri r ve Jay'in tartışmalı metindeki kelimeleri üretme olasılığını değiştirir.

0 to.008—olası değil, ama artık imkansız değil. Jay'in üzerindeki etkisi tahminler Hamilton veya Madison için olandan daha büyüktür çünkü gerçe k veri miktarı arttıkça, sahte veri miktarı sabit kalır ve bu nedenle tahmin ü zerindeki etkisi giderek daha küçük hale gelir. Bu düzenleme stratejisine *L aplace düzeltmesi* denir.

Laplace düzeltmesi, olasılıksal modelin dışında var olan bir ek düzeltme dir, ancak aynı zamanda bir ön dağılım aracılığıyla modeli kendisinde de d üzenleme ekleyebiliriz. Bu, esasen parametreye (örneğin, μ) kendi veri üret im sürecini verir. Sonuç, bir Bayes hiyerarşik modelidir ve düzenlemeyi Lap lace düzeltmesi ile aynı şekilde teşvik eder. Ancak, parametre μ'nın simplex üzerinde yer alması gerektiğini unutmayın, bu nedenle bir ön eklemek için , her çekimin simplex üzerinde bir noktaya sonuçlandığı bir dağılıma ihtiya cımız var. Bu tür en yaygın dağılım Dirichlet dağılımıdır, bunu bir sonraki b ölümde tartışacağız.

Doclingo https://www.doclingo.ai

6.4 Dirichlet Dağılımı

Dirichlet dağılımı, simplex üzerindeki bir parametre için bir veri ür etim sürecini belirtmek için bize araçlar sağlar, örneğin μ. Bu, gerçe k verilere biraz sahte veri eklemekten daha karmaşık bir süreç gibi g örünebilir, ancak daha karmaşık modeller inşa etmek için çok daha genel bir altyapı sağlayacaktır. Tam veri üretim sürecini şu şekilde ya zabiliriz,

(1) her yazar için kelime olasılıklarını örnekle μ k ~ Dirichlet (α) içi n k ∈ 1, 2, 3 (6.4.1) (2) yazar spesifik kelime oranlarını matrisin sü tunlarında yığmak μ = [μ 1 , μ 2 , μ 3] (6.4.2) (3) yazarın kelim e olasılıklarını kullanarak metni örneklemek W i , | μ , π i ~ Multinomial (M i , μ π i) (6.4.3) Parametre vektörü α, Dirichlet dağıl ımını tanımlar ve her yazar için μ vektörü ile aynı boyuttadır (bu ne denle, üç kelimeden oluşan sözlük örneğimizde, uzunluğu 3'tür). α' nın her değeri, α j pozitif bir sayıdır ancak başka bir kısıtlaması yokt ur. Aşağıda göstereceğimiz gibi, α, Laplace düzeltme düzenlemesi altında eklenen sahte veri miktarına karşılık gelir.

ÖZELLİKLER

Dirichlet dağılımının özellikleri, tipik μ çekimlerinin α'ya bağlı olarak nasıl görüneceği hakkında bize bir fikir verir. Özellikleri α cinsinden yazabiliriz ve k olaylık olması açısından α 0 terimini tanımlayabiliriz; bu, α'nın elemanlarının toplamına eşittir: α 0 = Σ j = 1 J α j.

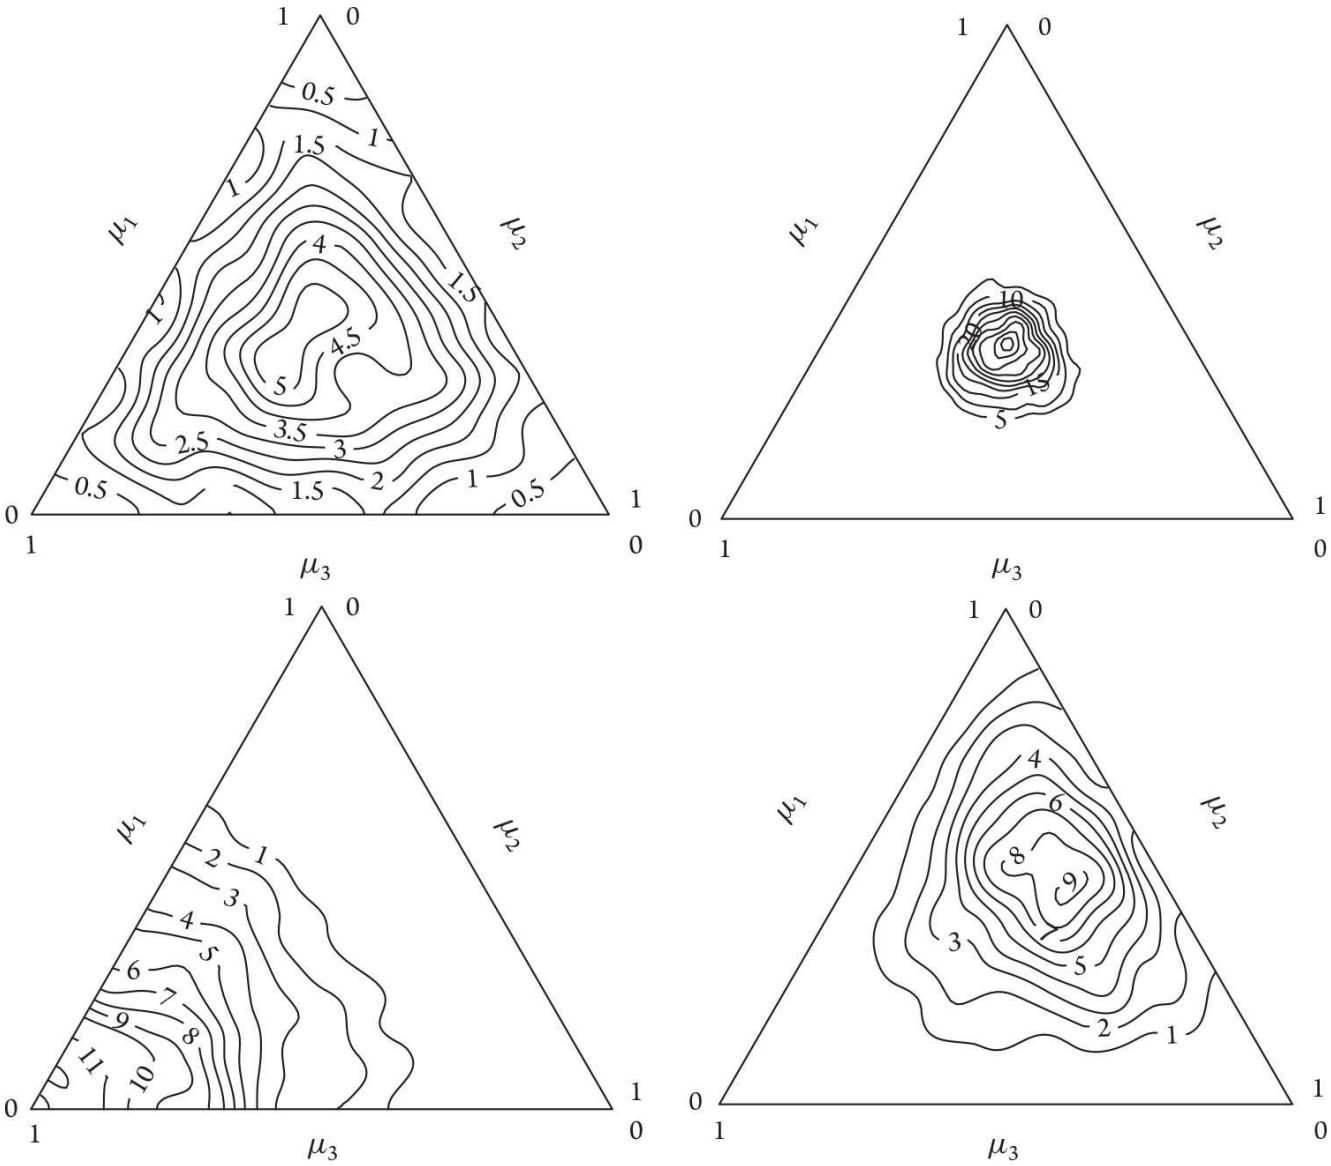
p (μ | α) = Γ (α 0) ∏ j = 1 J Γ (α j) ∏ j = 1 J μ j α j − 1 (6.4.4) E [μ j] = α j α 0 (6.4.5) Var (μ j) = α j (α 0 − α j) α 0 2 (α 0 + 1) (6.4.6) Cov (μ j , μ j ′) = − α j ′ α j α 0 3 + α 0 (6.4.7) Mod (μ j) = α j − 1 α 0 − J , (6.4.8) burada Γ gamma fonksiyonudur. Kaba bir şekilde, α değerl erinin göreceli büyüklüğü, μ oranlarının tipik boyutunu kontrol ede r ve α 0'ın büyüklüğü, μ'nın varyansını kontrol eder. Farklı α değerl erine sahip Dirichlet dağılımlarının yoğunlukları Şekil 6.5'te gösteril miştir.

Dirichlet dağılımı, bu kitap boyunca ele alacağımız daha karmaşı k olasılık modellerinin temel yapı taşlarından biridir. Bayesian çıkar ımda, posterior p (μ k | α , W i ,) ile karakterize ederiz. Dirichlet da ğılımı, çoknom dağılımı için 'konjugat öncel' dir; bu, koşullu posteri or dağılımının aynı olacağı anlamına gelir.

Doclingo https://www.doclingo.ai

önceki gibi form. Bizim amacımız için, bu, Bayes hesaplamasınınkarşılaştırmalı ol arak basit olduğu (bir nonconjugate prior'a göre) ve α 'nınμ değerlerini tahmin e derken sahte veri olarak bir yorumu olduğu anlamına gelir.

Doclingo https://www.doclingo.ai



Şekil 6.5. Dört farklı *α* değeri ile bir Dirichlet dağılımından çekimlerin konturları. Sol üst: α =(2,2,2), Sağ üst: α =(20,20,20), Sol alt: α =(1.2,1.2,4), Sağ alt: α =(4,3,2).

α 0 büyüdükçe değerlerin daha yoğun hale geldiğini ve belirli bir α j değerinin diğerleri nden daha büyük olmasının çekimleri simplex'in o köşesine ittiğini unutmayın.

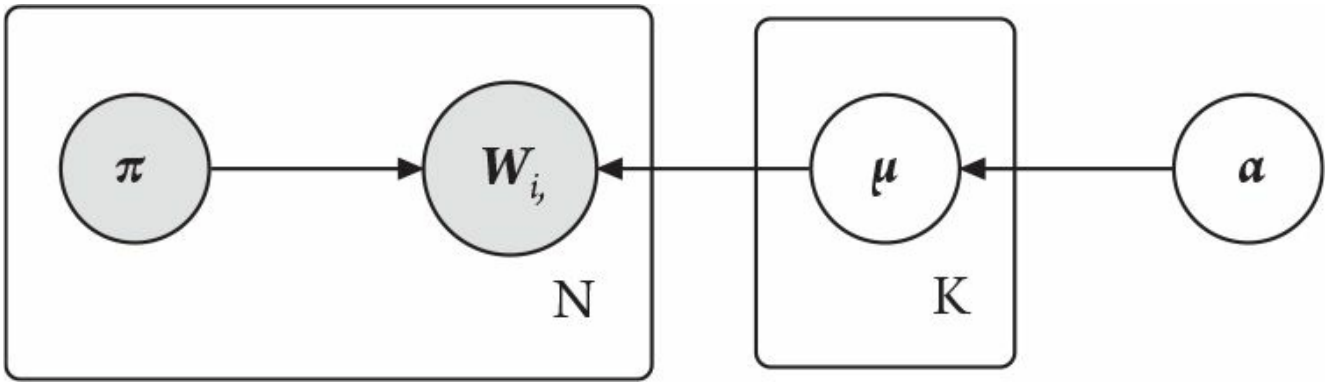
Federalist Papers'tan örneğimize dönersek, μ $\mathscr{H}$, μ’ ve μ $\mathscr{M}$ değerler ini dil modeli altında tahmin ettiğimizi hayal edin.

$$\mu k \sim \text{Dirichlet}(\alpha = (1, 1, 1)) \; W i, \mid \mu, \pi i \sim \text{Multinomial}(M i, \mu \pi i),$$

bu, Şekil 6.6'da plaka notasyonu ile gösterilmektedir. Bu, aşağıdaki formu alır:

$$\mu k \mid \alpha, W i, \sim \text{Dirichlet}(W i, + \alpha) \; E[\mu k \mid \alpha, W i,] = W i, + \alpha \; \Sigma j = 1 \; J \; W i, j + \alpha j.$$

Doclingo https://www.doclingo.ai



Şekil 6.6. Gözlemlenen etiketler ve dil modeli için bir öncelik ile çok terimli karışım mode li.

Tahminlerimiz (posterior ortalamaya dayalı) aşağıdaki formu alır:

$$\mu_{\mathscr{H}} = 8\,5\,9 + 1\,8\,5\,9 + 1\,0\,2 + 3\,7\,4 + (1+1+1), 1\,0\,2 + 1\,8\,5\,9 + 1\,0\,2 + 3\,7\,4 + (1+1+1), 3\,7\,4 + 1\,8\,5\,9 + 1\,0\,2 + 3\,7\,4 + (1+1+1) = (.64, .08, .28)$$

$$\mu\hat{}_{\mathcal{J}} = 8\,2 + 1\,8\,2 + 0 + 1 + (1+1+1), 0 + 1\,8\,2 + 0 + 1 + (1+1+1), 1 + 1\,8\,2 + 0 + 1 + (1+1+1) = (.97, .01, .02)$$

$$\mu\hat{}_{\mathcal{M}} = 4\,7\,4 + 1\,4\,7\,4 + 1\,7 + 7 + (1+1+1), 1\,7 + 1\,4\,7\,4 + 1\,7 + 7 + (1+1+1), 7 + 1\,4\,7\,4 + 1\,7 + 7 + (1+1+1) = (.95, .035, .015).$$

Bu, çok terimli model altındaki önceki tahminimize benziyor, bir kelime türünün her birinin ek bir sayısını gözlemlemişiz gibi. Bu ayarlama $\mu_{\mathscr{H}}$ or $\mu_{\mathscr{M}}$ değerlerini değiştirmese de, μ’ tahmininin tam olarak 0 olmasını engelliyor. Genel olarak, bu tahminlerimizi μ toward α / α 0'a doğru çeker, ancak gözlemlenen gerçek veri miktarını artırdıkça, Madison ve Hamilton ile yaptığımız gibi, bu sahte verinin tahminimiz üzerindeki efkânı önemsiz hale gelir. Nihai tahminimiz $p(\text{W Disputed} \mid \mu_{\mathscr{H}}) = 0.001$, $p(\text{W Disputed} \mid \mu') = .008$, ve $p(\text{W Disputed} \mid \mu_{\mathscr{M}}) = 0.077$. Model artık John Jay'e yazarlık için pozitif bir olasılık atasa da,çatı şmalı makalenin yazarlığını Madison'a atama sonucumuz değişme z.

Yukarıdaki örnekte, α değerini basitçe seçtik. Ayrıca, α'ya bir olasılık mo deli vererek modeli daha da geliştirebiliriz. Gizli değişkenlerin katmanlarını üst üste koyarak hiyerarşik modeller oluşturabiliriz. Bumodeller birkaç ön emli avantaj sunar: belgeler arasında bilgi ödünç almamıza ve tahminleri b elirli bir noktaya doğru küçültmemize olanak tanır; yazar veya zaman gibi b ilinen bir korpus yapısını içerecek şekilde modelimizi genişletmek için kulla nabiliriz ve daha karmaşık modeller oluşturmak için kullanabiliriz.keşif ve ö lçüm için, daha sonraki bölümlerde tartışacağız.

Doclingo https://www.doclingo.ai

6.5 Sonuç

Bu bölümde, çok terimli dağılıma dayanan bir kelime torbası modeli için ola sılıksal temelleri ortaya koyduk. Ayrıca, çok terimli dağılım için konjugat önceli ği kullanarak basit bir hiyerarşik modelin nasıl inşa edileceğini gösterdik - Diric hlet dağılımı. Bu modeller, bir kez belirlendiğinde, araştırmacıların hesaplama yapmalarını ve teorik özellikleri belirlemelerini sağlayan istatistik ve bilgisayar bilimlerinde zengin bir sonuç yelpazesinden yararlanmalarına olanak tanıdığı i çin caziptir (Bishop, 2006; Murphy, 2021; Gelman ve diğ., 2013).

Bir sonraki bölümde, kelime torbası temsilini temel alan modeller inş a etmek için başka bir yaklaşımı özetliyoruz - vektör uzayı modeli. Bu te meller çok terimli modelden oldukça farklı görünse de, olasılıksal ve alg oritmik modellerin genellikle ortak bir teknik setini tanımlamak için iki o ldukça farklı dil kullandığını vurguluyoruz.

Doclingo https://www.doclingo.ai

BÖLÜM 7

Vektör Uzayı Modeli ve Benzerlik Ölçüleri

Önceki bölüm, doküman-özellik matrisindeki her bir satırı çok terimli dağılımdan rastgele bir çekim olarak düşünmeye dayanan bir kelime torbası temsilini düşünmenin bir yolunu sundu. Bu bölümde, doküman-özellik matrisinin her bir satırını yüksek boyutlu bir uzayda bir vektör olarak gören vektör uzayı modelini tanımlıyoruz. Çok terimli yorumun, olasılık teorisi ve istatistikten zengin bir sonuç seti sağlaması gibi, vektör uzayı modeli de lineer cebirden zengin bir sonuç setinden yararlanmamıza olanak tanır ve kelime sayılarının ağırlıklı temsillerine daha doğrudan genelleştirilecektir. Vektör uzayı modeli, kitap boyunca ele alacağımız birçok algoritmik yaklaşımın temelini sağlar.

Vektör uzay modeli, başlangıçta bilgi erişimi bağlamında geliştirilmiştir (vektör uzay modellerinin anlamı üzerine mükemmel bir incelem e için Turney ve Pantel, 2010'a bakın). Bilgi erişimindeki temel bir görev, bir sorgu almak ve o sorguyla ilgili tüm belgeleri döndürmektir; diğer bir deyişle, sorguya "ilgili" veya "yakın" olan belgeleri döndürmektir. Vektör uzay modelinde, yakınlık, vektörlerin benzerliği ile belirlenir. Toplumsal bilimlerde bilgi erişim sistemlerini sıkça uygulamıyor olsak da, belge setleri arasındaki yakınlığın değerlendirilmesi, bu kitapta yer alan hemen hemen tüm yöntemler için merkezi bir öneme sahiptir. Örneğin, Discovery'de ele aldığımız yöntemler, belgeleri öyle bir şekilde gruplar ki, küme içindeki belgeler mümkün olduğunca yakın olur. Ölçümde, etiketlenmemiş belgeler, en yakın oldukları etiketli belgelere dayanarak etiketlenir. Ancak iki belgenin yakın olması ne anlama geliyor, bunun açık bir yanıtı yoktur. Bu yöntemler bilgi erişimi bağlamında geliştirildiğinden, genellikle ortak bir konu hakkında olan belgeleri döndüren bir yakınlık tanımını vurgularlar. Bu, belirli bir araştırma sorusuyla en ilgili benzerlik tanımıyla tutarlı olup olmayabilir.

Belgeleri bir uzaydaki vektörler olarak düşünmek, lineer cebirden elde edilen benzerlik ve mesafe ölçümlerini kullanmamıza olanak tanır. Bir sonraki bölümde, bazı benzerlik metrikleri ile mesafeleri tartışmaya başlayacağız.

Doclingo https://www.doclingo.ai

Kelime vektör alanını oluştururken kelimeleri ağırlıklandırmanın ya
ygın bir yaklaşımını tartışacağız.

Doclingo https://www.doclingo.ai

7.1 Benzerlik Metrikleri

Metin analizindeki merkezi bir zorluk, belge çiftlerini karşılaştırmak ve birbir lerine ne kadar “yakın” olduklarını değerlendirmektir. Yakınlığın ne anlama gel mesi gerektiği büyük ölçüde bağlama bağlıdır. Aynı film için olumlu ve olumsu z bir inceleme, farklı filmler için iki olumlu incelemeden daha mı yakındır? Bu, i ncelemenin duygusuna mı yoksa konuya mı daha çok önem verdiğinize bağlıdı r. Agnostik görüşümüzle tutarlı olarak, genel olarak benzerliğin tek bir doğru k avramı yoktur, ancak bireysel görevleri ele almak için daha az veya daha fazla etkili olan metrikler vardır.

Önceki bölümde, belgelerin yakınlığını dolaylı olarak bir olasılık mo deli temelinde düşündük. Tartışmalı Federalist 49, Madison’a en yakın olanıdır çünkü Madison’a atfedilen belgeler temelinde tahmin edilen parametrelerle bir dil modeli tarafından üretilme olasılığı en yüksektir . Bu bölümde, belge vektörleri üzerinde işlem yapan metrikler açısınd an yakınlığı düşüneceğiz. Bu vektörlerin her biri, her belgede yer alan her bir özelliğin sayısını içerir ve vektörler kendileri, doküman-özellik matrisimizde toplanmıştır.

Benzerlik ölçmek istediğimiz birkaç özellik var. İlk olarak, gözleml enen maksimum benzerlik, bir belgenin kendisiyle karşılaştırıldığınd a gerçekleşmelidir. İkincisi, ortak kelimeleri olmayan iki belge (bu, ik i vektörün dik olduğunu ima eder) minimum benzerliğe sahip olmalı dır. Üçüncüsü, benzerlik, aynı kelimelerin daha fazla kullanılmasıyla artmalıdır. Dördüncüsü, simetri uygulamak isteyebiliriz—belge a , b elge b kadar her zaman belge b 'ye yakın olmalıdır.

Belgeler arasındaki benzerliği ölçmenin doğal bir yolu, vektör tem silinden doğan iç çarpımı hesaplamaktır. İki vektör a ve b arasındak i iç çarpım, a 'nın b 'ye projeksiyonu çarpı b'nin uzunluğudur (simetri ktir, dolayısıyla eşit olarak b 'nın a 'ye projeksiyonu çarpı a'nın uzunl uğudur). İç çarpım, vektörlerin eleman bazında çarpımının toplamı il e hesaplanır. Böylece bazı genel vektörler için a = (a 1 , a 2 , …) ve b = (b 1 , b 2 , …) iç çarpım şudur:

$$a \cdot b = a^T b \quad (7.1.1) = a_1 b_1 + a_2 b_2 + \dots \quad (7.1.2)$$

Bu, her bir elemanın yalnızca 0 (belirli bir belgenin bir özelliği içermemesi durum unda) veya 1 (belirli bir belgenin özelliği içermesi durumunda) olduğu özel bir di kotomize doküman-özellik matrisinde basit bir yoruma sahiptir. Bu durumda, iki satır arasındaki iç çarpım, iki belgenin sahip olduğu kelime sayısı olacaktır.

Doclingo https://www.doclingo.ai

belgelerin ortak paydası - benzerlik için makul bir ilk kavram.

Genel terim sayıları ile örnek vermek için, Tablo 6.1'deki Federalis t Papers'tan üç kelimelik kelime dağarcığı vektörlerimize geri dönüy oruz. Hamilton için girişin iç çarpımını tartışmalı belge ile hesaplaya biliriz:

$$W_{\text{Hamilton}} , \cdot W_{\text{Disputed}} , = (8 5 9 , 1 0 2 , 3 7 4) \cdot (1 5 , 2 , 0) \quad (7.1.3)$$

$$= 8 5 9 \times 1 5 + 1 0 2 \times 2 + 3 7 4 \times 0 \quad (7.1.4)$$

$$= 1 3 0 8 9 \quad (7.1.5)$$

Bu terimlerin hepsi negatif olmayan sayılardan oluştuğundan (hücrelerin kelime sayıl arı olduğunu hatırlayın), iki vektördeki daha fazla sıfırdan farklı terim örtüştüğünde, e lde edilen benzerlik ölçüsü daha büyük olacaktır.

İç çarpım ile ilgili potansiyel bir sorun, sonucunun iki vektörün büyüklüğ üne bağlı olmasıdır. Örneğin, benzerlik ölçümümüzü tartışmalı makalenin Hamilton'ın yazısına mı yoksa Madison'ın yazısına mı daha yakın olduğunu değerlendirmek için kullanmaya çalıştığımızı hayal edin. Hamilton'ın vektör ü büyüklük açısından önemli ölçüde daha büyüktür ve iç çarpım bu farka d uyarlıdır.

$$W_{\text{Madison}} , \cdot W_{\text{Disputed}} , = (4 7 4 , 1 7 , 7) \cdot (1 5 , 2 , 0) = 7 1 4 4$$

Tartışmalı makale ile Madison'ın eseri arasındaki benzerlik, tartışmalı ma kale ile Hamilton'ın eseri arasındakinden daha düşük görünmektedir, anc ak bu, Hamilton'a atfettiğimiz daha fazla makale sayısının bir sonucudur. Bu sorunu ele almanın bir yolu, iç çarpımı almadan önce her vektörün bü yüklüğüne göre normalleştirmektir.

İç ürün operatörünü, vektörün (a ile gösterilir) büyüklüğünü hesaplam ak için kullanabiliriz; bu, sadece kendisiyle olan iç ürünün kareköküdür. Ö rneğin, Hamilton'un vektörünün büyüklüğü şudur,

$$W_{\text{Hamilton}} , = W_{\text{Hamilton}} , \cdot W_{\text{Hamilton}} , = \sqrt{8 5 9 2 + 1 0 2 2 + 3 7 4 2} = 9 4 2 . 4 2 .$$

Bu, Madison'un vektörünün büyüklüğü olan 474.36'dan önemli ölçüde daha büyüktür.

İki büyüklük normalleştirilmiş vektörün iç ürünü, iki vektör arasındaki açının (θ ile gösterilir) kosinüsüdür. Bu, vektörler arasındaki kosinüs benz erlik metriğidir.

$$\text{kosinüs benzerliği} (a , b) = \cos \theta \quad (7.1.6)$$

$$= \frac{a}{a} \cdot \frac{b}{b} \quad (7.1.7)$$

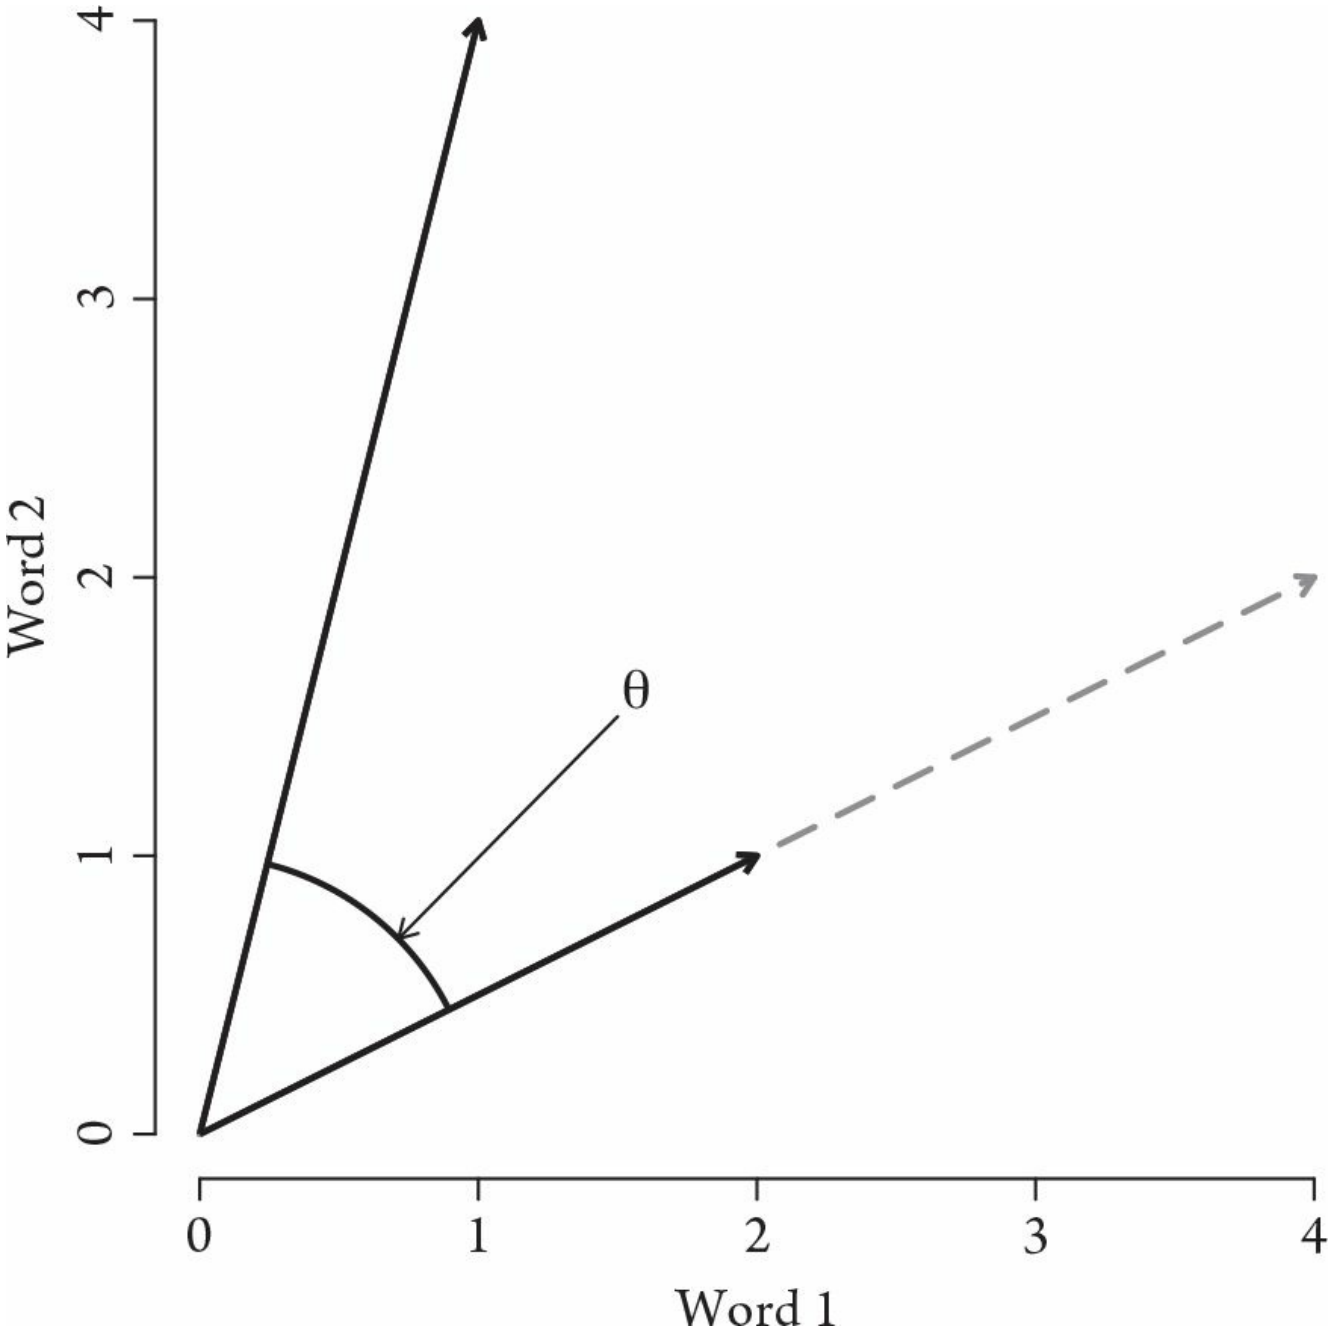
$$= \frac{a}{\sqrt{\Sigma_i a_i^2}} \cdot \frac{b}{\sqrt{\Sigma_i b_i^2}} \quad (7.1.8)$$

$$= \frac{\Sigma_i a_i b_i}{\sqrt{\Sigma_i a_i^2} \sqrt{\Sigma_i b_i^2}} \quad (7.1.9)$$

Doclingo https://www.doclingo.ai

Buradaki temel sezgi, vektörler arasındaki açının vektörlerin büyük lüğüne bağlı olmamasıdır; yalnızca yönleri önemlidir. Bunun görsel bir sezgisi için, yönü korurken vektörlerden birini uzattığımızda, ve ktörler arasındaki açının sabit kaldığını gösteren Şekil 7.1'ye bakın.

Açının kosinüsü, benzerliğin güzel bir ölçüsünü sağlar çünkü ölçü yü 0 ile 1 arasında normalize eder (resmi olarak -1 ile 1 arasındadır, ancak kelime sayılarımız gibi negatif olmayan özelliklerle, değerler 0' dan daha küçük olamaz), 0 en farklı ve 1 en benzer olanıdır.



Şekil 7.1. İki kelimelik bir alanda üç belge. Belge 1 (koordinatlarda 1,4) belge 2 ile (koordinat 1 ve 2 kelimelerinin oranı vardır ancak farklı büyüklüklere sahiptir. Açısı θ

Doclingo https://www.doclingo.ai

ilk belge ile ikinci/üçüncü belge arasında sabittir. Böylece,belgeler 1 ve 2 ile belgeler 2ve 3 arasındaki iç çarpım farklıdır, ancak kosinüs benzerliği aynıdır.

Bu tekniği Federalist Belgeleri'ne uygularız ve tartışmalı belgenin hangiyazara dah a yakın olduğunu yeniden değerlendiririz.

kosinüs benzerliği (W Hamilton , , W Tartışmalı ,) = W Hamilton , · W Tartışmalı , W Hamilton , W Tartışmalı , = (8 5 9 , 1 0 2 , 3 7 4) · (1 5 , 2 , 0) (8 5 9 , 1 0 2 , 3 7 4) (1 5 , 2 , 0) = . 9 1 8 kosinüs benzerliği (W Madison , , W Tartışmalı ,) = W Madison , · W Tartışmalı , W Madison , W Tartışmalı , = (4 7 4 , 1 7 , 7) · (1 5 , 2 , 0) (4 7 4 , 1 7 , 7) (1 5 , 2 , 0) = . 9 9 5

Sonuçlar artık tartışmalı belgenin Madison'un önceki yazılarıyla çok daha benz er olduğunu göstermektedir. Vektörlerin büyüklüğünü normalize ettiğimiz için artık Hamilton'u önceliklendirmiyoruz.

Doclingo https://www.doclingo.ai

7.2 Mesafe Ölçümleri

Belgeleri, uzaydaki noktalar olarak ele alarak ve aralarındaki mesafeyi hes aplayarak karşılaştırabiliriz. Mesafe ölçümleri, Discovery'de ele alacağımız kü meleme algoritmalarında merkezi bir rol oynayacaktır.

Eğer bir mesafe ölçümüne aşina iseniz, muhtemelen Öklid mesafesidir, bu da şu şekilde tanımlanabilir:

$$W i , - W i ' , = \sum j = 1 J (W i j - W i ' j) 2 . (7.2.1)$$

Öklid mesafesi, belge büyüklüğüne çok duyarlı olması nedeniyle iç çarpımın bazı aynı sorunlarını paylaşır. Hemen belirgin olmasa da, noktalar normalize edildiğinde kosinüs benzerliği Öklid mesafesi il e yakından ilişkilidir. İki normalize edilmiş vektörü

$$W i , - W i ' , = W i , + W i ' , - 2 W i , \cdot W i ' , (7.2.2) = 1 + 1 - 2 W i , \cdot W i ' , (7.2.3) = 2 1 - \text{cosine-similarity } W i , , W i ' , , (7.2.4)$$

şeklinde ilişkilendirebiliriz; ikinci satır, vektörleri büyüklüğü 1 olacak şekilde no rmalize ettiğimiz için geçerlidir. Diğer bir deyişle, kosinüs benzerliği ve normali ze edilmiş bir Öklid mesafesi yakından ilişkilidir. Bazen metin analizi için araştır macılar “kosinüs mesafesi” kullanır, bu da basitçe 1 eksi kosinüs benzerliğidir (böylece daha büyük sayılar daha az benzer belgeleri gösterir).

Öklid mesafesinin ötesinde, olası mesafe ölçümleri için geniş bir yelpa ze vardır. Bir örnek, Minkowski ailesi olarak adlandırılır. Minkowski mesaf e ölçümleri, şu formda olanlardır:

$$d p (W i , , W i ' ,) = \sum j = 1 J W i j - W i ' j p 1 / p (7.2.5)$$

verilen bir *p* değeri için. Minkowski mesafesi p = 2 Euclidean mesafesidir. Daha genel olarak, *p* büyüdükçe, en büyük farklara sahip kelime sayımları mesafeye daha fazla katkıda bulunacaktır. Aşırı durum, p = ∞ olduğunda o rtaya çıkar; bu, Chebyshev metriği olarak bilinir ve mesafe olarak en büyük mutlak farkı döndürür, diğer tüm özellikleri göz ardı eder.

Genellikle ortaya çıkan bir diğer özel durum, p = 1 olduğunda meydana gelen Manhattan mesafesidir. Manhattan mesafesinin arkasındaki fikir, yalnızca dik açı larda seyahat edebildiğinizde uzaydaki iki nokta arasındaki mesafeyi ölçmektir. Euclidean mesafesi, kuş uçuşu mesafesidir; Manhattan mesafesi ise bir taksinin Manhat tan'da gideceği mesafedir (bu nedenle bazen “taksi metriği” olarak da adlandırılır).

Doclingo https://www.doclingo.ai

Bu metrik, bireysel kelimelerin sayımları arasındaki büyük farklara daha dayanıklı olma eğilimindedir.

Mesafe metriklerinin seçimi, dikkate alınması gereken farkın ne tür olduğun a dair bir varsayıma dayanır. Kosinüs mesafesi kullanarak normalizasyon, belg e büyüklüğünü öncelik sırasından çıkarır ve Minkowski mesafesinin farklı versi yonları, vektörün bireysel bileşenlerinin göreceli önemini vurgulamak için kulla nılabilir. Farklı mesafe ölçüleri, iki belgenin benzer olması için ne anlama geldi ğine dair farklı kavramlara karşılık geldiğinden, algoritmik yöntemler bir mesaf e metriğini diğerine değiştirmekle önemli ölçüde değiştirilebilir. Daha sonra bi rçok algoritmik kümeleme yönteminin mesafe metriğinin kullanıcı tarafından belirlenen bir parametre olarak ayarlanmasına izin verdiğini göreceğiz, bu da önemli bir esneklik sağlar.

Doclingo https://www.doclingo.ai

7.3 tf-idf Ağırlıklandırması

Şu ana kadar, vektörlerin bir belgede bireysel kelimelerin sayıları olduğ unu varsayıyorduk; ancak, algoritmik çerçevenin avantajlarından biri, kelim eleri yeniden ağırlıklandırarak mesafe metriklerini daha bilgilendirici hale g etirebilmemizdir. Aslında, kelimeleri tamamen kaldırmak gibi bir aşırı ağırlı klandırma biçimini zaten tartıştık. Bu, önemsiz kelimeleri kaldırmanın, bilgi lendirici içeriklerinin az olduğu düşünüldüğünde ortaya çıktığı bir bağlamd a ilk kez gündeme geldi. Federalist Belgelerinin analizinde, tam tersini yap arak yalnızca önemsiz kelimelere odaklandık ve diğer her şeyi kaldırdık. Bir kelime setini kaldırmak, onlara 0 ağırlık vermekle eşdeğerdir.

Bu ağırlıkların tam olarak 0 mı yoksa başka bir şey mi olduğu önemli değil, amaç ilgi sinyalini artırmaktır.

Hesaplamalı dilbilim literatüründe yaygın bir tema, kelimelerden gelen en büyük sinyallerin, ne çok nadir ne de çok sık olan goldilocks bölgesinde olduğudur. Son derece sık kullanılan kelimeler, dili bir arada tutan yapıştırı cı gibidir ve metnin ne hakkında olduğu konusunda pek az ipucu sunar. Öt e yandan, nadir kelimeler çok fazla yararlı bilgi içerebilir, ancak o kadar na dir görünürler ki metin hakkında genelleme yapmak için faydalı değildirler. Anahtar, ortadaki kelimelerdir.

Bu içgörü, *terim sıklığı ters belge sıklığıağırlığı* or *tf-idf* kısaltmas ıyla korunmuştur. Belge-özellik matrisini hesapladıktan sonra, tf-idf, her terim sayısını, tüm korpus içindeki ters sıklık ölçüsü ile ölçeklend irir. Bu, sık kullanılan kelimelerin ağırlığını azaltma etkisine sahiptir. Cezanın birçok versiyonu olmasına rağmen, en yaygın tf-idf biçimi ş udur:

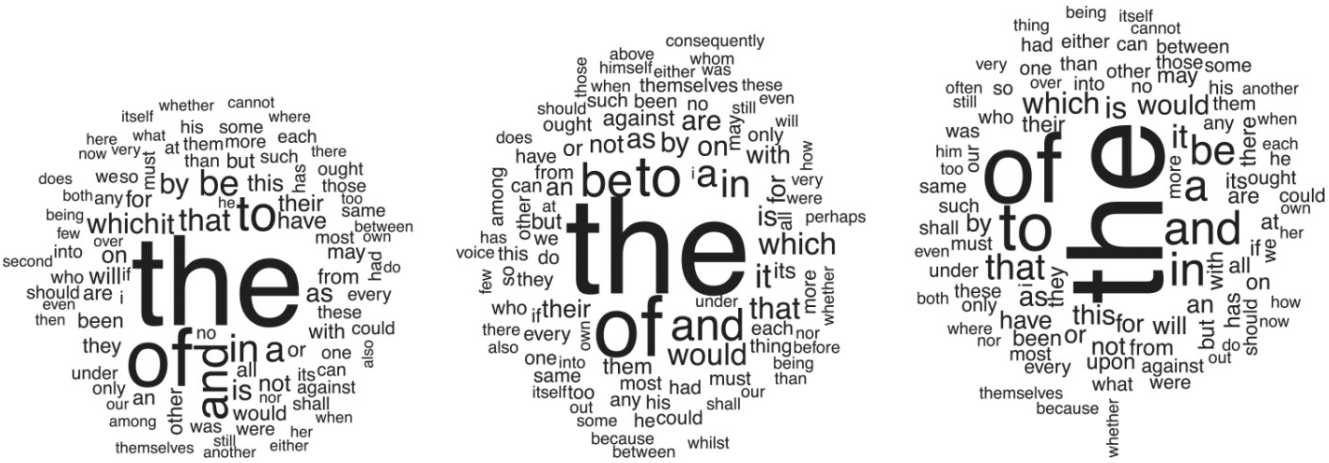
$$W_{ij}^{tf-idf} = \overbrace{\text{word count}}^{W_{ij}} * \log \frac{N}{\underbrace{n_j}_{\text{penalty for frequent words}}},$$

burada *N*, korpus içindeki belge sayısını ve n j, *j* kelimesini içeren bel ge sayısını temsil eder. Temel fikir, belgede çok sık bulunan, ancak tü m korpus içinde nadir olan kelimeleri önceliklendirmektir.

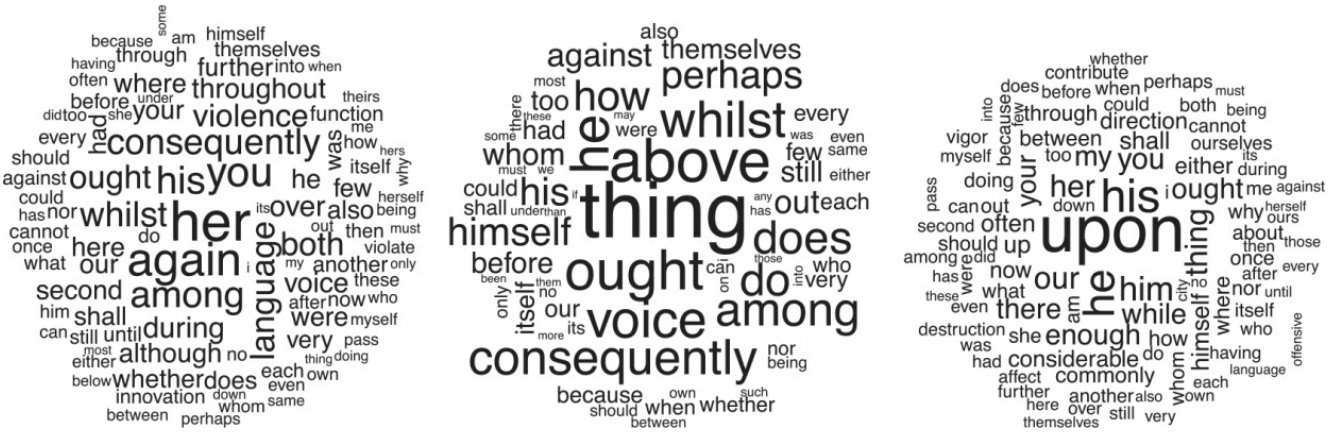
tf-idf sezgisi şaşırtıcı derecede sağlamdır. Federalist Kağıtlar örneğinde, durak k elimeleri üzerinde tf-idf kullanmak, tartışmalı belgelerin yazarlığı hakkında bilgi ort aya çıkarabilir. Bunu göstermek için, Federalist Kağıtlar'ın bir belge-özellik matrisin i oluşturduk, ancak yalnızca durak kelimeleri ve Mosteller ve Wallace (1963) tarafın dan belgeler içinde çok yaygın olarak tanımlanan kelimeleri dahil ettik.[2] Şekil 7.2, k orpus içindeki kelimelerin basit sayımlarının kelime bulutlarını göstermektedir. Sol

Doclingo https://www.doclingo.ai

şekil, Madison tarafından yazıldığı bilinen belgelerden gelen sayıları göstermektedir. Sağdaki şekil, Hamilton tarafından yazıldığı bilinen makalelerin sayımlarını göste rmektedir. Ortadaki şekil, bu kitapta şimdiye kadar ilgi çeken bilinmeyen makale #49'un kelime bulutunu göstermektedir. Gördüğünüz gibi, basit sayımların keli me bulutları, en yaygın önemsiz kelimeler tarafından baskın hale geldiği için yaz arları ayırt eden kelimeleri ortaya çıkarmamaktadır.



Şekil 7.2. Önemsiz kelimeler (stop words) ve yaygın kelimelerin kelime bulutları Federalist Papers. Sol: Madison tarafından yazıldığı bilinen belgeler. Merkez: bilinmeyen Kağıt #49. Sağ: Hamilton tarafından yazıldığı bilinen kağıtlar



Şekil 7.3. Önemsiz kelimelerin (stop words) ve yaygın kelimelerin bulutları Federalist Papers, tf-idf ile ağırlıklandırılmış. Sol: Madison tarafından yazıldığı bilinen ma kaleler. Ortada: bilinmeyen makale # 49 Sağda: Hamilton tarafından yazıldığı bilinen ma kaleler.

Ancak, kelimeleri tf-idf kullanarak ağırlıklandırırsak, her yazarın farklı sesi ortay a çıkmaya başlar. Şekil 7.3 aynı kelimelerin ağırlıklı tf-idf sayımlarının kelime bulutl arını göstermektedir. Solda, Madison tarafından yazılan makalelerin, onun, tekrar ve önemli olarak, sonuç olarak, iken ve gerekmektedir gibi kelimeleri orantısız bir ş ekilde kullandığını görüyoruz. Buna karşılık, Hamilton'ın makaleleri, diğer makalele re kıyasla, üzerinde kelimesini baskın bir şekilde kullanmaktadır, yanı sıra onun ve

Doclingo https://www.doclingo.ai

onu. Tartışmalı makale #49, sonuç olarak, bu şekilde ve gerekmektedir kelimelerinin orantısız kullanı mını göstererek Madison'a en çok atfedilen makale gibi görünmektedir.

Federalist Papers durumunda, tf-idf ağırlığı mesafe metriklerini daha bilgilendirici hale getirir. Doküman-özellik matrisimizin basit sayımlarını k ullanarak, Madison kelime sayıları ile makale #49 arasındaki kosinüs ben zerliği 0.9899 iken, Hamilton kelime sayıları ile makale #49 arasındaki kos inüs benzerliği 0.9848'dir, bu çok küçük bir farktır. Ancak, tf-idf ağırlıklı sa yıları kullanarak, Madison makaleleri ile makale #49 arasındaki kosinüs b enzerliği 0.5545, Hamilton makaleleri ile makale #49 arasındaki kosinüs b enzerliği ise 0.4981'dir.

Ayrıca, tf-idf ağırlığının mesafe/benzerlik hesaplamaları ve mesafe/benzerlik hesapl amalarına dayanan yöntemler için en önemli olduğunu not ediyoruz, lineer regresyon g ibi yöntemler yerine. Bir doküman-özellik matrisini kullanarak bir sonucu tahmin etmek için lineer regresyon, lineer özellik düzeyinde yeniden ölçeklendirmeye karşı değişmez olacağından, tf-idf ağırlıkları önemli olmayacaktır.

Doclingo https://www.doclingo.ai

7.4 Sonuç

Vektör uzayı modeli, belgeleri uzaydaki vektörler olarak kavramsallaştırır ve ardından bunlar arasında karşılaştırmalar yapmak için lineer cebirden eld e edilen sonuçları kullanır. Ana benzerlik ölçümlerinden, mesafe metriklerind en ve ağırlıklandırma sonuçlarından bazılarını kısaca ele aldık. Her durumda, amaç, belgelerle ilgili ilginç olanın sinyalini artırmak ve keşif ve ölçüm için so nraki yöntemlerin daha başarılı olmasını sağlamaktır. Bu fikirler, kelime sıras ını koruyan benzerliği yakalayan dize çekirdekleri gibi yöntemlerle daha da g enişletilebilir - örneğin, siyasi bilimde bir uygulama için Spirling (2012) 'ye ba kın.

Vektör uzay modeli, son bölümde gözden geçirilen çok terimli modelde n oldukça farklı görünse de, bu kitabın tekrarlayan temalarından biri, birço k görünüşte alakasız modelin aslında sıkı bir şekilde bağlantılı olduğudur. Vektör uzay modeli, belgeleri belge vektörleri üzerindeki mesafeleri hesapl ayarak karşılaştırırken, olasılık modelleri belirli bir model altında üretilme o lasılıklarını hesaplar. Bu, belgeleri karşılaştırmak için yöntemler geliştirmek üzere inşa edilecek farklı bir temel gibi görünüyor. Yine de, birçok olasılık modeli bir mesafe kavramını ima eder. Örneğin, bu bölümde ele alınan kos inüs benzerlik ölçüsü, von-Mises Fisher dağılımı ile yakından ilişkilidir (Bane rjee, Merugu, Dhillon ve Ghosh, 2005). Daha genel olarak, birçok yaygın olasılık dağılımları, yaygın mesafe metrikleri ile güçlü bağlantılara sahiptir (Banerjee, Merugu, Dhillon ve Ghosh, 2005). Bu bağlantıları, Bölü m 12'de kümeleme konusunu tartışırken daha fazla keşfedeceğiz.

Şimdiye kadar incelediğimiz modellerin en büyük güçlerinden biri, bire ysel kelimelerin ne anlama geldiği hakkında herhangi bir bilgiye dayanm adıklarıdır; bunun yerine, aynı kelimelerin belgeler arasında ne sıklıkla ku llanıldığına dayanarak çıkarımlar yaparlar. Bu, aynı tekniklerin farklı diller de ve hatta genetik veriler veya tüketici satın alma verileri gibi diğer yüks ek boyutlu sayım verileriyle çalışacağını garanti ettiği için avantajlıdır. An cak dezavantajı, aynı fikri iletmek için farklı kelimeler kullanan iki belge ar asındaki benzerliği kaçırma olasılığının ortaya çıkmasıdır. Bir sonraki bölü mde, dağıtılmış kelime gömme temelli temsilleri ele alacağız. Bu yaklaşı m, kelimelerin anlamları hakkında bilgi yakalamak için büyük dış metin k orpuslarını kullanır; bu bilgi daha sonra kelimeler arasında pürüzsüz bir ş ekilde benzerliği değerlendirmek için kullanılabilir.

Doclingo https://www.doclingo.ai

[1]Büyüklük, vektörün uzunluğudur; ancak, burada belirsizlikten kaçınmak için uzun luk kelimesini kullanmaktan kaçınıyoruzbelge büyüklüğünden bahsederken. Bir belg enin uzunluğu genellikle belgedeki kelime sayısı olarak düşünülür, ancak bu, belgeni n vektörünün uzunluğu ile aynı değildir.

[2]R'deki tm paketindeki durdurma kelimeleri listesini (Feinerer, Hornik ve Meyer, 2008) kullanıyoruz Mosteller ve Wallace (1963) tarafından sağlanan 2.5 ve 2.6 numaralı tablolardaki kelimelere ek olarak. Federalist Belgeleri için verilerProject Gutenberg'den gelmektedir, temizlenmiş ve bu blog yazısında P atrick Perry tarafından sunulmuştur: http://ptrckprry.com/course/ssd/lecture/federalist.html.

Doclingo https://www.doclingo.ai

BÖLÜM 8

Kelime Dağıtılmış Temsilleri

Son birkaç bölümde, her belgenin içerdiği kelimelerin (muhtemele n ağırlıklı) toplamı ile temsil edildiği temsilleri inceledik. Bu modell erde bir kelimenin temsili, bir sıcak kodlama—sözlükteki her benze rsiz kelime için bir boyut içeren bir vektördür ve o kelime için tek bi r 1 ve diğerleri için 0 ile temsil edilir. Bu temsilin bir sonucu olarak, her kelime benzersiz bir şekilde ele alınır ve ortak kelimeleri olmayan iki belge, esasen herhangi birölçekte 0 benzerliğine sahip olacaktır (bu, iki belgenin 0 iç çarpımına sahip olmasından kaynaklanmaktad ır).

Yine de, pratikte birçok kelimenin oldukça benzer anlamlara sahip olduğunu biliyoruz. Bu bilgiyi Bölüm 5 içinde lemmatizasyon veya kök alma ile kodladı k—yazar ve yazarlar gibi iki kelimeyi alıp aynıözelliğe çökertmek—amaçlarımız için, bunlarınözdeş bilgi içerdiği yönünde örtük bir idd iada bulunmak. Bu bölümde ele alınan dağıtılmış temsiller,yazar ve yazar gibi kelimeler arasındaki anlamsal ilişkileri öğrenerek bu fikr i genelleştirir,ortak bir lemma veya kök paylaşmasalar bile.

Bu bölümde, büyük miktarda metnin nasıl kullanılabileceğini ele alacağız dağıtılmış temsiller öğrenmek için—benzerlik ölçüsü oluş turmak içinbir tür sıcak kodlama temsili yerine geçen yoğun vektör ler. Bir kelimeyi (örneğin, kedi) temsil etmek yerine,bir sıcak kodla ma temsili ile kelime kedi için bir vektör kullanmak yerine,

$$\text{cat} = (0 , 0 , 0 , 1 , 0 , 0 , 0 , 0 , \dots , 0) ,$$

verileri kullanarak kedi'yi temsil etmek için uzunluğu *K* olan yoğun bir vektör t ahmin edeceğiz,K < J, örneğin:

$$\text{cat} = (1 . 3 , . 2 , \dots , . 4 5) .$$

Doclingo https://www.doclingo.ai

Bu teknikler, kelimeleri ortak bir düşük boyutluuzaya yerleştirdiğind en (sözlüğün boyutuna göre), *kelime gömme* olarak adlandırılırlar. Bu vektörlerin,kelimeler arasındaki benzerliği kodlama gibi arzu edilen bir özelliği vardır—benzerlik ölçütleri için, Bölüm 7'de tartıştığımız gibi, be nzerlik (kedi, köpek) kedi ve köpeğin yakınlığını yansıtacak vemuhtemel en benzerlik (kedi, gezegen)'den daha büyük olacaktır. Bu temsiller ge nellikle *dağıtım hipotezi* 'ne başvurarak öğrenilir,kelimelerin kullanıldığ ı bağlamın anlamlarına dair bir ipucu sağladığını öne sürer.

Öncelikle, kelime gömme yöntemlerinin neden çekici bir temsil olduğunu sav unacağız ve ardından bunların nasıl tahmin edildiğine geçeceğiz. Daha sonra, kel ime düzeyindeki temsilleri bir belgenin temsiline toplama zorluğunu tartışacağız. Bilgisayar bilimi literatüründe kelime gömme yöntemlerini doğrulama teknikleri ni kısaca ele alacağız ve son olarak, yakın zamanda geliştirilen bağlamsal kelime gömme yöntemleri hakkında kısa bir tartışma yapacağız.

Doclingo https://www.doclingo.ai

8.1 Neden Kelime Gömme Yöntemleri

Şu ana kadar ele aldığımız kelime torbası temsilleri, her kelimeyi ayrı , benzersiz bir anlamı varmış gibi ele alır. Birçok açıdan, bu kelime hakkı nda en fazla bilgiyi korur ve yeterli veri sağlandığında, sonraki görevimi z için esnek bir modelle, her kelime hakkında öğrenmemiz gereken her şeyi öğrenebiliriz. Ancak pratikte, orta boyutlu bir korpus bile, kelime d ağarcıklarında on binlerce veya yüz binlerce benzersiz kelime içerebilir. Bu kelimelerin her biri, kelime dağarcığının boyutuna uyan uzunlu kta tek bir 1 içeren oldukça seyrek bir vektörle temsil edilir. Belgele r üzerinde toplandığında bile, çoğu belge çoğu kelimeyi içermez ve bu nedenle belge-özellik matrisi çok seyrek olacaktır. Pratikte, son raki problem genellikle çok yüksek boyutludur ve özellik matrisinin , satır sayısını (veri noktaları) aşan sütunları (özellikleri) olabilir.

Dağıtılmış temsillerin temel içgörüsü, bir kelimeyi etiketlenmemiş v erilerden öğrenilen düşük boyutlu bir alanda yoğun bir vektör olarak t emsil etmektir. Bu, Amy Catalinac'ın 1. Bölümde tartışılan ve bu kitabı n sonraki bölümünde daha ayrıntılı olarak ele alınan konu modellerin e benzer bir denetimsiz öğrenme durumudur. Her kelimenin sayısal b ir temsilini keşfetmek için büyük bir metin verisi korpusu kullanarak, h angi kelimelerin benzer şekillerde kullanıldığını tahmin edebiliriz (önc eden belirtmek yerine). Umut, büyük genel amaçlı bir dil korpusunda n öğrenilen gömme temsillerinin, sınırlı mevcut etiketli verinin bulund uğu bağlam spesifik bir görevi yerine getirmede yardımcı olacak keli melerin anlamları hakkında bilgi yakalayacağıdır. Farklı bir ortamda y ardımcı olmak için büyük bir metin korpusundan bilgi kullanma fikrin e transfer öğrenme denir ve kelimelerin anlamının farklı korpuslar ara sında nispeten kararlı olduğu fikrine dayanır. Metinlerin dağıtılmış te msilleri en az 1980'lerden beri var olmuştur (Hinton,

1986), ancak yalnızca son zamanlarda, araştırmacıların yüz milyarla rca token ölçeğinde korpuslarda öğrenilmesine olanak tanıyan tah min yaklaşımları geliştirmesiyle popülarite kazanmaya başlamıştır.

Gömülü temsiller, dilin dağılımsal hipotezini kullanarak anlamı temsil ed er; bu fikir en azından Wittgenstein'a (1953) kadar uzanmaktadır. Dağılıms al hipotez, bu literatürde sıkça tekrarlanan bir alıntıyla özlü bir şekilde özetl enmiştir: “bir kelimeyi, onun yanında bulunan kelimelerden tanıyacaksınız” (Firth, 1957). Bunun, anlamsal hakkında bir şeyler öğrenebileceğimizi öne sürdüğünü belirtir. küçük bir alanda sıkça görünen kelimelere dayalı olarak kelimelerin anlamları

Doclingo https://www.doclingo.ai

odak kelimenin etrafındaki bağlam penceresi. Bu, kelimelerin anlamları hakkın da öğrenebileceğimizi önerdiği için muazzam bir potansiyele sahip bir fikirdir. *etiketleme olmadan verileri elle değil, bunun yerine büyük unlabeled koleksiy onlardan elde edilen kelime birlikte bulunma kalıplarını kullanarak.*

Kelime gömme yöntemleri, önceki bölümlerde incelediğimiz kelime sayımı özelliklerine kıyasla üç ana avantaj sunar:

1) benzerliği kodlarlar,
2) "otomatik genelleme"ye izin verirler,
3) anlamın bir ölçüsünü sağlarlar.

Benzerlik Kodlaması. Mikolov, Chen, Corrado ve Dean(2013) girişinde yazarlar şöyle yazıyor:

> Mevcut birçok NLP sistemi ve tekniği, kelimeleri atomik birim olarak ele alır —kelimeler arasında benzerlik kavramı yoktur, çünkü bunlarbir sözlükteki in deksler olarak temsil edilir. Bu seçim, birkaç iyinedenle desteklenmektedir— basitlik, dayanıklılık ve büyük miktarda veriyleeğitilen basit modellerin, daha az veriyle eğitilen karmaşık sistemlerdenüstün performans göstermesi gözl emi.

Son birkaç bölümdeki kelime torbası temsilleri altında, herhangi iki farklı kelimenin temsili için iç çarpım her zaman 0 olacaktır. Bu, iki anlamsal olarak benzer kelimenin, tamamen alakasız iki kelimeden daha yakın olduğu fikrinin olmadığı anlamına gelir. Aksine, kelimelerin dağ ıtılmış temsilleri, benzer anlamlara sahip kelimeler için benzer yönlere işar et eden vektörlere sahiptir. Bu ilişkiler o kadar güçlüdür ki, kelime gömme yöntemleri, vektörleri toplama ve çıkarma yoluyla analoji görevlerini çözm ek için kullanılmıştır. Mikolov, Yih ve Zweig (2013) tarafından, ünlü bir şekil de Kral − Adam + Kadın işleminin, Kraliçe'ye oldukça yakın bir vektör üretti ği gösterilmiştir. Bu basit vektör kaydırma yöntemi, gömme modelinin ana lojileri çözmek için açıkça eğitilmemiş olmasına rağmen, şaşırtıcı derecede güçlü bir performans sunmaktadır.

Otomatik Genelleme. Kelime temsillerindeki benzerliği kodlayarak, kelime gömme yöntemleri "otomatik genelleme" (Hinton, 1986) sunar — bir kelim e hakkında bir şey öğrenmek, ilgili kelimeler hakkında otomatik olarak bir ş ey öğrenmemizi sağlar. Örneğin, bir dizi elle etiketlenmiş örnek kullanarak film incelemelerinin duygusunu sınıflandırmaya çalıştığımızı hayal edin (bu tarz görev hakkında daha fazla bilgi Bölüm 19'da). Çünkü elle etiketlenmiş

Doclingo https://www.doclingo.ai

örnek küçüktür, belki de harika kelimesini hiç görmeyiz ama büyük kelim esini görürüz.bir bag-of-words temsilinde, büyük kelimesinin olumlu ince lemelerle ilişkili olduğunu öğrenebiliriz ama—etiketlisette hiç görünmedi ği için—yeni görünmeyen belgeleri sınıflandırırken harika kelimesini kull anamayız. Şimdikelime gömme temelli bir temsil ile soruna yaklaşmayı d üşünün. Çünkü büyük ve harikasıklıkla daha geniş dil korpuslarında benz er bağlamlarda ortaya çıkar, gömme vektörleri oldukça benzer olacaktır. Bu faydalıdır çünkü büyük kelimesinin olumlu incelemelerde sıkça göründüğ ünü gördüğümüzde,büyük ile olumlu incelemeler arasında gerçekten bir iliş ki öğrenmiyoruz; büyük kelimesiningömme alanındaki konumu ile olumlu in celemeler arasında bir ilişki öğreniyoruz. Harika kelimesibenzer bir konumda olduğu için, incelemenin olumlu olduğunu tahmin etme yeteneğimizotomat ik olarak harikaya genelleşir, o belirli kelimeyi herhangi bir film incelemesind e hiç gözlemlesek bile.Kelime gömme vektörlerinde yakalanan ilişkiler daha da ince olabilir, çünkü alandaki göreceli pozisyonların anlamı vardır, bu da Ki ng'in Man'a, Queen'in Woman'a benzerliği örneğiyle gösterilmiştir.Bu, kelim eler arasında daha karmaşık akıl yürütmenin mümkün olduğu anlamına gelir .

Kısacası, gömme vektörleri, kelimeler arasında bilgi paylaşımının verimli bir yol unu sağlar.Küçük metin koleksiyonlarında (veya kısa belgelerde) faydalar özellikle belirgin olacaktır, ancak dilin doğası gereği, büyük metin koleksiyonları bile nispet en nadir kelimelerin büyük bir kısmını içerecektir.

Anlamı Ölçme. Dağılımsal hipotez fikrini takip ederek,büyük korpuslarda öğre nilen kelime gömme yöntemleri, kelimeninanlamını ölçmek için de kullanılmışt ır. Bu, araştırmacıların kelimelerinanlamları ve bu anlamların zamanla veya ko nuşmacılar arasında nasıldeğiştiği hakkında araştırma sorularını incelemelerin e olanak tanımıştır(Caliskan, Bryson ve Narayanan, 2017; Garg ve diğerleri, 2018; Kozlowski, Taddy ve Evans, 2019; Rheault ve Cochrane, 2020; Rodman, 2020). Burada vurgulamak gerekir ki, çok belirgin bir anla mı kastediyoruz. İki kelime, benzer bağlamlarda kullanıldıklarında aynı anlama sahip olarak kabul edilir. Genellikle bu, anlamın sezgis el algımızla örtüşür, ancak bu kavramın sınırlamalarını akılda tutm ak faydalıdır.

Bu üç gücün tamamı, dağıtılmış temsillerin analistin koleksiyonunun ötesine geçme yeteneğinden kaynaklanmaktadır; bu, bir kelimenin anlamını daha büyük bir önceden v ar olan koleksiyonu kullanarak tahmin etme fikrini kullanır. Şimdi bu gömme işlemlerini n pratikte nasıl tahmin edildiğine geçiyoruz.

Doclingo https://www.doclingo.ai

8.2 Kelime Gömme Tahmini

Birçok farklı kelime gömme algoritması vardır. Her biri, dağılımsal hipotezin fikrini, bir belge korpusundan gömmeleri öğrenmek için kul lanılan biraz farklı bir hedef fonksiyonuna dönüştürür. Bu bölümde, ç oğu kelime gömme algoritmasını güçlendiren kendi kendine denetim fikrini kısaca ele alacağız ve ardından kullanıcıların yapması gereken b azı seçimleri tanımlayacağız. Daha sonra birkaç farklı tekniğin tahmini ne dalacağız.

8.2.1 KENDİ KENDİNE DENETİM GÖRÜŞÜ

Elle etiketlenmiş veriler pahalıdır. Bir araştırmacının bir etiketleme şemasını tanımlam ası zaman alır, kodlayıcıların verileri etiketlemesi zaman alır ve etiketlerin kalitesini değerl endirmek zaman alır. Bu, yüksek kaliteli, etiketlenmiş verilerin elde edilmesinin zor olduğu anlamına gelir.

Yine de, etiketlenmiş veriler mevcut olmadığında bile değerli bilgiler öğrenilebili r. Kendi kendine denetim görüşü, verilerin kendisi tarafından sağlanan bir etiketin olduğu denetimli bir görev oluşturabileceğimiz fikridir. Kelime gömmeleri bağlamı nda bu genellikle bir odak kelimenin etrafındaki kelimeleri kullanarak o kelimeyi ta hmin etmeyi içerir. Kendi kendine denetim görüşü, bu tahmini iyi yapmak için gere ken bilginin diğer görevleri tamamlamak için de yararlı olacağıdır.

8.2.2 KELİME GÖMMELERİNDE TASARIM SEÇİMLERİ

Bir araştırmacının kelime gömme kullanmayı düşünürken yapması gereken dört s eçim vardır. Rodríguez ve Spirling (N.d.) bu seçimlerin sosyal bilimciler için hedeflene n makale uzunluğunda bir hesabını ve değerlendirmesini sunmaktadır.

1) Veri Kaynağı. Kelime gömme işlemleri metin üzerinde eğitilmelidir ve seçilen belirli metin, öğrenilen temsil türü üzerinde büyük bir etkiye sahip olabilir. Kar arlı gömme işlemleri öğrenmek için çok fazla veriye ihtiyaç vardır—muhtemelen en az birkaç milyon token (Zhang ve diğ., 2021). Merkezî kelime gömme yöntemlerinin avantajlarından biri, büyük dışkorpüs üzeri nde eğitilebilmeleridir. Milyarlarca token içerenWikipedia, haber makalel eri ve web sayfalarından alınan korpuslar üzerindeöğrenilmiş birçok önc eden eğitilmiş gömme koleksiyonu indirilebilir.Ancak, bu belgelerde kulla nılan dili yansıtacaklarını belirtmek önemlidir.Rodríguez ve Spirling (N.d.) geniş çapta mevcut olanönceden eğitilmiş gömmelerin, siyasi anlamı yak alamada, siyasi konuşmaüzerine eğitilmiş gömmeler kadar iyi performan s gösterdiğini savunmaktadır.

Doclingo https://www.doclingo.ai

2) Bağlam Penceresi Boyutu. Dağılımsal hipotez, bir kelimenin anlamını çevresindeki kelimeleri inceleyerek anlayabileceğimizi varsayar. Bu durumda bir analistin yapması gereken ilk seçim, “yakın” kelimesinin ne anlama geldiğidir. Genellikle bu, gömme kelimenin etrafında sabit bir boyutta simetrik bir pencere olarak operasyonelleştirilir; örneğin, solda beş kelime ve sağda beş kelime. Bu pencerenin boyutu, gömmenin yakalayacağı bilgi türünü belirler. Pencere boyutu çok küçük olduğunda, bazı sözdizimsel anlamları yakalama eğiliminde olur ve pencere daha büyük olduğunda, anlamsal anlamları yakalama eğiliminde olur.

3) Gömme Boyutu. Kelime gömmeleri, bir kelimenin göründüğü bağlamlar hakkında bilgi kodlayan düşük boyutlu bir alandaki vektörlerdir, genellikle yalnızca nispeten az sayıda boyut—genellikle 50 ile 500 arasında. Başlangıçta bunun işe yarayabileceği şaşırtıcı olmalıdır—bu modellerin kelime dağarcıkları milyonlarca kelimeye ulaşabilir ve bir odak kelime için kelime gömme, bunların hepsiyle birlikte meydana gelen örüntüyü tahmin etmelidir. Yine de, nispeten düşük boyutlu gömmelerin etkinliği, zamanın testine dayanmış bulgulardan biridir.

4) Algoritma. Bir veri kümesi, bir bağlam penceresi ve gömmelerin boyutu verildiğinde, analistin verilerden gömmeleri öğrenmek için bir algoritma seçmesi gerekir. Aşağıda üç popüler algoritmayı inceleyeceğiz.

8.2.3 GİZLİ ANLAM ANALİZİ

Kelime gömmeleri son zamanlarda doğal dil işleme topluluğunu kasıp kavurmuş olsa da, bir süredir mevcutturlar. Deerwester ve ark. (1990) tarafından önerilen Gizli Anlam Analizi (LSA), gömmeleri (muhtemelen tf-idf ağırlıklı) doküman-özellik matrisinde kesilmiş bir tekil değer ayrıştırması kullanarak öğrenen kelime gömmelerinin özel bir durumudur. Bu, tüm belgenin bağlam penceresi olduğu ve dolayısıyla geri kazanılan gömmelerin genellikle anlamsal içeriği yakaladığı anlamına gelir (bu yüzden ismi!).

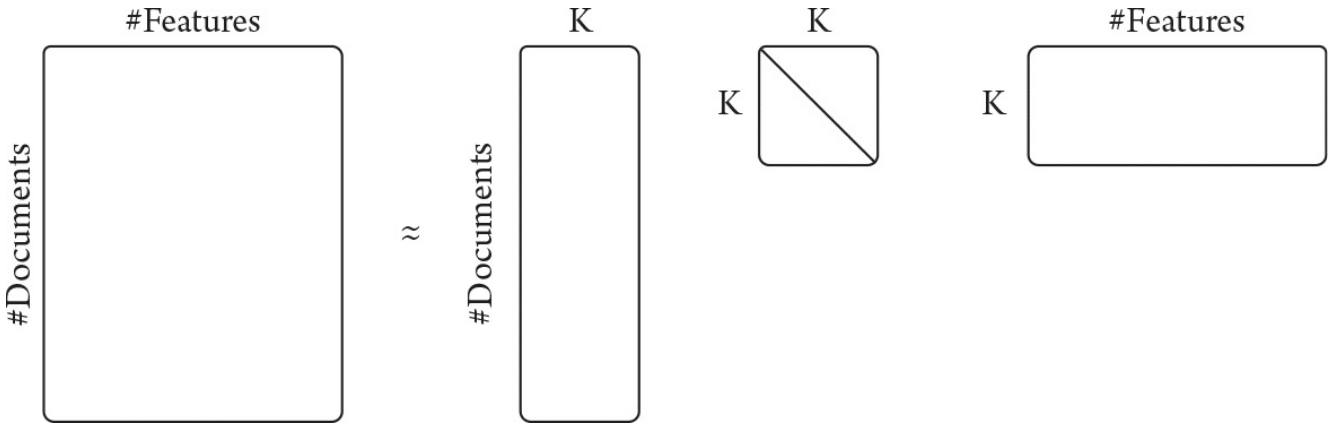
Temel algoritma, düşük dereceli matris faktörizasyonunu öğrenmek için genel bir yaklaşım olan kesilmiş tekil değer ayrıştırmasıdır. Kısaca, düşük dereceli bir faktörizasyonun fikri, bir matrisin daha küçük matrislerin çarpımı olarak ayrıştırılabileceğidir (Şekil 8.1). Sağdaki matrisin her sütunu, benzer kelimelerin benzer gömme değerlerine sahip olacağı kelime dağarcığında bir kelime için sürekli bir gömme değerini temsil eder; bu da onların aynı tür belgelerde görünme olasılığının yüksek olduğunu gösterir (bu, ya sıkça birlikte ortaya çıkmaları ya da yerlerini alabilmeleri nedeniyle olabilir).

Doclingo https://www.doclingo.ai

Bu strateji basit ve etkili olsa da, sınırlamaları vardır. Tüm belge, çok geniş bir bağlam penceresi olabilir ve belgelerin sayısı veya kel ime dağarcığının boyutu büyük olduğunda, hesaplama imkansız h ale gelebilir.

8.2.4 NÖRAL KELİME GÖMMELERİ

Modern kelime gömmeleri genellikle nöral gömmeler olarak adlandırılır çünkü bunlar nöro ağların mimarisine dayanmaktadır. Bu modeller, Bengi o ve arkadaşları (2003) kadar geriye giden bir tarihe sahip olsa da, gerçekt en Mikolov ve yazarları tarafından önerilen spesifik yaklaşımlarla (Mikolov, Chen, Corrado ve Dean, 2013; Mikolov, Sutskever, Chen, Corrado ve Dean, 2013) hesaplama açısından verimli öğrenme algoritmaları nedeniyle. Bu teknikler genellikle bunları uygulamak için yayımlanan yazılım olan word2vec olarak adlandı rılır.



Şekil 8.1. Düşük rütbeli bir ayrıştırma, bir matrisi üç daha düşük boyutlu matrisin çarpım ı olarak yaklaşıklar. İkinci matris, çapraz boyunca ince bir çizgi ile gösterilen bir diyagon al matristir.

word2vec aslında iki farklı hedef fonksiyonu için bir şemsiye terimdir — sürekli kelime torbası (CBOW) modeli (Mikolov, Chen, Corrado ve Dean, 2013) ve skipgram modeli (Mikolov, Sutskever, Chen, Corrado, v ve Dean, 2013)—ve bunu yapan optimizasyon rutini hesaplama açısından uygulanabilir—negatif örnekleme (Mikolov, Sutskever, C hen,Corrado ve Dean, 2013). CBOW, bir odak kelimenin etrafındaki bağlam tar afından tahmin edildiği bir tahmin problemi kurma fikrine dayanmaktadır. Örneğin, “tembel köpeğin üstünden hızlı kahverengi tilki [boş] atladı” ifadesi, “the, quick, b rown, fox, over, the, lazy, dog” kelimelerinin tahmin edilen kelime vektörlerinin ortalaması nı kullanarak boşluktaki kelimeyi tahmin etmek için kullanılacaktır. Boş alanı dolduran keli menin vektörü—atladı—denklemi maksimize edecek şekilde ayarlanmıştır.

Doclingo https://www.doclingo.ai

argmax μ sıçramaları exp (μ sıçramaları · v) Σ j exp (μ j · v) , (8.2.1)burada v bağlamdaki tüm gömme ortalamasını ifade eder (bu durumda hızlı, kahverengi, tilki, tembel, ve köpek kelimeler inin ortalama gömmeleri) ve jkapsamındaki tüm kelime dağarcığını indeksler. Alternatif skipgram modelinde tahmin problemi tam tersi dir - bağlam kelimeleri odak kelimeden birer birer tahmin edilir. Her iki hedefin de benzer gömme değerlerine sahip olma özelliği vardır, bu da iki kelimenin aynı tür keli

melerin bağlam pencerelerinde göründüğünde benzer gömme değerlerine sahip olacağı anlamına gelir.

Denklem 8.2.1'in zorluğu, paydanın çok sayıda terim üzerinde bir toplam içermesidir. Google tarafından word2vec projesi için yayımlanan kelime gömmelerinde, kelime dağarcığında üç milyondan fazla terim ve ifade bulunmaktadır, bu da paydanın üç milyon terim üzerinde bir toplam olduğu anlamına gelir. Negatif örnekleme, bu sorunu çözmek için tasarlanmış bir yaklaşık tahmin tekniğidir (Mikolov, Sutskever, Chen, Corrado ve Dean, 2013). Negatif örneklemede, payda

birkaç kelimenin (Mikolov, Sutskever, Chen, Corrado ve Dean (2013) arasında iki ile 20 arasında) (ağırlıklı) rastgele bir örneği kullanarak yaklaşık olarak hesaplanır ve bu kelimeler odak kelime değildir.

Negatif örnekleme yaklaşımı, LSA'da (Levy ve Goldberg, 2014) kullanılan matris faktörizasyon tekniğinin ağırlıklı bir versiyonu ile yakından ilişkilidir. Pennington, Socher ve Manning (2014) tarafından tanıtılan GloVe yöntemi, matris faktörizasyon problemini doğrudan ele almak için bu temelin üzerine inşa edilmiştir. GloVe, kelime eşzamanlılıklarının kare bir matrisini C oluşturur, böylece hücre C j j ′, kelimelerin *j* ve j ′ aynı bağlamda birlikte kaç kez göründüğünü eşitler. Bu model, yüksek frekanslı eşzamanlılıkları azaltan ağırlıklı bir hedef kullanılarak faktörleştirilir.

8.2.5 ÖN EĞİTİLMİŞ GÖMÜLER

Kelime gömülerinin merkezi bir avantajı, önceden eğitilmiş gömülerin büyük koleksiyonlarının Google'dan (word2vec), Stanford'un Doğal Dil İşleme Grubu'ndan (GloVe) ve Facebook'tan (fastText) indirilebilir durumda olmasıdır. Bu gömüler genellikle on milyarlarca token üzerinde eğitilmiştir. Ayrıca, İngilizce dışında dillerde de mevcuttur—örneğin, fastText şu anda Afrikaans'tan Zeelandic'e kadar 157 farklı dil için önceden eğitilmiş modellere sahiptir (aşağıda daha fazla tartışılacaktır).

8.2.6 NADİR KELİMELER

Bilyonlarca token üzerinde eğitilmiş olsa bile, her zaman uzun bir kuyruk olacaktır.

Doclingo https://www.doclingo.ai

nadir görünen kelimeler ve bu gömme işlemleri sonuç olarak daha gürültülü olacaktır. Birçok durumda, sosyal bilimciler, önceden eğitilmiş gömme işlemlerini kendi corpus'larına uyguladıklarında, belgelerinde kullanılan birçok kelimenin hiç eğitilmiş gömme işlemi olmadığını bulabilirler. Bu, özellikle araştırmacının ilgisini çekebilecek alan spesifik kelime dağarcığı ve jargon ile meydana gelme olasılığı yüksektir. Bu sorunu ele almak için farklı bilgi kaynaklarına dayanan üç stratejiyi kısaca özetliyoruz: dış anlamsal sözlüklerle yeniden yapılandırma, karakter düzeyinde bilgi kullanma ve gömme işlemlerini indükleme.

Yeniden yapılandırma, Faruqui ve diğerleri (2015) tarafından büyük topluluk veritabanlarından anlamsal bilgiyi kullanmak için tanıtılan bir stratejidir. WordNet (Miller, 1995), FrameNet (Baker, Fillmore ve Lowe, 1998) ve Paraphrase Database (Ganitkevitch, Van Durme ve Callison-Burch, 2013) gibi projeler, eşanlamlılar, yaygın anlamsal çerçeveler ve paraphrase ilişkileri gibi anlamsal ilişkiler hakkında kolayca erişilebilen kaynaklar sağlar. Bu kaynaklar, kelimelerin ilişkili kelimelere bağlandığı bir ilişki grafiği oluşturmak için kullanılabilir (örneğin, bir kelime tüm eşanlamlılarıyla bağlantılı olabilir). Yeniden yapılandırma prosedürü, önceden eğitilmiş kelime gömme işlemlerini ve bu ilişki grafiğini girdi olarak alır ve benzer gömme işlemlerini grafikteki komşulara atamaya teşvik edilen rafine bir gömme seti döndürür. Bu, gömme işlemlerinin, anlamsal veritabanlarında yansıtılan bilinen ilişkileri yansıtmasını sağlamaya yardımcı olur.

İkinci bir strateji, kelime seviyesinden karakter seviyesine düşmektir.Bu, kelimelerin genellikle bileşenlerden oluştuğu anlayışına dayanmaktadır.Örneğin, retrofitting terimini daha önce duymamış olsanız bile,kelimeyi parçalara ayırarak (retro-, -fit-, -t-, -ing) onun anlamı hakkındabir şeyler tahmin edebilmiş olabilirsiniz. Bu alt kelime bilgisi,şu ana kadar tartıştığımız gömme stratejileri tarafından kullanılmamaktadır.Bojanowski ve ark. (2017), karakter n-gramlarını analiz için atomikbirim olarak kullanan fastText gömme yöntemlerini tanıttı (bkz. ayrıca, Schütze, 1993; Wieting ve ark., 2016).fastText'te, her kelime, içerdiği karakter n-gramlarının (3, 4, 5 ve 6 boyutlarında) dizisi ile temsil edilir ve kelimenin elde edilen gömme,kelimenin içindeki tüm karakter n-gram gömmelerinin ortalamasıdır.Bu, fastText'in daha önce hiç görmediği kelimeleri gömmesine vebenzer karakter dizilerine sahip kelimeler arasında bilgi paylaşmasına olanak tanıyanbelirgin bir avantaja sahiptir.

Üçüncü stratejimiz, yeni bir kelime için,birkaç kullanım örneğine dayanarak bir gömme oluşturmak istediğimiz durumuele almaktadır. Bu, önceden eğitilmiş gömmelerin,belirli bir kelimeyi içermediği durumlarda ortaya çıkabilir.

Doclingo https://www.doclingo.ai

korpusumuz veya kelimenin belirli bir anlamı olabileceğine dair ne denlerimiz olduğu için. Khodak ve ark. (2018) à la carte gömülü sistemleri, yeni bir gömme oluşturmak için önceden eğitilmiş kelime g ömme seti ve yeni kelimenin bağlamdaki kullanım örnekleri temelinde bir yol o larak tanıtmaktadır. Temel içgörü, nadir kelime için bir gömme olmasa bile, etr afındaki bağlamda yer alan tüm kelimeler için önceden eğitilmiş gömmelere s ahip olmamızdır. Bu gömmelerin ortalamasının bir dönüşümünü kullanarak, K hodak ve ark. (2018) yalnızca kelimenin tek bir örneğinden bile doğru bir göm me elde etmenin mümkün olduğunu göstermektedir. à la carte gömme stratej isi, n-gramlar için gömme öğrenmek ve sosyal bilimler bağlamında kelimelerin bağlamsal olarak belirli anlamlarını yakalamak için özellikle yararlıdır (Rodrígu ez, Spirling ve Stewart, 2021).

8.2.7 BİR GÖSTERİM

İki kelime, farklı türde kelimelerin yakınında kullanıldıklarında farklı gömmele re sahiptir. Kullanımdaki bu fark, dağılımsal hipotez aracılığıyla anlamda bir fark olduğunu önermektedir. Araştırmacılar, büyük bir korpus üzerinde gömmeleri e ğitebilir veya kelimeler arasındaki ilişkileri veya aynı kelimenin farklı kullanımları (örneğin, farklı konuşma türleri, farklı konuşmacılar veya farklı zaman dilimleri) a rasında keşfetmek için önceden eğitilmiş gömmeleri kullanabilirler. Bir belge kol eksiyonunu, örneğin Birleşik Devletler'in Durumu korpusunu analiz ederken, ara ştırmacılar nadir kelimeler için teknikleri kullanarak kelime anlamlarını karşılaştır abilirler.

Gösterim amacıyla, 1900 ile 1959 yılları arasında Birlik Devletleri adresleri nde üretim kelimesinin kullanımını ele alıyoruz ve üretim kelimesinin kullanı mını karşılaştırıyoruz. 1960 ve 2016. Kelimenin anlamı üretim, sözlük tanımı anlamında değişmedi, ancak bu dönemde atıfta bulunduğu faaliyetler yavaş yavaş değişti. Bu zor bir görev çünkü sadece 53 toplamda "üretim" kelimesinin kullanımları, yaklaşık olarak iki zaman dilimi arasında eşit şekilde bölünmüştür. So n bölümde açıklanan à la cartegömme stratejisini kullanarak, yalnızca bu birkaç örneği ve üretim bağlam penceresinde yer alankelimeler içi n önceden eğitilmiş gömmeleri kullanarak üretim için zaman dilimine özgü birgömme üretebiliyoruz.

Bu, üretim için iki gömme oluştururken (biri 1960 öncesi vebiri 1960 s onrası), her biri (bizim durumumuzda) belirgin bir anlamı olmayan 300 b oyutlu bir vektördür. Gömmenin ne anlama geldiğine dair bir fikir verme k için, kosinüs mesafesini kullanarak en yakın komşuları sunuyoruz. 1960 öncesi dönem için en yakın beş komşu arasında ihracat, petrol ile ilgili,

Doclingo https://www.doclingo.ai

eşzamanlı, zarar, ve savaşla ilgili, listedeki komşularla birlikteenerji yoğun, i thalat/ihracat, savunma ile ilgili ve sermaye yoğun. 1960 sonrası dönem içi n en yakın komşular, üretimle ilgili farklı bir tartışmayı yansıtır; en üstteki b eş komşu yeniden donanım, yeniden donanım, işler, şehir merkezleri ve off shore ile birlikte, listedeki daha aşağıdaki komşular ise dış kaynak kullanım ı, küreselleşmiş, düşük nitelikli, yeniden eğitim ve iş gücünü içermektedir. S adece küçük bir örneklemle bile, gömme işlemleri, 1960 sonrası dönemde üretimin nasıl kullanıldığına dair farkı yakalamıştır ve etrafındaki kelimeleri kullanmaktadır. Bu bilgi hem kendi başına ilginç olabilir hem de sınıflandır ma ve kümeleme gibi sonraki görevler için metnin faydalı bir temsilini sağl ayabilir.

Yakın kelimelerle olan ilişkiler, araştırmacıların kelimelerin anlamlarını öğrenmelerine veya verilerinin daha iyi özellik temsilleri oluşturmalarına yardımcı olabilirken, gömme işlemleri, bu ilişkileri corpus'ta göründüğü g ibi yansıtır; bu da araştırmacıları sadece kelimelerin anlamları üzerinde d eğil, aynı zamanda olumsuz ilişkiler ve stereotipler üzerinde de düşünme ye yönlendirebilir. Son araştırmalar, büyük önceden eğitilmiş gömme işle mlerinin, cinsiyetli zamirler ile belirli meslekler (Bolukbasi ve diğ., 2016), c insiyet stereotipleri (Caliskan, Bryson ve Narayanan, 2017) ve etnik stereo tipler (Garg ve diğ., 2018) gibi sorunlu içeriklere sahip olduğunu gösterm ektedir. Verilerdeki bu zararlı ilişkilerin varlığı, bu gömme işlemlerini eğit mek için kullanılan büyük corpus'larda dilin nasıl kullanıldığını yansıtır—b u, corpus inşasının etik sonuçları üzerine 3. Bölümdeki 2. ilkemizde belirtt iğimiz bir noktadır. Sosyal bilimciler için, bu önyargıları incelemek için bir fırsat sunabilir. Garg ve diğ. (2018), eğitilmiş gömme işlemlerini kullanara k etnik stereotiplerin bir yüzyıl boyunca evrimini tanımlamaktadır.

Ancak, gömme işlemleri gerçek dünya sistemlerinde kullanıldığında, bu ayarların içinde zararlı ırksal ve cinsiyet eşitsizliklerini artırma riski taşır (Benjamin, 2019). Gömme işlemi, üretimin gerçek anlamı hakkında hiçbir şey bilmediği gibi, yalnızc a etrafında kullanılan kelimeleri bilmektedir; doktor kelimesinin gömme işlemi d e, bu işin herhangi bir cinsiyetten bir kişi tarafından yapılabileceğini bilmemekte dir, bu işin yalnızca erkeklerle ilişkilendirilmiş bir anlamı yoktur.

Bu ilişkileri kaldırmak için gömme işlemlerini “önyargısızlaştırmaya” çalışa n araştırmalar olsa da, gömme işlemlerinin eğitildiği dilin yansıması olduğu v e bu dilin bir boşlukta var olmadığı, aksine sosyal bir sürecin ürünü olduğu t emel endişeyi ele alamazlar. Mevcut eşitsizlikleri artırmamamız için bu sorun lar konusunda dikkatli olmalıyız, ancak bizim için önyargının varlığı, araştırm a hedefinin ve bu hedefi ele almak için kullandığımız verilerin dikkatli bir şeki lde değerlendirilmesini gerektirir.

Doclingo https://www.doclingo.ai

8.3 Kelime Gömme İşlemlerini Belge Düzeyinde Toplama

Varsayılan Kelimelerin Torbası tarifinde Bölüm 5, her token bir one-hot kodlaması olarak temsil edildi ve ilişkili belge temsili, token temsillerinin toplamı kadar kolaydı. Kelime gömme işlemleri, kelimelerin kendilerinin zengin bir temsilini sağlarken, belgeleri temsil etmek için nasıl kullanılacağı daha az açıktır, bu da sosyal bilimcilerin çalıştığı analiz düzeyidir.

Makuldür ki, ilk bir tahmin, belgedeki her kelimenin gömme değerlerini ortalamak olacaktır. Bu, cümleleri ağırlıklandırarak ve ardından ilk tekil vektörü çıkararak ortak bir bileşeni kaldıran Smooth Inverse Frequency (SIF) gömme değerleri kullanılarak geliştirilebilir (Arora, Liang ve Ma, 2017). Bu strateji, ortak sinyali önemsizleştiren bir şekilde ağırlıklandırarak 7. Bölümde tanımlanan tf-idf stratejisine dayanır. À la carte gömme değerlerini kullanan bu stratejinin bir varyantı, indüklenmiş n-gram'ları kullanarak kelime sırası bilgisini de içerebilir.

Alternatif olarak, biraz daha fazla eğitim yapma maliyetiyle, belge gömme değerleri verilerden öğrenilebilir. Le ve Mikolov (2014), paragraf düzeyinde temsilleri öğrenmek için doc2vec modelini tanıtmaktadır. doc2vec, skip-gram algoritmasıyla benzer bir model kullanır, ancak kelime vektörlerine ek olarak, tahmin modelinde tahmini desteklemek için optimize edilmiş bir paragraf düzeyinde vektör içerir.

Şu ana kadar bahsedilen tüm modeller, kelime sırasını yalnızca çok hafif bir şekilde kullanmaktadır (doc2vec durumunda n-gram'lar ve n-gram benzeri bilgiler aracılığıyla). Tekrarlayan sinir ağlarına dayanan modeller, eğitiminin ve uyum sağlamasının önemli ölçüde daha zor olmasının maliyetiyle, sıralama duyarlı belge temsilleri üretebilir (Socher ve diğ., 2013; Kiros ve diğ., 2015). Hedef sınıflandırma olduğunda, derin öğrenmeye dayanan birkaç yaklaşım yalnızca token düzeyinde temsiller gerektirir ve belge düzeyindeki temsili sınıflandırma süreci sırasında örtük olarak oluşturur.

Çoğu bilgisayar bilimi çalışmasının, kelime gömme verilerini toplamak için yapılan çalışmaların esasen cümleler veya paragraflar üzerinde yoğunlaştığını belirtmekte fayda var. Bu yöntemler kısa metinler için etkili bir şekilde çalışabilirken, daha uzun belgelerin performansı o kadar yüksek olmayabilir.

Doclingo https://www.doclingo.ai

8.4 Doğrulama

Bilgisayar bilimi literatüründe, kelime gömme doğrulaması genellikle iki kategoriye ayrılır: *extrinsic* evaluations, bir sonraki doğal dil işleme görevi ndeki performansı değerlendirirken, *intrinsic* evaluations, gömmelerin keli meler arasındaki benzerlikleri yakalayıp yakalayamadığını değerlendirir. Toplumbilimciler için en önemli doğrulama, bu metin temsillerinin belirli görevlerini yerine getirmelerine nasıl yardımcı olduğudur (Kozlowski, Tad dy ve Evans, 2019; Lauretig, 2019; Rheault ve Cochrane, 2020; Rodman, 2020). Ancak, bu ek yaklaşımlardan bazılarını kısaca gözden geçiriyoruz çünkü bu y öntemlerin literatürde nasıl değerlendirildiğine dair bir bağlam sağlıyorlar.

Doğal dil işleme topluluğundaki kelime gömme heyecanının çoğu, bunl arın aşağı akış sistemlerinde önemli performans artışları sağlamasıdır. Bu nedenle, önceki çalışmalar, bu tür gömmelerin isim tamlaması parçalama, sözcük türü etiketleme ve adlandırılmış varlık tanıma gibi temel görevlerin doğruluk oranlarını artırdığını göstermiştir (Pennington, Socher ve Mannin g, 2014). Bu konuları bir sonraki bölümde ele alacağız. Bu tür gömmelerin, basit doğrusal sınıflayıcılar kullanıldığında farklı sınıflandırmalarda doğrulu ğu artırdığı da gösterilmiştir.

İçsel değerlendirmeler, gömme işlemlerinin kelime benzerliğinin anlamlı kavr amlarını yakalayıp yakalayamayacağına odaklanmıştır. Bu görevlerin tam yapısı, kelime çiftleri benzerlik değerlendirmeleri de dahil olmak üzere birçok biçim alır (Finkelstein ve diğ., 2001), benzerlik çözümü (Mikolov, Sutskever, Chen, Corrado ve Dean, 2013; Levy, Goldberg ve Dagan, 2015), ve kümelenme görevleri, bir kümelenmenin kelimeleri anlamsal olarak tutarlı gruplara doğru bir şekilde ayırıp ayırmadığını görmek için tasarlanmıştır (Baroni, Dinu ve Kruszewski, 2014; Schnabel ve ark., 2015). Bu görevlerin birçoğu, bir dizikelimeyi bir sorgu kelimesi ile karşılaştı rmaya ve en yakın olanı seçmek için kosinüs benzerliğini kullanmaya dayanmaktadır.

Yüksek bir iç değerlendirme puanı, kelime gömme işlemlerinin bir şeyle ri yakaladığını gösterse de, görevlerin kendilerinin ideal olmadığı birçok yo l vardır. Kelime benzerliği görevleri doğası gereği öznel olup, çok anlamlılığ ı hesaba katamaz ve makine öğrenimi standartları gibi bazı standart özellik lerden yoksundur, örneğin eğitim-test bölmeleri ve muhtemelen yetersizdi r (Faruqui ve diğ., 2016; Card ve diğ., 2020). İşleri daha da karmaşık hale ge tiren Schnabel ve diğ. (2015), dışsal ve içsel doğrulamaların genellikle birbi rleriyle çeliştiğini göstermektedir. Bu, tüm görevler için tek bir doğru temsi lin asla olmayacağına dair daha geniş temamızı vurgulamaktadır.

Uygulamalı sosyal bilimciler için kelime gömme incelemelerinde, Rodríguez ve Spirling (N.d.) kelime gömme için bir Turing tarzı test geliştirmektedir, bu da

Doclingo https://www.doclingo.ai

bilgisayar bilimi literatüründeki içsel değerlendirmeleri genişletmektedir. Tasarıml arında, Amazon MTurk'ta bir grup kalabalık işçisine on siyasikelime veriyorlar ve o nlardan on en yakın komşu üretmelerini istiyorlar. Daha sonraaynı kelimeleri kulla narak, kelime gömme kullanarak en çok kosinüs benzer vektörü bulupmakine en y akın komşularını oluşturuyorlar. Ardından, bir başka insan grubunubir uyarı kelim esine ve iki olası en yakın komşuya (bir insanlardan, bir makineden,fakat etiketlen memiş) bakmaları için görevlendiriyorlar ve onlardan en iyisiniseçmelerini istiyorla r. Bu, insan tarafından üretilen kelimelerin diğer insanlar tarafındanmakine tarafın dan üretilen kelimelere göre ne sıklıkla seçildiğini hesaplamalarınaolanak tanır. Ha zır önceden eğitilmiş gömmelerin genellikle insan tarafından üretilenkelimelerle eş it veya daha iyi performans gösterdiğini buluyorlar.

Doclingo https://www.doclingo.ai

8.5 Bağlamsal Kelime Gömme

Şu ana kadar tartıştığımız tüm gömmelerde, bir kelimenin gömme değeri bağlamından bağımsız olarak sabittir. Yani, bat kelimesi, bir cümlede cave ve night veya bir cümlede ball ve pitch ile olup olmamasına bakılmaksızın bazı gömme değerine sahiptir. Bat gibi çok anlamlı kelimeler, kelimeye özgü anlamların ortalamasında bulunma eğilimindedir (Arora et al., 2018).

Son zamanlarda doğal dil işleme alanında yapılan yayınlar, bağlamsal kelime gömme yöntemlerinin muazzam potansiyelini göstermiştir (Peters et al., 2018; Devlin et al., 2019; Liu et al., 2019; Brown et al., 2020). Bu modeller, standart kelime gömme işlemleriyle aynı özdenetim içgörüsüne dayanmaktadır, ancak gömmeleri öğrenmek için çok daha karmaşık derin öğrenme dil modelleri kullanmaktadır. Bu modellerin avantajı, önceden eğitilmiş bir modelin, bir belgede her kelime için bağlama özgü bir gömme üretmek için kullanılabilmesidir; yani, sadece kelimeyi değil, aynı zamanda etrafındaki diğer kelimelerle olan ilişkisini de yakalayan bir gömme. Bu modellerin birçoğu, ya Tekrarlayan Sinir Ağları (Rumelhart, Hinton ve Williams, 1986) ya da Dönüştürücü mimarisi (Vaswani ve diğerleri, 2017), kelimesırası bilgilerini gerçekten yakalamak için dikkate aldığımız ilk modellerdir.

Bir dizi önceden eğitilmiş model, kullanım için hazır bulunmaktadır; bunlar arasında Devlin ve ark. (2019) tarafından geliştirilen BERT (Transformers'tan İki Yönlü Kodlayıcı Temsilleri) ve Brown ve ark. tarafından geliştirilen GPT-3 (Üretken Önceden Eğitilmiş Dönüştürücü) bulunmaktadır. (2020). Bu modeller, araştırmacının çalıştığı belirli bir korpusa daha da ince ayar yapılabilir[2] , ancak bu kısmi eğitim süreci bile hesaplama açısından yoğun olabilir.

Bu bölümde ele alınan çoğu kelime gömme modeli, bireysel sosyal bilimciler tarafından makul bir şekilde eğitilebilir (örneğin, Rodríguez ve Spirling, sekiz CPU çekirdeği kullanarak üç saatte 700 milyon token ile birçok model eğitti). Ancak, bağlamsal kelime gömme modelleri tamamen farklı bir ölçekte maliyetlidir, etkili bir şekilde Grafik İşleme Birimleri (GPU'lar) kullanmayı gerektirir ve eğitmek günler, haftalar veya hatta aylar alabilir. Bu modellerin eğitiminin enerji ve maliyet etkileri üzerine bir makalede, Strubell, Ganesh ve McCallum (2019), BERT'in her eğitim örneğinin 79 saat sürdüğünü ve bulut hesaplama süresi için 4.000–12.000 $ maliyetle sonuçlandığını tahmin ettiler. Makaleleri için bir vaka çalışmasında, benzer bir model oluşturmak için tek bir makale için 27 yıl boyunca GPU süresi (altı ay boyunca sürekli çalışan 60 GPU) kullandıklarını ve tahmini bulut hesaplama maliyetinin 100.000–350.000 $ olduğunu açıklıyorlar.

Doclingo https://www.doclingo.ai

8.6 Sonuç

Bu bölümde, 5. Bölümde tanımlanan varsayılan kelime torbası tarifine alternatif bir yaklaşım olarak kelime gömme modellerini ele aldık. Kelime torbası, her belge için büyük, seyrek bir vektör temsili üretirken, kelime gömme modelleri her kelime için karşılaştırmalı olarak küçük, yoğun bir temsil üretir; bu da daha sonra belge düzeyinde birleştirilmelidir.

Kelime gömme işlemlerinde temel bir fikir, her kelimenin temsilinin bir hedefi (ya bir kelime bağlamından, ya kelimeden bağlama, ya da sadece kelimelerin birlikte bulunma durumunu) tahmin etme yeteneğini artırmak için seçildiği özdenetim iç görüsüdür. Bu, gömme işlemlerinin kelimeler arasındaki benzerliği yakalama yeteneği kazandırarak, modellerin bag of words temsilleriyle her zaman kolay olmayan bir şekilde farklı kelimeler arasında genelleme yapmasına olanak tanır.

Özellikle, bu modeller büyük, önceden var olan dil korpuslarında öğrenilebilir ve ardından araştırmacının belirli araştırma bağlamında kullanılabilir; bu fikre transfer öğrenme denir. Bu amaç için sadece bu amaçla var olan birçok hazır gömme işlemi bulunmaktadır; bunlar arasında word2vec, GloVe ve fastText bulunmaktadır. Kelime sırası hakkında bilgi yakalayabilen daha yeni bağlamsal kelime gömme işlemleri de önceden eğitilmiş olarak indirilebilir.

---

[1] Bağlamdaki gömme işlemlerinin ortalaması, gömme alanının ortak boyutlarını abarttığı için kendisi iyi bir gömme işlemi değildir. Arora ve diğerleri (2018) tarafından elde edilen teoriyi kullanarak, Khodak ve diğerleri (2018) ortalamanın etkili bir tahmin stratejisi sağlayan lineer bir dönüşümünün öğrenilebileceğini göstermektedir.

[2] İnce ayar, bir modeli sınırlı sayıda iterasyon için bazı yeni verilerle eğitmeye devam etme sürecidir. İnce ayar, modelin mevcut görevi daha iyi karşılayacak şekilde hafifçe değiştirilmesini sağlar, ancak aşırı uyumdan kaçınmak için dikkatli bir şekilde yapılmalıdır.

Doclingo https://www.doclingo.ai

BÖLÜM 9

Dil Dizilerinden Temsiller

Kelime sırasını göz ardı ederken metin verisi projelerinde şaşırtıcı derecede ileri gidebilirsiniz. Böyle analizler, nispeten basit ve hesaplama açısından uygulanabilir oldukl arı için caziptir. Bu nedenle, Bölüm 5-8, bireysel kelimelerden nasıl anlams al bilgi elde edilebileceğine odaklanmıştır. Bu bölümde, bir dizideki kelimel erin rolüne daha açık bir şekilde odaklanan doğal dil işleme tekniklerini na sıl kullanacağımızı gösteriyoruz. Bu modellerin nasıl tahmin edildiğini keşfe tmek yerine, çıktılarının sosyal bilim uygulamalarını geliştirmek için nasıl fa ydalı olabileceğine odaklanıyoruz.

Bölüme, metin yeniden kullanımı tartışmasıyla başlıyoruz; bu, belgel er arasında metnin tam veya yaklaşık kopyalanmasını tanımlama süreci dir. Ardından, bir cümledeki her bireysel kelimenin konuşma kısmını eti ketleyen bir yöntem olan konuşma kısmı (POS) etiketleme konusunu tar tışıyoruz ve bunun isim tamlamalarını tespit etmek için nasıl kullanılabil eceğini gösteriyoruz. Üçüncü bölümde, araştırmacıların metinlerden in sanlar, organizasyonlar ve yerler gibi yapılandırılmış bilgilerin isimlerini çıkarmalarına olanak tanıyan adlandırılmış varlık tanıma (NER) konusun u gözden geçiriyoruz. Son bölümde ise, bir cümledeki kelimeler arasınd aki sözdizimsel ilişkileri haritalayan bağımlılık çözümlemesini tartışıyoru z. Her bölümde, yöntemi özetliyoruz ve bu yaklaşımları sosyal bilimlerd e kullanan uygulamaları tanımlıyoruz. Bu bölüm, mümkün olanların sad ece yüzeyine dokunuyor ve bu konu hakkında daha ayrıntılı bir incelem e için Eisenstein (2019) ve Jursfsky ve Martin (2009) öneriyoruz.

Doclingo https://www.doclingo.ai

9.1 Metin Yeniden Kullanımı

İntihal tespiti arkasındaki temel teknolojiye dayanarak, sosyal bilimci ler metin yeniden kullanımının sonuçlarını keşfetmeye başladılar. Bu al goritmalar, yeterince uzun olan ve şans eseri ortaya çıkması olası olmay an iki belge arasında yer alan ortak metin dizilerini tanımlar. Bu genelli kle bir belgenin diğerinden kopyalanması veya her ikisinin de ortak bir kaynaktan kopyalanması nedeniyle olur. Bu kopyalama kalıplarının nası l ortaya çıktığını anlamak, tarih (Smith, Cordell ve Dillon, 2013) gibi çeşit li bağlamlarda, bilimsel yazım (Citron ve Ginsparg, 2015), meme'ler (Les kovec, Backstrom ve Kleinberg, 2009) ve edebiyat çalışmaları (Bamman ve Crane, 2009) gibi siyasi ve sosyal süreçler için oldukça aydınlatıcı ola bilir.

Kitabın Keşif bölümünde daha fazla tartışacağımız bir projede, Grimmer (201 0) ABD senatörlerinin seçmenleriyle nasıl ilişki kurduğunu anlamak istedi. Bunu y apmak için 2007 yılında Senato ofisleri tarafından yayımlanan 24,000 basın bülte ni topladı. Bu çalışmadaki temel bir zorluk,
bu basın bültenlerindeki bilgiler, haber tüketicilerine ulaşan bilgileri yansıtmak tadır (çünkü çoğu haber tüketicisi, senatörlerinin ofisinden gelen günlük basın bültenlerini okumamaktadır). Grimmer (2010), hazır plajiarizm tespit yazılımlar ını kullanarak, yerel gazetelerin Senato basın bültenlerinin büyük bölümlerini e sasen kelime kelime yeniden yayımladığını göstermiştir (bkz. ayrıca Grimmer, 2013*b*). Daha küçük yerel gazetelerde, belirli bir eyaletin senatörünün basın bü ltenlerinin %30'unun kopyalanabileceği, büyük gazetelerde ise, örneğin *San Francisco Chronicle*, Kaliforniya senatörlerinin basın bültenlerinin %6-7'sini alıntı ya pmıştır.

Bail (2012) bu tekniği, 9/11 saldırısından sonra Amerika Birleşik Devletleri'ndeki Müs lümanların ana akım medya kapsamı üzerindeki marjinal sivil toplum kuruluşlarının etki sini izlemek için de uygulamaktadır. Ana akım gazete ve televizyon haberlerinin, sivil to plum basın bültenlerinden metinleri önemli ölçüde yeniden kullandığını belirlemiştir. D aha sonra bu basın bültenlerini, bazı basın bültenlerinin neden yayıldığını ve diğerlerini n neden yayılmadığını açıklamak için ek nitelikli kodlanmış bilgilerle birleştirmiştir. Med ya kuruluşlarının, hem iyi kaynaklara sahip sivil toplum kuruluşlarının hem de Müslüma nlar hakkında öfkeli ve korkulu çerçeveleri teşvik eden marjinal kuruluşların mesajını gü çlendirdiğini bulmuştur (bkz. ayrıca Bail, 2014*a*). Bail'in çalışması kopyalamanın gerçekleştiğini basitçe kanıtlamanın ötesinde, metin yeniden kullanımı kültürün ölçümünde önemli bir yenilik olabilir (Bail, 2014*b*; Mohr ve diğ., 2020).

Sonunda, Wilkerson, Smith ve Stramp (2015) evrimi izlemektedir

Doclingo https://www.doclingo.ai

ABD Kongresi'ndeki yasaların ilerleyişini takip ederek politika fikirlerinin gelişimini i zlemek için daha önce başarısız olan tasarılar arasında metinlerin yeniden kullanım ını sağlıyorlar. Bu içgörüleri, 232 daha önce sunulmuş tasarıdan fikirler alan Hasta Koruma ve Uygun Fiyatlı Bakım Yasası'nın (Obamacare) tarihine dair yeni kanıtlar s unmak için kullanıyorlar; bu tasarılar arasında daha sonra tasarıya karşı oy verecek olan Cumhuriyetçiler tarafından desteklenenler de bulunuyor. Olasılıklar, eyalet ya sama düzeyinde daha da zengin; burada Amerikan Yasama Değişim Konseyi gibi o rganizasyonlar, eyaletler arasında benimsenmek üzere yasama metinlerini açıkça dağıttı (Hertel-Fernandez ve Kashin, 2015; Burgess ve diğ., 2016; Jansa, Hansen ve Gray, 2019; Hertel-Fernandez, 2019). Son yıllarda, akademisyenler sadece metin yeniden kullanımının yasama üzerindeki etkisini anlamak için bir araç olarak potansiye lini kullanmaya başladı (Linder ve diğ., 2020; Gava, Jaquet ve Sciarini, 2021).

Bu yöntemlerin zorluğu, oldukça hesaplama açısından maliyetli olmalarıdır. Yapı itibarıyla, bu yöntemler belgeler arasında çift yönlü karşılaştırmalar yapar, bu da orta boyutlu bir korpusun, daha fazla yaklaşık hesaplamalar olmadan, karşılaştırmaların yapılmasını imkansız hale getirebileceği anlamına gelir. Örneğin, Wilkerson, Smith ve Stramp (2015) neredeyse 120,000 karşılaştırılacak bireysel tasarı bölümlerine sahiptir, bu da naif bir yaklaşımk ullanarak yedi milyardan fazla karşılaştırma gerektirecektir.Sonuç olarak, kar şılaştırmaların sayısını üçsıfır kadar azaltan ön işleme tekniklerinden yararla nmayı başarırlar,bu da bu tekniklerin kullanılabilir hale gelmesini sağlar. Bu karşılaştırmalarıyapmak için araçlar daha yaygın hale geldikçe, çalışmaların daha da yaygınlaşmasınıbekliyoruz.

Doclingo https://www.doclingo.ai

9.2 Konuşma Parçaları Etiketleme

Konuşma parçaları (POS) etiketleme, bir belgede her bir kelimeyebir gram er etiketi atama görevidir; örneğin, onu bir fiil, isim,edat veya sıfat olarak eti ketlemek. Kelimeler, ya kural tabanlı bir algoritmaya da her bir kelimeyi man uel olarak etiketlenmiş bir eğitim veri setinedayalı olarak sınıflandıran bir ma kine öğrenimi algoritması ile etiketlenir(Jursfsky ve Martin, 2009, s. 297). 4.8 milyon kelimeden oluşanPenn Treebank, 45 farklı konuşma parçaları etiketi i le etiketlenmişçeşitli İngilizce kaynaklardan oluşan bir korpus, genellikle İngi lizcePOS etiketleme için bir eğitim seti olarak kullanılır (Marcus, Marcinkiewic z,ve Santorini, 1993), ancak Twitter gibi diğer yazım ortamları içinfarklı yaklaş ımlar da mevcuttur (Gimpel ve diğerleri, 2011) ve çevrimiçi konuşmalar (Owoputi ve diğ., 2013).

POS etiketleme, diğer birçok teknik için önemli bir girdi olup, aynı zamandabelge-özellik matrislerini alt kümelemek için bir yol olarak da kullanılabilir.Örneğin, araştırmacılar belgelerindeki duygu içeriği yle özellikle ilgileniyorlarsa,tüm konuşma parçalarını, duygu hakkınd a ipuçları verme olasılığı daha yüksekolan sıfatlar ve zarflar dışında k aldırmak avantajlı olabilir. Konuşma parçasıetiketleri, konuşma parç alarıyla ayrılmış kelime anlamlarını ayırmak için defaydalı olabilir.

POS etiketlemenin önemli bir pratik uygulaması, özellik setlerine dahil edilebilecekifadeleri veya metinleri görselleştirmek için n-gra mları tanımlamaktır. Örneğin,isim ifadelerini—bir grup isim ve onu değiştiren kelimeleri tanımlayabiliriz.Bu ifadeler, sağlık hizmetleri ve Dünya Kupası gibi, genellikle kelime setinin,oluşan unigramların toplamından çok daha fazlasını ifade ettiği durumları gösterir.Böyl e ifadeleri tanımlamanın bir yolu, belirli dilbilgisel kalıpların kullanıl masıdır(Justeson ve Katz, 1995; Handler ve diğ., 2016). İsim ifadeler ini tanımlamak için,araştırmacılar önce her kelimeyi etiketlemek içi n POS etiketleme kullanır. Sonra,metin içindeki belirli bir uzunlukta ki tüm ifadeleri alırlar, örneğin, uzunluğu 4 olantüm ifadeleri. Daha sonra, herhangi bir ifadenin belirli bir dilbilgisel kalıba uyupuymad ığını belirlerler; bu genellikle eşleşmenin otomatikleştirilebilmesi iç inbir düzenli ifade ile yazılır. Örneğin, basit bir isim ifadesi, önünde ya bir isim(N) ya da bir sıfat (A) bulunan bir isim (N) olabilir:

$$(N|A)+N$$

| simgesi bir VE'yi gösterir. Bu dilbilgisi kalıbı ifadeleri alır

Doclingo https://www.doclingo.ai

New York, Dünya Kupası ve eski şarkılar gibi.

İsim öbekleri, ismi tanımlayan isimden sonra gelen edatları da içer ebilir; örneğin, New York'tan kadın veya Pasifik Okyanusu üzerindeki uçak. Bu nedenle, isim öbeklerini seçmek için daha karmaşık bir dilbil gisi deseni, edatları (P) ve belirteçleri (D) kullanır:

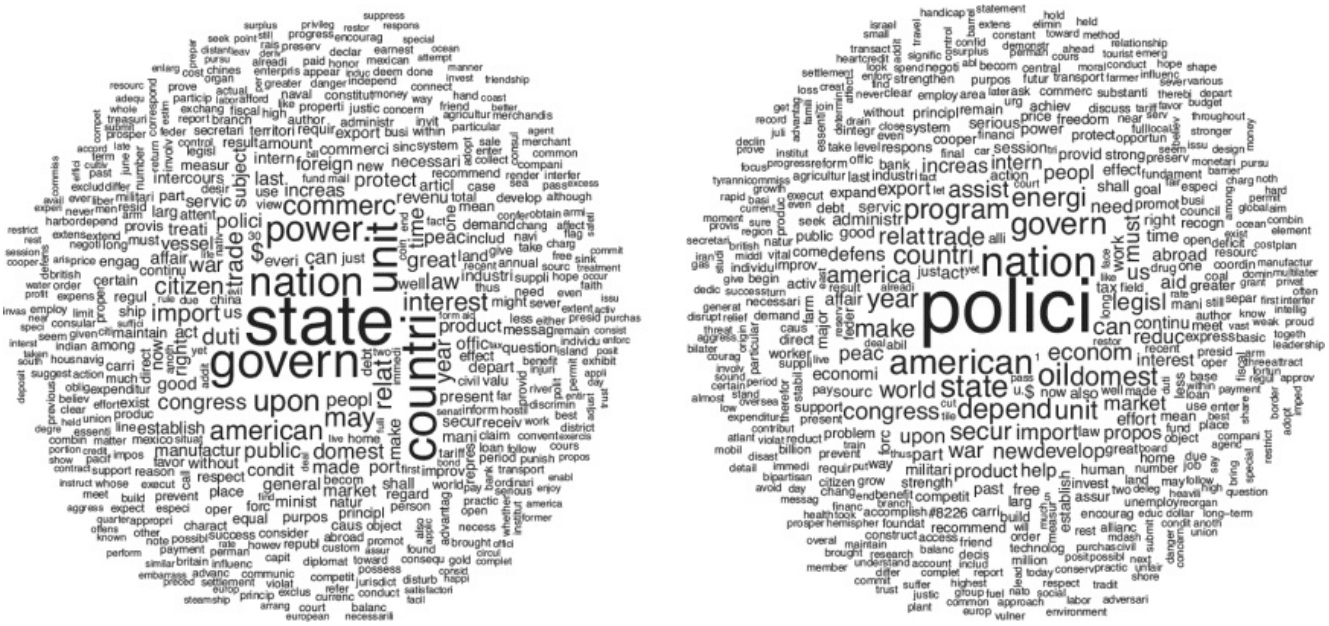
(N /A)+N(P+D*(A /N)*N)*

önceki cümlenin isteğe bağlı olduğunu belirtir. Böylece (P+D*(A /N)*N)* ifadesi, ifadenin isteğe bağlı olarak bir edat ve bir isim içerebileceğini, b unlarınöncesinde isteğe bağlı olarak bir sıfat veya bir isim ve öncesinde isteğe bağlı olarak birbelirleyici olabileceğini okur. Birçok varyasyona s ahip isim öbekleri, dijital kütüphanelerdearama geliştirmek için (Frantzi , Ananiadou ve Mima, 2000), metin içinde biyografik bilgilerikeşfetmek i çin (Bamman ve Smith, 2014), ve taraflı dili tanımlama (Handler ve diğerleri, 2016). Benzer stratejiler, olayları tanımlamak için bir temel olarak ya rarlı olabilecek fiil ifadelerini tanımlamak için kullanılabilir.

9.2.1 GÖRSELLEŞTİRMEYİ İYİLEŞTİRMEK İÇİN İFADELER KULLANMA

Önceki bölümlerin bir kısmında, metinleri görselleştirmek için kelime bulutl arı kullandık. Kelime bulutlarına karşı birçok eleştiri yapılabilir ve yapılmıştır, a ncak genellikle bir metnin hızlı, görsel olarak çekici bir görünümünü sağlarlar. İsim öbekleri, metinden bilgi çıkarmak için yalnızca kesin bir şekilde değil, aynı z amanda kelime bulutları ve benzeri görselleştirmelerin yorumlanabilirliğini artır mak için de faydalı olabilir. Metin görselleştirmesi üzerine bir çalışmada, Chuang , Manning ve Heer (2012) insan kodlayıcılardan tez özetlerini özetleyen anahtar k elimeleri yazmalarını istedi. Kodlayıcıların, faydalı anahtar kelimeler olarak isim ö beklerini seçme olasılığının çok yüksek olduğunu buldular. İsim öbekleri yalnızca özetlerdeki tüm ifadelerin %13'ü, bunlar için hesaplandı 65% oranında insanlar tarafından seçilen anahtar kelimeler (Chuang, Manning ve Heer, 2012, s. 8). Topluluk tarafından sağlanan kelime bulutu görselleştirmelerinin derecelendirmeleri benzer şekilde, insan y argıçların ifadelerle birlikte olan kelime bulutlarını daha bilgilendirici bulduğunu göstermiştir.

Doclingo https://www.doclingo.ai



Şekil 9.1. Birlik Durumu
korpusundan yabancı kelimesini içeren cümlelerin kelime bulutları. Sol: Önceki cümleler 1917. Doğru: 1917 ve sonrasındaki cümleler.

Bu durumun nasıl çalışacağını göstermek için, bir önceki örneklerimi zden birine geri dönüyoruz. Rule, Cointet ve Bearman (2015) tarafından yapılan, dış politikanın State of the Union konuşmalarında tanımlanma şeklinin 1917'de, ABD'nin II. Dünya Savaşı'na girişi sırasında değiştiği i ddiasını inceliyoruz. Rule, Cointet ve Bearman (2015), “devlet yönetimi” olarak adlandırdıkları konusal kümenin azaldığını ve bunun yerine “

dış politika” konusal kümesinin geçtiğini gösteriyor. Bunu basit bir k elime sayımı analizi ile araştırmak için, State of the Union korpusundan "foreign" kelimesini içeren tüm cümleleri çıkarıyoruz ve bu cümlelerin 1 917 öncesi ve sonrası ürettiği kelime bulutlarındaki farklılıkları inceliyor uz. Şekil 9.1 , Bölüm 5'te olduğu gibi tüm unigramların bir kelime bulut unu gösteriyor, ancak şimdi zaman içinde 1917 öncesi kullanımlar sold a ve 1917 sonrası kullanımlar sağda olacak şekilde ayrılmıştır (not: her c ümlede yapısal olarak bulunduğu için "foreign" kelimesini kendisi her d iğer kelimeyi domine etmesin diye çıkardık).Bulduğumuz sonuçlar, Rule , Cointet v

e Bearman(2015)'in dış politikanın çok daha baskın bir terim haline geldiği yönündeki yüksek düzeydeki bulgusunu yansıtmaktadır.

1917 (polici 1917 sonrası en yaygın kelime) iken devletlerin tartışılması belki de 1917'den önce daha yaygındı. Ancak bu y eniden ifade etmenin ötesinde, bu iki dönemde kelimelerin kullanımını a yırt etmek daha zordur.

Şekil 9.2'de, Şekil 9.1'in bireysel token'ları yerine yeni tanımlanan isim öbekler ini kullanarak aynı figürleri oluşturuyoruz. Bu yeni figür, tartışmasız olarak önem li ölçüde daha bilgilendiricidir. Bu grafikten elde edilen temel sonuçlardan biri, 1 917'den sonra yabancı petrol ve yabancı yardımlar hakkında artan tartışmadır.

Doclingo https://www.doclingo.ai

1917'den sonra. Ayrıca, ABD dış politikasının değişen coğrafi odaklanmasını ya nsıtır - ilk kelime bulutu Büyük Britanya kelimesini içerirken, ikinci kelime bulut u Orta Doğu kelimesini içermektedir.



Şekil 9.2. Yabancı kelimesini içeren Birlik Durumu korpusundan cümlelerin isim öbeği k elime bulutları. Solda: 1917'den önceki cümleler. Sağda: 1917'den sonraki cümleler.

Burada, kelime grubu tespiti ve daha genel olarak, sözcük türü etiketlemesi için sadece bir örnek göstermiş olduk. Sözcük türü etiketlemesi oldukça hızlıdır ve - ha ber makaleleri gibi resmi metinler için - oldukça yüksek bir doğruluğa sahiptir. Bu nedenle, bu tekniklerin sosyal bilimsel kullanımı için keşfedilmeyi bekleyen daha fa zla fırsat olduğunu öngörüyoruz.

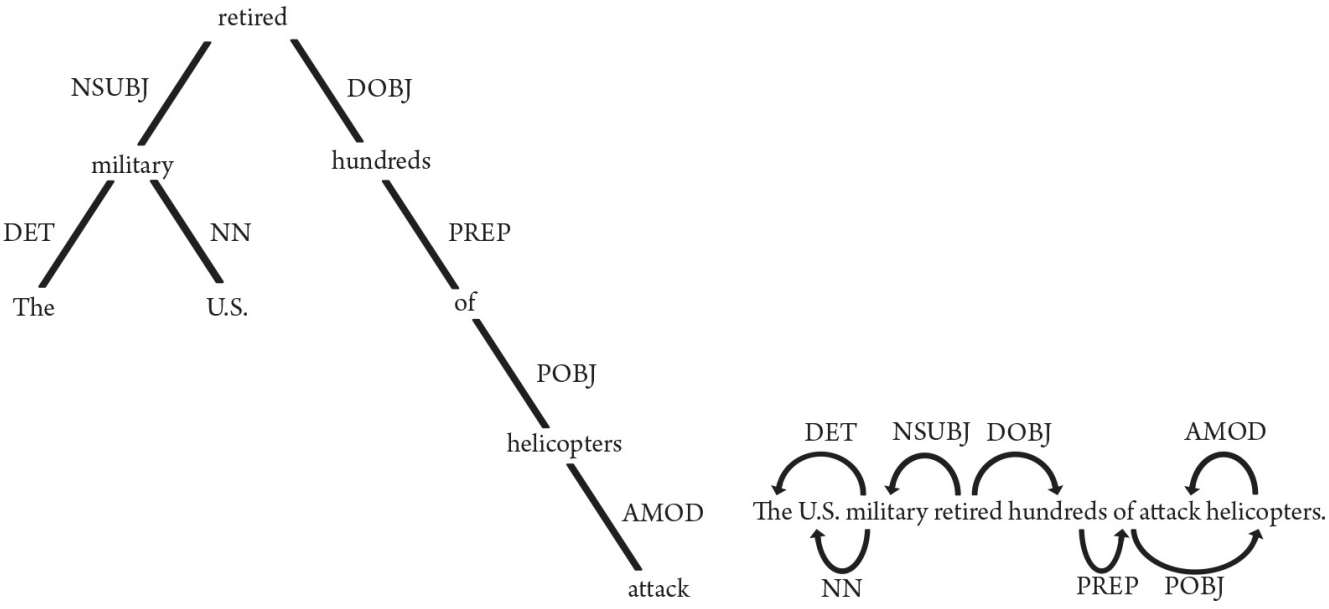
Doclingo https://www.doclingo.ai

9.3 İsimlendirilmiş Varlık Tanıma

Doğal dil işleme alanında, sözcük türü etiketleme, isimlendirilmiş varlık tanıma (NER) gibi diğer süreçler için önemli bir girdi sağlar. NER, metinler içindeki insanlar, organizasyonlar ve yerler gibi varlıkları etiketleme sürecidir (Manning ve diğ., 2014). Bazı özel bağlamlarda, bu sistemler tarih, ilaç isimleri veya kimyasal tepkimeler gibi ek bilgileri etiketlemek için öğrenilebilir. Sözcük türü etiketleme gibi, modern isimlendirilmiş varlık tanıma sistemleri genellikle sıralı makine öğrenimi modellerine dayanmakta ve resmi yazım gereksinimlerinin olduğu ortamlarda kutudan çıktığı gibi oldukça doğru olmaktadır.

Jaros ve Pan (2018), Çin'deki siyasi elitler arasındaki güç dağılımını daha iyi anlamak için resmi Çin gazetelerinde isimlendirilmiş varlık tanıma yazılımı kullanmaktadır. Birçok kişi, Kasım 2012'de göreve geldikten sonra Genel Sekreter Xi Jinping'in, selefi Hu Jintao'dan daha fazla güç konsolide ettiğini tahmin etmişti (Mulvenon, 2015). Diğer uzmanlar, Partinin, Çin'deki hükümete göre daha fazla güç konsolide ettiğini (Lampton, 2015) ve anti-Batı duygusunun Çin'de artış gösterdiğini gözlemlemiştir.

Ancak, güç ölçmek zordur, özellikle de Çin'de, burada siyasetin büyük bir kısmı kapalı kapılar ardında gerçekleşmektedir. Jaros ve Pan (2018), önceki araştırmaların Çin'deki resmi gazetelerin genellikle CCP içindeki güç konsolidasyonunu yansıttığını gösterdiğini belirtmektedir, çünkü bu gazeteler vatandaşlara ve elitlere, gazeteyi kontrol edenlerin bağlılıklarını işaret eder (Shih, 2008; Huang, 2015; Zeng, 2016). Bu nedenle, daha fazla güce sahip olan varlıklar, daha az güce sahip olanlardan daha sıkgazetelerde bahsedilecektir.



Şekil 9.3. Bağımlılık ayrıştırmasının iki farklı temsili

Doclingo https://www.doclingo.ai

“ABD ordusu yüzlerce saldırı helikopterini emekliye ayırdı.”

Gücü ölçmek için, Jaros ve Pan (2018) Çin resmi eyalet gazeteleri nde NER kullanarak Parti gazetelerinde adı geçen tüm kişi ve kurul uşları tanıdılar. Daha sonra, bir varlığın resmi gazetelerde ne kadar sıklıkla bahsedildiğini, diğer tüm varlıkların bahsedilme oranı olar ak kullanarak gücü ölçtüler. Resmi gazetelerin birçok varsayılan eği limi yansıttığını buldular. Xi Jinping, Parti gazetelerinde, görevde ol duğu süre boyunca selefinden çok daha sık bahsedildi. Parti kuru mları da Xi'nin görevde olduğu süre boyunca öne çıktı. Ancak, bekl enmedik bir şekilde, yabancı kuruluşların bahsedilmesinde bir azal ma olmadığını gösterdiler.

Doclingo https://www.doclingo.ai

9.4 Bağımlılık Analizi

Konuşma parçalama ve adlandırılmış varlık tanıma, bireysel kelimeleri e tiketler, ancak kelimelerin cümlenin bütününe nasıl ilişkili olduğuna dair bil gi çıkarmak da mümkündür. Bağımlılık analizi, kelimelerin ve ifadelerin bir cümle içinde birbirleriyle sözdizimsel olarak nasıl bağlantılı olduğunu açıkl ayan yönlendirilmiş bir grafiği çıkarmak sürecidir (Jursfsky ve Martin, 2009, Bölüm 14). Bağımlılık analizi, bir kök kelimeyi (genellikle ana fi il) tanımlar ve ardından diğer kelimeleri o kelimeye ve birbirlerine g öre açıklar. Örneğin, "ABD ordusu yüzlerce saldırı helikopterini eme kliye ayırdı" cümlesinde, cümlenin nominal öznesi "ABD ordusu" ve c ümlenin ana fiili "emekliye ayırdı"dır; bu, cümlenin kökü olarak tanı mlanır. "Emekliye ayırdı" kökünün doğrudan nesnesi "yüzlerce saldır ı helikopteridir." Nominal özne ve doğrudan nesne daha sonra bağı mlılıklara ayrılabilir; bu, Şekil 9.3'te gösterilmiştir.

Bağımlılık analizleri, hangi kelimelerin diğer kelimeleri değiştirdi ğine dair bilgi içerdiğinden, duygu belirlemeye çalışırken son derec e faydalı olabilir (Socher ve diğ., 2013), anlamsal ilişkileri tanımlamak aktörler ve konular arasındaki (Van Atteveldt, Kleinnijenhuis ve Ruigrok, 2008), veya bir metnin siyasi karmaşıklığını ölçmek (Benoit, Munger ve Spirling, 2019). Ancak, sosyal bilimciler için bağımlılık ayrıştırma bir amaç değil, daha geniş bir bilgi çıkarım görevleri yelpazesini mümkün kıldığı için önemlidir.

Doclingo https://www.doclingo.ai

9.5 Daha Geniş Bilgi Çıkarma Görevleri

Bilgi çıkarma, bir metinden belirli, yapılandırılmış bilgi parçaların ı tanımlama sürecidir. Bu kitapta yer alan birçok yaklaşım, bir metn in belge düzeyindeki özelliklerini tanımlamaya odaklanırken, bilgi ç ıkarma genellikle üç tür bilgi ile ilgilidir: *entiteler* bir metinde, *varlı klar arasındaki* ilişkiler ve *bu varlıklar arasında meydana gelen* ol aylar. Aslında, bilgi çıkarma görevlerinden bir örneği zaten gördük - adlandırılmış varlık tanıma.

İlişki çıkarma, belirli varlıklar arasındaki ilişkileri tanımlama sürecidir; ö rneğin Barack ve Michelle Obama'nın evli olduğu, Washington D.C.'nin A merika Birleşik Devletleri'nin başkenti olduğu, Mark Zuckerberg'in Faceb ook'u kurduğu veya Hamilton, Madison ve Jay'in Federalist Papers'ın yaza rları olduğu gibi. İlişki çıkarma görevlerinin sonucu genellikle varlıkları sa bit sayıda alana yerleştiren bir gerçekler listesidir.

Üçüncü geniş bilgi çıkarımı türü, olayları bulmakla ilgilidir. Olay çıkarımı, genellikle iki veya daha fazla varlık arasında belirli bir za man diliminde meydana gelen bir eylemi ifade eder. İlişkiler genellikle iki belirli varlık arasında mevcutken, olaylar genellikle zaman, yer, do ğa ve olayda yer alan katılımcılar gibi geri kazanmak istediğimiz çok d aha fazla bilgiye sahiptir. Olay çıkarımının bir dalı, olayı tanımlamak içi n doldurulması gereken belirli alanlara sahip şablonlara bakar.

Bu tekniklerin çoğunu bir araya getiren bir örnekte, Keith ve ark. (2017) haber makalelerinden polis tarafından öldürülen kişilerin isimlerini çıkarmak için NER ve bağımlılık ayrıştırması kullanmaktadır.

Polis tarafından öldürülen bireylerin federal veri setleri eksiktir ve bu ned enle, polis tarafından öldürülen bireylerin bir veri setini oluşturma çabala rı, haber makalelerinden isimlerin manuel olarak çıkarılmasına dayanma ktadır. Keith ve ark. (2017) bu süreci otomatikleştirmeyi hedeflemektedir. Öncelikle, tüm potansiyel hedefleri çıkarmak için NER kullanırlar. Ardınd an, her cümleden hedefi içeren bağımlılık yollarını çıkarırlar. Bu bağımlılı k yollarını diğer özelliklerle birlikte kullanarak, belirli bir olayı -hedefin pol is tarafından öldürüldüğünü- belirten cümleleri tanımlamak için modeller ini eğitirler. Altı aylık bir test süresi boyunca, Keith ve ark. (2017) The Gua rdian'ın "The Counted" veritabanında yer almayan 39 polis tarafından öld ürülen bireyi tanımlamıştır ve bu otomatik yaklaşımın mevcut veri setleri ni iyileştirmek için kullanılabileceğini göstermektedir.

SİYASİ OLAY VERİLERİ

Olay çıkarımının son derece zor bir görev olmasına rağmen, sosyoloji ve si yasi bilimlerde metin olarak verinin en erken örneklerinden biri olmuştur.

Doclingo https://www.doclingo.ai

Akademisyenler, 1980'lerden beri sosyal ve siyasi aktörler arasındaki karmaşık etkileşimleri kodlamaya çalışıyorlardı (Schrodt, 1986; Franzosi, 1989; Schrodt ve Gerner, 1994; King ve Lowe, 2003; Schrodt, 2006). Bu etkileşimler—birinin uluslararası alanda bir başkasına bir şey yaptığına dair kayıtlar—tahmin etmede faydalı olduğu gösterilmiştir (Brandt, Freeman ve Schrodt, 2011; Bagozzi, 2015; Chadefaux, 2017; Chiba ve Gleditsch, 2017). Erken sistemler esasen sözcük türü etiketlemeye dayanırken, modern sistemler bağımlılık ayrıştırması kullanmakta ve olay hakkında önemli ölçüde daha fazla bilgi kaydetmeye çalışmaktadır (Beieler ve diğ., 2016; Halterman, 2017; Lee, Liu ve Ward, 2019; Halterman, 2019).

Erken yaklaşımlar, olası aktörlerin (Rusya ve Amerika Birleşik Devletleri gibi) ve olayların (saldırı gibi) sabit bir sözlüğü ile desen eşleştirme kullanarak yön bilgilerini yakalamıştır. Bu yaklaşımlar genellikle karmaşık cümle yapıları tarafından engellenmiştir; örneğin, “Bağdat’taki ABD büyükelçiliğine saldırı düzenlendi.” Bağımlılık ayrıştırması, cümlenin yapısını yakaladığı için bir yol sunar; bu, analistin 1) cümlenin kökü olarak saldırıyı içerip içermediğini ve 2) saldırıyı gerçekleştiren aktörü tanımlamasına olanak tanır, bu aktör saldırı kelimesinden hemen önce görünmese bile. Cümle daha sonra, desen eşleştirme tekrar kullanılabilmesi için etkili bir şekilde yeniden düzenlenebilir (Beieler, 2016). Bu, sözlüklerin oluşturulması ve sürdürülmesinin pahalı olduğu merkezi sorunu hala bırakmaktadır; olay sözlükleri genellikle yüzlerce olay türü için her türlü ifadeyi kapsamaya çalışmaktadır. Bazı çalışmalar, keşif bölümlerinde tartışacağımız bazı teknikleri kullanarak eylemleri otomatik olarak öğrenme yeteneğini araştırmıştır (O’Connor, Stewart ve Smith, 2013).Bu, sosyal bilimler akademisyenlerinin en son doğal dil işleme tekniklerini kullanarak sanatı ileriye taşımak için aktif olarak çaba gösterdiği bir alandır (Salam ve diğ., 2020; Halterman,

2020).

Bu sistemlerin gelecekteki açık bir zorluğu, farklı medya türlerini entegre etmektir. Protestoların incelenmesinde, Zhang ve Pan (2019) sosyal medyadan Çin'deki protesto olaylarını çıkaran bir sınıflayıcı oluşturmuş ve metin ile fotoğrafların, yalnızca metinden daha fazla bilgi sağladığını bulmuşlardır.

Doclingo https://www.doclingo.ai

9.6 Sonuç

Bu bölümde, dili bir dizi olarak ele alan bir dizi ilgili görevi ele aldık - bu dizinin kopyalarını bulmaktan, bu dizinin ayrıştırmalarını kullanarak değerli bilgiler çıkarmaya kadar. Burada ele alınan birçok teknik, Bölüm 5–8' de ele alınanlardan oldukça farklıydı, ancak konuşma parçası etiketleme ve ayrıştırma gibi teknikler sosyal bilimlerde nispeten az kullanılmaktadır.

Bu, Temsil konusundaki bölümümüzün de sonucudur. Bu bölümde, metni çok çeşitli yollarla sayılara dönüştürmeyi gösterdik. Metin verisi yöntemlerinin çoğunun amacı, metin birimi için bir ölçüm tahmin etmek ve bu ölçümü, ilgi miktarına ulaşmak için tüm korpusu yansıtacak şekilde toplamak. Temsil, metindeki hangi bilgilerin saklanacağına ve hangilerinin atılacağına dair bir seçimdir ve bu nedenle, belirli araştırma sorusu ile araştırmacının süreçteki konumu ile içsel olarak bağlantılı olacaktır.

Eğer metnin ne içerdiğini bilmiyorsanız ve henüz ilginizi çeken bir sorunuz yoksa, metinleri temsil etmenin birkaç farklı yolunu denemeyi deneyebilirsiniz. Bu, kitabın bir sonraki bölümünde konuşacağımız keşif yöntemlerini uygulamanıza yardımcı olabilir. Bu yöntemler, verileri tanımlamaya, yeni kavramlar keşfetmeye ve araştırma sürecinizin bir sonraki adımlarını yönlendirmeye yardımcı olabilir. Keşif aşamasında metinleri temsil etmek, ilginç metinleri okumak veya anlamlı olabilecek metin gruplarını belirlemenize yardımcı olabilecek modelleri uygulamanıza yardımcı olabilir. Bu aşamada metni temsil etme şekliniz ne kadar yaratıcı olursa, corpus'u veya ilginizi çeken sosyal bilimler sorusunu organize etmenin veya düşünmenin yeni yollarını keşfetme olasılığınız o kadar artar.

Öte yandan, eğer analiziniz için nüfusunuzu ve ilginizi çeken miktarları zaten biliyorsanız, o zaman metnin temsil şekli, ölçmek istediğiniz miktar tarafından yönlendirilmelidir. Diğer bir deyişle, metinden hangi bilgiyi ölçmek istiyorsunuz, ilginizi çeken miktarlar ne olacak? Metinler karmaşıktır - anlamı kelime seçimi, ifade biçimi ve kavramların organizasyonu aracılığıyla kodlar. Ancak, metnin tüm karmaşıklığı herhangi bir özel analiz için gerekli değildir ve bu karmaşıklığı korumaya çalışmak başarı için bir engel olabilir. Metinlerin nicel analizleri genellikle büyük bir belge setinin birkaç genel özelliğini tanımlamaya odaklandığından - samanlıkta iğne aramak yerine samanı tanımlamak - analizlerimiz ve ilginizi çeken miktarlar genellikle metinlerden tüm bilgileri korumamızı gerektirmeyecektir. Karmaşıklığı azaltmak

Doclingo https://www.doclingo.ai

metin, analizin yalnızca elindeki görev için önemli olan metin yönlerine odakla nmasına izin vermek için anahtar bir adımdır.

---

[1]Wong, Edward. 2014. “Yeni Çin'de, 'düşmanca' Batı hâlâ alay konusu,” *New York Times*, 11 Kasım.

Doclingo https://www.doclingo.ai

BÖLÜM III
Keşif

Sosyal araştırmalar genellikle kullandığımız temel kavramların, ampirik dünyayı organize etmek için verildiği gibi sunulmaktadır. Yakın tarihli bir araştırmadan bir örneği düşünün. McGhee ve ark. (2014), kapalı bir ön seçimden—sadece bir partinin üyelerinin oy kullan abildiği—açık bir ön seçime—herhangi bir uygun seçmenin oy kullanabildiği—geçişin e yalet yasama organlarındaki ideolojik kutuplaşmayı nasıl etkilediğini incelemektedir. Bu sorunun yüzeydeki anlamı açıktır ve Amerikan politikasını reforme etme ile il gili derin sorularla örtüşmektedir. Ancak aynı zamanda dünyanın belirli bir organ izasyonunu da ima etmektedir. Ön seçimler, kimin oy kullanma hakkına sahip ol duğuna göre kategorize edilmelidir ve yasama organı üyeleri ideolojik bir alana yerleştirilmelidir.[1]

Bölüm 2'de, King, Pan ve Roberts'ın (KPR) Çin'deki sansürü incelemek içi n geldikleri dolambaçlı yolu anlattık. Onların çalışması, Çin hükümetinin so syal medya paylaşımlarını, hükümete yönelik eleştiriler temelinde değil, kol ektif eylem potansiyeli temelinde sansürlediğini göstermiştir. Bu çalışma, s ansür, hükümete eleştiri, kolektif eylem potansiyeli ve analizlerinde kullanıl an çeşitli paylaşımların konuları gibi çok sayıda kavramı tanımlamaya daya nmaktadır. Elbette, sosyal medya paylaşımlarının organize edilmesinin baş ka yolları da olabilirdi. Gerçekten de, daha sonra akademisyenler, eleştirini n daha ince bir kategorize edilmesinin, Çin hükümetinin sansür politikaları nı anlamada açıklayıcı gücü artıracağını savunmuşlardır (Shao, 2018; Gueorguiev ve Malesky, 2019). Sansür dışındaki diğer sorular için, örneğin kamuoyu analizi, araştırmacılar aynı gönderiler için tama men farklı bir organizasyon geliştirebilirler.

Bu durumlarda ve diğer birçok durumda, kavramlar araştırma projesinin t üm yapısını oluşturur. Hangi önlemlerin inşa edilmesi gerektiğini ve bu önle mlerin neyi başarmaya çalıştığını tanımlar; hangi sorular sorulabilir ve bir ce vabı neyin oluşturduğunu; ve nihayetinde, dünyayla ilgili hangi sonuçların el de edilebileceğini belirler. Ancak, nicel araştırmacılar geleneksel olarak kavra mlarını incelemek için çok az zaman harcamışlardır - onlara nasıl ulaştıkları v e dünyayı organize etmenin alternatif yollarının olup olmadığı. Bu, kavramlar ın araştırma bulgularına entegre olduğu için bir utançtır. Sanki

Doclingo https://www.doclingo.ai

sosyal bilimlerin yeni kavramlar geliştirme konusunda bir düşünce yolu yokmu ş gibi değil. Yeni kavramların yaratılması için metodoloji geliştirme konusunda nitel araştırmalarda uzun bir gelenek vardır. Temellendirilmiş teori (Corbin ve Strauss, 1990) ve çıkarımsal analiz (Tavory ve Timmermans, 2014), iki örnek ver mek gerekirse, ilk saha notlarından ve görüşmelerden kavramların ve yeni hip otezlerin üretilmesine yönelik ilkesel bir şekilde hareket etmek için yinelemeli ç erçeveler sağlar. Birçok akademisyen, bu nitel metodolojileri geliştirmek için ni cel yöntemlerin kullanılmasına yönelik çerçeveler sunmuştur ve bu, geleneksel olarak nitel bir görev olan alanda nicel yöntemler için bir yer açmaktadır (Bau mer ve diğ., 2017; Nelson, 2020; Karell ve Freedman, 2019).

Bu bölümde, gözlemleri organize etmenin yeni yollarını keşfetme ve uygulama metodolojisini sunuyoruz. Özellikle, metinlerin, keşif için nicel yöntemlerin ve dikka tli okumanın kombinasyonunun, dünyayı organize etmenin yeni yollarını ortaya çık armayı kolaylaştırabileceğini, mevcut organizasyon şemasının önemini yeniden vur gulayabileceğini ve yeni teorik yenilikleri kolaylaştırabileceğini gösteriyoruz. Yeni o rganizasyon, yeni miktarları ölçmemize, teorileri rafine etmemize, ilişkileri çıkarma mıza ve hatta politika önerileri sunmamıza yol açar. Bu süreç, uzun süredir ilgi çek en sorular hakkında yeni kanıtlar sağlamak ve tamamen yeni soruları düşünmek içi n tekrar tekrar tekrarlanabilir.

Bölüm 10: Keşif İlkeleri , keşif için temelimizi sağlar. Keşif için çerçevemizi oluşturan sonraki dört bölüm, yeni kavramlar ı keşfetmek için en etkili olduğunu düşündüğümüz dört yöntem sı nıfını vurgular: ayırt edici kelimeler, kümeleme yöntemleri, konu m odelleri ve gömme teknikleri.

Keşifteki merkezi bir zorluk, metinlerin bir organizasyonunu anlamaktır. B u, bir organizasyonun dünyada mevcut olmasından (örneğin, belgeleri konu şmacıya göre organize etmek) veya tartıştığımız denetimsiz yöntemlerden bi rini kullanarak yeni bir organizasyon keşfetmiş olmamızdan kaynaklanabilir. Organizasyonun nasıl ortaya çıktığına bakılmaksızın, genellikle bir organizas yonun neyin ayırt edici olduğunu tanımlamak isteriz, bu da onu anlamamıza yardımcı olur. Bölüm 11: Ayırt Edici Kelimeler, belirli bir belge grubunun ora ntısız bir şekilde kullandığı kelimeleri tanımlamak için yöntemleri açıklar.

Sonraki üç bölüm, metinlerin yeni organizasyonlarını keşfetmenin f arklı yollarını tanımlamaktadır. Denetimsiz kümeleme analizi yönteml eri, Bölüm 12: Kümeleme, metinlerin bir *partition* üretir: her belge *K* kategorilerinden birine atanır. Kategorilerin önceden bilindiğini varsa ymak yerine, denetimsiz kümeleme analizi yöntemleri, benzer belgele rin paylaşması için belgeleri atamaya çalışarak kategorileri keşfeder.

Doclingo https://www.doclingo.ai

Bir küme ve kümelerin birbirinden mümkün olduğunca farklı olmasını sağlar. Bölüm 13: Konu Modelleri , belgelerin tüm kategorilerde orantılı üyeliğe sahip olduğu *K* kategorilerinin bir setini keşfetmek için ilgili bir yöntemler sınıfını tanımlar (birinin tamamen üyesi olmak yerine). Bu kavramsal farklılık, konu modellerin in karmaşık tema karışımlarını kapsayan belgeleri daha sadık bir şekilde tem sil etmesine olanak tanır. Bölüm **14: Düşük Boyutlu Belge** Gömme , bir belgeyi reel değerli bir alanda konumlandıran son yak laşım setini sunar. Kümeleme (bir kategoride üyelik) ve konu mode llerindeki (kategoriler arasında orantılı üyelik) kısıtlı temsillerin aksi ne, gömme konumları kısıtlı değildir. Bu, bu teknikleri genellikle gö rselleştirme için (gömme düşük boyutlu olduğunda) veya belgeleri n benzerliğini hesaplamak için (gömme yüksek boyutlu olduğunda) özellikle yararlı hale getirir. Bu üç yaklaşım, insan okuyuculara bel irgin olmayabilecek metinlerdeki temel sistematik kalıpları çıkarara k keşfi kolaylaştırmak için yeni organizasyonlar önermektedir!

Bu dört yöntem sınıfının her biri, kendi büyük el yazması konusunu oluş turabilir (ve birkaç tanesi zaten var). Burada, her yöntem sınıfının arkasınd aki sezgiye odaklanıyoruz ve bu belirli tekniklerin kavramsal keşfi nasıl dest ekleyebileceğini açıklıyoruz. Okuyucu, belirli bir yöntem sınıfı için bir sezgiy e sahip olduğunda, bu, genel sınıftaki diğer modellere genelleştirilebilir (ya zma zamanı itibarıyla henüz var olmayan modeller dahil).

[1]Bu girişin bazı bölümleri Grimmer, Roberts ve Stewart (2021)'dan alınmıştır.

Doclingo https://www.doclingo.ai

BÖLÜM 10

Keşif İlkeleri

Bilimsel araştırmanın geleneksel kurallarının çoğu, verilerin kıt olduğu, ancak düşünmenin nispeten ucuz olduğu bir zamandan gelmektedir. V eri çok sınırlı olduğunda, teorileri değerlendirmek için mümkün olduğu nca fazla bilgi korumak adına verileri incelemeden önce teorileştirmek önemlidir. Düşüncenin mutlak maliyeti değişmemiştir, ancak veriler artı k daha kolay erişilebilir. Bu veri seli, bir belge setinde keşif için veri oda klı yaklaşımlar kullanmamıza ve ardından iddiaları geliştirmek ve değerl endirmek için farklı bir belge seti kullanmamıza olanak tanır. Bu yaklaşı m, veri madenciliğinin yaygın eleştirilerini -dairesel olacağı, aşırı uyum s ağlayacağı veya anlamsız olacağı- önler. Aşağıda açıklayacağımız gibi, b ir kavram elimize geçtiğinde, o bizimdir ve nasıl geliştirildiği önemsizdir . Önemli olan, kavramın sorunumuzu incelemenin içgörülü bir yolunu s ağlaması ve ileride taze veriler kullanmamızdır. Kavramın köken bağıms ızlığı, en iyi içgörüleri üreten herhangi bir tekniği kullanmamıza olanak tanır; temel varsayımlar hakkında endişelenmeden.

Bu bölüm, keşif için hesaplamalı yaklaşımımızı yönlendiren dört ilkeyi özetlem ektedir. Ardından, kavramların sadece bir çalışma parçasını değil, bir alanın tama mının araştırmasını nasıl şekillendirebileceğine dair bir örnek sunuyoruz. Keşfi a çıkça çalışmanın neden bu kadar önemli olduğuna dair bir argümanla sonuçlanıy oruz.

Doclingo https://www.doclingo.ai

10.1 İlke 1: Bağlamın Önemi

> *Veri olarak metin modelleri, teori ve maddi bilgiyi tamamlar. Bağlamsal bilgi, hesaplamalı keşifler yapma yeteneğimizi artırır.*

Bu bölümdeki yöntemler, araştırmacıya yardımcı olmak için tasarlanmıştır; ve rileri organize etmenin yeni yollarını önermek veya mevcut organizasyonların ve rilerde mevcut olduğunu doğrulamak için. Ancak, bu bölümde sunduğumuz yön temler, maddi bilginin yerini almaz. Başlangıçtan itibaren net olmak istiyoruz: Sosyal yapılar hakkında dikkatli bir çalışma ve derin bilgi için bir alter natif yoktur. Bu, "Teorinin Sonu: Veri Selinin Bilimsel Yöntemi Geçers iz Kılıyor" (Anderson, 2008) gibi makalelerdeki iyimser geleceği savu nanların iddialarını ciddiye alırsak şaşırtıcı olabilir.

Bu açıklamalar, makine öğrenimi algoritmalarının gücünü abartmakta ve nitelik sel insan analizinin önemini küçümsemektedir. Herhangi bir modeli uygulamadan önce, analiz edilecek ilginç verileri tanımlamamız gerekiyor; bu da maddi bilgi gere ktiriyor. Tartıştığımız herhangi bir modelin çıktısını yorumlamak, mevcut durumu d erinlemesine anlamayı gerektirir. Ve herhangi bir modelden elde edilen bulgularla ne yapacağımızı bilmek - ve bu bulguların dünyayı anlama şeklimizi nasıl revize etti ği - hala bir organizasyon teorisine ve durumumuz hakkında bilgiye sahip olmamızı gerektirir.

Örneğin, nitel literatürde genellikle kaçırma analizi olarak biline n, şaşırtıcı bir kategori, desen veya kavramı tanımlamak. Bunu, Böl üm 13 Karell ve Freedman (2019)'in analizinde Afgan radikal gruplar tarafından üretilen belgeleri tanımak, şaşırtıcı bir kategoriy i tanımak için mevcut radikal retorik teorik organizasyonlarının farkında olmayı g erektirir. Benzer şekilde, Bölüm 11 Nelson (2020)'in feminist organizasyonlar tarafından üretilen literatürü analiz etmek için hesapl amalı temellendirilmiş teoriyi kullanışını tanımlıyoruz. Nelson'un bu organizasy onların coğrafi yapısını anlaması, hesaplamalı yöntemleri kullanarak mevcut çe rçevelerin yapamadığı yeni ayrımları aydınlatmasına olanak tanır.

Bu bölümdeki yöntemleri geleneksel teorileştirmenin yerini alan bir şey olarak görmek yerine, tanıttığımız yöntemlerin geleneksel sosyal bilim teorisi oluşturma s ürecine en iyi şekilde tamamlayıcılar olarak düşünülmesi gerektiğini savunuyoruz. Teorileştirme ve keşfi birleştirerek, verilerde keşfedilen kategoriler ışığında teoriler imizi geliştirebiliriz. Bu bölümdeki yöntemler bu nedenle katkıda bulunur

Doclingo https://www.doclingo.ai

bilimsel sürecin yinelemeli doğasına, hedefin teori geliştirme olduğu ve derin öznel bilginin çıkarım için bir ön koşul olduğu anlamına gelir. Öznel bilgiyi değiştiremezler, ancak öznel bir durum hakkında yeni b ulguların keşfini kolaylaştırabilir ve önceki teorilerdeki gerilimleri vu rgulayabilirler.

Doclingo https://www.doclingo.ai

10.2 Prensip 2: Gerçek Doğru Yok

Gerçek doğru kavramsallaştırması yoktur; bir kavram sabitlendiğinde, onun doğru v eya yanlış olduğu hakkında anlamlı bir şekilde konuşabiliriz.

"Gerçek" kavramsallaştırmayı tartışmak pek anlamlı değildir çünkü verilerimizin farklı organizasyonları, dünyayı görmenin farklı yollarını i ma eder. Belgeleri gruplamanın tek bir doğru veya yanlış yolu yoktur. Örneğin, metinleri konularına, tonlarına veya yazara göre organize ed ebiliriz. Hangi kavramsallaştırmanın "doğru" olduğunu sormak zordur çünkü farklı organizasyon şemaları, farklı soruları yanıtlamak için dah a veya daha az yararlıdır.

Verilerimizi gruplamanın gerçek bir yolu yokken, bu, verilerin tüm organ izasyonlarının tüm görevler için eşit derecede yararlı olduğu anlamına gel mez. Aşırı bir örnek vermek gerekirse, bu kitabın dizini, belirli bir girişi kola yca bulmayı sağlamak için alfabetik olarak sıralanmıştır, ancak bu, bu kitap ta ele alınan konuları sunmak için yararlı bir sıralama olmaz. Daha az belirg in bir seçimde, bu kitapta yöntemlerin sunumu, tekniğin temellerine göre değil, araştırma görevine göre organize edilmiştir. Bu, metnin araştırma ta sarımı bileşenlerini vurgulama ve yöntemlerin istatistiksel ve algoritmik te mellerini önemsizleştirme etkisine sahiptir - bu, kitabımız için uygun bir seç imdir ancak farklı bir kitleye yönelik bir kitap için daha az yardımcı olur. Or ganizasyonun yararlılığı, çözmeye çalıştığımız soru veya probleme bağlı ola caktır.

Bir kavramsallaşmaya ulaştığımızda, bu kavramları ölçmek için daha az ve ya daha fazla doğru yöntemler olacaktır—bu, kitabın Dördüncü Bölümü'nün konusudur. Örneğin, yöntemimizin bir belgede "eleştiri"yi ne kadar doğru ta nımladığını doğrulamalıyız ve doğrulamalıyız. Ancak hangi kategorilerin kulla nılacağı ("eleştiri" ve "övgü" ile "aşırı" ve "kısa") tamamen araştırma sorusuna bağlı olacaktır.

Doclingo https://www.doclingo.ai

10.3 İlke 3: Kavramı Yargıla, Yöntemi Değil

> *Kavramsallaşmaya ulaşmak için kullandığınız yöntem, kavramın değerini değerlendi rmek için önemli değildir—kullanışlılığı önemlidir.*

Belirli bir kavramsallaşmanın değeri, bu kavramların araştırmacının neyi başa rmasına yardımcı olduğundan gelir ve bunları geliştirmek için kullanılan yöntem den değil. Organizasyon nereden gelirse gelsin, araştırmacı organizasyon şemas ını aklında bulundurduğunda, bunu ölçümler oluşturmak, hipotezleri test etmek ve teorileri uygun şekilde güncellemek için kullanabilir. Bu anlamda—metin anali zi yöntemlerimizin genel ilkesinde olduğu gibi—keşif için "en iyi" yöntem yoktur.

Bu, bir kavramsallaşmayı değerlendirmenin tek anlamlı yolunun, belirli uygulama için ne kadar kullanışlı olduğuna dayandığını ima eder. Örneğin, organizasyonun sosyal medyada paylaşımları kısıtlarken sansürcülerin biri ncil hedefini daha iyi anlamamıza yardımcı olup olmadığını, radikal gruplar ın retoriğini veya savunuculuk gruplarının medya manzarasını nasıl şekille ndirdiğini sorabiliriz. Ancak, sosyal medya konularını organize etmenin "du ygulara göre organize etmekten" "daha iyi" olduğu gibi uygulama bağımsız bir beyan yapmanın anlamlı bir yolu yoktur. Değer, belirli uygulamadan ge lir.

Bir kavramsallaştırma için önemli olan tek şeyin herhangi bir uygulam aya olan faydası olduğu göz önüne alındığında, organizasyon fikrinin ner eden geldiğini önceliklendirmek için bir neden yoktur. Bir yandan, bu, ar aştırmacının verilerini nasıl organize edeceğine karar verirken istediği ka dar keşif yapmasına olanak tanır. Öte yandan, keşif için metodolojiyi değ erlendirmek son derece zordur. Bazı yöntemlerin verilerin organizasyonl arını keşfetmede diğerlerinden daha iyi olduğunu gösteren yazılı kanıtlar yoktur. Bir yöntemin ortalama olarak diğerinden daha iyi olduğunu göst erebilecek benzer simülasyonlar yoktur. Ve belki de en sorunlu olanı, yön temin araştırmacı için bir kez içgörüler ürettiğini göstermek - yöntemin g erçek amacı - bu yöntemin gelecekte veya diğer araştırma ekipleri için ka rşılaştırılabilir içgörüler üreteceği garantisini vermez.

Bu, yeni araştırma kavramsallaştırmalarını keşfetmeye çalışırken, araştır macıların birçok farklı yöntemi ve verileri organize etmenin birçok farklı yol unu keşfetmeye hazırlıklı olmaları gerektiği anlamına gelir. İstatistiksel yön temler ve net ve kesin varsayımlara dayanan hesaplama algoritmaları

Doclingo https://www.doclingo.ai

Temel organizasyon, verileri düzenlemenin içgörü verici yollarını sunabilir; ama ormanlarda yürüyüşe çıkmak gibi radikal bir şey de yapabilir. İyi bir organizasyonu neyin oluşturduğuna dair benzer fikirleri uygulamanın birçok yolu vardır ve kavramsallaştırmalarımızda sahip olmak isteyebileceğimiz birçok sezgisel özellik vardır. Bu özellikleri değiştirmek, verileri düzenlemenin daha ilginç ve faydalı yollarını keşfetmek için esastır. Ayrıca, modelin özelliklerinin önemli olmadığı gerçek bir anlamda vardır—yalnızca faydalı organizasyonlar üretme yetenekleri dışında. Araştırmacılar bir kavramsallaştırmaya sahip olduklarında, bunu istedikleri herhangi bir amaç için kullanabilir ve kullanmak istedikleri herhangi bir yeni veri setine uygulayabilirler.

Doclingo https://www.doclingo.ai

10.4 İlke 4: Ayrı Veri En İyisidir

> *İdeal olarak, veriler keşif için kullanıldıktan sonra, keşifleri doğrulamak/test etmek için yeni veriler lehine atılmalıdır.*

Eğer kavramsallaştırmamızı araştırma sürecinin diğer noktalarında, örneğ inölçüm ve çıkarım için kullanmak istiyorsak, kavramsallaştırmaya ulaşmak iç inkullandığımız veriler, taze toplanmış veya daha önce ayrılmış veriler içinatıl malıdır. Dış verilerin kullanımı, keşfettiğimiz kategorilerin yalnızcakeşfedildikl eri belirli veri setinin birer artefaktı olmadığını ve kategorilere ya dadimansiy onlara koyduğumuz etiketlerin, iddia ettiğimiz anlamı taşıdığınısağlar. Bu, m etni veri olarak kullanarak nedensel çıkarımlar yaparkenözellikle doğrudur. V erileri iki ayrı veri setine ayırmayı başaramazsak,kitabın ilerleyen bölümlerin de daha ayrıntılı olarak tartıştığımız gibi,temel nedensel çıkarım varsayımları nı ihlal etme riskiyle karşı karşıya kalırız.

Pratikte, metin olarak veri alanında, onaylama ve test için ayrı bir veri se ti kullanmayan birçok araştırma bulunmaktadır (beğendiğimiz, inandığımız ve/veya yazdığımız çalışmalar dahil). Belirli projelerde veriler oldukça sınırl ıdır ve keşif ile test aşamalarını ayırmanın değeri her zaman tanınmamıştır (belki de kısmen keşfin kendisi hakkında bu kadar sık konuşulmamasından dolayı). Birçok çalışma, veri setinin dikkatli doğrulaması ve araştırması ned eniyle son derece ikna edici kalmaktadır. Ancak, mümkün olduğunda, yeni keşiflerin sonuçlarını değerlendirmek için ayrı verilere sahip olmanın değer ini küçümsemek zordur, özellikle de veriyi birçok farklı teknikle keşfederke n ve burada benimsediğimiz keşif tarafsız bakış açısını kullanırken.

Doclingo https://www.doclingo.ai

10.5 ABD Kongresi'ni Kavramsallaştırma

İstatistiksel modellerin metinlerde yeni içgörüler, çıkarımlar ve teoriler n asıl kolaylaştırabileceğini motive etmek için, benzer yöntemlerin Kongre oy lama verileri temelinde bir literatürü nasıl ilham verdiği üzerine bir tartışm aya yöneliyoruz - bu, bag-of-words temsilinden çok da farklı olmayan yükse k boyutlu bir veri biçimidir. 5. Özellikle, yeni bir istatistiksel bir model kullanılarak üretilen kavramsallaştırma, ABD Kongresi'ndeki yasama organlarının davranışları hakkında yeni içgörülere yol açtı ve bu kavramsallaştırmanın do ğrudan yeni araştırma sorularına, yeni teorilere ve nihayetinde toplumun ABD Kongresi'ni n nasıl davrandığına dair daha iyi bir anlayışa yol açtığını gösterdi.

Amerikan siyasi kurumlarının akademisyenleri, yasama organlarının ç eşitli tercihlerini nasıl topladıklarını açıklamak için teoriler geliştirirler. Bu teoriler, Kongre'nin kamu politikalarını şekillendirdiği zaman ve nasıl old uğunu anlamak için gereklidir. Kongre'nin nasıl çalıştığını incelemek ama cıyla, akademisyenler, üyelerini, kurumda alınan oyları ve çatışmanın beli rgin boyutlarını kavramsallaştırmanın birçok yolunu sunmuşlardır. Her k avramsallaştırma, üyelerin, oyların ve çatışma boyutlarının kendine özgü bir organizasyonunu katkıda bulunur; bu da Kongre'nin kamu politikası o luşturma biçimi hakkında belirli bir görüşü ima eder. Örneğin, MacRae (1 965), Kongre'nin oylama kayıtlarının altında, bir yasama taslağının içeriği ne bağlı olarak ortaya çıkan altı ila sekiz oylama bloğu olduğunu savunur. Diğer kavramsallaştırmalar, 1960'larda medeni haklar meseleleri etrafın da ortaya çıkan "muhafazakâr koalisyon" gibi, ara sıra ortaya çıkan geçici koalisyonlara vurgu yapar. Amerikan politikasında, politikacıları ideolojik bir spektrum boyunca tanımlama geleneği de uzun bir geçmişe sahiptir.

Siyasetçiler genellikle değerlendirilmektedir, rakiplerinin “aşırı sol liberal”, “libe ral”, “ılımlı”, “muhafazakâr” veya “aşırı sağ muhafazakâr” olduğunu beyan ederl er veya kendilerini bu şekilde tanımlarlar. Her etiket, ideolojik spektrumda bir konuma karşılık gelir.

Modern siyasi bilimin ABD yasama organlarının oylama kayıtlarının e n önemli kavramsallaştırması, VoteView projesinden (Poole ve Rosenth al, 1997) gelmektedir. 1980'lerin başında yayımlanan öncü çalışmalarla başlayan Keith Poole, Howard Rosenthal ve işbirlikçileri, yasama oylam a verilerini sıkıştırmak için Dinamik Ağırlıklı Nominal Üç Aşamalı Tahmin (DW-NOMINATE) algoritmalarına dayalı olarak yasama organlarının ide olojik spektrumda nerede yer aldığını ölçen düşük boyutlu ölçümler gel iştirmiştir. Bu, her yasama organını iki boyutlu bir puanla özetlemektedi r; ilk boyut, genellikle tek kullanılan boyut, yasama organının ideolojik k onumuna karşılık geldiği söylenmektedir (Poole ve Rosenthal, 1985). İlk

Doclingo https://www.doclingo.ai

boyut, Şekil 10.1'de görselleştirilmiştir. DW-NOMINATE puanları ile siyasette yaygın olan mekânsal modeller arasında yakın bir bağlantı vardır. Siyasi ekonomi modelleri, aktörlerin ve politikaların bir politika alanında yer aldığını varsayar; siyasetçiler, "ideal noktasında" veya siyasetçinin diğer seçeneklerden daha fazla tercih ettiği politika alanındaki noktada yer alır. DW-NOMINATE, siyasetçilerin mevcut duruma göre ideal noktalarına daha yakın olan önerilere oy verdiklerini varsayar; bu nedenle, DW-NOMINATE'den elde edilen tahminler, yasama organlarının ideal noktalarının bir ölçüsü olarak yorumlanabilir. Böylece, mekânsal modeller ile DW-NOMINATE'den elde edilen tahminler arasında doğrudan bir bağlantı vardır.

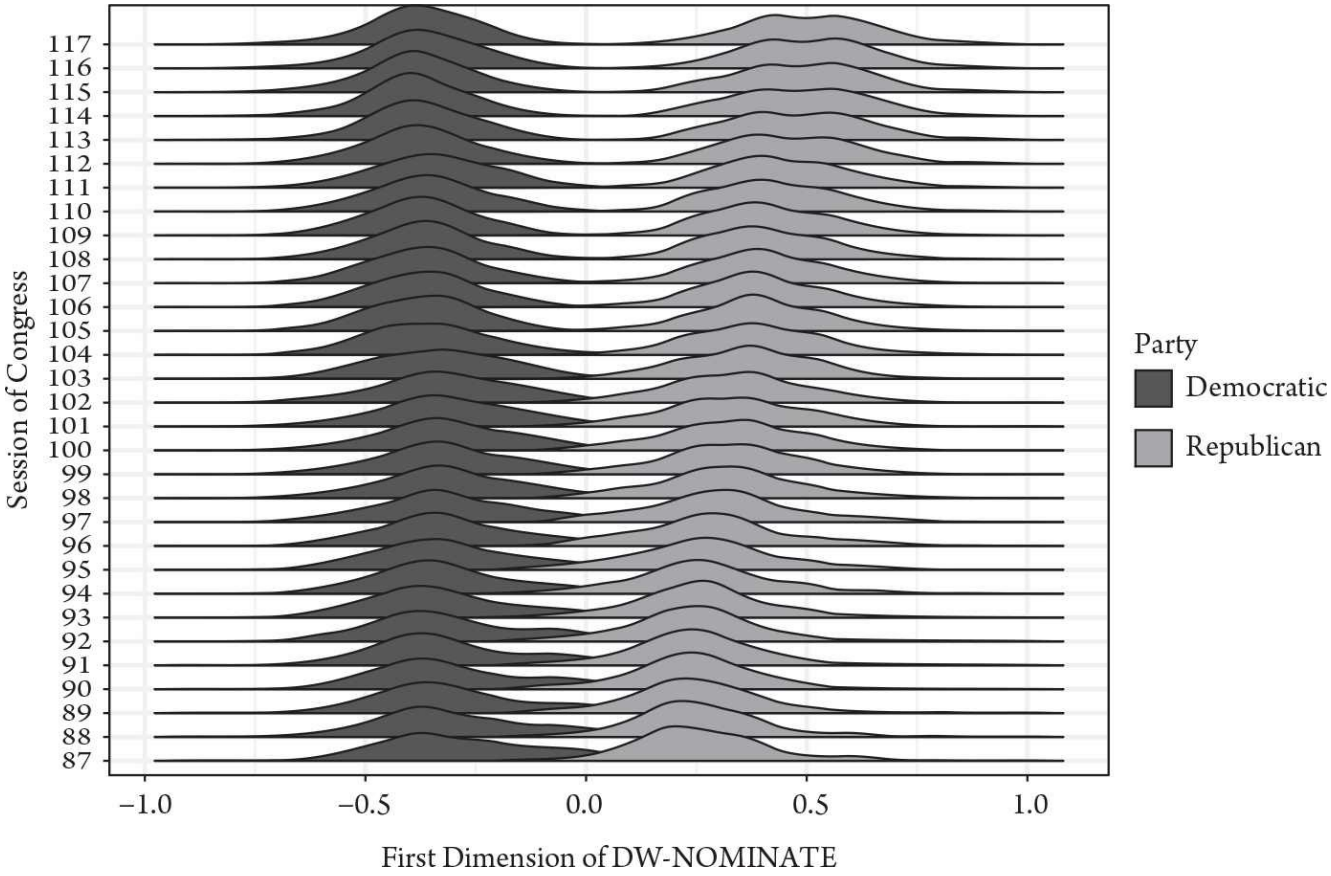
Örgüt, ilk tanıtıldığında cesur olarak değerlendirildi: Yalnızca iki boyutun Kongre içindeki çatışmanın belirgin ideolojik boyutlarını yakalayabileceğine dair derin bir şüphe vardı (Poole ve Rosenthal, 1997). Düşük boyutlu bir temsilin Kongre davranışını yakalayabileceği konusunda hemfikir olanlar arasında bile, nedenine dair derin bir ayrım vardı. Bu örgüt ve iddia için kanıt, yasama organlarının ideolojik alandaki konumlarının keşfinden geldi. Bu özel kavramsallaştırma, bir temsilcinin "ideal noktasını" vurguladı ancak Kongre çatışmasının birçok diğer özelliğini bastırdı ve tüm oylama kayıtlarını iki boyutlu bir alanda tek bir noktaya sıkıştırdı. Şaşırtıcı olmayan bir şekilde, birçok akademisyen bu kavramsallaştırmaya, Kongre çatışmasının nasıl çalıştığını anlamak için çok basit olduğu gerekçesiyle itiraz etti.

Yine de, 30 yılı aşkın bir analizden sonra, VoteView projesi Kongre üyelerinin varsayılan kavramsallaştırması haline geldi. Bu, siyasi bilimde yazılan ABD Kongresi ile ilgili hemen hemen her nicel çalışmada kullanılmakta ve Kongre'nin nasıl çalıştığını anlamanın temelini oluşturmaktadır. Hatta, ABD Kongresi'ndeki oylamanın neden bu kadar düşük boyutlu olduğunu açıklamaya çalışan yeni bir teoriye ilham vermiştir ve ABD dışındaki yasama organlarında literatürü yeniden yaratma girişimlerine ilham vermiştir (Snyder Jr., 1992). Aynı temel teknikler, ofis adaylarının (Shor ve McCarty, 2011), bağışçıların (Bonica, 2013), sosyal medya kullanıcılarının (Barberá, 2014; Bond ve Messing, 2015) ve seçmenlerin (Bafumi ve Herron, 2010) ideal noktalarını ölçmek için kullanılmıştır. Bu çalışma, oylama bilgilerini oylanan tasarının metniyle birleştirerek ideal noktaları geliştirmeyi amaçlayan bilgisayar biliminde sağlıklı bir literatür oluşturmuştur (Gerrish ve Blei, 2011,

2012; Nguyen ve diğ., 2015; Kraft, Jain ve Rush, 2016; Vafa, Naidu ve Blei, 2020). Bu teknik aracılığıyla, Kongre'nin kavramsallaştırılması diğer fenomen türlerine, diğer bilimsel topluluklara ve diğer veri modlarına yayılmıştır.

Doclingo https://www.doclingo.ai

Legislatorlerin VoteView projesinden gelen organizasyonu, tümevarım yol uyla geliştirilmiştir, ancak ABD Kongresi'nin tümdengelim teorilerini daha da geliştirmek için önemli olmuştur. Yani, DW-NOMINATE'ın boyutları önceden belirlenmemiş olsa da, yine de Kongre'nin teorik çalışmalarında hayati bir ar aç haline gelmiştir. Örneğin, Kongre'nin organizasyonu (Krehbiel, 1998), kur umlar arası pazarlık yapısının (Cameron, 2000) ve siyasi temsilin doğasının (C anes-Wrone, Brady ve Cogan, 2002) teorik yeniliklerini değerlendirmek için k ullanılmaktadır. DW-NOMINATE'ın teorik modelleri değerlendirmek için kulla nılması, diğer yasama organlarının akademisyenlerini, siyasi konuşma (Laver , Benoit ve Garry, 2003; Slapin ve Proksch, 2008) dahil olmak üzere çeşitli veri kaynaklarını kullanarak yasama organlarının ideolojik pozisyonlarının benze r ölçülerini geliştirmeye yönlendirmiştir.



Şekil 10.1. Yasama organı ideolojisinin zaman içindeki dağılımının, yasama organlarının oylama kayıtlarına dayanan DW-NOMINATE algoritması tarafından hesaplanan ilk boyut kullanılarak görselleştirilmesi.

Elbette, Kongre üyelerini ve eylemlerini organize etmenin başka öne mli yolları da var—farklı araştırma soruları ve Kongre'nin nasıl çalıştığın a dair farklı çıkarımlar öneren organizasyonlar. Örneğin, yasama organl arı liderlik pozisyonlarına göre organize edilir, daha fazla veya daha az güç sahibi komitelere yerleştirilir veya parti gruplarının üyeleri olurlar.

Doclingo https://www.doclingo.ai

Yasama organlarını bu şekilde organize etmek, farklı sorulara ve ölçümlere yol açar. Örneğin, Berry ve Fowler (2016), Tahsisat Komitesinde yer alan yasama o rganlarının kendi bölgelerine daha fazla para aktarabilip aktaramayacağını sor uyor. Diğer çalışmalar, yasama organı davranışları üzerine bir dizi kavramsalla ştırmayı içermektedir. Liderlerin nasıl güçlü hale geldiğini sorabiliriz (Powell, N. d.). Temsilci Kongre komitelerinin kurumu ne kadar temsil ettiğine dair zengin bir literatür vardır—bu sorular, yasama organlarını oturdukları komitelere ve i deolojik spektrum içindeki yerlerine göre organize etmeye bağlıdır (Krehbiel). 1990).

Diğer kavramsallaştırmalar, yasama organlarının seçmenleriyle nasıl iletişi m kurduğuna dayanmaktadır. Fenno (1978), yasama organlarını seçmenleriyle ilgilendikleri konu türlerine göre organize etmiştir. Bu bölümde geri döneceği miz bir araştırma projesinde, Grimmer (2013*b*) benzer bir senatör organizasyo nu kullanarak, retoriğini geniş ulusal konulara odaklayan senatörlerden, kendi bölgelerine aktarılan paranın kredisi için övgüde bulunan senatörlere kadar bi r spektrumda yerleştirmiştir. Bu organizasyon, yasama organlarının domuz/po litika spektrumunda nerede yer aldıkları gibi diğer önemli ölçümlere ve yasam a organlarının belirli stilleri benimseme nedenlerine, bu stillerin seçmenlerin s eçilmiş yetkilileri değerlendirme biçimlerini nasıl etkilediğine ve bu stilleri beni mseyenlerin farklılıklarının tartışmalara katkıları üzerindeki etkilerine dair soru lara yol açar.

Her bir örnek, sosyal bilimlerin çıkarımlarının kavramsallaştırmalarımıza bağlı ol duğunu göstermektedir.Kutuplaşmanın kökenlerini incelemek için, yasama organl arının ideolojik bir alanda yer alabileceğini ve bu alanın içindeki yasama organların ın organizasyonu tarafından tanımlandığını varsayıyoruz. Benzer şekilde, yasama o rganlarının çağrılarının seçmenlerin değerlendirmelerini nasıl etkilediğini inceleme k için, yasama organlarının ne söylediğini ve bunu nasıl söylediğini organize etmek için bir haritaya ihtiyacımız var. Varsaydığımız belirli organizasyon, belirli hipotezle ri kolaylaştırırken, diğer soruları imkansız veya mantıksız hale getirir. Bu nedenle, b elirli organizasyon esastır: tüm sonuçlarımız, dünyayı baştan nasıl organize etmeye karar verdiğimize bağlıdır.

Kavramlaştırmalar, araştırmalarda yaygın bir etkiye sahiptir, ancak yeni k avramlaştırmalar geliştirme yöntemleriyle çok az niceliksel çalışma ilgilenme ktedir. ABD Kongresi üzerine literatürde bile, DW-NOMINATE puanlarının uy gulanması, Kongre çatışmasının yapısını açıklamak için yeni organizasyonlar geliştirme girişimlerini çok geride bırakmıştır. Yeni kavramlaştırmalar geliştir meye yönelik dikkat eksikliği sorunludur çünkü bu, alanın Kongre hakkında n eyi inceleyebileceğini ciddi şekilde sınırlar. Yöntem eksikliği, zaman yoğunluğ u veya yeni şemalar üretme konusundaki kaygı nedeniyle sınırlayıcıdır.

Doclingo https://www.doclingo.ai

araştırmacıların daha önce kullandığı organizasyonları benimseyeceği veya kurumsal dan iyi bir şekilde yerleşmiş kavramsallaştırmaları benimseyeceği anlamına gelir. Kesinlikle, araştırmacıların kanıt biriktirmesi ve ortak bir bakış açısını paylaşması öne mlidir—bir alanda paylaşılan kavramsallaştırmaların olmaması kendi türünde bir işle v bozukluğuna yol açar. Ancak yalnızca bir kavramsallaştırmaya odaklanmak, araştır macıların sorabileceği soruları da sınırlayacak ve dolayısıyla verilerden çıkarabilecekl eri çıkarımları da sınırlayacaktır.

Doclingo https://www.doclingo.ai

10.6 Sonuç

Keşif hakkında yeterince konuşmuyoruz, oysa bu her araştırma projesinin örtük bir parçasıdır. Mitch Duneier'in ödüllü etnografisi *Sidewalk*'ın metodolojik ekinden bu alıntıyı düşünün:

> Başlangıçta spesifik araştırma sorumu bilmemem, sosyologların na sıl çalışması gerektiğine karşıt gibi görünebilir. Ancak ben farklı bir görüş alıyorum. Sosyal bilimlerin çoğunda, özellikle büyük veri setle ri kullanan nicel araştırmalarda, bir araştırma tasarımı genellikle ve riler toplandıktan sonra ortaya çıkar. Elbette, anket araçları kendiler i tasarım gerektirir, bu da başlangıçta bir tür teorik gündem veya k avramsal temel gerektirir.... Ancak iyi tasarlanmış bir anket, araştır manın daha sonra, bazıları beklenmedik olan çeşitli sorular ve konu lar ortaya atmasına olanak tanır. ...Mevcut verileri düşünerek neye bakmam gerektiği konusunda bir fikir edinen nicel araştırmacılar gi bi, sokakta gördüğüm ve duyduğum şeylerden fikirler almaya başla dım.
>
> (Duneier, 1999, s. 341)

Çoğu zaman, keşif aşaması yayımlanmış araştırmalarda görünmezdi r, ancak Duneier'in belirttiği gibi, nicel çalışmaların çoğu bu şekilde il erler.

Bu bölümde keşfin ne olduğu, nasıl ilerlemesi gerektiği ve yeni kavramsalla ştırmaların bir alandaki araştırma yolunu nasıl önemli ölçüde değiştirebileceği ne dair bir görüş sunmuş bulunuyoruz. Sonraki bölümlerde, hesaplamalı olara k desteklenen keşifler üretmeye yardımcı olabilecek bir dizi tekniği özetleyeceğ iz. Bu sonuç bölümünde, keşfi daha fazla tartışmanın ampirik pratiği nasıl geliş tirebileceğine dair düşündüğümüz üç yolu özetliyoruz.

İlk olarak, keşfi araştırma sürecinin bir parçası olarak kabul ettiğimizd e, bunu kolaylaştırmak için açıkça tasarlanmış yöntemler geliştirmeye ba şlayabiliriz. Bu, nitel araştırma tasarımı literatüründe en net bir şekilde ta kip edilmiştir (Strauss, 1952; Tavory ve Timmermans, 2014) ve birkaç hes aplamalı sosyal bilimci, bu içgörüleri metin olarak veri literatürüne aktar mak için çalışmıştır (Baumer ve diğ., 2017; Nelson, 2020; Karell ve Freed man, 2019). İlginç keşiflerin şansını maksimize edecek yeni modeller geli ştirmek için, keşif sürecinin nasıl çalıştığı, başarıya giden engellerin neler olduğu ve iyi bir keşfi gördüğümüzde nasıl anlayacağımız hakkında açık t artışmalar yapmak gereklidir.

Doclingo https://www.doclingo.ai

İkincisi, keşfi açıkça tasvir etmek, alandaki öğrencilere bilimsel s ürecin nasıl olduğunu daha doğru bir şekilde temsil eder.
Çoğu zaman, yeni kavramsallaştırmaları, parlak akademisyenlerin aklın dan kendiliğinden doğmuş gibi sunuyoruz. Bu, elbette, tekrarı zor bir s üreçtir ve alana yeni katılanlar için cesaret kırıcı olabilir.

Son olarak, keşfi kabul etmek, akademisyenlerin kanıtlarının doğası hakkınd a daha net olmalarını ve sonuçların en güvenilir olduğu yerleri belirlemelerini s ağlar. İlginç bir keşfin olasılığını belirleyen makaleler doğası gereği önemlidir, ancak o keşfin dış verilerle doğrulanıp doğrulanmadığını veya onu doğrulamak için kullanılan aynı kanıtlara dayanarak hipotez edildiğini bilmek faydalıdır. 21. Bölüm: Keşif Yöntemlerini Yeniden Kullanma'da, bu kitabın bu bölümünde tart ışılan tekniklerin ölçüm görevinde nasıl kullanılabileceğini tartışmak için bu tek niklerin kullanımına geri dönüyoruz. Bu tür bir değerlendirme, keşif ve ölçüm görevlerini net bir şekilde ayırdığımızda ve her birinin gerektirdiği farklı kanıt t ürlerini kabul ettiğimizde mümkündür.

Sonraki bölümde, keşif tekniğimiz olan kelimeleri ayırt etme tart ışmasıyla başlıyoruz; bu, belirli bir metin düzeninin ilginç veya ayırt edici olan yönlerini keşfetmek için bir dizi yöntem sunar.

Doclingo https://www.doclingo.ai

BÖLÜM 11

Ayrımcı Kelimeler

Bu bölümde, belirli bir belge organizasyonundaki dil kullanımını karakterize eden kelimeleri keşfetme yöntemlerini tanımlıyoruz. Bu yöntemler, belirli bir gözlemlenen kategoriye—örneğin, bir yazarın cinsiyeti, partizanlık veya ideoloji gibi—veya bir öğrenilmiş kategoriye—örneğin, bir sonraki bölümde tartışacağımız yöntemlerle oluşturulan kümelere—ait olan belirli bir kelime setini tanımlayarak çalışır. Bu bölümde takip eden yaklaşımların aksine, zaten var olan bir kategori setinin mevcut olduğunu varsayacağız. Siyasi bilimler ve ekonomi alanında, bu yöntemlerin yaygın bir uygulaması, Kongre'deki retoriğin Cumhuriyetçiler ve Demokratlar arasında nasıl farklılık gösterdiğini anlamaktır—metnin, konuşmacının partizan bağlılığı nedeniyle var olan bir organizasyonu.
2019). Benzer analizler, ideoloji (Diermeier ve diğ., 2012), cinsiyet (Cunha ve diğ., 2014) ve coğrafya (Eisenstein ve diğ., 2010) gibi çeşitli kategoriler ve metinler arasında farklılıkları anlamak için uygulanmıştır. Bu yöntemler, metinlerin yeni keşfedilen organizasyonlarını hızlı bir şekilde anlamak için araçlar sağladıkları için, takip edecek olan bilgisayar destekli keşif yöntemlerinin önemli bir parçasıdır.

Ayrıştırıcı kelime yöntemleri yaygın olarak kullanılmaktadır, kısmen çünkü güçlü bir sezgisel çekiciliğe sahiptirler. Bir grubun orantısız bir şekilde kullandığı dil, genellikle o grubun yapmak istediği argümanların türünü gösterece ği veya o grubun kullandığı dilsel çerçeveleri tanımlayacağı düşünülmektedir . Uygulamalar genellikle bu sezgiyi doğrular, ayırt edici kelimeleri ortaya çıkaran yöntemlerin, bir grubun nasıl iletişim kurduğuna dair değerli içgörüler sağladığını gösterir. Sonuçlar, gerçek bir keşfi ateşleyen bir şekilde de sürpriz olabilir.

Ancak, ayrıştırıcı kelimelerde önemli bir gerilim vardır, çünkü belgeler grupları arasında ayırt edici olan kelimeler ile o grup içinde yaygın olan kelimeler arasında doğuştan bir gerilim bulunmaktadır. Bu nedenle, ayırt edici kelimelerin nasıl ölçüldüğü konusunda bir zorluk ortaya çıkmaktadır. Ayrıştırıcı kelime yaklaşımları genellikle en ayırt edici kelimelere odaklanma eğilimindedir, ancak ilgili kelimelerin grubun bütünüyle hala temsil edici olmasını sağlamak için yaygınlığa dikkat edilmesi gerekmektedir. Bu dengeyi sağlamanın farklı yolları, “ayırt edici”nin farklı tanımlarına ve dolayısıyla farklı sonuçlara yol açar.

Doclingo https://www.doclingo.ai

“Ayrıştırıcı”nın farklı tanımları ve dolayısıyla farklı sonuçlar ortaya çıkar.

Bu bölümde, bilgi teorik bir ölçü olan karşılıklı bilgi ile başlayan ayrışt ırıcı kelimeleri hesaplamak için çeşitli yaklaşımlar sunacağız. Ardından, Bölüm 6'da yer alan multinom modelinden ilham alan olasılıksal bir yön temi ele alacağız, bu yönteme "Savaşan Kelimeler" (Monroe, Colaresi ve Quinn, 2008) denir. Son olarak, grup etiketlerinin öngörücü modellerin e dayanan bu probleme bir yaklaşım tanımlayacağız. Bu ayarları, inşa g ereği zaten bilinen bir bilgiyi tahmin ettiğimiz için "hayali tahmin proble mleri" olarak adlandırıyoruz. Amaç, tahminin kendisi değil, en etkili tah min ediciler olan kelimeleri tanımlamaktır.

Bu süreçte, Nelson (2020) adlı bir sürekli örnek kullanacağız. Nelson, Amerika Birleşik Devletleri'ndeki feminist hareketlerin "bilişsel çerçevelerini" keşfetmek içi n ayrıştırıcı kelime algoritmalarını kullanmaktadır. Mevcut literatür, bu konu hak kında öncelikle birinci dalga ve ikinci dalga feminist hareketler arasında ayrım ya parken, Nelson (2020) kadın hareketlerindeki coğrafi farklılıkları, özellikle Chicag o'daki hareketler ile New York'taki hareketler arasındaki farklılıkları araştırmakta dır.

Bunu yapmak için, Nelson (2020) her iki farklı konumda ve her ik i farklı zaman diliminde dört kadın kuruluşundan kaynaklanan belg eleri toplar: Hull House (ilk dalga, Chicago), Heterodoxy (ilk dalga, New York City), Chicago Kadın Kurtuluş Birliği (CWLU) (ikinci dalga, Chicago) ve Redstockings (ikinci dalga, New York City).
Nelson (2020) analizinden, hem Chicago kuruluşlarının (Hullhouse ve CWLU) eğitim, tıp ve kürtaja erişim gibi somut politikalara odaklandığı nı, hem de New York kuruluşlarının (Heterodoxy ve Redstockings) fem inizm hakkında soyut ve genel fikirlere odaklandığını çıkarır. Bu sonuç ları, daha sonraki bölümlerde ele alacağımız konu modelleri ve dikkatl i okuma ile doğrular. Nelson'un uygulaması, ayrımcı kelimelerin keşif i çin nasıl bir sıçrama tahtası olabileceğine dair harika bir örnek sunar, bu da daha fazla okumayı artırabilir.

Son olarak, bu teknikleri bireysel kelimelere dayalı bir özellik seti açısın dan konuşacağımızı belirtelim, ancak bazı yöntemleri kullanarak tespit ed ilen n-gramlar veya ifadeleri kullanmak da mümkündür ve genellikle terci h edilir. Çok kelimeli ifadelerin, tek kelimelere göre daha düşük sıklığa sa hip olacağı kesin olsa da, kelimelerin bir araya gelmesi genellikle tek başı na bireysel kelimelerden çok daha bilgilendirici olabilir (Chuang, Mannin g ve Heer, 2012).

Doclingo https://www.doclingo.ai

11.1 Karşılıklı Bilgi

Bir kelime ayrımının ilk ölçüsü olarak, bir belgenin kategorisi ile keli meler arasındaki karşılıklı bilgiyi değerlendiren bilgi teorisinden bir öl çü kullanıyoruz y i (Shannon, 1949). Karşılıklı bilgi, bir kelimenin belirli bir kategorideki belgelere ne kadar güçlü bir şekilde bağlı olduğunu gösteren imzasız bir ölçüdür. Bu tartışma için belgelerimizin K ayrık kategori setine sıralandığını varsayacağız ve böylece y i ∈ { 1 , 2 , … , K }. Kelimeler ile y i değeri nin karşılıklı bilgisi, belirli bir kelimenin varlığının, bir belgenin belir li bir kategoriye ait olup olmadığı konusundaki belirsizliğimizi ne k adar çözdüğünü tanımlayan bilgi teorik bir ölçüdür. Karşılıklı bilgini n kullanımını teşvik etmek için, rastgele seçilmiş bir belgenin y i de ğerini tahmin etme görevini aldığımızı varsayalım. Kelime j için kar şılıklı bilgi, kelime j'nin varlığının veya yokluğunun tahminimizi ne k adar bilgilendirdiğini ölçer.

Bir temel olarak, bilgi teorik terimlerde bir kategori için entropi olan koşulsuz belirsizliği düşünün. π k'nın kategori k'ya düşen belg elerin oranını temsil ettiğini varsayalım ve π − k = 1 − π k, bir belge nin kategori k'ya ait olmama olasılığını temsil etsin. π k ayrıca rastg ele seçilmiş bir belge için kategori k'yı tahmin etme konusunda do ğru olma oranını temsil eder. Kategori k için entropiyi tanımlayın.

$$H (k) = − π k \log 2 π k − π − k \log 2 π − k , (11.1.1)$$

bu, tahminimiz hakkındaki belirsizliğimizin bir ölçüsüdür. Her belge kategori *k* içinde olduğunda, kategori *k* entropi 0 olurdu. Entropi, π k = π − k olduğunda maksimumdur, bu da en belirsiz olduğumuz zamandır.

Bir kelimenin belgede mevcut olup olmadığını bilseydik, daha iyi bir tahmi nde bulunabilirdik. π k , j'yi, hem kategori k'da hem de kelime j'nin bulunduğ u belgelerin oranı olarak tanımlayın ve π k | j'yi, kelime j mevcut olduğunda kategori k'daki belgelerin oranı olarak tanımlayın. Koşullu entropiyi şu şekild e tanımlayabiliriz:

$$H (k | j) = − ∑ k , − k ∑ j , − j π k , j \log 2 π k | j ,$$

Σ k , − k'nin *k* içinde değil, belgeler üzerinde topladığımızı gösterdiği yer. Ko şullu entropi, bir kelimeye koşullandığımızda belgenin kategorisi hakkında b elirsizliğimizin ne kadar azaldığını tanımlar. Eğer bir kelime mükemmel bir

Doclingo https://www.doclingo.ai

belgenin kategorisinin tahmincisi ise, belirsizlik sıfıra inecek vebir k elime bir kategoriye dik ise, ölçüm yalnızca entropiyi döndürecektir . Bu özellik, kategori kve kelime *j* arasındaki Karşılıklı Bilgi'yi motive eder,

$$\mathrm{MI}\ k\ j = \mathrm{H}\ (\ k\ ) - \mathrm{H}\ (\ k \mid j\ )\ ,$$

bu, koşulsuz belirsizlikten koşullu belirsizliği çıkarmak olarak sezgisel bir şekilde okunabilir. Kelime kategoriye mükemmel bir şekilde tahmin ettiğin de, karşılıklı bilgi maksimumda olacaktır ve bir kelimenin tahmin gücü yoks a, sıfır olacaktır. Bu prosedürü her kategori ve her kelime için tekrar tekrar uygulayarak, her kategori için en yüksek karşılıklı bilgiye sahip kelimelerin bir listesini elde edebiliriz.

Bu performansın nasıl olduğunu anlamak için, Nelson (2020) ile karşılaştırabiliriz. Ayrıştırıcı kelimeleri tanımlamak için, Nelson (2020) oranlardaki farkı kulla nır. Yani, her kelime için, o kelimenin her organizasyonda ne kadar kullan ıldığını hesaplar. Sonra kelimeleri her organizasyon arasındaki oranlarda ki en büyük farklara göre sıralarız. Onun analizini Tablo 11.1'deki sol dört sütunda tekrarlıyoruz.

Tablo 11.1'de gösterildiği gibi, hem Chicago organizasyonları (Hull House ve CWLU) iş, dersler, okul ve tıbbi gibi kelimeler kullanırken, New York organizasyonları (Heterodoxy ve Redstockings), özelli kle ikinci dalga Redstockings için, en belirgin kelimeler daha soyut olanlardır; bunlar arasında bilinç, teori, devrim ve siyasi gibi kelimeler bulunmaktadır. Aynı probleme farklı bir bakış açısı sağlamak için karşılıklı bilgi kullanıyoruz. Tablo 11.1'nin sağ dört sütununda benzer bir desen buluyoruz; bu, belki de Birinci Dalga New York organizasyonu (Heterodoxy) için bazı soyut kelimeleri daha net bir şekilde merkezileştiriyor ve suffrage ile liberty gibi kelimeler list ede daha yüksek sıralarda yer alıyor.

Karşılıklı bilgi metriği ile ilgili temel bir zorluk, olasılıkların tahmini ndeki belirsizliği dikkate almamasıdır. Ayrıca, bir kelimenin bir belge de görünüp görünmediğini yalnızca dikkate alır, tekrar tekrar kullanı lan kelimelerle ilgili bilgileri göz ardı eder. Bu iki endişeyi de tamame n olasılıklı bir modele geçerek ele alabiliriz.

Tablo 11.1. Nelson (2020) feminist organizasyonlar (sol) ve karşılıklı bilgi kelimeleri (sağ) arasındaki oran farklarının tekrarı.

Oran Farkı (Tekrar)	Karşılıklı Bilgi

Doclingo https://www.doclingo.ai

Birinci Dalga	İkinci Dalga		
Hull Evi	Heterodoksi CWLU		Kırmızı Çoraplar
Gövde evi	kadın	chicago	hareket
kulüp	adam	çocuklar	kadınlar
hanımefendi	kadınlar	merkez	erkekler
okul	hayat	birlik	radikal
verilen	biliyor	okul	feminist
üyeler	dünya	çalışma	erkek
chicago	gibi	gevşetmek	siyasi
yıl	şarkıcı	vietnam	tarih
beyefendi	erkekler	nixon	kadınların
sınıflar	almak	insanlar	feminizm
ev	söyledi	ofis	devrim
erkekler	ev	gün	aşk
çalışma	sadece	sağlık	feministler
sosyal	söyle	şehir	sol
tutuldu	yapma	çalışan	güç
kulüpler	küçük	Vietnam zulmü	
hanım	yol	hukuki	sınıf
sakinler	düşünmek	savaş	kadın
oda	asla	önemsemek	kişisel
çocuklar	zorunlu	kadınlık kadını	
birçok	şey	hükümet gerçekten	
akşam	istemek	işçiler	bilinç
mahalle cinselliği		güney	bilinç artırma
İtalyan	hak	tıbbi	grup
bina	bir	ev	teori
çeşitli	kitleler	hastane	gruplar
yaz	yapmak	gebelik sonlandırma	hareket
oynar	şey	tecavüz	yeni
şehir	git	yardım	ezilen
dernek	iyi	ödemek	üstünlük

Birinci Dalga	İkinci Dalga		
Hull Evi	Heterodoksi CWLU		Kırmızı Çorap
Gövde evi	adam	kadınlar feminist	
hanımefendi	kadın	almak	erkek
kulüp	kitleler	chicago	hareket
verilen	söyle	birlik	radikal
beyefendi	üzerine	ABD	siyasi
üyeler	dünya	çalışan	devrim
hanım	mesele	yapabilir	kadınların
sakinler	şarkıcı	sağlık	kadınlar
akşam	olacak	ofis	özgürlük
yıl	henüz	iş	kırmızı çorap
ev	şey	yardım	hatta
kulüpler	iş	gevşetmek	güç
okul	düşünmek	kontrol	kadın
mahalle anlatımı		merkez	gerçekten
tutuldu	seçim hakkı	işçiler	baskı
çeşitli	zihin	işler	kadın
sınıflar	inanmak	hayatlar	bilinç
chicago	el	sayfa	erkekler
yıllar	gerçek	tıbbi	kişisel
müzik	büyük	gün	feministler
ücret	gelmek	kadınlar	üstünlük
büyük	özgürlük	ödemek	ezilen
yaz	biliyor	ev	zorunlu
salon	küçük	birlikte	teori
yüz	tam	hükümet gerçek	
oda	sevgili	etrafında	feminizm
erkekler	hak	devam	gibi
İtalyan	eş	ara	sadece
sosyal	margaret	sadece	aslında
eğilmek	her zaman	önemsemek	yol

Doclingo https://www.doclingo.ai

11.2 Savaşan Kelimeler

Gözden geçirdiğimiz çok terimli model üzerine, Monroe, Colaresi ve Quinn (2008) kategorileri sistematik olarak ayıran kelimeleri tanımlamak için Savaşan Kelimeler adında bir yöntem sunuyorlar. Makalelerinde, Nelson (2020) tarafından kullanılan oranlar arasındaki fark yönteminden başlayarak yavaş yavaş yöntemlerini geliştiriyorlar ve yöntemin her bir sonraki parçasını ekleyerek elde ettikleri sonuçları gösteriyorlar. Temel sezgi, kelime kullanımının olasılıksal bir modelini oluşturarak, kelimelerin farklı frekanslara sahip olmasından kaynaklanan belirsizlik seviyelerini hesaba katabilecekleridir.

Savaşan Kelimeler yöntemi ayrıca tahminlerin açıkça düzenlenmesini de tanıtıyor; yani, katsayıları bazı ortak değerlere doğru küçültüyor. Ortak kelimeler, gerçekten ayırt edici iseler bu ortak değerden uzaklaşabilecekler, ancak nadir kullanılan kelimeler ortalamaya küçültülecektir. Gördüğümüz gibi, düzenleme, belirli bir grubun dili nasıl kullandığını gösteren kelimeleri tanımlamak için esastır ve daha sonraki yöntemlerde tekrar edecektir.

Belgenin Nelson (2020) çalışmasında incelenen dört feminist gruptan birine ait olup olmadığını belirtmek için $y_i \in \{1, 2, \ldots, K\}$ kullanıyoruz. Her seviye k için, kategori k ait bir belgenin belirli bir kelimeyi kullanma olasılığını hesaplayabiliriz. Kategori k 'den gelen belgelerin içerdiği toplam token sayısını $n_k = \sum_{j=1}^{J} \sum_{i=1}^{N} I(y_i = k) W_{ij}$ olarak tanımlayın ve $W_{jk}^* = \sum_{i=1}^{N} I(y_i = k) W_{ij}$ olarak adlandırın. Daha sonra, kategori k 'den (yani, $y_i = k$) bir belgenin kelime j'yi kullanma olasılığının düzenlenmiş bir tahminini oluşturabiliriz.

$$\hat{\mu}_{jk} = W_{jk}^* + \alpha_j n_k + \sum_{j=1}^{J} \alpha_j, \quad (11.2.1)$$

α_j, tahminleri *smooth* etmek için kullanılan küçük bir değeri temsil eder. Bölüm 6, bu tahmini, bir Dirichlet önceliği ile Bayesian çok terimli bir model kullanarak orantıyı motive edebiliriz. $\mu \sim \text{Dirichlet}(\alpha)$ ve $W_k^* \sim \text{Multinomial}(n_k, \mu_k)$ olduğunu varsayarsak, tahmin, kelimeleri gözlemledikten sonra $p(\mu \mid W)$ posterior dağılımının beklenen değerine karşılık gelir.

Bir olasılık modeli ile Monroe, Colaresi ve Quinn (2008), belirsizliği de dahil eder ek gruplar tarafından kelime kullanımının göreli ölçülerini tahmin edebiliyorlar. Standartlaştırılmış log odds oranını tercih ediyorlar. Özellikle, belirli bir kelimenin kullanımının log odds'unu hesaplayarak grup k'deki kullanımı diğer gruplarla karşılaştırıyorlar.

Doclingo https://www.doclingo.ai

log odds oranı k j = log μ k j 1 − μ k j ⌣

k j ⌣ k diğer gruplardaki odds'lar.

Oranı standartlaştırmak için, odds oranının varyansının bir yaklaşık değerini ku llanmayı öneriyorlarVar(log odds oranı k j) ≈ 1 W k j * + α j + 1 W − k j * + α j. Bu varyansı kullanarak, standartlaştırılmış log odds oranını hesaplıyorlar, bu da kelime ayrımının önerilen ölçüsüdür.

Std. Log Odds j = log odds oranı k j Var(log odds oranı k j) (11.2.2)

Tablo 11.2. Nelson (2020)'dan örnekMonroe, Co laresi ve Quinn (2008)'in Fightin' Words algorit masını kullanarak.

Birinci Dalga		İkinci Dalga	
Hull HouseHeterodoksi		CWLU	Kırmızı Çoraplar
kulüp	adam	merkez	radikal
hanımefendi	yapabilir	çocuklar	feminist
okul	ABD	birlik	erkek
yıl	biliyor	okul	siyasi
verilen	dünya	vietnam	erkekler
beyefendi	söyledi	nixon	tarih
üyeler	gibi	ofis	feminizm
sınıflar	şarkıcı	gevşetmek	kadınlar
chicago	sadece	sağlık	devrim
ev	almak	şehir	baskı
erkekler	kadınlar	vietnamca	aşk
sosyal	düşünmek	hukuki	sol
çalışma	yapma	güney	bilinç
yıllar	söyle	gün	kadın
tutuldu	yol	tecavüz	feministler
hanım	zorunlu	kadınlıkkişisel	
oda	şey	hastane	teori
kulüpler	cinsiyet	çocuk bakımı	l
çocuklar	asla	tıbbi	sınıf
birçok	hak	araba	ezilen
akşam	hayat	kuzey	bilinç artırma
iki	istemek	önemsemek	liberal
yaz	ev	doğum izni	analiz
sakinler	şey	refah	üstünlük
şehir	git	savaş	güç
dernek kitleleri		hükümetgerçekten	
çeşitli	doğum	gonore	kadınların
numara	kontrol	öğleden sonra	hareket
komite	eş	ödemek	gruplar

Doclingo https://www.doclingo.ai

Bu formül, belirli bir kelimeyi kullanma olasılığını açıkça düzenler ve tahminlerdeki belirsizliği ele almak için standartlaştırır. Nelson (2020) v erilerindeki sonuçlar Tablo 11.2'de gösterilmiştir.

Yine de, bazı zorluklar devam etmektedir. Örneğin, Monroe, Col aresi ve Quinn (2008) modeli, bir konuşmacının ideolojisi gibi sürek li bir kategori ile uygulanması zor, daha önce dikkate aldığımız ayrı k kategorilerle değil. Bunu ele almak için bu sürecin daha genel bir formülasyonuna döneceğiz: *uydurma tahmin problemi*.

Doclingo https://www.doclingo.ai

11.3 Uydurma Tahmin Problemleri

Ayrımcı kelimeleri tanımlamak için birçok yöntem *uydurma tahmin problem i* kurar. Bir kelimenin belirginliği, doğrudan ilgi alanında olmayan bir tahmin p roblemi bağlamında ölçülür. Örneğin, Gentzkow, Shapiro ve Taddy (2019), bir Kongre üyesinin Cumhuriyetçi mi yoksa Demokrat mı olduğunu en iyi tahmin eden kelimeleri tanımlar. Açıkça, bir Kongre üyesinin siyasi partisinin tahmin e dilmesi asla ilgi alanında değildir—Kongre üyeleri kamuya açık bir şekilde bir p arti ile kendilerini tanımlarlar. Ve taraf değiştirebilir veya başka bir parti ile ken dilerini tanımlayabilirken, herhangi bir ciddi adayın veya yasama organının par ti aidiyeti hakkında tahmin yapmamıza gerek yoktur.

Modeli gelecekteki bir tahmin veya sınıflandırma yapmak için inşa etmek yerine, kurgusal tahmin problemi analitik kolaylık için kullanılmaktadır. Tah min problemi olduğu kurgusunu eğlenceli bulmak faydalıdır, çünkü bu, araşt ırmacıların sürekli temel organizasyonlar (ideoloji durumunda olduğu gibi) v eya diğer daha karmaşık ayarlar gibi durumları daha kolay bir şekilde ele ala bilen tahmin yöntemlerini yeniden kullanmalarını sağlar. Premis, bir sonucu n tahmininde faydalı olan bir kelimenin, keşif için faydalı bir anlamda da ayrı ştırıcı olacağıdır.

Tahminin sadece bir kurgu olduğunu kabul etmek önemlidir, çünkü bu, bir modeli n tahmin konusunda iyi performans gösterdiğini kanıtlamanın, kelimelerin belirli bir grubun retoriğinin doğru bir damıtımını sağladığını göstermeye yeterli olmadığını gö sterir. Bir sonraki bölümde, tahmin doğruluğunu ölçmek için kullanılan prosedürlerin , çapraz doğrulama gibi, sınıflandırma yöntemlerinin performansını değerlendirmek i çin gerekli olduğunu göstereceğiz, çünkü bunlar yöntemin merkezi görevde nasıl per formans gösterdiğine dair bir tahmin sağlar. Ancak burada çapraz doğrulama daha a z faydalıdır, çünkü belirli kategorilerin göstergesi olan kelimeleri tanımlamada “daha iyi” bir iş çıkaran ama daha az tahmin edici olan modelleri tercih edebiliriz.
Aslında, kullandığımız doğrulamalar mutlaka daha az doğrudan olacak ve kelimele rin ölçümlerinin ana ayırt edici özellikleri anlamamıza ne ölçüde yardımcı olduğunu değerlendirmek için konu uzmanlığı gerektirecektir.

Hayali tahmin problemleri, ayırt edici kelimeleri tanımlarken potansiyel bir riski de vurgular. Belirli bir kategori ile ilişkili kelimeleri tanımlamak için problemi kuruyoruz, ancak belgelerin kategorilerle ilişkili olabilecek başka özellikleri de olabilir. Örneğin, Taddy (2013) Demokratlar ve Cumhuriyetçile rle ilişkili kelimeleri bulmak için Kongre konuşmalarını analiz eder. Ancak bi rçok Cumhuriyetçi, kamu arazilerine büyük tahsisatlar yapılan eyaletleri te msil eder ve bu nedenle, modeller genellikle ulusal parklarla ilişkili kelimel eri Cumhuriyetçi kelimeler olarak tanımlama eğilimindedir, hatta

Doclingo https://www.doclingo.ai

bununla birlikte, bu konularla ilgili tartışmalar özellikle partizan değildir. B u, analizde teorinin rolü hakkında daha genel noktamıza geri bağlanır—bul duğumuz şeyleri bağlamlaştırmak için partizanlığın ne olduğunu titiz bir şe kilde kavramamız gerekir.

Kamu arazisi tartışması ve partizanlık arasındaki karışıklık, daha önce dile g etirdiğimiz temel gerilimi vurgular. Kategorileri ayırt eden kelimeler, bir kateg oriyi gösteren kelimelerden farklı olabilir. Yani, özellikle partizan olan kelimeler —Cumhuriyetçilerin ve Demokratların partilerinin duruşunu ilettiklerinde nasıl konuştuklarını gösteren—Cumhuriyetçi ve Demokratik retorikleri ayırt eden ke limeler seti ile tamamen örtüşmeyebilir. Taddy (2013) kovaryatların dahil edilm esini önerir, ancak hangi kovaryatların dahil edileceği ve neden olduğu sorusu nu gündeme getirir.

Hayali tahmin probleminin çerçevesi, tahmin problemini aşırı uyum sağlam a açısından ayırt edici kelimeleri bulma ihtiyacını anlamak için bazı bağlamlar s ağlar. Aşırı uyum sağlama durumunun en uç örneği, herhangi bir veri kümesin de yalnızca bir kez söylenen herhangi bir kelimenin konuşmacıyı ya Cumhuriye tçi ya da Demokrat olarak mükemmel bir şekilde sınıflandırmasıdır. Bu durum, kelimenin partizan içeriğinden bağımsız olarak doğrudur - bu yalnızca kelime nin nadir olmasından kaynaklanır. Ve bu sorun, yalnızca bir kez söylenen kelim eleri ortadan kaldırdığımızda bile devam eder. Nadir kullanılan kelimeler olduğ unda, bu kelimelerin yalnızca bir grup tarafından, tamamen şans eseri kullanıl ması olasılığı vardır. Eğer bu olursa, artık bir grup tarafından sistematik olarak daha sık kullanılan kelimeleri tanımlamıyoruz, aksine belirli bir kategori setiyle sadece tesadüfen örtüşen kelimeleri tanımlıyoruz.

Öngörü problemi yaklaşımının basit bir ilk örneği olarak, İstatistik alanın da yaygın olarak kullanılan test istatistiklerine dayanan basit bir prosedürü tanımlıyoruz. Ardından, bu amaç için inşa edilmiş daha karmaşık bir olasılı ksal modele geçiyoruz - Çoklu Ters Regresyon (MNIR) (Taddy, 2013).

11.3.1 STANDARTLAŞTIRILMIŞ TEST İSTATİSTİKLERİ AYRIM ÖLÇÜL ERİ OLARAK

Yine, koşu örneğimizde feminist organizasyon olan bazı özellikler y i i le başlayacağız. Ancak, y i'nin sürekli ölçümler (gelir veya ideoloji gibi) v eya kategorik ölçümler (parti bağlılığı veya feminist organizasyon gibi) dahil olmak üzere herhangi bir tür değişken olmasına izin vereceğiz.

Bir sıradan en küçük kareler regresyonu hesaplıyoruz ve sonucu tahmin ediyoruz (ka tegorik bir değişken durumunda, belgenin kategori *k*'de olup olmadığını belirten bir dikotomik değişken kullandığınızı hayal edebilirsiniz),

Doclingo https://www.doclingo.ai

$$y\ i = \mu\ 0 + \mu\ 1\ j\ W\ i\ j + \varepsilon\ i\ .$$

Regresyon çıktısını kullanarak, μ 1 j = 0 olan sıfır hipotezine karşılık gel en test istatistiğini hesaplıyoruz ve ardından bu test istatistiğini ayrım ölç ümüz olarak kullanıyoruz:

$$\text{Standard}\ j = \mu\ 1\ j\hat{}SE\ (\ \mu\ 1\ j\ )\hat{},$$

burada SE standart hatayı belirtir. Bu ölçü, kategoriler arasında daha iyi ayr ım yapan kelimeleri önceliklendirir; ayrım, katsayının tahmin edilen standa rt hatası ile ölçeklendirilmiştir. Test istatistiği ne kadar pozitifse, katsayı o k adar ayrımcıdır ve varyansı ile ölçeklendirilmiştir. Test istatistiği açısından, 0 katsayısının sıfır hipotezi altında, daha büyük bir test istatistiği daha düşü k bir p-değerine karşılık gelir.

Bu yaklaşımı Tablo 11.3'te kullanarak, Chicago organizasyonlarıyla iliş kili daha spesifik ve somut kelimeler ile New York organizasyonlarıyla iliş kili daha soyut ve genel kelimeler arasında benzer bir desen buluyoruz. K elimeler, katılım, müzik ve eğlence gibi gerçek olaylarla ilişkili kelimelerin Chicago organizasyonlarında orantısız bir şekilde kullanıldığını ve analiz etme, düşünme ve değerlendirme gibi kelimelerin New York organizasyo nlarında orantısız bir şekilde kullanıldığını göstererek bize daha net bir re sim veriyor.

11.3.2 χ 2 Test İstatistikleri

Gentzkow ve Shapiro (2010), Kongre'deki siyasi partilerin orantısız bir şekilde ku llandığı kelimeler üzerine yaptıkları çalışmada ilgili bir prosedür önermektedir. Bu ölçüyü oluşturmak için, kategoriler arasında eşit dağılım için bir χ 2 testinden elde edilen bir χ 2 istatistiği kullanıyorlar. İki kategorili duruma odaklanacağız, ancak fik ir doğal olarak çok kategorili ayara genelleşiyor. İstatistiği oluşturmak için, W j 1 * = Σ i = 1 N W i j * I (y i = 1), yani grup 1'deki gözlemlerin kelime *j*'yi kaç kez kullan dığının toplam sayısı ve W − j 1 = Σ m ≠ j J Σ i = 1 N W i m I (y i = 1), yani grup 1'd eki bireyler tarafından kullanılmayan kelimelerin toplam sayısı tanımlanabilir. Daha sonra W j 0 * ve W − j 0 *'ı benzer şekilde tanımlayabiliriz. χ j 2 istatistiği daha sonr a şöyle tanımlanır:

$$\chi\ j\ 2 = W\ j\ 1\ *\ W - j\ 1\ * - W\ j\ 0\ *\ W - j\ 0\ *\ (\ W\ j\ 1\ *\ +\ W\ j\ 0\ *\ )\ (\ W\ j\ 0\ *\ +\ W - j\ 0\ *\ )\ (\ W\ j\ 1\ *\ +\ W - j\ 1\ *\ )\ (\ W - j\ 1\ *\ +\ W - j\ 0\ *\ )\ .$$

Tablo 11.3. Standartlaştırılmış temel alınarak Ne lson (2020) tarafından ayrıştırılan kelimeler

Doclingo https://www.doclingo.ai

doğrusal regresyon test istatistikleri.

Birinci Dalga		İkinci Dalga	
Hull Evi	Heterodoksi	CWLU	Kırmızı Çoraplar
Gövde evi	kadın	kadınlık	analiz etmek
hanımefendi	yapabilir	chicago	anti-kadıncılık
verilen	gibi	birlik	inanç
kulüp	yol	ofis	klasik
üyeler	biliyor	devam	çapraz
chicago	hak	bu	cesur
okul	düşünmek	gün	değerlendirme
çeşitli	adam	sağlık	inceleme
mahalle	şey	okul	ifade etme
sakinler	söyledi	belmont	yanlış
yıl	asla	s	korku
tutuldu	inanmak	ev	bulma
akşam	ABD	yardım	yüceltme
ev	henüz	şehir	gidiyor
kulüpler	git	çocuklar	tarih
müzik	sadece	ay	devam eden
numara	dünya	öğleden sonra	kişisel
çocukların	söyle	nixon	nedenler
katıldı	şey	çalışan	tanıma
eğilmek	herhangi bir şey	sayfa	ilişkin
direktör	nazik	t	romantik
oda	almak	gevşetmek	öz suçlama
sınıflar	kadınlar	illinois	konuşma
üyelik	anlamlar	merkez	başlama
akşamlar	söyle	üç	durdur
birkaç	görmek	iki	almak
eğlence	zorunlu	haftalar	düşünmek
ocak	daha çok	önemsemek	yetenekli
katılım	şimdi	e	sömürülen
toplantılar	hayat	yıl	yeterli

Tablo 11.4. Nelson (2020) tarafından Multinom ialInverse Regression (Taddy, 2013) temeli nde ayrıştırılan kelimeler.

Birinci Dalga		İkinci Dalga	
Hull Evi	Heterodoksi	CWLU	Kırmızı Çoraplar
Gövde evi	sangerler	belmont	kırmızı çoraplar
eğlenceleradrian		devam	radikalizm
addams	Daha sonra	mors	analiz et
jimnastik salonu	mikrofon	grafikler	üstünlük yanlısı
eğlendirildi	hewitt	danışmanlık	Sağ
gövde	sert ağaç	daley	Haniş
himaye	Grefesaunder	luteran	reformist
ewing	çelikler	olabilmek	wlm

Doclingo https://www.doclingo.ai

bilmece	kurşun	katılır	zalimler
polonya	dora	vietnamlılar	efendim çocuğu
konserler	mickey	janitressler	otantik
dante	sevgili	Saygon	baskı yapan
stereoptikon	mirah	yeniden yapılandırma	güzel kadın
memnun edici	çay	orta batı	varsayımlar
yenileyici	ortaklık	latince konuşanlar	netlik
orkestra	şarkıcı	eksiklik	manipülasyon
nasıl	oy kullanma hakkı savunucusu	bakteri	yazılar
İngiliz	soyut	Ağustos ayı	liberalizm
hamilton	içgüdü	yeniden eğitim	irade
cömertçe	fizyoloji	oto	friedan
süslenmiş	yoldaş	l0	fırsatçılar
eğlence	yasak	laos	yanında
benedict	burjuvazi	haiphong	scef
Nancreed	suffragistler	temizlikçiler	ölçü
pelham	önleme	idrar	sncc
Bay	yazışma	ödemeler	geri çekilme
program	mahkum edildi	müzakere etmek	şiddetsiz
suriye	en ucuz	sınav	inek
ödünç verilen	hammadde	lokasyonlar	matriarkal
ülke insanları	yolsuzluk	karmaşıklıklarhepsi kadın	

Bu ölçütü kullanarak, grup 1 veya 2'deki bireyler tarafından orantısız bir şekilde k ullanılan kelimeleri tanımlayabiliyoruz; bu, kategoriler arasında eşit kullanım var sayımı altında daha düşük bir p-değeri ile tutarlıdır.

Standartlaştırılmış regresyon katsayıları veya χ 2 istatistikleri ile, nadi ren kullanılan bir kelimenin grupları ayırmasıyla daha düzenli kullanılan bir kelimeyi karıştırabileceğimiz konusunda endişelenebiliriz; bu, kateg oriler arasında dil kullanımında sistematik bir farkı yakalar. Bu sorunu manuel olarak ele alabiliriz, kullanım eşiğinin altına düşen kelimeleri kal dırarak. Ancak, bu eşiği belirlemek zor olabilir.

Kelime kaldırmak yerine, parametre tahminlerini açıkça düzenleyen modellere tekrar döneceğiz. Gördüğümüz gibi, küçülme miktarı, tahmi n oluşturmak için verilerde mevcut olan bilgilere bağlı olacaktır. Belirli bir kategoriyle tesadüfen örtüşen nadir kelimeler, ortak değere doğru düzleştirilecektir. Ancak, düzenli olarak kullanılan ve kategorileri ayırt e den kelimelerin yalnızca küçük bir miktar küçülmesi olacaktır.

11.3.3 ÇOKLU TERS REGRESYON

11.3.1. Bölümde etiket, y i, kelimeler *W* üzerinde regresyon yaptık. Elbet te, tüm *J* özellikler üzerinde aynı anda regresyon yapmak sorunludur. Bir s orun, eğer J > N ise regresyon katsayılarının tanımlanmadığıdır. Ve eğer re gresyon katsayılarını hesaplayabiliyorsak, tüm *J* özellikleri dahil etmek

Doclingo https://www.doclingo.ai

kategoriler arasında yararsız karşılaştırmalar üreten gürültülü tahminler e. 11.3.1. Bölümde bunu, her kelimeyi birer birer regresyona dahil edere k önledik.

Taddy (2013), sürekli Y i'yi dahil etme yeteneğimizi sağlarken, Fightin' Words il e benzer bir düzenleme görevi gerçekleştirmek için Çok Terimli Ters Regresyon (MNIR) tanıtmaktadır. İsimden de anlaşılacağı gibi, MNIR regresyon problemini te rsine çevirir: y i'yi özellikler üzerinde regresyon yapmak yerine, özellikleri y i üzer inde regresyon yapar. Bu çerçeveyi kullanarak, Taddy (2013) bir çok terimli regre syon modeli tanıtmaktadır. Yani,

$$W_{i,} \sim \text{Çok Terimli}(n_i, \theta_i)\ \theta_{ij} = \frac{\exp(\mu_{0j} + \mu_{1j} y_i)}{\sum_{l=1}^{J} \exp(\mu_{0l} + \mu_{1l} y_i)}. \quad (11.3.1)$$

Nadir kelimelerin kelime kullanımında şans farklılıkları yaratma sorunun u ele almak için, Taddy (2013) Lasso regresyonundaki düzenlemeye (Hastie , Tibshirani ve Friedman, 2013) ilişkin düzenleme sağlayan bir Gamma-Lapl ace önbilgisi kullanmaktadır. MNIR kullanarak, belirli kelimelerin kategorile ri ne kadar iyi ayırdığını ölçmek için tahmin edilen katsayıları kullanabiliriz.

Çalışan örneğimiz için Tablo 11.4'te üretilen kelimeleri incelediğimizde, üretilen kelimelerin türlerinde dramatik bir fark görebiliriz. Bu kelimeler, önceki yöntemler den elde edilenlere göre önemli ölçüde daha nadirdir, ancak yine de gruplar arasın daki dil kullanımındaki sağlam ayrımlara karşılık gelmektedir. Bu kelimeler, Nelson' un (2020) grup farklılıklarıyla ilgili temel teorisini yansıtmaktadır; sadece bu farklılık ların alternatif bir görünümünü sunmaktadır. En dikkat çekici olarak, New York biri nci dalga feministlerinin (Heterodoxy) daha soyut endişeleri, bu listede önceki listel erden çok daha net bir şekilde ortaya çıkmaktadır.

Doclingo https://www.doclingo.ai

11.4 Sonuç

Belgeler grupları arasında ayırt edici kelimeleri incelemek, belge koleksiyonlarında içgörüler keşfetmenin güçlü bir yolu olabilir. Bu tür kelime listeleri, korpusun farklı segmentleri arasındaki karşıtlıklara dikkat çekerek, farklı toplulukları temsil eden bir dil anlayışı sağlar. Bu, ilginç fikirleri ateşlemek için kullanılabilir ve bu fikirler daha derin metinlerle etkileşimle doğrulanabilir.

Ayrıca, yaygınlık ve ayırt edicilik arasındaki ayırt edici kelimelerdeki temel gerilimi vurguladık. Belirli bir korpusu en iyi temsil eden kelimeleri belirlemeye çalışırken yaygınlık ve ayırt edicilik arasında optimal bir denge yoktur. Bir sonuç olarak, tek bir en iyi yöntem yoktur ve burada Nelson (2020) korpusunun farklı görüşlerini ortaya koyan bir dizi yaklaşım sunduk.

Buradaki yaklaşımlar, mevcut olan birçok teknikten yalnızca küçük bir örnektir (bazılarını daha sonraki bölümlerde de tartışacağız). Kurgusal tahmin problemi çerçevesinin gücünün bir kısmı, esasen herhangi bir denetimli öğrenme yönteminin etiketler oluşturmak için kullanılabilmesidir. Karmaşık tahmin modellerinden basit özetlerin çıkarılmasına olanak tanıyan birçok teknik vardır ve bu teknikler ayırt edici bir kelime listesi oluşturmanın temeli olarak hizmet edebilir (Ribeiro, Singh ve Guestrin, 2016).

Sonraki üç bölümde, metinlerin yeni organizasyonlarını keşfetmek için kümeleme, karma üyelik konu modelleri ve belge gömme tekniklerini tanımlıyoruz. Bu bölümde ele alınan teknikler, diğer algoritmaların keşfettiği kalıpları anlamaya yardımcı olmak için değerli araçlar olabilir ve etiketleme ve yorumlama sürecinde onlara geri dönüceğiz.

---

[1] Kelimelerimiz biraz farklı çünkü Nelson (2020) ile biraz farklı ön işleme kullanıyoruz. Ancak, maddi sonuçlar değişmedi.

Doclingo https://www.doclingo.ai

BÖLÜM 12

Kümeleme

Keşif süreci, verilerle etkileşimde bulunma, kavramsallaştırma ve ardından yi neleme ile yeniden etkileşimde bulunma sürecidir. Nitel araştırmacılar, bu sü reç için açık kodlama da dahil olmak üzere birçok çerçeve önermiştir; burada metnin özelliklerine, metni organize eden veya başka şekilde tanımlayan no tasyonlar atanır (Corbin ve Strauss, 1990). Gözlemler arasındaki benzerlikleri n farklı boyutlarını dikkate alarak dikkatlice okuyarak, araştırmacı temellerde n kavramlar ve kategoriler oluşturabilir. Hesaplamalı destekli keşifteki amacı mız, okuyucunun metinle etkileşimde bulunma yeteneğini artırmak, uygulan abilir gruplamaları önermek, farklı fikirleri temsil eden belgelere okumayı yö nlendirmek ve analistin yorumlama çalışmalarını rehberlik etmektir.

Önceki bölümde, mevcut bir metin grubunu nasıl tanımlayacağım ızı tartıştık. Bu bölümde, denetimsiz kümeleme analizi kullanarak bel gelerin nasıl bölümlere ayrılacağını—karşılıklı olarak dışlayıcı ve kap samlı kategoriler—ele alacağız. Buradaki model seçimi ve kümeleri y orumlama konusundaki birçok fikir, konu modelleri ve belge gömm e konusundaki tartışmamıza aktarılacaktır.

Metin verileri için kümeleme algoritmaları, bir metin koleksiyon unu girdi olarak alır ve bu K kategorisine ve her bir K kategorisine belge atamaları içeren bir küme seti üretir, verilerin bir bölümünü oluşturur. Bu, belgelerin düzenlenme şeklinin sürecin bir parçası ol arak tahmin edilmesi nedeniyle keşfi kolaylaştırır, varsayılmak yeri ne. Her belge için küme atamasını tahmin edeceğiz; π i, belgenin k üme *k*'ye ait olması durumunda π i k = 1 ve aksi takdirde 0 olan bir one-hot kodlamasıdır. π i, benzer belgelerin aynı kümede veya kat egoride ve benzer olmayan belgelerin farklı kümelere atanacak şe kilde seçilir. Bu temel görev basit görünebilir, ancak birkaç ana adı mda içsel bir belirsizlik vardır ve bu da verileri bölme yöntemlerini n çoğalmasına yol açar—özellikle benzerliğin nasıl ölçüldüğü, bu b enzerliklerin çözümün genel kalitesini değerle
ndirmek için nasıl toplandığı ve ima edilen optimizasyon probleminin çözümüne yaklaşım.

Kümeleme işleminin otomatik kısmı kategorilerin oluşturulmasını içerir,bununl a birlikte araştırmacı hala girdileri vekümeleme prosedürünü seçmede yoğun bir ş ekilde yer almaktadır ve ardından sonuçları yorumlama aşamasında da yer alır. A

Doclingo https://www.doclingo.ai

Kümeleme yöntemlerinin küçük bir sınıfı, araştırmacının kümeleme süreci sırasında e tkileşimde bulunmasını, metnin birçok farklı organizasyonunu keşfetmesini içerir; nih ai bir bölünme, birçok potansiyelbölünmeyi keşfettikten ve dikkate aldıktan sonra ort aya çıkar (Grimmer ve King, 2011).

Sezgimizi odaklamak ve kümeleme algoritmalarına dair genel tartışma mız için bir referans sağlamak amacıyla, Bölüm 12.1'de klasik *k*-ortalama kümeleme algoritması ile başlıyoruz. Ardından, kümeleme sürecinin çeşit li bileşenlerini, metin için seçtiğimiz temsilleri (12.2), kümeleme yapmak i çin mevcut olan farklı yaklaşımları (12.3), model hakkında seçim yapma y öntemini (12.4) ve yorumlama ve etkileşim yaklaşımlarını (12.5) inceleme k için geri adım atıyoruz.

Doclingo https://www.doclingo.ai

12.1 *k*-Ortalama Kümeleme Kullanarak Başlangıç Örneği

Kongre araştırmacıları, Kongre üyelerinin kendilerini nasıl tasvir ettikleri yle uzun zamandır ilgilenmektedir. Ünlü bir şekilde, Mayhew (1974) Kongre üyelerinin iletişimlerini üç kavramsal türe ayırmıştır: kredi talep etme, pozi syon alma ve reklam yapma. Sürekli bir örnek olarak, Grimmer ve King (20 11) çalışmasında bir alıştırmayı kavramsal olarak tekrarlayacağız ve 558 ba sın bülteni kullanacağız. 2005 ve 2007 ABD Senatörü Frank Lautenberg'in ofisi. Lautenberg, 1982'den ölümüne kadar toplam 2 8 yıl boyunca görev yapan New Jersey'den bir ABD senatörüydü. 2013. Amacımız, Kongre üyelerinin faaliyetlerini seçmenlerine nasıl tanı mladıklarını kavramanın farklı ve yeni yollarını keşfetmektir.

Birçok yaygın kullanılan kümeleme algoritmalarından biri olan k-ort alama algoritması ile başlayacağız. Kümeleme işlemine başlamadan ön ce, belgelerimiz için bir temsil seçmemiz gerekiyor. Bölüm 5'te açıklana n kelime torbası tarifini kullanarak, N = 558 belgelerimizi her metnin b elgede her özelliğin ne kadar sıklıkla göründüğünü gösteren J × 1 sayı m vektörü olarak temsil ettiğimizi varsayalım. Belge uzunluklarında ön emli farklılıklar olduğu için, her sayım vektörünü belgedeki toplam tok en sayısına bölüyoruz, böylece W_i, artık belgede her token türünün oranını temsil ediyor. Sonuçta şunları elde ediyoruz: 7,118 unigramlar toplam.

Amacımız, belgelerimizi *K* kategorisine ayırmaktır; benzer kelim e kullanım oranlarına sahip belgeler aynı kümeye atanırken, farklı belgeler farklı kategorilere atanacaktır. Her bir *K* kategorisinin J × 1 ortalama vektörü μ k = (μ 1 k , μ 2 k , … , μ J k) tüm belgelerin *k*thkümesinin merkezini tanımlayan bir ifad edir. Bu durumda, normalize edilmiş kelime sayıları kullandığımız için, bu , *k*th kümesine ait belgelerin kullandığı ortalama oranı tanımlayacaktır. *j*th özelliği. Amacımız, yeniden ifade edersek, bir küme merkezleri seti μ bulmak ve belgel erimizi π öyle bir şekilde partition etmek olacak ki belgeler atandıkları küme merkezlerine yakın olsun.

k-ortalama'ya ulaşmak için, bu sezgiyi kesinleştirmemiz gerekiyor. Bir b elgenin ve küme merkezinin arasındaki farklılığı, kare Euclidean mesafesi o larak ölçeceğimizi varsayıyoruz:

$$d (W i , , \mu k) = \sum j = 1 J (W i j - \mu j k) 2 . \quad (12.1.1)$$

Bu benzerlik ölçüsünü kullanarak, herhangi birinin kalitesini değerlendirebiliriz.

Doclingo https://www.doclingo.ai

partition π v ve herhangi bir küme merkezi seti μ. *k*-ortalama algoritması har datamaları yapar, böylece her belge yalnızca bir kategoriye atanır (ve böylec evektör π i'nin yalnızca bir elemanı 1'e eşittir ve geri kalanlar 0'dır). Amaç fon ksiyonunu yazabiliriz—her çözümün kalitesini yansıtan ve optimizasyon algo ritmamızın minimize edeceği fonksiyon—şöyle:

$$f (\pi , \mu , W) = \sum i = 1 N \sum k = 1 K \sum j = 1 J W i j - \mu j k 2 \smile \text{dissimilarity measure} \pi i k \backsim \text{Cluster indicator} . (12.1.2)$$

Kelimelerle, amaç fonksiyonu, belgelerin atanan küme merkezlerinde n ne kadar farklı olduğunu ölçer ve bu farklılık tanımını Denklem 12.1. 1'den kullanır.

Bu hedef fonksiyon tanımıyla, en iyi yanıtı sağlamak için küme merkezle ri ve karşılık gelen küme atamaları kümesini bulmaya çalışıyoruz; bu, küme merkezi ile o kümeye atanan belgeler arasındaki kareler toplamı (yani, kar e hata toplamı) açısından en az kareler Euclidean mesafesini minimize etm ektedir. Ne yazık ki, 12.1.2 numaralı denklemi küme atamaları ve küme me rkezleri açısından optimize etmek zordur. Küme atamaları ayrık olduğunda n, genel doğrusal modeller gibi yaygın sosyal bilim araçları için kullanılan o ptimizasyon yöntemleri mevcut değildir. Bunun yerine, *k*-ortalama algoritması, Denklemi optimize etmek için yinelemeli bir algoritmaya dayanır. 12.1.2.

Küme merkezlerinin rastgele bir başlangıcıyla başlıyoruz. Bu parametreler k ümesine μ 0 adını vereceğiz. Bu başlangıç küme merkezleri setine dayanarak, her belgeyi en yakın olduğu merkeze (kareler Euclidean mesafesi açısından) atı yoruz. Bu küme atamaları setine π 1 adını veriyoruz. Ardından, bu yeni küme a tamalarına dayanarak, küme merkezlerini güncelliyoruz. *k*-uncu merkez için g üncelleme, μ k 1 şöyle:

$$\mu k 1 = \sum i = 1 N \pi i k 1 W i , \sum i = 1 N \pi i k 1 (12.1.3)$$

bu, *k*-uncu küme merkezine atanan belgelerin her boyut boyunca ortalamasıdır. Küme merkezlerinin yeni konumuna (μ) dayanarak. 1), en yakın merkez, birçok belge için değişmiş olabilir ve bu nedenle yeniden ata ma yaparak π 2'yi elde ediyoruz. Amaç fonksiyonundaki değişiklik, Denklem 12.1 .2, küçük bir eşik değerinin altına düştüğünde bu iki parametre setini güncellem eye devam ediyoruz. Algoritma, optimal küme merkezlerinin ve partition μ *, π * 'nin tahminlerini döndürür. Şekil 12.1 algoritma için sahte kodu sağlar.

Tanımladığımız algoritmanın, amaç fonksiyonunu küresel olarak minimize eden çözümü sağlayacağına dair bir garanti yoktur. Aksine, bu algoritma

Doclingo https://www.doclingo.ai

küresel optimal (kare Euclidean mesafelerin toplamını minimize etme anlamı nda) partition'un bir yaklaşık değerini üretecektir. Bu, analizimiz için önemli s onuçlar doğurur: tanımladığımız iteratif algoritma genellikle yerel optimuml arda (algoritmanın küresel olarak amaç fonksiyonunu minimize etmeyen bir noktaya yakınsadığı) sıkışıp kalır ve bu da algoritmanın tekrar eden çalışmala rı arasında çözümlerde istikrarsızlığa neden olur (Roberts, Stewart ve Tingley , 2016). Daha az istikrarsızlık ve daha iyi çözümler elde eden birçok başlangıç yaklaşımı vardır—amaç fonksiyonu ile ölçüldüğünde (Pena, Lozano ve Larran aga, 1999; Arthur ve Vassilvitskii, 2007; Celebi, Kingravi ve Vela, 2013).

Input: $\boldsymbol{W}$ (documents), K (number of desired clusters)

- Initialize a set of K cluster centers, $\boldsymbol{\mu}^0$
- While the change in the objective function (the sum of squared errors) remains above the threshold,
  - Set $\pi_{ik}^t = 1$ if document i is closest to center k in terms of squared Euclidean distance, set to 0 otherwise
  - Set $\boldsymbol{\mu}_k^t = \frac{\sum_{i=1}^N \pi_{ik}^t \boldsymbol{W}_{i,}}{\sum_{i=1}^N \pi_{ik}^t}$
- Return $\boldsymbol{\mu}^*$ and $\boldsymbol{\pi}^*$.

Şekil 12.1. *k*-ortalama Algoritması için Pseudocode

Tablo 12.1. Basın Bültenlerine *k*-ortalama Uygulaması

	Oran	Kelimeler
1	0.17	başkan, çalı, yönetim, sen, seçilmiş, şirket, oPEC, vergi, bay
2	0.16	senat, lautenberg, frank, r, açıklama, basın, washington, yorum, d, soru
3	0.28	yeni, jersey, menendez, secur, milyon, fon, hibe, kimya, nj, feder
4	0.39	sen, epa, fatura, hareket, yasa, güvenlik, aile, korumak, gerektirmek, kurban

Ancak, verilen çözüm küresel minimum olmasa bile,yeni organizas yonlar keşfetmek için hala faydalı olabilir. Metinlerintek bir *doğru* or ganizasyonu olmadığını unutmayın, bu nedenleamaç fonksiyonu, ben zer belgeleri bir araya getirmek için sadecefaydalı bir araçtır—belirli b ir amaç fonksiyonu için yalnızcayerel olarak optimal olan bir organiza syon, en anlamlı veilginç olanı olabilir. Bu nedenle, yaklaşık çözüm bil e,araştırmamız için faydalı kavramsallaşmalara yol açabilecekilginç m etin organizasyonları verebilir.

Doclingo https://www.doclingo.ai

Şimdi, elimizde bir çözümle, sonuçlara bakabiliriz. Tablo 12.1 \'te K = 4 ayarı ile *k*-ortalama algoritmasını uygulayarak elde edilenkü me özetini sağlıyoruz. Aşağıda kümeleri etiketleme prosedürlerini t artışıyoruz,bununla birlikte şu anda her küme için, o küme için orta lama vektör μ ile diğer kümelerin ortalama vektörlerinin ortalama sı arasındaki farkı alıyoruz. Kümeleri,μ k'nın küme k \'ya göre en bü yük pozitif farkı olan 10 kelimeyle etiketliyoruz.Hemen hemen hem en, ilk kesimden sonra kümelerin, Mayhew (1974)\'teanlatılan Kon gre temsilini anlama çerçevesine gevşek bir şekilde benzer olduğu nukeşfediyoruz.Küme 4'teki belgeler, "Lautenberg Specter, Devlet Destekli Terörizmin Kurbanlarına Adalet Vermek İçin Tasarıyı Tanıtı yor—Ölçüm, Kurbanların Terör Sponsorları Olan Ülkelerin Varlıklar ını Takip Etmelerini Sağlayacak" gibi yasama organının konusunu t artışma eğilimindedir; küme 3'teki belgeler ise senatörün New Jers ey için güvence altına aldığı fonlarla ilgili kredi talep eden belgeler dir, örneğin "Lautenberg ve Corzine, New Jersey Tarım Programları için 1
2 Milyondan Fazla Güvence Sağladı"; ve küme içindeki belgeler

2 reklam yasası başarıları ile ilgili gibi görünüyor, örneğin “Yurt Güvenliği Şefi Lautenberg’in İzinden Gidiyor, Riskin Siyaseti Geçeceğini Duyuruyor, Değişiklik Amerika’yı Daha Güvenli Hale Getirecek diyor Lautenberg.”

kümedeki kelimeler 1 bu kategorilendirmeye tam olarak uymuyor, “Lautenberg, Cumhuriyetçilerin Yetersizliğine Tepki VeriyorCumhuriyetçiler v e Başkan Bush, Nükleer Silah BilgileriniÇevrimiçi Yayınladı” gibi belgeler, Cu mhuriyetçi partiye veözellikle Bush yönetimine olumsuz yorumlar yapıyor. G rimmer ve King (2011) benzer bir kategori buldular ve bunu Kongre konuşm asının yeni bir kategorisi olarak önerdiler, “partizan alay.” Konuşma eylemini, başka bir siyasi partiye veya üyelerine yönelik açık, kamuya açık ve olumsuz bir saldırı olarak tanımladılar. Kategoriyi keşfettikten sonra, bu kategorinin y aygın olduğunu gösteriyorlar; partizan alayı tanımlamak için bir sınıflayıcı gel iştirerek (ölçüm kısmında gösterdiğimiz araçları kullanarak) ve bunu 301 sen atör-yılına ait 64,033 basın bültenine uygulayarak. Bu dış örnek veri setindeki basın bültenlerinin tam %27’sinin partizan alay olarak sınıflandırıldığını bulu yorlar.

Kısa bir *k*-ortalama keşfi nasıl gerçekleştirebileceğine dair bir genel bakı ş verdikten sonra, şimdi kümeleme sürecinin her bir parçasını, *k*-ortalama yerine seçebileceğimiz birçok farklı yaklaşımı keşfetmek için geri adım atıy oruz.

Doclingo https://www.doclingo.ai

12.2 Kümeleme için Temsiller

Bu bölüm kümeleme ile ilgilidir, ancak kümelediğiniz şeyin, kümeleme yönteminden çok daha önemli olduğunu vurgulamakta fayda var. Bu, Bölüm 2 'de tanımladığımız belge seçimi ve temsil süreçlerinin burada özellikle önemli olduğu anlamına gelir. Örneğin, kelime sayımlarını kullanmak yerine, belgeleri Bölüm 8 'de açıklandığı gibi kelime gömme yöntemleriyle temsil edebilirdik veya Bölüm 9 ' da açıklandığı gibi dilbilgisel veya adlandırılmış varlık etiketleri ekleyebilirdik.

Bir örnek vermek gerekirse, Launtenberg basın bültenlerindeki kelimeleri temsil etmek için önceden eğitilmiş GloVe kelime gömme yöntemlerini kullandık.[2] Her belgeyi içindeki kelimelerin gömme ortalaması olarak temsil ettik. Daha sonra bu belge temsillerini *k*-ortalama algoritmasına girdi olarak kullandık, *K*=6. Tablo 12.2 her küme için en iyi kelimeleri göstermektedir.[3] Çok benzer kümelerin ortaya çıktığını görüyoruz: ulaşım ve güvenlik (küme 1), ödüller ve onurlar hakkında ifadeler (küme 2), Başkan Bush ve Cumhuriyetçilerle alay etme (küme 3), New Jersey'deki hibe talepleri (küme 4), sağlıkla ilgili yasalar (küme 5) ve çevreyle ilgili yasalar (küme 6).

Doclingo https://www.doclingo.ai

12.3 Kümeleme Yaklaşımları

Az önce tanımladığımız iki kümeleme, aynı belgelerin düzenlenebileceği sayısı z yoldan sadece ikisidir. *k*-ortalama, denetimsiz kümeleme probleminin basit ve sezgisel bir çözümüdür; ancak "iyi" bir bölme oluşturmanın doğasında bulunan b elirsizlik, kümeleme yöntemleri üzerine büyük bir literatürün ortaya çıkmasına n eden olmuştur. Bu yöntemlerin her birinin nasıl gerekçelendirildiği, modellerin v e algoritmaların verinin temel yapısı hakkında hangi varsayımlarda bulunduğu v e yöntemlerin daha büyük veri setlerine ne kadar iyi ölçeklendiği konusunda öne mli farklılıklar vardır. Genel olarak iki tür kümeleme yöntemi vardır: istatistiksel karışım modelleri, bir veri üretim sürecini dağılımların dil iyle tanımlayan ve algoritmik kümeleme yöntemleri, bir çözüm üret mek için bir dizi adım tanımlayan.

Tablo 12.2: *k*-ortalama kümeleri, kelime gömme temsili kullanarak.

Küme	Kelime
1	yolcu, amtrak, demir yolu, güvenlik, gaz, lott, daha güçlü, önceden, onaylandı, milyar
2	mahkeme, o, demint, burr, mi, nc, adaylık, r, idi, madalya
3	irak, dc, amerikalı, başkan, birleşik, vergi mükellefi, aşağıdaki, açıklamayı, senatör
4	fonlar, için, duyurmak, il, milyon, olacak, nehir, hibe, proje, hudson
5	gelir, bakım, ilaç, çocuklar, sağlık, kapsama, programlar, yararlanıcılar, medicare, kesintiler
6	epa, kirlilik, sakinler, tehlikeli, yakın, çevresel, veriler, güvenlik, ajansı, kimyasallar

Farklı seçimlere dalmadan önce, her bir kümeleme yönteminin bileşenlerini tanımlıyoruz ve ardından modeller arasında meydana gelen bazı ana stilistik f arklılıkların bir genel görünümünü sunuyoruz. Daha sonra, Bölümde tanıtılan çok terimli temsili temel alan ve genişleten olasılıksal modelleri tartışıyoruz. 6, algoritmik yöntemler ve bu yaklaşımlar arasındaki bağlantılar.

12.3.1 BİR GRUPLAMA YÖNTEMİNİN BİLEŞENLERİ

Gruplama yönteminin temelleri veya onu tanımlamak için kullanılan di l ne olursa olsun, tüm gruplama yaklaşımlarının ya açıkça belirtilen ya da örtük olarak sabitlenmiş üç bileşeni vardır: 1) belge (benzerlik) farklılığı k avramı, 2) önerilen bir bölümlerin kalitesini ölçmek için bir hedef fonksiy onu, ve 3) bir bölümlerin kümesi üzerinde optimize etme yöntemi. Biz her bir bileşeni tanımlayın, *k*-ortalama ile ilişkilendirerek, ardından elde edilen b ölümler için nasıl önemli olduklarını açıklayın.

Doclingo https://www.doclingo.ai

Bileşen 1: Belge (Benzerlik) Farklılığı

İlk bileşen, iki belge arasındaki belge benzerliği/mesafesinin bir ölçü südür. Bu ölçü, iki belgenin benzer olmasının ne anlama geldiğini kesinl eştirir. k-ortalama algoritmasında, farklılık, kareli Öklid mesafesi kullanıl arak ölçülür. Diğer yöntemler, 7. Bölümde tartıştığımız gibi, çok daha g eniş bir mesafe ölçüleri setinden yararlanabilir. Örneğin, belgeler arası ndaki kosinüs benzerliği ölçüsünü kullanabilir, belgeler arasındaki Man hattan mesafesini hesaplayabilir veya bir çekirdek kullanarak bir çift bel genin benzerliğini ölçebiliriz. Bunlar, iki belgenin birbirine "benzer" olm asının ne anlama geldiğini kesin bir şekilde tanımlamanın farklı yollarıdı r.

Tüm kümeleme yöntemleri, yalnızca örtük olarak bile olsa, belge f arklılığı kavramını çağrıştırır. İstatistiksel karışım modelleri, belgeleri n üretim sürecini tanımlamak için olasılık dağılımları belirler ve bu d ağılımlar altında her belgeyi görme olasılıkları, belge farklılığı ölçüsü nü ima eder. k-ortalama, kareli Öklid mesafesini kullanır, ancak bun u Normal dağılımların bir karışımını kullanarak olasılıksal bir model aracılığıyla da ifade edebiliriz (Fraley ve Raftery, 2002). Biz aşağıda tartışılacak olan kosinüs benzerliği, von Mises-Fisher dağılı mı olarak adlandırılan bir dağılım aracılığıyla karşılık gelen bir olası lıksal yorumlama da sunar (Banerjee, Merugu, Dhillon ve Ghosh, 2 005). Daha genel olarak, geniş bir olasılık dağılımları sınıfı ile benze rlik ölçüleri arasında bire bir eşleme vardır (Banerjee, Merug u, Dhillon ve Ghosh, 2005).4 Benzerlik ölçüsünü seçmek, metin a nalizindeki en zorlu görevlerden biridir. Sezgisel olarak, belgelerin daha az veya daha fazla benzer olmasının ne anlama geldiğini hay al etmek kolay görünüyor. Ancak bu sezgisel benzerlik kavramını a çık bir ölçüme dönüştürmek zordur. Sonuçta, insanlar dil hakkında tam bir metin aracılığıyla akıl yürütmeye alışkındır, ancak biz bilgis ayarlara belgenin çok farklı ve daha sınırlı bir temsilini sunuyoruz. Denetimsiz yöntemler genellikle hızlı ve kolay çalıştırılabildiğinden, ölçüyü önceden dikkatlice düşünmek yerine, genellikle birkaç yönt emi çalıştırmak ve sonuçları son radan karşılaştırmak en kolay yol olacaktır.

Birden fazla model çalıştırmak ve en iyi olanı öznel olarak seçmek, geleneksel istatistiksel test yaklaşımlarına alışkın araştırmacılar için alarm zilleri çalabilir. Yine de, kavramsallaştırmalar keşfetmek tamamen farklı bir görevdir ve bu t ür bir yaklaşım doğası gereği sorunlu değildir. Bölüm 10'da belirttiğimiz gibi, bir kavramsallaştırmaya nasıl ulaştığınız önemli değildir çünkü evrensel olar ak “doğru” bir kavramsallaştırma yoktur. Keşif amacımız, gözlemlerin bazı

Doclingo https://www.doclingo.ai

yararlı temsillerini bulmaktır. Yeni verilerin nihai ilgi miktarını değerlendirme k ve çıkarım yapmak için kullanıldığı sürece, araştırmacıların yeni kavramsall aştırmalar “avlaması” konusunda bir endişe yoktur.

Bileşen 2: Bölüm Kalitesinin Ölçüsü

Belge (benzerlik) farklılığı kavramı verildiğinde, benzerlik ölçüsü ile ölç ülen bir bölümün kalitesini ölçebiliriz. Yukarıda açıkladığımız gibi *k*-ortala ma ile, belgelerimizin iyi bir bölümünün benzer belgeleri bir araya getire ceğini ve farklı belgeleri ayıracağını sezgisel olarak biliyoruz. Ancak, bu se zgiyi somut hale getirmek, hangi bölüm özelliklerini ölçeceğimiz ve hangi bölüm özelliklerinin daha az önemli olduğu hakkında varsayımlar gerekti rir. Örneğin, *k*-ortalama ile, her belgenin küme merkezinden ne kadar far klı olduğunu toplayarak bölüm kalitesini ölçeriz. Bu, sezgisel amacımızın bir kısmını gerçekleştirir—benzer belgeleri bir araya getirmek.
Ancak, farklı kümelerin ayırt ediciliği hakkında bilgi sağlamaz; bu, h edef fonksiyonda açıkça dikkate almak isteyebileceğimiz bir şeydir.

Hedef fonksiyonlar, bölümlerin kalitesini ölçmek için bize net bir st andart sağlar, ancak farklı yöntemler arasında karşılaştırmalar yapma k için kullanabileceğimiz mutlak bir küme kalitesi ölçüsü sağlamazlar. Ayrıca, bir kümenin belirli bir yöntemden geldiği için optimal olduğunu asla varsayamayız. Veri kümesinde ne olduğunu veya bir analizin genel hedeflerini net bir şekilde bilmeden, iki bölüm arasında ayırt etmemiz i mkansızdır. Bunun nedeni, hedef fonksiyonların farklı ölçeklerde olması , genellikle belge benzerliğinin farklı kavramlarına dayanması ve farklı t ürde projelerle ilgilenen araştırmacılar için faydalı olabilmesidir.
Hedef fonksiyonların sağladığı şey, belirli bir en iyi kavramına göre “en i yi” bölümü seçmek için iyi olan küme kalitesinin göreli ölçüleridir; bu, aç ıkça veya dolaylı olarak bir olasılık modeli aracılığıyla belirlenebilir.
Farklı hedef fonksiyonlar arasında karar vermek, temel bir kümeleme gör evi olacaktır.

Bileşen 3: Optimizasyon Algoritması

Kümeleme yönteminin son özelliği, bir veri seti verildiğinde, hed ef fonksiyonu optimize etmek için bir algoritmadır.
Optimizasyon algoritmaları gereklidir çünkü bir hedef fonksiyonuna göre en iyi böl meyi bulmak neredeyse hiçbir zaman basit değildir. Optimizasyonun zor olmasının bir nedeni, en iyi bölmeyi bulmanın, genellikle kalkülüsün yararlı kurallarının uygul anamadığı ayrık bölmeler üzerinde arama yapmayı gerektirmesidir. İkinci neden is e, küçük nesne setlerini bile bölme yollarının sayısının muazzam olmasıdır.

Doclingo https://www.doclingo.ai

100 belgeyi bölme yollarının sayısının 4.75 × 10^15'ten fazla olduğunu açıkladığımız gibi, bu, en iyi çözümü seçmek için tüm potansiyel çözümler üzerinde kaba kuvvet araması yapmanın imkansız olduğu anlamına gelir.

Global maksimum olan bölmeyi bulmak, o kadar büyük bir çaba gerektirecektir ki, bu yöntemleri işe yaramaz hale getirecektir. Yöntemler genellikle yaklaşık optimizasyon yaklaşımları kullanır. Bu, en iyi çözüm garantisinden sıklıkla vazgeçtiğimiz anlamına gelse de, kümeleme yöntemlerinin gerçek dünya ortamlarında çalıştırılabileceği anlamına gelir. k\-ortalama için kullanılan yinelemeli yer değiştirme şemasını içeren çok çeşitli yaklaşık yöntemler vardır. Optimizasyon için yeni yöntemler tanıtan geniş bir literatür bulunmaktadır ve kitap boyunca, sunduğumuz materyali sunmak için gerekli olduğunda algoritmaları tanıtacağız. Ne yazık ki, belirli optimizasyon pratikte oldukça önemli olabilir, aynı benzerlik ölçüsü ve aynı bölme kalitesi ölçüsü kullanıldığında bile.

Yaklaşım algoritmalarının kullanımı genellikle küresel optimal çözümden vazgeçmekten daha fazla maliyetle gelir. Yaklaşım algoritmaları genellikle kararsız çözümlerle sonuçlanır, bu da aynı algoritmanın iki kez çalıştırılmasının bazen farklı çözümlerle sonuçlanabileceği anlamına gelir. Yaklaşımları dikkatli başlangıç değerleriyle stabilize edebiliriz. Ancak, aşağıda tartıştığımız gibi, keşif için kümeleme yöntemleri kullanırken bu kararsızlık daha az sorunludur çünkü verilerimizi organize etmenin ilginç yeni yollarını arıyoruz. Bir bölme yalnızca yerel olarak optimal olsa bile, kavramsallaştırma için hala faydalı olabilir.

Tablo 12.3'te, aynı basın bültenlerini Tablo 12.1'dekiyle aynı yöntemle, ancak farklı başlangıç değerleriyle kümeliyoruz. Genel olarak, kümeler benzer görünse de, bazı farklılıklar olduğunu fark edeceksiniz. Özellikle, Tablo 12.3'te iki tanıdık küme görüyoruz - kredi talep eden küme artık küme 1, ve küme 2 alay etme ve reklam kümelerinin bir kombinasyonu; belki de bunu "açıklama" kümesi olarak yorumlayabiliriz. Küme 3 ve 4 ise yenidir. Küme 3 genel olarak yasalarla ilgiliyken, küme 4 esasen kimyasal ve ulaşım güvenliğine odaklanmıştır ve Senatör Lautenberg'in konteyner güvenliği üzerindeki çalışmalarını yansıtmaktadır.

12.3.2 KÜMELEME YÖNTEMLERİNİN STİLLERİ

Her kümeleme yönteminin yukarıda listelenen üç bileşenin bir versiyonu olsa da, kümeleme yöntemlerinin davranışını ve döndürdükleri bilgi türlerini önemli ölçüde değiştiren birçok başka stilistik özellik de vardır. Yöntemlerin çeşitliliği şaşırtıcıdır. Genel olarak, herhangi bir

Doclingo https://www.doclingo.ai

Bizim bu çeşitliliği tanımlayabileceğimizi iddia etmemiz biraptallık olur du—alanın genişliği, önemli ayrımları mutlaka kaçıracağımız anlamına geliyorve yeni yöntem üretim hızı, asla kapsamlı olamayacağımızı gös teriyor. Daha da önemlisi,belirli bir kümeleme yönteminin lehine yapıl an argümanlar genellikle abartılıyor,özellikle de kümeleme yöntemler ini keşif yapmak için kullandığımızda. Bu nedenle,tüm yöntemleri liste lemek yerine, en belirgin kümeleme yöntemleri türlerine odaklanıyor uzve ardından birkaç örnek veriyoruz.

Tablo 12.3. Basın bültenlerine k-ortalama uygulamak, Tablo 12.1'den farklı başlangıç değerleri ile.

Oran	Kelimeler
10.28	yeni, jersey, menendez, fon, proje, feder, milyon, program, counti, nj
20.21	senat, lautenberg, frank, r, açıklama, s, başkan, yorum, basın, takip
30.42	amerikan, aile, kurban, yasama, epa, yasa, libya, terör, sponsor, rapor
40.08	güvenlik, kimyasal, yurt, liman, yasa, risk, koruma, yönetim, dhs, tasarı

Olasılıksal vs. Algoritmik

Bu kitapta tartışılan birçok yöntemle olduğu gibi, en belirgin ayrım olasılıksal ve algoritmik yaklaşımlar arasındadır. Olasılıksal kümeleme yöntemleri bir veri ü retim sürecini tanımlar ve ardından verileri bu süreci tersine çevirmek ve gizli pa rametreleri öğrenmek için kullanır. Algoritmik modeller genellikle yararlı bir küm eleme oluşturma konusunda sezgiye dayalı bir çekimle motive edilir ve ardından kümeleme prosedürü hakkında metaforlar temelinde teoremler türetilir. Kümele meye yönelik her bir yaklaşım, iyi bir kümeleme oluşturmanın ne olduğu ve nesn el fonksiyonu optimize etmek için prosedürler üzerinde nesnel fonksiyonlar ima eder. Bu ayrımı daha aşağıda tartışacağız, ancak kısacası her iki model türünden de öğrenilecek çok şey var.

Yumuşak vs. Sert

Kümeleme algoritmalarıyla birlikte ayrı bir boyut, verilerin yumuşa k veya sert bir bölünmesini sağlayıp sağlamadığıdır. Verilerin sert bir bölünmesi, her belgeyi yalnızca bir kümeye atar. Yumuşak bir kümele me (bazen bulanık kümeleme olarak adlandırılır) yöntemi, bir belgeyi belirli bir kümeye belirli bir olasılıkla atayarak belirsizliği ifade eder.

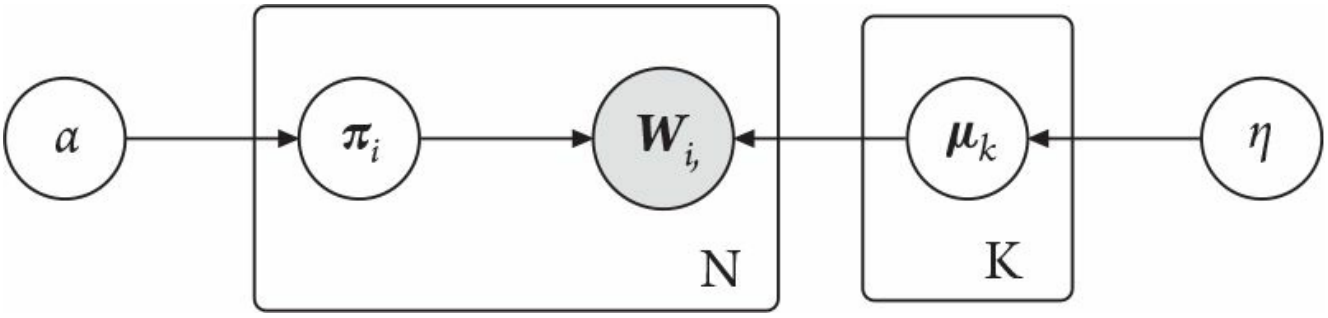
Algoritmik yaklaşımlar genel olarak sert kümeleme kullanma eğilimindeyken, model tabanlı yak laşımlar yumuşak kümeleme kullanma eğilimindedir. Genel olarak, fark, yüzeyde göründüğü ka dar önemli değildir. Yumuşak kümeleme yöntemleri her belgeyi bir kümeye doğru iterek, bulan ık yöntemlerin çoğu belgede tek bir kümeye en yüksek olasılığı yerleştirmesine neden olur.

Doclingo https://www.doclingo.ai

belirli belgeler için en yüksek olasılığı tek bir kümeye yerleştirir.

Ortalama vs. Mediodlar

Bir kümenin merkezi tanımlanma şekli, kümeleme yöntemleri arasında başka bir fark oluşturur. Bazı yöntemlerde, örneğin k-ortalama ve karışım modellerinde, küme merkezi, kümeye atanan belgelerin ortalamasıdır. Örneğin, k-ortalama yönteminde belgelerin merkezi, kümeye atanan belgelerin ortalamalarıdır. Buna karşılık, mediod yöntemlerinde kümenin merkezi, kümeye atanan bir belgenin tam üstünde yer almak zorundadır (medyanın bir set içindeki bir sayı olma zorunluluğu gibi, bağlamlar hariç). Örneğin, k-mediodlar, k-ortalama ile benzer bir tahmin prosedürüne sahiptir, ancak küme merkezi yeniden yerleştirildiğinde, kümeye atanan diğer belgelere olan mesafeyi minimize eden belge olarak belirlenir.



Şekil 12.2. Tipik bir olasılıksal karışım modelinin yapısı.
π , küme üyeliğini belirten vektördür ve w , bazı dağılım parametreleri için her belge için çekilir ve bu parametreler μ , küme-spesifik olan bir dizi parametre ile tanımlanır. α ve η , sırasıyla üyelik ve küme parametreleri üzerinde düzenleyici önbilgiler olarak işlev görür.

Düz vs. Hiyerarşik

Kümeleme yöntemleri, düz veya hiyerarşik olup olmamalarına göre de farklılık gösterir. Düz kümeleme yöntemleri, şimdiye kadar incelediğimiz yöntemlerdir; bunlar verilerin tek bir kümesini üretir. Hiyerarşik kümeleme yöntemleri ise gözlemlerin bir iç içe geçişini sağlar. Hiyerarşinin en üstünde tüm yöntemler bir araya gruplandırılırken, en altta gözlemler kendi kümelerinde yer alır.
Hiyerarşik yöntemler, ağaçta yukarı doğru hareket ettikçe giderek daha kaba kümeler oluşturmak için gözlemleri iç içe yerleştirir.

12.3.3 OLAĞANÜSTÜ KÜMELEME MODELLERİ

Şimdi kümeleme yöntemlerinin bazı özelliklerini tanımladıktan sonra, birkaç özel durumu kısaca gözden geçiriyoruz. Olasılıksal kümeleme yöntemlerinde yaygın yaklaşım, her bir verinin bir karışım modeli kullanarak varsayıldığı bir model kullanmaktır.

Doclingo https://www.doclingo.ai

nokta, bilinmeyen olasılık dağılımlarından bir kümeden kaynaklanmaktadır. Bu, Bölüm 6'da tartışmalı Federalist makalesini üç olası çok terimli dağılımd an birinin (her yazar için bir tane) kaynaklandığı şekilde görmemize benzer. Ana fark, yazar sorununda, her yazarla ilişkilendirilmiş bazı belgelerimizin ol ması ve bu nedenle belirli bir yazara ait her çok terimli dağılımı öğrenebilme mizdir; kümeleme problemi böyle etiketlere sahip değildir. Bunun yerine, tü m belgeler için etiketleri çıkaracağız, belgelerin kümelere atanmasını ve dağı lımların özelliklerini yineleyerek iyileştireceğiz, tıpkı *k*-ortalama ile yaptığımız gibi.

Karışım modelleri genellikle verilerin oluşturulma sürecini yansıta n ortak bir forma sahiptir ve aşağıdaki veri oluşturma sürecini takip eder.

- her bir küme için, k = 1'den *K'ye*
  - kümenin tanımını yapan parametreleri örnekle (μ k)
- her bir belge için, i = 1'den *N'ye*
  - belirli bir belge için bir küme örnekle (π i) çok terimli bir da ğılımdan
  - kümeden verileri μ π i ile parametreleştirilmiş dağılımı kullanarak ör nekle

Bu, verileri örneklemek için seçtiğimiz dağılıma bağlı olarak oldukça far klı davranabilen çok esnek bir modeldir. Kullanılan yaygın karışım mod elleri arasında çok terimli dağılımların karışımları (Nigam et al., 2000), n ormal dağılımların karışımları (Fraley ve Raftery, 2002) ve von Mises-Fis her dağılımlarının karışımları (Banerjee, Dhillon, Ghosh ve Sra, 2005) bu lunmaktadır. Olasılıksal karışım modelleri, modeli genişletmek, model s eçimi yapmak ve parametreleri tahmin etmek için ilkesel yollar sağlaya n istatistiksel altyapıyla birlikte geldikleri için caziptir. Örneğin, tahmin genellikle Beklenti-Maksimizasyon (EM) algoritması (Dempster, Laird ve Rubin, 1977) veya varyasyonel çıkarım (Wainwright ve Jordan, 2008) ar acılığıyla mümkündür.

Çok Terimli Karışım

Çok terimli karışım kümeleme modeli, olasılıksal, yumuşak,ortal ama tabanlı ve düz bir kümeleme yöntemidir. Ayrıca, etiketli veriler in olmadığı duruma,Bölüm 6'daki çok terimli modelin doğrudan ge nelleştirilmesidir. Veri üretim süreci şudur:

μ k ~ Dirichlet (α) (12.3.1) π i ~ Çok terimli (η) (12.3.2) W i , | m , π ben , M ben ~ Çok terimli (M i , μ π i) . (12.3.3)

Doclingo https://www.doclingo.ai

Bu model kendi başına faydalıdır (Nigam et al., 2000), ancak aynı zamanda Bölüm 13'te tartıştığımız modeller için bir yapı taşı olarak hizmet eder.

Sıklıkla olasılık modelleri belirli bir girdi verisi biçimi gerektirir. Çok terimli karışım modelinde,kelime sayımlarını alır ve M i parametresini dahil ederek belge uzunluğunu dolaylı olarakhesaba katar. Böylece, k-ortalama durumunda olduğu gibi, belgelerdeki kelime oranını kullanarak,çok terimli karışım modeli, benzer kelime sayısına sahip belgeleri değil,benzer kelime kullanım oranına sahip belgeleri gruplandırır. Burada çok terimli modelin bir avantajı,her belgede token sayısı hakkında bilgi korumasıdır ve böylece daha uzun bir belgenin,kısa bir belgeden daha fazla bilgi içerdiğini doğru bir şekilde yansıtabilir.

Von Mises-Fisher karışımı

Banerjee, Merugu, Dhillon ve Ghosh'un (2005) von Mises-Fisher modelinin karışımı, çok terimli modelin karışımına benzer, ancak kelime sayıları için çok terimli dağılımı von Mises-Fisher dağılımı ile değiştirir; bu, Bölüm 7'de tanımlanan kosinüs benzerlik metriği ile ilgili yönlü veriler için bir dağılımdır. Von Mises-Fisher dağılımı, verilerin vektörün büyüklüğü ile normalize edildiğini varsayar. Sayım verilerini W i olarak tanımlayarak, von Mises-Fisher verilerle çalışacaktır,

$$W i , * = W i , W i , (12.3.4) = W i , \sum j = 1 J (W i j - W i ' j) 2 . (12.3.5)$$

Veri üretim süreci şu şekildedir,

$$\mu k \sim \text{Dirichlet} (\alpha) (12.3.6) \pi i \sim \text{Multinomial} (\eta) (12.3.7) W i , * | \pi i , \mu \sim \text{von Mises-Fisher} (\phi , \mu \pi i) . (12.3.8)$$

Tablo 12.4. Von Mises-Fisher dağılımlarının Lautenberg basın bültenlerine uygulanması.

Küme	En İyi Kelimeler
1	sen, d, bill, kurban, aile, terör, askeri, libya, r, amerikan
2	secur, kimya, vatan, liman, risk, hukuk, dhs, koruma, tsa, demiryolu
3	yeni, jersey, fon, menendez, feder, proje, nj, milyon, program, ilçe
4	senatör, lautenberg, başkan, bush, frank, yayın, açıklama, birim, irak

Von Mises-Fisher dağılımı, normal dağılıma benzer ancak bir küren in yüzeyinde yer alır, bu da yönlü veriler için uygun hale getirir. μk dağılımın merkezidir ve ϕ dağılımın hassasiyetine benzer.

Doclingo https://www.doclingo.ai

Bu veri üretim süreci, kümeleme yöntemini tanımlamak için üç a na bilgi parçası sağlar.Von Mises-Fisher dağılımı, belge ile küme m erkezi arasındaki açının kosinüsünü ölçer.
Tam veri üretim süreci, nesnel fonksiyonu sağlayan bir olasılık mo deli tanımlar. Ve olasılığı optimize etmek için birçok yöntem vardır —EM algoritması en yaygın kullanılan yöntemler arasındadır (Dem pster, Laird ve Rubin, 1977).

Tablo 12.4 , von Mises-Fisher dağılımının karışımına dayanan Lauten berg basın bültenlerinin bir modelinden dört kümeyi tanımlar. Küme 1 (partizan alay etme) ve küme 2 (açıklamalar ve yasalar) *k*-ortalama küm eleme ile von Mises-Fisher kümeleri tarafından bir araya getirilmiştir. Von Mises-Fisher kümeleri, askeri yasalarla ilgili küme 1, *k*-ortalama kümes inden, küme 4'ün bir parçasıdır. Her iki kümeleme için de kredi talep etme kümesi olan küme 3, iki kümeleme arasında oldukça güçlü bir şekilde hizal anmaktadır.

Von Mises-Fisher karışım modeli, çok terimli karışım ile çok benzer bir yapıya sahiptir ancak benzerliği farklı bir şekilde kavramsallaştırır. Örneği n, çok terimliler her belgede kelime kullanım oranını dikkate alırken, von Mises-Fisher, normalize edilmiş vektörün hangi yöne işaret ettiğine baka r. Bu iki durumdan hiçbiri doğru ya da yanlış değildir, ancak belge büyükl üğünün farklı bir kavramını dikkate alırlar.

Diğer Olasılık Modelleri

Birçok başka olası olasılık modeli vardır, bunlar arasında Gauss k arışımı (Fraley ve Raftery, 2002) ve sosyal bilimcilerin latent sınıf an alizi (Lazarsfeld ve Henry, 1968). Değiştirerek karışım modelindeki olasılık dağılımında, hem belge benzerliğini h em de bölümlerin kalitesini değiştirdiğimizde, ancak iyi davranan b ir dağılım seti içinde kaldığımız sürece, optimizasyon algoritması g örece basit kalmaya devam edecektir (McLachlan ve Peel, 2004). Bu modellerin bir diğer avantajı, zaman içinde belgeleri iç içe yerleştirme (Quinn et al., 2010) veya yazar (Grimmer, 2010) gibi daha karmaşık veri hiye rarşilerinin yapı taşlarını oluşturabilmeleridir. Bu fikirlere Bölüm 13'de geri döneceğiz.

12.3.4 ALGORİTMİK KÜMELEME MODELLERİ

Algoritmik kümeleme yöntemleri, veri üretim süreci hakkında açık varsa yımlar yapmaz. Bunun yerine, belirli bir algoritma (örneğin, *k*-ortalama) ta nımlar ve performansı bazı açık bir hedef fonksiyonu ile ilişkilendirir.

Doclingo https://www.doclingo.ai

Tablo 12.5. Lautenberg basın bültenlerine yakınlık yayılımı uygulamak.

Küme	Üst Kelimeler
1	demiryolu, fatura, amtrak, yolcu, yıl, lautenberg, sistem, geliştirme, hizmet, ulaşım
2	başkan, açıklama, irak, bush, vergi, takip, william, birim, beyaz, birlik
3	güvenlik, yeni, kimyasal, jersey, güvenlik, yönetim, milyon, s, yasa, bush
4	eyalet, d, jersey, yeni, federasyon, senatör, menendez, sağlık, nj, r

Yakınlık Yayılımı

Affinity propagation, algoritmik, sert, mediod tabanlı ve düz bir kümeleme yöntemidir (Frey ve Dueck, 2007). Model, belgeler arasındaki benzerliği ölçen bir benzerlik matrisini alır; burada satır r ve sütun c'deki hücre, belge r'den belge c'ye olan benzerliği ölçer ve bu ölçümler, Bölüm 7'de tartışılanlar gibi ölçümler kullanır. Her kümenin bir merkezi belge vardır ve algoritma, belgeler ile merkezleri arasındaki benzerliği maksimize etmeye çalışır. Model, bir belgenin örnek olarak uygunluğunu belirleyerek ve diğer modeller için hangi belgelerin örnek olabileceğini değerlendirerek küme atamasını optimize eder. Önemli bir avantaj, affinity propagation'ın aynı algoritma ile çok çeşitli benzerlik ölçümleri kullanabilmesidir.

Affinity propagation, kümelerin sayısının dolaylı olarak ayarlandığı ve açıkça değil, gördüğümüz algoritmalardan da farklıdır. Benzerlik matrisinin diyagonal elemanları, kendine benzerliği temsil eder ve belirli bir belgenin örnek olarak seçilme olasılığını belirler. Bu sayı düşük olduğunda, genellikle az sayıda küme olacaktır ve sayı yüksek olduğunda, daha fazla belge ortaya çıkacak ve kendi kümelerini oluşturacaktır. Elbette, bu, kullanıcının küme sayısını ayarlama sorununu çözmez, çünkü yine de kendine benzerlik ölçüsünü ayarlaması gerekir. Ancak, farklı belgelerin farklı kendine benzerlik seviyelerine sahip olma olasılığını sağlar (ve böylece örnek olarak hizmet etme olasılıkları daha fazla veya daha azdır).

Kendine benzerliğin -7 olarak ayarlandığı Tablo 12.5'te kosinüs benzerliği kullanarak bir örnek veriyoruz; bu, dört küme ile sonuçlanır. Affinity Propagation, *k*-ortalama ile oldukça farklı bir kümeleme sağlar. *k*-ortalama ile 1 ve 2 numaralı kümeler—alay etme ve ifadeler—esas olarak ikinci Affinity Propagation kümelerine kümelenir. Ancak, *k*-ortalama ile 3 ve 4 numaralı kümeler, Senatör Lautenberg'in çalışmalarını ulusal ve New Jersey politikaları arasında ayırırken, Affinity Propagation'dan 3 ve 4 numaralı kümeler çalışmayı konusal olarak, güvenlik ve sağlık hizmetleri arasında ayırır.

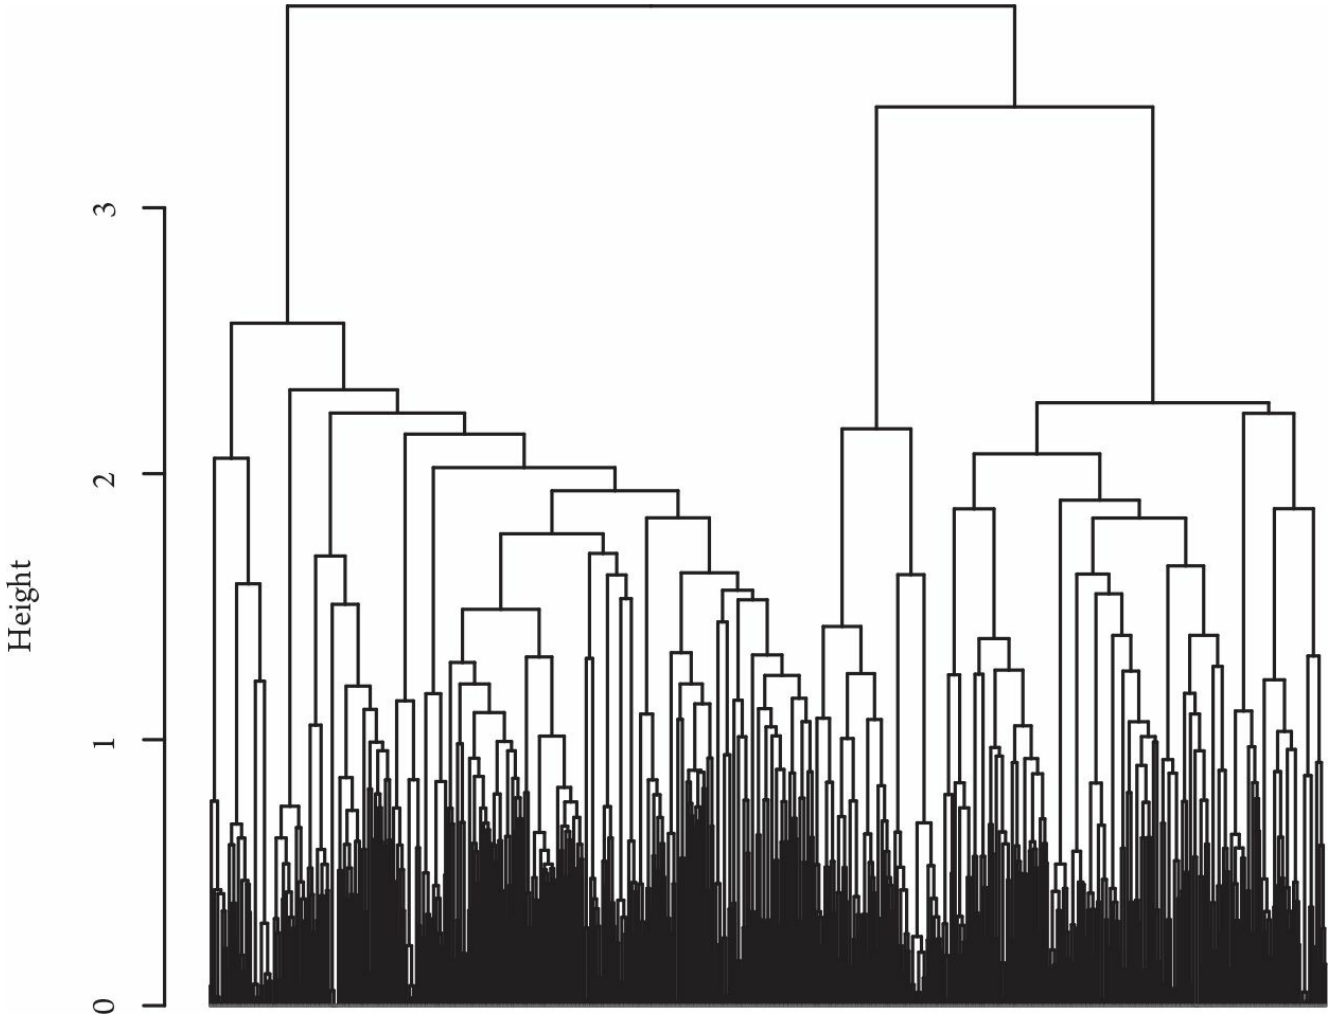
Doclingo https://www.doclingo.ai

Hiyerarşik Kümeleme

Hiyerarşik kümeleme, kendine özgü bir dünya olan farklı algoritmalar sınıfıdır (Ward Jr., 1963). Tek bir Belgelerin kümelere ayrılması, hiyerarşik kümeleme bir ağaç döndürürburada kümeler, en üstteki tek bir kümeden aşağıda kendi kümesinde bulunan herbireysel belgeye kadar ardışık olarak bölünür. Affinite yayılımına çok benzer,bu yöntemler genellikle farklı benzerlik ölçüleri için geniş bir çeşitlilik sağlar (bununla birlikte bu durumda genellikle simetrik olmaları kısıtlanmıştır).

Algoritma her zaman bir hiyerarşi döndürdüğü için, açıkça bir küme sayısı belirlemiyoruz. Ancak, kümeleri yorumlamak için ağacı belirli bir yükseklikte "kesmemiz" gerekiyor. Bu örneği görmek için, Lautenberg basın bültenlerinin hiyerarşik kümeleme örneği olan Şekil 12.3'e bakın. Ağacın yapraklarında, kümeler giderek daha spesifik hale geliyor. Ancak, ağacı yatay olarak 3. yükseklikte keserek, üç farklı küme elde ediyoruz. Tablo 12.6 bu üç küme için en ayırt edici kelimeleri göstermektedir. Belgelerin bir örneğini okuduğumuzda, bu kümelerin farklı yorumları var—küme 1 yasalaşma ve pozisyon alma ile ilgilidir, küme 2 kredi talebi ve kümeleme 3 ile ilgilidir ulusal ve yurt güvenliği. Farklı bir yükseklikte kesim yaparsak, bu kümelerin daha fazla alt bölümlerini göreceğiz.

Doclingo https://www.doclingo.ai



Şekil 12.3. Lautenberg basın bültenlerinin hiyerarşik kümeleme analizi Ward'ın minimum varyans yöntemi kullanılarak.

Tablo 12.6. Lautenberg basın bültenlerine hiyerarşik kümeleme uygulamak.

Küme	Üst Kelimeler
1	amerikan, dc, öldür, birim, tazminat, iki partili, john, yasal, r, md
2	jersey, menendez, yeni, nj, robert, ikamet, topluluk, proje, bahçe, iletişim
3	güvenlik, kimyasal, yurt, daha güçlü, dhs, önleyici, liman, benimse, say, saldırı

Diğer Algoritmik Yaklaşımlar

Diğer algoritmik yaklaşımlar vardır, bunların birçoğu kümeleme probl emini ilgili bir probleme dönüştürerek ele alır. Örneğin, popüler bir algor itma sınıfı olan spektral kümeleme, grafik kesme algoritmalarına yakın bi r analoga sahiptir—bir ağda sıkı bir şekilde bağlı toplulukları bulmaya çalı şan prosedürlerdir (Ng, Jordan ve Weiss, 2001). Pratik bir perspektiften b akıldığında, algoritmik yaklaşımlar genellikle cazip görünmektedir çünkü kullanılabilecek verilerin temsilinde bu kadar çok kısıtlama getirmezler;

Doclingo https://www.doclingo.ai

ancak, aynı istatistiksel altyapıya sahip değillerdir
olasılıksal muadilleriyle.

12.3.5 OLASILIK VE ALGORİTMİKKÜMELENME ARASINDAKİ BAĞLAR

Olasılıksal ve algoritmik kümeleme arasındaki farklar, tanımlamak için kullanılan dildeki önemli farklılıklara dayanarak göründüğünden daha küçüktür. Örneğin, *k*-ortalama, normal dağılımlardaki kovaryans matrisleri sıfıra gittiğinde normal karışımın bir sınır durumudur (Kulis ve Jordan, 2012; Broderick, Kulis ve Jordan, 2013). Ayrıca, yukarıda gösterdiğimiz gibi, farklı kümeleme algoritmaları da oldukça benzer çözümler üretmektedir.

Bu ayrım, kümeleme yöntemlerini kullanırken varsayımlar hakkında konuşma şeklimiz için özellikle önemlidir. *k*-ortalama genellikle temel veriler hakkında hiçbir varsayımda bulunmadığı şeklinde tartışılırken, normal karışımın verilerin küme içinde çok değişkenli normal dağıldığını varsaydığı görülmektedir. *k*-ortalama, verilerin üretim sürecinden bağımsız olarak belgelerin merkezlerine olan kare hata toplamını minimize etmeye çalışacak olsa da, Gauss karışım modellerinin de kare hata toplamını minimize etmeye dayandığını vurgulamak önemlidir. Olasılıksal karışım modellerinde kodlanan dağılımsal varsayımlar, aslında *k*-ortalama ile verilen belge benzerliği ve bölme kalitesi ölçüsünü kodlamaktadır. Doğrusal regresyon, veriler koşullu olarak normal dağıtılmadığında bile iyi tanımlanmış bir yaklaşım olarak anlaşılabilir (Aronow ve Miller, 2019), bu nedenle olasılıksal karışım modelleri. Elbette, 3. İlkemizle tutarlı olarak: Kavramı Yargıla, Yöntemi Değil Bölüm 10'da, varsayımlar hakkında çok daha az endişeliyiz, ilginç içgörüleri belirlemek ve ardından bunları yeni verilerle doğrulamaktır.

Doclingo https://www.doclingo.ai

12.4 Seçim Yapma

Analistler, kümeleme sırasında etiketleri önceden belirlemeseler de, yine de çok sayıda seçim yapmak zorundadırlar; bunlar arasında: temsil, kümeleme yöntemi, küme sayısı ve genellikle ek önemli hiperparametreler bulunmaktadır. Bu bölümde, bu seçimleri nasıl yapacağımızı konuşacağız.
Model seçimi hakkında bazı genel tavsiyelerle başlıyoruz ve ardından belirlenmesi gereken en yaygın parametre olan küme sayısını tartışıyoruz.

12.4.1 MODEL SEÇİMİ

Belirli uygulamamız için hangi kümeleme yönteminin daha yararlı olduğunu belirlemek için hangi metrikleri kullanabiliriz? Tek bir "doğru" kavramsallaştırma olmasa da, belirli bir görev için hangi metin organizasyonunun daha yararlı olacağını bize söyleyebilecek metrikler üzerinde karar verebiliriz. Bu bölümde, hem istatistiksel rehberliğe hem de insan değerlendirmelerine dayanarak küme kalitesini değerlendirmek için bazı stratejileri tanımlıyoruz.

En faydalı kümeleme yöntemini belirlemek, araştırmacının nicel kanıtları dik kate almasını gerektirir, ancak aynı zamanda karşılaştığı belirli sorunu, projeni n maddi hedefini göz önünde bulundurmasını ve farklı kümelemeleri değerlen dirmesini de gerektirir. Bu, tek bir istatistiğin model seçiminde yeterli olmayac ağı anlamına gelir, ancak istatistikler yine de faydalı olabilir. Tercih ettiğimiz pr osedür, kümelerin faydasını temsil eden istatistikleri, araştırma ekibi dışındaki güvenilir insan değerlendirmelerini elde etmemize yardımcı olan deneyleri ve f arklı potansiyel kümelemelerin manuel derin incelemesini kullanacaktır.

İstatistikler

Belirli bir kümelemeyi seçmek için faydalı olan iki ek istatistik tan ıtıyoruz: ayrışma ve bütünlük (Roberts ve diğ., 2014; Mimno ve diğ., 2011). Ayrışma ve bütünlük üzerindeki odaklanmamız, "f aydalı" bir kümelemeyi neyin oluşturabileceği konusundaki sezgimizde n gelmektedir. Genellikle amacımız benzer belgeleri aynı gruba koymak olacaktır, bu nedenle dilin aynı bütünlükte kullanıldığı belge gruplarını tanımlayacağız: aynı gruptaki belgelerin içeriği benzerdir. Elbette, küme lerin sayısı arttıkça, her küme içindeki belge grupları daha bütünleşik h ale gelecektir, ancak aynı temel içeriği tekrarlayan birkaç küme olabilir. Genellikle, belirgin kümeler oluşturmakla ilgileniyoruz. Bu nedenle, fay dalı bir kümelemenin ikinci özelliği, kümelerin ayrışık olmasıdır: birkaç k üme aynı temel içeriği tekrarlamaz.

Roberts ve ark. (2014) ile Mimno ve ark. (2011) ekindeki tartışmaları takip ediyoruz.

Doclingo https://www.doclingo.ai

Öncelikle, bir dışlayıcılık tanımını düşünelim. Bir kümenin dışlayıcı old uğunu söyleyeceğiz eğer bir kümedeki üyeliği tanımlayan “en iyi” keli meler diğer kümelerdeki üyeliği de tanımlamıyorsa. Özellikle, her kü menin bir merkez vektörü μ k = (μ 1 k , μ 2 k , … , μ J k) olduğunu vars ayalım; burada μ j k, küme k'deki j'inci kelimenin görünme olasılığını t anımlar. Her küme için en büyük M ağırlığı seçebiliriz ve M en büyük a ğırlığa sahip kelimelerin indekslerini $\mathscr{M}$ k'ya toplayabiliriz. Her m keli mesi için m ∈ $\mathscr{M}$ k dışlayıcılığı şu şekilde tanımlayabiliriz:

$$\text{Exclusivity m k} = \mu \text{ m k} \sum \text{k} = 1 \text{ K } \mu \text{ m k} .$$

Bir kelime mümkün olduğunca dışlayıcıysa—sadece bir kümede kullanılıyorsa—o za man dışlayıcılık 1'dir. Eğer kelime hiç dışlayıcı değilse ve kümeler arasında eşit olarak kullanılıyorsa, o zaman puan 1 K olacaktır. Ve eğer diğer kümelerde daha sık kullanılı yorsa, puan daha da küçük olacaktır.

O zaman kümeler için dışlayıcılık puanlarını kelimeler ve kümeler ara sında toplamak suretiyle bir araya getirebiliriz. Belirli bir kümeleme için *K* kümeleri, ortalama ayrışıklığını şöyle tanımlayabiliriz

$$\text{Average Exclusivity} = 1 \text{ K} \sum \text{k} = 1 \text{ K} \sum \text{m i n M k Exclusivity m k} .$$

Kapsayıcılığı ölçmek için Mimno ve diğerlerinin benimsediği stratejiyi kullanıyoruz. (2011) ve iki kelimenin, bir belgenin bir kümeye ait olduğunu gösteren kelimelerin, o kümeye ait belgelerde ne ölçüde birlikte bulunduğunu in celeyin. D( ) fonksiyonunu, argümanlarının belgelerde kaç kez geçtiğini sayan bir fonksiyon olarak adlandırın. Örneğin, m1 ve m2 indekslerini s ağlarsak, D(m1, m2) kelimelerinin m1 ve m2'nin belgelerde kaç kez birli kte bulunduğunu sayarken, D(m1) kelimesinin m1'in geçtiği belge sayısı nı sayar. Eğer tekrar tüm en üst M kelimelerini $\mathscr{M}$ kümesine toplarsak, o zaman bir kümenin bütünlüğünü şöyle tanımlayabiliriz:

$$\text{Cohesion} = \sum \text{n} = 1 \text{ M} \sum \text{l} = 1 \text{ l} - 1 \log \text{D} (\text{m n} , \text{m l}) \text{ D} (\text{m l}) . \quad (12.4.1)$$

Ve kümeler arasında ortalamayı alarak bir kümeleme düzeyindebütünlük ölçüsü hesaplayabiliriz.

Roberts ve ark. (2014) tarafından belirtildiği gibi, farklı küme sayısı na sahip modeller arasında bütünlük ve dışlayıcılığı karşılaştıramayız, çünkü farklı kümeler farklı kısıtlamaları ima eder. Ayrıca, dışlayıcılığı a rtırmak, mutlaka bütünlükte bir düşüşe yol açacaktır, bu nedenle istat istikler, seçilecek tek model hakkında belirli bir öneri sunamaz. Ama

Doclingo https://www.doclingo.ai

kapsayıcılık ve dışlayıcılık ölçüleri, kapsayıcılık/dışlayıcılık sınırında y er almamızı sağlayabilir: kapsayıcılık ve dışlayıcılık ticaretini en iyi y öneten model setleri.

Deneyler

İstatistikler, karar verme süreçlerini yönlendirmek için faydalıdır, ancak kümel enmenin güvenilir insan değerlendirmelerini de dahil edebiliriz. Burada iki böyle deneyi inceliyoruz: konu-dışlayıcı tespiti ve genel küme değerlendirmesi. Her biri , kümelerin içeriğiyle etkileşime girerken insanların bilişsel sınırlamalarına dikkat ederken, kümelenmenin insan değerlendirmesini enjekte etmeye çalışır.

Öncelikle, Chang ve ark. (2009) tarafından ilk kez tanıtılan konu-dışlayı cı deneyini ele alıyoruz. Konu dışlayıcı deneyinin sezgisi, eğer bir küme se ti hem kapsayıcı hem de dışlayıcıysa, belirli bir kümeye ait olmayan dili ko layca tespit edebilmemiz gerektiğidir. Yine, bir küme μ k için gösterge nit eliğinde kelime ağırlıklarımız olduğunu varsayalım ve her küme için en iyi M kelimeyi belirlediğimizi varsayalım. Eğer bir küme, kapsayıcı ve dışlayı cı bir dil içeren belgeleri bir araya getiriyorsa, o zaman bu M kelimelerle k azara karıştığında başka bir kategoriden bir üst kelimeyi tespit edebilece ğimizi beklemeliyiz. Bunu test etmek için, rastgele bir dışlayıcı seçiyoruz. Özellikle, rastgele farklı bir küme seçiyoruz ve ardından o diğer kümeden en iyi kelimelerden birini dışlayıcı olarak rastgele seçiyoruz.
O zaman, belirli konumuzdan M + 1 kelime içeren bir listeye sahibiz, *M* ve diğer konudan bir kaçak kelime.

Konu-kaçak deneyinin anahtarı, deney katılımcılarından kaçak kelimeyi tanı mlamalarını istemektir. Kaçak konu kelimelerinin tespit oranı ne kadar yükseks e, model bu insan değerlendirmesi altında o kadar iyi performans gösterir. Anlamlı karşılaştırmalar yapmak için kodlanması gereken örnek sa yısı, karşılaştırma modellerinin konu-kaçak oranına bağlıdır.
Genel olarak, kümelenmeler için konu kaçak tespit oranı ne kadar düşükse, kodl ama gerektiren daha fazla örnek vardır. Bunun nedeni, konu kaçak oranı çok yük sek olduğunda konu kaçak oranının varyansının çok düşük olmasıdır. Ying, Mont gomery ve Stewart (2019) bu tasarımları genelleştirir ve bir küme için insan tarafı ndan seçilen etiketi doğrulamaya yardımcı olan yeni görevler geliştirir.

Grimmer ve King (2011), bir kümelenmenin kalitesini tahmin etme ve karşılaştırmalar yapma konusunda farklı bir yaklaşım önermektedir. Bu k üme kalitesi ölçüsünün arkasındaki sezgi, yüksek kaliteli kümelenmelerin okuyucuların benzer olarak değerlendirdiği belge çiftlerini bir araya geti rmesi ve benzer olmayan belge çiftlerini ayırması gerektiğidir. Bu fikri ins an okumasıyla değerlendirmek için ilk adım, aynı kümeye atanan belge çi ftlerini ve farklı kümelere atanan belge çiftlerini örneklemektir. Sonra,

Doclingo https://www.doclingo.ai

değerlendiricilerden belgelerin çiftlerini üç puanlı bir ölçekle değerlendirmeleri istenir. Belgeler, benzerlik yoksa 1, biraz benzerlik varsa 2 ve çok benzerle rse 3 alır.Kodlayıcılardan alınan değerlendirmeleri kullanarak, aynı kümeye atanan belgelerin ortalama değerlendirmesi hesaplanır ve farklı kümelere atanan belgelerin ortalama değerlendirmesi hesa planır. Son olarak, bir küme kalitesi hesaplaması yapılır:

Küme Kalitesi = Ortalama Aynı Küme − Ortalama Farklı KümeKü

melemeler, aynı kümeye atanan belgeler farklı kümelere atananlardan d aha yüksek değerlendirildiğinde daha yüksek küme kalitesine sahip olaca ktır.

12.4.2 DİKKATLİ OKUMA

Özellik ve bütünlük ölçüleri ile donanmış olarak ve potansiyel olarak belirli kümelemelerin deneysel ölçümleri ile, belirli bir kümelemeyi nihai olarak se çmeye hazır hale geliyoruz. Elbette, istatistikler tek başına yetersizdir. Bunun nedeni, istatistiklerin ve deneylerin çelişkili öneriler sunması olabilir. Özellikl e, kümelemelerin bir alt kümesi potansiyel olarak geçerli organizasyonlar ola rak kalabilir. Kümelemeler arasında karar vermenin tek yolu, organizasyonla rı dikkatlice değerlendirmek, ne anlama geldiklerini ve daha fazla analiz için ne gibi sonuçlar doğurduklarını düşünmektir.

Belgeleri okumak, organizasyon ve araştırma sorusuna dair ken di maddi bilgimizle yönlendirilerek, kümelenmelerin anlamını anla mak için gereklidir. Örneğin, basın bültenleri örneğimizde, bazı ara ştırma soruları kimyasal ve ulaşım güvenliğine dikkat ölçmeyi gere ktirebilir. 12.3, diğer sorular için bu küme büyük ölçüde alakasız olacaktır. Diğer sorular için, taraflı alay etme veya kredi talep etme daha yararlı kavramlar olabilir. Metinle yakından etkile şimde bulunmak ve belgeleri organizasyon ışığında okumak, dünyayı gözlemleme konusunda yeni içgörüler ve kavramsallaştırmalar sağlamaya eğilimlidir.

12.4.3 KÜMELERİN SAYISINI SEÇME

Şu ana kadar analizimize dahil edilecek küme sayısını bildiğimizi varsayd ık, ancak genellikle bu, bireylerin keşfetmek istediği bir miktardır (kümeleri n içeriğiyle birlikte). Bu bölümde, ilk olarak bir kümelenmedeki küme sayısı nı belirlemek için kullanılan yaygın yöntemleri gözden geçiriyoruz. Ardında n, bu yöntemlerin eksikliklerini ve küme sayısını seçmenin alternatif bir yol unu tartışıyoruz.

Doclingo https://www.doclingo.ai

Kümelerin Sayısını Belirlemede Yaygın Stratejiler

İlk bakışta, kümeleme elde etmek için kullanılan amaç fonksiyonunun, k ümelerin sayısını belirlemek için bilgi sağladığı görünebilir. Bu belirlemeyi yapmak için kümeleme yöntemlerinin mekanizmasını kullanmaya çalışmak cazip olabilir. Örneğin, k-ortalama yönteminden elde ettiğimiz bölümleri k arşılaştırmak için k-ortalama amaç fonksiyonunu kullanabileceğimiz (sezgi sel olarak) düşünülebilir. Ne yazık ki, örnek içi uyum, kaç küme dahil edilec eği konusunda bir rehber sağlayamaz. Bunun nedeni, k-ortalama amaç fon ksiyonunun, birçok diğer istatistiksel model gibi, daha fazla küme bileşeni (parametre) eklendikçe iyileşmesidir. Amaç fonksiyonunun yalnızca tavsiyes ini takip edersek, her belgeyi kendi kümesine yerleştirme önerisiyle karşıla şırız.

Kaç küme dahil edileceği konusunda rehberlik sağlamaya çalışa n birçok nicel yöntem bulunmaktadır (Fraley ve Raftery, 2002). Kü me sayısını belirlemede sayısal yaklaşımların temel sezgisi, iki reka bet eden endişeyi dengelemek için bir ceza teriminin kullanılabilec eğidir. Bir yandan, belgelerimizdeki büyük varyasyonu yakalamak ve anlamlı ilginç metin gruplarını bulmak için yeterli sayıda kümey e sahip olmak isteriz. Diğer yandan, çok fazla model karmaşıklığınd an kaçınmak isteriz: çok benzer metinleri bölen veya esasen aynı “t ipte” belgeleri bir araya getiren birçok küme oluşturmak. İstatistiks el yöntemler bu probleme birkaç yaklaşım sunar.

Belki de kümelerin sayısını belirlemek için en öne çıkan yöntem gr uplarından biri, kümeleme ile ilgili nesnel fonksiyonu temel alır ve ek küme bileşenleri için bir ceza ekler. Örneğin, verileri kümelendir irken bir karışım modeli kullanıldığında, yeni kümelerin eklenmesin i cezalandıran Akaike Bilgi Kriteri (AIC) ve Bayes Bilgi Kriteri (BIC) (F raley ve Raftery, 2002) gibi kolayca erişilebilen istatistikler vardır. Bu ceza, yeni bir kümeleme bileşeni eklemek için model uyumundaki i yileşmenin ek parametreler için cezayı aştığını bilmemizi sağlar.

Alternatif olarak, birkaç yöntem, kümelerin sayısını tahmin etme sürec inin bir parçası olarak tahmin etmeye çalışır. Örneğin, yakınlık yayılımı, ar aştırmacının kümelerin sayısını belirlemesini gerektirmez, ancak kendine benzerlik parametresi, ortaya çıkması muhtemel kümelerin sayısını belirl er (Frey ve Dueck, 2007). Parametre dışı Bayes yöntemleri, istatistiksel m odellerde karşılaştırılabilir bir yaklaşım sunar. En yaygın kullanılan param etre dışı Bayes önceliği, parametreler yerine dağılımlar üzerinde bir önce lik olan Dirichlet süreç önceliğidir (Blackwell ve MacQueen, 1973). Veriyi ü reten süreç artık sonsuz sayıda küme olduğunu varsayıyor,

Doclingo https://www.doclingo.ai

veri setimizde görünen sonlu sayıda.

Hem parametrik olmayan hem de ceza tabanlı yaklaşımlar, tamdataset'e uygulanır ve istatistiksel modellerin açgözlülüğünü düzeltmeye çalışır; bu, m odeli daha az küme kullanmaya yönlendiren bir ceza ile yapılır. Küme sayısını belirlemenin diğer yaklaşımları, ek kümelerin, eğitimden ayrılan belgeleri ta hmin etmede ne kadar iyi yardımcı olduğunu değerlendirir (Wallach ve diğ., 2009). Ek kümeler eklemek her zaman örnek uyumunu artırır, ancak çok f azla küme aşırı uyuma yol açar—sinyal yerine daha fazla gürültü yakalar —ve performansı düşürür.

Küme Sayısını Seçmede Nicel Yaklaşımların Eksiklikleri

Model seçimi için nicel yaklaşımların bir eksikliği, nihai bir model i seçmek için kör bir araç olmalarıdır ve nicel yaklaşımlardan elde e dilen çıktılar ile keşif için en yararlı model arasında yalnızca zayıf bi r ilişki olabilir. Bu bölümün başında tartıştığımız gibi, belirli bir araş tırma sorusu olmadan, belgeleri kategorilere ayırmanın tek bir "do ğru" yolu yoktur. Kümeleme yöntemleri için nesnel fonksiyon, küm elemenin veriye ne kadar "iyi" uyduğunu model veya mesafe metri ğine göre özetlemeye çalışır. Bu nesnel fonksiyon, metinlerin yarar lı bir organizasyonunu sağlayabilir, ancak yalnızca bir istatistik kull anarak model uyumları arasında seçim yapmak zor olabilir. Ancak sorun daha da zorlaşır, çünkü otomatik yöntemlerin seçtiği bölüml er ile maddi araştırmalar için en yararlı bölümler arasında yalnızca zayıf bir ilişki vardır. Chang ve diğ.(2009), belirli bir belge seti için, i nsanlardan olumlu bir puan alan yöntemler ile otomatik değerlend irme yöntemlerinin puanları arasında negatif bir ilişki olduğunu gö stermektedir. Bu, metin temsilinin basitleştirilmesi ile daha da kötü leşmektedir. Ön işleme adımlarımız, metinleri bir belge-terim matri sinde temsil ettiğimizde önemli bilgileri atar.

Genel hedef—yararlı bir kümeleme bulmak—belirsizdir çünkü “ilginç” olanı doğrudan nasıl modelleyeceğimizden emin değiliz. Genellikle, önceden neyin yararlı olacağını tanımlamak imkansızdır, hatta kümeleme sonrası neyin aydınlatıcı olduğunu biliyorsak bile. Sonuç olarak, istatistiksel prosedürleri kullanarak kategorileri keşfetmek, ilginç organizasyonları kaçıracak ve kategori sayısını belirlemek için yetersiz olacaktır.

Araştırmacıların metnin çeşitli organizasyonlarını keşfetmek için geniş bir küme boyutu yelpazesi denemelerini öneriyoruz. Genellikle, analistleren çok hangi kü meleme ayrıntısına ilgi duyduklarına dair bir fikre sahip olacaktır. Örneğin, bir araştırmacıbir gazete veri setini tek bir araştırma sorusu için analiz ederken “Sporlar,” “D ış İlişkiler” ve “Hava Durumu” gibi geniş kategorileri tanımlamak isteyebilir, ancakbaşka bir araştırma sorusu için “Futbol,” “Amerikan Futbolu,” “Beyzbol,” “Uluslararası Ticaret,” “Yurt Dışında Seçimler,”“Hava Durumu Tahmini” veya “Bugünkü Hava Durumu” gibi daha spesifik alt kategorilere ihtiyaç duyabilir.

Doclingo https://www.doclingo.ai

Araştırma sorusu, en ilginç kümeleme ayrıntısını belirleyecektir. Ar aştırmacı ayrıntıya karar verdikten sonra, Bölümde tanıtılan yönte mlere geri dönebilir.

Alternatif kümelenmeler arasında karar vermek için 12.4.

Farklı küme sayılarının farklı kavram granülariteleri ile sonuçlanacağını göster mek için, Lautenberg Basın Bültenlerini dört yerine 40 küme kullanarak kümelen dirdik. Küme merkezini temsil eden kelimeleri Tablo 12.7'de gösteriyoruz. Bu da ha küçük kümelerin, önceki örneklerde tartıştığımız daha büyük kümeleri böldüğ ü açıktır. Örneğin, Tablo 12.3'teki kimyasal ve ulaşım güvenliği kümesi artık kimy asal güvenlik ile ilgili 36. kümeye ve ulaşım güvenliği ile ilgili 23. kümeye bölünm üştür ve bu da bize kümenin daha granüler bir görünümünü sağlamaktadır. Dah a fazla küme sayısı, daha önce kaybolmuş olabilecek kümelerin ortaya çıkmasına da olanak tanır; örneğin, 16. küme, Senatör Lautenberg'in kamu alanlarında sig ara içmeyi yasaklama konusundaki çalışmalarını yansıtmaktadır. Kendi çalışmala rımızda, iyi bir yaklaşımın birçok küme ile başlamak ve kümeleri bir araya getirer ek daha büyük kategoriler ve kavramlar oluşturmak olduğunu bulduk.

Tablo 12.7. Lautenberg basın bültenlerinden oluşan 40 küme.

Küme	En İyi Kelimeler
1	ev, yazar, son tarih, sistem, yönetici, varlık, yeni, hud, genel, genişlet
2	epa, çocuklar, kütüphane, test, mercuri, koruma, ajans, kimyasal, ürün, sağlık
3	s, u, şirket, iran, yabancı, iş, halliburton, kontrol, havayolu, yaptırım
4	güvenlik, milyon, fon, hibe, jersey, nj, yurt, liman, yeni, dhs
5	program, eğitim, gıda, çete, eğitim, gençlik, sağlamak, iş, erteleme, fon
6	yeni, jersey, eyalet, ilan, menendez, federal, ilçe, felaket, faa, yönetim
7	askeri, artış, sen, aile, tricar, d, afganistan, co, emekli, ücret
8	bütçe, yeni, milyon, kesinti, jersey, başkan, highland, s, bush, eğitim
9	yangın, güvenlik, hibe, departman, itfaiyeci, kolej, kampüs, yardım, nj, öğrenci
10	havaalanı, hibe, almak, federal, jersey, menendez, fon, iyileştirme, duyuru, yeni
11	alan, epa, ringwood, süperfon, kirlenme, temizlik, rapor, kalıntı, çevre, ajansı
12	başkan, bush, s, senato, irak, açıklama, yönetim, beyaz, sosyal, iraklı
13	aralık, güvenlik, koruma, orman, warren, hava, ateş, resid, topluluk, hesap
14	senato, lautenberg, komite, monmouth, irak, frank, komiser, fort, cumhuriyetçi, r
15	amerikan, kadınlar, onur, gao, irak, haber, canlı, bay, aşı, propaganda
16	sigarayı, tütün, hafif, katran, şirket, nikotin, pazar, sigara içen, düşük, d
17	geniş bant, belediye, erişim, teklif, sağla, topluluk, eyalet, karşılayabilir, kamu, yasakla
18	şirket, park, silah, doğa, plaj, palmyra, koy, mühendis, kazı, mühimmat
19	inşa et, enerji, emisyon, tasarı, küresel, yönetim, ısınma, sera, yeşil, feder
20	fon, yeni, jersey, proje, menendez, ulaşım, milyon, program, sayım, tünel
21	sözleşme, başkan, t, dedi, sekreter, hud, almak, jackson, seçmek, don

Doclingo https://www.doclingo.ai

22 okyanus, su, eyalet, korumak, tasarı, evcil, plaj, ihbar, yasama, ulus
23 güvenlik, liman, yurt, risk, tsa, tarayıcı, demiryolu, senato, chertoff, kap
24 güvenlik, havaalanı, uçuş, faa, gecikme, kamyon, idare, pist, yeni, ulaşım
25 yargıç, mahkeme, s, en yüksek, hak, aday, karar, senato, wigenton, avukat
26 lautenberg, basın, açıklama, büyükelçi, sen, çiftlik, sorun, frank, ofis, d
27 senato, lautenberg, açıklama, frank, r, takip, sorun, birim, soru, basın
28 çocuklar, sağlık, sigorta, bakım, jersey, program, yeni, başkan, veto, tasarı
29 kanun, kask, lautenberg, motosiklet, içki, yaş, yasal, yıl, ölüm, sürücü
30 vergi, artış, lautenberg, yardım, kredi, senato, cumhuriyetçi, elizabeth, bush, değişiklik
31 kapsama, boşluk, medicar, yaşlı, ilaç, plan, lautenberg, reçete, cumhuriyetçi, hesaplama
32 amtrak, demir yolu, yolcu, fon, lott, sistem, yıl, hizmet, milyar, senato
33 işçi, sendika, çalışan, istihdam, yasa, tazminat, ira, engelli, seçim, özgür
34 silah, yasa, uygulama, ateşli silah, silah, terörist, satın alma, suç, saldırı, tiahrt
35 proje, sel, nehir, milyon, plaj, kontrol, fon, fırtına, raritan, koy
36 kimyasal, güvenlik, yasa, eyalet, yönetim, koruma, bush, daha güçlü, hükümet, hüküm
37 atık, düzen, site, eyalet, demir yolu, tesis, katı, demiryolu, jersey, kurul
38 seç, serbest bırak, toksik, kimyasal, eyalet, çalı, hak, tesis, bilmek, feder
39 petrol, opec, sızıntı, fiyat, wto, s, kartel, eylem, ticaret, ürün
40 kurban, terör, libya, d, sen, libyalı, aile, sponsor, eyalet, bomba

Doclingo https://www.doclingo.ai

12.5 Kümeleme'nin İnsan Tarafı

Kümeleme, verilerdeki kalıpları tespit etmenin yanı sıra bu kalıpları belgelerin bazı özellikleri açısından yorumlamayı da içerir. Bölüm 11 b azı kümeleri etiketlemek için kullanılabilecek bazı araçlar sağladı, anc ak bu bölümde süreci daha geniş bir perspektife yerleştiriyoruz.

12.5.1 YORUM

Kümeleme algoritmaları, belgelerin bir partition'unu elde etmemizi sağlar, anca k bu partition'un kavramsal olarak neyi temsil ettiğini söylemezler. Kümeleme yönt emlerinin çıktısını yorumlamak için, Quinn ve diğerlerinin önerilerine dayanıyoruz. (2010). Kümeleme algoritmaları, bir belgenin özelliklerinden belirli kümelere n et bir eşleme sağlar. Bu aşamadaki hedef, bu algoritmik kuralı maddi bir kural a dönüştürmektir: manuel kodlayıcılara kolayca açıklayabileceğimiz türde bir k ural. Gerçekten de, bu kitapta daha sonra birçok görev için kümeleme yönteml erinin en iyi değerlendirmesinin, denetimsiz kümeleme belgelerinden kavrams allaştırmayı bağımsız olarak yeniden üretebildiğimizi doğrulamak olacağını sav unacağız; bu, Ölçüm bölümünde tartışılan el ile kodlama veya denetimli öğren me yöntemleriyle yapılacaktır.

Yöntem 1: Ayırt Edici Kelimeleri Belirleme

Bazı modeller için, örneğin *k*-ortalama gibi, her bir kümenin temsil ettiği keli meleri tanımlamak için model parametreleri, örneğin küme merkezleri μ kullan abiliriz; ancak bu yaklaşımın sınırlamaları vardır. Affinity Propagation gibi bazı yö ntemler, 12.3.4), kelime dağarcığında parametreler yoktur ve model bu yöntemler için parametrelerin yorumlanması zordur. Parametreler mevc ut olduğunda bile, model parametreleri yöntemlere göre değiştiğinden, küm eleme yaklaşımları arasında karşılaştırma yapmak zordur. Neyse ki, model p arametreleri ne kadar belirsiz olursa olsun, ayırt edici kelimeleri tanımlamak için her zaman Bölüm 11'deki teknikleri kullanabiliriz.

Yöntem 2: Her Küme İçin Atanan Belgelerin Örneklenmesi

Quinn ve diğerlerinin (2010) tavsiyelerini takip ederek, küme bileşenle rini etiketlemek için önerdiğimiz ikinci yaklaşım, her küme bileşenine ata nan belgeleri örneklemek, bu belgeleri okumak ve ardından etiketleri elle oluşturmaktır. Genellikle her kategoriye atanan 10-30 gönderiyi okumayı öneriyoruz. Alışıldık yöntemimiz, belgeleri dikkatlice okumak ve okurken bir dizi not almak. Ardından bu notları tutarlı bir etiket haline getirmeye ç alışıyoruz. Eğer hemen kullanılabilir bir etiket yoksa (veya bir etiket sağla makta zorlanıyorsak), o zaman bu belirli durum için iyi bir kanıtımız var.

Doclingo https://www.doclingo.ai

küme (veya genel bölüm) keşif amaçları için yararlı olmayabilir. Belgeleri okumak iki amaca hizmet eder. Öncelikle kümeleri etiketlemek için yar arlıdır, ancak metinleri okumak—özellikle yeni bir şekilde gruplandıklarında—ke ndi başına yeni içgörüler sağlayabilir.

12.5.2 ETKİLEŞİMLİ KÜMELEME

Farklı kümeleme yöntemleri, aynı verilere uygulandığında benzer, ancak farklı kümelemeler üretebilir. Elbette, potansiyel kümeleme yön temlerinin yüzeyini zar zor kazıdık. Diğer yöntemler, bir karışımın farkl ı bileşenlerini belirtebilir, belgeler arasındaki benzerlik tanımını dolaylı olarak değiştirir. Ya da farklı yöntemler, bir küme bulmak için farklı o ptimizasyon prosedürleri kullanabilir veya "iyi" bir küme tanımlamak i çin farklı hedef fonksiyonları bile kullanabilir.

Potansiyel model seti sayısızdır ve hızla büyümektedir. Yeni kümele me yöntemlerinin her biri, net bir varsayımlar setine ve titiz türetmele re dayanarak dikkatlice türetilmiştir. Genellikle, yöntemi tanıtan bir m akale, yeni kümeleme yönteminin bilgi retrieval veya sınıflandırma gib i önemli bir görevde mevcut yöntemleri "geçebileceğini" gösterir. Bu, aynı zamanda, kümelenme algoritmalarının ve bunların uzantıları nın hızla arttığı aktif bir araştırma alanıdır.

Ancak, türetimlerdeki titizlik ve alanın büyümesi, kümelenme algoritmalar ının ne zaman uygulanacağı ve hangi problemlere uygulanması gerektiği ko nusunda eleştirel bir inceleme ile karşılanmamıştır. Aslında, belirli bir proble m için bir kümelenme yöntemi seçme konusunda literatürde çok az rehberlik bulunmaktadır. Teoremlere dayanan teorik rehberlik özellikle eksiktir. Bilgimize göre, yararlı içerik keşfetmek için bir belirli kümelenme yönteminin diğ er kümelenme yöntemlerinden daha etkili olduğunu gösteren genel olarak uygu lanabilir teoremler yoktur. Literatürde, verilerin gözlemlenebilir özelliklerine day alı olarak kümelenme yöntemlerinin ne zaman uygulanacağı konusunda rehberli k sağlayan daha mütevazı bir hedefe sahip makaleler de eksiktir.

Kümelenme literatürünü dikkate alırken, bir göreve uygun yönt emlerin önceden tanımlanmasının zor olacağına dair örtük bir tanı ma vardır ve kullanılan yöntemler, ilke yerine daha çok kolaylıkla il gili olabilir. Bu tür bir keyfiyet, keşif amacının belirsizliğinin ve diğe r denetimsiz yöntemlerin kullanımındaki genel belirsizliğin doğrud an bir sonucudur. Sonuç olarak, yazması kolay bir nesnel fonksiyon dan yoksunuz.

Bu bölümde başladığımız hedefi düşünelim: metinlerin ilginç bir o rganizasyonunu keşfetmek. Kesinlikle bir şeyin olduğunu biliyoruz.

Doclingo https://www.doclingo.ai

ilginç, bir kez gördüğümüzde, ancak genel olarak bir kümelemenin ilginç olup olmadığını bilmek insan müdahalesi olmadan imkansızdır. Bu, insanları tamam en dışlayan otomatik aramayı imkansız hale getirir.

Bu sürece doğal bir çözüm, insanları açıkça küme seçim sürecine dahil etmektir. Grimmer ve King (2011), ilginç kümelerin birinin önüne konuld uğunda kolayca fark edilebileceğini savunuyorlar ve bu nedenle birçok k ümenin coğrafyasını oluşturuyorlar - temelde yakın çözümlerin oldukça b enzer olduğu bir harita. Bu prosedür, onlara Senatör Lautenberg'in basın bültenlerini kullanarak partizan alaycılığı keşfetmelerine yol açtı.

Genel olarak, insan döngüsünde uygulama ile ilgili ticaret dengeleri vardır. geleneksel kümeleme. Geleneksel yöntemler tek ve net bir kümeleme sağla maktadır. Ayrıca, yorumlanabilir parametrelerle daha karmaşık modeller olu şturmak oldukça kolaydır. Ancak, geleneksel yöntemler verileri kümeleme sır asında dikkate aldığımız varsayımlar kümesini mutlaka sınırlayacaktır. İnsan döngüsündeki yöntemler, bunun aksine, kümelenme yöntemlerinin varsayı mlarını herhangi bir yöntemden daha kapsamlı bir şekilde keşfetmemizi sağlar. Ge rçekten de, dikkate alınacak çok daha fazla kümelenme olacaktır. Bununla birlikte, i nsan döngüsündeki bir yöntemi kullanmak, analistten büyük bir çaba gerektirebilir ve otomatikleştirilmesi imkansızdır. Sonuç olarak, seçim hem araştırmacının tercih lerine hem de araştırmacının düşündüğü temel problemin türüne bağlıdır.

Doclingo https://www.doclingo.ai

12.6 Sonuç

Bu bölümde, analistlerin araştırması için potansiyel olarak ilginç kalıpl arı tanımlayarak belgelerde keşfi kolaylaştıran bir yol olarak kümelenmey i tanımladık. Bu, genel sürecin bir hissini sağlar, ancak kümelenme, belge içeriklerinin yalnızca bir tür damıtılmasıdır. Her belgeyi yalnızca bir küme ye üye olacak şekilde kısıtlamak, kümelenmenin keşfedebileceği kalıp tür ü üzerinde büyük bir kısıtlamadır. Bu kısıtlama hem bir nimet hem de bir lanettir—kümelenmeler özetlenmesi nispeten basit (bir belge ya kümeye dahildir ya da dışındadır), ancak temsil edebilecekleri fenomen türü açısı ndan da sınırlıdır. Önümüzdeki iki bölümde, keşif için daha esnek yöntem ler hakkında konuşacağız: karışık üyelik konu modelleri ve belge gömme yöntemleri.

---

[1]Bugün insanların tanıdığı *k*-ortalama formülasyonu, 31 Temmuz 1957'de Stuart Lloyd t arafından Bell Labs'taki akademisyenlere bir taslak olarak yayımlandı ve bu, darbe kod mo dülasyonu için bir yöntemdi (analog sinyalleri dijital sinyallere dönüştürme yöntemi, ses gi bi). Bu el yazması daha sonra *IEEE Transactions on Information Theory* dergisinde Lloyd (1982) olarak yayımlandı. Aynı dönemde, Forgy (1965) esasen aynı yöntemi önerdi. MacQueen (1967) *k*-ortalama terimini tanıttı, yakınsama özelliklerinin bir analizini sağladı ve bağımsız olarak keşfedilen içgörüler hakkında kanıtlara eklenen notlar da dahil olmak üzere farklı alanlardaki ilgili çalışmaların karmaşık bir ağını belirtti. Bu bahsedilenlerden biri, sosyal bilimlerde kullanılmak üzere "küme arama teknikleri"ne bir giriş sağlamayı amaçlayan Geoff rey Ball tarafından yazılan bir makaledir; bu teknikler yeni "bilgisayar odaklı" hesaplama yönt emlerine uygun hale getirilmiştir (Ball, 1965). Hartigan ve Wong (1979), muhtemelen progra mlama dili R'nin varsayılan olarak kullandığı en popüler algoritmayı sağladılar.

[2]Kelimeleri https://nlp.stanford.edu/projects/glove/ adresinden elde ettik.

[3]Burada, en iyi kelimeleri tanımlamak için Bölüm 11 da tanımlanan bir test istatistiği yaklaşımını kullanıyoruz.

[4]Resmi olarak, Banerjee, Merugu, Dhillon ve Ghosh (2005), düzenli üstel aile ile dü zenli Bregman sapmaları arasında bir bijeksiyon kurar, bu da geniş bir yöntemler sın ıfını birleştirir.

[5]Eğer analistin belirli bir kavramsal gruplama ilgisi varsa, o zaman “benzer” tanımı na daha fazla yön verilebilir.

[6]Eğer yalnızca iki kümelemeyi karşılaştırıyorsak, o zaman yalnızca iki kümenin anlaşmazlık göste rdiği belge çiftleri için küme kalitesini hesaplamamız gerekir. Bunun nedeni, her iki kümede de ya a ynı kümeye yerleştirilen ya da her iki kümede de farklı kümelerde bulunan çiftlerin, iki değerlendir me arasındaki nihai farkı etkilemeyecek olmalarıdır. Ayrıca, herhangi bir belge çiftinin küme kalitesi ni hesaplamak için kullanılabileceğini unutmayın.

[7]K-means için amaç fonksiyonunun artan olmadığını doğrudan kanıtlayabiliriz. Diyelim ki, K kümesi olan bir belge koleksiyonunun optimal bir kümeleme düzeni var. Şimdi

Doclingo https://www.doclingo.ai

bir küme eklediğimizi ve K + 1 kümesi ile yeni bir çözüm bulmak istediğimizi varsayal ım. Her kümede farklı belgeler olduğu sürece, amaç fonksiyonu iyileşecektir. Amaç f onksiyonunun iyileştiğini görmek için, kümesine en kötü uyan gözlemi (ve dolayısıyla amaç fonksiyonuna en fazla katkıda bulunan) alıp yeni kümeye taşıyın. Eğer bölme mükemmel ise, her belgenin her kümeleme içinde özdeş olduğu anlamında, o zama n yeni bir küme bileşeni amaç fonksiyonunu etkilemeyecektir. Bu optimal bir çözüm olmasa da, bir belgeyi taşımak ya kümeleme amaç fonksiyonunu iyileştirir ya da aynı bırakır, bu nedenle herhangi bir optimal bölme amaç fonksiyonunu daha iyi hale get irmelidir.

[8]Dirichlet süreç önceliği (DPP) iki bileşene sahiptir: bir temel ölçü, G 0 ve bir yoğunluk parametresi *ξ*. Yoğunluk parametresi, modelden oluşan küme sayısı üzerinde önemli bir etkiye sahiptir (Wallach et al., 2010). Gerçekten de, gözle m sayısı sonsuza gittiğinde, DPP'den beklenen küme sayısı ξ log (1 + N ξ) (Wall ach et al., 2010) olur. Ayrıca, DPP, “zengin daha zengin olur” dinamiğine yol aç an bir küme atama sürecini varsayar: birkaç küme birçok belge alacak ve birço k küme yalnızca birkaç belge alacaktır.

Diğer parametrik olmayan öncelikler, Pitman-Yor önceliği gibi, DPP'yi genelleştirir ve veri üretim sürecinin bazı özelliklerini gevşetir. Ancak Pitman-Yor önceliği, birçok bel genin alındığı birkaç küme gibi benzer özellikleri korur (Pitman ve Yor, 1981). Ve Unif orm süreç önceliği (Wallach et al., 2010) gibi diğer parametrik olmayan öncelikler, far klı bir veri üretim süreci sağlar, ancak yine de önemli modelleme varsayımlarında bul unur.

Doclingo https://www.doclingo.ai

BÖLÜM 13

Konu Modelleri

Bir dizi kümeleme algoritması olmasına rağmen, özünde her belgenin bir kümeye ait olduğu ortak varsayımını paylaşırlar. Hatta “yumuşak” kümeleme yöntemleri, atamalar hakkında belirsizlik ifade etmesine izin verirken, her belge için bir küme olduğu varsayımı altında çalışır. Ancak belgeler birden fazla fikir içerebilir ve kümeler veya kavramlar arasında eşit şekilde bölünebilir. Örneğin, siyasi konuşmalar çeşitli ana temaları kapsayabilir. Gazete makaleleri bir hikayeyi çeşitli bakış açılarından ele alabilir. Ve romanların genellikle birkaç tema içerdiği düşünülmektedir. Belgeler farklı fikirlerin karışımını içerdiğinde, kümeleme yöntemleri bu varyasyonu gizleyecektir.

Konular, kümeleme yöntemleriyle yakından ilişkili bir model sınıfıdır, ancak her belgenin atandığı kategoriler hakkında temelde farklı bir varsayımda bulunurlar. Her belgeyi yalnızca bir kümeye atamak yerine, konu modelleri her belgeyi tüm kategorilere orantılı üyelikle atar. Yani, konu modelleri her belgenin kategoriler arasında bir karışım olduğunu varsayar - karışık üyelik modeli. Bu şekilde serbest bırakıldığında, konu modelleri çok daha odaklanmış kavramları temsil edebilir çünkü tek bir konu, kendi başına bir belgenin tamamını temsil etmek zorunda değildir. Bu özgüllük, karışık üyelik konu modellerine daha büyük bir insan yorumlanabilirliği sağlar. Gördüğümüz gibi, karışık üyelik modelleri, genellikle kümeleme algoritmalarında mevcut olmayan önemli içgörüler sağlayabilir.

Bu bölümde, kanonik konu modelini, Gizli Dirichlet Tahsisi'ni tanımlıyoruz ve ardından önerilen birçok uzantıdan küçük bir örnek hakkında konuşuyoruz. Süreç boyunca, konu modellerinin hesaplamalı keşifleri nasıl kolaylaştırabileceğine dair iki örnek sunuyoruz.

Doclingo https://www.doclingo.ai

13.1 Gizli Dirichlet Tahsisi

En ünlü konu modeli *Gizli Dirichlet Tahsisi* (LDA) (Blei,Ng ve Jordan, 2003).[1] LDA, bir yazarın bir metin üretme süreci için belirli bir veri üretim sürecini varsayan bir Bayes hiyerarşik modeldir ve bu, Bölüm 6 da tanımladığımız çok terimli dil modeline ve Bölüm 12deki çok terimli karışım modeline dayanır. Öncelikle, bir metin yazarken yazarın bir konu karışımı seçtiğini varsayıyoruz: belirli konuların ne kadar yaygın olduğunu tanımlayacak bir ağırlık seti. Bu ağırlık setine dayanarak, yazar gerçek metni üretir. Yazar her kelime için önce kelimenin konusunu çizer. Ardından, konuya bağlı olarak, gerçek kelime konuya özgü bir dağılımdan çekilir. Bu konuya özgü dağılım, belgeler arasında yaygındır ve belirli bir konuyu tartışırken kelimelerin ne sıklıkla göründüğünü karakterize eder.

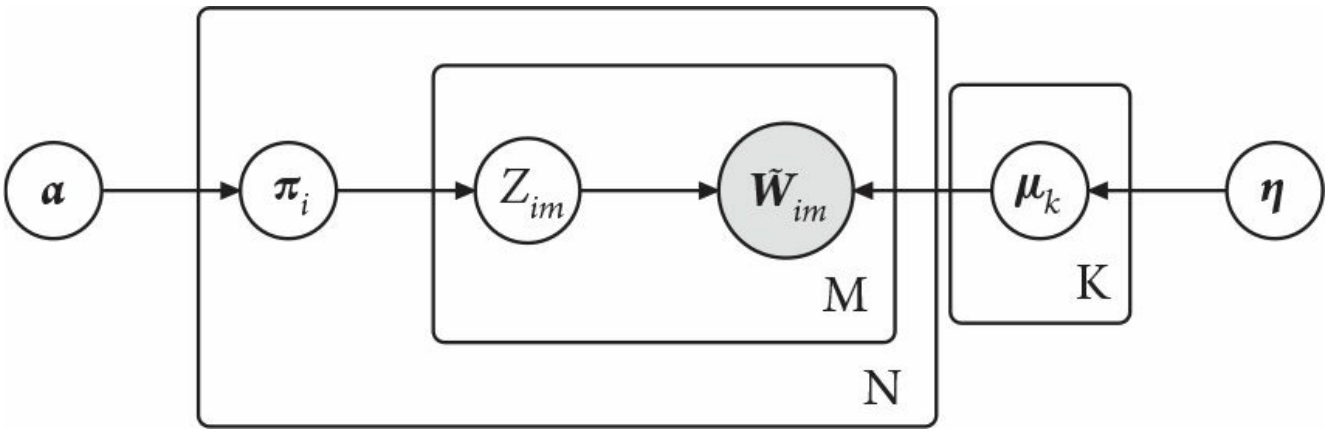
Bu veri üretim sürecine dayanarak, metinlerin nasıl üretildiğine dair belirli bir istatistiksel model yazabiliriz. Her belge için i (i = 1 , 2 , … , N)K × 1 konu ağırlık vektörü π i = (π i 1 , π i 2 , … , π i K) çizeceğimizi varsayıyoruz. Şimdi, belirli bir belgeden kelimeleri bir sırayla ürettiğimizi varsayalım; bu belgedeki *m*inci kelime (m = 1 , 2 , … , Mi) W i m olarak adlandırılacaktır. Her kelimenin, Multinomial dağılımından bir çekim olan karşılık gelen bir konu göstergesi olduğunu varsayıyoruz Z i m ~ Multinomial (1 , π i). Sonra W i m 'nin çok terimli bir dağılımdan geldiğini varsayacağız.

W i m ~ Çok Terimli (1 , μ Z i m), burada μ J × K matrisidir. kuncu sütun, μ k = (μ 1 k , μ 2 k , … , μ J k), her birμ j k'nın k konusunu tartışırken j kelimesini kullanma olasılığını tanımladığı J × 1 vektörüdür. Busüreç, M i × 1 matris W i'yi üretir. Sütunlar üzerinde topladığımızda,doküman terim matrisindeki karşılık gelen satırı elde ederiz, W i , = Σ m = 1 Mi W i , m Verileri üreten süreci, hem π i hem de μ k'nın bir Dirichlet dağılımından geldiğini varsayarak önbilgilerle tamamlarız. Model için basit bir varsayılan önbilgi kullanmak yaygın olsa da, diğer makaleler asimetrikönbilgilerin daha anlamlı konu sonuçlarına yol açabileceğini göstermektedir (Wallach, Mimno ve McCallum, 2009). Plaka diyagramı Şekil 13.1'de gösterilmektedir.

Metinlerde LDA'nın konuları nasıl yakaladığına dair sezgi için,daha farklı iki konuşma hakkında basit bir örneği düşünelim. Birkonuşma ABD başkanlık politikalarını içerebilir. Bu kitabın yazıldığızamanda, bu “Donald Trump'ın açıklaması” veya “Rus seçim skandalı üzerindeki tartışma”nın tartışılmasını içerebilir. Buna karşılık, bahçecilik hakkında birkonuşmamız olabilir. Orada “böcekler ve pestisitler” ile “peyzaj tasarımı”nı tartışabiliriz.

Doclingo https://www.doclingo.ai

Anahtar, başkanlık hakkında konuştuğumuzda bir set ilişkili kelime dağarcığı, bahçecilik hakkında konuştuğumuzda ise ikinci, nispeten farklı bir kelime dağarcığı olmasıdır. Daha sonra, "başkanlık" kelimelerine nispeten yüksek olasılıklar atayacağımız bir konu seti ve "bahçecilik" kelimelerine nispeten yüksek olasılıklar atayacak ikinci bir konu öğreniyoruz. Elbette, bazı (genellikle yaygın) kelimeler her iki konuda da yüksek bir ağırlık alabilir.
Her iki konu da kelime dağarcığındaki tüm kelimelere bir miktar ağırlık (genellikle küçük bir ağırlık) atar. Çoğu zaman bu iki konu farklı belgelerde görünebilirken, bazı belgeler her iki konunun eşit bir kombinasyonu olabilir; örneğin, Beyaz Saray'ın bahçesi hakkında bir konuşma. Beyaz Saray'ın bahçesi hakkında bir konuşma olasılığı, LDA gibi karışık üyelik konu modellerinin önemli bir avantajını vurgular. Karışık üyelik modelinde, başka birine benzemeyen bir belgeyi bile, bileşenlerini gördüğümüz sürece iyi bir şekilde tanımlayabiliriz. Dolayısıyla, bahçecilik hakkında başka belgeler ve başkanlık politikaları hakkında başka belgeler olduğu sürece, LDA modeli Beyaz Saray'ın bahçesi hakkında yalnız bir belgeyi iyi bir şekilde açıklayabilecektir. Bu, hem bahçecilik hem de başkanlık politikalarının özel kelime dağarcıklarına sahip olmasından mümkündür. Aksine, tek üyelik modelinde, böyle bir yalnız belge muhtemelen ya başkanlık politikaları ya da bahçecilik hakkında bir kümeye atanacaktır.Her iki küme de belgeyi kötü bir şekilde karşılayacaktır.



Şekil 13.1. Gizli Dirichlet Dağılımı modeli için plaka diyagramı.
Karışım modelinin Şekil 12.2 ile karşılaştırıldığında, bireysel token'ları indeksleyen bir iç plaka olduğunu unutmayın. Bu, her token'ın kendi konusuna sahip olmasını sağlar,ve π artık belgenin her konuya ne kadar atandığını gösteren bir vektördür.

13.1.1 ÇIKARSAMA

Diğer olasılıksal modellerde olduğu gibi, genel strateji bir veri

Doclingo https://www.doclingo.ai

üretim süreci tanımlamak ve ardından verilerden parametrelerin ne ola bileceğini tersine mühendislik ile bulmaktır. LDA ile modelin karmaşıklı ğı, çıkarımın oldukça zor olduğu anlamına gelir ve üç geniş strateji vard ır: çökertilmiş Gibbs örnekleme yöntemleri, varyasyonel yaklaşıklar ve moment tahmincileri. Bunları detaylı bir şekilde tartışacak alanımız yok, ancak farklı yaklaşımların aslında oldukça farklı sonuçlar verebileceğini vurgulamak istedik.

13.1.2 ÖRNEK: KONGRE BİLDİRİLERİNDE YANGIN HİBE İÇİN KREDİ T ALEBİNİ KEŞFETME

Bu bölümde, LDA'nın nasıl yenilikçi bir keşfi kolaylaştırabileceğine dair bir örnek s unuyoruz. Grimmer (2010) tarafından tüm Senato basın bültenleri üzerinde bir LDA k onu modeli çalıştırıyoruz—100'den fazla senatörden 72,631 basın bülteni. Durdurma kelimelerini kaldırdık, köklerini aldık ve noktalama işaretlerini ve sayıları çıkardık. R'd eki topicmodels paketini kullanarak (Grün ve Hornik, 2011), 40 konulu bir LDA tahmin ettik. Modeli varyasyonel EM kullanarak optimize ettik.[2]

Her konu için, Tablo 13.1 bu konudaki en yüksek olasılığa sahip on kelimeyi göstermektedir.Hemen, gıda veürün güvenliği (Konu 10) ile g öç (Konu 16) ve eğitim (Konu28) gibi tanıdık konuları tanıyoruz. Grim mer (2010) gibi, bu konuları kullanmak için, her birini gözden geçirir,t emsilci belgeleri okur ve onlara bir kategori adı ile etiketleriz.

Bu basit Kongre basın bülteni konu modeli bile, araştırmaya yönelik bir tümevarım y aklaşımının araştırmacıları yeni yönlere nasıl yönlendirebileceğini ve onlara beklenmedi k, ancak maddi olarak önemli, siyasi dinamikleri keşfetmelerine nasıl yardımcı olabilece ğini gösterebilir. Konu 7, “yangın,” “ayrılmak” ve “hibe” gibi en olası kelimelerle. Grimmer (2010), bu aynı basın b ülteni setine “İfade Edilen Gündem Modeli” adında bir konu modeli kullanara k, genellikle yangın departmanlarıyla ilgili hibe duyurularına atıfta bulunan b u aynı basın bülteni kategorisini keşfetti. Kongre konuşmasının hiçbir kavra msallaştırması, bunu ilgili bir konuşma kategorisi olarak önermemişti, ancak Grimmer, bu kategoriyi Gerçek bir program olan Yangın Söndürücülere Yard ım Hibe Programı (AFGP) ile ilişkilendirecek şekilde doğrulayabildi ve bu bası n bültenlerinin bu kategoriye sınıflandırılması şaşırtıcı derecede doğruydu. Grimmer (2010), bu hibe programıyla ilgili basın bültenlerinin yaklaşık %2'sinin bulundu ğunu tespit etti.

Tablo 13.1. Grimmer (2010) tarafından Senato basın bültenlerinden elde edilen kır k konunun en olası kelimeleri.

Konu 1	Konu 2	Konu 3	Konu 4	Konu 5	Konu 6	Konu 7	Konu 8	Konu 9	Konu 10

Doclingo https://www.doclingo.ai

1	güvenlik	mikulskicourt		hak	mektup	taşımacılıkyangın		su	araştırmasağlığı	
2	yönetmek	lincoln	yargıç	canı sıkkın	sekreter	fon	bölüm	proje	sağlık	bilgilendirmek
3	federal	ulus	senato	internet	eyalet	proje	hibe	toprak	hastalık	gıda
4	sosyal	temel	adalet	seçmek	endişe	havaalanı	yangın çatışması	nehir	kanser	fda
5	hesappryor		isim	oy	bölüm	milyon	programı	fon	hücre	gereksinim
6	rapor	maryland yasası		kamusal	rapor	geliştirme	fon	tarım tıbbı		tüketim
7	sözleşme arkansas		avukat	ulus	istek	$	güvenlik	çiftlik	bakım	korumak
8	soruşturma		komitepark		yönetimşehri		ödül	milyon	kök	ürün
9	vergi mükellefi	komisyon başkanı		erişim	öneri	federasyon	yardımcı olmak	korumak	önleme eylemi	
10	özel	brak	herhangi	iletişim planı		yeni	donatmak	eyalet	kuluçka	ilaç

	Konu 11	Konu 12	Konu 13	Konu 14	Konu 15	Konu 16	Konu 17	Konu 18	Konu 19	Konu 20
1	militaritax		başkan	kıdemli	ulus	güvenlik	harkin	tasarı	felaket	ticaret
2	koruma	sağlık	amerikanmurray		onur	sınır	iowa	senato	yardımcı olmak	pazar
3	hizmet	sigorta	çalı	Ve	amerikanyerleşimci		ofis	yasama	kasırga.	
4	ulusa	iş	çalışma	bakım	gün	vatan okulu		hareket	ortaya çıkma	sanayii
5	üye bakımı		senato	mesele	yıl	liman	akademi	değiştirmek	federasyon	ürün
6	aile	küçük	beyan sağlık		aile	eyalet	alaska	toplum durumu		çin
7	savunma	maliyet	demokratservis		çalışma	ulus	yetenek	geçmek	obama	üretim
8	sağlık	aile	bugün	washington dünya		kaçak	alan	ev	katrina	chambliss
9	zihinsel	eyalet	ihtiyaç	kamış	tarih	uygulama	onun	oy	durbin	anlaşma
10	asker	yıl	cumhuriyetçi ada		hizmet et	bölüm	yüksek	şartlar	kadın	isakson

	Konu 21	Konu 22	Konu 23	Konu 24	Konu 25	Konu 26	Konu 27	Konu 28	Konular 29	Konular 30
1	dakota	enerji	kar	fon	yeni	ilaç	coleman	çocuklar	intelligiraq	
2	kuzey	petrol	ana	$	schumer	Medikarminnesotaedduc			nükleer savaş	
3	Johnson yakıtı		collin	milyon	clinton	kıdemli	colorado	okul	ulus	birlik
4	dorgan	fiyat	lautenberg bütçesi		york	reçetesalazar		öğrenci	birim	iraklı
5	idaho	gaz	kıyı	programı	geliştirmek	medicaidnelson		programı	eyalet	zorla
6	güney	yenilemek	jersey	yıl	iş	montanasen		kolej	teröristbaşkan	
7	dedi	artırmak	yeni	milyar	bilim	planı	allard	eyalet	dünya	askeri
8	conrad	ulus	eyalet	kesmek	ekonomi	programsığır		çocuk	güvenlik	güvenlik
9	craig	ürün	Olimpiyat	başkan	araştırma	yakmak	robert	sağlamak	yabancıamerikan	
10	iletişimazalt		menendez artır		teknologbaucus		söyledi	yardım	silahpolit	

	Konu 31	Konu 32	Konu 33	Konu 34	Konu 35	Konu 36	Konu 37	Konu 38	Konu 39	Konu 40
1	hukuk	işçi	milyon	bir	ev	kredi	sağlık	yer	nevadatexa	
2	uygulama	istihdam	savunma	insanlar	domenicihear		fon	bebeğim	kerri	onun
3	suç	iş	sistem	git	yeni	komite $		indiana	ile ilgili	İskender
4	program çalışması		hava	yapabilir	meksika	banka	merkez	içinde.	reid	tennessee
5	Shelby	ücret	geliştirmek	biz	topluluk finansmanı		topluluk birimi		bayrak	bayat
6	eyalet	askeriistihdam		zaman	bingamanoranı		kırsal	eyalet	the	hutchison
7	adalet	iş gücü	fon	bilmek	programı	başkanprogramı		stajyer	john	graham
8	e-posta	kennediforc		de	geliştirmek	feingoldservic		darfur	the	son teslim tarihi
9	fon	yıl	$	sadece	levin	ipotek sayısı		yönetmek	O	senato
10	polis	minimum teknoloji düşüncesi			$	ev	sağlamak	kahverengi sırtlı las		basın

Konu modeli, yeni ve ilginç bir basın bülteni grubunu ortaya koyuyor, ancak bir sonr aki soru şu: Neden ülke genelindeki senatörler tarafından bu kadar çok itfaiye departm anı basın bülteni yayımlandı? Temsilciler Meclisi'ndeki bulguyu tekrarladıktan sonra

Doclingo https://www.doclingo.ai

basın bültenleri, Grimmer, Westwood ve Messing (2014) itfaiye departma nı hibe basın bültenlerinin kökenleri hakkında daha fazla bilgi edinmeye karar verdiler. İlk bulguları sadece merakı artırdı: AFGP, Kongre etkisine k arşı dayanıklı olacak şekilde tasarlanmıştı ve hibeler rekabetçi bir temele dayalı olarak veriliyordu. Eğer Kongre üyelerinin hibeler üzerinde hiçbir e tkisi yoksa, neden bunlar için kredi talep ediyorlardı? Bunu öğrenmek için Grimmer, Westwood ve Messing (2014) ajans yetkilileriyle röportaj yaptı. Bir yetkili gizemi çözdü. Ajansın resmi ajans duyurususundan önce Kong re yetkililerine hibeler hakkında bilgi verdiğini açıkladı ve bu, seçilmiş yet kililerin hibeler için kredi alma fırsatı yarattı. Grimmer, Westwood ve Mes sing (2014) bu modeli, basın bülteni verileri ve AFGP duyurularının zaman laması hakkında bilgi kullanarak toplamda doğruladılar.

Bu, yeni ve daha derin bir soruya yol açtı: Eğer yasama organları hi be tahsisatını etkileyemiyorsa, fonların tahsisatından nasıl kredi talep edebilirlerdi? Grimmer, Westwood ve Messing (2014), yasama organla rının kredi almak için örtük anlam kullandıklarını keşfettiler: Hibe için sorumlu olduklarını ima ederler, ancak harcama için asla doğrudan kr edi talep etmezler. İtfaiye departmanı basın bültenlerinde yasama org anları, sürekli olarak yeni parayı bölgeye "duyurur" ve bu tür finansm an için nasıl mücadele edecekleri hakkında genel ifadeler kullanırlar. Bu, yasama organlarının doğrudan sorumlu olduğu harcamalar için k redi talep etme ile tezat oluşturur; burada, bölge için finansmanı "güv ence altına" alabildiklerini açıklarlar. Son olarak, Grimmer, Westwood ve Messing (2014), bunun seçmenler üzerinde etkili bir strateji olduğu nu gösterir. Bir deneyde, yasama organları kredi talep ettiklerinde kre di aldıklarını, ancak gerçek katkılarını açıkladıklarında seçmenlerin seç ilmiş yetkilileri ödüllendirmekte isteksiz olduklarını gösterdiler.

Bu örnek, işimizde açıkça tümevarım yapmanın gücünü göstermektedir. Önceden hipotezlerinin mevcut olmasını beklemek yerine, Grimmer, Westwo od ve Messing (2014) kanıtları indüktif olarak bir araya getirdi ve incelenen f enomen—anlam çıkarımı—hakkında bilgi edindi. Uygun olduğunda, anlam çı karımının etkisini değerlendirmek için bir deney gibi daha tümevarımsal yakl aşımlar uyguladılar.

Doclingo https://www.doclingo.ai

13.2 Konu Modellerinin Çıktısını Yorumlama

Kümeleme yöntemlerine benzer şekilde, LDA belgelerin yeni organizasyonl arını önermek için son derece güçlü bir araçtır. Ve tıpkı kümeleme yöntemleri gibi, LDA da keyfi ayar parametrelerine ve çıkarım yönteminin seçimine güçlü bir şekilde bağımlı olabilir. Ancak bu değişkenlik faydalı olabilir. LDA'yı keşif içi n kullanırken, belgelerimizi görmenin yeni yollarını öğrenmeye öncelikle ilgi d uyduğumuzu hatırlayın. Algoritmanın çalışmaları arasında değişkenlik olsa bile , veriye bakmanın tek bir faydalı yolunu sağladığı sürece, model faydalı olmuşt ur.

Tablo 13.2. Ateş hibeleri ile ilgili 0.20'den fazla olan beş rastgele seçilmiş basın bülteninin başlıkları 0.20'den fazla olan Konu 7 ile ilgili.

	Konu 7 Örnek Başlıklar
1	Shelby, Clarke County'deki Fulton Gönüllü İtfaiyesi için 102,000 $'dan fazla bir miktar açıkladı
2	Schumer, Dört Finger Lakes Bölgesi İtfaiyesinin 280,000 $'dan fazla Federal Ateş Hibesi Alacağını Açık ladı
3	Senatörler Stabenow ve Levin, Lansing için Acil Durum Personelinin Kriz Sırasında İletişim Kurmasına Yardımcı Olacak 23 Milyon Dolarlık Hibe Duyurdu
4	Polonya, Senatör Dewine Yasası ile Yangınla Mücadele Hibesi Aldı
5	Pickrell Kırsal İtfaiye Departmanı, Yeni Bir Yangınla Mücadele Aracı İçin FEMA'dan 123,840 Dolar Aldı

Modelin önerdiği organizasyonları anlamak için, kümelenme modellerinin çık tısını etiketlemek ve yorumlamak için kullandığımız yöntemleri konuları etiketle mek üzere uyarlayabiliriz. Bir sonraki bölümde, konu modellerinin çıktısını karşıl aştırmanın ve ölçüm modelleri olarak performanslarını değerlendirmenin birkaç yolunu tanımlıyoruz. Bu değerlendirmeyi yaparken, amacımız belgeleri belirli bir organizasyona göre güvenilir bir şekilde organize etme yeteneklerini değerlendi rmektir. Ancak, kümelenme yöntemlerinin çıktısını doğrulamak için kullandığımı z prosedürlerde hafif değişiklikler yapabiliriz ve konu modellerinin çıktısını yoru mlayabiliriz. Önerdiğimiz iki ana yöntem vardır: örnek metinlerin dikkatli okunm ası ve belirli konuları ayırt eden kelimeleri tanımlamak için nicel prosedürler.

Kümelenme yöntemlerinden elde edilen çıktıyı etiketlerken, önerdiğimiz bir y aklaşım, bir kümeye atanan metinlerin rastgele bir örneğini dikkatlice okumaktır. Benzer bir öneri, konu modelleri ile yapıyoruz, ancak belgelerin tüm kategorilerde kısmi ü yeliği olduğu için hafif bir değişiklik benimsemek zorundayız. Bir yaklaşım, belirli bir kateg oriye atanan büyük bir paya sahip belgeleri seçmektir. Özellikle, dikkate alınan belirli kate goriye atanan en yüksek belge oranına sahip belgelerin küçük bir alt kümesini seçiyoruz.

Doclingo https://www.doclingo.ai

Bu belgeleri okuyarak ortak yönlerini değerlendirebilir ve belirli bir organizasyonun mantıklı olup olmadığını sorgulayabiliriz. Ayrıca, belirli bir kategoriye daha yüksek bir pay tahsis edilen belgelerin daha olası bir şekilde seçilmesini sağlamak için belgeleri örnekleyebiliriz. Örneğin, herhangi bir belgeyi seçme olasılığını π i k = π i k Σ ℓ = 1 N π ℓ k olarak ayarlayabiliriz. Bu, çeşitli belgeleri seçmemizi sağlama avantajına sahiptir, ancak anlamaya çalıştığımız kategori ile az ilişkisi olan belgeleri seçme dezavantajına da sahiptir.

Örneğin, Tablo 13.2 , 0.20'den fazla yüklemeye sahip beş rastgele seçilmiş basın bülteninin başlıklarını göstermektedir. Bu beş belge, bize Konu 7 'nin doğası hakkında bir fikir verir ve Kongre üyelerinin hibe için kendilerine kredi talep etmek için nasıl örtük anlam kullandıkları hakkında bazı fikirler sunar.

Gruplama yöntemlerinde olduğu gibi, belirli bir konuyu gösteren kelimeleri tanımlayabiliriz, tıpkı Tablo 13.1'de yaptığımız gibi. Bu kelimeleri elde etmenin en basit yöntemi, her konudaki en yüksek olasılığa sahip kelimeleri seçmektir. Bu kesinlikle faydalı olsa da, en iyi kelimeleri seçmek, belirli bir konunun ayırt edici özelliklerini gizleyebilir. Bunun nedeni, bazı kelimelerin konular arasında yüksek olasılığa sahip olabilmesidir çünkü yaygındırlar. Bunu Bölüm'de açıklıyoruz. 13.5 yöntemleri nasıl kullanacağınız hakkında ayırt edici kelimeleri tanımlama.

Konuların modellerinin kümeleme yöntemleriyle benzer bir yanı, modele dahil edilecek konu sayısını belirlemenin zor bir meydan okuma olabilmesidir. Belirli bir konu modelinin uygulaması hakkında daha fazla bilgi sahibi olmadan konu sayısını belirlemek imkansızdır. Bunun nedeni, farklı ayrıntı düzeylerine sahip konu modellerinin bize farklı türde içgörüler sunabilmesidir.

Doclingo https://www.doclingo.ai

13.3 LDA'ya Yapı Entegre Etme

Konular modeli, veriler içinde temel bir hiyerarşi üzerine inşa edilir. Hiye rarşinin en üstünde, korpus içindeki belgelerin konularının dağılımını kara kterize eden bir popülasyon düzeyinde Dirichlet dağılımı vardır. Her belgen in konu karışımı bu aynı dağılımdan çekilir. Ardından, belgenin konu karışı mına bağlı olarak, her kelime için konu etiketleri çekilir. Bu konu etiketleri, gerçek kelimeyi çekmek için hangi konuya özgü çok terimli dağılımın kulla nılacağını belirlemek için kullanılır.

Bu yaklaşımları keşif için özellikle çekici kılan şeylerden biri, analis tten koleksiyon hakkında önceden nispeten az bilgi gerektirmeleridi r. Ancak, sosyal bilimciler genellikle belgeleri hakkında daha fazla bil giye sahiptirler ve bunu, yazar, mekan veya yayın tarihi gibi belge ha kkında ek bilgileri tanımlayan meta veriler, belge düzeyindeki değişk enler olarak kodlarlar. Sosyal bilim araştırmalarında yaygın bir dese n, araştırmacıların bir konunun yaygınlığının meta verilerle nasıl değ iştiğini keşfetmek istemesidir. Örneğin, Catalinac (2016*b*) Japon parti manifestolarının içeriğinin zamanla nasıl değiştiğini incelerken, DiM aggio, Nag ve Blei (2013) farklı gazetelerin zamanla sanat için hükü met finansmanını nasıl çerçevelediğini incelerler. Grimmer (2010), s enatörlerin basın bültenlerinde vurguladıkları konuları bilgilendiren bir sunum tarzı benimsediklerini savunur. Bu sunum tarzını ölçmek i çin Grimmer (2010), bir belgenin yazarına dair yeni bilgileri konu mo deline entegre eder. Farklı bir modelde, Quinn ve ark.(2010) Senato tartışmalarındaki konuların yaygınlığını incelerler. Zamanla konular arasında bir zamansal bağımlılık olduğunu savunurlar.

Bir model inşa ediyorlar ve zamanın dahil olduğunu varsayıyorlar, ABD Senatosu'ndaki konuların pür üzsüz bir şekilde evrildiğini, bir önceki günün konusunun bir sonraki günün konu dağılımını bilgilendi rdiğini varsayıyorlar.

Alternatif olarak, konuşan kişinin özelliklerinin konunun içeriğini bilg ilendirebileceğini varsayabiliriz. Örneğin, Amerika Birleşik Devletleri'nd e Cumhuriyetçilerin ve Demokratların kelime dağarcığını paylaşmasını bekleyebiliriz, ancak aynı konuyu -örneğin vergi politikası- farklı bir şekil de tartışabilirler (Monroe, Colaresi ve Quinn, 2008; Gentzkow, Shapiro v e Taddy, 2019). Elbette, farklı meta verilere sahip metinlerin aynı konuy u nasıl tartıştığını incelemek için bilgi dahil etmek, zorlu bir kavramsal s orunu ele almayı gerektirir: Meta verileri farklı olan metinler aynı konun un farklı versiyonlarını mı tartışıyor yoksa temelde farklı konuları mı tar tışıyorlar. Bu zordur, çünkü farklı bilgilerle aynı konuyu tartışan iki kişi il e farklı konuları tartışan iki kişi arasında belirgin bir fark yoktur.

Doclingo https://www.doclingo.ai

Bu sorunları aşmak için, araştırmacıların konu tartışmalarındaki farklılıkları incelemek için kovaryatları dahil ederken dikkatli olmaları gerekir.

Metadata bilgilerini konu modellemesi tahminine dahil etmek, birden fazla farklı amaca hizmet edebilir. Karışık üyelik konu modelleri bağlamında, Mimno ve McCallum (2008) yukarı akış (upstream) kovaryant modelleri ile aşağı akış (downstream) kovaryant modelleri arasında yararlı bir ayrım getirir. Her birinin farklı bir amacı vardır; yukarı akış kovaryantları, konularımızın yorumlanabilirliğini artırmak ve konularla bir ilişki tahmin etmek için belirli bir yapıyı modellemek amacıyla hizmet eder. Aşağı akış kovaryant modelleri ise, kovaryantı tahmin eden konular üretmek için özel olarak tasarlanmıştır.

13.3.1 YUKARI AKIŞ, BİLİNEN YAYGINLIK KOVARYANTLARI İLE YAPI

Yukarı akış yaygınlık kovaryant konu modellerinde, LDA'nın belge-konu oranları (π i) için global önceliğini (α) belge düzeyindeki kovaryantların (X i) bir fonksiyonu olarak oluşturulmuş belgeye özgü bir öncelikle değiştiriyoruz. "Yukarı akış" adı, kovaryantların grafikte bir alan için de olduğu plaka diyagramından gelmektedir; okların akışını aşağıya doğru takip etmek, belge-konu oranlarına ulaşır. Pratikte bu, yukarı akış kovaryant modellerinin bilginin paylaşılmasına izin verdiği anlamına gelir, ancak aşağı akış kovaryant modellerinin açıklamaya çalışmadığı konular söz konusudur.

Orijinal LDA modeline yapılan en erken uzantılardan bazıları, yazarına göre belgeleri düzenleyen yukarı akış kovaryat modelleri de dahil olmak üzere, 2004) veya zaman (Blei ve Lafferty, 2006). Bu genel yaklaşım da erken sosyal bilimlerdeki yaklaşımları tanımlamaktadır (Quinn ve diğ., 2010; Grimmer, 2010). Daha fazla uzantılar, bu belirli türdeki kovaryatları daha keyfi kovaryatlara genelleştirmiştir (Mimno ve McCallum, 2008; Roberts ve diğ., 2013).

Yukarı akış kovaryantları, belgeler kısa olduğunda konu modellerini uyarlamaya yardımcı olur. Kısa belgeler, konu modelleri için özellikle sorunludur, çünkü konuları tahmin etmek için kelimeler arasındaki korelasyona dayanırlar. Uzun belgeler, birçok farklı kelime arasındaki korelasyonu gözlemleme fırsatı sunar - fikirlerimizi birçok farklı şekilde ifade ettiğimizde, düşüncelerimizi ifade etmek için genellikle farklı ama ilişkili kelimeler kullanırız. Ancak kısa belgelerde, bu korelasyonları gözlemleme fırsatımız yoktur. Sonuç olarak, görünüşte benzer konular hakkında iki belgenin çok farklı olarak değerlendirilebilme riski vardır.

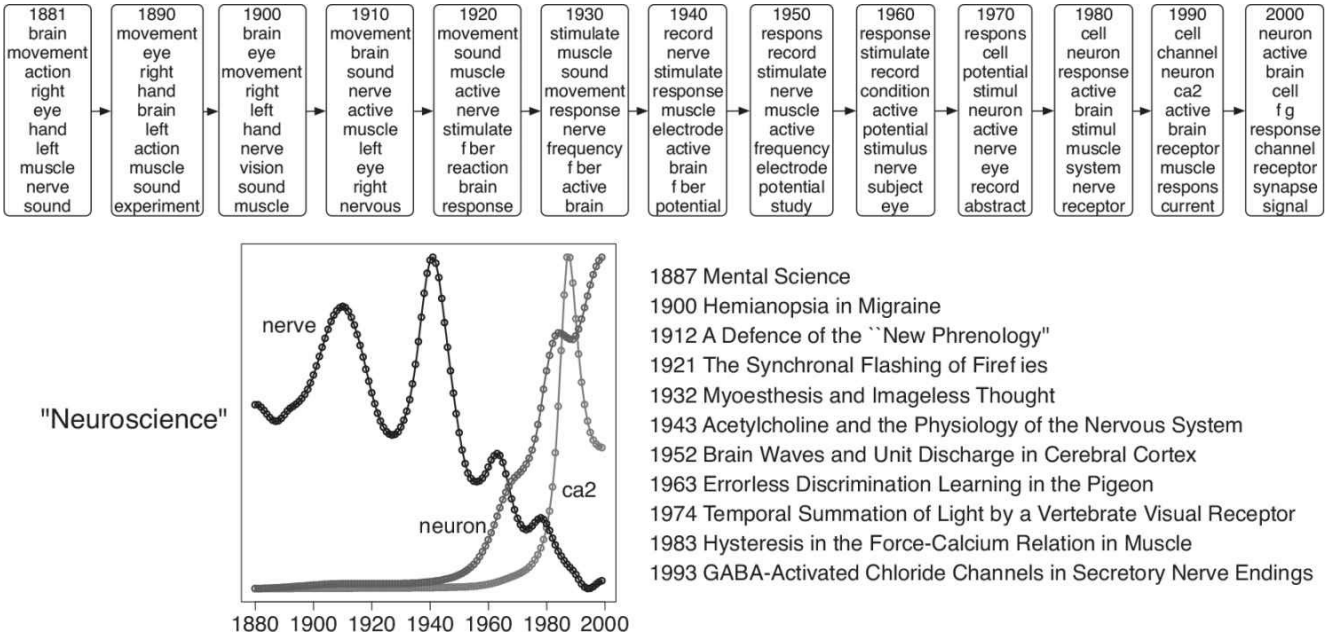
Doclingo https://www.doclingo.ai

Yukarı akış kovaryant modelleri, modelin benzer kovaryantlara sahip bel gelerden "güç ödünç almasına" olanak tanıyarak bu sorunu çözmeye yardı mcı olur. Bu kovaryantlar, bireylerin daha uzun belgeler yazmaya zorlandık larında belki de bir araya getirilecek benzer kelimeleri kullanan belgeleri b ağlamak için bir köprü görevi görebilir. Ancak bireysel belge uzunlukları so nsuza doğru eğilim gösterdiğinde, veriler ön bilgiyi aşar ve belirli bir belge nin konularının tahmini yalnızca içerdiği kelimelerle yönlendirilir. Elbette, b elgeler son derece uzun hale geldikçe, bireysel eşzamanlılıkların daha anla mlı hale gelmesi için bunları daha küçük parçalara ayırmak daha cazip hale gelir. Yukarı akış kovaryant modelleri gibi hiyerarşik bir yapı oluşturan kon u modelleri, ilgi duyulan gerçek miktarı toplamak için kullanılabilir.

13.3.2 ÜST AKIŞTA, BİLİNEN İÇERİK KOVARYATLARIYLA YAPILAN YAPI

Koşullu değişkenler, modelin konusal içeriğini şekillendirmek için de kullanılabilir. Bu modeller, konuya özgü kelime dağılımının zamanla (Blei ve Lafferty, 2006), coğrafya (Eisenstein ve diğ., 2010), ideolojik bağlantı (Ahmed ve Xing, 2010), veya keyfi bir kategorik kovaryat (Eisenstein ve diğ., 2010; Roberts ve diğ., 2013). Bir içerik kovaryant modeli kullanarakessansiyel olarak her bir konu için, içerik kovary antının her bir seviyesi için birden fazlaversiyon oluşturur. Bunlar, konunun farklı versiyonları arasındaki sapmalardakiseyreklik ile ya da zaman içindeki süreklilik gibi bir pürüzsüzlük varsayımı ile kısıtl anır(Blei ve Lafferty, 2006). Zaman içindeki evrim, Şekil 13.2, Blei ve Lafferty (2006)'nin *Science* dergisindeki bir örneği yeniden yayı mlayan bir bölümdür. Şekil, sinirbilim konusunun en olası kelimeleri olan b eyin, hareket ve eylemden, en olası kelimeleri nöron, beyin ve sinaps olan bir hale evrildiğini göstermektedir. Bu, sinirbilim üzerine akademik tartışm anın zamanla nasıl evrildiğine dair güçlü bir içgörü sunmaktadır.

Doclingo https://www.doclingo.ai



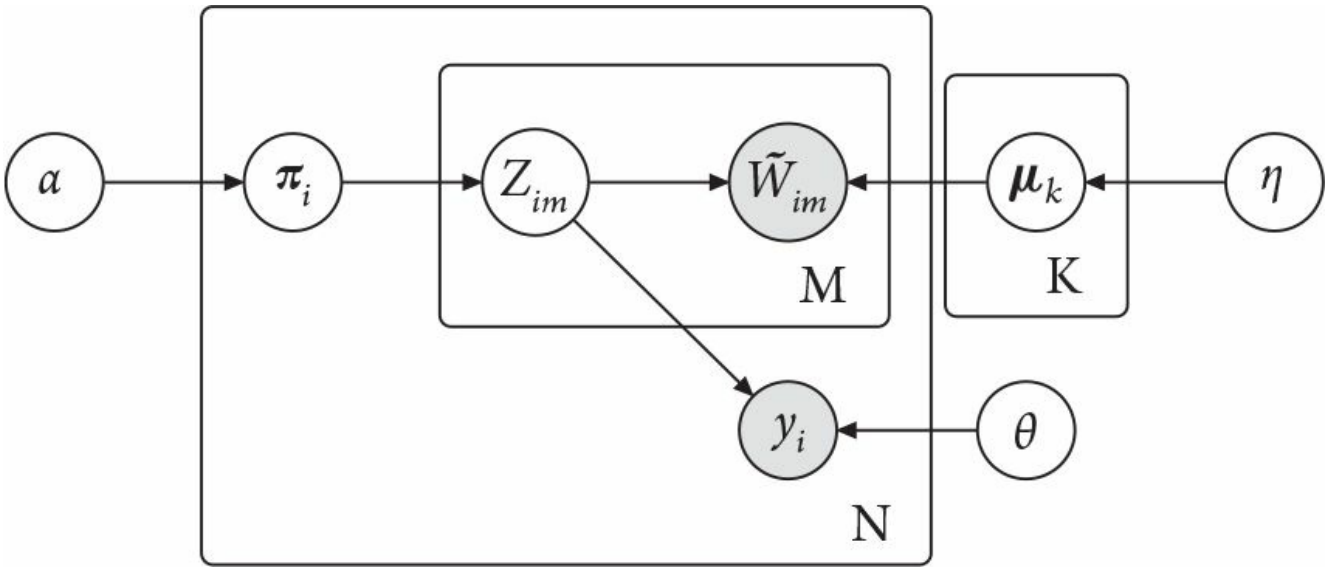
Şekil 13.2. Blei ve Lafferty (2006) tarafından yapılan bu şekil, dergideki makalelerden öğ renilen bir konu setini göstermektedir. Şekil, nörobilim konusunun zaman içindeki içerik değişimini izlemektedir.

Konu içerik modelleri, aynı şey hakkında konuşan ancak biraz farklı kelimeler kullanan farklı alt popülasyonlar arasındaki dil kullanımı far klılıklarını anlamak istediğimizde güçlü olabilir. Örneğin, Cumhuriyetçi ler “ölüm vergisi” ifadesini kullanırken, Demokratlar “mülk vergisi” ifa desini kullanabilir; her ne kadar aynı sorunlar setine atıfta bulunsalar da. Dil kullanımı farklılıkları ilgi alanının ana miktarı olmasa bile, bu m odeller, ana ilgi alanı olmayan bir farkı marjinalleştirmek için faydalı ol abilir. Örneğin, Lucas ve ark. (2015), içerik kovaryatlarının çok dilli met in koleksiyonları ile çalışırken faydalı olabileceğini göstermektedir. Onların fikri, ortak bir dile makine çevirisi yapmak ve ardından çevirideki i diosinkrasileri marjinalleştirmek için dili belirten bir içerik kovaryatı kulla nmaktır.

Ancak, içerik kovaryatlarının modele prevalans kovaryatlarından ço k daha önemli bir değişiklik ürettiğini vurgulamak önemlidir. Bu değiş iklik, konuların birbirleriyle karşılaştırılamaz hale gelme riskini taşıyabi lir. Örneğin, Blei ve Lafferty (2006)’nin dergi çalışmasında, araştırmacıl ar nörobilimi incelemek istediklerini önceden belirtmemektedir; konu verilerden keşfedilmektedir. Ancak, 2000’deki konu uyumu, 1881’deki konu uyumundan çok farklıdır. Bu konuları bağlayan şey, on yıl on yıl sürekliliktir. Bu durumda, konu mantıklı bir şekilde evrimleşmiştir, anc ak analistin, model tarafından tanıtılan tek bir konudaki varyasyonları n karşılaştırılamaz hale gelmemesi için dikkatli olması gerekmektedir.

Doclingo https://www.doclingo.ai

Bu sorun oldukça bariz olacak, ancak iki farklı varyasyonun kavrams al olarak aynı konu olup olmadığı karmaşık bir sorudur ve belirgin bi r çözümü yoktur.



Şekil 13.3. Aşağı akış kovaryant modeli için bir plaka diyagramı. Parametreler θ etiketli sonuç y i'nin dağılımını kontrol eder, bu sonuç token düzeyindeki konu göstergeleri z k ullanılarak tahmin edilir.

13.3.3 AŞAĞI AKIŞ, BİLİNEN KOVARYANTLARLA YAPILAN YAPI

Aşağı akış kovaryant modelinde (bkz. Şekil 13.3), kovaryant konu oranlarının aşağısında yer alan bireysel token gizli değişkeninden üretil ir. Bu, konuların belirli bir belge için hem kelimeleri hem de kovaryant değeri ni açıklamasını zorunlu kılar. Bu nedenle, bu modeller iki farklı amaca hizmet eder; bu amaçlar yukarı akış kovaryant modellerinden temelde farklıdır: tahmin performansını maksimize etmek ve kelimeleri ve kovaryantları ortak bir alana projekte etmek.

Tahmin performansı durumunu motive etmek için, bir film eleştirmeninin bir filme verdiği yıldız sayısını (y i) incelemenin metninin bir temsiline (W i,) d ayanarak tahmin etmek istediğimizi hayal edin. Örneğin, orijinal LDA makale sinde (Blei, Ng ve Jordan, 2003) umulan, LDA modelinden elde edilen konular ın bir sınıflandırıcıda kullanılmak üzere iyi özellikler olacağıydı. Pratikte, gene llikle öyle olmadı. LDA tarafından öğrenilen konular (π i) gerçekten kullanılan kelimelerin iyi tahmincileri olsalar da, ilgi alanımız olan y i'nin iyi tahmincileri değildiler. Bu, Mcauliffe ve Blei'nin (2008) Denetimli LDA (sLDA) tanıtarak ele aldığı bir sorundur. Onların içgörüsü, tahmin etmek istediğimiz değişkeni, y i'yi konuların aşağısına yerleştirerek, konuların hem W i'yi hem de y i'yi açıkla mak zorunda kalmasıydı. Yeni bir belge için gözlemlenen kelimeleri kullanar ak π i'yi çıkarabiliriz ve ardından π i'yi tahmin etmek için kullanabiliriz.

Doclingo https://www.doclingo.ai

sonuç y i.[4] Bu nedenle, aşağı akış kovaryatını dahil etmek, konuların iyi tahmin ediciler olmas ını sağlamaya yardımcı olur; bu fikir, Bölüm 26'da tekrar ortaya çıkacaktır.

sLDA durumunda genellikle tahmin etmek istediğimiz düşük boyutlu bir değişken y ve yüksek boyutlu kelimeler W vardır. Ayrıca, kelimelerle ortak bir alana projekte etmek istediğimiz yüksek boyutlu bir y da olabilir. Yaygı n bir kullanım durumu, y 'nin bir siyasi kurumda oylar olduğu ve W i 'nin si yasi aktörlerden metin temsili olduğu durumdur. Örneğin, Kongre önünde ki tasarıları ve bunların oylarını (Gerrish ve Blei, 2012; Kim, Londregan ve R atkovic, 2018) veya Yüksek Mahkeme görüşlerini ve oylarını (Lauderdale ve Clark, 2014) düşünebiliriz. Bu modeller, hem oyları hem de metni ortak bir alana projekte eder; bu, her ikisinin de temel ölçüyü bilgilendirdiğine inan dığımız verileri birden fazla kaynaktan kullanmanın etkili bir yolu olabilir.

13.3.4 EK YAPI KAYNAKLARI

Yukarıda belge düzeyinde kovaryat bilgisine odaklandık, ancak k eşif modellerine maddi bilgiyi dahil etmenin başka yolları da vardır. Konular hakkında bilgi mevcut olduğunda, bu konular seyrek (Wang v e Blei, 2009; Williamson ve diğ., 2010), hiyerarşik bir yapıya sahip olabi lir (Li ve McCallum, 2006; Paisley ve diğ. , 2015), belirli tercih edilen kelimeler arasındaki bağlantılar (Andrzejewski, Zhu ve Craven, 2009), ya da belirli anahtar kelimelere dayanmaktadır (Magnusson ve diğ., 2018; Eshima, Imai ve S asaki, 2020), bunu modelimize entegre edebiliriz. Ayrıca kullanabiliriz mevcut olduğunda bilgi kaynağı olarak etkileşimli insan geri bildiri mi(Vikram ve Dasgupta, 2016). Hu ve ark. (2014), bir analistin metn in bir organizasyonu ile karşılaştığı ve modelin hızlı bir şekilde yeni den ayarlandığı etkileşimli konu modeline bir yaklaşım sunmaktadı r.

Alternatif bir yaklaşım, benzer düşüncelere sahip metinleri bir araya getir mek için ikinci bir modelleme katmanı kullanmayı hedeflemektedir. Örneğin, Grimmer (2013*a*), senatörlerin konulara olan dikkatlerine göre kümelendiği bir modeli tanıtmaktadır ve Blaydes, Grimmer ve McQueen (2018), konuları d ilsel benzerliklerine göre kümeler. Konu yaygınlığına uygulandığında, bu yakl aşım hem anlamlı ilginç grupları tanımlamak hem de benzer belgelerden gü ç almak için faydalı olabilir. Konulara uygulandığında, bu yaklaşım, konu sayı sını belirleme ile ilgili bazı endişeleri hafifletmeye yardımcı olabilir ve ince ve kaba konuların eşzamanlı ölçümünü mümkün kılabilir. Burada kovaryantları n keşfedildiğini söylüyoruz, çünkü kümeleme prosedürü belirli bir kovaryant setine göre katmanlaştırmaya eşdeğerdir, ancak bununla birlikte

Doclingo https://www.doclingo.ai

tahmin süreci sırasında çıkarılan kovaryatlar.

Doclingo https://www.doclingo.ai

13.4 Yapısal Konu Modelleri

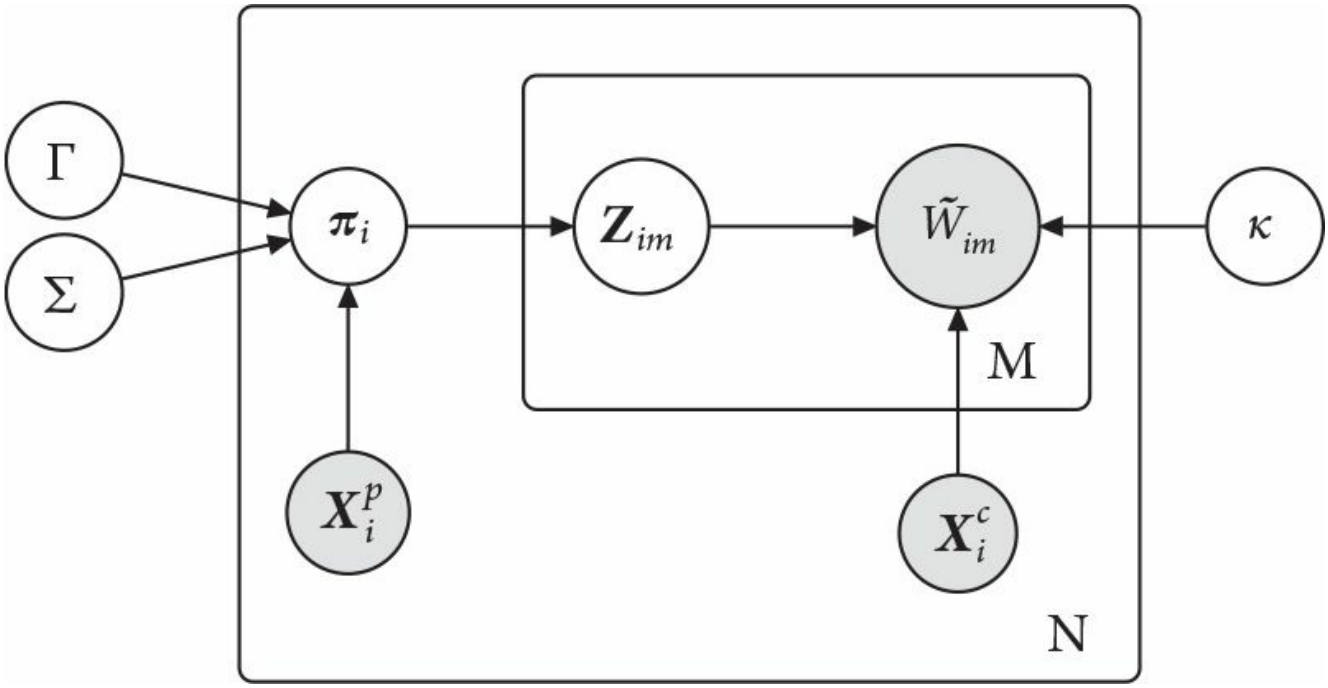
Önceki bölüm, yapıların konu modellerine eklenebileceği birçok yolu tartıştı, ancak yıllarca uygulayıcılara erişilebilir genel amaçlı uy gulamalar azdı. Yapısal Konu Modeli (STM, Roberts, Stewart ve Airo ldi, 2016), konu yaygınlığını ve içeriğini etkileyebilecek oldukça gen el yukarı akış meta verilerini dahil etmenin bir yolunu sunar. STM'yi tanıtmak için, her bir birim için *i* bir dizi *P* kovaryat X i p'in, konu yaygınlığını açıklamak için kullanılacağını ve ay rı bir dizi P ′ kovaryat X i c'in konu içeriğini açıkladığını varsayalım. Bu k ovaryat seti ile gözden geçirilmiş veri üretim sürecini belirleyebiliyoruz. Belgelerin aşağıdaki hiyerarşik modele göre üretildiğini varsayalım :

$$\gamma k \sim \text{Normal } P (0 , \sigma 2 I P) \pi i \sim \text{LojistikNormal } K - 1 (\Gamma ' (X i p) ' , \Sigma) Zi m \sim \text{Çok terimli } K (\pi i) W i m \sim \text{Çok terimli } J (\mu c Z i m) \mu c k j = \exp (\kappa j (0) + \kappa k j (t) + \kappa X c j (c) + \kappa X c k j (\text{int})) \sum j \exp (\kappa j (0) + \kappa k j (t) + \kappa X c j (c) + \kappa X c k j (\text{int})) ,$$

burada Γ, konu yaygınlığı modelinin katsayıları için bir P × (K − 1) matrisidir ve { κ . , . (t) , κ . . (c) , κ . . (int) } bir dizi oran sapmasını tanımlarkonular, kovar yantlar, konu-kovaryant etkileşimleri (sırasıyla) korpus içindeki kelime dağılma sının genel dağılımından κ (0) ile belirtilmiştir veW i , = Σ m = 1 M i W i m. An a fikir, her *κ* bir kelimenin kullanımının bir dizi kovaryant arasında nasıl değişti ğini, bir özelliğin kullanımının bir konunun yaygınlığı ile nasıl değiştiğini ve ikisi nin belirli bir konu için nasıl etkileşimde bulunduğunu içermesidir.

Bu, bir konunun varlığını/yokluğunu ölçmek için esnek bir yöntem sağ lar.

Doclingo https://www.doclingo.ai



Şekil 13.4. Yapısal Konu Modeli için plaka diyagramı.

STM, araştırmacıların konu yaygınlığı ve içeriğinin belgeler arasında belgenin özelliklerine veyameta verilerine dayalı olarak nasıl değiştiğini kodlamasını sağlar. Şekil 13.4 plaka diyagramını sağlar. Konu yaygınlığı kovaryantları, belgelerdeki konuların önemini tahmin etmemize yardımcı olurken,konu içeriği kovaryantları, konuların nasıl tartışıldığını değiştirir. Pratikte, STM'nin çoğu kullanımı içerik kovaryantlarını kullanmaz ve bu nedenle konularLDA'daki gibi ele alınır.

Koşulları içeren birkaç neden, keşif süreci için faydalı olabilir. Roberts, Stewart ve Airoldi (2016), koşulları dahil etmenin STM'nin daha anlamlı ilginç konuları tanımlamasına yardımcı olduğunu ve bu konuların, az sayıda belge veya sınırlı bir kelime dağarcığı olduğunda daha istikrarlı olduğunu göstermektedir. Şekil 13.4, STM'nin keşfedilen konuları ve bu konuların belgelerde ölçülen yaygınlığını nasıl iyileştirebileceğine dair teknik bir nedeni netleştirmeye yardımcı olur. Belgenin konuları üzerindeki ön bilgi, modelin konu yaygınlığının tahminini iyileştirmek için belgeler arasında bilgi almasına olanak tanır. Koşulları dahil etmeden model, tüm belgeleri bir ön bilgiye toplar ve belgeler arasında eşit bilgi alır. Ancak, koşulları dahil etmek, modelin benzer koşul değerlerine sahip belgelerden bilgi almasına olanak tanır. Heuristik olarak, bu modelin daha iyi konuları tanımlamasına yardımcı olur, özellikle dahil edilen koşullar dilsel farklılıkları açıkladığında.

Koşulların keşif için konu modelini kullanırken oldukça faydalı olması muhtemel olsa da, kalabilecek sorunlar için bir panzehir değildir. Şekil 13.4

Doclingo https://www.doclingo.ai

Modelimize kovaryantları dahil ettiğimizde, konu modellerinin metninde n oldukça uzaklaştığımızı gösterir. Ve modelleme prosedürlerinde, metin den uzaklaştıkça, kovaryantların model uyumunu geliştirmek için yapabil eceği şeyler azalır, çünkü güç ödünç almanın veri içindeki bilgilere göre ö nemi azalacaktır.

Ayrıca, STM modelinin basit bir iki aşamalı yaklaşık hesaplamasını yapmak da mümkündür. Araştırmacılar, konu modellerini yalnızca maddi varyasyon u tanımlamak için kullanmakla ilgileniyorlarsa, önce bir LDA modeli çalıştırab ilirler. Ardından, o modelin çıktısını kullanarak, konu yaygınlığı π i'yi belgenin kovaryantları X i üzerinde regresyon yapabilirler. Belge uzunluğu ve belge s ayısının sınırında, bu STM ile aynı farklılıkları sağlayacaktır, ancak bilgi ödünç almanın bazı ek avantajlarından feragat edebilir.

13.4.1 ÖRNEK: RADİKAL DİSCOURSU KEŞFETME

Karell ve Freedman (2019), radikal örgütler arasında yaygın olan radikal söylem temalarını keşfetmek için Yapısal Konu Modeli'ni kullanmaktadırlar. Afganistan, İran ve Pakistan'daki radikal gruplar tarafından yazılmış dergile r, gazeteler, konuşmalar ve broşürlerden oluşan 23,000'den fazla sayfalık b ir korpusu incelemektedirler. Bu gruplar arasında ortak retorik temaları ke şfetmeyi amaçlamaktadırlar. Verileri 1979'dan 2001'e kadar uzanmakta olu p, 22 farklı radikal grubu kapsamaktadır.

Karell ve Freedman (2019)'ın çalışmasının amacı, yeni temaların indükt if keşfine katılmak olsa da, mevcut teoriden bağımsız değildir. Tamamen indüktif olmaktan ziyade, yaklaşımlarını "hesaplamalı abductive analiz" ol arak tanımlamaktadırlar ve bu, abductive analiz (Tavory ve Timmermans, 2014) niteliksel yöntemine dayanmaktadır. Temellendirilmiş teori ile karşı laştırıldığında, abductive analiz, mevcut teorilerle çelişen şaşırtıcı kanıtlar a dayalı olarak teori üretir (Timmermans ve Tavory, 2012). Bu nedenle, ve rilerini analiz etmeden önce, Karell ve Freedman (2019), radikal retoriğin mevcut kavramını özetlemişlerdir—"radikal söylemin genellikle dışa dönü k olarak anlaşıldığını varsaydık: radikaller, toplumlarındaki güçlü bireyleri , organizasyonları, fikirleri ve yaşam biçimlerini hedef alır, ancak kendi to plulukları ve destekçi ağlarının dışındadır."

Belgelerini İngilizceye çevirdikten sonra, yazarlar STM'yi kullanarak belgel er içindeki konuları ve temaları keşfederler ve radikal retoriğin önceki kavra mlarından sapma gösteren herhangi bir konuyu tanımlamaya dikkat ederler. Ardından, her bir konudaki en olası kelimeleri ve en temsilci belgeleri kullan arak, çıktının sağladığı sekiz konunun her birine etiket vermektedirler.

Doclingo https://www.doclingo.ai

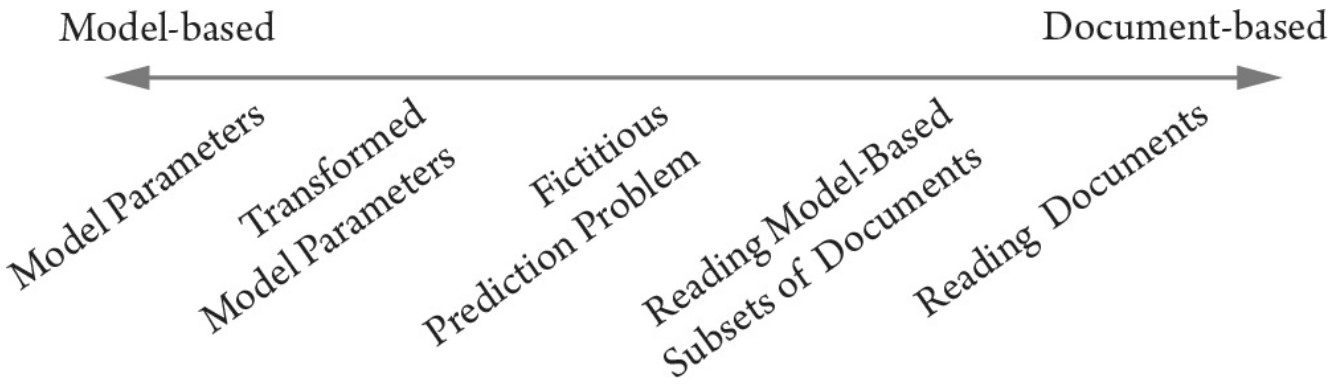
model. Karell ve Freedman (2019) daha sonra radikal retoriklerin mevcut k avramlarını yansıtan sekiz konudan beşini tanımlarlar; bunlara dışa dönük radikalizm veya “Subversiyon Radikalizmi” derler.

Ancak, konusal analizleri içinde, diğer iki konunun—“Yerel & Eğitim Pazarları” ve “Dini Kod” olarak adlandırdıkları—içe dönük değil, dışa d önük olduğunu da keşfederler. Bu belgeleri dikkatlice okuyarak, bu ko nuları “Geri Dönüş Radikalizmi” olarak adlandırdıkları daha büyük bir kavrama gruplar. Başka yerlerde dini ve sosyal hareketler hakkında o kuduklarında, bu fikrin, çalışmalarının ötesinde grupların geniş bir da vranış yelpazesini açıklamada faydalı olduğunu kabul ederler. Böylece , bunun radikal grupların retoriklerini küresel ölçekte incelemek için p otansiyel olarak yeni ve faydalı bir kavram olabileceği sonucuna varırl ar.

Doclingo https://www.doclingo.ai

13.5 Konu Modellerini Etiketleme

Konu modellerini etiketlemek, nihayetinde Bölüm 12'de tartışıldığı gibi küm eleri etiketlemeye oldukça benzer—bu, dikkatli okuma ve otomatik sezgilerin b ir kombinasyonunu içeren nihayetinde insana ait bir etkinliktir. Ancak, konu m odellerini etiketlemek için daha otomatik yaklaşımlara her zaman ilgi vardır, sa dece keşif amaçları için başlangıçta bir görüş sağlamak amacıyla. Bu teknikleri, iki uç nokta ile sabitlenmiş bir süreklilik boyunca var olduğunu düşünürüz. Model tabanlı yaklaşımlar, konu modelinin parametrelerini kullana n ve tamamen rastgele seçilen belgeleri okuyarak bu okumaları eti ketleri bilgilendirmek için kullanan belge tabanlı yaklaşımlardır.



Şekil 13.5. Model tabanlıdan belge tabanlıya kadar uzanan etiketleme yöntemlerinin bir spektrumu.

Model tabanlı yaklaşımlar genellikle daha kolay kullanılır ve daha “otom atik”dir, ancak genellikle modelde güçlü varsayımlar kullanır, bu da gerçek dünya metnini iyi yansıtmayabilir. Belge tabanlı yaklaşımlar, orijinal belgel eri okumayı içerir, bu da onları kullanmayı daha zor ve maliyetli hale getirir ; ancak, modele bağımlılığı önleyerek, bu yaklaşımlar genellikle konu mode linin ne yaptığını anlamada merkezi bir rol oynar.

Şekil 13.5'in en sol tarafında, konuların ne anlama geldiğini yorumlamanın en basit stratejisi - doğrudan model parametrelerini kullanmaktır. Parametreler μ, belirli bir konunun ürettiği token verildiğinde her kelime türünün olasılığını bize söyler. En olası kelimeleri doğrudan okumak etkili olabilir, ancak bu, yalnızca kü mede yaygın olan değil, genel olarak çok yaygın olan kelimeleri tercih etme eğili mindedir. Dil genellikle anlam açısından çok ayırt edici olmayan, ancak son derec e yaygın olan kelimelerle doludur. Konu modelleri bu kelimeleri temsil etmek zor undadır, ancak bunlar her şeyle birlikte ortaya çıkar ve bu nedenle genellikle kon ular arasında biraz eşit şekilde dağılırlar.

Bu sorunu ele almanın bir yolu, modellemenin başında sık kullanılan ve bilgilendirici olmayan kelimeleri çıkarmaktır; bunu daha önce tartışmıştık.

Doclingo https://www.doclingo.ai

Ancak, önceden belirlenmiş bir listeden durak kelimeleri çıkardığımızda, genell ikle çok sık kullanılan ama nispeten bilgilendirici olmayan korpus spesifik kelim eler vardır.

Alternatif olarak, model parametrelerini dönüştürerek daha bilgilendirici bir özet oluşturmaya çalışab iliriz. Roberts, Stewart ve Tingley (2019), Bischof ve Airoldi (2012) ile Airoldi ve Bischof (2016) tarafından y apılan önceki çalışmalara dayanan bir metrik öneriyor ve buna FREX deniyor. FREX, bir küme içindeki bir kelimenin sıklığı ile küme için özgüllüğünü kullanarak kelimelerin sıklığını ve özgüllüğünü yakalar. Bir küme ile ilişkili kelimelerin sıklığını ve küme için özgüllüğünü kulla narak, kelimelerin sıklığı ile küme için özgüllük arasında ağırlıklı harm onik ortalama kullanarak, kelimelerin sıklığını ve özgüllüğünü yakalar. Sık kullanılan ama kümeye özgü olmayan kelimeleri cezalandırarak, kümeleri n ne hakkında olduğunu ve onları ayıran unsurları daha iyi bir şekilde görebil iriz; bu, temel model değişmemiş olsa bile.

Sonuç olarak, en iyi yaklaşım, birçok farklı yöntem kullanarak etiketlemektir ve ko nunun en iyi hissini elde etmek için farklı kelimelerin kombinasyonunu kullanmaktır. Bu, kurgusal bir tahmin problemi yaklaşımıyla üretilen kelimelerle birleştirilebilir(Bölüm 11). Yine de, belgeleri dikkatlice okumak öne mlidir.

Doclingo https://www.doclingo.ai

13.6 Sonuç

Bu bölümde, Bölüm 12'den kümeleme modellerinin genellemesi olan konu modellerini ele aldık. Kümelemede, her belgenin tek bir küme ile temsil edilmesi gerekir ve dolayısıyla kelimeler üzerinde tek bir dağılım olmalıdır. Konu modellerinde, her belgenin karışık üyelik temsili vardır, bu da her belgenin kelimeler üzerinde tamamen benzersiz bir dağılıma sahip olabileceği, ancak bunun konuların ağırlıklı bir kombinasyonu ile sınırlı olduğu anlamına gelir. Ayrıca, kanonik LDA modelinin, belgeler ve konular arasında bilgilerin etkili bir şekilde paylaşılmasına olanak tanıyan kovaryant bilgilerle nasıl genelleştirilebileceğini de tartıştık.

Elbette, tanımladığımız yaklaşımlar belgelerdeki konusal bilgiyi modellemenin tek yolu değildir. Konu modelleri, belgeleri konuların ağırlıklı bir kombinasyonu olarak temsil eder, ancak aynı zamanda negatif olmayan—ancak başka türlü sınırlı olmayan—ağırlıklar kullanan (Lee ve Seung, 2001), çoklu üyelik, bir dizi konunun açılıp kapatılabileceği (Griffiths ve Ghahramani, 2011) ve konuların bir ağaç boyunca yollar olarak temsil edildiği (Paisley ve ark., 2015) yaklaşımlar da vardır. İncelediğimiz modellerin çoğu, konuların kelimeleri üretme şekline göre nispeten basit bir toplama yapısına sahiptir. Bu tür bir modelin bir sınırlaması, modelin bireysel konulardan daha aşırı olan bir belgeyi tahmin edememesi veya yeterince açıklayamamasıdır.[6] Pratikte bu, bir belgenin birden fazla konu ile temsil edilebileceği anlamına gelirken, konuların örtüşmelerinden kaynaklanan daha kesin bir tahmin üretmek için etkileşime giremeyeceği anlamına gelir. Eğer akademik disiplinlerin bir modeline sahipsek ve bir belgeyi "beşeri bilimler" ve "bilgisayar bilimi" karışımı olarak temsil ediyorsak, "dijital beşeri bilimler" ifadesinin, orijinal konulardan herhangi birinin tek başına vereceğinden daha yüksek bir olasılığını elde edemeyiz.

Bu endişe, konuların kendi benzersiz anlamlarını almasına izin vermek için gizli eklemeli model yapısından vazgeçerek önlenebilir (Salakhutdinov ve Hinton, 2009; Larochelle ve Lauly, 2012; Paul ve Dredze, 2012; Gan ve diğ., 2015; Ranganath ve diğ., 2015). Bu modeller, burada tartıştığımız konu modellerinden çok daha esnektir ve dolayısıyla, dışarıda tutulan metin üzerinde çok daha yüksek tahmin doğruluğu elde edebilirler.
Ancak, bu esneklik aynı zamanda onları yorumlamayı da orantılı olarak daha zor hale getirir. Yukarıdaki örneğimizi sürdürmek için, LDA modelinden "bilgisayar bilimi" konusunu, o konu altında en olası olan kelimeleri incelemeyi düşünelim. Model altında, bu kelimeler, büyük bir "bilgisayar bilimi" bileşenine sahip herhangi bir belge için her zaman yüksek olasılığa sahip olacaktır. Çarpan gizli değişken modelleri altında, yüksek olasılıklı kelimeler

Doclingo https://www.doclingo.ai

bir belgedeki tüm mevcut konular arasındaki etkileşime bağlıdır. Bu, muazzam bir ifade gücü sağlar, ancak aynı zamanda bu etkileşimlerin nasıl kolayca değerlendirileceğini düşünmeyi de çok zor hale getirir.

Bu esnekliğin ve yorumlanabilirliğin potansiyel ticaret dengesi, keşif için modellerde özellikle önemlidir. Her zaman daha fazla karmaşıklık ekleyebiliriz—örneğin, kelime sırasını modelleme veya konular arasında etkileşimlere izin verme—ancak keşfi hala kolayca tanıyabileceğimizden emin olmamız gerekiyor, aksi takdirde bu bizim için çok faydalı olmayacaktır. Konu modelleri, sosyal bilimlerde popüler görünmektedir çünkü iyi bir denge kurmaktadırlar. Kümeleme modellerinden daha karmaşık olmalarına rağmen, basit eklenebilir yapı ve orantılı üyelik temsili, yorumlamayı yönetilebilir kılmaya yardımcı olmaktadır.

Bir sonraki bölümde, keşif için son yöntemler setini—belge gömme yöntemlerini ele alacağız. Bu yöntemler, belgeleri sınırsız ama çok düşük boyutlu bir alana projekte etmeye odaklanır ve genellikle görselleştirme için faydalıdır.

---

[1]Bir kez daha burada zengin bir entelektüel tarih var. Bölüm 8'de Gizli Anlam İndeksi (LSI) hakkında konuştuk—Tekil Değer Ayrıştırması (SVD) uygulaması, muhtemelen ağırlıklı bir belge terim matrisine. LSI, bilgi retrieval için önemli bir atılımdı ve birkaç alanda kullanılmaya devam etmektedir (Deerwester ve diğ., 1990).

LDA'nın doğrudan öncüsü, olasılıksal Gizli Anlam İndeksleme (Hofmann, 1999), tamamen algoritmik LSI'yi olasılıksal modelleme çerçevesine yerleştiren bir çalışmadır. Hofmann'ın formülasyonunda, belge düzeyindeki gizli parametrelere ön dağılım verilmemiştir, bu da üretken modelin eksik olmasına ve muhtemelen aşırı uyum sağlamasına yol açmıştır. Blei, Ng ve Jordan'ın (2003) Latent Dirichlet Allocation modeli, 2001 yılında Neural Information Processing Systems Konferansı'nda tanıtıldı. Yazarların bilmediği bir şekilde, aynı model genetik topluluğunda Pritchard, Stephens ve Donnelly (2000) tarafından bağımsız olarak geliştirilmişti. Orijinal makale varyasyonel çıkarım kullanıyordu, ancak başka bir atılım, çökertilmiş gibbs örnekleyicisinin (Griffiths ve Steyvers, 2004) tanıtılmasıyla geldi. Bu yaklaşımlar modüler çıkarıma uygun hale geldi ve bu nedenle birçok LDA varyantı tasarlandı. LDA uygulamalarının bir özeti için Blei (2012) ve Boyd-Graber, Hu ve Mimno (2017) çalışmalarına bakın; bunlar sırasıyla kısa ve monografik uzunluktadır.

Bu bölümün bazı kısımları Grimmer, Roberts ve Stewart (2021)'den alınmıştır.

[3]Bu belirli modelde, konuların evrim geçirebilme derecesi, zaman içindeki rastgele yürüyüşteki varyans parametresi tarafından güçlü bir şekilde etkilenmektedir. Varyans parametresi çok büyük olduğunda, konular alakasız konulara evrimleşecektir.

[4]Pratikte, aslında Z token düzeyindeki değişkenlerin bir fonksiyonunu kullanıyoruz çünküpratikte daha iyi performans gösteriyor. π i y i'yi tahmin ederken, kelimelerden çok kopuk hale gelebilir (Mcauliffe ve Blei, 2008).

Doclingo https://www.doclingo.ai

[5]STM, üç önceki modelin genelleştirilmesi ve birleştirilmesidir. Blei ve Lafferty(2007), daha geniş bir konu korelasyonları yelpazesi sağlamak için Dirichlet'e alternatif olarak lojistik normal önbilgiyi tanıtan korelasyonlu konu modelini tanıttı. Mimnove McCallum (2008), belge yüklemeleri üzerindeki Dirichlet önbilgisinin bir parametreleştirmesini kullanarak yaygınlık kovaryantları için hızlı bir genel altyapı tanıttı. Eisenstein, Ahmed ve Xing (2011), konular, kovaryantlar ve etkileşimleri nedeniyle seyrek sapmalar yoluyla içerik kovaryantlarını dahil etmenin genel bir yolunu tanıttı. Tahminlemede birkaç iyileştirme de hesaplamayı mümkün ve etkili kılmak için esastı (Khan veBouchard, 2009; Arora ve diğ., 2013; Wang ve Blei, 2013). STM modeli, Roberts ve diğ. (2013) tarafından arşiv dışı bir makalede tanıtıldı ve ilk uygulamaRoberts ve diğ. (2014) tarafından yayımlandı. Roberts, Stewart ve Airoldi (2016), modeliistatistiksel bir kitleye tam olarak tanımlamaktadır. Modelin uygulamalı kullanımında anahtar, R'de stm (Roberts, Stewart ve Tingley, 2019) uygulamasıdır; yayın tarihine rağmen, 2014'te yayımlanmıştır.

[6]Herhangi bir konveks kombinasyon, konveks kabuğun içinde yer alır. Bu, LDA gibi bir modeldeki belge temsilinin, bireysel konulara göre daha keskin bir kelime dağılımını tahmin edemeyeceği anlamına gelir.

Doclingo https://www.doclingo.ai

BÖLÜM 14

Düşük Boyutlu Belge Gömme

Metinleri veri yöntemleri olarak kullanarak, metinlerin içeriğini damıtarak ve ardından bu damıtmayı belgeleri organize etme yolunu öğrenmek için kullanarak keşfi kolaylaştırabiliriz. Şu ana kadar iki organizasyon biçimini ele aldık: belgelerin bir kümeye atandığı bölümler veya belgelerin bir konu setinde orantılı üyelik aldığı karışımlar. Bu bölümde üçüncü bir yaklaşımı ele alıyoruz - düşük boyutlu belge gömme (bazen ölçekleme olarak da adlandırılır). Bu yöntemler, her belgeyi düşük boyutlu bir alana (genellikle yalnızca bir ila üç boyut) yerleştirir, bu da onları görselleştirme için uygun hale getirir.

Keşifte ele aldığımız diğer birçok yöntem gibi, bu yöntemlerin uygulanmasında, hedefin belirsiz olmasından kaynaklanan içsel bir belirsizlik vardır. Genel olarak, amacımız, dilin belirgin özelliklerini yakalayan düşük boyutlu bir gömme ile dilin yüksek boyutlu karmaşıklığını yaklaşık olarak temsil etmektir. Ne yazık ki, bu, dilin içeriğini iyi bir şekilde yakalamanın ne anlama geldiğini ve dolayısıyla farklı çözümler arasında nasıl karar verebileceğimizi belirsiz bırakır.

Ölçekleme, gizli temsilin boyutunun genellikle kümeleme veya konu modellerine göre çok daha düşük olması açısından diğer yöntemlere göre dikkate değerdir. Ölçekleme için iki temel işlevsel yaklaşımı ele alıyoruz: Temel Bileşen Analizi ve Klasik Çok Boyutlu Ölçekleme. Ardından, bölümü ve Keşif kısmını diğer keşif yaklaşımlarına dair kısa bir tartışma ile sonlandırıyoruz.

Doclingo https://www.doclingo.ai

14.1 Temel Bileşen Analizi

Temel Bileşen Analizi (PCA) içindeki amaç, daha yüksek boyutlu verileri yaklaşı k olarak temsil etmek için kullanacağımız, altında yatan küçük bir gizli özellikler s etini—temel bileşenleri—keşfetmektir. PCA, yalnızca metin değil, her türlü veriyi analiz etmek için yaygın bir yöntemdir.

Basitlik açısından, belgelerin kelime torbası yaklaşımına yakın bi r temsilini—merkezlenmiş kelime torbasını—ele alacağız. Orijinal k elime torbasını alıyoruz ve her sütunda her kelimenin ortalama kaç kez göründüğünü çıkarıyoruz. Böylece, belge *i* içindeki kelime *j* i çin 2 değeri, kelimenin tüm belgeler arasındaki ortalama kullanım oranına göre iki ek kez kullanıldığını gösterir. Bu bölüm için notasy onu basit tutmak adına, her belge için merkezlenmiş vektörü W i , = (W i 1 , W i 2 , … , W i J) olarak adlandıracağız. Bu merkezlenmiş vektörlerin bir matrisini *W* verildiğinde, her belgeyi *K* temel bileşe n seti (k = 1 , … , K) ile yaklaşık olarak temsil etmeye çalışacağız. H er temel bileşen, o bileşenle ilişkili her kelimenin kullanım oranı ha kkında bilgi sağlayan J × 1 vektörüdür μ k = (μ k 1 , μ k 2 , … , μ k J). Her gözlem *i* için, temel bileşenler üzerinde *K* puan olduğunu var sayacağız. *i*'nci gözlem için puanların K × 1 vektörüne π i = (π i 1 , π i 2 , … , π i K) adını vereceğiz.Puanları ve temel bileşenl eri kullanarak, her gözlemi W i , olarak yazacağız,

$$W i , = \pi i 1 \mu 1 + \pi i 2 \mu 2 + \ldots + \pi i K \mu K \breve{} W\hat{} i , + \varepsilon i \backsim \text{error} , \quad (14.1.1)$$

J × 1 vektörü ε i = (ε i 1 , ε i 2 , … , ε i J) bir hata terimidir ve W i ,W i 'nin yakl aşık değeridir. Skorların *π* uzatması, kısaltması veya çevirmesi gerektiğini u nutmayınana bileşenleri belirli gözlemi yaklaşık olarak elde etmek için. Çünkü *K* , *J*'den daha küçüktür, bu yaklaşımda mutlaka bazı hatala r olacaktır.

Tahminin amacı, hatanın büyüklüğünü en aza indirmek için *π* ve *μ* se çmektir. Yani, *π* ve *μ* seçerek en aza indireceğiz.

$$f (\pi , \mu) = 1 N \sum i = 1 N \varepsilon i ' \varepsilon i = 1 N \sum i = 1 N (W i , - \sum k = 1 K \pi i k \mu k) ' (W i , - \sum k = 1 K \pi i k \mu k) . \quad (14.1.2)$$

Denklemin hata büyüklüğünü en aza indirmek için optimal çözüm 14.1.2, en büyük *K* eigenvalue'lara karşılık gelen *K* eigenvector'leri k ullanmak için W ′ W (ampirik varyans-kovaryans matrisi) *K* ana bil eşenler olarak kullanılır. Ayrıca, *k*th ana bileşen üzerindeki *i*th gözle m için puan, π i k = μ k ′ W i ,. Eigenvector'lar hakkında sezgi için

Doclingo https://www.doclingo.ai

en büyük özdeğerlerle ilişkili olanlar seçilir, hedefi göz önünde bulundurun : mümkün olduğunca fazla belge-terim matrisinin varyasyonunu açıklamak için küçük bir ana bileşenler seti kullanmaktır. Doğrusal cebir sezgisine faz la başvurmaktan kaçınırken, diyagonalizasyon sonuçlarına aşina olanlar, bi r matrisin daha iyi bir şekilde yaklaşık olarak elde edilebileceğini, önce en b üyük özdeğerlerle ilişkili olan yaklaşık bileşenleri seçerek not edebilirler. Bu nedenle, önce en büyük özdeğerlerle ilişkili özvektörleri seçmek, varyans-k ovaryans matrisini mümkün olduğunca iyi bir şekilde yaklaşık olarak elde e tmemizi sağlar. Alternatif olarak, ana bileşenleri türetmek, hata büyüklüğü nü minimize etmenin, puanların varyansını maksimize etmekle eşdeğer ol duğunu gösterir. Bu, en büyük özdeğerlerle ilişkili özvektörleri seçerek yap ılır.

Temel bileşenleri tahmin ettikten ve belgelerin her bir temel bileşe nde nasıl yüklendiğini belirledikten sonra, belgelerin hata payını mini mize eden bir damıtma elde etmiş oluruz. Ancak keşif amaçları için çık tıyı yorumlamamız gerekir: temel bileşenleri ve puanları etiketlemek v e temel bileşenlerin yakaladığı altında yatan gizli kavramları açıklama k. Küme analizi yöntemlerinde olduğu gibi, temel bileşenleri ve puanl arı anlamak için hem otomatik hem de manuel yöntemler kullanacağı z.

14.1.1 TEMEL BİLEŞENLERİ ETİKETLEMEK İÇİN OTOMATİK YÖN TEMLER

Düşük boyutlu temsili temel bileşenlerden yorumlamanın en doğruda n yolu, her bir μ k'daki özellikle pozitif veya negatif olan değerleri incelem ektir. Özellikle, μ k'daki en yüksek değerlere sahip on kelimeyi ve en nega tif değerlere sahip on kelimeyi seçebiliriz. Bu kelimeler bilgilendiricidir, ç ünkü bir belgede mevcut olduklarında, o belgenin o temel bileşende özel likle negatif veya pozitif bir puana sahip olmasına neden olacak kelimeler i bize söyler. Bunun nedeni, $\pi i k = W i , ' \mu k$ olduğundan, μ k'daki özellikl e büyük olan girişlerin, bir belgenin spektrumda nerede yer alacağını beli rlemede özellikle etkili olmasıdır.

Temel bileşenleri doğrudan analiz etmenin ötesinde, belgelerin bir spektrum da nerede yer aldığını tahmin etmeye çalışabiliriz. Bunu yapmak için, bir belgeni n puanını, belgenin yazarının veya belgenin diğer meta verileri gibi diğer bilgilerl e regresyona tabi tutabiliriz. Bu yaklaşım, yazarların veya metinlerinin ideolojisin i ölçmek için temel bileşen analizi (ve ilgili yöntemler) kullanıldığında özellikle fay dalıdır. Örneğin, belirli bir temel bileşenin ideolojiyi ölçtüğüne inanıyorsak, yazar ların puanlarını iyi doğrulanmış bir ideoloji ölçüsü ile regresyona tabi tutabiliriz.

Doclingo https://www.doclingo.ai

ABD bağlamında bu genellikle metinlerden elde edilen puanların, r oll call oylamalarından türetilen ABD Kongresi'ndeki ideolojik davr anışların düşük boyutlu ölçüleri olan DW-Nominate puanlarına reg resyona tabi tutulmasını içerir (Tausanovitch ve Warshaw, 2017). Bi r uyarı noktası belirtmekte fayda var:

Düşük korelasyonlar, iki gizli kavram ilişkili olsa bile ortaya çıkabilir. Bunun nedeni, ölçüm hatasının mevcut olabilmesi ve korelasyonları zayıflatabilmesidir.

14.1.2 TEMEL BİLEŞENLERİ ETİKETLEMEK İÇİN MANUEL YÖNTEMLER

Belgeleri etiketlemek için nicel yaklaşımlara ek olarak, temel bileşen modellerinin çıktısını metinlerin yakın okumalarını yapılandırmak ve ar dından bileşenleri etiketlemek için kullanabiliriz. Bunu yapmak için, spe ktrumda benzer noktalarda belgeleri örneklemeyi öneriyoruz. Özellikle, bu belgelerin ortak noktalarını anlamak için spektrumun uç noktaların dan bir örnek belge okuyabiliriz. Alternatif olarak, belgeleri belirleyici bi r şekilde seçmek yerine, spektrum boyunca belgeleri örnekleyebiliriz; u ç noktalara daha yakın belgeleri daha fazla ağırlıklandırarak, belgelerin belirli konumlarda neden bir araya toplandığını anlamaya çalışabiliriz.

Belgeler dikkatlice okunduktan sonra, spektrumun uçlarını etiketle yebiliriz ve belgelerin spektrum boyunca nasıl değiştiğine dair bir fikir edinebiliriz. Belgeleri okumak ayrıca verilerden öğrendiğimiz kavram sallaştırmayı geliştirmede kullanılabilecek önemli içgörüler sağlar.

14.1.3 SENATO BASIN BÜLTENLERİNİN TEMEL BİLEŞEN ANALİZİ

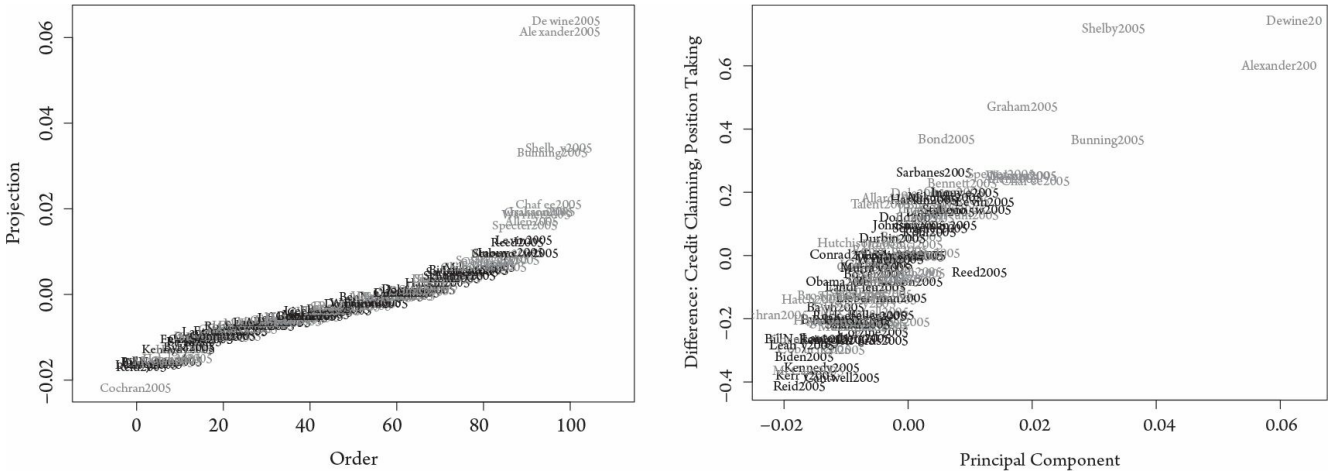
PCA'yı Grimmer (2010) tarafından sağlanan 2005 yılında yayımlanan tüm Senato b asın bültenlerini kapsayan bir Senato basın bülteni koleksiyonuna uyguluyoruz. Meti nler koleksiyonunu analiz etmek için, 2005 yılında görev yapan 100 senatör için tek bi r sayım vektörü oluşturuyoruz. Belgeyi W i olarak adlandıralım, tüm basın bültenleri i çin 2 7 9 6 × 1 normalleştirilmiş terim sayım vektörü.

Her senatör için temel bileşenleri ve puanları hesaplıyoruz. Şekil 14.1, temel bileşenlerin iki görünümünü sağlar. Sol taraftaki grafik , senatörlerin ilk temel bileşendeki puanlarını sıralar ve senatörleri Cum huriyetçi ise açık gri, Demokrat ise siyah renkte renklendirir. Sol tarafta ki grafik, gözlemler arasında doğal bir partizan sıralama görünmediğini göstermektedir; aslında iki parti arasında büyük bir örtüşme vardır.

Bu, PCA'nın değersiz olduğu anlamına gelmez. Sağdakigrafik, ilk ana bileşenin Grimmer (2013b) tarafından tanımlanan yasam a iletişim stratejisinin temel bir özelliğini yakaladığını gösteriyor: pozisyon alma ve kredi talep etme arasındaki denge.

Doclingo https://www.doclingo.ai

PCA, yasama organları arasında sistematik davranış farklılıklarını y akalıyor, ancak bunun önceden tahmin edilmesi kolay olabilecek bi r şekilde değil.



Şekil 14.1. 2005 ABD Senatosu basın bültenlerine uygulanan PCA.

PCA'nın pozisyon alma ve kredi talep etme arasındaki dengeyi yakaladığı, il k ana bileşendeki en yüksek ve en düşük değerlere sahip kelimelerden de görü lebilir. En yüksek değerlere sahip kelimeler depart, grant, program, fund, firefi ght, million ve award'dır—bunların hepsi kredi talep etme ile ilişkilidir. En düşü k değerlere sahip kelimeler ise american, court, judg, time, congress, justic ve i raq'tır—bunların hepsi politika yapma veya pozisyon alma ile ilişkilendirilmesi beklenen kelimelerdir.

14.1.4 ANA BİLEŞEN SAYISINI SEÇME

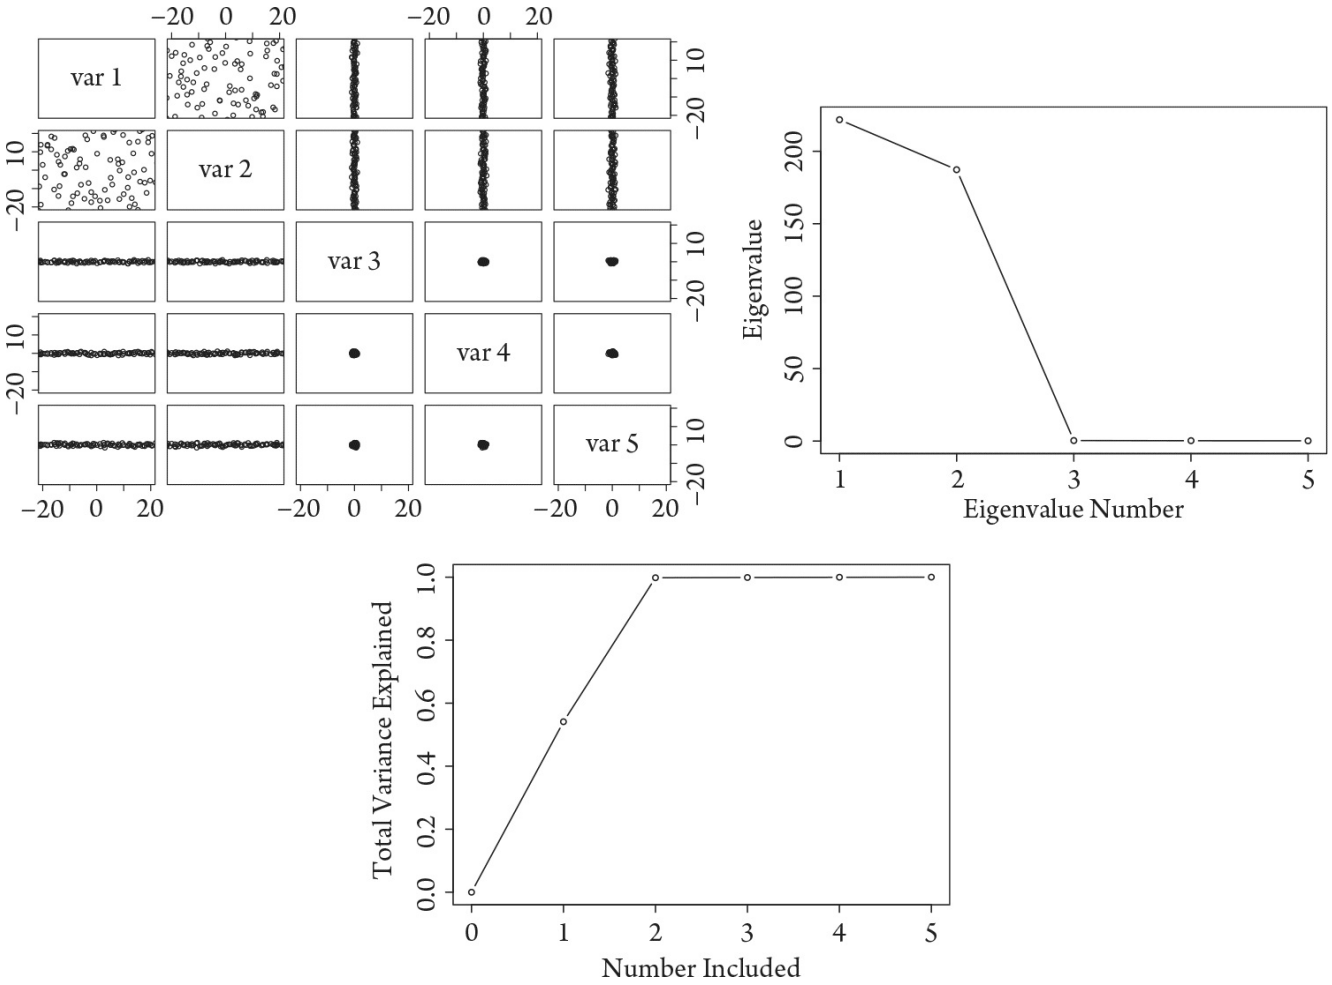
Şu ana kadar modelde dahil edilecek ana bileşen sayısını bildiğimi zi varsaydık. Ancak, elbette, en önemli modelleme kararlarından biri, modelde dahil edilecek ana bileşen sayısını belirlemektir. Ve kümele nme yöntemlerinde olduğu gibi, veriye uygulanan model kullanılara k ana bileşen sayısını doğrudan optimize edemiyoruz. Bunun nedeni , ana bileşen modellerinin açgözlü olmasıdır: daha fazla ana bileşen yaklaşıma eklendikçe, yaklaşım daha iyi hale gelir. Bu açgözlü davra nış göz önüne alındığında, modeli iç örnek uyumu kullanarak değerl endirmek, önemsiz bir çözüm verecektir—vokabülde yer alan giriş s ayısı kadar ana bileşen dahil ettiğimizde en iyi iç örnek yaklaşımını el de ederiz. Bu keşif için faydalı değildir: verimizdeki benzersiz kelime sayısını zaten biliyoruz.

PCA modellerinin açgözlü özelliği, bileşen sayısını seçmek için diğer y aklaşımları kullanmamız gerektiği anlamına geliyor. Sayısal olarak, hata

Doclingo https://www.doclingo.ai

modelde kalan, hariç tutulan özdeğerlerin toplamına eşittir. Bu, özdeğerler in boyutunu model seçimimizi yönlendirmek için kullanabileceğimiz anlamı na gelir. Nedenini görmek için Şekil 14.2'ye bakalım. Burada, görünüşte b eş boyutlu olan verileri sunuyoruz, ancak yalnızca iki boyutun varyansı var dır, geri kalan üç boyut ise yalnızca küçük miktarlarda gürültüdür. Bunu, n oktaların bir araya toplandığı boyutlarla birlikte sol üst grafikte görebiliriz. Sağ üst grafikte PCA uyguladığımızda iki büyük başlangıç değeri ile özdeğe rler elde ettiğimizi gösteriyor, geri kalan üçü ise küçüktür. Ve nihayet, alt g rafikte her boyutun açıkladığı varyansı gösteriyor. İlk iki dahil edilen özdeğ er neredeyse tüm varyansı açıklar, geri kalan üç özdeğer ise az bir şey açıkl ar, bu da bu boyutların dahil edilip edilmediği konusunda yaklaşık olarak a ynı iyi bir tahmin yaptığımızı önermektedir.

Doclingo https://www.doclingo.ai



Şekil 14.2. PCA kullanarak sayıyı belirleme örneği bileşenler.

Sağdaki grafikteki sezgi Şekil 14.2 alışılmışa yol açar bir PCA gerçekleştirirken bileşen sayısını seçerken öneri: Şekil 14.2 sağdaki grafikte "dirsek" aramaktır. Dirsek, açıklanan varyansın bü küldüğü yer veya daha fazla bileşen eklemenin açıklanan varyanst a bir artışa yol açmadığı yerdir.

Şekil 14.2 stilize edilmiş bir örnektir ve grafikten çıkan güçlü sonucunilgilendiği miz örneğe PCA uygulandığında geçerli olmayabileceği konusundauyarıyoruz. Ger çek uygulamalarda, açıklanan varyans grafiği neredeyse hiçbu kadar net görünme yecektir. Bu nedenle, açıklanan yüzde varyans faydalı olacaktır,bununla birlikte bu örneğin önerdiği kadar net bir rehberlik sağlamayacaktır.

Farklı bir yaklaşım, yeni açıklayıcı güç sağladıkları sürece daha fazla boyut içermektedir. Boyutları etiketlemek için, farklı belgelerin ana bi leşenin farklı kısımlarında nasıl yüklendiğini inceleyebileceğimiz birço k özelliği gözden geçirebiliriz. Bu daha niteliksel inceleme, ana bileşen lerin maddi yorumlarını geliştirebilmemiz için de gereklidir.

PCA için boyut sayısını seçerken anahtar,

Doclingo https://www.doclingo.ai

niceliksel yaklaşım sınırlamalarını model seçimi için hatırlayın. PCA içinmodel uyumunun niceliksel ölçüleri, her ek boyutun ne kadar var yansı açıkladığınıölçer. Verilerdeki “gerçek” boyut sayısını size söyl eyemez, çünkü doğru sayıhata toleransınıza bağlıdır. Basitliğin ekstr a hatadan daha önemli olduğuortamlarda, daha az sayıda bileşen kull anmaya istekli olabiliriz. Ancak diğerortamlarda doğruluk son derece önemli olacaktır, bu nedenle dahil edilecekbileşen sayısının daha büy ük olması gerekecektir. Ve hala diğer ortamlarda PCA’yıtahminler yap mak için bir girdi olarak kullanırız. Bu durumlarda, dahil edilenbileşen sayısını belirlemek için net bir nesnel fonksiyonu kullanabiliriz. Ancak ortam dışında, dahil edilecek bileşen sayısı analizimizin hedeflerine ba ğlı olacaktır.

Doclingo https://www.doclingo.ai

14.2 Klasik Çok Boyutlu Ölçekleme

PCA ile olduğu gibi, Klasik Çok Boyutlu Ölçekleme (MDS) amacıdırbi r belge koleksiyonu için düşük boyutlu bir yaklaşım bulmaktır. Ve gör eceğiz ki,bazı özel varsayımlarla, MDS PCA ile aynı yanıtı verecektir. Bu aynı temsili elde etmek için,MDS, metinler arasındaki mesafeleri dah a düşük boyutlu bir temsil ile korumaya odaklanır.Klasik MDS'yi türet mek için, elimizde bir koleksiyon olduğunu varsayalım *N* belge. Diyelim ki, N × N mesafe matrisini *Q* oluşturuyoruz, burada q ii ′ girişi, bel geler arasındaki Öklid mesafesini temsil eder *i* ve i ′ (bunu Bölüm 7: Vekt ör Uzay Modeli ve Benzerlik Ölçüleri'nde tanımlıyoruz). MDS'nin amacı, m esafeleri mümkün olduğunca yakın bir şekilde yaklaşık olarak temsil ede n N × K vektörleri, *π*bulmaktır. Yani, belge *i* için daha düşük boyutlu bir te msil arıyoruz, π i, ve belge i ′, π i ′ böylece *i* ve i ′ arasındaki mesafeleri mümkün olduğunca yakın bir şekilde tahmin edebiliyoruz.

Bu yaklaşık değeri elde etmek için Klasik MDS, mesafe matrisindeki g özlemler arasındaki mesafeyi latent alandaki gözlemler arasındaki mes afe ile karşılaştıran aşağıdaki hedef fonksiyonu minimize etmek için *π* a ramaktadır:

$$f(Q,\mu)=\sum_{i=1}^{N}\sum_{i'<i} q_{ii'}-\sum_{k=1}^{K}(\pi_{ik}-\pi_{i'k})^{2}\,2\,.$$

PCA'da olduğu gibi, MDS'nin optimizasyonu, mesafe matrisini özvektörlerle yaklaşık hale getirmeye indirgenir. Bunu yapmak için, mesafe matrisini satır ortalamalarını ve sütun ort alamalarını çıkararak iki kat merkezli hale getiriyoruz ve ardından − 2 ile bölüyoruz. Bu, N × N matrisini W W ′ sağlar. Daha sonra bu matrisi ilk *K* eş eigenvektör il e yaklaşık olarak temsil ediyoruz. Her gözlem için gömme W i , = λ 1 π i 1, λ 2 π i 2 , … , λ k π i k, burada λ k *k*'inci özvektörün özdeğerine atıfta b ulunur. Tam bir türetim için Hastie, Tibshirani ve Friedman (2013) 'e bakın.

Düşük boyutlu gömme yöntemleri, bir belge koleksiyonundaki tem el yapıyı keşfetmek için faydalıdır. Ancak MDS uygularken, düşük boy utlu yapının kullanılan mesafe ölçütüne güçlü bir şekilde bağlı olduğu nu hatırlamak önemlidir. Bu şaşırtıcı değildir; sonuçta, MDS daha az d eğişkenle mesafeleri yaklaşık olarak tahmin etmeye çalışmaktadır. An cak, farklı mesafe ölçütleri kullanarak yakınlık tanımını değiştirmek, fa rklı yapıların bulunmasına neden olacağını hatırlamak önemlidir. Ayrıca, MDS ve PCA gibi yöntemler yalnızca belgelerin göreceli konumlarını koru yacaktır. PCA'nın türetilmesi bunu net bir şekilde ortaya koyar, çünkü verilerdeki korelasyon yapısını korur. Ve MDS yalnızca nesneler arasındaki mesafeyi korur.

Doclingo https://www.doclingo.ai

Bu, PCA ve MDS gibi yöntemlerin yalnızca düşük boyutlu alandaki k onumlar hakkında göreceli bilgi sağlayabileceği anlamına gelir.

14.2.1 KLASİK MDS'İN UZANTILARI

Klasik MDS, bir veri setinin düşük boyutlu yapısını tanımlamak için faydalı olan güçlü bir yöntemdir. Klasik MDS'nin hedef fonksiyonu, düşük boyutlu al andaki gözlemler arasındaki mesafeleri, orijinal mesafe matrisindeki belgele r arasındaki mesafelerle karşılaştırarak metnin herhangi bir düşük boyutlu t emsilinin kalitesini değerlendirir. Bu karşılaştırma makuldür, ancak belgeler arasındaki daha büyük mesafeleri yaklaşık olarak tahmin etme konusunda d aha iyi iş çıkaran gömme yöntemlerine öncelik verir, daha küçük mesafeler y erine. Bu önemli bir hedef olabilir; ancak, araştırmacıların genellikle belirli bi r gözlemin etrafındaki belgeleri doğru bir şekilde temsil etmekle en çok ilgile ndikleri durumlar sıklıkla ortaya çıkar. Ve belgeler birbirlerinden daha uzakla ştıkça daha fazla hata tolere edilebilir.

Belgelerin en yakın mesafeleri önceliklendirecek şekilde ölçeklendirilmesini sağlayan Klasik MDS hedef fonksiyonunda birkaç değişiklik bulunmaktadır. En basit olanı Sammon MDS'dir. Sammon MDS, iki belge arasındaki m esafeyi normalize ederek Klasik MDS mesafe fonksiyonunu normalize eder. Yani, Sammon MDS hedef fonksiyonu şudur:

$$f(Q,\pi) = 1 \sum i = 1 N \sum i' < i q i i' \sum i = 1 N \sum i' < i q i i' - \sum k = 1 K (\pi i k - \pi i' k) 2 2 q i i' .$$

İki belge yakın olduğunda veya $q_{ii'}$ küçük olduğunda, mesafe matris mesafesi ile gömülü mesafe arasındaki farklar büyütülecektir. Ancak da ha büyük mesafedeki belgeler için $q_{ii'}$ ile gömülü mesafe arasındaki t utarsızlıklar daha az önemli olacaktır. Hedef fonksiyonunu değiştirmek, optimizasyonun zorluğunu artırır. Doğrudan lineer cebir uygulaması ye rine, bir Sammon MDS için gömme elde etmek bir gradyan iniş algoritması gerektirir.

Gözlemlerimizi ölçeklendirmek için yapabileceğimiz birkaç başka değişiklik daha vardır. Örneğin, temsilci noktaların bir setini gömmek için landmark MDS kullanabilir ve ardından kalan belgeleri bu noktaların etrafında gömebiliriz (Pl att, 2005). Diğer yöntemler, potansiyel olarak karmaşık bir gizli yapıyı ortaya çı karmak için yerel olarak Öklidyen olan bir manifold veya daha karmaşık geom etrik yapı arayışındadır (Roweis ve Saul, 2000).

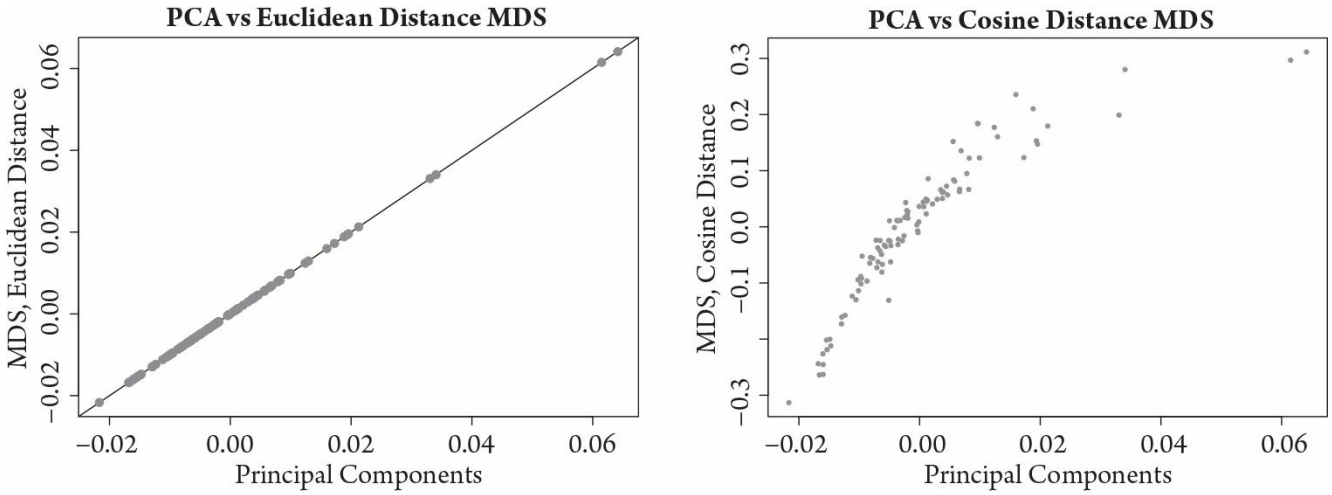
14.2.2 KLASİK MDS'Yİ SENATO BASIN BÜLTENLERİNE UYGULAMA

Doclingo https://www.doclingo.ai

Keşif amaçları için, MDS ve PCA'nın aynı hedefi vardır: belgeler h akkında içgörüler sağlayan gizli bir metin temsili bulmak.

Bölüm 14.1.4'te, Senato basın bültenleri koleksiyonuna PCA uygulamanın, senatörlerin ke ndi bölgelerindeki parayı sahiplenme ile önemli konulardaki pozisyonlarını ifade etme ara sında nasıl bir denge kurduğunu ortaya koyduğunu gördük.

Şekil 14.3'teki sol taraftaki grafik, senatörlerin toplu basın bültenleri arasında ki mesafenin Öklid mesafesi ve PCA kullanılarak hesaplandığı MDS'den elde edile n gömme değerlerini karşılaştırmaktadır. Bu grafik, gömme değerlerinin tam ola rak eşit olduğunu göstermektedir: belgeler arasındaki mesafeyi Öklid mesafesi k ullanarak ölçmek ve ardından Klasik MDS uygulamak, belge koleksiyonuna PCA uygulamakla eşdeğerdir. Bir sonraki grafik, farklı mesafe metriklerinin ve metin t emsillerinin farklı gömme değerlerine yol açtığını göstermektedir. Sağ taraftaki grafikte, belgeler arasındaki mesafeyi 1 −kosin benzerliği olarak ölçüyoruz. Bu, K lasik MDS'nin gözlemlerin farklı, ancak yine de benzer bir gömme değerini sağla dığını göstermektedir.



Şekil 14.3. Senato basın bültenlerinde MDS ve PCA'yı karşılaştırma. Sol: Klasik MDS, PCA ile eşdeğerdir. Doğru: PCA, kosinüs mesafesi MDS ile karşılaştırıldığınd a.

Doclingo https://www.doclingo.ai

14.3 Sonuç

Bu bölümde, belgeleri sınırsız, düşük boyutlu alanlara projekte etme tekni klerini ele aldık. Bu, verileri görselleştirmek için genellikle yardımcıdır çünkü grafikler yalnızca makul bir şekilde iki veya en fazla üç boyutu (örneğin, renk kullanarak) yakalayabilir. Bu yöntemler, verilerin çoğunu açıklayan bir veya ik i çok güçlü boyut olduğuna inandığımızda da yardımcı olabilir, tıpkı ideolojini n oy sayıları için yaptığı gibi.

Bu, genel olarak daha fazla konuşulması gerektiğine inandığımız Discovery'nin sonuna da getiriyor. Dört ana yaklaşımı ele aldık: ayırt edici kelimeler, kümeleme, konu modelleri ve belge gömme. Tüm bu yaklaşımlar, analistlerin metinleri yeni bir ışıkta okumalarını ve görm elerini teşvik etmeye yardımcı olmanın yollarıdır—sonuçta keşfi yapan algori tma değil, araştırmacılardır.

Ayrıca, bunun keşif için alınabilecek farklı yaklaşımların yalnızca küçük bir örneği olduğunu vurgulamak istiyoruz. Diğer alanlar, hesaplamalı olarak yönlendirilen keşif için yaklaşımlara sahiptir ve verimli bir yaklaşım genellikle bu alanların yaklaşımlarını ödünç almak olmaktadır.

Örneğin, kelime eşzamanlılıklarını, her kelimenin bir düğüm ve her k enarın bir metin birimi içindeki eşzamanlılığını temsil ettiği ağırlıklı yön süz bir ağ olarak temsil ederek sosyal ağ analizi üzerine zengin literatür ün içgörülerinden yararlanabiliriz (Carley, 1990, 1997). Örneğin, Rule, C ointet ve Bearman (2015), 1790'dan 2014'e kadar ABD Birlik Devletleri a dreslerindeki söylemin evrimini incelemek için bir topluluk tespit algorit ması ve ağ görselleştirme için birçok yaklaşım kullanmaktadır. Bu toplul uk tespit algoritmaları, Bölüm'de tanımlanan kümeleme algoritmalarıyl a yakından ilişkilidir. 12, ama burada bunlar uygulanmıştır kelime dağarcığı, belgelerin gruplandırılması yerine terimlerin gruplandırılmasını oluşturma.

Biz de kendimizi diğer alanlardan teknikler kullanmakla sınırlamak zoru nda değiliz. Bazen alternatif bir çerçeve, ilgi alanımızı temelden değiştirebil ir. Bail (2016), savunuculuk organizasyonlarının kamu dikkatini nasıl çektiği ni incelemekte ve yine ağ analizi perspektifinden yararlanmaktadır. Bail (20 16), genellikle farklı temaları birleştirerek kültürel köprüler oluşturabilen or ganizasyonların yeni kitlelerle daha kolay bağlantı kurabileceğini varsayma ktadır. Otizm spektrum bozukluğu ile ilgili savunuculuk organizasyonlarını n bir veri setini kullanarak, her savunuculuk organizasyonunun bir düğüm olduğu ve aralarındaki ağırlıklı kenarların isimler ve isim öbeklerinin örtüşe n kullanımını gösterdiği bir ağ oluşturur. Daha sonra kültürel köprüleri,

betweenness centrality adı verilen bir ölçüt kullanarak ölçer. Bir organizasyon

Doclingo https://www.doclingo.ai

yüksek aralarındaki merkezilik ile, organizasyonlar arasında çok sayıda en kısa yol bulunmaktadır. O, önemli kültürel köprüleme yapan organiz asyonların yeni sosyal medya kullanıcılarından iki buçuk kat daha fazla yorum aldığını bulmaktadır. Bu yalnızca belirli bir yöntem değil, aynı za manda ilgi miktarı ve daha geniş analitik yaklaşımın ağ perspektifi taraf ından tanımlandığıdır. Yeni keşifler yapmayı planlıyorsak, veriye yaklaşı m şekillerimizin sınırlarını zorlamaya devam etmek mantıklıdır.

İlgi alanımızın kavramsallaşmasını keşfettikten sonra, Ölçüm görevine geçiyoruz; bu, kitabın bir sonraki bölümünün konusudur. Orada, belgeler de ilgi alanlarının özelliklerini ölçmek için denetimli öğrenmeyi nasıl kulla nacağımızı tartışacağız. Ölçümün son bölümünde, Bölüm 21, bu kitabın b u bölümündeki tekniklerin ölçüm amaçları için kullanılmasının sonuçların ı tartışmak üzere geri döneceğiz.

Doclingo https://www.doclingo.ai

BÖLÜM IV
Ölçüm

King, Keohane ve Verba (1994) "hızla değişen sosyal dünyayı anlam ak istiyorsak, kolayca nicelendirilemeyen bilgileri de dahil etmemiz gerekecek" (s. 5) yazıyor.
Metin analizi heyecan vericidir çünkü ölçülebilir bir şekilde nicelendirilebile cek fenomenlerin yelpazesini büyük ölçüde genişletir. Bu fırsat, dijital çağd a sosyal bilimin hızla genişleyen kanıt tabanına katkıda bulunmuştur (King, 2009; Lazer ve diğ., 2009; Salganik, 2018). Metin analizi, belgeleri v erilere dönüştürerek, teorik ilgi alanlarımızla daha yakın olabilecek yeni ölçümler oluşturmamıza olanak tanır.

Yirminci yüzyılın sonlarındaki sosyal bilimlerin büyük bir kısmı, Genel Sosyal Ank et, Amerikan Ulusal Seçim Çalışması, Askerileştirilmiş Uluslararası Anlaşmazlıklar v e Gelir Dinamikleri Üzerine Panel Çalışması gibi nispeten az sayıda büyük, merkezi olarak yönetilen veri setleri etrafında inşa edilmiştir. Mevcut verilerin kullanımı güç lüdür çünkü araştırma maliyetlerini düşürerek akademisyenlerin önceden var olan çalışmalardan yararlanmalarına olanak tanır. Ancak, bu kolaylık bir bedel ödemeyi gerektirir; veri setleri, geniş bir soru yelpazesine yanıt verebilecek kadar kapsamlı olmalı ve toplanan değişkenler birçok farklı kavramı temsil etmelidir.
Bir değişkenin bir çalışma için iyi bir uyum sağlayıp sağlamadığı genellikle da ha iyi seçeneklerin yokluğunda sorgulanmaz. Belirli bir ampirik fenomen kav ramsallaşmasını kutsayarak, popüler büyük veri setleri, sorulan soruların do ğasını şekillendirebilir.

Karşılaştırıldığında, metin olarak veri yöntemleri, akademisyenlerin k endi projeleri için özel olarak tasarlanmış devasa nicel veri setlerini kola yca oluşturmasına olanak tanıyan bir özelleştirilmiş ölçüm döneminin g elişmesine izin vermiştir. Stil açısından, bu yeni ölçüm stratejileri nicel v e nitel gelenek arasında bir yerde durmaktadır. Bize ampirik olguların si stematik, nicel özetlerini sağlarken, nitel yorumlama ve uygulamada ön emli bir dikkat gerektirir.

Birkaç odak veri kaynağına sahip olmanın avantajı, doğrulama ile ilgilidir. Büyük a raştırma ekipleri ve verileri kullanan yüzlerce akademisyen, verilerin ve ölçümlerin di kkatlice kontrol edilmesini ve doğrulanmasını sağlar. Ölçümün demokratikleşmesi

Doclingo https://www.doclingo.ai

güçlüdür, ancak bireysel analistlerin artık doğrulamaya daha fazla odakla nması gereken daha fazla sorumluluğu üstlenmelerini zorunlu kılar.

Bu bölümde, dünyanın kavramsallaştırılmasının hedeflendiği Ke şif'ten, o kavramsallaştırmayı ölçmek istediğimiz Ölçüm'e geçiyoru z. Metin analizi genellikle daha önce incelenmemiş bir şeyi ölçmek i çin kullanıldığından, genellikle sadece şeyleri saymak yeterince ilgi nçtir. Bir özelliğin veya olayın sıklığını nicelleştirebilmek, onu anla manın güçlü bir ilk adımı olabilir.

15. Bölüm: Ölçüm İlkeleri'nde, keşiften ölçüme geçişteki bazı be nzersiz hususları tanımlıyoruz.

Bölüm 16: Kelime Sayma en basit ölçüm stratejisiyle başlar: tek tek seçilen kelimeleri sayma. Bu bölüm, önceden üretilmiş kelime kol eksiyonlarını kullanan ve belirli kavramları ölçmek için onlara ağırlıklar ek leyen popüler sözlük tabanlı yaklaşımları içermektedir. Ayrıca, kelime sözl üklerinin metinlerden kendiliğinden üretildiği denetimli ölçekleme gibi b u yaklaşımın doğal bir genellemesini de keşfediyoruz.

Belgeleri önceden belirlenmiş bir kategori setine yerleştirmek için insan uz manlığından yararlanma geleneği uzundur. Bu genellikle belgeleri "kodlama" o larak adlandırılır ve onları etiketleyen insanlara "kodlayıcılar" denir. [2] İnsanlar t arafından bir belge örneği kodlandıktan sonra, kodlama sürecini otomatikleşti rmek için makine öğrenimini kullanabiliriz. Bölüm **17: Bir Genel Bakış** Denetimli Sınıflandırma bu süreçteki üç adım için bir giriş genel bakışı ve varsayılan tarif sağlar: kodlama, sınıflandırma ve doğrulama.

Takip eden bölümler (Bölüm 18: Bir Eğitim Seti Kodlama, Bölüm 19: Denetimli Öğrenme ile Belgeleri Sınıflandırma, Her bir adımı daha derinlemesine ele alır. Bölüm 21: Yeniden Kullanım Keşif Yöntemleri teknikleri yeniden gözden geçirir ve Keşif'te tartışılan ve bunların ölçüm uygulamalarının sonuçlarını açıklar.

---

[1]Bu girişin bazı bölümleri Grimmer, Roberts ve Stewart (2021)'dan alınmıştır.

[2]Bazı literatürlerde bu süreç anotasyonlar olarak adlandırılabilir (ve anotatörler tarafından yapılır). Bu, programlama anlamında kodlama ile karışıklığı önlese de, sosyal bilimlerd e daha sık gördüğümüz ifadeyi kullanmaya karar verdik.

Doclingo https://www.doclingo.ai

BÖLÜM 15

Ölçüm İlkeleri

Toplumsal ölçüm üzerine yazdığı risalede sosyolog Otis Dudley Duncanşunu gözle mlemiştir,

> Ölçüm, insanların birçok başarısından ve uygulamasından biridir ve na sıl ve neden çalıştığına dair kimsenin sormayı düşünmeden önce gelişt i ve sıradan hale geldi.
>
> (Duncan, 1984, s. 119)

Metin verisi yöntemlerinin nispeten yeni olmasının bir avantajı, ölç ümdeki varsayımlara ve dikkatli doğrulamanın önemine yeniden di kkat çekmiş olmalarıdır.

Hedefle başlıyoruz. Ölçümdeki hedef, nicelleştirmeyi kolaylaştırmak içi n hipotezimiz veya teorimiz içinde bir kavramı somutlaştırmaktır.1Bizim bakış açımıza göre, hiçbir ölçüm gözlemlenen şeyin teorik anlayışından t amamen ayrılmış olamaz. Bir şeyi ölçmek, gözlemlenebilir verilerin teorik bir kavrama nasıl dönüştürüleceği hakkında test edilebilir ve test edilem ez bir dizi varsayımı çağrıştırmaktır. Ölçüm, kavramsal argümanımız ile el imizdeki kanıt olarak mevcut veriler arasında köprü kuran hayati bir bağl antıdır.

2. Bölümde özetlediğimiz temel ilkelerimizle tutarlı olarak, tüm orta mlarda en iyi performans gösterecek tek bir ölçüm yaklaşımı yoktur. Ancak, çoğu ölçümü araştırmacı için aşağıdaki adımları içeren bir süreç olarak düşünüyoruz,

1. Ölçmek istediğimiz kavramsallaştırmayı tanımlayın.
2. Tanımlanan kavramın etkilerini içeren bir veri kaynağını bul un.
3. Verileri gizli bir temsile dönüştürmenin bir yolunu oluşturun.
4. Temsili etiketleyin ve tanımlanan kavrama bağlayın.
5. Ortaya çıkan ölçümü doğrulayın.

Keşif'te, tanımladığımız kavramları belirlemeye yardımcı olacak yöntemleri açıkladık.

Doclingo https://www.doclingo.ai

Yeni araştırma soruları veya teori için yaratıcı bir fikir ateşleyerek ölçmek istiyoruz. Bölüm 4'te, metin verisi kaynaklarını nasıl bulacağımızı ele aldık . Bu bölümde, 3-5. adımlara ve o teorinin gözlemlenebilir sonuçlarını test edecek ölçümlerin geliştirilmesine geçiyoruz. Amacımız tanım, nedensel çıkarım veya tahmin olsun, karmaşık bir dünyadan fenomenleri sistemati k olarak ölçmek için bazı araçlara ihtiyacımız olacak.

Ölçüm kaçınılmaz olarak sıkıştırmayı içerir: bir şeyi ölçerken, beli rli bir nesne hakkında çoğu bilgiyi atmayı seçiyoruz, böylece o nesn enin genelleştirilebilir bir özelliğine odaklanabiliyoruz. Bu sıkıştırm a süreci, bir belge ile ölçüm için kullanacağımız gizli temsilimiz aras ında haritalama yapan bir fonksiyon ile biçimlendirilir. Önümüzdek i birkaç bölüm, o fonksiyona ulaşmak için kullandığımız yöntemleri ve gizli temsili daha geniş araştırma sürecimize nasıl entegre ettiği mizi ele alacaktır.

Doclingo https://www.doclingo.ai

15.1 Kavramdan Ölçüme

Keşif, dünyayı anlama önerisinde bulunma, bu anlayışı verilerle sarsma ve ardından dünyayı farklı bir şekilde görene kadar revize e tme sürecidir. Nihayetinde bu yinelemeli süreç durulur ve ölçüm sü reci başlar. Pratikte, keşif ve ölçüm görevleri her zaman temiz bir ş ekilde ayrılmamaktadır; genellikle keşif kısmı hiç konuşulmadığı içi n. Bu iki ayrı aşamayı ayırarak, her birine uygun tekniklerle yaklaşa bilir ve her görev için en iyi şekilde uyum sağlayacak yeni yöntemle r tasarlayabiliriz. Keşfi ve ölçümü ayrı olarak görsek de, çoğu geniş araştırma programında bu iki aşama arasında araştırma sorusu ge liştikçe gidip gelme olacağını hayal ediyoruz.

Bir kavramı ölçmek için evrensel olarak en iyi yöntem yoktur, bu ned enle‘herkes için uygun’ bir yaklaşım sunamıyoruz. Bunun yerine, her bir i analistinbilgilerini farklı bir şekilde kullanan çok çeşitli yaklaşımları tanı mlıyoruz.

Doclingo https://www.doclingo.ai

15.2 İyi Bir Ölçüm Nedir

İyi bir ölçümün rolü, analistin bir süreci doğru bir şekilde tanımlamasına veya bir teorinin gözlemlenebilir sonuçlarını test etmesine olanak tanıyan gerçek dünya olaylarının basitleştirilmesini sağlamaktır. Hiçbir ölçüm dünyanın tüm karmaşıklığını yansıtamayacağından, iyi bir ölçümün özellikleri, analistin çözmeye çalıştığı belirli problemle içsel olarak bağlantılıdır.

Bilgisayar bilimcileri ve endüstriyel veri bilimcileri, metin analizi çabalarınıözellikle bilgi retrieval ve tahmin uygulamalarına odakla mışken, sosyal bilimcilerve dijital beşeri bilimler akademisyenleri n eredeyse tamamen metinleri ölçümmekanizması olarak kullanmay a odaklanmışlardır. Metinler, kültür (Bail, 2014*b*),politik gündemler (Grimmer, 2010), şiddetli cihat destekleme (Nielsen, 2017) ve uluslararası olaylar (Schrodt, 2012) gibi çeşitli şeyleri ölçmek için kullanılmı ştır. Sosyal bilimcilerinölçüm uygulamalarına odaklanması şaşırtıcı değildir, çünkü sosyal bilimlerdehem manuel içerik analizi (Krippendorff, 2012; Neuendorf, 2016) ve ölçüm daha geniş anlamda (Stevens, 1946; Thurstone, 1954). Aslında, ilk bilgisayar destekli içerik analizi (bildiğimiz kadarıyla) Sebeok ve Zeps (1958) tarafından yapılmış olup, masalları analiz etmiştir. Hedefteki ince far klılıklar da önemlidir. Daha sonra gireceğimiz gibi, hangi e-postaların spam oldu ğunu tahmin edebilen bir model, e-postalarınızın ne kadarının spam olduğunu öl çmede iyi bir iş çıkaramayabilir. Saman yığını metaforuna tekrar dönecek olursak , bazı insanlar samanın bir ipini bulmak isterken, diğerleri saman yığınını tanımla mak istemektedir. Ölçüm, analistin ölçümün ne olduğunu tanımlamasını ve araşt ırma sürecindeki rolünü gerekçelendirmesini gerektiren ağır talepler de getirir.

Ölçümlerimizde ulaşmayı hedeflediğimiz özelliklerin bir ifadesiyle başlamak f aydalı olacaktır. Bu beş özellik, herhangi bir makalede veya projede tam olarak k arşılanamayabilecek zorlu bir kriter setini oluşturmaktadır.

15.2.1 İLKELER 1: ÖLÇÜMLER AÇIK HEDEFLERE SAHİP OLMALIDIR

Bir ölçüm, orijinal kaynak materyalin bir azaltılmasıdır. Orijinal kaynak hak kında korunacak evrensel olarak doğru veya yanlış bir bilgi yoktur ve bu ned enle bir ölçüm, dünyayı neyi yakalamaya çalıştığına dair açık bir hedefe sahip olmalıdır. Bu, ölçümün net bir kapsamı ve amacı olduğu anlamına gelir, bu d a başlangıçtaki analizde doğru bir şekilde kullanılmasını sağlamaya yardımcı olur ve gelecekteki akademisyenler tarafından yanlış kullanılma olasılığını az altır. Mümkün olduğunda, bu ifade, alandaki uzman olmayan kişiler tarafınd an açıkça anlaşılabilir şekilde yeterince basit olmalıdır.

Doclingo https://www.doclingo.ai

15.2.2 İLKEL 2: KAYNAK MALZEME HER ZAMAN TANIMLANMALI VE İDEAL OLARAK HALKA AÇIK YAPILMALIDIR

Metinlerin, üretildiği bağlamın özelliklerine duyarlı olan farklı anlamları vardır. Ölçümün anlamını net bir şekilde iletmek için, orijinal malzemenin kaynağı her zaman açıkça belirtilmelidir. Her zaman mümkün olmasa da, kaynak metinlerin halka açık hale getirilmesi hem gelecekteki çalışmaları kolaylaştırır hem de ölçümün bağımsız olarak doğrulanmasına olanak tanır.

15.2.3 İLKEL 3: KODLAMA SÜRECİ AÇIKLANABİLİR VE TEKRARLANABİLİR OLMALIDIR

Bilimsel bir ölçüm olarak kullanılabilmesi için, araştırmacının ölçümün nasıl oluşturulduğunu anlaması gerekir. Bu birçok farklı biçimde olabilir, ancak ilke olarak okuyucuya, ham girdi belgeleri verildiğinde, elde edilen ölçümün yeniden yapılandırılabilmesi için yeterli talimatlar sağlanmalıdır. İnsan anotatörleri durumunda, bu genellikle kodlama sistemini uygulayan çalışanlar için net prosedürler tanımlayan kapsamlı bir kod kitabının yayımlanmasını içerir. Bilgisayar destekli görevler için ise, etiketlemeyi üretmek için kullanılan model veya yazılımın tam bir tanımını içerir. “Açıklanabilir” özelliği, bu materyallerin mümkün olan en geniş kitle tarafından anlaşılmasını gerektirir.Bizim görüşümüze göre, bir ölçüm, nasıl üretildiğini bilmediğimiz sürece bilimin bir parçası olamaz. Belki de açıkça tartışmalı olmamakla birlikte, bu, birçok hazır siyah kutu ölçüm stratejisinin kullanımını reddeder.

15.2.4 İLKEL 4: ÖLÇÜM DOĞRULANMALIDIR

Ölçüm stratejisinin doğruluğu, geliştirildiği veriler dışında başka verilerle doğrulanmalıdır.Ölçümler, geniş bir kitle tarafından anlaşılabilir olacak şekilde de seçilmelidir. Bir fenomenin gerçekten nasıl ölçüldüğü ile amaçlanan kavram arasında her zaman bir kavramsal boşluk vardır. Ancak, bu boşluk mümkün olduğunca küçük olmalıdır. Doğrulama, okuyuculara ve araştırmacılara, ölçümün ölçmeyi iddia ettiği teorik kavrama iyi bir şekilde eşleştiğini kanıtlamak sürecidir.

15.2.5 İLKEL 5: SINIRLAR ARAŞTIRILMALI, DOKÜMANTE EDİLMELİ VE KİTLEYE İLETİLMELİDİR

Bir derece ölçüm hatası kaçınılmazdır—ancak ölçüm hatasının sonuçları, ölçümü nasıl kullanmayı planladığımızla yakından ilişkilidir.

Doclingo https://www.doclingo.ai

araştırma. Bu nedenle, analistlerin ölçümün ne zaman iyi performans gösterdiğini ve n e zaman göstermediğini tanımlayıp açıklamaları kritik öneme sahiptir. Bu, okuyucuların ve ölçümlerimizin kullanıcılarının beklentilerini uygun şekilde ayarlamalarına olanak ta nır. Örneğin, bazı ölçümler, olası değerlerinin tüm aralığında iyi ayrım yaparken, diğerle ri yalnızca uçlarda veya ortada en iyi performansı gösterir. Ölçümler ayrıca gruplar aras ında farklı hata oranlarıyla performans gösterebilir, bu da adalet açısından önemli sonu çlar doğurur (Jacobs ve Wallach, 2021). Ölçümümüzün kapsam koşullarını tanımlamak, doğru bir şekilde kullanılmasını ve yorumlanmasını sağlamaya yardımcı olur.[2]

Doğal ve sosyal bilimlerde ölçüm teorisi üzerine önemli bir literatür bulunmaktadır. Bu alanların çoğuna kıyasla, veri olarak metin henüz emekleme aşamasındadır. Bu bölümde bilim felsefesi, psikometri ve d iğer ölçüm geleneklerinden elde edilen içgörülerden yararlanırken, ni cel metin analizi uygularken birçok benzersiz ölçüm zorluğu vardır. Bu önceki geleneklerin büyük içgörüleri bir boşlukta üretilmemiştir; aks ine, alanın erken gelişiminde deneme yanılma yoluyla üretilen en iyi pr osedürlerin rasyonelleştirilmesi ve kodifikasyonuydu (Duncan, 1984). Öl çümün tam bir teorisi bu çalışmanın kapsamının ötesindedir, ancak ken di deneme yanılma sürecimizin sonuçlarından elde ettiğimiz en iyi rehb erliği sunuyoruz.

Doclingo https://www.doclingo.ai

15.3 Keşif ve Ölçümün ÖrnekBölümleri ile Dengelemesi

Konseptualizasyonu ve ölçümü aynı anda ifade etmenin zor olduğun u söylemek gerekir. Sonuçta insanlar insandır ve önyargılarımızın veya teorik beklentilerimizin ölçüm veya yorumlamaya sızmasına izin verme kten endişe edebiliriz. Bu tür öznel ölçüm hatalarıyla ilgili endişeler, mü lakatçıların bazen bir konu hakkında ana beklentilere kör olarak gönder ilmesinin veya kodlayıcıların kodlama yaparken sonuçları görmemesini n nedenidir. Metindeki bir özelliğin ölçümünü oluşturmak istiyorsak, ölç ümümüzün metnin dışındaki bir şeyden ne ölçüde etkilendiğini en aza i ndirmek isteriz.

Bu tür ölçüm hatalarını önlemek için yöntemleri tanımlarken, King, Keohane v e Verba (1994) şunları tavsiye eder:

> Bu durumlarda tavsiyemiz, öncelikle, tamamen farklı amaçlar için diğ er araştırmacılar tarafından yapılan yargıları kullanmaya çalışmaktır. Nitel veya nicel ölçümdeki bu keyfiliğin unsuru, ölçümün hipotezlerin izden etkilenmeyeceğini garanti eder; bu hipotezlerin muhtemelen d aha sonra oluşturulmuş olması gerekir. Eğer bir dizi değişkeni kullan an ilk kişiyseniz, diğer bilgili kişilerin, değerlendirmek istediğiniz ilişki hakkındaki teorinizi bilmeden değişkenlerinizi kodlaması faydalı olac aktır.
>
> (King, Keohane, ve Verba, 1994, s. 156)

Metin analizinde kullanmak istediğimiz ölçütler genellikle mevcut değildir,bu nedenle kodlamayı diğer sonuçlardan veya kovaryatlardan ayırmak faydalıdı r. Bu sorunu ele almanın bir yolu, verilerin bir örneği üzerinde ölçütü geliştir erek “eğitim verisi” oluşturmak ve ardından “test verisi” üzerindeki ölçüt son uçlarını raporlamaktır.

Ölçütü eğitim setinde geliştirip ardından test setinde uygulayara k, belirli türde aşırı uyumdan kendimizi koruyabiliriz. Örnek bölmel eri, nedensel çıkarım tartışmamızda da merkezi bir rol oynayacak, ancak burada ölçümlerimizi doğrulamak için faydalıdırlar.

---

[1]Doğal bir temel, ölçümü bazı kurallar setine göre nesnelere sayısal değerle r atama olarak tanımlayan Stevens (1946) tarafından sağlanmaktadır. Sosyolo g Otis Dudley Duncan, Stevens tanımını,

Doclingo https://www.doclingo.ai

“piyanoyu çalmak, enstrümanın tuşlarına bir desene göre vurmak” şeklinde tanımlayarak (Du ncan, 1984, s. 126) eksik olarak tanımlamaktadır çünkü Stevens, ölçümün bir nesnenin sahip olduğu bir niteliğin derecesini ifade etmek için değerler atama fikrini açıkça içermemektedir. Bu daha amaç odaklı ölçüm görüşünü takip ediyoruz, ancak nihayetinde sınıflandırmayı da i çeren biraz daha geniş bir tanımı onaylıyoruz.

[2]Tahmin edici bir modelin amacını ve sınırlamalarını belgelemek için yararlı bir şablon için (ölçüm için kullanılanlar dahil) Mitchell ve diğerleri (2019) ile bakın.

Doclingo https://www.doclingo.ai

BÖLÜM 16

Kelimeleri Sayma

Bu kitabın ölçümle ilgili bölümü, metinleri bilinen kategorilere etiketlemeye odak lanacaktır. Bölüm 18, metinleri etiketleme için farklı yaklaşımları veya metinleri bir kod kitabına dayalı olarak kategorilere nasıl yerleştireceğinizi tanımlar. Bölü m 19, bu etiketlenmiş belge setini, belgeleri kategorilere otomatik olarak yerleşti recek bir model geliştirmek için eğitim verisi olarak nasıl kullanacağınızı açıklar. Bu çerçevede, istatistiksel model, metnin temsili olan W ile metnin k ategorileri olan y arasında sağlanan eşlemeyi öğrenmek için eğitim verilerini kullanır.

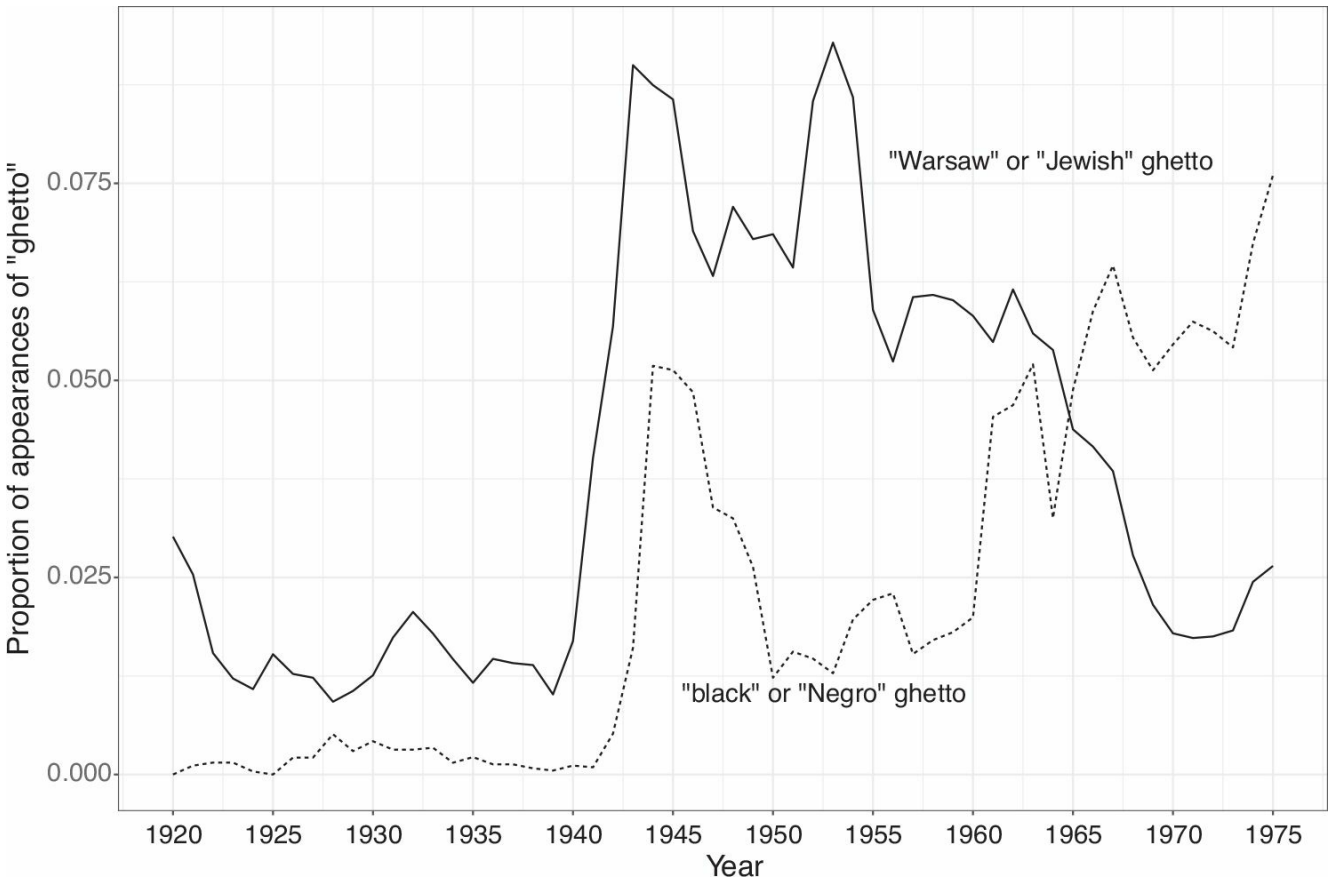
Ancak denetimli öğrenme sürecini tanımlamadan önce, insanın metinler içindek i kelimeleri etiketlediği daha basit bir yöntemler grubunu ele alıyoruz, belgelerin k endilerini değil. Metin gruplarını bilinen kategorilere yerleştirmek yerine ve ardınd an bu kategorilerin özelliklerle nasıl ilişkili olduğunu öğrenmek için bir model kulla nmak yerine, araştırmacılar doğrudan bir dizi insan tarafından üretilen kuralları kul lanarak eşleme fonksiyonunu yazarlar. İnsan tarafından üretilen kuralların en tem el olanları anahtar kelime veya sözlük tabanlı yöntemlerdir. Bu yöntemlerin temeli nde, insan tarafından üretilen kurallar bir belge setine uygulandığında, metin seviy esinde metnin kategorisini doğru bir şekilde yansıtan bir etiket üreteceği varsayımı yatmaktadır. Bu bölümde, önce bu yöntemleri tartışacağız, ardından doğrulamala rı ve potansiyel tuzakları ele alacağız.

Doclingo https://www.doclingo.ai

16.1 Anahtar Kelime Sayımı

Sözlük yaklaşımının en basit versiyonu, belirli bir kelime veya ifade nin örneklerini saymaktır. Bazen bu tür temel sayımlar, belirli bir kavr amın veya fikrin evrimi hakkında kanıt sağlayabilir.

Anahtar kelime sayımının avantajı, açık ve iletmesi kolay olmasıd ır. Bir grup gazete makalemiz olduğunu ve ABD başkanlık siyasetin e olan ilgiyi ölçmek istediğimizi hayal edin. Başkan kelimesini en az bir kez kullanan makale sayısını sayabiliriz. Ancak, örneğin başkan kelimesini saymanın, başkanlık siyaseti hakkında bir tartışmanın ke sin bir ölçüsü olduğu net değildir; şirketler, diğer ülkeler, üniversit eler ve her türlü organizasyonun başkanları vardır. Bunun yerine, White House ifadesinin örneklerini saymak için biraz daha karmaşı k bir seçeneği tercih edebiliriz. Bu, daha az yanlış pozitif üretme av antajına sahiptir (elbette, beyaz olan başka evler de vardır), ancak başkanlık siyaseti hakkında birçok makale White House ifadesini iç ermeyebilir. Kelimeleri saymak mekanik olarak basit olsa da, karm aşık örtük kavramları pratikte doğru bir şekilde temsil etmek zordu r.Yine de, sayılan kelimeler dikkatlice değerlendirildiğinde ve sonuç lar dikkatli bir okuma ile doğrulandığında, anahtar kelime sayımı s on derece etkili olabilir.



Doclingo https://www.doclingo.ai

Şekil 16.1. Duneier (2016) tarafından hazırlanan, "ghetto" kelimesinin iki kullanımını işar et eden kelimeler bağlamında kullanım oranını gösteren Grafik 1. Veriler Google Ngram s'tan alınmıştır.

Duneier (2016), kitabı Ghetto: The Invention of a Place, the Histo ry of an Idea'da, "ghetto" kelimesinin kökenini on altıncı yüzyıl Ven edik'inden başlayarak, Avrupa'daki Nazi gettoları üzerinden günü müzdeki Afrika Amerikalıların ayrımcılığı ile olan bağlantısına kada r izlemektedir. Duneier (2016)'in ödüllü kitabının çoğu detaylı bir ta rihsel anlatım olsa da, Nazi gettoları ile olan ilişkiyi yükseliş ve ardı ndan Afrika Amerikalıların konut ayrımcılığı ile olan bağlantının on u geçişini gösteren tek bir grafik sunmaktadır. Şekil 16.1, "ghetto" kelimesinin iki anlamını örnekleyen dört ifadeyi aramak için 800,00 0'den fazla kitabı incelemek üzere Google Ngrams'ı kullanmaktadır . Varşova Gettosu ve Yahudi Gettosu, 1940'ta Avrupa'daki Yahudile rin Nazi tarafından gettolaştırılmasına dair haberlerin yayılmasıyla hızla artmaya başladı. Bu kullanımı, Kuzey ABD şehirlerinde Afrika Amerikalıların konut ayrımcılığına atıfta bulunmak için en yaygın if adeler olan Siyah Getto ve Negrolu Getto izledi.

Duneier, bu değişen getto fikrinin ilişkisinin bir tesadüf olmadığı nı savunuyor. 1945'te, iki Afrikalı Amerikalı sosyolog, Horace R. Cayton ve St. Clair Drake, *Black Metropolis* adlı eserlerini yayımladı ve Chic ago ve diğer ABD şehirlerinde Siyah insanların ayrımcılığını sürdüren zorla yıcı konut politikalarına dikkat çekmek için Siyah Getto fikrini öne sürdü. Ca yton ve Drake, getto kelimesinin Nazi'nin Yahudilere uyguladığı baskı ile ol an ilişkisini kullanarak Amerika'nın Siyah nüfusuna yönelik muamelesinin i kiyüzlülüğünü vurguladılar. Bu, Amerika'nın kendi şehirlerindeki ırksal bas kının farkında olması için ahlaki bir zorunluluğu vurgulamaya yardımcı old u; o sırada Amerika, yurtdışında farklı bir tür ırksal baskıyla savaşıyordu. D uneier (2016), 1940'ların başında Siyah basının Siyah Getto'ya atıf yapması ndaki artışı tanımlıyor, grafikteki eğilim çizgisini oluşturan birçok bireysel k itaptan alıntılar yapıyor ve okuyor.

Bu değişimin zamanlaması, getto teriminin Amerikan şehirlerinin bazı böl geleriyle ilişkilendirilmesinin esasen Nazi'nin terimi kullanmasından kaynakl andığını gösteriyor. Duneier (2016), ABD şehirlerinde Siyah nüfusun konut ay rımcılığını sürdüren kısıtlayıcı sözleşmelerin 1928'de başladığını vurguluyor. Yine de, o, “Siyah geto” teriminin yükselişini, Nazi kontrolündeki Avrupa'n ın Yahudi getosuna atıfta bulunulmasından çok daha sonra gördüğümüz ü savunuyor. Duneier (2016), bu fikirlerin nasıl ortaya çıktığını araştırarak bu noktayı daha da pekiştiriyor ve yazıyor,

Doclingo https://www.doclingo.ai

> Drake ve Cayton, getoyu hem ayrımcılığın hem de Kafkas saflığının bir metaforu olarak Nazi döneminde gördüler ve bu anlamda kelimenin kullanımı tarihi anla özeldi.
>
> Orta sınıf siyahilerin dışarı çıkmaya çalıştıklarından bahseden Drake ve Cayton, "Onlar yavaş yavaş Siyah Kuşak içinde güney yönüne doğru sü zülüyorlar. Ancak her zaman, kısıtlayıcı sözleşmelerin görünmez *diken li tel* çitine çarpıyorlar" [vurgulama bana ait]. Dikenli tel, onaltıncı yüzyıl Venedik'inde icat edilen bir şeyden ziyade Nazi getolarının bir sembol üydü.
>
> (Duneier, 2016, s. 71-72)

Diğer bir deyişle, Duneier, geto kelimesinin çağrışımının değiştiğini—grafikten açıkça görülebilen bir şey—ve geto teriminin Siyah konut ayrımcılığını tanımlamak için kullanılmasının Nazi döneminde bu kelimenin benimsenmesiyle bağlantılı olduğunu savunuyor.

Duneier'in kitabı, basit nicel analizin nasıl detaylı ve incelikli tarihsel sosyolojiye faydalı bir tamamlayıcı olabileceğinin güçlü bir örneğidir. Duneier (2016), metnin çok basit bir sayısal temsilini—dört basit ifadenin sayımını—seçiyor; ancak bu temsili, temel kaynakların kapsamlı okunmasıyla bir arada kullanarak, tek başına her bir kanıt kaynağından daha ikna edici bir argüman oluşturabiliyor. Duneier (2016)'nin ek kanıt kullanımı, argümanın güvenilirliği için esastır. Tek başına kullanıldığında, anahtar kelime sayımları nihayetinde daha az ikna edici olabilir. Ghetto kelimesinin toplam kullanımları, Şekil 16.1'de izlenen dört bigramdaki kullanımlardan çok daha fazladır. Ayrıca, Pechenick, Danforth ve Dodds (2015) tarafından belirtildiği gibi, Google Ngrams korpusunu bir ifadenin zaman içindeki popülaritesi hakkında çıkarımlar yapmak için kullanmanın sınırlamaları vardır; çünkü veritabanını oluşturan kaynakların bileşimi değişmektedir. Ancak, daha zengin bir nitel analiz bağlamında, Şekil 16.1'deki gibi basit bir grafik, yalnızca noktanın güçlü bir görsel gösterimini sağlamakla kalmaz, aynı zamanda kapsamlı manuel analizi de güçlendirmeye yardımcı olur.

Doclingo https://www.doclingo.ai

16.2 Sözlük Yöntemleri

Sözlükler, anahtar kelime sayımının bir genellemesidir—bir metinde anah tar kelimelerin görünme oranının ağırlıklı ortalamasını kullanarak belgeleri k ategorilere ayırmak veya belgelerin belirli kategorilere ne ölçüde ait olduğun u ölçmek için kullanılır.Örneğin, hedefin gazete makalelerindeki tonu ölçmek olduğunu varsayalım (örneğin, Eshbaugh-Soha 2010): makalelerin bilgiyi olu mlu veya olumsuz bir şekilde iletip iletmediği. Sözlük yöntemleri, ekli ton pua nları olan bir kelime listesi ve kelimelerin ortaya çıkma oranını kullanarak bir belgenin tonunu ölçer. Tonu ölçmek için bir sözlük, ya olumlu ya da olumsuz olarak ikili bir şekilde sınıflandırılan ya da içeriklerinin daha sürekli ölçümleri ni içeren kelimelerin bir listesidir. Resmi olarak, her kelime j için ilişkili puan μ_j olacaktır. En basit ölçümler için, $\mu_j = -1$ eğer kelime olumsuz bir ton ile iliş kilendirilmişse ve $\mu_j = 1$ eğer olumlu bir ton ile ilişkilendirilmişse.
Eğer $M_i = \sum_{j=1}^{J} W_{ij}$ kelimeleri belge *i*'de kullanılıyorsa, o zaman sözlük yöntemler i herhangi bir belgenin tonunu π_i olarak ölçebilir,

$$\pi_i = \sum_{j=1}^{J} \mu_j W_{ij} M_i .$$

Akademisyenler genellikle π_i'yi belge tonunun yaklaşık sürekli bir ölçüsü olara k kullanır, ancak aynı zamanda bir karar kuralı varsayıldığında belgeleri ton kat egorilerine sınıflandırmak için de kullanılabilir. Belki de en basit kodlama kuralı , $\pi_i > 0$ olan tüm belgeleri olumlu ton kategorisine ve $\pi_i < 0$ olanları olumsuz t on kategorisine atamak olacaktır.

Ton, bir sözlük yönteminin gerçekleştirebileceği sadece bir analiz türüdür. Sözlüklerin genel fikri, onları çeşitli sorunlar üzerinde uygulamak için nispet en kolay ve ucuz hale getirir: önce, kategorileri ayıran bir kelime seti belirleyi n ve ardından bu kelimelerin metinlerde ne sıklıkla geçtiğini ölçün (çeşitli kav ramları ölçmek için sözlükleri kullanan bazı örnekler için Kellstedt'e bakın. 2000; Burden ve Sanberg 2003; Laver ve Garry 2000; Young ve Soroka 2012). Burada, araştırmacılar kendi uzmanlıkları aracılığıyla kendi sözlüklerin i oluşturabilir veya mevcut bir sözlük bulabilirler. Farklı kategoriler için anaht ar kelimeler sağlayan çeşitli yaygın olarak kullanılan hazır sözlükler bulunma ktadır (örneğin, Bradley ve Lang 1999; Hart 2000; Pennebaker, Francis ve Bo oth 2001; Turney ve Littman 2003).

Akademisyenlerin mevcut bir sözlüğü yoksa, ancak belgeleri zaten kategoriler e kodlanmışsa, mevcut yöntemleri kullanarak sözlükler üretilebilir. Bunları Bölü m 11'de açıkladık. Monroe, Colaresi ve Quinn (2008), kelimelerin zaten tanımlan mış olanları ne kadar iyi ayırdığını ölçen çeşitli yöntemleri tanımlamaktadır.

Doclingo https://www.doclingo.ai

ilgi alanları (bkz. ayrıca Taddy (2013) ve Diermeier ve diğ. (2012)). Bu yöntemlerden h erhangi biri, kelimelerin sözlük benzeri puanlarını üretmek için kullanılabilir ve bu pu anlar daha sonra belgeleri sınıflandırmak için diğer bağlamlarda uygulanabilir.

Doclingo https://www.doclingo.ai

16.3 Sözlük Yöntemlerinin Sınırlamaları ve Doğrulamaları

Sözlük yöntemlerinin iyi çalışabilmesi için, kelimelere eklenen puanla rın belirli bir bağlamda kelimelerin nasıl kullanıldığıyla yakından örtüşm esi gerekir. Eğer bir sözlük belirli bir uygulama için geliştirilmişse, bu va rsayım kolayca haklı çıkarılabilir (ancak Barberá ve diğ. (2021) görev od aklı sözlüklerin bile denetimli öğrenmede yetersiz kalabileceğini bulma ktadır). Ancak sözlükler bir alanda oluşturulup başka bir alanda uygula ndığında ciddi hatalar meydana gelebilir. Bunun en net örneği Loughra n ve McDonald (2011) tarafından gösterilmektedir. Loughran ve McDon ald (2011), muhasebe literatüründe yasal olarak gerekli olan kurumsal k azanç raporlarının tonunu ölçmek için hazır sözlüklerin giderek daha ya ygın kullanımını eleştirmektedir. Diğer bağlamlarda olumsuz bir çağrışı mı olan birçok kelimenin, vergi, maliyet, ham (petrol) veya kanser gibi, k azanç raporlarında olumlu bir çağrışımı olabileceğini belirtmektedirler. Örneğin, bir sağlık şirketi kanseri sıkça anabilir ve petrol şirketlerinin ha m petrolü kapsamlı bir şekilde tartışması muhtemeldir.Ve hazır sözlükle rde olumsuz olarak tanımlanmayan kelimelerin, kazanç raporlarında ol dukça olumsuz bir çağrışımı olabilir (örneğin, beklenmedik).

Sözlükler, bu nedenle, önemli bir dikkatle kullanılmalı ve kesinlikle açık bir doğrulama ile birlikte olmalıdır. Sözlükler uygulanırken, akademisyenle r, diğer bağlamlarda oluşturulan kelime listelerinin kendi ortamlarına uygu lanabilir olduğunu doğrudan belirlemeli veya alanına özgü bir sözlük oluşt urmalıdır. Araştırmacılar ayrıca, oluşturdukları sözlüklerin belgelerde kelim elerin nasıl kullanıldığıyla uyumlu olmayabileceğinin farkında olmalıdır ve bu nedenle uygulamaya ve bağlama dikkat etmelidir. Her iki durumda da, akademisyenler sonuçlarını doğrulamalıdır. Örneğin, araştırmacılar, sözlüğ ün sınıflandırmak için kullanıldığı belgelerin bir örneği için elle etiketler üre tmelidir. Ardından, sözlük tarafından üretilen toplam ölçümü elle etiketlen miş doğrulama seti ile karşılaştırmalıdır.

Önemli olarak, sözlüklerin doğrulaması, sözlüğün oluşturulduğu verilerden farklı verilerde gerçekleştirilmelidir. Eğer doğrulamadan sonra araştırmacılar s özlüğü değiştirmeye karar verirlerse, o zaman aynı verilerde sözlüğü tekrar do ğrulayamazlar. Bunu yapmak, araştırmacıların doğrulama setinde gördüklerin e dayanarak sözlük için kelimeleri seçmeleri durumunda aşırı uyum riski taşır; bu, genelleştirilemeyen bir eşleştirme olabilir. Doğruluğu sağlamak için, revize edilmiş sözlüğün doğrulaması yeni bir taze veri setinde gerçekleştirilmelidir.

Uygulamada, sözlüklerden alınan ölçümlerin nadiren doğrulandığı görülmektedir. Daha ziyade, sözlükler in kullanımında standart uygulama, oluşturulan ölçümlerin doğru olduğu varsayımına dayanmaktadır.

Doclingo https://www.doclingo.ai

bir sözlüğün doğru olduğunu varsaymak ve ardından bunları probleme uygulamak. Alan özgüllüğünün ve doğrulama eksikliğinin sonucu, sözlüklere dayanan birçok analizin sarsıntılı temeller üzerine inşa edilmesidir. Sorun, sözlüklerin belirli özelliklere sahip bir ölçüm üretmemesidir. Doğru ağırlıklandırılacak özellikleri seçtiğimiz varsayılsa bile, temel soru, ağırlıklarda üretilen varyasyonların ölçülen miktardaki temel farklılıkları temsil edip etmediği veya sadece gürültü mü eklediğidir. Bu nedenle, bu yöntemlerle, durum spesifik doğrulamanın son derece önemli olduğunu düşünüyoruz.

16.3.1 SÖZLÜKLERİN ÖTESİNE GEÇMEK: KELİME PUANLARI

Wordscores algoritması, Laver, Benoit ve Garry (2003) tarafından, siyasi bilimde metni veri olarak kullanmada gerçek bir atılımı temsil etmektedir. Sosyal bilimlerde büyük ölçekli metin analizini kullanan ilk makalelerden biri olan Laver, Benoit ve Garry (2003), aktörleri ideolojik bir alanda yerleştirmek için yazılı kelimelerini kullanarak bir yöntem tanıtmaktadır. Manuel kodlama veya doğrulaması zor olan sözlük yöntemlerine güvenmek yerine, Laver, Benoit ve Garry (2003), örnek metinlere dayalı olarak siyasi aktörleri ölçeklendirmek için tamamen otomatik bir yöntem tanıtmıştır, *wordscores*. Kendi sözleriyle, “siyasi metinlerden maddi politika pozisyonları hakkında bilgi çıkarmak için bir İngilizce sözlük tasarlama prosedürü” geliştirmeyi amaçlamışlardır, kelimeler ve kategoriler arasında doğrudan ilişkiler varsaymadan (Laver, Benoit ve Garry, 2003, s. 626). Bu yöntemi, kelime sayımı ve sözlükleri de

netimli öğrenme ile birleştiren bir yol olarak açıklıyoruz; bu, önümüzdeki üç bölümde odaklanacağımız konudur.

Wordscores'un amacı, belirli bir metin belgesi için bir ideoloji ölçüsü bulmaktır; bu, Bölüm 14'te tanımladığımızın denetimli bir versiyonudur. Bunu yapmak için, ideolojik bir alan tanımlamak üzere bir dizi örnek metin kullanır ve ardından belgeleri örnek metinleri ayırt eden özelliklere göre puanlar. İlk adım, alan içindeki siyasi pozisyonları tanımlayan referans metinlerin seçilmesidir. En basit örnekte, liberallerin ve muhafazakârların spektrumun uçlarını tanımlamak için iki metin seçebiliriz. Örneğin, ABD senatörlerini konuşmalarına göre ölçeklendirmek istiyorsak, çok liberal bir senatör olan Ron Wyden (D-OR) veya Barbara Boxer (D-CA) gibi birinin tüm konuşmalarını referans metin olarak tanımlayabiliriz ve çok muhafazakâr bir senatör olan Tom Coburn (R-OK) veya Jim DeMint (R-OK) gibi birini de. Referans (eğitim) metinleri, her kelime için bir puan oluşturmak üzere kullanılır. Puan, her kelimenin referans metinlerde ne kadar sıklıkla kullanıldığını ölçer. Bu, kelimenin liberal ve muhafazakâr üyeleri ne kadar iyi ayırdığını ölçen bir ölçü oluşturur—bir kelimenin *liberal*

Doclingo https://www.doclingo.ai

yoksa *muhafazakâr* olup olmadığını belirlemenin bir ölçüsü. Kelime puanları daha sonra kalan metinleri ölçeklendirmek için kullanılır.

Laver, Benoit ve Garry (2003) bunlara *virgin* metinler diyor, ancak denet imliöğrenmede bu metinlere *test set* deriz. Belgeleri kelime puanlarını kullanarak ölçeklendirmek için,öncelikle Laver, Benoit ve Garry (2003) h er bir test belgesinde kelimelerin kullanımoranını hesaplar. Metinlerin k onumu, bir metindeki kelimelerin kelime puanlarının ağırlıklıortalaması nı alarak belirlenir; burada ağırlıklar kelimelerin kullanım oranı ile verili r.

Kelimeler puanları zengin ve çok boyutlu hale getirilebilir ve birkaç referansmetni içerebilir. Ancak kelime puanlarının yönleri yöntemi kısı tlar ve genel kullanım içinönerilmesini zorlaştırır (uzun bir eleştiri için Lowe (2008) bakınız). “Liberal” ve“muhafazakâr” terimlerini yalnızca uç ları gösteren referans metinleri kullanarak tanımlayarak,Laver, Benoit ve Garry (2003) ideolojik dili yazarlar arasındaki stilistik farklılıklarlabi rleştirir ve metinler üzerinde ideolojik üstünlük varsayımını dayatır. So nuç olarak,kelime puanlarının her kullanımı, kullanılan referans metin lerine güçlü bir şekilde bağlıdır,bir kısmı yazarlar arasındaki stilistik fa rklılıklardan ve bir kısmı da referans metinlerininideolojik olmayan içe riği tartışmasından kaynaklanmaktadır. Metinlerin dikkatli bir şekildeö n işlenmesi, yalnızca stilistik olma olasılığı yüksek kelimeleri kaldırarak bu sorununbir kısmını hafifletebilir. Örneğin, Beauchamp (2011) tekni k dili kaldırmanın,sonuçların önemli ölçüde iyileştiğini göstermektedir ; bu, daha çok parti gücüyle örtüşmektedirve ideolojiyle değil.

Doclingo https://www.doclingo.ai

16.4 Sonuç

Bu bölümde, en basit denetim biçimi olan kelime sayımını ele aldık. İn sanların kelimeleri kategorilere yerleştirdiği ve ardından bu kelimelerin k ombinasyonlarını kullanarak belgeleri ölçeklendirdiği veya kategorize etti ği ölçüm için sözlüklerin kullanımını tartıştık. Daha sonra, iki uç noktayı ta nımlayan "örnek" belgeler temelinde bir sözlük üreten Wordscores algori tmasının bir uzantısını ele aldık. Bu yaklaşımlar basit ve anlaşılır olsa da, doğruluk açısından birkaç dezavantaja da sahiptir. Bir sonraki bölümde, kelime düzeyinde değil, belge düzeyinde insan denetimi ekleyerek sözlük yaklaşımlarının birçok dezavantajını ele alan denetimli öğrenmeyi tartışı yoruz. Ne yazık ki, bu aynı zamanda çaba ve zaman açısından önemli bir artış gerektirir; ancak bu çabanın genellikle yatırım yapmaya değer olduğ unu düşünüyoruz.

---

[1] Bu bölümdeki sözlük yöntemleri ile ilgili kısım Grimmer ve Stewart (2013)'den alınmıştır.

Doclingo https://www.doclingo.ai

BÖLÜM 17

Denetimli Sınıflandırmaya Ge nel Bakış

Bu bölüm, denetimli sınıflandırma kullanarak ölçüm otomasyonu için varsayılan bir tarif sunmaktadır. Denetimli sınıflandırma, belgeleri kategorilere etiketleyerek bir istatistiks el model (bazen "sınıflandırıcı" olarak adlandırılır) oluşturmak için bir dizi belge kullanır ve bu model, belgelerdeki kelimeleri etiketlerle ilişkilendirir ve bu modeli, aksi takdirde etiketlenmemiş belgeler için karşılaştırılabilir etiketler elde etmek üzere uygular.
Denetimli sınıflandırmanın tüm sürecine genel bir bakış sunuyoruz—bir eğitim setinin etiketlenmesinden, bir modelin eğitilmesine, sonuçların doğrulanması na kadar. Sonraki üç bölümde, bu üç bileşenin her birine daha derinlemesine d alıyoruz.

Denetimli sınıflandırmada, amaç, belge setindeki özellikler ile ar aştırmacı tarafından tanımlanan daha genel kategoriler ve kavraml ar arasında bir eşleme oluşturmaktır. Şu ana kadar, bir eşleme fon ksiyonu tanımlamak için iki önemli senaryoyu ele aldık: analistin bi r belirli kelimeyi ilgi ölçüsü için bir vekil olarak seçip saydığı durum ve eşleme fonksiyonunun araştırmacı tarafından bir sözlükle açıkç a tanımlandığı ikinci durum. Denetimli sınıflandırmada, bir algorit mayı eğiterek verilerden ilgi kategorisini metinden tahmin etmeyi öğreniyoruz ve kodlanmış belgelerden bir örnek kullanıyoruz. Mod elimizi, belge i \için tahminimiz y i 'nin bir fonksiyon f μ (W i ,) tara fından üretildiği şekilde tanımlıyoruz; burada W i , belge temsili ve μ \modelin parametreleridir. Daha sonra modelin parametrelerini, giriş *W* ve çıkış *y* (eğitim örnekleri olarak adlandırılır) rastgele örn eklerini gözlemleyerek öğreniyoruz.Bu, esasen ölçüm problemini b ir tahmin görevi haline getirir ve analistin kendisine atayacağı etik eti tahmin etmek için istatistiksel modellerden yararlanır. Bu yaklaş ım oldukça genel olup, modelin parametreleri öğrenildiğinde, ek b elgeleri sınıflandırmanın esa
sen maliyetsiz olma avantajına sahiptir.

Bu yaklaşımda, insan üç bilgi kaynağını sağlamaktan sorumludur: eğitim belgeleri için etiketler, girdinin temsili ve öğrenilecek modelin sınıfı. Etiketlerin olması genellikle analisti n zaten bir kodlama şeması ve kafasında bir eşleme fonksiyonu geliştirdiğini ima eder.

Doclingo https://www.doclingo.ai

Şu anda analistin eğitim belgeleri örneğini rastgele seçtiğini ve seçilen belgelere etiketleri mükemmel bir doğrulukla atadığını varsayıyoruz.

İkinci adım, girdinin özellik temsili. Bu, sürecin önemli ve yeterince takdir edilmeyen bir parçasıdır. Seçilen temsil, analistin meşgul olduğu görev türüyle eşleşmelidir. Bu bölüm boyunca tekrarlayan bir tema, etiket y'yi tahmin etmek için kullandığımız özelliklerin, model sınıfından çok daha önemli olduğudur. Bu nokta, yazarların analistin karşılaşabileceği herhangi bir eşleme fonksiyonu için genel tavsiyeler vermeye çalıştığı literatürde genellikle kaybolur. Ancak, her seferinde daha iyi modeller yerine daha iyi özellikler seçmeyi memnuniyetle tercih ederiz. Açıklayıcı amaçlar için, temsilimiz olarak terim sayıları vektörü W_i'yi kullanıyoruz, ancak metinden çıkarılan kelime gömme, ifadeler veya çok çeşitli diğer özelliklere dayalı bir temsili kolayca seçebilirdik.

Üçüncü ve son adım, öğrenilecek bir model sınıfı seçmektir. Çok sayıda seçenek vardır; ancak tüm farklı seçenekler, bilgiyi paylaşmanın farklı yollarını sunar. Özelliklerin çıktıya nasıl eşlendiği hakkında hiçbir varsayımda bulunmazsak, yalnızca eğitim setinde gözlemlediğimiz bir örneğe tam olarak benzeyen belgeleri sınıflandırabiliriz. Farklı model sınıfları, öğrenilen işlevin girdi temsilinden etikete nasıl eşlendiğini tanımlar. Göreceli olarak basit modeller seçebiliriz; bu modeller genellikle yorumlaması kolaydır ve eğitmek için görece az veri gerektirir, ancak insan etiketlerini tahmin etmek için yeterince esnek olmayabilir. Daha karmaşık modeller, veri için daha açgözlüdür ve analist için görece opak olabilir, ancak genellikle karmaşık tahmin problemlerini ele alabilir.

Doclingo https://www.doclingo.ai

17.1 Örnek: Diskürrsif Yönetim

Denetimli sınıflandırmanın genel bir görünümünü sağlamak için, Gillion (2016)'nın Amerika'daki ırk hakkında siyasi yetkililerin söylemini analizinde n bir örnek alıyoruz. Siyasi stratejistler, siyasi yetkililerin, en geniş seçmen kitlesine hitap etmek için politikalar etrafındaki söylemlerini ırksal olarak d eracialize etmeleri gerektiğini savunmuşlardır; ancak Gillion (2016), retorikt e ırkın rolünün seçimler ve politika yapma süreci dışında da etkileri olduğu nu savunmaktadır. Gillion (2016), ırkı tartışmanın, onun "diskürrsif yönetim " olarak adlandırdığı süreç için önemli etkileri olduğunu belirtmektedir; bu süreç, retoriğin yalnızca seçimleri ve politikayı doğrudan etkilemekle kalma yıp, aynı zamanda kamuoyunun ve politika yapıcıların gündemi belirlemesi, tasarlaması, tartışması, uygulaması ve politikaları değerlendirmesi üzerind e de etkisi vardır. Irkı tartışmamak, oylayıcıların gözünde ırksal eşitsizliğin önemini azaltır ve bu eşitsizlik üzerindeki politikaların etkisi hakkında öne mli bilgilerin politika yapma sürecinden dışarıda kalmasına neden olur.

Gillion (2016), kanıt temeli olarak, başkan ve Kongre üyeleri tarafından yapılan e tkileyici bir ifade koleksiyonunda ırk tartışmasını ölçmektedir - “başkanlık tartışmal arı, kampanya bağış toplama konuşmaları, veda konuşmaları, açılış konuşmaları, u lusa hitaplar, haftalık radyo konuşmaları, basın toplantıları, Birleşik Devletler'in Dur umu konuşmaları, Kongre'ye yapılan diğer konuşmalar, yerel konuşmalar (örneğin , mezuniyet konuşmaları ve halk toplantısı konuşmaları), imza beyanları ve yabancı yasama organlarına ve Birleşmiş Milletler (BM) Genel Kurulu'na hitaplar” (s. 33). Ay rıca, Temsilciler Meclisi'ndeki tüm zemin konuşmalarını, Kongre Kayıtları'ndaki tüm belgeleri ve Başkanların Kamu Belgeleri'nin tüm ciltlerini de dahil etmektedir. Bu metinleri ifadeler olarak ayırmak için, Gillion (2016) analizin biri mi olarak paragrafı kullanmakta ve toplamda 1955-2012 yılları aras ındaki başkanlardan 912,466 paragraf ve 104. ile 112. Kongre üyel erinden 2.3 milyon paragraf ile sonuçlanmaktadır.

Sonrasında, Gillion (2016) belgelerde “ırk ile ilgili söylemi” ölçmeyi amaçlam aktadır; bunu “siyasi diyalog veya politikacılar tarafından ifade edilen retorik, e sasen temsil edilmeyen bir ırksal veya etnik azınlık grubuyla ilgili olan veya açık ça ırksal bir çağrışım taşıyan terimleri kullanan” (s. 33) olarak tanımlamaktadır. Açıkça, Gillion (2016) tarafından toplanan belge sayısı, insan kodlayıcıların m anuel olarak kodlaması için çok fazladır. Ancak, belirttiği gibi, sözlükler de ye tersizdir. Bu ırk ile ilgili tanıma uyan paragraflar, ırk konularını tartışsalar bile "ırk" kelimesini kullanmayabilirler. "Taşımacılık" gibi diğer kelimeler ise yalnı zca belirli bağlamlarda ırk ile ilgili olabilir.

Bunun yerine, Gillion (2016) her paragrafı ırk ile ilgili veya ırk ile ilgili olmayan olarak kodlamak için insan kodlamasını denetimli makine öğrenimi ile birleştirmeye karar verir.

Doclingo https://www.doclingo.ai

Burada, Gillion (2016)'nın ölçümünün gelişimini üç adımda takip ed iyoruz: 1) bir eğitim seti oluşturmak, 2) belgeleri denetimli öğrenm e ile sınıflandırmak ve 3) performansı kontrol etmek.

Doclingo https://www.doclingo.ai

17.2 Bir Eğitim Seti Oluşturun

Denetimli sınıflandırmadaki ilk adım, bir eğitim seti oluşturmaktır; bunu Bölüm 18'de kapsamlı bir şekilde ele alıyoruz. İnsan anotatörler, belgelerin bir alt kümesini araştırmacı tarafından tanımlanan kategorilere etiketler. Gillion (2016)'da, iki anotatör, daha büyük örneklemden 12,300 paragraf ok uyarak, Gillion (2016)'nın öne sürdüğü belirli tanıma dayanarak bunların ırk ile ilgili olup olmadığını belirtir.

Bir eğitim seti oluşturulurken iki ana husus dikkate alınmalıdır. İlk olara k, denetimli sınıflayıcının eğitim setinden test setine desenleri ne kadar iyi genelleyebileceği, eğitim setindeki belgelerin daha büyük bir setten nasıl ö rneklenmiş olduğuna bağlıdır. Temsili olmayan bir eğitim seti, yeni belgele re genellendiğinde yanlı bir sınıflayıcı oluşturabilir. Eğitim seti için belgeleri n rastgele bir örneğini kullanmak, eğitim belgelerinin geri kalan örneği te msil etmesini sağlamak için en basit güvencedir. Gillion (2016), belgelerin z aman dilimini temsil ettiğinden emin olmak için katmanlı rastgele bir örne klem oluşturarak temsili sağlamada daha ileri gitmektedir. Bazı durumlard a, rastgele örnekleme mümkün değildir; bu konuları daha fazla tartışıyoruz Bölüm 18.

İkinci husus, insan kodlayıcıların kendilerinin doğruluğudur. En basit kategorileştirme şeması bile farklı insan kodlayıcılar tarafından farklı şekilde yorumlanabilir. Kategorilerin net bir şekilde iletilmesi, hem gelecekteki çalışmalar içi n hem de eğitim setinin daha geniş bir şekilde uygulanmadan önce doğruluğunu sağ lamak için önemlidir. Bölüm 18'de uzun bir şekilde tartıştığımız gibi, belgeleri kodlam ak için en az iki insan anotatörünün bulunmasını öneriyoruz ve ardından bu kodlayıcı ların aynı kategoriye koyduğu belgelerin oranı olan kodlayıcılar arası güvenilirliği değ erlendirmeyi takip ediyoruz. Gillion (2016), iki anotatörü arasındaki kodlayıcılar arası anlaşma oranını %97 olarak rapor etmektedir (s. 164). Anotatörler arasında anlaşmaz lık olduğunda, nihai kararı kendisi vermiştir.

Doclingo https://www.doclingo.ai

17.3 Denetimli Öğrenme ile Belgeleri Sınıflandırma

Denetimli sınıflandırmadaki bir sonraki adım, eğitim setinde etiketlen miş kategoriler ile özellikler arasındaki eşleşmeyi öğrenmek için bir sınıfl ayıcı seçmektir. Bu, öncelikle özelliklerin nasıl temsil edileceğini seçmeyi i çerir, bu konuyu Bölüm 2: Temsil. Özelliklerin, kategoriler hakkında en bilgilendirici olabilecek türlerini dikkatlice düşünerek, alan uzmanlığına dayanarak bir temsil seçmeyi öneriyoruz.
Birçok sınıflayıcı ayrıca, sınıflayıcının alakasız bulduğu özellikleri kal dıracak bir özellik seçimi bileşeni içerir. Gillion (2016), belgeleri tem sil etmek için bir kelime torbası yaklaşımı kullanır, noktalama işaret lerini, sayıları, boşlukları ve durak kelimeleri kaldırır (s. 164).

Bir sonraki adım, eşleşmeyi öğrenmek için modeli seçmektir. Seçilecek birçok model vardır, bunlardan bazılarını Bölüm 19'da detaylandırıyoruz. Ayrıca, model ler, araştırmacıların her belgenin nihai etiketinde "oy vermek" için birçok farklı m odeli kullandığı sınıflayıcıların *toplulukları* içinde birleştirilebilir. Bu, Gillion (201 6)'nın belgeleri ırk ile ilgili ve ırk ile ilgili olmayan olarak kodlamak için kullandığı yaklaşımdır.

Doclingo https://www.doclingo.ai

17.4 Performansı Kontrol Et

Denetimli sınıflandırmanın son adımı, sınıflandırıcının performansını kontrol etmektir. Burada araştırmacı, modelin (2)'de tanımlanan model uyumundan hariç tutulan bir eğitim verisi setini ayırmalı ve bunu doğrulama için kullanmalıdır. Modeli uyarladıktan sonra, araştırmacı bu ayrılmış veri setine modeli uygular ve modelin insan etiketleri üzerindeki performansını karşılaştırır.

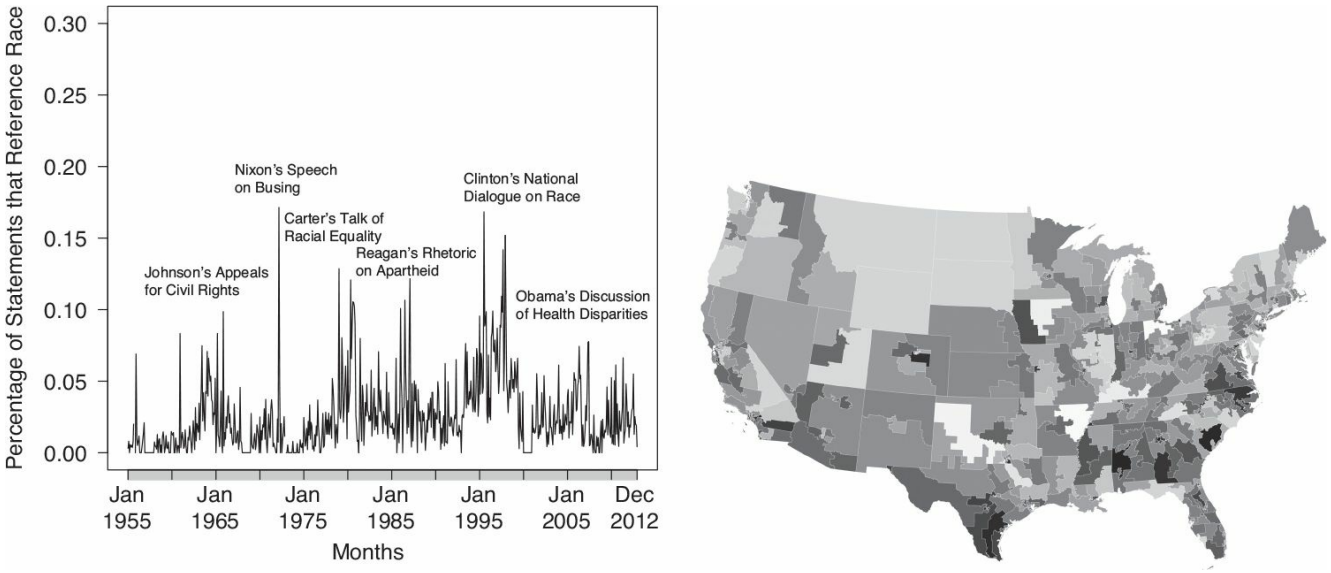
Bu doğrulama adımında dikkate alınması gereken birkaç husus vardır, bunları Bölüm 20'de detaylandırıyoruz. İlk olarak, belirli bir doğrulama veri setine aşırı uyum sağlamayı önlemek için, araştırmacılar genellikle çapraz doğrulama kullanır; eğitim verisini böler, modeli uyumlar ve doğruluğu birçok farklı kez değerlendirip ardından performans ölçütünü ortalama alırlar. Bu, Gillion (2016)'nın benimsediği yaklaşımdır ve başkanlık belgeleri setinde %0.77, Kongre belgeleri setinde ise %0.66 doğruluk rapor etmektedir.

Diğer bir husus ise performans ölçütüdür. Doğruluk—doğru sınıflandırılan toplam sayının doğrulama setindeki toplam sayıya bölünmesi—performansın doğal bir ölçüsü olmasına rağmen, yüksek doğruluk kötü performansı maskeleyebilir, özellikle verilerdeki kategoriler oldukça çarpık olduğunda. Analiste, performans hakkında daha fazla bilgi verebilecek olan kesinlik ve hatırlama gibi diğer performans metriklerini detaylandırıyoruz Bölüm 20.

Doclingo https://www.doclingo.ai

17.5 Ölçüyü Kullanma

Gillion performansı kontrol ettikten sonra, sınıflandırıcısını test seti ne uygulamaya hazırdır. Gillion (2016), veri setindeki tüm ifadeleri sını flandırıcıya uygulayarak, başkanlık ifadelerinin ırkla ilgili sıklığının fark lı yönetimler arasında nasıl değiştiğini ve Kongre üyeleri tarafından ya pılan ırk ile ilgili ifadelerin coğrafya ile nasıl ilişkili olduğunu anlamak i çin yeni ölçüyü kullanabilir.



Şekil 17.1. Gillion (2016) kaynaklı Şekil 2.1 ve 2.3. Sol panel, zaman içinde ırkla ilgili başk anlık ifadelerinin oranını göstermektedir. Sağ panel, Temsilciler Meclisi'nde ırk hakkında ifadeler yapan temsilcilerin coğrafyasını göstermektedir; daha koyu alanlar daha sık ifa deleri belirtmektedir.

Şekil 17.1'de, Gillion (2016) tarafından denetimli ölçüme dayanan iki şekli ye niden üretiyoruz. Sol panel, zaman içinde ırkla ilgili başkanlık ifadelerinin oranı nı göstermektedir. Şaşırtıcı bir şekilde, ırk ile ilgili ifadeler, diğer başkanlarla ka rşılaştırıldığında Başkan Obama için oldukça düşüktür ve Gillion (2016), Obama 'nın bir Siyah başkan olarak ırk tartışmalarını minimize etme baskısı hissetmiş olabileceğini savunmaktadır. Sağ panel, Kongre üyeleri tarafından yapılan ırk il e ilgili ifadelerin tartışmalarının coğrafyasını göstermektedir. Gillion (2016), bu tartışmaların çoğunun Güneydoğu Amerika Birleşik Devletleri'nde yoğunlaştığı nı belirtmektedir.

Sonraki bölümlerde tartışacağımız gibi, sınıflandırıcıyı test setimi ze uyguladıktan sonra, onu sonraki analizlerde nasıl kullanacağımı zı dikkatlice düşünmemiz gerekecek. Sınıflandırıcılarımızla oluşturd uğumuz ölçümler, insan kodlamasındaki hatalardan veya

Doclingo https://www.doclingo.ai

sınıflandırıcıdaki hatalar aracılığıyla. İdeal olarak, bu ölçüm hatasını nihai analize aktarmanın yollarını bulacağız ve bu hatanın analizimizi etkileyebi lecek sistematik bir şekilde olup olmadığını araştıracağız.

Doclingo https://www.doclingo.ai

17.6 Sonuç

Bu bölümde, denetimli sınıflandırma sürecine genel bir bakış sunduk. Gillion (2016) çalışmasında ırkla ilişkili söylemin ölçümünden yararlanarak, araştırmacının insan kodlayıcılar tarafından oluşturulan bir eğitim kümesini kullanarak özel ölçümler oluşturma yöntemine kuş bakışı bir bakış sağladık; önce bir eğitim kümesini kodlayarak, ardından belgeleri denetimli bir sınıflandırıcı ile sınıflandırarak ve son olarak ölçütün performansını değerlendirerek. Sonraki üç bölümde, bu üç adımın her birine ayrıntılı olarak dalıyoruz.

---

[1]Nihai doğruluğu bu seviyenin üzerine çıkarmak için, Gillion (2016) daha sonra sınıflandırıcı tarafından yönlendirilen bir başka elle kodlama turu yaptı (165,166).

Doclingo https://www.doclingo.ai

BÖLÜM 18

Bir Eğitim Kümesinin Kodlanması

İnsan kodlama, metinleri düzenlemek ve nicel olarak değerlendirmek için uzun zamand ır kullanılmaktadır. Bir araştırmacı kategorileri tanımladıktan sonra, insan kodlama bu b elgeleri manuel olarak bu kategorilere yerleştirme sürecidir. İnsan kodlama, modern ist atistiksel metin analizi yaklaşımlarından önce ortaya çıkmış olmasına rağmen, hala küç ük veri setleri ve karmaşık kavramların kodlanması için son derece faydalıdır. Mükemm el bir kod kitabı yazmayı ve kodlayıcıları eğitmeyi öğrenmek, otomatik yöntemler bağla mında da önemlidir çünkü manuel kodlama genellikle istatistiksel sınıflandırıcılar için e ğitim ve doğrulama kümelerinin temelini oluşturur.

İnsan kodlama, metinden ilgi alanlarına bir eşleme fonksiyonu sağla r; bu, insanların metni yorumlamalarına dayalı olarak ürettikleri bir fon ksiyondur. Bu eşleme fonksiyonu, kod kitabı, kodlayıcılara verilen eğiti m ve kod atama sürecinde içsel düşünce süreçlerinin bir kombinasyonu dur. İstatistiksel sınıflandırma ile karşılaştırıldığında, insanlar, metindek i bağlamı kullanarak kodlama şemasındaki boşlukları doldurmak için m addi ve arka plan bilgilerini kullanabilirler. İnsan kodlama, otomatik sını flandırmadan çok daha yavaş olmasına rağmen, ilgi alanlarının kategori lerini netleştirmek ve bunların nasıl iletildiği konusunda da faydalı olabi lir.

Belgeleri kategorilere manuel olarak yerleştirmek ilk başta görece basit bir görev gibi görünse de, insan kodlama oldukça karmaşık olabilir. Dildeki belirsizlikler, kodlayıcıların sınırlı dikkati ve incelikli kavramlar, belgelerin g üvenilir bir şekilde sınıflandırılmasını zorlaştırır—uzman kodlayıcılar için bil e (Grimmer ve Stewart, 2013). Ne yazık ki, uzman kodlayıcılardan oluşan ek ipler nadirdir ve sosyal bilimlerdeki modal manuel içerik analizi projesi, Sch rodt'un (2006) olay verilerinin toplanmasını tanımlarken renkli bir şekilde if ade ettiği gibi, “kopyaları karıştıran sıkılmış öğrenciler lejyonlarıdır.” *York Times*” (s. 2). Dilin derin bağlamsal doğası nedeniyle, tüm bir kod kitabını ön ceden belirlemenin zor olduğu komplikasyonlar ortaya çıkar. Bu nedenle, kodlayıcıl ara rehberlik edecek öncelikli ve özlü bir kod kitabının yazıldığı açık bir keşif/keşif a şamasını öneriyoruz; ardından kodlayıcılar, kod kitabını ilk belge setine uygular. Ko d kitabını kullanırken—özellikle başlangıçta—kodlayıcıların kodlama şemasındaki b elirsizlikleri veya gözden kaçan kategorileri tanımlamaları muhtemeldir.

Doclingo https://www.doclingo.ai

Bu, sonrasında kod kitabının revizyonuna yol açar. Kodlayıcılar, belgeleri önemli belirsizlikler fark etmeden kodlama şemasını uyguladıktan sonra ancak “nihai” bir şemanın analiz için kullanılan ayrı bir belge setine uygul anmaya hazır olduğu kabul edilir. Bu, belirsizliklerin yeterince ele alındığı nı ve kod kitabını geliştirmek için kullanılan belge setine aşırı uyum sağla ma riski olmadan sağlandığını garanti eder.

Bu bölümde, önce bir kod kitabı geliştirme, kodlayıcı seçme ve bir eğitim setini kodlama temellerini ele alıyoruz. Ardından, kalabalık kaynak kullanımı ve bulunan verilerle denetim dahil olmak üzere etiketlenmiş veri kaynaklarını da göz önünde b ulunduruyoruz. Manuel kodlama çok önemli bir konudur, ancak bu kitapta tam bir ele alımını veremeyiz. Neyse ki, manuel içerik analizi zengin bir şekilde geliştirilmiş bir alandır ve iyi bir kod kitabı yazma ve kodlayıcıları eğitme konusunda tamamen kitaplar bulunmaktadır. Özellikle Krippendorff (2012), Neuendorf (2016) ve Riffe ve ark. (2019) kodlama süreci ile ilgili daha ayrıntılı ele alımlar ve pratik tavsiyeler için öneriyoruz. Barberá ve ark. (2021), tüm denetimli öğrenme sürecinin mükemmel b ir makale uzunluğunda ele alımını sunmaktadır.

Doclingo https://www.doclingo.ai

18.1 İyi Bir Eğitim Kümesinin Özellikleri

İnsan kodlamasının amacı, araştırmacının ilgisini çeken kategorile re metinlerden güvenilir bir insan eşlemesi sağlamaktır. Bölüm 3'te: Keşif, ölçmek istediğimiz kavramları keşfettiğimiz yerdir; bir eğitim kümesini kodlarken, b u kavramları *operasyonelleştirmek* istiyoruz. Bu eşlemenin oluşturulmasında birçok kar maşıklık ortaya çıkmaktadır, bunları aşağıda daha ayrıntılı olarak açıklayacağız. Neuendor f (2016, Bölüm 1) iyi bir insan kodlu veri seti veya eğitim kümesinin aşağıdaki özelliklerini güzel bir şekilde ortaya koymaktadır:

- Nesnellik-İntersubjektivite: Kategorilerin ölçümü nesneldir, çünk ü kategorilerin anlaşılması belirli bir kişiye özgü değildir. Nesnel olamıyorsa bile, Neuendorf (2016) en azından intersubjektiviteye , yani araştırmacılar arasında paylaşılan bir anlayışa sahip olması gerektiğini savunmaktadır.
- A Priori Tasarım: Bölüm 3'te: Keşif, kategorileri tanımlamak ve ye niden tanımlamak araştırma sürecinin önemli bir parçasıdır. İnsan kodlama sürecinde, kategorilerin daha da rafine edilmesi gerekeb ilir. Ancak, nihai eğitim kümesi nihai bir kod kitabına dayanmalı ve yeni veriler üzerinde kodlanmalıdır.
- Güvenilirlik: Metinlerin kategorilere eşlenmesi güvenilir olma lıdır, farklı insan kodlayıcılar bağımsız çalıştıklarında aynı eşl emeyi üretmelidir.
- Geçerlilik: Ölçüm, ilgi alanındaki kavramı veya kategoriyi yansı tmalıdır. Ölçüme atfettiğimiz kategori etiketi, gerçekten neyi öl çtüğümüzü yansıtmalıdır.
- Genelleştirilebilirlik: Bir eğitim seti oluşturmak için genellikle yalnızcaç ok daha büyük bir veri setinin bir örneğini kodlayacağız. Elle kodlama ile ürettiğimiz eşleme,tüm veri setine ve araştırmacının ilgilendiği nih aipopülasyona genellenebilir olmalıdır.
- Tekrar edilebilirlik: Ölçüm, aynıdatalarda ve ideal olarak farklı ver iler ve farklı bağlamlarda da tekrar edilebilir olmalıdır.

Doclingo https://www.doclingo.ai

18.2 Elle Kodlama

Bu hedefleri akılda tutarak, önce araştırmacının elle kodlama kullanarak bir eğitim seti oluşturduğu durumu ele alıyoruz. Araştırmacının ölçmeyi amaçladığı kategorilere ve elle kodlama için ayrılan örnek setinin boyutuna bağlı olarak, elle kodlama süreci çok basit bir süreçten haftalar, aylar veya hatta yıllar süren bir sürece dönüşebilir (Baumgartner, Jones ve MacLeod, 1998). Yine de, insan kodlu bir veri seti oluşturmak için gerekli birkaç temel adım ve karar vardır:

18.2.1 1: BİR KOD KİTABI BELİRLEYİN

Kod kitabı, kodlayıcıların belgeleri kategorilere yerleştirmesi için talimat kılavuzudur.Eğer kategoriler araştırmacı tarafından oluşturulmuşsa, kendi kod kitabını yazması gerekecektir. Kod kitabı, yalnızca ilgi alanındaki kategorileri tanımlamakla kalmaz, aynı zamanda güvenilirlik, geçerlilik ve tekrarlanabilirliği sağlamak için bunları etkili bir şekilde iletmelidir. Bu, her kategori için örnek metinler sağlamayı ve kenar durumlarını tanımlamayı gerektirebilir.[2] Akış şemaları, kodlayıcıların kategoriler in hiyerarşisini anlamalarına veya birçok kategorinin bulunduğu durumlarla başa çıkmalarına yardımcı olmak için de kullanılabilir (Krippendorff, 2012, s. 135).

Eğer araştırmacı sıfırdan özel bir kod kitabı oluşturmak istemiyorsa, araştırma projesinin amacına uygun birçok kod kitabı mevcuttur. Mevcut bir kod kitabını uyarlamanın avantajı, genellikle birden fazla test turu ile rafine edilmiş olmasıdır. Örneğin, Karşılaştırmalı Manifestolar Projesi (https://manifesto-project.wzb.eu/
), seçim manifestolarının politika tercihlerini kategorize etmek için birkaç versiyon kod kitabı sunmaktadır.

18.2.2 2: KODLAYICILARI SEÇİN

Öznellik, güvenilirlik ve tekrarlanabilirliği sağlamak için, insan kodlamasının ilkelerinden biri, araştırmacı dışındaki kodlayıcıların verileri etiketlemesidir (Krippendorff, 2012, s. 131). Ayrı bir kodlayıcı seti kullanmak, araştırmacının kategorileri diğer insanlara etkili bir şekilde iletip iletemediğini test eder.

Bir sonraki soru, verileri etiketlemek için kaç kodlayıcı kullanılacağıdır. En iyi uygulama, araştırmacının eğitim verilerini oluşturmak için en az iki kodlayıcı seçmesidir. Bu, araştırmacının kodlayıcılar arasındaki anlaşma düzeyini güvenilirlik ölçüsü olarak değerlendirmesine olanak tanır; bunu aşağıda daha ayrıntılı olarak tartışacağız. Araştırmacının seçmesi gereken toplam kodlayıcı sayısı, kodlayıcıların verileri etiketlemedeki hassasiyetine bağlı olacaktır.

Doclingo https://www.doclingo.ai

Araştırma alanında çok deneyimli eğitimli kodlayıcılarla, araştırmacılar toplamda yalnızca iki ko dlayıcı kullanabilirler. Daha az eğitimli veya daha az dikkatli bir iş gücünde, kodlayıcıların daha a z hassas olabileceği durumlarda, verileri güvenilir bir şekilde etiketlemek için her veri noktası içi n birçok değerlendirme gerekebilir. Barberá ve ark. (2021), kodlayıcı sayısını seçerken bu ticaret dengeleri hakkında mükemmel bir genel bakış ve karakterizasyon sunmaktadır.

18.2.3 3: KODLANACAK BELGELERİ SEÇİN

Sonra, araştırmacı hangi ve ne kadar belgeyi kodlayacağını seçmelidir. Genelleştirilebilirlik ve sınıflandırıcının en iyi performansı için, eğitim kümesi araştırmacının kodlamayı amaçladığı daha büyük veri kümesini ve ayrıca araştırmacının çıkarımda bulunmayı amaçladığı popülasyonu temsil etmelidir. Bunu sağlamanın basit bir yolu, eğitim kümesi için daha büyük kümeden basit bir rastgele örneklem çekmektir.

Eğitim kümesinde kullanılacak belge sayısı, kategori sayısına ve kodl ayıcılarıngüvenilirliğine bağlı olacaktır. Kategori sayısı ne kadar yüksek ve kodlayıcılarıngüvenilirliği ne kadar düşükse, araştırmacının güvenilir bir sınıflandırıcı oluşturmak için o kadar fazla belgeye ihtiyacı olacaktır (Barberá ve diğ., 2021). Sınıflandırıcınınaşağıda doğrulanması, istenen d oğruluğa ulaşmak için yeterli sayıda belgeninkodlanıp kodlanmadığını ortaya çıkarmaya yardımcı olabilir.

18.2.4 4: KODLAYICILARI YÖNETİN

En iyi performans için, araştırmacılar kodlayıcılara eğitim kümesini etiketlemeleriiste ndiğinde önce eğitim vermelidir. Bu, kodlayıcıların kod kitabını dikkatliceokumasını ve h erhangi bir soru sormasını içerir. Genellikle, kodlayıcılardan birmetin örneğini etiketlem eleri istenir ve talimatları anlayıp anlamadıklarını veyatalimatların gözden geçirilmesi g erekip gerekmediğini değerlendirmek degerekmektedir.

Bir eğitim kümesi oluşturmanın son adımı, kodlayıcılar arası güvenilirliği kontrol etmektir.4 Bu, kodlayıcılar arasında aynı belgelerdeki etiketlerin k arşılaştırılmasını içerir. Etiketleri karşılaştırmak için birkaç farklı ölçüt kullan ılabilir; iki yaygın olarak kullanılan ölçüt Cohen'in kappa (Landis ve Koch, 1 977) ve Krippendorff'un alpha (Krippendorff, 2012)dır. Okuyucuyu

Neuendorf (2016) Bölüm 6 için güvenilirliği değerlendirme ölçütleri ve tuzakları hakkında mükemmel bir genel bakış için yönlendiriyoruz.

Araştırmacılar, insan kodlama sırasında meydana gelebilecek iki tür "drift" hakkında bilgi sa hibi olmalıdır. İlk olarak, kodlayıcılar, kodlama süreci ilerledikçe kategorilere etiket atama yönte mlerini değiştirebilirler. Bu, kodlamadaki yorgunluktan veya kodlama süreci sırasında edinilen y eni içgörülerden kaynaklanabilir (Neuendorf, 2016, Bölüm 6). Bu tür bir drift için, araştırmacını n kodlama sürecinin birden fazla noktasında güvenilirliği değerlendirmesi faydalı olabilir.

Doclingo https://www.doclingo.ai

18.2.5 5: GÜVENİLİRLİĞİ KONTROL ET

18.2.6 DRİFTİ YÖNETME

Bir kez kodlayıcılar eğitildiğinde ve kod kitabı son haline getirildiğinde, kodlayıcılar verileri birbirleriyle veya kod kitabının kendisi dışındaki kaynaklarla herhangi bir temas olmadan etiketlemelidir (Krippendorff, 2012, s. 131). Bu, üretilen eğitim verilerinin güvenilirlik açısından değerlendirilebilmesini sağlar. Nihai eğitim verileri, kod kitabının son revizyonundan sonra üretilmelidir.

İnsan kodlaması, veri kayması tarafından da etkilenebilir—bir içerik akışının zamanla evrildiği durumlarda, bu kod kitabı için yeni belirsizlikler yaratabilir. Örneğin,yeni kategoriler zamanla evrilebilir, çökebilir veya diğerleriyle birleşebilir.Eğer kod kitabı kaymaya dayanarak değiştirilirse, daha yeni verilerin eski verilerdenfarklı şekilde etiketlenmesi mümkün olabilir. Bu durumda, bir nihai kodlama turu,yeni kod kitabının nihai güvenilirliğini değerlendirmeye yardımcı olabilir (Krippendorff, 2012, 218).

18.2.7 ÖRNEK: HABER YAPMA

Haber Yapma'da, Amber Boydstun, hangi tür politika konularının en fazla haber kapsamı aldığını ve nedenini sorgulayan önemli bir soruyu ele alıyor. Boydstun (2013), medyanın yalnızca gözetleyici olarak hareket etmediğini—tümkonu alanlarını denetleyerek—veya yalnızca ani olaylara yanıt veren alarm sistemleriolarak hareket etmediğini savunuyor. Bunun yerine, medya birçok konu alanınıizleyen, ancak “sıcak” hale geldiğinde birkaçına orantısız kaynaklar akıtan biralarm/gözetim hibrit modeli öneriyor. Politika konularına haberlerdeki dikkatiölçmek için, 31,034 makaleden oluşan bir veri seti topluyor ve bunları politikakonu alanlarına yerleştiriyor. En fazla haber dikkati alan politika alanlarınıanlamaya en çok ilgi duyduğu için, analizini ön sayfa hikayeleriyle sınırlıyor.

Boydstun (2013), veri kümesindeki her bir ön sayfa New York Times makalesini etiketlemek için mevcut bir kod kitabına—Politika Gündemleri Projesi—güvenmektedir. Kod kitabını The New York Times korpusuna uyarlamak için, kodlayıcılara daha açık talimatlar sağlamak amacıyla kod kitabını notlandırmıştır. Kod kitabı, birçok kategoriden oluşmaktadır - 27 ana konu kategorisi ve Bu 27 ana kategori içinde 225 alt konu.

Boydstun (2013), kodlayıcıları bir makale örneği üzerinde eğitti ve kodlayıcılardan bu örnekte yüksek güvenilirlik elde etmelerini istedi, ardından geri kalanını kodlamaya geçtiler.

Doclingo https://www.doclingo.ai

veri. Zamanla güvenilirliği sağlamak için, Boydstun (2013) kodlayıcıların kodlama sür eci boyunca tekrar eden metinleri etiketlemesini sağladı. Boydstun (2013) hem Kripp endorff'un alfa değerini hem de Cohen'in kappa değerini rapor etti ve kod kitabını çe vrimiçi olarak erişime açtı.

Boydstun (2013)'in ön sayfa *New York Times* makalelerinin elle kodlanmasıona zamanla farklı politika konularına dikkat etme fırsatı veriyor. O, konu kapsamınınul uslararası ilişkilere oldukça eğilimli olduğunu ve genellikle olaylar tarafından yönle ndirildiğini buluyor. Örneğin, Şekil 18.1 Boydstun (2013, Bölüm 4)'den2001 Eylül'ü ndeki Dünya Ticaret Merkezi'ne yapılan saldırıların, *The New York Times* ön sayfası ndaki medya kapsamınısavunmaya doğru büyük ölçüde kaydırdığını ve diğer politi ka alanlarının konu kapsamını dışladığını gösteriyor.

Doclingo https://www.doclingo.ai

18.3 Kitle Kaynak Kullanımı

Son on yılda, Mechanical Turk gibi çevrimiçi iş piyasalarının tanıtımı, anotatörler, anket katılımcıları ve deneylere katılanlar için işe alım manzarasını köklü bir şekilde değiştirmiştir (Snow et al., 2008; Kittur, Chi ve Suh, 2008; Buhrmester, Kwang ve Gosling, 2011; Berinsky, Huber ve Lenz, 2012; Budak, Goel ve Rao, 2016; Benoit ve diğ. 2016). İşgücü piyasaları, tipik bir üniversite ortamında akıl almaz ölçeklerde, eğitimsiz veya az eğitimli işçilere erişim sağlar. Kolayca açıklanabilen, nispeten basit ve hızlı bir şekilde tamamlanabilen görevler için, çevrimiçi işgücü piyasaları belge anotasyonları toplamak için değerli bir yol olabilir.

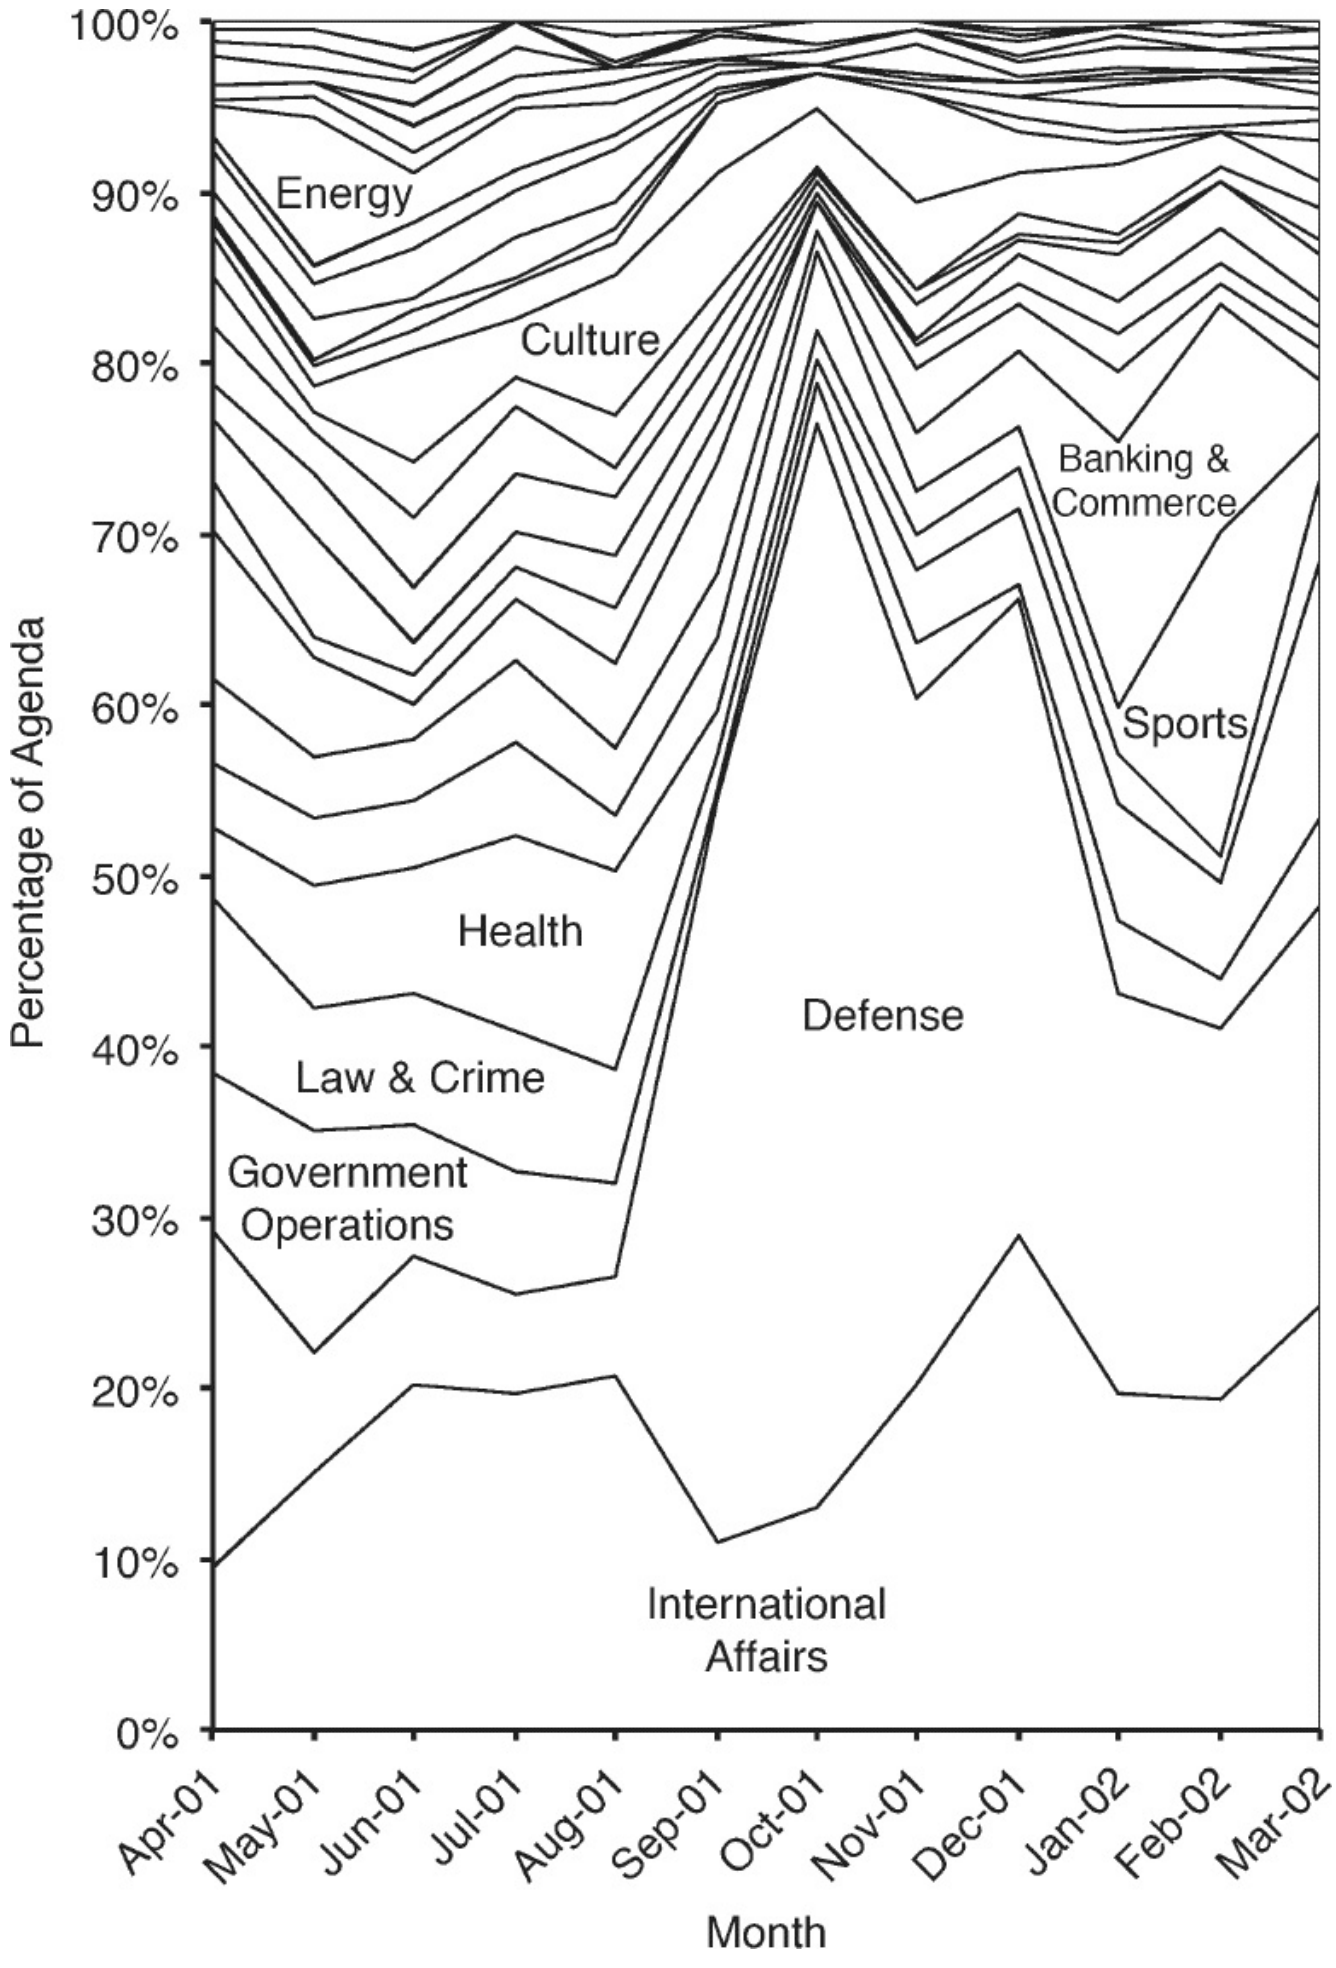
Bu çevrimiçi iş pazarlarını sonsuz büyüklükte işçi havuzları olarak düşünmek cazip olsa da, aslında (yazma anında en azından) göründüğünden çok daha küçüktür. Örneğin, Amazon'un Mechanical Turk'u akademik araştırmalar için en popüler çevrimiçi iş pazarındır. Yakın tarihli bir çalışma, benzersiz işçi sayısının iki yüz binden az olduğunu, her an aktif olan işçi sayısının ise yaklaşık iki ila beş bin arasında olduğunu tahmin etmektedir (Difallah, Filatova ve Ipeirotis, 2018). Bu işçiler, genel nüfusa göre çarpık demografik ve siyasi özelliklere sahip olma eğilimindedir, ancak kesinlikle üniversite ortamlarındaki öğrenci nüfusuna göre bu kadar çarpık değildir (Huff ve Tingley, 2015).

Kalabalık kaynak kullanımı ile insan kodlayıcılar arasındaki farklar. Küçük bir insan kodlayıcı ekibi ile büyük bir kalabalıkla çalışmak arasında üç büyük fark vardır. İlk olarak, kalabalık ortamında sabit maliyetlerin daha düşük olması gerekir, bu nedenle yoğun eğitim daha az uygulanabilir hale gelir. Pratikte bu, kalabalık çalışanların yapabileceği iş türlerini, uzmanlık gerektirmeyen nispeten basit görevlerle sınırlamaktadır. Düşük sabit maliyetlerin avantajları, ikinci büyük farkı doğurur - kalabalık çalışanları hızlı bir şekilde ölçeklendirmek, yüksek verimlilikte kodlama sağlamak için daha uygulanabilir hale gelir. Bir üniversite veya sanayi ortamında, yeni çalışanlar işe almak zaman alır, ancak kalabalık kaynak kullanımı ile basit bir görev için binlerce anotasyon sadece birkaç saat içinde toplanabilir. Üçüncü büyük fark, anotasyonlardaki hata kaçınılmazlığını tamamen kabul etmemiz gerektiğidir. Hata oranları kabul edilebilir derecede düşük olana kadar küçük bir anotatör ekibini eğitmek mümkündür, ancak kalabalık kaynak kullanımı ile çelişkili etiketleri uzlaştırmanın yollarını bulmamız gerekir.Neyse ki, bu eski bir sorun olup, son yıllarda çevrimiçi iş piyasalarının etkisiyle yeniden ilgi görmüştür (Dawid ve Skene, 1979; Sheng, Provost ve Ipeirotis, 2008; Zhang ve diğ.)

Doclingo https://www.doclingo.ai

2014; Benoit ve diğ., 2016; Barberá ve diğ., 2021). Bu yöntemlereBölüm 20'de doğrulam a üzerine geri döneceğiz.

Doclingo https://www.doclingo.ai

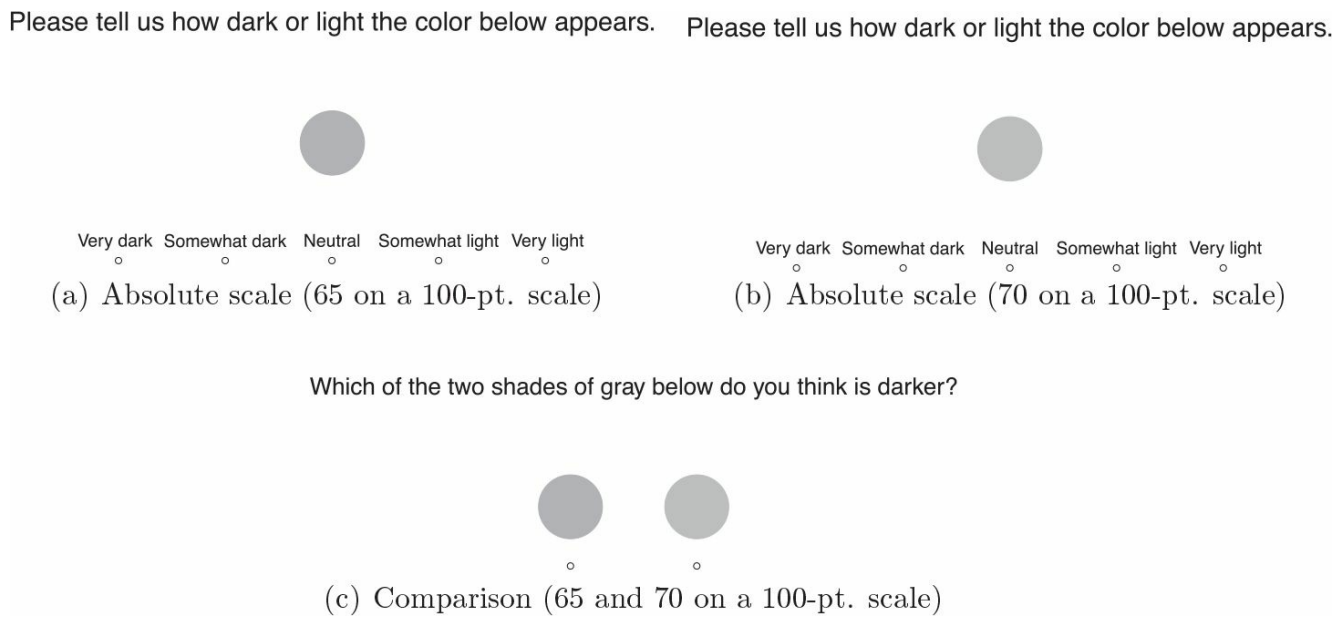


Doclingo https://www.doclingo.ai

Şekil 18.1. *The*
New York Times gazetesindeki savunma tartışması, Eylül'den sonra önemli ölçüde arttı. 11, 2001.
Şekil 4.8, Boydstun (2013) kaynaklıdır.

Bazıları dördüncü büyük fark olarak, kalabalık kaynak kullanımının daha ucuz olduğunu ekleyecektir.
Kesinlikle doğru olan, kalabalık kaynaklı notların Mechanical Turk'tan, li sansüstü notlayıcılardan daha ucuz elde edilebileceğidir, ancak bunları n elde edilip edilmemesi sorgulanabilir. İşçiler bağımsız yükleniciler old uğundan, genellikle yerel asgari ücretin altında etkili bir şekilde ödeme alırlar. İstatistiksel metin analizi amaçları için kalabalığı belirli bir tür "al goritma" olarak düşünmenin faydalı olabileceğini belirtelim, ancak işçil er gerçekten de insanlardır ve bu nedenle uygun tazminat hakkında eti k hususlar geçerlidir (Fort, Adda ve Cohen, 2011; Mason ve Suri, 2012; S hank, 2016).

Görevi Değiştirmek. Pratikte, kalabalık kaynak kullanımının anahtarı genelli kle kodlama görevini küçük "lokmalık" parçalara ayırmanın en iyi yolunu bu lmak olmuştur. Çevrimiçi iş piyasaları on yıldan fazla bir süredir var olduğu ndan, araştırmacılar daha kolay ayrıştırılabilen yeni görevler geliştirmeye y aratıcı bir şekilde başlamışlardır. Carlson ve Montgomery (2017), belgeleri bir ölçeğe yerleştirme yaklaşımını, hızlı ikili karşılaştırma görevlerine binler ce yanıt toplayarak tanıtmaktadır.



Şekil 18.2. Carlson ve Montgomery (2017) tarafından, ikili karşılaştırma görevlerinin mut lak ölçek görevlerinden daha yönetilebilir olabileceğini açıklayan bir şekil.

Doclingo https://www.doclingo.ai

Temel içgörü, Carlson ve Montgomery (2017) tarafından verilen bir örnekle güzel bir şekilde gösterilmektedir; bu örnek Şekil 18.2'de tasvir edilmiştir. Renklerin ne kadar koyu veya açık olduğunu değerlendirmek gibi birçok görevde, bir referans noktası olmadan mutlak bir ölçek atamak oldukça zordur. Ancak, iki değer arasındaki karşılaştırmanın güvenilir bir değerlendirmesini yapmak oldukça yönetilebilir. Bu ikili karşılaştırmalar, bir temel gizli boyutu geri kazanmak için kullanılabilir; bu fikir, en azından Thurstone (1927) döneminden beri psikometri alanında mevcuttur ve tartışmasız olarak 1800'lere kadar uzandığı söylenebilir.

Carlson ve Montgomery (2017) çalışmasında, Amazon'un Mechanical Turk platformu aracılığıyla kalabalık işçileri işe alarak birçok böyle ikili yargı toplarlar. Sistemin son derece güvenilir olduğunu ve diğer yaklaşımlarla karşılaştırıldığında da olumlu sonuçlar verdiğini gösterirler. Dikkate değer bir şekilde, kodlayıcıların ikili bir yargı vermek için mutlak bir ölçek atamaktan çok daha az eğitime ihtiyaç duyduğu görülmektedir. İkili karşılaştırmalar yapma ihtiyacı, değerlendirmelerin sayısının metin sayısının karesi ile ölçeklenmesini gerektirir, bu nedenle bu genel yaklaşım, makul sayıda belge ile en iyi şekilde çalışır (en büyük durum 2,000 belgeden azdır).

Önemli bir nokta, Carlson ve Montgomery (2017) çalışmasındaki görevin, hiçbir zaman herhangi bir birimin gerçek "doğru" değeri ile etiketlenmediği anlamında tam olarak denetimli olmamasıdır. Bunun yerine, amaçlanan ölçüm hakkında içgörü sağlamak için gizli boyut hakkında dolaylı geri bildirim (örneğin, hangi gri rengin daha koyu olduğu) kullanıyoruz. Bu, bu ölçüm stillerini denetimli kategorileme yaklaşımları ile denetimsiz yaklaşımlar arasında bir orta zemin olarak bırakıyor ve öğrenilen sürekli boyutun amaçlanan sonucu verdiğini dikkatlice araştırmak önemlidir.

Doclingo https://www.doclingo.ai

18.4 Bulunan Verilerle Denetim

Bir eğitim seti oluşturmak için tanımladığımız son strateji "bulunan verilerle denetim"dir; bu, kategorileri belirlemek ve belgeleri etiketlemek için bulunan verileri kullanmayı içerir. Bu yaklaşım, araştırma ekibinin dışındaki bireyler tarafından üretilen mevcut kategorileri eğitim seti olarak kullanır. Örneğin, Richard Nielsen'ın *Ölümcül Din Adamları: Engellenmiş Hırs ve Cihad Yolları* adlı kitabında, bazı Müslüman din adamlarının neden şiddetli cihadı desteklemeye başladıklarını araştırıyor (Nielsen, 2017). Bunu yapmak için, webdeki Müslüman din adamlarının bir sayımını topluyor ve ürettikleri metinleri derleyerek şiddetli cihadı destekleme ölçüsünü oluşturuyor; buna "Cihad Skoru" diyor.

Ancak, insan kodlaması kullanarak puan üretmek zordur. Nielsen, din adamı seviyesinde radikalleşme ölçüsü üretmek için yola çıktı ve Nielsen'in örneğindeki ortalama din adamı yazdı 523 belgeler. Bu insanı İslamcı ideolojiye sahip din adamlarının küçük bir rastgele örneğinin değerlendirilmesi çok zaman alıcıdır. Bu zahmetli insan kodlama sürecinden kaçınmak için, Nielsen bunun yerine İslamcılar tarafından seçilen ve web forumlarında yayınlanan belgelerin hazır bir örneğine, “Cihadistin Kitap Çantası”na yöneliyor ve bunu cihadı temsil eden bir örnek olarak kullanıyor. Kitap çantası, İslamcı ideolojiye bir giriş amacıyla İslamcılar tarafından düzenlenmiş olması nedeniyle ek bir avantaja sahiptir ve bu nedenle Nielsen, metinler üzerinde şiddetli cihadın kendi tanımını dayatmak zorunda kalmıyor. Nielsen, bu koleksiyonu bilinen İslamcı olmayan din adamlarından alınan düzenlenmiş bir belge örneği ile eşleştiriyor. Bu etiketli veri seti, nihai puanı üretmek için kullanılan sınıflandırıcı için eğitim setini sağlıyor.

Bulunan verilerle denetim, bir eğitim kümesi üretmek için düşük maliyetli bir yaklaşım olabilir. Ayrıca, bu yöntem gerçek uzmanlar tarafından üretilen kodlara sahip olma avantajına da sahip olabilir; Nielsen'in durumunda, cihatçılar kendileri. Karmaşıklık, bu prosedürün en az iki nedenle ölçümlerinizi öngörülemeyen yönlere kaydırabilmesidir. İlk olarak, etiketler analist tarafından atanmadığı için bilinmeyen bir süreçten gelmektedir. Analist, bu belgelerin içeriklerinin kodlamak istedikleri kategorileri yansıttığından emin olmalıdır. Bulunan veriler için kodların analistin atayacağı gibi olduğunu varsaysak bile, ikinci endişe, belgelerin rastgele seçilmemiş olmasıdır ve bu nedenle, gizli kategoriye göre kelimelerin tahmin edilen olasılıklarının doğru olması pek olası değildir. Bu, pratikte özellikle doğrudur, çünkü bulunan verilerle denetim genellikle bir yönde aşırı durumları seçerek ortaya çıkar ve bu durumlarda dil kalıpları oldukça farklı olabilir.

Nielsen (2017) bu sorunların farkındadır ve puanlarının geçerliliğini belirlemek için tasarlanmış sekiz farklı doğrulama sunmaktadır, bunları

Doclingo https://www.doclingo.ai

20. Bölümde gözden geçireceğiz. Kelime torbası veya metinlerin üretken mode lleri gibi diğer varsayımlar yanlış olsa da, "bulunan verilerle denetim" rastgele bir örneklem değildir, ancak pratikte iyi çalışabilir. Ancak, dikkatli bir doğrulam a gerektirir.

Doclingo https://www.doclingo.ai

18.5 Sonuç

Bu bölümde, insan kodlaması kullanarak bir eğitim veri seti oluşturmanın farklı yaklaşımlarını tartıştık. İyi eğitim setlerinin özelliklerini ve insan kodlam asıyla üretilen bir eğitim setinin nasıl oluşturulabileceğini gözden geçirdik. Son olarak, kalabalık kaynaklardan eğitim verisi toplamanın ve bulunan verilerle denetim yapmanın avantajlarını ve dezavantajlarını tartıştık - araştırma görevinden farklı nedenlerl e kodlanmış mevcut verileri tanımladık. Bir sonraki bölümde, bu eğitim verisini denetimli öğrenme ile belgeleri sınıflandırmak için kullanmaya geçiyoruz.

---

[1]Bu bölümün bir kısmı Grimmer ve Stewart (2013)'den alınmıştır.

[2]Örnek metinler sağlamanın ticaret dengeleri için Neuendorf (2016) Bölüm 5'e bakın.

[3]Bu kodlamayı gerçekleştirecek yeterli uzmanlığa sahip kodlayıcılara erişim zorluğu veya finansman ned enleri nedeniyle bunun her zaman mümkün olmayabileceğini kabul ediyoruz.

[4]Kodlayıcılar arasında güvenilirlik, kodlayıcıların benzer hatalara sahip olabileceği için doğrulu ğu garanti etmez (Barberá ve diğ., 2021). Ancak, "gerçek" etiketlere erişim olmadan, gerçek doğruluğu değerlendirmek zordur.

Doclingo https://www.doclingo.ai

BÖLÜM 19

Belgeleri Denetimli Öğrenme il e Sınıflandırma

Denetimli öğrenme, eğitim verilerindeki örnekler ile onlara atanan etiketler ar asındaki eşlemeyi yaklaşık olarak belirlemek için istatistiksel modeller kullanır. Bu eşlemeler, daha büyük etiketlenmemiş veri kümesinde kategori atamalarını tahmin etmek için uygulanabilir. Denetimli öğrenme, insan harcamasını artıra rak eğitim kümesine uygulanan insan eşlemesini yaklaşık olarak elde etmeyi s ağlar ve bu, çok daha büyük bir veri kümesine uygulanabilir.

Birçok istatistiksel sınıflandırıcı oldukça karmaşık olsa da, okuyucular, eğiti m verilerinin etiketlerinin (*y*) eğitim metinlerinden çıkarılan özelliklere (*W*) nas ıl uyarlandığını anlamak için lineer regresyonun tanıdık sezgisini kullanabilirler . Her istatistiksel sınıflandırıcı, *y* 'yi *W*'nin bir fonksiyonu ile yaklaşık olarak belir leyecektir; tıpkı lineer regresyonda *y* 'nin X β ile yaklaşık olarak belirlendiği gibi . Sınıflandırıcı, modelin parametrelerini *β* 'yi bir *lossfunction*'ı optimize ederek seçecektir. Lineer regresyon durumunda, kayıp fonksiyonu Σ i = 1 N (y i − X i β) 2'dir; her istatistiksel sınıflandırıcının kendi kayıp fonksiyonu versiyonu olaca ktır.

Bu, eğitim kümesindeki belgeleri nasıl temsil edeceğimiz sorusunu gün deme getiriyor. Özellikleri çıkarmanın çeşitli tariflerini 2. Bölümde ele aldık: Temsil. Aşağıda detaylı olarak tartışacağımız gibi, bu özellikler daha sonra dönüştürülebilir, b irbiriyle çarpılabilir veya daha karmaşık özellikler oluşturmak için katmanlı hale getirilebilir. Metin verilerinin yüksek boyutlu doğası ile özelliklerin daha yüksek der eceli etkileşimleri, özellik alanını çok büyük hale getirebilir. Modelin kar maşıklığını otomatik olarak azaltmak veya düzenleme, modeli uyumlu h ale getirmek ve aşırı uyumdan kaçınmak için önemlidir.

Bir sınıflandırıcıyı uyarladıktan sonra, performansını değerlendirmemiz gerekecek. Önemli olarak, performansı modelin uyarlanmasında kullanılan veriler dışında bir veri üzerinde de ğerlendirmeliyiz. Bu nedenle, bir sınıflandırıcıyı uyarlarken daha sonra performansı değerlendirme k için kullanmak amacıyla bazı eğitim verilerini dışarıda bırakmak standart bir uygulamadır. Model performansını değerlendirme ile ilgili daha fazla detayı 20. Bölümde ele alacağız.

Bazı sezgiler sağlamak için, Naive Bayes (Maron ve Kuhns, 1960) adlı bir temel mo del üzerinden dikkatli bir yürüyüşe başlayacağız ve bazı uzantılarını inceleyeceğiz.

Doclingo https://www.doclingo.ai

Model, kendi başına makul bir şekilde iyi performans gösterdiği için ve diğer d aha karmaşık modellerin temelini oluşturduğu için önemlidir. Daha sonra sınıfl andırma ve tahmin için kullanılabilecek daha geniş makine öğrenimi yöntemle ri sınıflarını tanımlamaya geçiyoruz.

Doclingo https://www.doclingo.ai

19.1 Naif Bayes

Diyelim ki, her belge D i'yi belge-özellik matrisini *W* girdi olarak kullanarak karşılıklı olarak dışlayıcı ve kapsayıcı kategorilere yerleştirebileceğimiz bir model oluşturmak isti yoruz. Belgenin kategori etiketini y i ∈ { 1 ... K } olarak tanımlayalım. y i'deki bilgiyi π i ol arak yeniden ifade etmek faydalı olacaktır; bu, elemanı π i k = 1 olan K uzunlukta bir vek tördür, eğer belge *i* k kategorisindeyse (yani, y i = k) ve π i k = 0 aksi takdirde.
Görmediğimiz bir belgenin k kategorisinde olma olasılığıyla ilgileniyor uz, D i belgesini gözlemlediğimizde. Bayes kuralını kullanarak, bu olas ılığı şöyle yazabiliriz:

p (π i k = 1 | D i) = p (π i k = 1 , D i) p (D i) (19.1.1) = p (π i k = 1) p (D i | π i k = 1) p (D i) . (19.1.2)

Payda tüm kategoriler arasında sabit olacağından, bunu basitçe atla yabiliriz ve sürecin sonunda normalleştirebiliriz. Bu, her bir bileşenin net bir anlamı olan bir formüle yol açar,

p (π i k = 1 | D i) ⏟ prediksiyon ∝ p (π i k = 1) ⏟ k sınıfının yaygınlığ ı p (D i | π i k = 1) ⏟ kategoriye özgü dil modeli. (19.1.3)

p (π i k = 1)'i, α k parametresi ile belirteceğimiz verilerden tahmin edeb iliriz. Rastgele bir belge örneği olarak bir eğitim setine sahip olduğumu zu varsayarsak, her sınıfa düşen oranı hesaplayabiliriz:

$$\hat{\alpha}k = \sum i N I (y i = k) N , (19.1.4)$$

burada I ( ) argümanı doğru olduğunda 1 değerini alan gösterim fonksiyonudurve aksi takdirde 0 değerini alır.

Bu noktaya kadar, kategoriye özgü dil modelinin biçimi hakkında kayıtsız kaldık. Ne yazık ki, belge D i'yi herhangi bir varsayım olmada n modellemek karmaşıktır. Bunu ele almak için belge-özellik matris t emsilcisi W i'ye geçeceğiz ve eponymous “naif” varsayımını yapacağı z. Belgedeki her token'in sınıfa bağlı olarak bağımsız bir şekilde çekil diğini varsayacağız. Bu, yazmamıza olanak tanır

W i , | π i k = 1 ~ Multinomial (Σ j W i j ⏟ Token sayısı , μ k ⏟ Sınıf k iç in kelime olasılıkları) (19.1.5) p (W i , | π i k = 1) ∝ ∏ j = 1 J μ k j W i j , (19.1.6)

Doclingo https://www.doclingo.ai

burada μ k, sınıf k'deki her kelimeyi çekme olasılığını gösteren olas ılık vektörüdür. Naif Bayes fikri oldukça genel olup, eğer farklı türd e özelliklerimiz olsaydı (örneğin, sürekli), farklı bir şekilde faktörleşt irebilirdik.

Belge sınıfına bağlı bağımsızlık varsayımı neredeyse kesinlikle ya nlıştır, ancak bizi daha kolay tahmin edebileceğimiz bir parametre setine ulaştırır.

μ k j = Σ i N π i k W i j ⏟ Özellik j'nin sınıf k'daki belgelerdeki sayısı Σ i Σ jπ i k W i j ⏟ Sınıf k'daki belgelerdeki özelliklerin sayısı (1

9.1.7)Sınıf *k* için parametreleri tahmin etmeyi, sınıf *k* 'ye atanan tüm eğiti m belgelerini bir araya getirip, her kelimenin ne sıklıkla kullanıldığını hes aplayarak düşünebiliriz.

Bu, yeterince nadir olan ve belirli bir sınıf altında asla görünmeyen keli melerle bir sorun yaratır. Bu, onların ortaya çıkma olasılığının 0 olarak tah min edilmesine neden olur, bu da belirli bir sınıfın tamamen dışlandığı anla mına gelir. Bu sorunu önlemek istiyoruz, bu yüzden her kelime için küçük bir sabit *c* ekliyoruz,

$$\hat{\mu}_{kj} = c + \sum_i N \pi_{ik} W_{ij} \; J c + \sum_i \sum_j \pi_{ik} W_{ij} \; . \; (19.1.8)$$

c = 1 olduğunda, bu, kelime dağarcığındaki her kelimeden birini içeren her sınıf için yeni bir belge eklemek gibidir. Bu, daha önce Bölüm 'de ta rtıştığımız Laplace düzeltmesi ile aynı fikirdir. 6 çok terimli dil modeli.

Bunların hepsini bir araya getirerek, Naive Bayes algoritması şu şekilde verilebilir:

$$p (\pi_{ik} = 1 \mid W_i ,) \propto \alpha_k \prod_{j=1}^{J} \mu_{kj} W_{ij} \; . \; (19.1.9)$$

Belirli bir sınıf için en iyi tahmini yapmak istiyorsak, genellikle en ola sı kategoriyi belirtmek için arg max notasyonunu kullanarak yeniden yazarız,

$$\hat{y}_i = \arg\max_k \hat{\alpha}_k \prod_{j=1}^{J} \hat{\mu}_{kj} W_{ij} \; (19.1.10) = \arg\max_k \log (\hat{\alpha}_k) + \sum_j J W_{ij} \log (\hat{\mu}_{kj}) \; , \; (19.1.11)$$

log almak sayısal kararlılığı artırır ancak maksimumu korur.

Sezgisel olarak, Naive Bayes, her sınıf için bir prototip belge oluşturmak üzere eğitim belgelerini kullanır.

Doclingo https://www.doclingo.ai

Bir sınıf seçerken, algoritma yeni belgenin her prototipe olan benzerliğini değerlendirir ve sınıfın nadirliğini düzeltir. Naive Bayes sınıflandırıcısı, karşılaştırmalı olarak basit olması, iyi performans göstermesi ve aşağıda tanımlayacağımız ek yöntemlerde bulunacak birkaç unsuru içermesi nedeniyle incelenmesi çekici bir modeldir. Makine öğrenimi sınıflandırıcılarının daha geniş bir listesine geçmeden önce, Naive Bayes yöntemine dair birkaç yorumda bulunuyoruz.

19.1.1 NAIVE BAYES'TEKİ VARSAYIMLAR NEREDEYSE KESİNLİKLE YANLIŞTIR

Naive Bayes'in türetilmesi Bayes kuralıyla başladı ve belge olasılığını basitleştirmek için, $p(D_i \mid \pi_i k = 1)$, bağımsız çok terimli çekimlerin sınıf koşullu bir seti olarak temsil edilebileceği güçlü varsayımını yaptık. Farklı koşullu dağılımlara sahip bir dizi Naive Bayes yöntemi vardır ve bunların hepsi bir tür bağımsızlık varsayımında bulunur. Genel olarak, bu varsayımların gerçek dilde yanlış olduğuna inanıyoruz. Ancak önemli olan, yanlış olma varsayımının yöntemin faydalı veya doğru olmasını engellememesidir. Otomatik içerik analizinde özellikle tehlikeli bir tuzak, varsayımlar yanlış olduğu için yöntemleri elden çıkarmak veya onları değiştirmek için zaman harcamaktır; bu varsayımların etkisini değerlendirmeden.

Neden bu varsayımları yapıyoruz ve bunların sınıflayıcımız üzerinde ne etkisi var? Varsayımın avantajı, modelin uyum sağlaması gerekken parametre sayısını sadece $(J - 1)K + (K - 1)$ kadar azaltmasıdır. Bu, modelin veriye uyum sağlama yeteneğinin daha sınırlı olduğu anlamına gelir—örneğin, kelimeler arasındaki etkileşimleri yakalayamaz—ancak modeli iyi bir şekilde uyum sağlamak için nispeten az veri gerektirir. Bağımsızlık varsayımı, Naive Bayes modelinin tahminlerinde aşırı güvenli olmasına neden olur. Bağımsızlık varsayımı modele, her ek kelime sayısının daha önceki tüm parçalardan ayrı yeni bir bilgi parçası olduğunu söyler. Aslında, kelimelerin "patlayıcı" olduğunu genellikle düşünürüz—belirli bir kelime bir metinde kullanıldığında, tekrar kullanılma olasılığı daha yüksektir—ve bu nedenle model, gerçekte olduğundan daha fazla bilgiye sahipmiş gibi davranır. Bu aşırı güven, modelin genellikle doğru kategoriyi seçtiği, ancak π_i den elde edilen tahmin edilen olasılıkların kötü bir şekilde kalibre edildiği bir duruma yol açar.
Kötü kalibrasyon, bir grup tahminin ortalamasının belirli bir sınıftaki toplam oranı kötü bir şekilde tahmin etmesi anlamına gelir. Bu nedenle, sınıf *k*'deki belgelerin oranını tahmin etmek istediğimizde, bu tahminler bizi yanıltabilir (aşağıda geri döneceğimiz bir sorun).

Doclingo https://www.doclingo.ai

19.1.2 NAIVE BAYES JENERATİF BİR MODEL

Naive Bayes sınıflandırıcısını tahmin ederken amacımız, bir belgeni n içeriği verildiğinde belirli bir sınıfta olma olasılığını tahmin etmekti, p (π i k = 1 | D i). Ancak, bu süreçte, modelin nasıl oluşturulduğunu t anımlayan bir ortak dağılımı tanıttık ve maksimize ettik: p (π i k = 1 , D i) = p (D i | π i k = 1) p (π i k = 1). Aslında, bunu, bazı bileşenlerin an alist tarafından önceden etiketlendiği Bölüm 3: Keşif'te tartıştığımız tü rde bir karışım modeli olarak düşünebiliriz.

Jeneratif modelin çekici bir yönü, algoritmaları oluşturma, uyarlam a ve yorumlama konusunda bize bir yol sağlamasıdır. Örneğin, yukarı daki algoritmayı tanıtırken, bazı kelimelerin sıfır olasılığını tahmin etm e sorununu çözmek için küçük bir sabit *c* eklemeyi tartıştık. Bu süreci, sahte belgenin ön dağılımın bir sonucu olarak ortaya çıktığı bir Bayes ian önceliği eklemek olarak yorumlayabiliriz. Benzer şekilde, kelimeler deki patlama endişelerini, multinomialin daha karmaşık bir karşılığı ol an Dirichlet bileşik multinomialini benimseyerek ele alabiliriz (Elkan, 2006). Üretken modeller, daha karmaşık modellere mükemmel yapı taşla rı oluşturur; zaten çoklu dağılımların karışımının Latent Dirichlet Allocatio n'a ve nihayetinde Yapısal Konu Modeli'ne yol açtığını gördük.

Ancak, sınıflandırma görevleri için, üretken modellerde biraz garip bir ş ey var. Eğer ilgimiz p (y i | D i) öğrenmekse, neden p (D i | y i) öğrenmey e çalışmalıyız? Girdi ile sonuç etiketine haritalayan bir fonksiyonu öğrenme k için p (y i | D i)'yi doğrudan maksimize edemeyiz mi? Aslında edebiliriz v e bu, birçok sosyal ve veri bilimcinin regresyondan tanıdığı ayrıştırıcı model lere yol açar; bu modellerde, belgeleri temsil etmek için kullandığımız özelli kler üzerinde yalnızca koşullandırırız, bu nedenle onlar için bir model üret memize gerek yoktur. Bu, y i'yi tahmin etmek için kullandığımız özellikler X i için herhangi bir üretken model varsaymadığımız regresyon alanında birç ok sosyal ve veri bilimcisine tanıdık gelecektir.

Ayrıştırıcı Naive Bayes modelinin analoğu çoklu lojistik regresyond ur (bazen lojistik regresyon veya bilgisayar bilimlerinde softmax sınıfl ayıcı olarak adlandırılır). Model şu şekilde verilebilir:

$$p (\pi i k = 1 | W i ,) \propto \exp (W i , \mu) . (19.1.12)$$

Ng ve Jordan (2002), teorik ve ampirik olarak, lojistik regresyonun daha yüksek asi mptotik doğruluğa sahip olduğunu, Naive Bayes'in ise asimptotik doğruluğa daha hızlı ulaştığını göstermektedir. Diğer bir deyişle, küçük eğitim örnekleri için Naive B ayes'in lojistik regresyondan daha iyi bir performans sağlamasını beklemeliyiz.

Doclingo https://www.doclingo.ai

varsayımlar yaklaşık olarak geçerliyse regresyon. Bu sezgisel olarak mantıklıdır. Naive Bayes'e ulaşmak için yaptığımız ek varsayımlar, bize sorun üzerinde biraz avantaj sağlıyor, ancak yeterince verimiz varsa, nihayetinde ihtiyacımız olan tüm parametreleri öğrenebiliriz. Bu aynı fikir, asimptotik verimlilik, Çok Değişkenli Ters Regresyon'un (Bölüm 11), bu aynı zamanda çok terimli bir üretken model varsayar (Taddy, 2013).

Ayrıştırıcı modeller, farklı türdeki kovaryatların ayrı uygulamaları nı gerektirmediğimiz için araç kutumuzun da yararlı üyeleridir. Örn eğin, Naive Bayes'e ek bilgi eklemek için, sosyal medya gönderisin deki oy sayısını belirtmek üzere modeli değiştirmemiz gerekecektir . Lojistik regresyonda, kelime sayımlarıyla birlikte değişkeni basitçe ekleyebiliriz. Kolaylık bedeli olsa da, girdi değişkenlerinin bir mode lini yazmak, girdilerde eksik verilerle başa çıkmayı kolaylaştırmak g ibi diğer faydalar da sağlar.

Üretken ve ayırt edici modeller her zaman net bir ikilikte mevcut değildir. Bir m odel bazı değişkenler için üretken bir süreci belirleyebilir, ancak diğerleri için belirl emeyebilir. Naive Bayes'in küçük veri setlerindeki başarısının bir kısmı neredeyse k esinlikle üretken yapıya atfedilebilir, ancak bu aynı zamanda Naive Bayes'in milyonl arca eğitim örneği içeren üretim düzeyindeki sistemlerde neden nadiren görüldüğ ünü de açıklar.

19.1.3 NAIVE BAYES BİR DOĞRUSAL SINIFLANDIRICIDIR

Bu bölümde incelediğimiz modellerde ortak bir tema, bunların bazı özell ikler setinde doğrusal olarak ifade edilebilmesidir. Bu, sınıflandırma kararı nın şu şekilde ifade edilebileceği anlamına gelir:

$$y\,i\hat{}= f\,\mu\,0 + \sum j = 1\ J\ \mu\ j\ W\ i\ j\ , \quad (19.1.13)$$

burada f ( ) fonksiyonu özelliklerin doğrusal kombinasyonunu tahminin çı ktı alanına dönüştürür ve μ, yukarıda tanımlandığı şekilde μ ile örtüşmek zorunda değildir.

Aslında, Naive Bayes sınıflandırıcısının 19.1.11 numaralı denklemin logaritmik formunun 19. 1.13 numaralı denklemin formuyla eşleşecek şekilde düzenlenebileceğini görebiliriz:

$$y\,i\hat{}= \arg\max k \breve{}\ f\ (\ )\ \log\ (\ \alpha\hat{}k\ ) \breve{}\ \mu\ \tilde{}0 + \sum j\ J\ W\ i\ j\ \log\ (\ \mu\hat{}k\ j\ ) \breve{}\ \mu\ \tilde{}j$$
$$(19.1.14) = f\,\mu\,\tilde{}0 + \sum j = 1\ J\ \mu\ \tilde{}j\ W\ i\ j\ . \quad (19.1.15)$$

Doğrusal sınıflandırıcılar, eğitmek ve uyarlamak için oldukça hızlıdır ve ma kine öğrenimindeki daha sofistike alternatiflerine göre aşırı uyum sağlama eğilimleri çok daha düşüktür. Ancak, anlamlı etkileşimleri yakalayamazlar.

Doclingo https://www.doclingo.ai

özellikler. Bu, sağladığımız özelliklerin algoritma için anlamlı ve yararlı o lduğu ortamlarda iyi çalışır. Bir sonraki bölümde, daha fazla veri talep e tme maliyetiyle daha iyi özellikler oluşturabilecek daha geniş bir seçene k setini ele alacağız.

Doclingo https://www.doclingo.ai

19.2 Makine Öğrenimi

Naive Bayes, en basit makine öğrenimi modellerinden biridir, ancak birço k başka seçenek de vardır. Burada, koşullu yoğunluğu modellemenin birkaç yolunu, yani y i'nin W i ile nasıl ilişkili olduğunu ele alıyoruz. Bu yöntemler, ke yfi girdilere ve esasen keyfi çıktılara sahip her türlü tahmin problemi için gen eldir.

Temelde tüm makine öğrenimi sınıflandırıcıları, aşağıdaki optimizasyon probleminin bi r örneği olarak görülebilir (Mullainathan ve Spiess 2017 tarafından yapılan mükemmel inc eleme makalesinden ilham alınmıştır).

$$\arg\min \mu \sum i = 1 N L (f (W i , , \mu) \smile \text{function of } W i , , y i) \backsim \text{training loss} + R (\mu , \lambda) \smile \text{regularization} \quad (19.2.1)$$

Kelimeyle ifade etmek gerekirse, karmaşıklık kısıtlaması R (·) ile tanımla nan bir fonksiyon f (·) belirleyerek, kayıp fonksiyonu L (·) tarafından belirl enen eğitim setimizdeki hatayı minimize ediyoruz. Bu başlangıçta bunaltıcı görünebilir, ancak basit sıradan en küçük kareler modeline başlayalım. Bur ada kayıp fonksiyonu kare hataların toplamıdır, fonksiyon bir lineer tahmin cidir ve herhangi bir düzenleyici yoktur, böylece,

$$L (f (W i , , \mu) , y i) = (y i - f (W i , \mu)) 2 \quad (19.2.2)$$ $$f (W i , , \mu) = W i , \mu \quad (19.2.3)$$ $$R (\mu , \lambda) = 0 \quad (19.2.4)$$ $$\arg\min \mu \sum i = 1 N (y i - W i , \mu) 2 . \quad (19.2.5)$$

Bu model birçok sosyal bilimciye tanıdık gelecektir. Modelin çekici bir yanı görece basitliğidir. Model tahmini $\hat{y} i = W i , \mu = \Sigma j W i j \mu j$ olarak , her özellik W i j için farklı bir ağırlık olan μ j ile belge *i* üzerinde özelli klerin toplamı olarak düşünülebilir.

Farklı sonuç türlerini tahmin etmek için farklı kayıp fonksiyonları kullanabiliriz. Doğrusal regresyon sürekli bir sonuç için temel mod elken, *softmax sınıflayıcı* multi-kategori bir sonuç için temel model dir. İsim, bir dizi reel değerli sürekli sonucu *a* softmax fonksiyonu k ullanarak bir dizi değere eşleyen fonksiyondan gelmektedir. Burad a 1'den *K* toplam kategorilere kadar kategori *k* belirtmek için *k* kull anacağız.

$$\sigma (a) k = \exp (a k) \sum k ' = 1 K \exp (a k ') .$$

Tam model şu şekilde yazılabilir:

Doclingo https://www.doclingo.ai

L (f (W ben , , μ) , y ben) = - y ben log (f (W ben , , μ)) (19.2.6) f (W ben , , μ) = exp (W i , μ k) Σ k ′ = 1 K exp (W ben , μ k ′) (19.2.7) R (μ , λ) = 0 (19.2.8) arg min μ k Σ ben = 1 N − y i log exp (W ben , μ k) Σ k ′ = 1 K exp (W ben , μ k ′) . (19.2.9)

Bu model, her kategori için her zaman sıfır olmayan ve tüm kategoriler arasında 1'e toplamı olan basit bir doğrusal sınıflandırıcı sağlar.

Altındaki modellerde daha karmaşık f (·) fonksiyon sınıflarını dikkate alacak olsak da, genellikle bunların bazı dönüştürülmüş özellik setleri üzerinde doğrusal bir fonksiyon olarak temsil edilebileceğini göreceğiz. Aslında, bu daha karmaşık modelleri çerçevelemenin bir yolu, özelliklerin doğru dönüşümünü aradıklarını belirtmektir; böylece doğrusal model iyi performans gösterir. Sonraki iki bölümde, özellikleri dönüştürmenin iki farklı yaklaşımını ele alacağız - sabit temel fonksiyonlar ve uyarlanabilir temel fonksiyonlar.

Tablo 19.1, okuyucuya aşina olabilecek bu tür modellerin bazı örneklerini sunmaktadır.

19.2.1 SABİT TEMEL FONKSİYONLAR

Sabit temel fonksiyon modelleri, burada dikkate alacağımız temel sıradan en küçük kareler modeline en yakın olanlardır. Doğrusal tahminci f (W i , μ) = W i , μ, tahminin doğrusal ve eklemeli olduğunu ima eder. Ancak, model, orijinal kovaryantların doğrusal olmayan dönüşümlerini dahil ederek doğrusal olmayan ve etkileşimli fonksiyonları temsil edebilir; bunları h (W i ,) ile göstereceğiz. Artık parametreler açısından doğrusal, ancak orijinal tahminciler açısından doğrusal olmayan f (W i , , μ) = h (W i ,) μ doğrusal tahmincisine sahibiz!

Tablo 19.1. Mullainathan ve Spiess (2017) Tablosu'ndan uyarlanmış sabit temel fonksiyon ve uyarlanabilir temelfonksiyon modellerine bazı örnekler

2 .

	Kayıp Fonksiyonu	Düzenleme
Sabit Temel Fonksiyon Modelleri		
Regresyon	(y ben - W ben , μ) 2	Yok
Kement	(y ben - W ben , μ) 2	∑ j = 1 J | μ j |
Sırt	(y ben - W ben , μ) 2	∑ j = 1 J μ j 2
Destek Vektör Makineleri	maksimum (0 , y ben (W ben , μ))	∑ j = 1 J μ j 2
Uyarlanabilir Temel Fonksiyon Modelleri		
Sınıflandırma ve Regresyon Ağaçları		derinlik, düğümler, bölünmelerde bilgi kazancı
Artırma	sınıflandırıcıların lineer kombinasyonu	öğrenme hızı, iterasyon sayısı
Sinir Ağları	çapraz entropi/ortalama kare hatasıkatman sayısı, nöronlar, yinelemeler	

Doclingo https://www.doclingo.ai

Birçok sosyal bilimci, sabit bir temel fonksiyon türü olarak polinomların veya etkileşimlerin eklenmesi fikrini muhtemelen biliyordur. Örneğin, her bir tahmin edici üzerindeki doğrusal olmayan dönüşümü h (W i j) = (W i j , W i j 2 , W i j 3 … W i j b) *b*. polinomuna kadar tanımlayabiliriz. Ayrıca, h (W i ,) her bir çift etkileşi mi W i j W i j ′ döndürecek şekilde etkileşimleri de dahil edebiliriz. Bu dönüşüm, o rijinal tahmin edicilerin bir temel fonksiyon genişlemesidir. Görüldüğü gibi, herh angi bir sürekli fonksiyon, bazı temel fonksiyonlar kümesi üzerinde doğrusal bir f onksiyon olarak temsil edilebilir. Bu, yalnızca doğru temel fonksiyonlara sahipse k, herhangi bir sürekli fonksiyonu yakalamak için basit bir doğrusal model kullan abileceğimiz anlamına gelir. İşin püf noktası, "doğru temel fonksiyonları" belirtm ektir.

Sabit temel fonksiyon modelleri, tahmin öncesinde bir temel fonksiyon setine bağlı kalan ve ağırlıkları μ optimize edenlerdir. İki tür temel fonksiyo nu düşünebiliriz: küresel ve yerel. Küresel bir temel fonksiyonun, yukarıda tartışılan polinomlar gibi, katsayısı *W*'nin tüm aralığı üzerindeki verilerden etkilenir. Alternatif olarak, belirli bir yerel *W* bölgesindeki verileri modelley en yerel bir temel fonksiyon vardır. Belirli türdeki fonksiyonları modelleme k için farklı temel fonksiyonlar uygundur. Örneğin, spline'lar düzgün fonksi yonları modellemede yetenekliyken, dalgacıklar keskin kesintileri ele alabili r.

Metin gibi belgelerin özelliklerinin basit temsilleri bile yüksek bo yutludur. Temel fonksiyonlar eklemeye başladığımızda, boyut hızla patlayabilir ve oluşturulan özelliklerin sayısı belgelerin sayısını aşa bilir. Bu durumda, bazı ek kısıtlamalar olmadan parametreleri μ ta hmin edemeyeceğiz. Daha basit fonksiyonlar için bir tercih ifade e den bir düzenleyici R (μ, λ) ekleyebiliriz.

Farklı türdeki düzenleyiciler, farklı türde sonuçlar verir. Ridge düzenleyicis i μ 2 2, parametreleri yavaşça sıfıra doğru küçültür. Aksine, Lasso düzenleyici si μ 1, birçok parametreyi tam olarak sıfıra ayarlayan seyrekliği teşvik eder. B u son stratejinin örneklerini, ayırıcı kelimeleri bulma üzerine olan Bölüm 11 ' de gördük. Seyrek düzenleme, çoğu özelliğin tahmin etmeye çalıştığımız mik tar hakkında esasen bilgilendirici olmadığına inandığımız durumlarda yardı mcı olduğu için bu bağlamda ortaya çıktı, ancak hangilerinin olduğunu bilmi yoruz. Örneğin, bir ürün incelemesinin duygusunu tahmin ederken, kelimele rin büyük çoğunluğu ürünün kendisini tanımlıyor olabilir, ancak ürünün olu mlu veya olumsuz bir görüşe sahip olup olmadığına dair nispeten az bilgi taş ıyor olabilir.

Eğer parametreler gerçekten seyrekse, o zaman bir seyrekliği teşvik eden ceza kullanmak

Doclingo https://www.doclingo.ai

yüksek boyutlu durumda tartışmasızdır. Ancak, sosyal bilimlerdeve daha geniş anlamda dilde, dünyanın küçük ama genellikle sıfır olmayan etkilerle dolu olduğuna inanabiliriz; yani, parametre vektörünün *yoğun* olduğunu, seyrek değil. Hastie, Tibshirani ve Friedman (2013) "seyrekliğe bahis yapma" ilkesini tanıtır, bu da analistlerin "seyrek problemlerinde iyi sonuç veren bir prosedür kullanmaları gerektiği" tavsiyesidir, çünkü yoğun problemler için hiçbir prosedür iyi sonuç vermez." Birinin felsefi pozisyonuna bakılmaksızın, seyreklik düzenleme araç setinin önemli bir parçasıdır.

Düzenleme ile sabit temel fonksiyon modelleri, makine öğrenimi yöntemlerinin muazzam bir yelpazesini kapsar ve kendi başlarına bir kitaplık dolusu materyal içerebilir. Modeller, öğrendiğimiz fonksiyonun karmaşıklığı üzerinde büyük kontrol sağlar. Bu modeller, özelliklerin sonuç hakkında çok fazla bağımsız bilgi taşıdığı durumlarda en iyi şekilde çalışır; ayrıca, veri sınırlı olduğunda alternatiflerden daha iyi performans gösterme eğilimindedirler. Aşağıda iyi özelliklerimiz olmadığında alternatifleri değerlendiriyoruz.

19.2.2 ADAPTİF TEMEL FONKSİYONLAR

Özellikler, ilgi alanındaki kategori hakkında bilgilendirici olduğunda, denetimli öğrenme görece kolaydır. En büyük zorluk, düzenleme ile ele alınabilecek yüksek boyutluluk sorunudur. Sorun, karmaşık kategoriler için, kelime sayımlarına dayanan basit özelliklerin, basit sınıflandırıcıları öğrenmek için yetersiz olabileceğidir. Mümkün olduğunda, sınıflandırma sorununu daha kolay hale getiren belirli özelliklerin inşası olan "özellik mühendisliği" ile ilgilenebiliriz. Bunu daha önce Bölüm 2: Temsil'de örneklerini gördük.

Son zamanlarda makine öğreniminde, manuel özellik mühendisliğini, verilerden en öngörücü özellikleri adaptif olarak öğrenen yöntemlerle değiştirme eğilimi olmuştur. Bu, önemli ölçüde daha fazla veri gerektirir ve doğru bir şekilde tanımlanmış sabit bir temel fonksiyon modeli kadar verimli değildir, ancak daha az insan çabası ile birçok başka durumda sınıflandırıcıları öğrenmede son derece etkili olabilir. Bu fikri eylemde görmek için, bir sinir ağı fikrini ele alalım.

Önceden gösterilen softmax sınıflandırıcısını hatırlayın. Burada y i için tahminimizσ (W i , μ) = exp (W i , μ j) Σ j ′ = 1 K exp (W i , μ j ′) ile verildi. Belki deöngörmek istediğimiz kategoriler, W i 'nin basit bir fonksiyonu ile iyi bir şekildeyaklaşmıyordur. W i , = (W i 1 , W i 2 , … , W i J) olan alternatif bir özellik setiolabilir; bu, W i 'nin özelliklerinin bilinmeyen bir fonksiyonudur. σ (W i , μ W i ,)döküman ları kategorilere daha doğru bir şekilde atayabilir.

Doclingo https://www.doclingo.ai

Bu özelliklerin her birini, tüm W i 'lerin bir fonksiyonu olarak öğrenebiliriz vea yrı bir ağırlık matrisini μ W i , kullanarak, böylece W i j = f (W i , μ W) olur. E debiyattabirçok fonksiyon dikkate alınmıştır—şu anda popüler olan bir fonks iyon, W i j = max (0 , μ Wi j W i ,) formuna sahip olan Düzleştirilmiş Doğrusal Birim (ReLu) fonksiyonudur. Bu,yeni özelliklerin her birinin W i 'lerin ağırlık v ektörü μ W i j kullanılarak elde edilen lineer kombinasyonuya da 0 olduğu an lamına gelir; hangisi daha büyükse. Bu özellik setine W i , "gizli katman"deni r çünkü gözlemleyemediğimiz bir özellik setidir.

Önceki bölümde tartışılan sabit temel fonksiyonlar gibi, gizli katman W i , modelin orijinal özelliklerin W i , daha karmaşık, doğrusal olmayan ve etkileşi mli fonksiyonlarını ifade etmesine olanak tanır. Ancak, önceden belirtmemiz gereken sabit temel fonksiyonların aksine, burada bunları verilerden tümeva rımsal olarak öğrenebiliriz. Modeli oluşturma sürecinin bir parçası olarak, giz li katmandaki gizli özelliklerin W i , sayısını kontrol ederiz. Bu gizli özelliklerin sayısı, genellikle katmanın "genişliği" olarak adlandırılır, modelin W i , fonksiy onlarını temsil etme esnekliğini belirler.

"Derin öğrenme" devrimi, hesaplama gücü ve verilerin, yalnızca tek bir giz li katmandan daha fazlasını öğrenmek için kullanılabilir hale geldiğinde başla dı. Araştırmacılar, katmanları üst üste yığarak daha güçlü sınıflandırıcılar inş a edebileceklerini fark ettiler; bu sınıflandırıcılar daha iyi genelleme perform ansına sahipti. Böylece, bir gizli özellik seti bir sonraki gizli özellik katmanını t ahmin eder ve bu şekilde devam eder. Ampirik olarak, araştırmacılar, ağın g enişliğini (her katmandaki gizli özellik sayısını) azaltırken derinliği (üst üste yı ğılmış katman sayısını) artırarak, gizli özelliklerin giderek daha soyut kavraml arı öğrendiğini ve bunların iyi genelleştiğini bulmuşlardır.

Makine öğrenimindeki mevcut çalışmaların çoğu, bu tür derin sinir ağlarına yöneliktir. Bu yöntemlerin başarısı, alanın odak noktasını çeşi tli özellik mühendisliğinden daha karmaşık ağ mimarileri geliştirmeye kaydırmıştır. Burada yalnızca kısa bir özet sunuyoruz çünkü bu hızlı g elişen bir alan ve makine öğrenimi için belirli tekniklerin tanımları birç ok mevcut kitapta yer almaktadır. Derin sinir ağlarıyla başlamanız için Goodfellow, Bengio ve Courville (2016) önerilmektedir. Chang ve Mast erson (2020), sosyal bilimciler için hedeflenen metin üzerinde yaygın olarak kullanılan tekrarlayan sinir ağı modellerine bir giriş sunmaktad ır. Hvitfeldt ve Silge (2021), bu modellerin R'de tahmin edilmesine prat ik bir giriş sağlamaktadır.

19.2.3 NİTELİK

Sonuçları iyileştirmenin farklı bir yolu, ilgi miktarını değiştirmektir.

Doclingo https://www.doclingo.ai

Birçok sosyal bilim uygulaması için ilgi miktarı yalnızca bir kategori deki belgelerin oranıdır ve bireysel sınıflandırmalar değildir. Örneğin, King, Pan ve Roberts'ın sansürlü ve sansürsüz blog yazılarını konusal kategorilere ayırması gerektiğini hatırlayın; bu, Çin sansürün ün motivasyonunu keşfetmek içindi. Onlar, herhangi bir belirli yazının bir kategoride olup olmadığını değil, sansürlü ve sansürsüz yazıların her bir kategoride ne kadar paya sahip olduğunu merak ediyorlardı. Hopkins ve King (2010), odak noktasının her bir K kategorisindeki belg elerin oranını tahmin etmek, p (π) = p (π 1 , π 2 , ... , π K) üzerine old uğunda, bireysel belge sınıflandırmalarını tamamen atlayarak bu hed efe doğrudan odaklanarak doğrulukta önemli iyileştirmeler elde etme nin mümkün olduğunu göstermektedir. Stratejilerine ReadMe adını v ermişlerdir.

Hopkins ve King (2010), metinleri temsil etmek için belirli bir tarifl e başlarlar: her kelimenin bir belgede geçip geçmediğine dair göster geler (genellikle varsaydığımız gibi sayılar yerine). Daha sonra, kelim elerin bağımsızlığı hakkında ek varsayımlar yapılmadığı takdirde, bu temsil altında 2J olası belge olduğunu belirtirler. Bir olasılık dağılımı tanımlayabiliriz. 2 J mümkün belgeler ve bunu p (W) olarak adlandırın, belge dağılımı, kategoriye bağlı olarak p (W | π) (bir 2 J × Kmatrisi) ve ilg i miktarı, sınıflar üzerindeki olasılık dağılımı olarak, p (π), her sınıftaki b elgelerin oranını belirten bir *K* uzunluğunda vektördür. Yine, metinleri t emsil etmek için kullanılan süreçten başka herhangi bir varsayım olmak sızın, metinler için veri üretim sürecini şu şekilde yazabiliriz,

$$p (W) = p (W | \pi) p (\pi) . (19.2.10)$$

Hopkins ve King (2010)'in içgörüsü (King ve Lu'dan elde edilen içgörülere dayanarak 2008) eğer p (W) ve p (W | π) biliniyorsa, o zaman problem basit matris ce birine indirgenir.p (W) test kümesinden tahmin edilebilir, ancak p (W | π)'n in yüksek boyutluluğu,tahmin edilemeyeceğini ima eder. King ve Lu (2008) il e Hopkins ve King (2010),eğitim kümesini ve matris düzleştirme algoritmaları nı kullanarak p (W | π)'yi hesaplamayıve ardından p (π) için çözümlemeyi ö nermektedir. Bu, çok sayıda özellik arasındaki bağımlılığınkorunmasını sağla rken, aynı zamanda sınıflandırma için yararlı bir model tahmin etmektedir.Di kkat edin, Denklem 19.2.10, Naive Bayes modeline çok benziyor, ancak Read Me, Naive Bayes bağımsızlıkvarsayımlarından kaçınmaktadır. Jerzak, King ve Strezhnev (2019) tarafından yapılan daha sonraki çalışmalar,p (W | π) için al ternatif modelleri ele almıştır.

Doclingo https://www.doclingo.ai

Hopkins ve King (2010) içindeki oranlara geçiş, çıkarım için fayda sağlarken, bireysel belge sınıflandırmalarını kaybetme maliyetiyle gelir. Bu, eğitim verileri için gerekli varsayımları zayıflatır. Rastgele bir örnek gerektirmek yerine, verilerin yalnızca kategoriye bağlı olarak özellikleri n dağılımını paylaşması gerekir—p (W | π) (henüz yazılmamış belgeler için daha makul bir varsayım). Ayrıca, çok sayıda kategori ile bireysel bir sınıflandırıcı kullanıldığında meydana gelen önyargıyı düzeltmeye yardımcı olur. Örneğin, beş belgenin her birinin kategori *k* içinde olma olasılığı 0.2 ise, bireysel bir sınıflandırıcı bunların hepsini farklı bir kategoriye yerleştirirken, ReadMe bu tahminleri kategori *k* içindeki belge oranına katkıda bulunabilir.

ReadMe algoritması, az sayıda belgesi olan veya sonuçlarını bir dış kovaryantla ilişkilendirmek isteyen kullanıcılar için daha az pratiktir. Örneğin, ReadMe'yi bireylere göre duygunun nasıl değiştiğini değerlendirmek için kullanamayız. Kovaryantın her değeri için birçok belgemiz olduğunda, ReadMe'yi her bireysel katmanda çalıştırabiliriz, ancak sürekli kovaryantlar veya birçok katmana sahip olanlar için bireysel sınıflandırma kullanmamız gerekecektir.

19.2.4 DENETİMLİ ÖĞRENME ÜZERİNE SON DÜŞÜNCELERRASTGELE ÖRNEKLERLE

Burada tanıttığımız çeşitli algoritmaların karmaşıklığının ötesinde, bir temel fikir vardır. Ölçüm için tamamen makul bir strateji, bir dizi kategori tanımlamak, insanların bu kategorileri kullanarak belgelerin rastgele bir alt kümesini not almasını sağlamak ve ardından bir makine öğrenimi algoritmasını bu kategorileri tahmin etmesi için eğitmektir. Makine öğrenimi algoritması, ölçmek istediğiniz türde belgelerde doğru tahminler yaptığı sürece, ne olduğu çok da önemli değildir. Metin üzerinde uygulanabilecek makine öğrenimi teknikleri hakkında daha fazla bilgi edinmek isteyenler için öneriyoruz: Bishop (2006), Eisenstein (2019), Murphy (2021) ve Aggarwal (2018).

Doclingo https://www.doclingo.ai

19.3 Örnek: Cihat Puanlarını Tahmin Etme

Bu bölümde, Richard Nielsen'ın kitabı *Deadly Clerics'e geri dönüyoruz: Engellenmiş Hırs ve Cihad Yolları* denetimli sınıflandırmanınhareketteki bir örneği için. Nielsen (2017), bazı Müslüman din adamlarının nedenşiddetli cihadı desteklemeye başladıkları sorularını araştırıyor. Şiddeti destekleyenbir ideolojiye yönelmenin başlıca nedeninin engellenmiş hırs olduğunu savunuyor—din adamınınönemli devlet işlerinden dışlanması, hedeflerini etkili bir şekilde engelliyor.

Bu soruya dair kanıt oluşturmak için, web üzerindeki Müslümancleriklerin ilk nüfus sayımını ve cleriklerin çevrimiçi olarak paylaştığı yazıları, makaleleri, kitapları, vaazları ve fetvaları (İslam'daki hukuki hükümler) toplar. Bu metinler, burada odak noktası olan ifade ettikleri ideolojiyi yakalar. Ardından, şiddetli cihadı destekleme ölçüsünü denetimli öğrenme kullanarak oluşturur.

Nielsen (2017), belirli bir clerik için tüm metinleri bir araya getirir. Eğitim kümesi olarak, Nielsen (2017) “bulunan verilerle denetim” veya mevcut etiketler olarak adlandırdığımız şeyi kullanır; “Cihadistin Kitap Çantası” adlı, cihadist ideolojiye giriş sağlamak için tasarlanmış belgeler koleksiyonunu, cihadist olmayan metinlerden derlenmiş belgelerle birleştirir.

Nielsen (2017), bu eğitim kümesini ve derinlemesine açıkladığımız Naive Bayes (NB) modelini kullanarak, herhangi bir clerikin yazılarının Cihadistin Kitap Çantası'na karşılık gelen metinler kümesine sınıflandırılma olasılığını tahmin eder. Bu olasılığı doğrudan kullanmak yerine, modelin çıktısını şiddetli cihadı destekleme ölçüsünün sürekli bir ölçüsü olan “Cihad Skoru”nu hesaplamak için kullanır. NB model varsayımlarının altında, belge *i* için skor, cihad ve cihad dışı için eşit öncelikli oranlar varsayarak, belge *i* 'nin cihad sınıfında olmasının log-odds'udur (Beauchamp, 2011; Perry ve Benoit, 2017). Belge *i* için skor

$$\text{Jihad Score}_i = \sum_j W_{ij} \sum_j W_{ij} \log \frac{\mu_{j1}}{\mu_{j0}} \text{word score}, \quad (19.3.1)$$

$\mu_{j\cdot}$, belgenin ya bir cihatçıdan (μ_{j1}) ya da değilse (μ_{j0}) geldiği durumlarda, kelime *j* görme olasılığını gösterir. Gözlemlenen kelimeyi görme olasılığı bir cihatçı belgede daha yüksek olduğunda, o kelimenin puan katkısı pozitif olacaktır; gözlemlenen kelimeyi görme olasılığı bir cihatçı olmayan belgede daha yüksek olduğunda, puan katkısı daha düşük olacaktır. Böylece, olasılıkların log-oranı, her kelime için bir ağırlık gibi davranır ve bu ağırlıklar, her din adamının yazılarındaki tüm kelimeler üzerinde basitçe toplanır. Bu ağırlıklar, Şekil 19.1'de olduğu gibi incelenebilir.

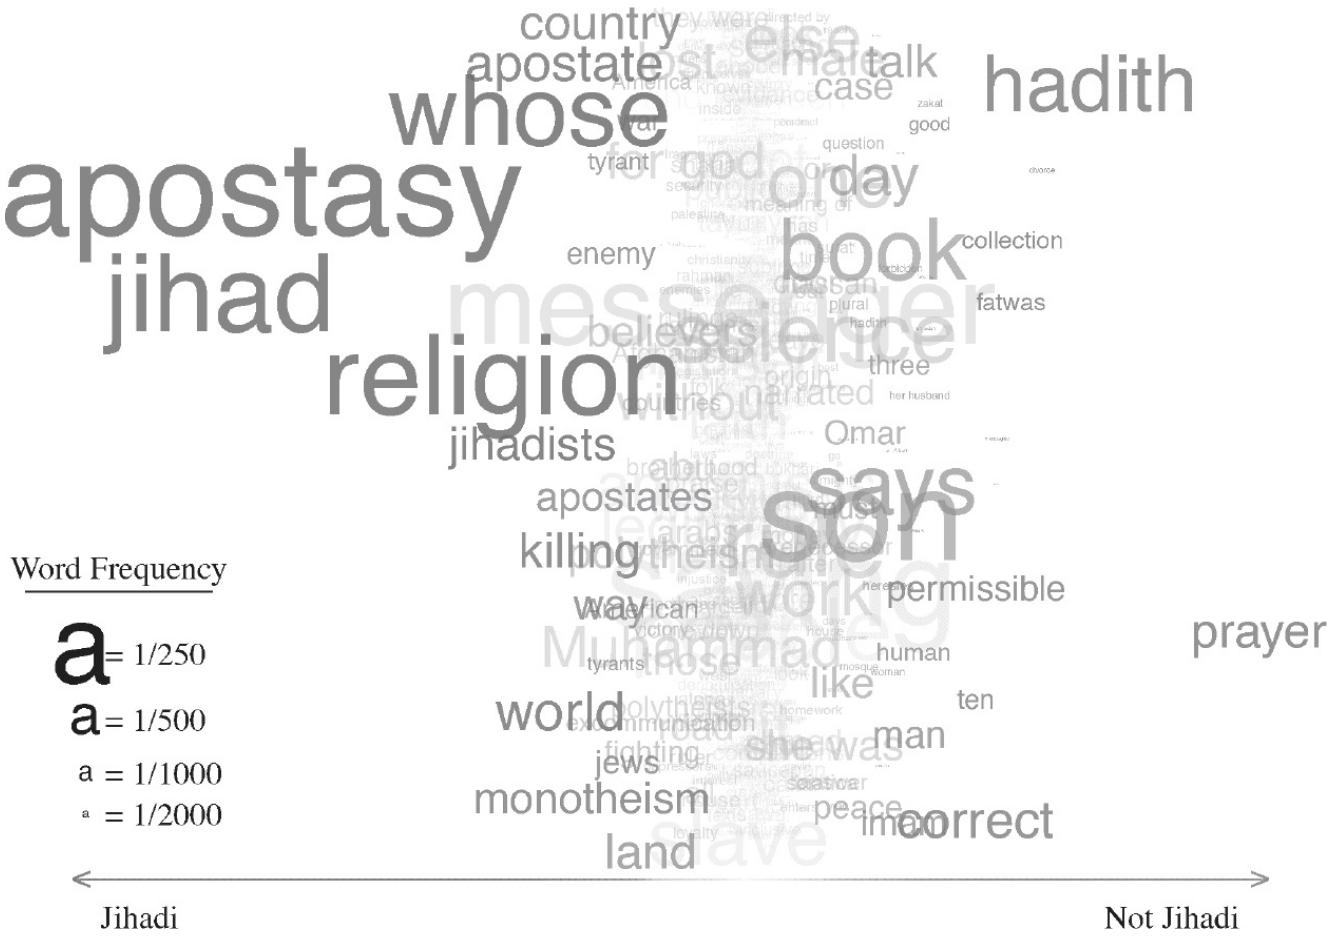
Doclingo https://www.doclingo.ai

Nielsen (2017), her kelimenin her metin kategorisinde görme olasılıkla rını tahmin etmek için eğitim kümesini kullanır. Bu ana parametreler tah min edildikten sonra, veri setindeki her din adamı için puanları oluşturur ve bunları çeşitli şekillerde doğrular, bunları Bölüm 20'de tanımlıyoruz. İf ade edilen ideolojinin bu doğrulanmış ölçüsüyle, din adamlarının şiddeti desteklemeye yönelmesinin önemli bir nedeni olarak engellenmiş hırsı d estekler.

Din adamlarını cihatçı ve cihatçı olmayan ikili kategorilere sınıflandı rmak için NB modelini kullanmak yerine, Nielsen (2017)'in yaklaşımı, ö lçüm olarak öngörülebilirlik olarak adlandırdığımız bir yaklaşımdır. Bu , insanların bazı temel özelliklere atfedilecek kesin sürekli değeri oluşt urmakta zorlanacağı düşük boyutlu gömme yöntemlerinde yaygın bir yaklaşımdır. Bu, Bölüm 11'de özetlediğimiz kurgusal tahmin proble miyle de yakından ilişkilidir; burada bir *tahmin* görevi kullanarak bir boyutun *yoğunluğunu* ölçeriz.

Elbette Nielsen (2017) durumunda, tahmin tamamen kurgusal değil: Aslında, din adamlarını cihatçı ve cihatçı olmayanlar olarak sınıflandırmak f aydalı olacaktır. Nielsen (2017), cihat puanlarını bireyin şiddetli cihadı deste kleme olasılığının bir göstergesi olarak ele almakta genellikle dikkatli olsa da, bazen bunun destek yoğunluğunu da ölçtüğünü öne sürdüğü izlenimin i vermektedir. Diğerleri, bir sınıfın tahmininin ideoloji gibi bir boyutta yoğu nluk ölçümü sağladığı iddiasını daha doğrudan yapmaktadır (Beauchamp, 2011) ve kutuplaşma (Gentzkow, Shapiro ve Taddy, 2019). Bu göre vlerdesonucun öngörülebilirliği, ilgi alanındaki temel boyut için bir ikame işlevdir.

Doclingo https://www.doclingo.ai



Şekil 19.1. Nielsen (2017)'in Cihad Skoru'ndaki her kelimenin ağırlıklarının İngilizce çeviri leri ile grafiği. Şekil 5.2 Nielsen'den (2017).

Denetimli öğrenmenin ölçüm için kullanılmasının ilginç ve yeterince incelen memiş bir komplikasyonu, ölçümün belirsizliğini sonraki analizlere nasıl dahil edeceğimizdir.[1] Ölçümler bir sınıflandırıcının sonucu olduğundan, kaçınılmaz olarak bir hata seviyesi ve dolayısıyla gerçek ölçüm hakkında belirsizlik olacaktı r. Bu belirsizliği hesaba katmazsak, en azından belirsizliğimiz hakkında yanlış b ir algıya sahip olmamıza neden olacaktır. Hatalar analizdeki diğer değişkenlerl e sistematik olarak ilişkiliyse, bu daha da gözden kaçan değişken yanlılığı (Fon g ve Tyler, 2020) getirebilir. Nielsen (2017), din adamı puanları hakkında belirsi zliği değerlendirmek için bir blok bootstrap yaklaşımı kullanarak, her din adam ı için kelimeleri yer değiştirme ile yeniden örnekleyip ardından belirsizliği hesa plamak için puanı yeniden hesaplamaktadır (Benoit, Laver ve Mikhaylov,

2009). Fong ve Tyler (2020), makine öğreniminden elde edilen ölçümlerin aşağı akış analizlerine dahil edilmesi için alternatif bir genel momentler yöntemi yaklaşımını önermektedir.

Doclingo https://www.doclingo.ai

19.4 Sonuç

Bu bölümde, denetimli öğrenme için farklı modelleri gözden geçirdik. Öncelikle, ista tistiksel sınıflandırıcılar için sezgi oluşturmak amacıyla Naive Bayes modelini detaylı bir şekilde ele aldık. Ardından, doğrusal regresyonun sezgisi kullanılarak, hem sabit temel f onksiyon hem de uyarlanabilir temel fonksiyon modellerini kapsayan makine öğrenimi modellerinin sınıflarını gözden geçirdik. Son olarak, Naive Bayes'in bir varyantının, Niels en (2017)'in din adamı ideolojisi ölçütü kullanılarak nasıl uygulandığını gösterdik. Sonra ki bölümlerde, denetimli öğrenmenin son adımı olan doğrulamayı tartışmaya geçiyoruz .

[1]Bu, elle kodlama için de bir sorun olduğunu unutmayın; insan anotasyonundaki hata genellikle aşağı akış analizlerinde göz ardı edilmektedir.

Doclingo https://www.doclingo.ai

BÖLÜM 20

Performansı Kontrol Etme

Bu bölümde, ölçümlerin doğrulanması için bazı yaklaşımları özetliyoruz. Ölçüm, verilerin kategorilere veya sürekli bir çizgide bir değere sıkıştırılma sıdır—bir kavramın belirli bir operasyonelleştirilmesi. Doğrulama süreci ar acılığıyla, sıkıştırmamızın incelemek istediğimiz kavramı yansıttığından ve s ıkıştırdığımızı doğru anladığımızdan emin oluruz ve hangi bilgileri attığımız ı belirleriz. Ölçümümüzün, modelimizi eğitmek için kullandığımız veriler dış ında iyi performans gösterdiğinden emin olmak için doğrulamayı kullanırız .

Birçok doğrulama tekniği vardır ve tek bir net organize edici çerçeve yoktur. Ancak, çeşitli seçenekleri birleştiren bir temel ilke vardır: yanlış olduğu kanıtlanma zafiyeti. Ölçümlerimizi, yalnızca doğru çalıştıklarında geçme olasılığı yüksek olan testlere sürekli maruz bırakarak, hem kend imize hem de okuyucularımıza ikna edici olabilecek bir kanıt temeli oluş turmaya başlarız.

Hiçbir doğrulama miktarı, doğru olduğumuzu tamamen garanti edemez v e farklı ortamlar, farklı kesinlik seviyeleri ve dolayısıyla farklı doğrulama seviy eleri gerektirecektir. Ancak her durumda, bir değerlendirme döngüsü oluştu rmaya çalışmayı vurguluyoruz - araştırma süreci boyunca ve dağıtım sonrası nda (devam eden ölçümler için) ölçümün doğrulanması ve ardından güncelle nmesi süreci. Bu, modelimiz üzerinde düzenli, dışsal bir kontrol sağlar. Bu kit apta ortaya konan ilkelere yansıdığı gibi, hiçbir metin modelinin kendini haklı çıkardığına inanmıyoruz ve bu nedenle herhangi bir yöntemi doğrulamadan körü körüne kullanmaktan kaçınmalıyız.

Doğrulamak ne anlama geliyor? Temelde, doğrulamalar, ölçümü n ilgilendiğimiz olguyu yakaladığını gösterir. Ölçümde, kavram ho mojenliği varsayımını örtük olarak çağrıştırıyoruz (Goertz, 2008; Teune ve Przeworski, 1970; Gerring ve Thomas, 2005), ölçümün geri kazanmaya çalıştığı kavramsal boyutl a ilgili olarak aynı ölçüm değerine atanan iki gözlemin eşdeğer old uğunu belirtmektedir. Kavramsal boyutun, ilgilendiğimiz teorik ölç ümümüzü yakaladığı ve gözlemlerin kavramsal boyutta doğru bir ş ekilde yerleştirildiğini değerlendirmeye çalışıyoruz.

Doclingo https://www.doclingo.ai

20.1 Altın Standart Verilerle Doğrulama

En basit durum için altyapıyı belirleyerek başlıyoruz. Denetimli öğren im için dört bileşen içeren kanonik bir ayarda olduğumuzu varsayıyoruz : karşılıklı olarak dışlayıcı ve kapsamlı bir kategori seti, bu kategoriler içi n altın standart etiketlere sahip, ilgi popülasyonundan rastgele örnekle nmiş bir belge seti, ölçmek istediğimiz etiketlenmemiş belgeler seti ve a ltın standart etiketlerden etiketlenmemiş belgelere dışsallaştırma yapa n bir istatistiksel sınıflandırıcı. Altın standart ile, etiketlerin doğru bir şe kilde kodlandığı ve ilgi kavramını mükemmel bir şekilde yansıttığı anla mına gelir. Sınıflandırıcının doğruluğunu altın standart etiketleri kullana rak değerlendirebiliriz.

Tablo 20.1. Bir karışıklıkmatrisinin örnek formatı.

	C 1	C 2	C 3	C 4	Makine
C 1	N 1 1	N 1 2	N 1 3	N 1 4	N 1 ,
C 2	N 2 1	N 2 2	N 2 3	N 2 4	N 2 ,
C 3	N 3 1	N 3 2	N 3 3	N 3 4	N 3 ,
C 4	N 4 1	N 4 2	N 4 3	N 4 4	N 4 ,
İnsan	N , 1	N , 2	N , 3	N , 4	N

20.1.1 DOĞRULAMA KÜMESİ

Sınıflandırıcıyı, modeli uyarlamak için kullandığımız verilerden farklı verilerle doğrulamak istediğimizi unutmayın. Bu, modelimizi uyarlamak için tüm altın standart etiketli verilerimizi kullanmamamız gerektiği anlamına gelir. Bunun yerine, modelin bu ayrılmış verilerdeki perf ormansını test edebilmemiz için, *doğrulama kümesi* olarak adlandırdığımız bir veri setini dış arıda bırakmalıyız.

Altın standart belgelerimizi bir eğitim ve doğrulama kümesine ayırıyoruz. Eğitim belgeleri, bir eşleme fonksiyonu elde etmek için kullanılabilir ve doğr ulama kümesindeki doğruluğu değerlendirebiliriz. Doğrulama kümesi etiketl i veriler içerdiğinden, doğrulama kümesindeki etiketleri, onun için tahmin ett iğimiz etiketlerle doğrudan karşılaştırabiliriz. Bu karşılaştırmayı, tahminleri t anımlayan satırların ve altın standart kodlarını karakterize eden sütunların b ulunduğu K × K çapraz tablo olan bir *karışıklık matris*ı kullanarak yapabiliriz. Her hücre, ilgili satır ve sütundan sınıflandırma alan belgelerin sayısını tanım lar. Modelin yeni bir belge için tahmin edilen bir sınıf ürettiği ve başka hiçbir bilgi (örneğin, tahmin edilen bir olasılık) sağlamadığı basitleştirilmiş durumda,

Doclingo https://www.doclingo.ai

karışıklık matrisinin genellikle en ilgili performans bilgilerini basit b ir özetini sağladığını belirtir.

Örneğin, N 1 2, bir otomatik yöntemin 1 olarak kodladığı belgelerin sayısı nı, altın standartın 2 olarak etiketlediğini tanımlar. Genel olarak, Tablo 20.1'd eki çapraz elemanlar büyükse, yöntem iyi performans gösteriyor demektir.

Model performansını değerlendirmek için karışıklık matrislerini doğrud an kullanmak zor olabilir; bu nedenle matrisleri özetlemek standart bir uyg ulamadır. Kullanılan en belirgin üç özet şunlardır: (1) Doğruluk - doğru sınıf landırılan belgelerin oranı, (2) Kategori k için Kesinlik - kategori k'ya doğru sınıflandırılan belgelerin sayısı, kategori k olarak sınıflandırılan toplam belg e sayısına bölünmüştür, ve (3) Kategori k için Hatırlama - doğru sınıflandırıl an kategori k belgelerinin sayısı, kategori k'daki altın standart belgelerin sa yısına bölünmüştür.

Doğruluk = N 1 1 + N 2 2 + N 3 3 + N 4 4 N; Kesinlik k = N k k Σ k ′ = 1 K N k k ′; Hatırlama k = N k k Σ k ′ = 1 K N k ′ k

Performans için hangi metriğin kullanılacağı, ilgi alanına bağlı ol acaktır. Bazen, uygulamada kesinliği hatırlamadan daha önemli kıl an özel hususlar vardır. Örneğin, e-posta için spam filtresini düşün ün; bu durumda, önemli bir mesajı spam klasörüne koymak, bir sp amın gelen kutusuna girmesinden daha maliyetlidir.

Spam filtresi, bu nedenle spam'ı sınıflandırmanın doğruluğunu (spam'in gerçekten spam olduğundan emin olmak) hatırlama (tüm spam'ı spam kutusuna koyma) üzerinde öncelikl endirmelidir.

Öte yandan, sosyal bilimlerde birçok görev “iğneyi tanımlamaya” çalı şmakta ve belirli bir katmandaki (örneğin bir zaman dilimi veya yazar) b elirli bir kategorideki belgelerin oranını ölçmekte, farklı hatalara yaklaşı k eşit ağırlık verilmektedir. Bu durumlarda, belge düzeyinde doğruluk, hassasiyet ve hatırlama, oran tahminindeki yanlılıktan daha az önemlidi r. Her spesifik araştırma görevi için, araştırmacılar model performansın ın en ilgili metriklerini dikkatlice değerlendirmelidir.

20.1.2 ÇAPRAZ DOĞRULAMA

Doğrulama, modelin uyum sağladığı, doğruluğunun kontrol edildiği ve ardından mo delin ayarlandığı veya değiştirildiği ve tekrar uyum sağlandığı yinelemeli bir prosedürd ür, doğruluk tekrar kontrol edilir.[1] Bu ayarlarda yalnızca bir doğrulama seti kullanırsak, prosedürümüz muhtemelen o belirli doğrulama setine aşırı uyum sağlayacaktır. Bunu e le almak için, çapraz doğrulama (Efron ve Gong, 1983; Hastie, Tibshirani ve

Doclingo https://www.doclingo.ai

Friedman, 2013). V-katlı çapraz doğrulamada, eğitim seti rastgele V (v = 1 .. ., V) gruplarına ayrılır. Modelin performansı her bir grup üzerinde değerlen dirilir, tüm tahminlerin örnek dışı veriler üzerinde yapılması sağlanır. Her g rup için *v*, model V - 1 diğer grup üzerinde eğitilir, ardından performansı d eğerlendirmek için *V* 'inci gruba uygulanır. V-katlı çapraz doğrulama, perfo rmansın *V* ölçümlerini oluşturur, bu da herhangi bir modelin değerlendiril mesi için ortalaması alınabilir. Çapraz doğrulama faydalıdır - aşırı uyumu ö nler, örnek dışı tahmine odaklanır ve aday modeller setinden temel veriler için en iyi modeli seçer (bu Oracle özelliği olarak bilinir) (van der Vaart, Dud oit ve van der Laan, 2006).[2]

Çapraz doğrulama, örnek dışı uyumu yaklaşık olarak tahmin etmenin yararlı bir yöntemi olsa da, bu yalnızca altın standart belgelerin ilgi popülasyonundan rastgele bir örnek olması durumunda ilgi duyulan tahmin hatasının doğru bir tahminini sağlar. Örneğin, eğer amaç 1993'ten gelen bir haber gönderisi eğiti m kümesinden bugünkü internet haber gönderilerini kategorize etmekse, hat amızı doğru bir şekilde tahmin etmemiz pek olası değildir. Bu örnek tuhaf görü nebilir, ancak birçok makale henüz yazılmamış belgeleri sınıflandıracak sisteml er kurmaya çalışmaktadır. Kavramsal kayma veya veri üretim sürecinde başka bir değişiklik olduğunda, iyi bir çapraz doğrulanmış performans elde etmiş ols ak bile hatamızın doğru bir tahminine sahip olamayız.

20.1.3 ALTIN STANDART VERİLERİN ÖNEMİ

Yukarıdaki örnekler, tamamen doğru altın standart verilere sahip olduğum uzu varsayıyor, ancak gerçekte bu zor olabilir. İnsan kodlama genellikle altın st andart olarak düşünülür, ancak insan kodlu bir eğitim kümesi oluşturmak yanl ış yorumlama, karmaşık kategoriler veya kodlayıcı eğitiminin eksikliği nedeniyl e zorlayıcı olabilir. Bölüm 18'de tartıştığımız gibi, etiketlerin doğru olduğu vars ayımına dayanan sınıflandırıcıyı doğrulamadan önce, insan kodlu eğitim veri k ümesini kodlayıcılar arası güvenilirliği değerlendirerek doğrulamak önemli bir ilk adımdır.

20.1.4 DEVAM EDEN DEĞERLENDİRMELER

Büyük projelerin birçoğunda, verilerin uzun bir süre boyunca sürekli olarak to planması için tasarlandığı görülmektedir. Bu tür ortamlarda, sınıflandırıcı perfor mansının alışkanlık haline getirilmiş değerlendirmesini sistemin bakımına entegr e etmeyi şiddetle öneriyoruz. Kısa süreler içinde bile değişiklikler performansı dr amatik bir şekilde değiştirebilir. Twitter'da duygu değerlendirmesi yapmak üzere tasarlanmış bir sınıflandırıcıyı düşünün. Dil hızla evrimleşmekle kalmıyor, aynı za manda platformları kullanan insanların popülasyonu da öyle. Bu tür değişiklikler,

Doclingo https://www.doclingo.ai

orijinal doğruluk tahmininde hesaba katılmamaktadır.

Doclingo https://www.doclingo.ai

20.2 Altın Standart Verisi Olmadan Doğrulama

Eğitim kümesinin doğrulama için kullanabileceğimiz bir altın standart veri havuzu olarak güvenilir olduğundan daha az emin olduğumuzda, performansı kontrol etmek daha zor hale gelir. İnsan kodlamasında bilinen hatalar, eğitim kümesi için bulunan verilere bağımlılık veya sınıflandırma için denetimli öğrenme yerine sözlük yöntemler inin kullanılması gibi birçok nedenle altın standart verisinden yoksun olabiliriz. Bu du rumlarda, altın standart verisinin eksik olmasını, belgelerin etiketlenmesinin ilk aşam alarındaki insan çabasının yükünü doğrulama aşamasına kaydırmak olarak görüyoru z. Ve eğitim setimizin altın standarda yakın olduğuna inandığımızda bile, aşağıdaki d eğerlendirmeler sınıflandırıcının davranışını değerlendirmek için hala faydalı olabilir. Burada, altın standart verisi olmadan doğrulama için bazı yaklaşımlar sunuyoruz. Anc ak, bunların birbirini dışlayıcı olmadığını ve kapsamlı olmadığını, genel olarak her uy gulamaya göre uyarlanması gerektiğini belirtmekteyiz.

20.2.1 YERİNE GEÇİCİ ETİKETLER

Altın standart verilere sahip olmasak da, yine de bize doğru yold a olduğumuzu gösteren yeterince yakın bir yaklaşım olanikame eti ketleri toplayabiliriz. Psikometrik literatürde bu genelliklebaşka ilgi li ölçümlerle uyum sağladığımızı belirleyen *yakınsama geçerliliği*ka psamında değerlendirilir (Adcock ve Collier, 2001). İçin örneğin, eğer haber makalelerini konuya göre kategorize etmeye çalışıyorsak, onları gazetedeki göründükleri bölümle veya çevrimiçi bir veritabanında verile n bir etiketle karşılaştırabiliriz. Yaklaşık olmalarına rağmen, etiketlerimizin ve b u dış etiketlerin birbiriyle bir miktar örtüşmesini beklemeliyiz.

Yaklaşık etiketler, doğrulama sürecinin önemli bir parçası olabilir, ancakbunlar altın st andart veriler değildir. İki şekilde bizi yanıltma potansiyeline sahip olduklarını vurguluyoru z. Bu, bu yöntemleri kullanmamak için bir neden değil, daha çok neyi yapıp neyi yapamay acakları konusunda dikkatli olmamız gerektiğini ifade ediyor.

Öncelikle, yaklaşık etiketlerin yalnızca en uç durumlar hakkında bilgi verme eğiliminde olduğunu belirtmek gerekir. Bu, ölçümlerin zor olduğ u veya kesin bir altın standart elde etmenin imkansız olduğu durumlard a dikkatli olmamız gerektiği daha geniş bir noktadır. Bu, ölçümlerimizin yüzeyde sahip olduğu gibi ayrım gücünden yoksun olduğunu fark etm ediğimiz durumlara yol açabilir. Goertz (2008), ölçümle ilgili daha genel bir endişeyi "gri alan" olarak adlandırmaktadır; bu, birbirinden gerçekte n ayırt edilmeyen bir ölçek boyunca ara noktalar aralığıdır. Demokrasi i çin Polity ölçeğini kullanarak bir örnek verir; bu ölçek -10'dan +10'a kad ar uzanmaktadır. En uç değerleri (-10 ve +10) alırsanız, bunların 2

Doclingo https://www.doclingo.ai

Verilerin %3'ü ve diğer tüm değerler rastgele uniform çekimlerle değişti rilirse, ilgi ölçüsü ile 0.5 korelasyon gösteren bir ölçüm elde edersiniz. B uradaki endişe, kendimizi tüm bir boyutta iyi ayrım yapan bir ölçümüm üz varmış gibi kolayca kandırabilmemizdir, ancak aslında sadece iki uç arasında kaba bir ayrım yapmaktadır.

İkinci endişe, ikame etiketlerin genellikle rastgele seçilmemesi ve dolayısı yla ilgi popülasyonunu temsil etmemesidir. Bu, ikame etiketlerin mevcut veri lerden bulunması veya oldukça nadir bir kategorinin doğruluğunu değerlen dirmekle ilgilendiğimiz için olabilir; bu da verimli bir şekilde değerlendirmek i çin orantısız derecede büyük bir rastgele örneklenmiş belge sayısı gerektireb ilir. Neyse ki, bu amaç için özel olarak geliştirilmiş değerlendirme tasarımları vardır (King ve Lowe, 2003).

20.2.2 KISMİ KATEGORİ TEKRARI

Doğrulama ile ilgili zorluklardan biri, kategorilerin sayısının tüm kategoriler için doğrulamak veya yüksek performans elde etmek için çok büyük olmasıdır. Ancak, 100 veya daha fazla kategorinin bulunduğu ortamlarda bile, genellikle yalnızca ilgi miktarıyla ilgili bir alt küme (veya kategorilerin bir toplamı) vardır. Bu ortamlarda, yalnızca ilgi alanındaki kategorilerin alt kümesi için bir kod kita bı yazmak (geri kalanları başka bir kategoriye gruplamak) ve standart denetiml i öğrenme ve doğrulama gerçekleştirmek mümkündür. Grimmer (2013*a*) bu ya klaşımı, denetimli yöntem ReadMe'nin yasama kredi talep etme ile ilgili ilgi ala nındaki toplam kategorileri yakalayabildiğini belirlemek için kullanmaktadır.

20.2.3 UZMAN OLMAYAN İNSAN DEĞERLENDİRMESİ

Uzman olmayan insan değerlendirmeleri genellikle faydalıdır. Örneğin, sınıf landırıcının bir kategoriye yerleştirdiği metnin bir örneğini alabiliriz ve başka bi r kategoriden bir müdahili tanıtabiliriz. Sonra insan değerlendiricilerden uyma yan metni bulmalarını isteyebiliriz. Ya da, uzman olmayan insanlardan, insan k odlayıcıların o kategoriyi temsil eden en belirgin kelimelere dayalı etiketler üre tmelerini isteyerek anlamsal geçerliliği değerlendirmelerini isteyebiliriz ve etik etlerini kendi etiketlerimizle karşılaştırabiliriz. İlgili bazı deneysel tasarımların g enel bakışlarını sağladık. 3: Keşif, küme kalitesi dahil (Grimmer ve King, 2011) ve müdahili tespit görevlerinin (Chang ve diğ., 2009) d eğerlendirmeleri. İkili karşılaştırmalar ve sıralama görevleri, değerlendirmeleri talep etmenin başka bir yararlı yoludur (Lowe ve Benoit, 2013; Carlson ve Mon tgomery, 2017).

Doclingo https://www.doclingo.ai

20.2.4 DIŞ BİLGİLERLE UYUM

Doğru ölçümler, dış bilgilerle belirli ilişkiler taşımalıdır. Bu ilişkiler öncede n tahmin edilebilir ve belirlenebilir olduğunda, hipotez geçerliliğini değerlen direbiliriz. Örneğin, Temsilciler Meclisi'ndeki Kongre konuşmalarındaki dalga lanmaların büyük haber olaylarına dayanarak öngörülebilir olmasını bekleye biliriz (Quinn ve diğ., 2010) veya Senato'daki komite başkanlarının kendi kom iteleriyle ilgili konular hakkında daha fazla konuşmalarını bekleyebiliriz (Grim mer, 2013b).

Hipotez geçerliliğinin anahtarı, gözlemlenen ilişkiyi görmemenin, ölçüm kötü performans gösterdiği durumlar dışında son derece olası olmadığı şe kilde hipotezleri dikkatlice seçmektir. Bu genellikle araştırmacıların yeni ölç ümlerinin bazı beklenen ilişkileri gösterdiğini ve ardından ana bulgularında beklenmedik bir ilişki gösterdiği bir paradoks yaratır.

Doclingo https://www.doclingo.ai

20.3 Örnek: Cihad Puanlarının Doğrulanması

Altın standart verilerin yokluğunda doğrulamanın nasıl görünebilece ğine dair bir fikir vermek için, Nielsen (2017) cihad ölçeğinin geliştirilme si için doğrulama sürecini tanımlıyoruz, bunun bağlamını ise Bölüm 18. Nielsen (2017, Ch. 5) ölçümünün farklı varsayımlarını ve performans nitelikl erini değerlendirmek için sekiz parçalı bir doğrulama kullanmaktadır. Bu, altın standart verileri elde etmenin zorluğu nedeniyle, ölçekleme çalışmasının motiv asyonunun bir parçası olarak özellikle zor bir durumdur. Önemli olarak, birçok doğrulama, metin örneklerinin yakın okumalarıyla eşleştirilmiştir.

Doğrulama 1: Etiketlenmiş belgelerin temsili. Nielsen (2017) ölçeğin iki uç nokta ile belirlendiği "bulunan verilerle denetim" stratejisini ku llanmaktadır: Cihadistlerin Kitap Çantası olarak adlandırılan bilinen c ihadistlerden oluşan bir belge seti. Bu belgeler, bu amaç için not edil memiş olan "bulunan veriler" biçimindedir ve sınıflandırmaya çalıştığ ımız bir belge seti değildir. Sonuç olarak, bu belgelerin Nielsen'in kit apta ortaya koyduğu cihad tanımının temsili olup olmadığını düşün mek önemlidir. Bu metinler seti için teorik bir gerekçe vardır—cihadi stlerin kendileri bu seti oluşturmuştur—ancak Nielsen, içeriklerin cih ad tanımıyla ve akademik topluluğun bu terimi nasıl tanımladığıyla uyumlu olduğunu doğrulamalıdır.

Belge Jihadist'in Kitap Çantası'nda gerçekten ölçmeyi amaçladığı şeyi yansıttığını sağlamak için, Nielsen (2017) eğitim verilerini tanımlamak için $K = 5$ konu ile bir LDA konu modeli çalıştırır. Kitapta, her konu için en yüksek FREX puanlarına sahip beş kelimeyi ve her konu için verilen konunun en yüksek oranlarına sahip üç belgenin başlıklarını sunar. Daha sonra, bu belgelerin yazarlarını farklı konuları kullanmalarına göre kümelere ayırarak belirli cihatçı yazarların örüntülerini gösterir. Bu değerlendirmeler ve materyalin okunması yoluyla, bu belgelerin cihatçı ideolojisinin kendi kavramını doğru bir şekilde yansıttığı sonucuna varır.

Doğrulama 2: Alternatif veri setine duyarlılık. Seçtiği etiketli belgelerin belirli setinin bulgularını etkilemediğinden emin olmak için, Nielsen (2017) çevrimiçi cihatçı kütüphanesindeki "Tevhid ve Cihat Minberi" belgelerini kullanarak yeni bir ölçekleme oluşturdu. Bu veri setini başlangıçta ideolojik olarak çok geniş olduğu için seçmemişti. Yine de, bu veri setinin benzer nitelikte bulgular ürettiğini göstermektedir.

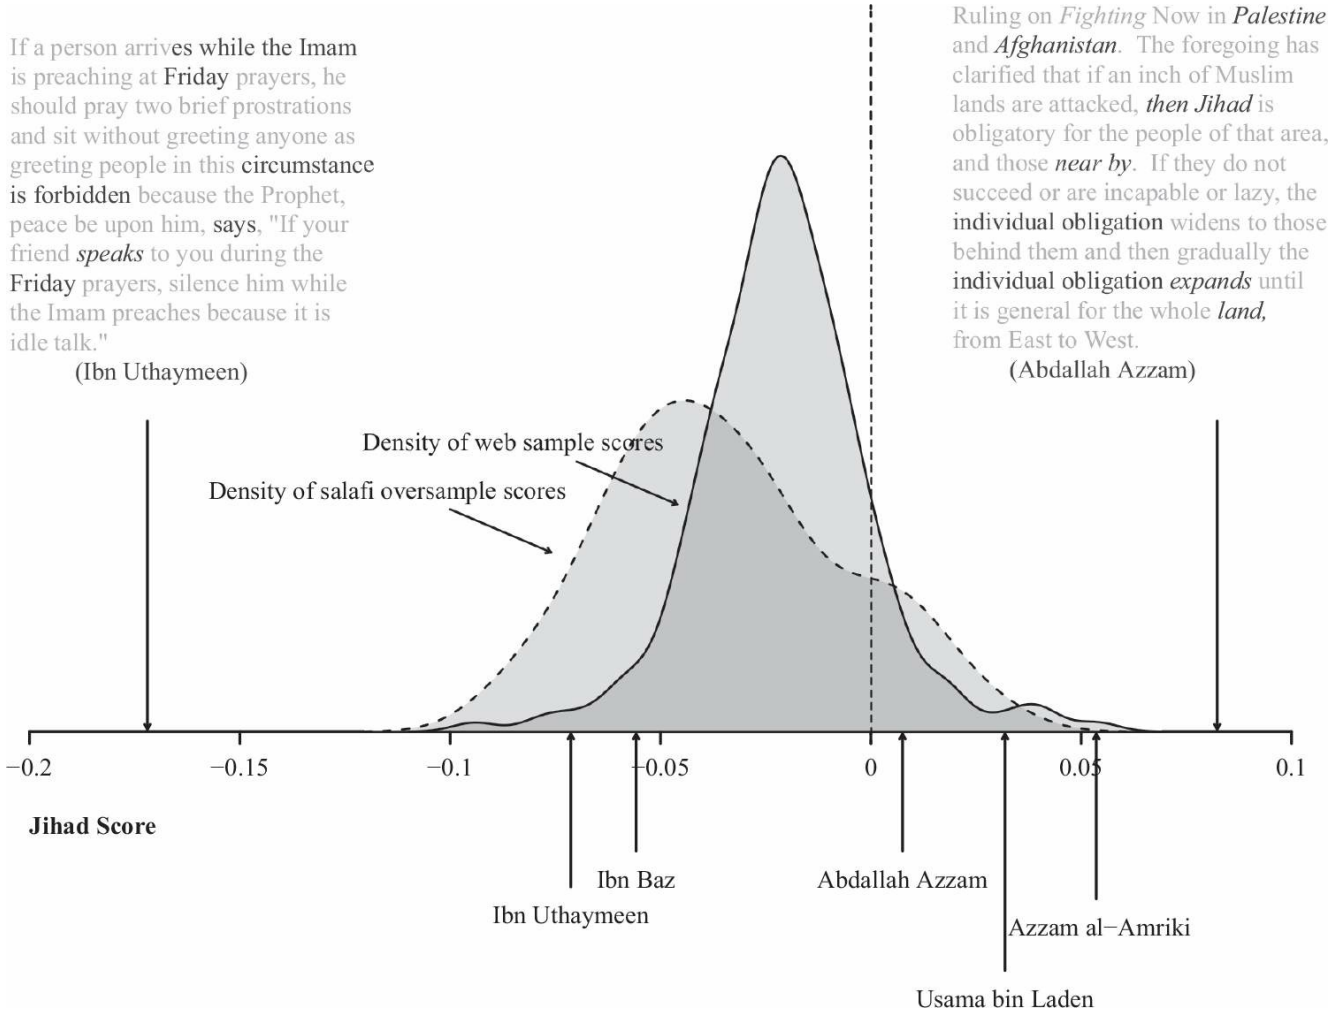
Doğrulama 3: Kelime ağırlıklarını değerlendirme. Bu tür ölçekleme modelleri

Doclingo https://www.doclingo.ai

belgenin puanlanma şeklinin oldukça şeffaf olmasının belirgin avantajı. Nielsen (2017), kelime ağırlıklarını inceleyerek bunların yüzeysel olarak m akul göründüğünü belirtti. Ayrıca, çevrilen sonuçları görselleştirdi (Şekil 1 9.1). Bu, sınıflandırıcının makul bir şey yaptığını garanti etmemize yardım cı olurken, okuyucuya cihadı gösteren kelimeler hakkında daha fazla bilgi iletmektedir.

Doğrulama 4: Bilinen bireyler için elde edilen puanların karşılaştırılması. Nielsen (2017), puanların doğası hakkında bazı temel kontroller rapor etmektedir. Puanların dağılımını gösterir ve anahtar figürlerin puan sürekli üzerindeki yerlerini belirtir (Şekil 20.1). Bu durumu, bu din adamlarının ölçek boyunca neden makul bi r şekilde yerleştirildiğine dair açıklamalarla birleştirir. Ayrıca, ölçeğin en uç noktası ndaki tüm din adamlarını araştırır ve bunların gerçekten aşırı cihadistler olduğunu doğrular.

Doclingo https://www.doclingo.ai



Şekil 20.1. Nielsen (2017) tarafından bireysel din adamlarının doğrulamasını ve yazıların dan çevrilen alıntıları gösteren Şekil 5.3.

Doğrulama 5–8: Dış kaynaklara karşı kontroller. Eğer cihad puanları doğruysa, bun ların uzman bilgi kaynaklarıyla uyumlu olmasını bekleyebiliriz. Nielsen (2017), bu tü r bilgilerin dört kaynağını değerlendirir: (5) din adamlarının biyografileri (bunlar on ları cihadist olarak tanımlayabilir), (6) El Kaide'nin mevcut lideri Ayman el-Zawahiri t arafından oluşturulan El Kaide destekçilerinin listesi, (7) hem diğer cihadistleri hem de açıkça reddettikleri din adamlarını listeleyen üç cihadist web sitesinin seti ve (8) McCants, Brachman ve Felter (2006) tarafından yer alan terörle mücadele uzmanla rının değerlendirmeleri. Her durumda, cihad puanlarının bu listelerdeki sınıflandır maların öngörücüsü olduğunu gösterir ve hatalar durumunda, hatanın doğasını ve nihai puanların geçerliliği için neden sorunlu olmasının olası olmadığını dikkatlice açıklar.

Bu doğrulamalar, belirli bir duruma oldukça özgü olmakla birlikte, eğitim veriler inin gerçekten ilgi alanındaki kavramı yansıttığını ve puanların bilinen cihatçı din a damlarını tahmin ettiğini ve cihatçı din adamları listeleriyle tutarlı olduğunu belirle meyi kapsamaktadır. Elbette, her zaman yapılabilecek daha fazla doğrulama vardır , ancak bu değerlendirme oldukça kapsamlıdır—doğrulama bölümü

Doclingo https://www.doclingo.ai

kitapta 20 sayfa yer kaplamaktadır (s. 114–130, ek s. 204–209) ve altı şekil il e iki tablo içermektedir. Puanlar kitabın argümanının merkezinde yer aldığı ndan, bu titiz doğrulama gereklidir.

Doclingo https://www.doclingo.ai

20.4 Sonuç

Bu bölümde, denetimli sınıflandırmanın doğrulamasını tartıştık. İdeal olarak, altın standart eğitim verileri ile, eğitim setinin bir kısmını doğrula ma seti olarak dışarıda bırakabiliriz; bu seti modelimizin doğruluğunu değerle ndirmek için kullanabiliriz. Performansın çeşitli ölçümlerini (doğruluk, kesinlik ve hatırlama) tartıştık ve çapraz doğrulamayı tanıttık.

Ayrıca, altın standart verilerin mevcut olmadığı durumlarda doğrulama yaklaşımlarını da tartıştık. Nielsen (2017) örneğini kullanarak, ikame etiketler kullanmanın, sözcük ağırlık larını anlamsal geçerlilik açısından kontrol etmenin ve dikkatli okumaların ölçümümüzün performans testlerini sağlamada nasıl yardımcı olabileceğini gösterdik.

---

[1]Bu bölümün bazı kısımları Grimmer, Roberts ve Stewart (2021)'dan alınmıştır.

[2]Bu özellikler yalnızca tüm adımlar (ilgili tahmin edicilerin seçimi dahil) çapraz doğrulam anın eğitim kümesindeve tam etiketli veriler içinde değilken ele alındığında geçerlidir. Çap raz doğrulamanın doğru uygulanması hakkında daha fazla bilgi için (Hastie, Tibshirani ve F riedman, 2013) bölüm 7.10.2'ye bakın.

Doclingo https://www.doclingo.ai

BÖLÜM 21

Yeniden Kullanım Keşif Yöntemleri

3. Kısım: Keşif'te, keşif için bir dizi teknik ele aldık:
tek üyelik kümelenme modelleri, karışık üyelik konu modelleri ved üşük boyutlu gömme stratejileri. Bu teknikleri, araştırmacının hala corpus'u vearaştırma sorusunu oluşturacak kavramları keşfettiği d urumlarda, önceden az insan girişi gerektirdiği içinbu kitabın keşif kısmında tanıttık. Ancak, bu teknikler ölçüm amacıyla da kullanılabi lir. Bu bölümde,denetimsiz yöntemlerle ölçüm yaklaşımımızın bir g enel görünümünü sağlıyoruz vebu yaklaşımın, bu yöntemleri keşif amacıyla kullanma şeklimizden nasıl farklılaştığını açıklıyoruz.

Metinlerin sosyal bilimlerde veri olarak kullanımı, kendi çalışmalarımız da dahil olmak üzere, keşif ve ölçüm rolünün sıklıkla bulanıklaştığı bir alan olmu ştur. Bu bölümde, ölçüm ve keşfi ayırmayı savunuyoruz; iki görevi farklı veri setlerinde gerçekleştirerek. Örneğin, Bölüm 12'de tartışıldığı gibi, Grimmer v e King (2011), bir senatörden alınan küçük bir korpus kullanarak yasama org anlarının basın bültenlerinde nasıl iletişim kurduğuna dair kavramsallaştırm alarını keşfederler. Ardından, bulgularını doğrulamak için farklı bir korpus üz erinde bir ölçüm stratejisi kullanırlar. Verileri önce geliştirmek, sonra uygula mak için iki ayrı örneğe ayırmanın, denetimsiz yöntemlerin ölçüm için kullanı lmasına dair bazı endişeleri çözdüğünü bulduk.

Öncelikle, denetimsiz yöntemlerin genellikle hangi tür kavramları ölçmek için daha donanımlı olacağını tartışarak başlıyoruz. Ardından, denetimsiz ölçülerin öl çüm için nasıl kullanılacağına dair bir iş akışını tanımlıyoruz. Son olarak, denetim siz yöntemlerin ölçüm için kullanılmasıyla ilgili sıkça duyduğumuz bazı endişeleri ele alıyoruz. Denetimsiz ölçüleri “bulunan” verilerle ilişkilendirerek sonuçlandırıy oruz.

Doclingo https://www.doclingo.ai

21.1 Denetimsiz Yöntemler Genellikle İnceliklerden Daha İyi Ölçüm Yapma Eğilimindedir

Kümeleme, konu modelleri ve gömme gibi denetimsiz modeller, sıkıştırma yoluyla çalışır. Bu modellerin öğrendiği konuların insanlar tarafından yorumlanabilir olmasının nedeni, yüksek boyutlu bilgiyi düşük boyutlu bir kanaldan geçirmeye çalışmalarıdır. Örneğin, standart bir konu modeli, bir belgede görünen tüm J bireysel kelimeleri yalnızca K konuyu kullanarak temsil etmelidir. Çünkü J genellikle K'den çok daha büyüktür, model, yalnızca çalışılacak az sayıda konu olduğu için sıkça bir arada bulunan kelimeleri aynı konu altında toplar.

Bir belgede gözlemlenen tüm kelimeleri K konularını kullanarak açıklama ihtiyacı, sık kullanılan kelimeleri tercih etme eğilimindedir. Dil genel olarak oldukça isim ağırlıklıdır (özellikle durdurma kelimeleri çıkarıldıktan sonra). Bu, konu modellerinin, örneğin, duygu yerine konu içeriğini seçme eğiliminde olmasına neden olur. İşte bu nedenle konu modelleri bu ismi alır. Modelde, konu içeriğini seçmeye zorlayan herhangi bir açık karar almadık; bu sonuç, dilin kullanım şekli ile sık kullanılan kelimelere daha fazla ağırlık veren bir modelleme yaklaşımının etkileşimi ile ortaya çıkar.

Denetimsiz yöntemler, ölçümün amacının metnin stilini, tonunu veya metnin daha ince bir özelliğini değil, metnin ana konularını yakalamak olması durumunda daha iyi çalışması olasıdır. Bu yöntemler her zaman metinde öne çıkan unsurlara en duyarlı olacaktır. Eğer denetimsiz yöntemlerle daha ince bir şeyi ölçmeyi umuyorsak, en iyi yaklaşım, keşfedilecek gizli özelliğin türünü değiştirmek için belge-özellik matrisinin içeriğini değiştirmektir. Örneğin, sözcük türü etiketlemesi kullanarak, eğer modeli duyguya daha fazla yönlendirmek istiyorsak, bir dizi metinde sıfatlar ve zarflar dışında her şeyi atlayabiliriz. Ancak genel olarak, bir analistin çıkarmak istediği belirli bir miktar varsa ve bu miktar ön işlenmiş metnin büyük bir kısmına katkıda bulunmuyorsa, denetimsiz yöntemlerin kullanımı son derece sinir bozucu bir deneyim olabilir çünkü bu miktarı yakalamak için çok kaba olabilirler.

Bunun bir diğer sonucu, agnostik görüşümüzle tutarlı olarak, denetimsiz yöntemin döndürdüğü şeyin metin içinde gerçek bir gizli yapı değil, o metnin ekonomik bir sıkıştırması olduğudur. Örneğin, bir konu modelindeki bir konu, belgenin kelimeler torbası temsilini yeniden oluşturmakta makul derecede etkili olan kelimeler üzerinde bir dağılımdır. Bu durumdan çıkardığımız herhangi bir anlam, modelin kendisinin sonucundan daha çok doğrulama ile haklı çıkar.

Doclingo https://www.doclingo.ai

21.2 Örnek: Diferansiyel Kelime Oranları ile Ölçekleme

Bu bölümde, denetimsiz yöntemlerin ölçüm için ne zaman işe yaradığını ve han gi koşullarda başarısız olduğunu gösteren bir örnek sunuyoruz.1 Bir metin korpus u kullanarak politik bir spektrumu tahmin eden denetimsiz bir ölçekleme yöntemin i kullanmayı düşünüyoruz. İlk olarak Monroe ve Maeda (2004), daha sonra Slapin v e Proksch (2008), politik partilerin mekansal konumunu otomatik olarak tahmin et mek için metin tabanlı istatistiksel modelleri tanıtmaktadır.
Siyasetçilerin, politikacı *i* için θ i parametresi ile temsil edilen düşük boyutlu bir poli tik alanda bulunduğu varsayılmaktadır. Bu alandaki bir politikacının (veya partinin) konumunun, metinlerde kelimelerin kullanım oranını etkilediği varsayılmaktadır. B u varsayımı ve metin verilerini kullanarak, denetimsiz ölçekleme yöntemleri, politik aktörlerin temel konumlarını ölçmek için kullanılabilir. Slapin ve Proksch (2008), yö ntemlerini Poisson-IRT modeli olarak geliştirmiştir.
Özellikle, Slapin ve Proksch (2008), birey *i*'den her kelime j'nin, oranı λ i j olan bir Poisson dağılımından çekildiğini varsaymaktadır; W i j ~ Poi sson (λ i j). λ i j, birey *i*'nin konuşkanlığı (α i), kelime j'nin kullanım sıklı ğı (ψ j), bir kelimenin temel ideolojik alanı (μ j) ve politikacının temel k onumu (π i) arasında ayrım yapma derecesi gibi faktörlerin bir fonksiy onu olarak modellenmektedir.

$$\lambda_{ij} = \exp(\alpha_i + \psi_j + \mu_j \pi_i).$$

Bu denetimsiz yöntemi temel pozisyonları tahmin etmek için kullanma k için, ideolojik bir hakimiyet varsayımına ihtiyacımız var - siyasi aktörleri n dilinin ayırt edici özelliğinin ideoloji olduğuna dair. Varsayım geçerli old uğunda, model dil kullanımındaki ideolojik farklılıkları güvenilir bir şekild e yakalayacaktır. Ancak, bu ideolojik farklılıklar metindeki diğer varyasyo n türleri tarafından gölgede bırakıldığında modeller başarısız olacaktır. Ö rneğin, aktörler arasındaki ideolojik olmayan farklılıklar, politikaya veya y ağmura (Grimmer, 2013*b*) odaklanmaları, makalelerin yazıldığı stil veya if adelerin tonu hakkında olabilir. Model açıkça denetim içermediğinden, m odelin çıktısının siyasi aktörlerin ideolojik konumlarını yakalayacağını gar anti etmek zordur ve bu nedenle model dikkatli bir doğrulama gerektirir.

İdeolojik hakimiyet varsayımı veriye uyduğunda, model siyasi metinlerde n geçerli ideolojik boyutları güvenilir bir şekilde elde edebilir. Örneğin, Şekil 21.1'deki sol taraftaki grafiği ele alalım. Bu, Slapin ve Proksch (2008) tarafınd an uygulanan Wordfish algoritmasının Şekil 1'deki bir grafiğini tekrarlar.

Doclingo https://www.doclingo.ai

parti platformları. Slapin ve Proksch (2008) tarafından gösterildiği gibi, sol taraftaki grafikteki tahminler Alman partilerini ayırmakta ve zaman içindeki Alman parti hareketlerinin uzman değerlendirmelerini tekrarlamaktadır.

Ama ideolojik hakimiyet varsayımı veriye uymadığında, Wordfish temel politika boyutlarını elde edemez. Sağ taraftaki grafik, Grimmer (2010) tarafından tanıtılan Senato basın bülteni verilerine Wordfish algoritmasını uygular. 21.1 sayısındaki alt, sağ taraftaki grafik, Demokrat (siyah çizgi) ve Cumhuriyetçi (gri çizgiler) pozisyonlarının Wordfish algoritmasından elde edilen yoğunluğudur. Model, Demokrat ve Cumhuriyetçi senatörleri ayırmada açıkça başarısız olmaktadır - bu, artık kutuplaşmış Senato'da siyasi ideolojinin geçerli bir ölçeklendirilmesi için bir gerekliliktir.

Wordfish ölçeklendirmesi anlamlıdır, ancak standart politika alanına karşılık gelmemektedir. Üst grafik, Wordfish algoritmasının Grimmer (2013*b*) tarafından ifade edilen gündem modelini yeniden ürettiğini göstermektedir - senatörlerin basın bültenlerinde pozisyon alma ve kredi talep etme dengesini nasıl sağladıkları. Bu grafik, Grimmer (2013*b*) tarafından elde edilen ölçeklendirmeyi yatay eksende Wordfish'ten elde edilen ölçeklendirme ile karşılaştırmakta ve siyah çizgi bir lowess eğrisi (Cleveland, 1979) oluşturmaktadır. İki ölçüm arasındaki ilişki son derece güçlüdür - 0.86 oranında korelasyon göstermekte, Wordfish'in Senato basın bültenlerinde bu ilginç - ancak ideolojik olmayan - spektrumu tanımladığını açıkça göstermektedir.

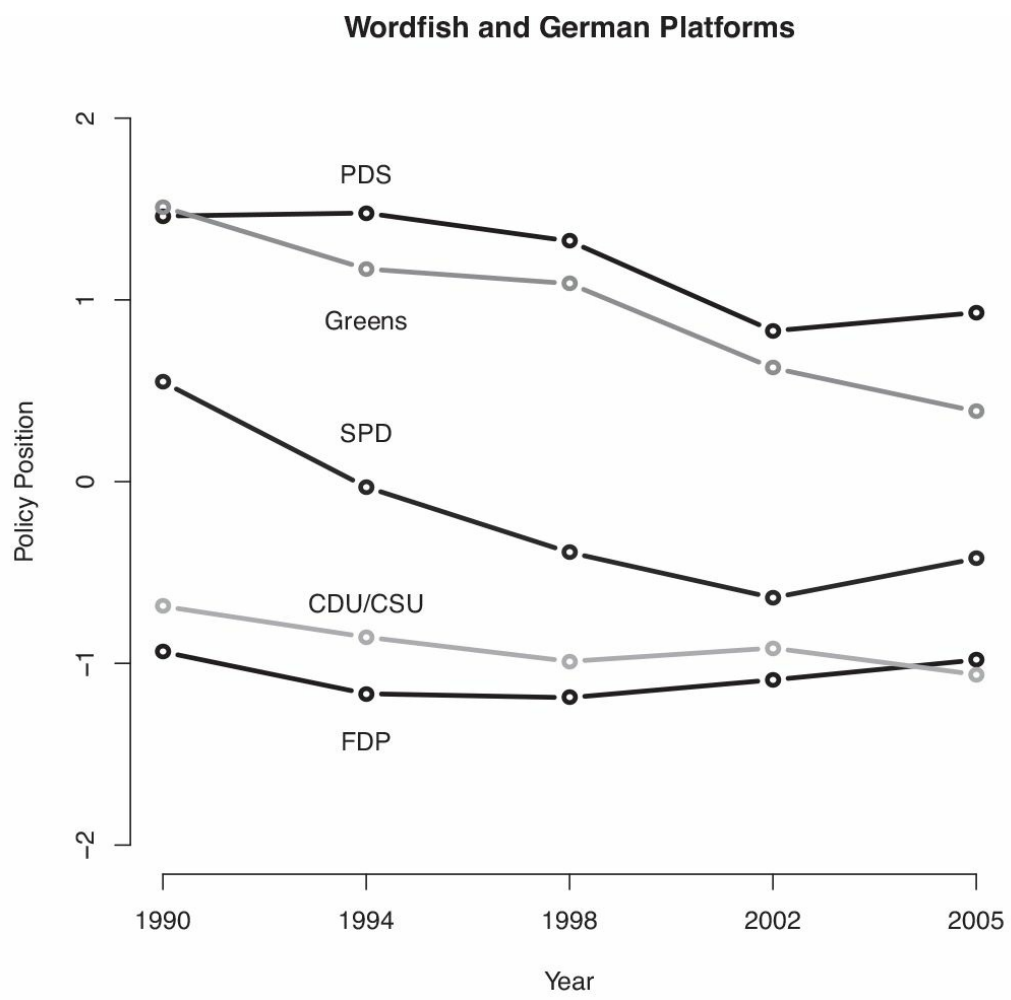
Bu, denetimsiz yöntemlerin ilginç ölçümü ne zaman geri kazanma olasılığının yüksek olduğunu gösterir—ilginç kavramın, metinde oldukça sık bulunan konu ile örtüştüğü durumlarda. Wordfish için, siyasi aktörler yoğun ideolojik konuşmalar yaptığında—Alman parti platformlarında olduğu gibi—denetimsiz yöntemlerin güvenilir pozisyon tahminlerini elde edebildiği görünmektedir. Ancak siyasi aktörler ideolojik konuşmalardan kaçınabildiğinde—Senato basın bültenlerinde olduğu gibi—ölçekleme yöntemleri başka, ideolojik olmayan bir ölçekleme elde eder.
Bu nedenle, ölçüm için denetimsiz ölçümler uygularken, hedeflenen alanın tanımlandığını doğrulamak için dikkatli bir doğrulama gereklidir.

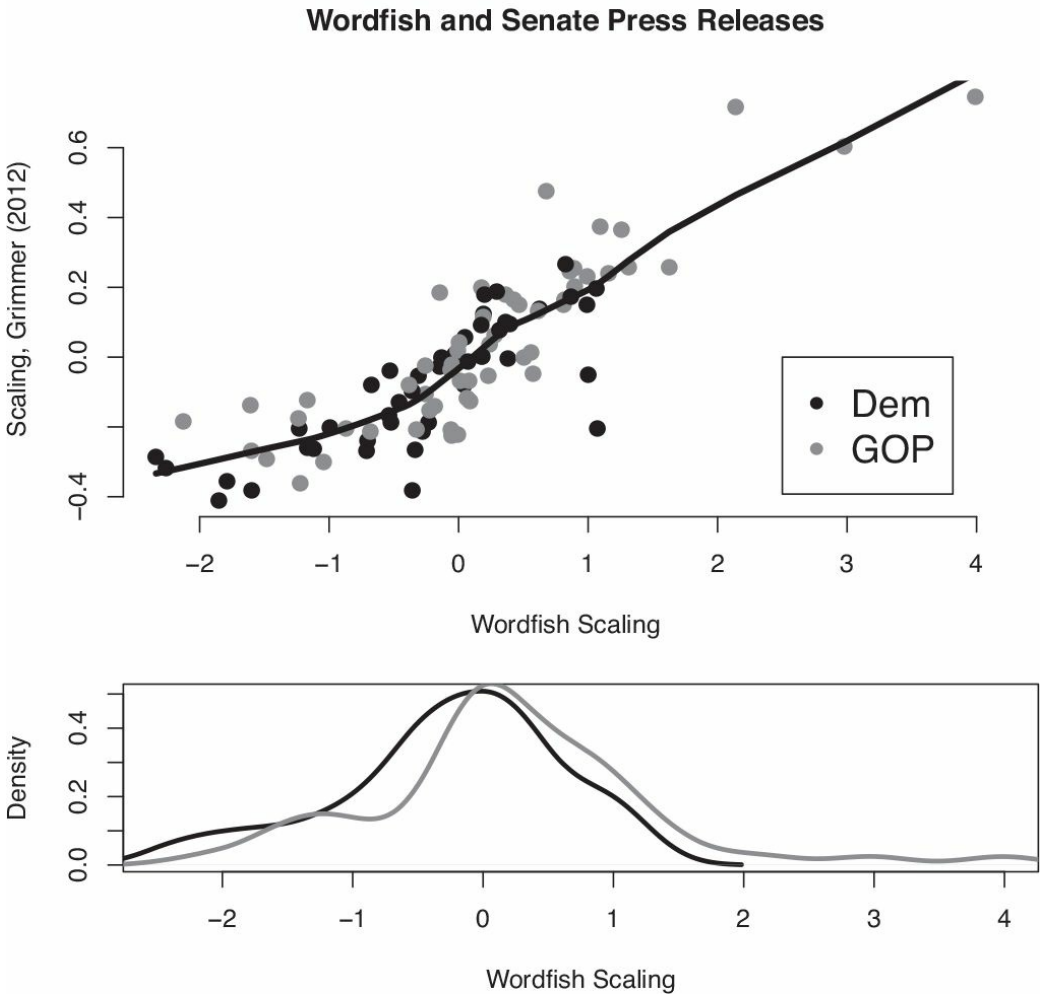
Doclingo https://www.doclingo.ai

21.3 Ölçüm İçin Denetimsiz Yöntemlerin Yeniden Kullanımı İçin Bir İş Akışı

Bu bölümde, denetimsiz yöntemlerin ölçüm için kullanılmasına yönelik id eal sürecin bir genel görünümünü sunuyoruz. Burada, araştırmacının zaten corpus'tan tahmin etmek istediği bir ölçüye sahip olduğunu varsayıyoruz. Örnek amaçları için, araştırmacının bir gazete corpus'unun çevre ile il gili olan oranını tahmin etmek istediğini ve bu tahmini yapmak için bir konu modeli kullanmayı seçtiğini varsayıyoruz.

Doclingo https://www.doclingo.ai





Doclingo https://www.doclingo.ai

Şekil 21.1. Performans, Wordfish algoritması ile bağlamlar arasında değişir. Grimmer ve Stewart (2013) tarafından Şekil 7.

21.3.1 1: VERİYİ BÖL

Denetimsiz bir ölçüm yöntemi kullanmanın ilk adımı, veri kümesini bir eğitim ve test kümesine ayırmaktır. Veriyi bölmek, araştırmacının belirli veri kümesine aşırı uyum sağlama veya ürettiği sonuçlara dayanarak bir ölçüm seçme endişesi olmadan farklı ölçüm yaklaşımlarını keşfetmesine olanak tanır. Veri kümesini bölmek ayrıca araştırmacıya ölçümün genelleştirilebilirliğini test etme fırsatı sunar ve ölçümün oluşturulduğu verinin dışındaki verilerde iyi performans göstereceğini garanti eder.

Eğitim kümesine karşı test kümesine ne kadar veri dahil edileceği, araştırmacının ölçmeyi amaçladığı kavrama ve elindeki veri miktarına bağlı olacaktır. Bir yandan, araştırmacının güvenilir bir ölçüm geliştirebilmesi için eğitim kümesinde yeterli veriye ihtiyacı vardır ve bunun diğer veri kümelerine genelleştirileceğinden emin olmalıdır. Öte yandan, araştırmacının kesin nihai ölçümler yapabilmesi için test kümesinde yeterli veriye ihtiyacı olacaktır.

21.3.2 2: MODELİ UYARLAMA

Veri eğitim ve test kümesine ayrıldıktan sonra, araştırmacı eğitim verileri üzerinde denetimsiz modeli uyarlayabilir. Ayrılmış örnek, araştırmacının ölçmek istediği kavramla en iyi uyum sağlayan ölçüyü bulmak için birkaç farklı modeli keşfetmesine olanak tanır. Örneğin, çevre ile ilgili bir konuyu en temiz şekilde üreten modeli bulmak için farklı konu sayılarıyla birçok farklı konu modelini uyarlayabilir. Ya da, modelin farklı uyumlarını keşfetmek için farklı başlangıç değerleri, durdurma kuralları veya hiperparametreler denemek isteyebilir. Bu süreçte, ilgilendiği kavramı en iyi şekilde yakalayan ölçüyü oluşturan modeli aramaktadır.

Eğitim verilerinde modeli uyarlamak ve yeniden uyarlamak, araştırmacının ürettiği nihai ölçüyü geçersiz kılmaz. Ve aşağıda daha ayrıntılı olarak tartıştığımız gibi, model her çalıştırıldığında aynı sonucu üretmese bile, bu ölçülerin yararlı olmadığı anlamına gelmez. Örneğin, çevre ile ilgili konu, araştırmacının uyarladığı birçok konu modelinden sadece birinde göründüğünde, bu, çevre ile ilgili belgelerin corpus'ta yer almadığı veya çevre konusunu üreten konu modelinin yanlış olduğu anlamına gelmez. Sadece, konu modellerinden yalnızca birinin corpus ile ilgili oranı tahmin etmek için parametreler ürettiği anlamına gelir.

Doclingo https://www.doclingo.ai

çevre. Araştırmacı, ilgi alanına en iyi şekilde uyan ölçüm modeli seç melidir.

21.3.3 3: MODELİ DOĞRULAYIN

Araştırmacı bir model seçtikten sonra, ölçümü doğrulamalıdır. Burada, ölçüm için kullanılan denetimsiz modelleri doğrulamanın birkaç f arklı yaklaşımını tanımlıyoruz. Bu yaklaşımlardan bazıları, Bölüm 20'de ta rtıştıklarımızla örtüşürken, bazıları ölçüm için keşif modellerinin yeniden kullanılmasıyla özeldir.

Elle Kodlama

Elle kodlama, ölçüm için kullanılan denetimsiz bir yöntemi doğrul amanın en basit yaklaşımıdır. Denetimsiz yöntemler birçok farklı kon u veya küme ürettiğinde bile, doğrulama ilgi alanındaki ana kavraml ar üzerinde gerçekleştirilebilir, eğer tüm model üzerinde değilse. Ör neğimizdeki araştırmacı, araştırma asistanlarından, corpus'undan bi r belge örneğini iki kategoriye elle kodlamalarını isteyebilir: 1) çevre hakkında ve 2) çevre hakkında değil. Eğer rastgele bir belge örneğini elle kodlarsa, çevre hakkında olan elle kodlanmış belgelerin oranını, konu modelinin çevre hakkında olan belgelerin oranı için ürettiği ta hminle karşılaştırabilir. Ayrıca, çevre hakkında olarak kodlanmış belg elerdeki konu yüklemesini, çevre hakkında olarak kodlanmamış belg elerle karşılaştırabilir.

Bireysel kodlama kullanarak denetimsiz yöntemleri doğrulamanın zorl uklarından biri, denetimsiz yöntemlerin genellikle kategorik ölçümler yeri ne sürekli ölçümler üretmesidir. Bu durumlarda, denetimsiz ölçekleme ve konu modelleri gibi, doğrulama amacıyla denetimsiz yöntemin çıktısını k abalaştırmak isteyebiliriz. Örneğin, bir gazete makaleleri konu modelinde , bir analist bir makalenin esasen “çevre” hakkında olduğunu doğrulayabi lir, ancak çevrenin belgede yer alan tokenlerin %18'ini oluşturduğunu do ğrulayamaz. Bu durumda, insan kodlu doğrulama seti ile karşılaştırma ya pmak için sürekli konu oranını kabalaştırabiliriz.

Elle kodlama ve uzman olmayan değerlendirme, ortaya çıkan ölçümlerin anlamını anlamak ve etiketlemek için de kullanılabilir. Örneğin, insan kodlayı cılar, konuları en olası kelimelerine veya en temsilci belgelere dayanarak etik etlemek için kullanılabilir. Değerlendiricilerin anlamsal geçerliliği sağlamak iç in kullanılmasına dair bazı yaklaşımları Bölüm 20 ve Bölüm 3'te tartıştık: Keşif.

Temsilci Etiketler

Doclingo https://www.doclingo.ai

Bölüm 20 'de denetimli sınıflandırma için açıkladığımız gibi, temsilci etiketl er doğrulama için de kullanılabilir. Elle kodlama bir seçenek olmadığında, araşt ırmacılar farklı bir amaç için üretilen belgeler için etiketler arayabilir ve bunları modelin çıktısıyla karşılaştırabilir. Örneğin, bir gazete makaleleri konu modelin in çıktısı, bir gazete veritabanındaki makalelere verilen anahtar kelime etiketle riyle karşılaştırılabilir. Temsilci etiketler, elle kodlama olmadan oldukça faydalı olabilir, ancak okuyucuları Bölüm 20 'ye, temsilci etiketlerin doğrulama için kul lanılırken kaçınılması gereken bazı tuzaklar hakkında geri yönlendiriyoruz.

Hipotez Geçerliliği

Eğer ölçütler iyi çalışıyorsa, diğer dışsal değişkenlerle belirli ilişkile r kurmaları gerekir. Bölüm 20'de tartıştığımız gibi, önceden görme miz gereken ilişkileri belirleyebilirsek, bunları ölçütün doğrulaması o larak kullanabiliriz. Örneğin, grip hakkında haberler oluşturmakla ilg ileniyorsak, bu haberlerin kışın artmasını ve yazın azalmasını beklem eliyiz. Eğer bu ilişkiyi görmezsek, ölçütün gerçekten doğru konuyu y akalayıp yakalamadığından şüphe duyabiliriz. Buradaki anahtar, yok luğunun ölçütün başarısızlığını göstereceği ilişkileri belirlemektir.

Catalinac (2016*a*), Bölüm 1'de kapsamlı bir şekilde tartıştığımız çalışması nda, Japonya'daki aday manifestolarındaki konuları tahmin etmek için Latent Dirichlet Allocation konu modelini kullanmaktadır. Modeli doğrulamak için h ipotez geçerliliği üzerine kapsamlı testler yapmaktadır. Örneğin, tarım ve or mancılık konularının kırsal alanlardaki manifestolarda daha yaygın olduğunu , ancak turizm ve sanayi konularının kentsel alanlarda ofis için aday olanlar a rasında daha yaygın olduğunu göstermektedir (Catalinac, 2016*a*, s. 97).

Model Tabanlı Değerlendirmeler

Bunlardan biri en basit değerlendirmelerden biridir, ancak belki de en azaydı nlatıcı olanı model tabanlı değerlendirmelerdir. Burada, modelinbaşlangıçta opti mize edilmesi için tasarlandığı kriter veya bazıilişkili dış kriter temelinde modelin uyumunu değerlendiriyoruz. Bizmodellerle yalnızca dünyayı bize anlatabilecekle ri açısından ilgileniyoruzve kendileri birer amaç olarak değil, bu nedenle model t abanlıdeğerlendirmeler diğer yaklaşımlar kadar aydınlatıcı değildir. Yine de,çoğu zaman hesaplanması en kolay doğrulamalardır ve bu nedenle diğerdoğrulama yöntemleri için kesinlikle birer ikame olmasa da faydalıtamamlayıcılar olabilirler.

Metin için üretken modellerde, en basit model tabanlı

Doclingo https://www.doclingo.ai

değerlendirme, modelin eğitiminde kullanılmayan bir örnekte modelin uyum unu değerlendiren, tutulmuş log-olasılıktır. Bu, sıkıştırılmış gizli değişkenin, üreteç modelinde (örneğin, kelime sayıları) kullanılan gözlemlenen verileri ye niden üretme yeteneğine dair bir gösterge sağlar.

Ne yazık ki, gizli değişken modellerinin doğası gereği, tutulan log-ola sılığını tam olarak hesaplamak bile zor olabilir (Wallach ve diğ., 2009). Verilen bir test belgesi için *i* , p (W i , | W train) = ∫ π i , μp (W i , , π i , μ | W train) d π i d μ hesaplamak istiyoruz, ancak integral hesaplanamaz. Konu m odeli durumunda, Wallach ve ark. (2009) mevcut yaklaşık tekniklerin bir gene l görünümünü ve karşılaştırmasını sunmaktadır. Bu yöntemler yalnızca karşıl aştırmalı olarak gerçekten yorumlanabilir. Foulds ve Smyth (2014), ısınma yol larını kullanarak modeller arasındaki göreli performansı doğrudan tahmin et me yaklaşımını göstermektedir. Tutulan olasılığı optimize etmek, modelin ak tif olarak yer almadığımız bir görevdeki performansını maksimize eder: belg eler için terim sayısı vektörlerini tahmin etmek. Bu, bizi belirli bir tür aşırı uyu mdan korur, ancak belgelerin temel anlamı hakkında hiçbir şey yakaladığımı zı garanti etmez.

21.3.4 4: TEST VERİLERİNE UYUM VE YENİDEN DOĞRULAMA

Araştırmacı doğrulamayı tamamladıktan sonra, ölçüm için denetimsiz yöntemleri n kullanılmasındaki son adım, test verilerine uyum sağlamak ve ardından yeniden do ğrulamaktır. Burada, eğitim verileri üzerinde geliştirdiğimiz uyumlu modeli kullanma k ve bunu test verilerine uygulamak istiyoruz. Önemli olan, bu durumun farklı verilerl e aynı modeli yeniden çalıştırmak anlamına gelmediğidir. Bu, eğitim verileri ile tahmi n edilen parametreleri kullanarak test verileri için çıktı üretmek anlamına gelir. Bu çık tıyı kullanarak, araştırma görevimiz için ilgi duyduğumuz analizleri gerçekleştirebiliriz .

Geniş kapsamlı doğrulama, eğitim verilerinde modelin test verilerine iyi u yum sağlayacağına dair bir güvence sağlamalıdır, özellikle de eğitim verileri daha büyük bir kümeden rastgele örneklenmişse. Ancak, her zaman eğitim v erilerinde modelin uyumunun, araştırmacının ölçmek istediği kavramları yan sıtmayan test verilerinde ölçümler üretme şansı vardır. Bu nedenle, nihai ölç ümün ilgi alanındaki kavramı yansıttığından emin olmak için test verilerinde i kinci bir doğrulama yapılmasını öneriyoruz.

Doclingo https://www.doclingo.ai

21.4 Ölçüm İçin Denetimsiz Yöntemlerin Yeniden Kullanımı ile İlgili Endişeler

Keşif, genellikle iyi bir fikri nasıl ateşleyeceği ile ilgilenirken, ölçüm, eşleme fonksiyonunun neyi yakaladığı ve bunun bazı teorik kavramlar ı nasıl yaklaştığı hakkında belirli bir iddia ortaya koymayı gerektirir. Bu yöntemler ölçüm görevine yönlendirildiğinde, ek endişelerimiz olma sı makuldür. Aşağıda, ölçüm için denetimsiz yöntemlerin kullanımıyla il gili ifade edilen bir dizi endişeyi ele alıyoruz ve genel bir yanıt veriyoruz. Neyse ki, tüm endişelerin ortak bir yanıtı var ve bu yanıt, kayıtsız bakış açımızla tutarlıdır: ölçümün değeri, modelin kendisiyle değil, bir mikt arın yararlı sosyal bilimsel ölçüsü olarak sonucun doğrulanmasıyla ha klı çıkar. Bunlar pratikte yararlı ölçümlere yol açabilecek araçlardır, an cak aynı zamanda olmayabilirler. Fikirleri yönetilebilir tutmak için, karı şık üyelik konu modelleri durumunda endişeleri tartışıyoruz; ancak, e ndişeler daha genel bir niteliktedir.

21.4.1 ENDİŞE 1: YÖNTEM HER ZAMAN BİR SONUÇ DÖNDÜRÜR

Bu endişe genellikle şu itiraz olarak ifade edilir: “Eğer bu model her za manküme/konu/ölçekler üretiyorsa (veri rastgele olsa bile), bu nasıl geçe rli birölçüm stratejisi olabilir?” Diğer birçok istatistiksel modelde olduğu g ibi, öncemodeli varsayıyoruz ve ardından veriye en iyi uyan parametreleri buluyoruz. Birdoğrusal regresyonun her zaman bir çizgi döndürmesi gib i, gizli değişkenmodelleri de veride her zaman bir yapı döndürür. Bu ned enle doğrulama, araştırmasürecinin bu kadar önemli bir parçasıdır. Bizim bir şeyi ölçtüğümüzü gösteren,modelin sonuçları değil, etiketleme ve do ğrulama sürecidir.

İtiraz, gizli değişken modellerinin belirli bir temel yapının varlığınıbelirle mek için genellikle zayıf araçlar olduğunu doğru bir şekilde tanımlar—özell ikle böyle bir yapının var olduğunu bildiğimiz tamamen sentetik verilerde.K = 5 ile bir küme modeli çalıştırmak, veride beş küme olduğuna dair yalnızc aminimal kanıt sağlar. Aksine, yöntem, mevcut olan herhangi bir yapıya en iyibeş küme yaklaşımını üretir. Bu, ne bir temel küme yapısının varlığını ga rantieder, ne de kümelerin sayısı hakkında herhangi bir şey söyler. Genel o larak,gerçek dünya verilerinde “gerçek” bir temel yapının olduğuna bile ina nmıyoruz,sadece belirli hedefler için daha veya daha az yararlı olan şeyler v ardır.

21.4.2 ENDİŞE 2: BELİRSİZ DEĞERLENDİRME STRATEJİLERİNDEKİ F ARKLAR

Doclingo https://www.doclingo.ai

Her bir model için en iyi uyumlu parametreleri tahmin etmenin birk aç farklı yaklaşımı vardır. Tahminin detayları bu kitabın kapsamının öt esinde olsa da, bu farklılıkların belirli uygulamalarda özellikle belirgin olabileceğini vurgulamak istiyoruz.

Bu somut hale getirmek için, vanilya Latent Dirichlet Allocationmodelini düşünün. Bu, tahminin amacınınposterior dağılımını yaklaşık olarak belirle mek olduğu bir Bayes modelidir. Bu model içinçıkarsama yapmak üzere üç geniş yaklaşım vardır: çökertilmiş Gibbs örnekleme (Griffiths ve Steyvers, 2004; Yao, Mimno ve McCallum, 2009), varyasyon çıkarımı (Blei, Ng, ve Jord an, 2003) ve spektral yöntemler (Arora ve diğ., 2013). Bu yöntemlerin hepsi nin avantajları ve dezavantajları vardır. Ne yazık ki, bu farklılıklar belirli pro blemler ve ilgi alanındaki miktarlar için önemli olabilir (Asuncion ve diğ., 2009; Boyd-Graber, Mimno ve Newman, 2014). Örneğin, çökertilmiş G ibbs örnekleyicisinin tek bir geçişi, genellikle seyrek görünen konular üretir; yani, her belge yalnızca küçük bir konu sayısını ifade eder ve he r konu yalnızca az sayıda kelimede destek bulur. Buna karşılık, aynı po sterior dağılım için varyasyonel yaklaşım genellikle yoğundur, belgele r ve konular içindeki birçok konuya kayda değer bir kütle yerleştirir. B u, bir belge setinin küçük bir konu setine ne kadar "odaklandığı" hakkı nda çıkarım yapmayı, sıradan bir kullanıcıya görünmeyebilecek sorunl arla dolu hale getirir. Pratikte, yazarların kullandıkları belirli yazılım uy gulamasının yanı sıra tahmin yaklaşımını her zaman belirtmelerini ön eriyoruz.

21.4.3 ENDİŞE 3: SEZGİSEL OLMAYAN HİPERPARAMETRELE RE DUYARLILIK

Zaten *K*'nın seçimini tartıştık, muhtemelen konu modellerini kull anırken manuel olarak ayarlanan en bariz parametre. Ancak, perfo rmansı önemli ölçüde etkileyebilecek başka bir dizi hiperparametr e var (Wallach, Mimno ve McCallum, 2009; Wallach ve ark., 2010). Sonuçta, bu seçimler zor çünkü uygulayıcıların bunları en iyi şekilde ayarlamak için pek az sezgisi olabilir. Manuel olarak ayarlamak zorunda kaldığımızda en iyi stratejiyi, birçok farklı seçeneği dik kate alarak ve maddi uyuma göre seçerek buluyoruz.

21.4.4 ENDİŞE 4: SONUÇLARDAKİ İSTİKRARSIZLIK

Son endişe, diğer endişelerin de merkezindedir: gizli değişken modelle rinin, özellikle sosyal bilimlerdeki diğer yaygın istatistiksel modellere, örn eğin doğrusal regresyona göre, istikrarsızlığı. Temelde tüm yöntemler

Doclingo https://www.doclingo.ai

yukarıda tanımlananlar, konveks olmayan (ve bu nedenle kolayca çözülemeye n) optimizasyon problemlerine yol açar. Pratikte, sonuçlar başlangıç değerlerin e duyarlıdır ve model her çalıştırıldığında farklı bir sonuç elde edebiliriz. Farklı sonuçlar, modelin küresel optimal bir çözüm yerine yerel optimal çözümler bul masından kaynaklanmaktadır.

Bu, sonuçlarının doğru olup olmadığı konusunda endişe duyan uygulayıcıla r için anlaşılır bir şekilde rahatsız edicidir. Bir dizi makale, sorunu bir ölçüde de rinlemesine incelemiştir. Örneğin, Roberts, Stewart ve Tingley (2016) konuyu a çıklamakta, farklı çözümleri keşfetmek için stratejiler sunmakta ve farklı başlat ma stratejileri önermektedir (ayrıca ek görselleştirme yaklaşımları sunan Chua ng ve ark. 2015'e de bakınız).

İstikrarsızlık sorunu, hesaplama yeniden üretilebilirliğinin (aynı v erilerden aynı sonuçları üretebilme) basit bir problemi değildir.

Analist, sonuçların bilgisayarlar arasında tutarlı olmasını sağlamak için rastgele s ayı üreteci tohumunu ayarlayabilir. Roberts, Stewart ve Tingley (2016) daha ileri giderek, Arora ve ark. (2013) tarafından geliştirilen deterministik ve (belirli koşull ar altında) küresel olarak tutarlı bir tahminciye dayanan bir başlatma stratejisi ön ermektedir. Bu yaklaşım, herhangi bir durumda küresel olarak en iyi çözümü bul acağımızı garanti etmemektedir, ancak ampirik olarak iyi performans göstermek te ve asimptotik garantiler sunmaktadır. İstikrarlı başlatma stratejileri bulabildiği mizde bile, modeller genellikle ön işleme veya temel verilerdeki değişiklikler gibi görünüşte küçük değişikliklere karşı oldukça hassas olmaktadır (Denny ve Spirlin g, 2018; Wilkerson ve Casas, 2017). Bu istikrarsızlık, küresel ve yerel olarak optim al çözümler arasındaki ayrımı daha az ilgili hale getirmektedir.

Verilerin küçük perturbasyonları, yerel bir optimumun potansiyel olarak küresel hale ge lmesine neden olabileceğinden, diğerlerinden daha yüksek olanın ayrımı tartışmalı bir ş ekilde daha az ilgili olabilir - bunlar sadece farklı şeyleri ölçer, bu da farklı zamanlarda s ahip olduğunuz verilere en iyi uyum sağlayabilir. Yine de, yerel olarak optimal bir çözü me sahip olmanın önemli olduğuna inanıyoruz, çünkü bu, ölçtüğümüz şey ve sahip old uğumuz veriler göz önüne alındığında, bu ölçümün verilere en iyi uyum sağladığını bil memizi sağlar.

Denny ve Spirling (2018), denetimsiz yöntemler için metin ön işleme adımlarının etkisi üzerine yazılarında temel endişeyi etkileyici bir şekilde ifade ediyorlar:

> Felsefi noktamızı burada vurgulamak için, sorun sadece dürüst olmayan araştırmacıların sevdikleri b ir spesifikasyonu seçip bununla devam edebilecekleri değil, bilimsel sorgulamanın zararına. Daha in ce bir sorun, iyi niyetli akademisyenlerin bulgularının doğruluk değeri hakkında hiçbir fikrinin olma masıdır. Denetimsiz metin modellerinin belirli bir özelliği, genellikle birçok olası spesifikasyonun olm ası ve bunlara uydurulabilecek birçok makul “hikaye” olmasıdır ve tahmin sonrası doğrulanabilir.

Doclingo https://www.doclingo.ai

> Temelde, ön işleme konusuna dikkat edilmemesi, araştırmacıl arın sonuçlarını yorumladıkları ve daha sonra kesimler, testle r ve doğrulama kontrolleri önermeden önce, belgelerini farklı bir şekilde ön işleme tabi tutmuş olsalardı güncelleyebilecekle rini fark etmeden, potansiyel olarak virülan bir "forking paths" (Gelman ve Loken, 2014 anlamında) seti üretir.
>
> (Denny ve Spirling, 2018, s. 187)

Bu endişe, ölçüm için keşif yöntemlerinin kullanılabilirliğinden şüphe duyan birç ok sosyal bilimci tarafından daha geniş bir şekilde dile getirilmektedir. Yazarlar, güçlü bir teorinin yokluğunda, sonuçlarımızın farklı ön işleme kararlarına dayanı klı olmasını görmek istediklerini ve ideal olarak farklı alternatifler üzerinde ortala ma almak istediklerini önermektedir. Wilkerson ve Casas (2017), daha geniş bir b ağlamda farklı parametre değerleri arasında dayanıklılık için benzer bir çağrıda b ulunmaktadır.

21.4.5 İSTİKRARI YENİDEN DÜŞÜNMEK

Denetimsiz yöntemler, analistin ölçmek istediği nicelik hakkında d oğrudan bilgiye sahip değildir. Performans için nesnel, kolayca değe rlendirilebilir bir kriterimiz olduğunda, bu tartışmalar daha basittir: mümkün olan çözümler alanında arama yaparız ve o kriter üzerinde en iyi performansı gösteren çözümü buluruz. Keşif yöntemlerinin di kkat çekici yanı, belirli bir ölçüm amacına yönelik çalışabilir bir *ikam e* kriteri sunmalarıdır. Bazen bu, ilgi alanındaki kavramı ölçmek için i şe yarar ve bazen de yaramaz.

Denny ve Spirling (2018) ile Wilkerson ve Casas (2017) eleştirilerini n anahtarı, bu yöntemlerin ölçmeye çalıştığı istikrarlı, temel bir hede f varsayımıdır. Bu dünya görüşü altında, her farklı model çözümü, be lgede bazı temel gerçeklere farklı bir yaklaşım olarak görülmektedir. Bu durumda, modelin farklı varyasyonlarına dayanıklı bir sonucu ta kip etmek kesinlikle mantıklıdır.

Modelin her yeniden tanımlanmasının belgeler hakkında farklı b ir şey yakaladığını savunuyoruz. Sabit bir kavramın ölçümündeki ist ikrarsızlığı, ölçtüğümüz kavramın seçimindeki farklılıklarla karıştır mamalıyız. Bir belge setinden ölçebileceğimiz şeylerde farklılıklar o lsa da, düzgün bir şekilde doğrulanmış bir ölçüm, belgelerin gerçe k içeriğiyle sınırlıdır.

Doclingo https://www.doclingo.ai

Eğer bu sezgisel gelmiyorsa, basit bir iddia sunuyoruz: Çoğu akademisyen, bir metni okumanın sadece bir doğru yolu olduğunu iddia eden birinin absürt olduğunu düşünecektir. Ancak bu, bu bağlamda istikrarlı, temel bir hedef ölçü münün ima ettiği şeydir. Bu istikrar, iyi tanımlanmış bir tahmin edilebilirliği bir deney veya regresyon analizi kullanarak tahmin etmek gibi birçok diğer nicel e tkinlik ile karşılaştırıldığında doğal görünmektedir. Ancak bu istikrar varsayımı, daha karşılaştırılabilir niteliksel manuel içerik analizi geleneğinde yoktur. Aynı belge setine yaklaşan iki farklı niteliksel akademik ekibi düşünün; f arklı kodlama şemaları geliştireceklerdir. Farklı yöntemler kullanmayı v e potansiyel olarak farklı sorular yanıtlamayı seçtikleri için hiçbir ekibin bulgularını göz ardı etmeyeceğiz. İçerik analizi girişimini, birden fazla y öntemin aynı sonuca ulaşıp ulaşmadığına göre değil, ortaya çıkan ölçü mün dünyamız hakkında ne söylediğine göre değerlendirmeliyiz.

Doclingo https://www.doclingo.ai

21.5 Sonuç

Kitabında, *Bit by Bit: Social Research in the Digital Age*, Matt Salganikaraştırmacıların, idari veya endüstriyel uygulamalar gibi başka bir amaç için toplanan verileri yeniden kullanma olasılıklarını vurgulamaktadır. Salganik, bu verilerin belirli bir amaç için tasarlandığını, ancak o amacın *not* research olduğunu ve bu hedefler arasındaki farkın özellikle erde bir farklılığa yol açtığını belirtmektedir.

Denetimsiz öğrenmenin sonuçlarını, başka bir amaç için tasarlanmış ölçüm olarak düşünmenin faydalı olduğunu düşünüyoruz. Bu ölçüm, araştırmacıların hedefleriyle çelişebileceğinden, kullanıcıların ölçümden ne beklediği ile ölçümün ne olduğu arasında her zaman bir boşluk vardır. Ancak, bu tamamen girişimi terk etmek için bir neden değildir. Verileri yeniden kullanmak son derece faydalı olabileceği gibi, ölçüm için keşif yöntemlerini yeniden kullanmak da son derece değerli olabilir.

> Salganik, bağlamımıza güzel bir şekilde uyan faydalı tavsiyeler sunuyor; her zaman verilerinizi oluşturan insanlar ve süreç hakkında mümkün olduğunca fazla şey anlamaya çalışmanızı öneririm. İkinci olarak, verileri yeniden kullanırken, genellikle problem iniz için ideal veri kümesini hayal etmek ve ardından o ideal veri kümesini kullandığınız veri kümesiyle karşılaştırmak son derece faydalıdır. Verilerinizi kendiniz toplamadıysanız, istediğiniz ile sahip olduğunuz arasında önemli farklılıklar olma olasılığı yüksektir. Bu farklılıkları fark etmek, sahip olduğunuz verilerden ne öğrenebileceğinizi ve ne öğrenemeyeceğinizi netleştirmeye yardımcı olacak ve toplamanız gereken yeni verileri önerebilir.
>
> (Salganik, 2018, s. 16)

Denetimsiz yaklaşımlardan geliştirilen ölçütlerle, modelin optimize ettiği hedef hakkında (verilerinizi oluşturan “süreç”) bir şeyler anlamak ve ideal bir dünyada sahip olmak istediğiniz veriler ile gerçek dünyada sahip olduğunuz veriler arasındaki farkları dikkatlice düşünmek faydalıdır.

Bu bölüm ayrıca Bölüm 4: Ölçüm ile sona ermektedir. Bu bölümde, metin verilerinden ölçütler oluşturmak için çeşitli tekniklerin genel bir görünümünü sağladık. Ölçüm için sözlük yaklaşımlarıyla başladık, ardından bir eğitim kümesini kodlama, bir sınıflandırıcıyı uyarlama ve bir ölçütü doğrulama dahil olmak üzere denetimli öğrenmenin genel bir görünümünü sağladık. Son olarak, ölçüm için keşif yöntemlerini nasıl yeniden kullanacağımızı açıkladık.

Doclingo https://www.doclingo.ai

İnsan kodlu bir eğitim kümesi oluşturmak, bir sınıflandırıcıyı eğitmek ve b unu altın standart verilerle doğrulamak, metin verileri için ölçütler tasarlama nın belki de en sağlam yöntemidir, ancak bu yaklaşım, araştırmacılara her za man mevcut olmayan kaynaklar ve belirli veri türleri gerektirir. Sözlük yönte mlerinden, bulunan verilerle denetim yapmaya, denetimli öğrenmenin pratik olmadığı durumlarda etkili ikame olabilecek keşif yöntemlerini yeniden kulla nmaya kadar birkaç alternatif önerdik. Ancak, bu yöntemlerin tümü, denetim li sınıflandırma dahil, kapsamlı doğrulama gerektirir.

Ölçümler geliştirildikten sonra, birbirleriyle veya diğer meta veril erle ilişkili ölçümler sormaya başlayabiliriz veya oluşturduğumuz öl çümlerin tedavi veya sonuç olarak işlev gördüğü deneyler yaratabil iriz. Bu sonraki göreve geçiyoruz:

Çıkarım. Burada, ölçümde tahmin için tanımladığımız benzer yöntemleri kull anarak ve nedensel çıkarım amacıyla ölçümler kullanarak ve geliştirerek dah a ayrıntılı bir şekilde tartışıyoruz.

---

[1]Bu bölüm, Grimmer ve Stewart (2013) eserinin 7.2 ve 7.3 bölümlerinin bir kopyasıdır.

[2]Pratikte, bu bile farklı yazılım sürümleri ve farklı makinelerdeki sayısal hass asiyet seviyeleri nedeniyle zor olabilir. Ancak, bunlar, analizin ilk olarak çalıştırı ldığı ortamı tam olarak yeniden üreten sanal ortamlar tarafından ele alınabile cek mühendislik sorunlarıdır.

[3]Ayrıca Lancichinetti ve diğerlerinin dikkatli sayısal analizi ve başlatma stratejisine de bakın. (2015).

Doclingo https://www.doclingo.ai

BÖLÜM V

Çıkarım

Ölçüm, gözlemlenen bir popülasyonu tanımlamak için bize araçlar sağlarken, gözlemlenmeyen bir popülasyon hakkında çıkarım yapmaya çalışmanın ek zorlukları vardır. O popülasyon birçok nedenle gözlemlenmemiş olabilir: ölçmesi daha zor olabilir, gelecekte gerçekleşebilir veya karşıt gerçek olabilir. Bu tür çıkarım problemlerinin merkezi bir zorluğu, her zaman önceden belirgin olmamalarıdır. Çıkarım için gereken varsayımlar hakkında netlik, analizin kesin hedefi hakkında netlik gerektirir (Lundberg, Johnson ve Stewart, 2021).

Özellikle, farklı alanlar, gelecek ve karşıfaktüel ayarlar hakkında güvenilir çıkarımlar yapma bilgisi son birkaç on yılda patlama yaptı. Bu sonraki birkaç bölümde, bu büyüyen literatürü metin olarak veri literatürü ile birleştiriyoruz ve metinle nedensel çıkarımlar yapmanın belirli zorluklarına özel dikkat gösteriyoruz. Bölüm 22: Çıkarım İlkeleri fiziksel olarak elimizdeki görev için ilkeleri belirleme genel kalıbımızı izliyor. Bu bölümde, tahmin ile nedensel çıkarım arasındaki benzerliklere ve farklılıklara özel dikkat gösteriyoruz.

2009 yılında, Google, insanların aradığı terimleri kullanarak, bu veriler mevcut olmadan önce Hastalık Kontrol Merkezi tarafından bildirilen grip oranlarını tahmin etti (Ginsberg ve diğ., 2009). Bu aynı fikir, tweetlerdeki dili kullanarak kalp hastalığı mortalitesi (Eichstaedt ve diğ., 2015) ve siyasi anketler (O'Connor ve diğ., 2010; Beauchamp, 2017) gibi çeşitli sonuçları tahmin etmek için Twitter verilerine uygulanmıştır. Bu, "şu an tahmini" (Choi ve Varian, 2012) olarak adlandırılan bir süreçtir.

Dünyanın mevcut durumunu, başka bir ölçümle uyumlu bir şekilde tahmin etmek. Bölüm 23: Öngörü bu ve çeşitli diğer öngörü görevlerini ele alıyoruz.

Sonra, bazı müdahaleler altında karşıfaktüel popülasyonlar hakkında çıkarımlar yapmayı içeren nedensel çıkarım görevine geçiyoruz. Bölüm 24: Neden-sonuç Çıkarımı neden-sonuç çıkarımının temellerini ve özellikle metinle ilgili ortaya çıkan bazı özellikleri ortaya koymaktadır. Ardından, üç bölüm boyunca, metnin nedensel çıkarım çerçevesinde oynayabileceği her bir rolü ele alıyoruz: Bölüm 25: Sonuç Olarak Metin, Bölüm 26: Tedavi Olarak Metin

Doclingo https://www.doclingo.ai

Ve Bölüm 27: Karıştırıcı Olarak Metin.

Doclingo https://www.doclingo.ai

BÖLÜM 22

Çıkarım İlkeleri

Bu kitap bölümünde *çıkarımsal* görevleri ele alıyoruz. Çıkarımı, iyi tanımlanmış (a ncak muhtemelen karşıfaktüel) bir popülasyonda bulunan bir miktarı tahmin et mek için bir örnek kullandığımız durumlar olarak dar bir şekilde tanımlıyoruz. Bu na karşılık, hem keşif hem de ölçümde, sahip olduğumuz belgeler örneğinde ilgi çekici bir kavramı yakalayan yüksek boyutlu verilerin yararlı bir fonksiyonunu bul maya odaklandık. Çıkarımda, daha geniş bir popülasyona çıkarım yapmak için da ha güçlü varsayımlara ihtiyaç duyacağız.[1]

Doclingo https://www.doclingo.ai

22.1 Öngörü

Bir görev, *prediction*: belirli bir birim veya birimler
in farklı bir popülasyondan beklenen sonuç değeridir. Tahmin görevle
rinin, kitapta daha önce ele aldığımız denetimli öğrenme görevlerine
yüzeysel olarak benzer göründüğünü göreceğiz. Ancak burada öneml
i bir fark var: daha önce, ilgi popülasyonundan rastgele örnekleme ya
pabileceğimizi varsaymıştık, çünkü tüm birimleri zaten gözlemlemişti
k. Bu güçlüdür, çünkü beklenti açısından, örnekteki ilişkilerin popülas
yondaki ilişkileri yansıtacağını ima eder.

Yeni bir nüfusa tahmin yapmak, ilgi alanındaki nüfustan rastgele
bir örnek almanın mümkün olmadığı anlamına gelir. En yaygın tah
min görevi, mevcut olan bilgileri kullanarak gelecekteki sonuçların
nasıl görüneceğini tahmin etmektir. Ancak, elbette, gelecekte rastg
ele bir örnek alamayız. Bu nedenle, tahmin ek bir varsayım gerektir
ir: geçmişteki sonuç ile özellikler arasındaki ilişki geleceğe devam e
der. Bir tahmin yapmadan önce, bu varsayım doğrulanamaz. Evet,
verilerimizi kullanarak varsayımı yaratıcı bir şekilde yaklaşık olarak
belirleyebiliriz, ancak gerçek birimleri gözlemleyene kadar varsayı
mı test edemeyeceğiz. Bu, ölçüm bölümünde tanımladığımız denet
imli öğrenme görevlerinden farklıdır. Tüm verileri gözlemliyorsak,
sınıflandırıcılarımızı oluşturmak için birimlerden rastgele bir örnek
alabiliriz. Rastgele örnek, eğitim setimizde bulunan ilişkinin, ortala
ma olarak, test setinde bulunanla aynı olduğunu varsayımını haklı
çıkarır.

Başka bir deyişle, tahmin yöntemleri, önceki tahmin performansının
gelecekteki başarıyı göstereceğini gerektirir. Sosyal bilim verilerinde bu
güçlü bir varsayımdır - özellikle nadiren meydana gelen ve temel süreçl
erin hızla değişebileceği olayları tahmin ettiğimizde. Örneğin, popüler b
ir tahmin görevi olan başkanlık seçimlerini tahmin etmeyi düşünün.
Bir üzerine inşa etme 30 yıllık siyaset bilimi literatürü, büyük bir sayı
tahminciler, Nate Silver'ın meteoritik yükselişini takip ederek başkanlık seçim
leri hakkında olasılıksal tahminler yapmaya başladılar. Artık belirli bir adayın
seçimi kazanma olasılığı hakkında tahmincilerin tartıştığını görmek yaygın bi
r durumdur; bazı durumlarda seçimden aylar önce bile.

Seçim tahmininin istatistiksel modelleri, aynı temel içgörüye dayanır: başk
anlık oy tercihi hakkında yapılan kamuoyu yoklamaları, seçim sonuçlarını ön
görmektedir. Önceki seçimlerden elde edilen verileri kullanarak, tahminciler
kamuoyu yoklamaları ile önceki seçim sonuçları arasındaki ilişkiyi modelleme
ktedir. Daha sonra, önceki seçimlerde bulunan ilişkiyi kullanarak, bunu

Doclingo https://www.doclingo.ai

mevcut seçim, yaklaşan seçimin sonucunu tahmin etmek için. Güçlüvar sayım, anketler ile sonuçlar arasındaki ilişkinin önceki seçimlerdebulun anların, mevcut seçimde de bulunacağıdır. Bu varsayımkanıtlanamaz, a ncak seçim sonucundan sonra tahminlerin doğruluğunu gözlemleyebili riz. Ancak önceki seçimlerdeki tahminlerin doğruluğu, sonraki seçimler de de doğru olacağına dair bir garanti değildir.

Doğru tahminler yapmak, ilgi alanındaki sonuçların tahmin edici olan, tahm in yapıldığında mevcut olan ve popülasyondaki sonuçlarla aynı ilişkiye sahip ol ma olasılığı yüksek olan özellikleri tanımlamayı gerektirir. Seçim tahminine ger i dönecek olursak, Amerikan siyaseti üzerine geniş bir literatür, ülkenin ekono mik koşullarının mevcut başkanların yeniden seçilme şanslarıyla ilişkili olduğu nu belirtmiştir. Yine de, tahminciler, COVID-19 ile ilgili kapanmalar nedeniyle 2 020'deki ekonomik durgunluğu nasıl ele alacakları konusunda belirsizdi. Ekonomik bir durgunluk genellikle mevcut parti için felaketi işaret ede rken, bunun 2020 seçimlerinde böyle olacağına dair bir garanti yoktu. Kamuoyunun, Başkan Trump'ı durgunluk nedeniyle affedeceğini tah min etmiş olabiliriz. Sonuçta, ekonomik daralmanın bazı bileşenleri, C OVID-19'un yayılmasını durdurmak için işletmelerin kapanmasıyla kas ıtlıydı. Ya da tam tersini tahmin etmiş olabiliriz: kamu, Trump'ı korona virüse karşı hükümetin yanıtını kötü yönetmekle ve pandeminin sonu cu olan ekonomik durgunluğu muhtemelen uzatmakla suçlayacaktı. E konomi ve oy verme arasındaki ilişkinin gelecekte nasıl olacağına dair içsel belirsizlik, o dönemde ekonominin ve mevcut performansın 2020 'deki ilişkisinin önceki seçimlerdeki gibi olup olmadığını doğrudan test edecek verilerin mevcut olmadığı anlamına geliyordu.

Doclingo https://www.doclingo.ai

22.2 Nedensel Çıkarım

Ayrı bir çıkarımsal görev, nedensel çıkarım: dünyada müdahale ettiği mizde sonuçlar nasıl farklılık gösterir? Nedensel çıkarımın uygulamaları g eniş bir yelpazeye yayılmaktadır: bir ilacın etkisini değerlendirmekten, bir ülkede bir politikanın uygulanmasının etkisine, bir reklamın tüketicilerin satın alma kararları üzerindeki etkisine kadar. Nedensel bir ifadenin anah tarı, akademisyenlerin müdahale yalnızca değişseydi sonucun nasıl farklı olacağını sormasıdır.

İlk bakışta, nedensel çıkarımın sadece başka bir tahmin problemi olduğ unu düşünebiliriz. Sonuçta, bir birimin bir müdahaleye yanıtı, verilerimizin dışında bir yanıtı "tahmin etmenin" başka bir örneğidir. Ancak tahmin ve n edensel çıkarımı birleştirmek, hesaplamalı sosyal bilimler literatüründe kaf a karışıklığına neden olmuş ve hesaplamalı sorular üzerinde ilerleme için ci ddi bir engel teşkil etmiştir. Bu kafa karışıklığını önlemeye yardımcı olmak i çin, tahmin ve nedensel çıkarım arasındaki dört ana farkı vurguluyoruz. Bu nların: (1) tanımlama ve tahminin rolü, (2) birincil hedefler, (3) modellerin d oğrulanması ve (4) özelliklerin rolü açısından nasıl farklılaştığını belgeliyoru z.

22.2.1 NEDENSEL ÇIKARSAMA YERLERİNİN TANIMLANMASI İLK ÖNCE

Hem tahmin hem de nedensel çıkarım için sürecin iki bileşeni ara sında bir ayrım yapıyoruz: tanımlama ve tahmin. Heuristik olarak, pa rametrelerin tanımlandığını söyleyeceğiz eğer veri setleri benzersiz bir şekilde bir parametre değeri setine eşleniyorsa. Tanımlama, gözl emlenen veri setlerimizden sonsuz veri ile ne öğrenebileceğimizle il gilidir. Tahminde, bir tanımlama varsayımı, elimizdeki verilerin örne k dışı veriler için yararlı olduğu olabilir. Nedensel çıkarım için, tanıml ama varsayımı, tedavi atamasıyla ilişkili olan arka plandaki "karıştırıc ı" faktörlerin olmadığıdır; yani, gözlemlenen ilişki, ilgilendiğimiz gözl emlenmemiş karşıt nüfusu temsil eder.

Tahmin, gözlemlenen veri setimizin özelliklerini nasıl tanımladığımızla ilgil idir. Tahmin varsayımları, tahmin için kullanılan fonksiyonel formlar veya beli rli istatistiksel modellerin nasıl uyarlandığı hakkında olabilir. Örneğin, bir tah min yaparken standart modellerden yararlanabiliriz—örneğin, doğrusal regr esyon—veya bu modellerin düzenlenmiş versiyonları—örneğin, Lasso veya R idge regresyonu. Tahmin varsayımları, belirli bir tahmin edicinin verileri iyi bi r şekilde tanımlama yeteneği ile ilgilidir.

Hem tanımlama hem de tahmin etme önemlidir, ancak nedensel alanında akademisyenler

Doclingo https://www.doclingo.ai

çıkarım, kimliğin birinci öncelik olarak tanımlanmasına odaklanma eğiliminde olmuştur. Bunun nedeni, kimlik varsayımlarının genellikle verilerden doğrulan amaz olmasıdır. Ve kimlik olmadan, hiçbir tahmin rutini doğru parametreleri g üvenilir bir şekilde tahmin edemez. Aksine, tahmin akademisyenleri genellikle tahmini öncelikli olarak ele alır. Bunun nedeni, tahminle sonunda doğru olup o lmadığımızı görebilmemizdir - dolayısıyla, tahminler genellikle kimlik varsayıml arı ihlal edilse bile yapılacaktır.

Nedensel çıkarım ile tahmin arasındaki büyük bir fark, nedensel çıkarım yapmaya çalışan akademisyenlerin, tanımlama varsayımlarını daha olası hale getirmek için ara ştırma tasarımlarını açıkça oluşturacak olmalarıdır. Örneğin, akademisyenler, daha z ayıf varsayımlar altında nedensel etkileri tanımladıkları için nedensel çıkarım için altın standart olan rastgele deneyler tasarlayacaklardır. Gözlemsel nedensel çıkarım çalış malarında, akademisyenler, araştırma tasarımlarını potansiyel karıştırmayı sınırlama k için kullanmalarını sağlayan varyasyonları arayacaklardır; bu, nispeten zayıf tanımla ma varsayımları altında gerçekleşir.

Bu, tasarım ve tanımlama sorunlarının tahmin yaparken önemsiz ol duğu anlamına gelmez. Tahmin yapmak için ilgili verileri kullandığımı zdan emin olmalıyız. Örneğin, seçim tahmini bağlamında, 1932 ABD s eçimlerinden elde edilen verilerin sonuçları tahmin etmekte yararlı ol up olmadığını sorabiliriz. 2020 ABD seçim (muhtemelen değil). Ama hangi verilerin dahil edileceğini veya hariç tutulacağını belirlemek, tahminler hakkında t anımlayıcı varsayımlar yapmak anlamına gelir.

22.2.2 TAHMİN, OLACAK SONUÇLAR HAKKINDA, NEDENSEL ÇIKARSAMA, SONUÇLAR HAKKINDA MÜDAHALELER

Öngörü ve nedensel çıkarım temelde farklı hedeflere sahiptir. Öngörü nün tamamı, tahminin yapıldığı popülasyonun dışındaki bir birim için son ucu tahmin etmeye odaklanmıştır. Buna karşılık, nedensel çıkarımlar bir müdahalenin bir sonucu nasıl etkilediğini tahmin etmeye odaklanır.

Bu iki görev kavramsal olarak farklıdır ve bir görevde iyi performans göstermek, diğerini g erçekleştirmek için iyi donanımlı olduğunuz anlamına gelmez.

Bir tahmin yaparken, çabalarımızın tamamı, elimizdeki örnek bilgilerini kullanarak bazı örnek dışı değerlerin bir tahminini geliştirmeye odaklanmaktadır. Verilerin nasıl üretildiğine veya sonucun özelliklerle nasıl ilişkili olduğuna dair bir teoriye sahip olm ak, daha doğru bir model inşa etmeye yardımcı olabilir, ancak özelliklerin dahil edilm esi için teorik bir açıklama gerekmemektedir. Bir özellik, daha iyi bir gelecekteki tahm in oluşturmamıza yardımcı oluyorsa faydalıdır (ancak doğruluk değerlendirmelerimiz de güvenilir olmak için genellikle dikkatli varsayımlara ihtiyaç duyarız). Ve bir

Doclingo https://www.doclingo.ai

Sonuç olarak, tahmin konusunda iyi olan modeller, diğer ortamlara uygulanmak için uygun olmayabilir. Aşağıda açıkladığımız gibi, çok doğru bir tahmin modeli bile genellikle yanıltıcı açıklamalar önerir ve olayların neden gerçekleştiği konusunda çok az içgörü sağlar. Bu kopukluk, bu "ya ne olursa" veya "neden" sorularının kendilerinin nedensel olmasından kaynaklanır, gelecekle ilgili olsa bile.

Nedensel bir çıkarım yaptığımızda, temelde farklı bir odaklanma söz konusudur. Nedensel çıkarımlar, yalnızca bir müdahalenin etkisini tahmin etmeye odaklanmıştır. Bir müdahale ile, değiştirilebilecek makul bir dünya özelliğini kastediyoruz. Sadece o müdahaleyi değiştirmenin bir birim için farklı bir sonuç doğurduğu durumlarda nedensel bir etki meydana gelir. Elbette, bu karşıfaktüel dünya halini asla gözlemleyemeyiz. Bu nedenle, nedensel çıkarımın tüm amacı, gözlemlediğimiz karşıfaktüel dünya halinin makul tahminlerini yapmak için çalışmalar tasarlamak ve modeller tahmin etmektir; burada yalnızca müdahale değişir. Bu, özellikleri seçerken çok daha seçici olmamız gerektiği anlamına gelir.

22.2.3 TAHMİN VE NEDENSEL ÇIKARIM FARKLI DOĞRULAMALAR GEREKTİRİR

Öngörüler ve nedensel çıkarımlar, modellerimizi değerlendirmek için mevcut olan bilgilere göre de farklılık gösterir. Bir öngörüde bulunduğumuzda, nihayetinde doğru yanıtı görürüz. Bir nedensel etkiyi tahmin ettiğimizde ise, ilgi alanımızdaki müdahalenin değiştiği karşıt gerçeklikte neler olacağını asla göremeyiz. Sonuç olarak, tahmin ettiğimiz nedensel etkileri doğrudan doğrulayamayız - ya bir grup için ya da bireysel düzeyde. Holland (1986) bunu nedensel çıkarımın temel problemi olarak adlandırır. Bilgi açısından bu fark, öngörüleri ve nedensel çıkarımları değerlendirirken farklı standartların kullanıldığını ima eder.

Gerçek sonuçlar elimizde olduğunda, öngörülerimizi gerçeklerle doğrudan karşılaştırabiliriz; tahmin edilen sonuç değerlerinin gerçek sonuç değerleriyle ne kadar iyi örtüştüğünü karşılaştırarak. Bu basit olsa da, farklı karşılaştırmalar, tahminin farklı özellikleri hakkında bilgi verir. Örneğin, bir tahminin doğruluğunu hesaplamakla ilgilenebiliriz: doğru tahmin yaptığı zamanın oranı. Ya da, bir tahminin kalibre edilip edilmediğini değerlendirmekle ilgilenebiliriz: bir olayın meydana gelme olasılığının tahmin edilen değeri, olayın meydana gelme gerçek olasılığıyla örtüşüyor mu?

Tam tersine, gerçek karşıfaktüel sonuçları asla göremiyoruz ve bu nedenle gerçek nedensel çıkarımları değerlendirmek zorunlu olarak daha dolaylıdır. Nedensel çıkarımları değerlendirmek için yaygın bir yaklaşım, tanımlama koşullarını değerlendirmeye dayanır: herhangi bir karıştırmanın verilerde bulunmadığını sağlamak için kullanılan varsayımlar.

Doclingo https://www.doclingo.ai

Verilerdeki karıştırmanın, ilgi alanındaki nedensel etkileri güvenilir bir şekilde tahmin etmeyi imkansız hale getirmediğini sağlamak için kullanılan varsayımlar. Doğrulama için başka bir yaklaşım, bir duyarlılık analizidir. Duyarlılık analizinde, olası karıştırmalar hakkında varsayımlar yaparız ve ardından bu karıştırmanın bir bulguyu etkilemesi için ne kadar büyük olması gerektiğini değerlendiririz.

Ve diğer ortamlarda, bulgularımızın etkileri tahmin ederken belirli varsayıml ara dayanmadığını göstermek için farklı tahmin stratejileri kullanırız.

Tahmin ile nedensel çıkarım arasındaki farklar, bilgisayar bilimlerinde en yaygın d eğerlendirme tekniği olan paylaşılan görevin, nedensel çıkarım için çok daha az yarar lı olduğunu önermektedir. Bilgisayar bilimlerinde paylaşılan tahmin görevlerinde ina nılmaz ilerlemeler kaydedilmiştir. Bu görevlerde araştırma ekipleri, bu yöntemlerin a ynı veri setine uygulanan önceki yöntemlerden daha iyi performans gösterdiğini göst ererek yeni tahmin modellerinin iyi çalıştığını kanıtlarlar.

Paylaşılan görevler, analistlerin doğru yanıtı bilmek için tüm veri kümesini o luşturmak zorunda olmaları nedeniyle nedensel çıkarım için daha az faydalıdır. Sonuç olarak, bu uygulamalarda bulunan karıştırma, gerçek dünyadaki karıştı rmanın doğasını yansıtmayabilir. Bu, nedensel çıkarım paylaşılan görevlerinin, belirli türde karıştırmaların gerçek uygulamalarda meydana geldiğini varsaydı ğını ima eder. Eğer başka türde karıştırmalar aslında daha yaygınsa, nedensel yöntemleri değerlendirmek için paylaşılan görev yaklaşımına güvenmek, daha az etkili yöntemlerin seçilmesine yol açabilir. Paylaşılan görevde iyi performan s gösteren, ancak gerçek dünya görevlerine uygulandığında kötü performans gösteren nedensel çıkarım yöntemlerini seçebiliriz. Ayrıca, paylaşılan görevler, herhangi bir paylaşılan görev içinde sabit tutulacak olan tanımlama koşulları y erine tahmin stratejilerini önceliklendirir.

Bu pozisyonu çok ileri götürmek istemiyoruz—simüle edilmiş veri setleri, yeni n edensel çıkarım yöntemlerini değerlendirmek için çok faydalı olabilir. Aslında, nede nsel çıkarım yöntemlerinin, yöntemlerin varsayımlarını kullanarak üretilen verilere uygulandığında doğru tahminleri elde etmesi gereklidir (ama yeterli değildir). Ayrıca, simüle edilmiş veri setleri, tanımlama koşullarında küçük perturbasyonlar yapıldıkça yöntemin nasıl performans gösterdiğini karakterize etmeye yardımcı olabilir. Ancak, bu görevler, belirli bir ortamda nedensel çıkarım yöntemi için kull anılan tanımlama varsayımlarının daha dikkatli ve uygulamaya özgü bir analizini n yerini alamaz.

22.2.4 PREDİKSİYON VE NEDENSEL ÇIKARIM FONKSİYONLARI FARKLI ŞEKİL DE KULLANILIR

Prediksiyon ve nedensel çıkarımda özellikler temelde farklı roller üstlenir. Prediksiyonda, özellikler , örnek dışındaki birimlere tahmin yapmak için kullanılan araçlardır. Biz yalnızca, tahmin setimizdeki s onuçla aynı ilişkiye sahip olma olasılığı yüksek olan veri setimizdeki bilgileri bulmak istiyoruz.

Doclingo https://www.doclingo.ai

Örneğin, geleceği tahmin etmek için gecikmeli değerler kullanmak oldukça yaygındır. Elbette, bir sonucun önceki değerlerinin gelecek teki değerlerle neden bu kadar güçlü bir ilişkiye sahip olduğunu ve ya bu önceki değerlerin nereden geldiğini bilmeyebiliriz - ancak yin e de tahmin için faydalıdırlar.

Nedensel çıkarımda ise, özelliklere temelde farklı bir bakış açısı getiriyoru z. Nedensel çıkarımda, tedaviler ve kovaryantlar arasında ayrım yapıyoruz. T edaviler, etkisini değerlendirdiğimiz müdahaleyi temsil eder. Kovaryantlar, n edensel etkilerin daha doğru, tarafsız ve kesin bir şekilde tahmin edilmesini s ağlamak için kullanılacaktır. Bu, modellerimize hangi bilgilerin dahil edileceği ni düşünürken dramatik şekilde farklı tavsiyelere yol açar. Prediksiyonda, so nucu iyi tahmin etmek için kullanabileceğimiz her türlü kovaryantı ararız, tah minimizi yaptığımızda mevcut olan ve bağımlı değişkenle istikrarlı bir ilişkiye sahip olma olasılığı yüksek olanları tercih ederiz. Nedensel çıkarımda ise, kov aryantların nedensel süreçte nerede düştüğüne dikkat etmemiz gerekir. Örn eğin, yalnızca pre-treatment olan kovaryantları dahil edebiliriz: bunlar, ilginç müdahalenin nedensel bir sonucu değildir (Montgomery, Nyhan ve Torres, 2018). Ve tedavi öncesi kovaryantlar arasında, yanlılığı artırabilecek diğ er değişkenlerden kaçınmak istiyoruz. Bu, yanlılığı daha kötü hale getir en belirli bir bağımlılık yapısına sahip çarpanlar veya değişkenleri içerir (Elwert ve Winship, 2014).

Doclingo https://www.doclingo.ai

22.3 Tahmin ve Nedensel Çıkarımın Karşılaştırılması

Tahmin ve nedensel çıkarım, eksik olan değerleri tahmin etmekle ilgilidir. Ancak tahminde, nihayetinde gerçek eksik değeri gözlemleyeceğiz. Nedensel çıkarımda ise, gerçek, karşıt durum değerini asla göremeyeceğiz. Bu ayrımın görünürdeki netliğine rağmen, tahmin ve nedensel çıkarım arasındaki farklılıklar ince olabilir ve dikkatli bir şekilde belirlenmeyi gerektirir.

Örneğin, bir internet reklamcılığı kampanyasının etkinliğini değerlendirmek için işe alındığımızı varsayalım. Şirketten ürününü kimin satın alacağını tahmin etme talebini hayal edebiliriz. Bu değerlendirmeyi yapmak için, ürünün kimin satın alacağını tahmin etmek amacıyla muhtemelen birçok demografik, sosyoekonomik ve özel veri kullanırız. Ardından ayrı bir soru hayal edebiliriz: reklam kampanyamız bireyleri ürünümüzü satın almaya teşvik ediyor mu? Bu, nedensel bir sorudur. Bir reklamı gören bir bireyin davranışının, reklamı gösterilmeyen bireylerden nasıl farklılaştığını sorar—dünyanın karşıt durumları hakkında bir soru.

Şirket, neden-sonuç çıkarımı ve tahmini bir araya getiren daha ince soruları yanıtlamamızı isteyebilir. Örneğin, şirket şunu sorabilir: Bu birey, onlara reklamı gösterirsek ürünü satın alacak mı? Yüzeysel olarak, bu bir tahmin sorusudur. Bunun nedeni, yalnızca bir bireyin (belirli bir özellik setine sahip) bir ürünü satın alıp almayacağını değerlendirmemizi istemesidir; bu durumda onlara bir reklam da sunuyoruz. Reklamın birey üzerinde çok az veya hiç etkisi olmasa bile, satın alma olasılığının yüksek olduğunu yanıtlayabiliriz. Aksine, şunu sorabiliriz: Reklama en duyarlı olan kimdir? Bu, koşullu ortalama tedavi etkilerini tahmin etmeye ve reklamın çok etkili olduğu bireylerin katmanlarını tanımlamaya odaklanan iyi tanımlanmış bir neden-sonuç çıkarım sorusudur.

Neden-sonuç çıkarımı ile tahmin arasındaki ayrım, tahmin araçlarının neden-sonuç çıkarımları yaparken yararsız olduğu anlamına gelmez. Örneğin, büyüyen bir literatür, belirli bir müdahalenin bireylerin özellikleri arasında nasıl farklılık gösterdiğini tahmin etmek için makine öğrenimi yöntemlerini kullanmaktadır. Bu koşullu ortalama tedavi etkileri, ilgili bir soruyu sormaktadır: Belirli bir özellik setine sahip bireyler için ortalama olarak etki nedir? Bu, benzer tahmin sorusundan farklıdır: Belirli bir özellik setine sahip bireyler için ne olasıdır?

Doclingo https://www.doclingo.ai

22.4 Tahmin ve Nedensel Çıkarımda Kısmi ve Genel Denge

Ayrı bir konu olarak, tedavinin yalnızca bir bireye uygulandığında ve tedavinin bir gruba uygulandığında nedensel etkilerin nasıl farklılık gös terdiğini sorabiliriz. Bu, genellikle kısmi ve genel denge olarak adlandırı lan şeyin farkıdır.

Örnek olarak, sosyal medya sitesi Twitter'ın kullanıcıların 280 karakter uzunluğunda gönderi oluşturmasına izin verme kararını düşünün, bu önceki 140 karakter kısıtlamasının iki katıdır. Bu değişikliğin etkisini merak ettikleri için, Twitter önce bir deney yaptı: rastgele olarak daha fazl a 140 karakter kullanma yeteneğini küçük bir hesap grubuna verdi. Elbette bu rastgelelik, 280 karakter yazabilen hesapların, yazamayan hesaplardan sist ematik olarak farklı olmadığını sağladı. Ancak bu, deneyin politikanın genel olarak uygulanması durumunda ne olacağı hakkında bilgilendirici olduğu anlamına gelmez.

Bu, küçük bir kullanıcı grubunun, diğer kullanıcıların erişemediği bir yeteneğe sahip olması nedeniyledir. Sonuç olarak, daha uzun tweetler yazabilen kullanıcıl ar, diğer kullanıcılardan daha uzun tweetler yazma yeteneklerini vurgulayan yük sek etkileşimli tweetler yazma eğilimindeydiler.

Bu, yalnızca bir alt kümenin tweet'e erişiminin olması açısından 'kıs mi' bir etkidir. Tüm kullanıcılar 280 karaktere sahip olduğunda, "genel denge" etkisi devreye girecek ve daha uzun tweetler yazmanın yenili ği kaybolacak ve bu etkinin ortadan kalkmasını bekleyeceğiz (Jaidka, Z hou ve Lelkes, 2019).

Kısmi ve genel denge arasındaki farklar, bir çalışmanın sonuçlarını nas ıl yorumlayacağınızı anlamak için esastır, çünkü bunlar, küçük bir deneyd en elde edilen bir politikanın genel olarak uygulanması durumunda ne ol acağına doğrudan işaret eder. Nedenini açıklayan bolca benzer örnek var dır. İş eğitimi, işçilerin rekabet avantajı elde etmesi için faydalı olabilir, an cak tüm işçiler aynı iş eğitimine sahip olduğunda bu avantaj ortadan kalk ar ve iş eğitimlerinin maaşları artırmadığını görebiliriz. Benzer şekilde, ün iversite diplomaları, okulda edinilen bilgi ve birinin etkili bir şekilde çalış ma yeteneği hakkında bir sinyal sunması nedeniyle değerli olabilir. Ancak herkes üniversiteye giderse, üniversitenin sinyal değeri ortadan kalkar.

Kısmi ve genel denge sorunları, rastgele kontrol denemelerinin (RCT'ler) bazı sınırlamalarını vurgulamaktadır. RCT'ler, sosyal bilimler alanında devrim yaratmı ş ve genellikle nedensel çıkarım için altın standart olarak öne sürülmektedir.

Doclingo https://www.doclingo.ai

RCT'lerde kesinlikle bir değer görüyoruz ve hepimiz bunları araştırmalarımızda kullandık. Ancak, sorduğumuz en önemli nedensel sorulardan bazıları için RCT'lerin ciddi sınırlamaları vardır.

RCT'ler neredeyse tamamen kısmi denge etkilerini tahmin etmek için tasarlanmıştır, ancak en ilginç sosyal bilim (ve politika) sorularımızın çoğu genel denge sorularıdır. Örneğin, bir seçim sırasında oy tercihi üzerindeki bir kampanya mesajının etkisini tahmin etmek için tasarlanmış bir RCT'yi düşünün (Kalla ve Broockman, 2018). Rastgele denememiz, bir kampanyadan gelen bir mesajı hiç mesaj almamakla karşılaştırmak olabilir. Daha sonra koşullar arasında oy tercihini karşılaştırabiliriz ve bu bize tek bir mesajın marjinal etkisi hakkında kanıt sağlar. Null bir etki bulursak, mesaj almanın ve almamanın arasında bir fark yoksa. Bu, kampanyanın diğer tüm yönleri göz önüne alındığında, bu belirli mesajın özellikle etkili olmadığını öne süren ilginç bir bulgudur. Ancak, kampanya mesajlarının genel olarak etkili olmadığı sonucuna varmak mantıksal bir hatadır. Çünkü, mesajlaşmayı tamamen durduran bir kampanyaya önemli ölçüde farklı bir tepki olacağını bekleyebiliriz.Bu nedenle, vatandaşların oy tercihi üzerindeki kampanyaların genel etkisi hakkında bir sonuca varamayız.

Öngörü yaparken paralel bir dizi endişe ortaya çıkar. Tarihsel verilere dayalı öngörülerde bulunduğumuzda, geçmişteki sonuç ile özellikler arasındaki ilişkinin, örnek dışı verilerde de geçerli olduğu güçlü varsayımını yapıyoruz. Bu, dünya değişirse yanlış olabilir—özellikle, tahminimizin bireylerin davranışlarını nasıl etkilediği durumunda. Bu, sosyal medya şirketlerinin düzenli olarak karşılaştığı bir sorundur. Şirket, örneğin, potansiyel bir siyasi reklamverenin kampanya düzenlemelerine uyan kampanya reklamları yayınlayıp yayınlamayacağını sorabilir. Bu tahmin yöntemi geçmiş veriler için doğru olsa bile, stratejik kötü niyetli aktörler, gelecekteki niyetlerini gizlemek için yeni tahmin yöntemini manipüle etmeye çalışabilir. Bu stratejik yanıt, tahmin yönteminin artık özellikle öngörücü olmamasına neden olur. Bu fikir, makroekonomiden Lucas Eleştirisi'nin bir örneğidir (Lucas, 1976). Ana fikir, stratejik aktörlerin geçmiş yanıtı bildiği ve ardından bu yanıtı öngörerek davranışlarını değiştirecekleridir.

Doclingo https://www.doclingo.ai

22.5 Sonuç

Çıkarım, birçok araştırma projesinin nihai hedefidir. Ancak bu kitap ta tanımladığımız diğer araştırma aşamaları gibi, ilgi alanındaki belirli çıkarım görevini anlamak, uygun çıkarımları nasıl yapacağımızı belirle mek için esastır. Bilgisayar bilimcileri tahmine vurgu yaparken, sosyal bilimciler nedensel çıkarıma çok daha fazla dikkat ayırmışlardır.

Hem tahmin hem de nedensel çıkarımın araştırma sürecinin temel bi leşenleri olduğu açıktır. Araştırmacıların hangi çıkarım görevini üstlendi klerinden emin olmaları da gereklidir. Bunun nedeni, tahmin ve nedens el çıkarımın farklı varsayımlar gerektirmesi ve farklı doğrulamalarla gel mesidir. Bir sonraki bölümde, tahmin için bu varsayımları ve doğrulama ları tanımlayacağız.

Bu bölümün bazı kısımları Grimmer, Roberts ve Stewart (2021)'dan alınmıştır.

Doclingo https://www.doclingo.ai

BÖLÜM 23

Tahmin

Metni ölçüm için nasıl kullanacağımızı anlamak, ilgi alanındaki kavramları operasyonelleştirmemize yardımcı olabilir. Bu bölümde, çok farklı bir gör ev için benzer bir yaklaşım seti kullanacağız - tahmin. Bir kişinin, bir ekon ominin, bir kurumun veya bir ülkenin başına ne geleceğini tahmin etmek, politika kararlarını bilgilendirebilir, bize para kazandırabilir ve sosyal dün yayı anlama derinliğimizi artırabilir. İnternetteki temel işlerden biri ve ma kine öğrenimindeki teknik gelişmelerin itici güçlerinden biri, kullanıcıların tıklayacağı zamanı tahmin ederek web sayfalarındaki reklamların seçiml erini optimize etmektir. Hisse senedi fiyatlarını tahmin etmek, yatırımcılar ve ekonomik tahmincilerin birincil görevlerinden biridir. Yazım hatalarını veya bir metin mesajındaki bir sonraki kelimeyi tahmin etmek, artık çoğu telefon, bilgisayar ve arama motorunda varsayılan bir yazılım görevidir. Metni içindeki bir kavramı ölçmek için kullanmak yerine, bu bölümde met ni gelecekle ilgili bir şey söylemek için kullanmayı düşüneceğiz.

Metin, yapılandırılmış verilerde yer almayan ve tahmin için son derece fayd alı olabilecek insanlar, işletmeler ve hükümetler hakkında geniş bir bilgi yelpaz esi içermektedir. Örneğin, hiçbir spamcı e-postaları açıkça "spam" olarak işaret lemez, ancak e-posta istemcileri, mesajların metnini kullanarak mesajın spam klasörüne mi yoksa gelen kutusuna mı gitmesi gerektiğini sınıflandırabilir. Met in, sosyal tahminlerde de faydalıdır - araştırmacılar, hukuki süreçlerin metnini kararları tahmin etmek için (Aletras ve diğ., 2016), tweetlerin metnini filmlerin gişe hasılatını tahmin etmek için (Asur ve Huberman, 2010) ve gazete makalele rinin metnini çatışmanın başlangıcını tahmin etmek için (Mueller ve Rauh, 2017).

Bilgisayar bilimi ve sanayide makine öğrenimi algoritmaları neredeyse ta mamen tahmine odaklanarak geliştirilmişken, sosyal bilimciler ve dijital beşe rî bilimler akademisyenleri tahmini araştırmalarının merkezi bir hedefi haline getirmekte daha temkinli davranmışlardır ve bunun yerine genellikle tanıml ayıcı veya nedensel çıkarımlar yapmaya odaklanmaktadırlar. Ancak, sosyal bi limler gerçek zamanlı olarak mevcut olan yeni veri türleriyle karşılaştıkça, tah min giderek daha fazla önem kazanmaya başlayabilir (Hofman, Sharma ve W atts, 2017). Tahminsel modeller, belirli sosyal bilim teorilerinin faydasını netl eştirmede giderek daha önemli bir rol oynayabilir ve hangilerinin

Doclingo https://www.doclingo.ai

olayları önceden açıklama yeteneği (Cranmer ve Desmarais, 2017). Herhangi bir güçlü teknik gibi, öngörücü yöntemler de kötüye kullanılabilir, özellikle g örev kötü tanımlandığında, bu konuya bölüm boyunca geri döneceğiz.

Bölüme tahminin temel görevini tanıtarak başlıyoruz ve bunun ölç ümle nasıl benzer ve nasıl benzer olmadığını netleştiriyoruz. Bölüm b oyunca geri döneceğimiz tahminle ilgili bazı genel ilkeleri tartışıyoruz. Daha sonra, dört farklı öngörücü görev türüne geçeceğiz—kaynak tahmini, bir metnin kaynağının kimliğini veya özelliklerini tespit ed er; dilsel tahmin, metin üretir; sosyal tahmin, ekonomik, politik vey a sosyolojik olayları tahmin eder; ve şimdi tahmini, diğer yöntemle rle yeterince hızlı ölçülemeyen devam eden olayları tahmin eder.

Doclingo https://www.doclingo.ai

23.1 Tahminin Temel Görevi

Standart tahmin görevi üç bileşene sahiptir: veri, bir model ve bir değerle ndirme metriği. Fikirleri netleştirmek için, Twitter'dan elde edilen verileri kull anarak Amerika Birleşik Devletleri'ndeki seçim anketlerini tahmin etme göre vini düşünün. Anketler genellikle ne kadar pahalı olduklarıyla sınırlıdır. Bir ba şkanlık seçiminde, anketlerin yüksek rekabet beklenmeyen eyaletlerde yapıl maması anlamına gelebilir. Ancak, belirli bir başkanlık adayının belirli bir eyal ette belirli bir haftada nasıl bir anket sonucu alacağını tahmin edebilmekle il gilenebileceğimiz birçok akademik ve ticari neden vardır.

Temel görev, bir sonuç y i'yi tahmin etmektir—bu durumda bir anket—burada i belirli bir birim (örneğin bir eyalet anketi veya ulusal anket) için tahminin yapıldığın ı gösterir.[1] y i için tahminimizi ŷ i olarak adlandırıyoruz.

Birim *i* , tahmin için yararlı olabilecek ve tahminin yapılmasından önce mevcut olan bir dizi metin ve metin dışı özellik ile ilişkilidir. Birim ile ilişkili metin dışı özelliklere X i diyoruz; bu, y i'yi tahmin etmek için mevcut olan bi rim *i* için *P* değişkenler vektörüdür. Anketler durumunda, bu, eyaletin eko nomik göstergeleri veya diğer metin dışı varlıklar olabilir. y i'nin metin tah mincilerine W i olarak atıfta bulunacağız. İncelediğimiz durumda, anketleri tweetlerle tahmin etmek istiyoruz, bu nedenle W i, tweetlerin metnini tanı mlayacaktır.

Öncelikle, etiketlenmiş bazı verilere ihtiyacımız var; bu, hem tahmincileri X i v e W i ,, hem de tahmin için hedef olan y i'yi bildiğimiz bazı veriler anlamına gelir. Anket örneğinde, bu, ilgi alanındaki hafta ve yereliteden gelen tweetlerle birlikte gerçekleştirilen gerçek anketlerin bir seti olacaktır. Bu etiketlenmiş veri, bir eğiti m ve *test* setine ayrılacaktır—Bölüm 19'da olduğu gibi, bu, modelin gerçekten u yum sağlaması için bazı verilerin kullanılmasına olanak tanırken, performansı de ğerlendirmek için ayrı bir setin mevcut olmasını sağlar.

İkinci bileşen modeldir. Modeli seçmeyi(tıpkı Bölüm 19'da yaptığımız gibi) etiketli veriler içindekiöngörülen sonuç ile gerçek sonuç arasındaki farkı nicelendirerek bir *ölçü fonksiyonu* L (·) seçmek olarak düşünebili riz. Model, L (·)'yi minimize eden parametreleri bulmaya çalışacaktır. Örneğin, eğitim kümesindeki kareler toplamını minimize eden doğrusal regresyonu düşünün *I*, böylece

$$\hat{\mu} = \arg\min_{\mu} \sum_{i \in I} (y_i - W_i, \mu)^2 \quad (23.1.1)$$

koefisiyentleri μ elde etmek için.

O zaman, tahmin edilen μ'yi gelecekte kullanabileceğiz, ne zaman ki biz yokuz.

Doclingo https://www.doclingo.ai

bir tahmin ŷ i elde etmek için W i , μ hesaplayarak y i 'yi bilmek, gözlemle diğimiz W i 'ye dayanır.Bu nedenle, örneğimizde, anket sonuçlarını tahmi n etmek için anketlerin mevcut olduğu haftaları kullanıyoruz.Anketlerin mevcut olmadığı haftalar için. Doğrusal regresyon basit bir tahmin mode lidir ve ölçüm bölümünde tartışılan daha karmaşık makine öğrenimi yönt emlerini kullanarak performansımızı artırmalıyız.

Öngörü görevindeki üçüncü bileşen değerlendirme ölçütüdür. Açıkça, tahmin modelimizin her zaman tam olarak doğru yanıtı üretme sini isteriz, ancak pratikte, analistin hedeflerini yansıtan bir performans değerlendirme yöntemine sahip olmak önemlidir. Performansı değerle ndirmek için en iyi yaklaşım genellikle tahmin görevinin nedenine bağlı olacaktır. Örneğin, siyaset bilimcileri, olumsuz kampanyanın etkilerini i ncelemeye çalıştıkları için, anketlerin geriye dönük olarak ne olacağını t ahmin etmek için tweetleri kullanmak isteyebilirler ve gerçekleşmediği haftalarda tüm adaylar için anketleri doldurmak isterler. Öte yandan, si yasi danışmanlar, yalnızca kendi adayları için ve yalnızca mevcut hafta i çin destek tahmin etmekle ilgilenebilirler. Bu, farklı değerlendirme strat ejileri gerektiren çok farklı görevlerdir.

Genel olarak değerlendirme metriği, *generalizasyon hatası* biçiminde bir şeydir—görülmemiş veriler üzerinde modeli uygularken tahmin hatas ı. Eğer ilgi alanındaki popülasyondan rastgele bir örnek alırsak, bu miktar ı, bir tutulmuş örnek üzerinde bir beklenti kullanarak yaklaşık olarak hes aplayabiliriz *O* öyle ki

$$\text{Error out} = \mathrm{E}\ i \in O\ [\ \mathrm{L}\ (\ y\ i\ ,\ \mathrm{f}\ (\ \hat{\mu}, W\ i\ ,\ )\ )\ |\ \mathrm{I}\ ]\ .$$

Bunu, Bölüm 20'de açıklandığı gibi, ya gerçek bir tutulmuş set kullanarak ya da bir çapraz doğrulama prosedürü aracılığıyla tahmin edebiliriz. Aşağıdaki ilkeler bölüm ünde bu basit tarifin karmaşıklıklarını tartışıyoruz.

Doclingo https://www.doclingo.ai

23.2 Tahmin ve Ölçüm Arasındaki Benzerlikler ve Farklılıklar

Şimdiye kadar, Bölüm 3'te tanımlanan denetimli öğrenme problem i ile neredeyse özdeş bir problemi tanımladık: Ölçüm, burada y i ilgi al anındaki kategori ve W i, bu kategoriyi tahmin etmek için kullandığımı z belgede bulunan kelimelerdir. Ayrıca, y i ilgi alanındaki sonuç, t i ilgi alanındaki "tedavi"—bir birimin aldığı müdahale seviyesini kodlayan b ir değişken—ve X i potansiyel karıştırıcılar—hem tedavi hem de sonuç ile ilişkili değişkenler—ile ilgili olan nedensel çıkarım probleminin kur ulumu ile de çok yakındır. Her durumda, y i ile tahmin ediciler arasınd aki ilişkiyi tahmin etmek için çeşitli modeller kullanabiliriz. Her durum da, model doğrulaması için bir tür bölünmüş örnek yaklaşımını da sav unuyoruz.

Üçü de dışarıdan benzer görünse de, tahmin, ölçüm bölümünde tanımlanan denetimli öğrenme problemini nedensel çıkarımdan d aha yakın bir şekilde yansıtır. Denetimli öğrenme, tahminin belirli bir örneğidir - belgede bulunan kelimeler W ve bunların kovaryatla rı X verildiğinde, elle kodlayıcıların bir belgeyi nasıl etiketleyeceğini tahmin etmeye çalışıyoruz. Yanlış sınıflandırma hatasını tahmin et me yöntemini burada tahmin hatasını tahmin etme yöntemiyle ay nı şekilde tanımlıyoruz ve analistlerin bu hatayı karakterize etmek i çin tutulmuş örnekler kullanmalarını öneriyoruz. Bu bölümün, ölçü mde tartışılan denetimli öğrenme problemi ile karşılaştırıldığında e le alacağı tek fark, tahmin etmeye çalıştığımız y'nin aralığının yalnız ca belirli bir belgenin etiketiyle sınırlı olmaması, Yüksek Mahkeme kararları

nın sonuçları, borsa geleceği veya hatta gelecekteki belgelerin içeriği gibi daha geniş bir yelpazeyi içermesidir.

Gözlemlenmemiş y i değerlerini tamamen farklı (ve genellikle gelec ekteki) bir veri setinde tahmin etmek, belgeler içindeki kavramları etik etleme görevine göre daha fazla dikkate alınması gereken unsurlar iç erir. Belgelerin aksine, ölçüm görevine başlamadan önce genellikle sa bit bir korpusumuz varken, tahmin kaçınılmaz olarak zamanın karmaş ıklığı ile ilgilenir - gelecekte ne olacağını tahmin etmeye veya aralıklı öl çümler arasında gözlemlenmemiş değerleri doldurmaya çalışıyoruz. B u, etiketli verilerimizin, tahmin etmeye çalıştığımız verileri her zaman yansıtmayacağı anlamına gelir; bu da zamanla kayma yaratabilir. Özel likle, incelediğimiz bireyler veya bulundukları bağlam davranışlarını ve stratejilerini değiştirebilir, böylece tahminlerimiz artık faydalı olmaya bilir. Bu noktaya bölüm boyunca geri döneceğiz ve tahminin,

Doclingo https://www.doclingo.ai

önceki bölümde tanımladığımız ölçüm.

Doclingo https://www.doclingo.ai

23.3 Tahminin Beş İlkesi

Gerçek dünya tahmin problemlerinde, yukarıda özetlediğimiz te mel tarifte birçok karmaşıklık vardır. Bu, kısmen kendi analizlerimiz i yönlendiren bir dizi ilkeye yol açmaktadır.

23.3.1 TAHMİNSEL ÖZELLİKLER SONUCU OLUŞTURMAK ZORUNDA D EĞİLDİR

Bir tahmin görevi, tahmin edicilerin sonucu oluşturmasını gerektirmez. Tah mine nasıl ulaştığımız, tahminin doğruluğundan daha az önemlidir. Örneğin, mayo satışlarını tahmin etmek istediğimizi varsayalım. Dondurma ile ilgili sosy al medya paylaşımlarının mayo satışlarının iyi bir tahmin edicisi olduğunu bulu yoruz. Elbette, dondurma ile ilgili sosyal medya paylaşımları mayo satışlarını ol uşturmaz, ancak her ikisi de daha sıcak hava ve yaz tatili kombinasyonu tarafın dan etkileniyor olabilir. Ancak, eğer veriler genel tahmin gücünü artırıyorsa, do ndurma ile ilgili sosyal medya paylaşımları mayo satışlarının tahmin modelinde hala kullanılabilir.

Elbette, nedensel faktörler tahmin için yararlı olabilir ve bunları bir modele dahi l etmek, tahminlerin doğruluğunu artırabilir. Hava durumu, hafta sonları veya tatill erle ilgili bilgilerin dahil edilmesi—bunların hepsi mayo satışlarını muhtemelen etki ler—gerçekten de mayo satışlarını tahmin eden bir modelde yardımcı olabilir.
Bu tür özelliklerin dahil edilmesi, zaman ve mekandaki tahminlerin istikrarı iç in özellikle önemli olabilir. Ancak bazı durumlarda, neden-sonuç faktörleri so nuç üzerinde çok da öngörücü olmayabilir; eğer neden-sonuç etkisi büyüklü k açısından minimalse, sıfırdan önemli ölçüde farklı olsa bile, tahminin doğru luğunu mutlaka artırmayacaktır (Lo ve diğ., 2015).

Tahmin edicilerin sonucu neden olmaları gerekmez, tahmin edici analizde ki tahmin ediciler sonuç da olabilir. Bu bölümün sonunda daha ayrıntılı olara k ele alacağımız bir örnekte, anlık tahmin genellikle y i'nin sonucunu tahmin etmek için y i'ye ait verileri kullanır. Örneğin, herhangi bir bölgede grip vakal arının görülmesi zor olup, grip vakalarına ait veriler genellikle birkaç hafta g ecikir çünkü önce sağlık yetkilileri tarafından toplanması gerekir. Ancak, grip vakalarının artmasının bir sonucu, bölgedeki insanların Google'da grip ilaçlar ı aramasıdır. Araştırmacılar, grip vakalarının kendisinin aramayı tetiklemesin e rağmen, bu arama verilerini grip vakası verilerini tahmin etmek için kullan mışlardır (Ginsberg ve diğ., 2009).

23.3.2 ÇAPRAZ DOĞRULAMA HER ZAMAN TAHMİN GÜCÜ İÇİN İYİ BİR Ö LÇÜ DEĞİLDİR

Doclingo https://www.doclingo.ai

20. Bölümde, bir modelin tahmin performansını değerlendirmek için verilerin bir alt kümesini ayırarak ve ayrılan veriler üzerindeki hata oranını tahmin ederek nasıl değerlendirebileceğimizi açıkladık. Test verilerinin ilgi alanındaki popülasyo nun rastgele bir örneği olması durumunda, test verileri üzerindeki genelleme ha tasını tahmin etmenin nihai görevdeki performansının iyi bir tahmini olacağını b elirttik. Ancak, genellikle tahmin yapmak istediğimizde, henüz gerçekleşmemiş v eri noktalarını tahmin etmek isteriz. Modeli eğittiğimiz veriler tarihsel verilerse, g enellikle tahmin etmeyi umduğumuz noktaların rastgele bir örneği değildir—gel ecek veriler. Ayrılan tarihsel veriler, tahmin için kullanmak istediğimiz gelecektek i verilerden sistematik olarak farklıysa, genel olarak çapraz doğrulama hata oran ını doğru bir şekilde tahmin etmeyecektir.

Buzlu dondurma ile mayo satışlarını tahmin eden sosyal medya bahsine geri dö nelim. Buzlu dondurma ile ilgili sosyal medya bahsine dayanarak mayo satışlarının ne zaman zirve yapacağını tahmin etmek için son iki yazdan verileri kullanabiliriz. V e modelimizi, bu yaz talebi tahmin etmek için kullanan bir mayo mağazasına satmı ş olabiliriz. Ancak belki de bu arada, kullandığımız sosyal medya platformu, kullanıc ılarının sağlığını teşvik etmek için haber akışında buzlu dondurmayı azaltmak amac ıyla algoritmasını değiştirdi. Kullanıcılar buzlu dondurma hakkında okumadıkları içi n, buzlu dondurma hakkında daha az paylaşımda bulunuyor olabilirler.

Bu, mayo satışlarını tahmin etme hatamızı artırır çünkü dondurma ile mayo satışları arasındaki ilişki değişmiştir.

Bir tahmin problemi için hata oranını tahmin etmek amacıyla çapraz doğrulama kull anmanın en iyi durumu, geleceğin geçmiş verilerin rastgele bir örneği gibi olduğu duru mdur; diğer bir deyişle, geçmiş verilerde geleceğe dair bilgiye sahip olduğumuzdur.

Tarihsel verilere dayanan tahmin ve öngörü modelleri, geçmiş ile gele cek arasındaki benzerliğe dayanır. Elbette, sorun geleceğin hızla değiş ebilmesidir—iyi bir tahmin edici ile bir sonuç arasındaki ilişki gelecekt e bozulabilir. Basit bir örnek alalım—2008'de sosyal medyada "Obama " kelimesinin geçmesi, Demokratik başkan adayının seçimi kazanıp ka zanmayacağını tahmin etmiş olabilir, ancak bu ilişkinin 2016'da Obam a'nın başkan adayı olmadığı zamanlarda bu kadar güçlü olması muhte mel değildir. Tahmin ediciler ile sonuçlar arasındaki zamanla değişen bu tür durumlar, doğru modelleri ayarlama çabalarımızı karmaşıklaştı racaktır.

Sosyal bilim araştırmaları ve uygulamaları için önemli olan, başarılı tahmi nler ironik bir şekilde tahmin ediciler ile sonuçlar arasındaki ilişkide kaymaya neden olabilir ve bu tahminleri yaparak bir analistin tahminlerini zayıflatabili r. Diyelim ki, içindeki kelimelerin iyi bilindiği bir durum ortaya çıkıyor.

Doclingo https://www.doclingo.ai

şirketlerin finansal raporları, gelecekteki borsa değerlerini tahmin eder. Eğer bu tahmin yaygın olarak bilinir hale gelirse, ya şirketler ya da yatırımcılar davranışlarını değiştirebilir. Şirketler, olumsuz hisse değişimlerini tahmin eden kelimeleri atlayabilir veya bunların yerine geçecek kelimeler bulabilir. Yatırımcılar, bu hisseleri satma ve alma şekillerini değiştirebilir. Davranıştaki bu değişim, tahmini zayıflatabilir, çünkü finansal raporlar ile borsa arasındaki ilişki, tahminler nedeniyle değişmiş olacaktır. Bu durumlarda, tarihsel verilerde çapraz doğrulama, hata oranının iyi bir ölçüsü olma olasılığı düşüktür.

Çapraz doğrulama, birçok durumda bir tahminin öngörü gücünü ölçmek içindo ğru ve düşük maliyetli bir yol olabilir, ancak nihayetinde önemli olan,tahminin gerç ek dünyada ne kadar iyi tutunduğudur. Tahminler yapmak vesonrasında bunları g erçek zamanlı verilere dayanarak kontrol etmek,doğruluğun en iyi ölçüsüdür. Spa m veya tıklama gibi bazı tahmin durumlarında,sonuçlarla ilgili veriler hızlı geldiğind e, gerçek zamanlı doğruluğu ölçmekdaha uygulanabilir hale gelir. Savaş veya seçi mleri tahmin etmek gibi diğerdurumlarda, gerçek zamanlı tahmin yapan bir analist in, sonuçların gözlemleriarasında uzun süre beklemesi gerekir ve bu nedenle yalnı zca gerçek zamanlıtahminlere dayanarak bir modeli ayarlamak uygulanabilir olma yabilir.

23.3.3 HER ZAMAN ORTALAMA ÜZERİNDEN DAHA DOĞRU OLMAK DAHA İYİ DEĞİLDİR

Bu bölümün başında belirttiğimiz gibi, tahminlerimizi mümkün olduğu nca doğru yapmak istiyoruz. Ama doğruluk aslında ne anlama geliyor? Bir e-posta'nın spam olup olmadığını tahmin etmeye çalıştığımız basit bir ö rnek alalım, $y_i \in \{0, 1\}$. Problemi ele almanın bir yolu, ortalama doğruluğ u optimize etmeye çalışmaktır; yani tahminimizin doğru olduğu zamanların oranı, $\sum_{i=1}^{N} I(y_i = \hat{y}_i) / N$.

Ancak doğruluk, bir tahmin modelini değerlendirirken her zaman en iyi metrik değildir. Nedenini görmek için spam örneğine geri dönelim. Diyelim ki e-postaların ızın rastgele bir örneğinde, iki spam e-posta ve 998 spam olmayan e-posta var. O z aman model, e-postalarınızın hiçbiri spam değilse tahmin ederse oldukça iyi bir so nuç alır; doğruluğumuz $998/1000 = .998$ olur, yani %99.8 oranında doğru tah minde bulunuruz. Ancak bunu yaparak, asla spam tahmininde bulunmayız—model in başlangıçtaki amacı budur. Bu, genellikle doğruluk paradoksu olarak bilinir—da ha yüksek doğruluk her zaman daha iyi bir model anlamına gelmez.

Doğruluk paradoksunu hafifletmenin bir yolu, F1 skoru olarak adlandırılan bir ölçütü kullanmaktır. F1 skoru, hem geri çağırmayı—gerçek sınıfın ne kadarı nın o sınıf olarak tahmin edildiğini—hem de kesinliği—tahmin edilen sınıfın ne kadarının gerçek sınıf olduğunu dikkate alır. Bunu daha net görmek için,

Doclingo https://www.doclingo.ai

ikili bir sınıflayıcı için aşağıdaki karmaşıklık matrisidir.

		Gerçek Sınıf	
		Olumlu	Olumsuz
Öngörülen Sınıf	Olumlu Olumsuz	Gerçek Olumlu Yanlış Olumsuz	Yanlış Olumlu Gerçek Olumsuz

Sütunlar boyunca gerçek sınıf, satırlar boyunca öngörülensınıf bulunmaktadır . Unutmayın ki, geri çağırma, Gerçek Olumlu sayısınınGerçek Olumlu ve Yanlış Ol umsuz sayısına bölünmesiyle elde edilir, diğer bir deyişle,gerçek sınıf olumlu ola nların ne kadarının olumlu olarak öngörüldüğüdür. Kesinlik ise,Gerçek Olumlu s ayısının Gerçek Olumlu ve Yanlış Olumlu sayısına bölünmesiyle elde edilir.Diğer bir deyişle, öngörülen olumlu olanların ne kadarının gerçekten olumlu olduğudu r.

Geri Çağırma = Gerçek Olumlu Gerçek Olumlu + Yanlış Olumsuz Kesinlik = Gerçek Olumlu Gerçek Olumlu + Yanlış Olumlu

F1 skoru, kesinlik ve hatırlama arasında denge kurmanın bir yoludur; bunları çarparak elde edilir.Başka bir deyişle, eğer hatırlama veya kesinlik çok düşük olu rsa, F1 skoru da düşük olacaktır, çünkü bu, hatırlama ve kesinliğin toplamı yerine çarpımını yansıtır.

F 1 = 2 × Hatırlama × Kesinlik / (Hatırlama + Kesinlik)

Ancak yine de, F1, analist için kesinlik ve hatırlamanın maliyetlerini ve faydalarını doğru bir şekilde yansıtmayabilir. Örneğin, bir e-postayı yanlışlıkla spam olarak etiket lemenin, spam bir e-postayı spam değil olarak etiketlemekten çok daha maliyetli old uğunu düşünebiliriz ve bu durumda yanlış çıkabiliriz. Başka bir deyişle, bazen sınıflan dırıcının kesinliğine (tahmin edilen spamların ne kadarının gerçekten spam olduğu) d aha fazla önem verebiliriz, sınıflandırıcının hatırlamasına (gerçek spamların ne kadarı nın spam olarak tanımlandığı) göre. Diğer zamanlarda ise, nadir bir hastalığı teşhis e derken olduğu gibi, hatırlamaya kesinlikten daha fazla önem verebiliriz.

Eğer bu maliyeti, *C*'yi belirterek, hatırlamanın kesinlikten daha önemli olduğudurumların sayısını b elirleyerek nicelleştirebilirsek, o zaman bu maliyeti yansıtacak şekilde F1 puanını güncelleyebiliriz, kullanarak:

$$F C = (1 + C 2) \times \text{Recall} \times \text{Precision} \, \text{Recall} + (C 2 \times \text{Precision}) .$$

Doclingo https://www.doclingo.ai

Genel doğruluk, alt gruplar içindeki doğruluğu her zaman yansıtmayacaktır. Analistler, doğru tahminler yapma eğiliminde oldukları birim türlerini ve tah minlerin genellikle yanlış olduğu birim türlerini de dikkate almalıdır. Bu, cinsi yet ve ırkı görüntülerden tahmin etme üzerine literatürde sıkça gündeme gel miştir, çünkü yüz tanıma algoritmalarının beyaz erkekler için daha doğru old uğu, daha koyu tenli kadınlar için ise daha az doğru olduğu gösterilmiştir (B uolamwini ve Gebru, 2018). Bu doğruluk farklılıkları alt gruplar, algoritmanın aşağı akış uygulamalarında ciddi ırksal ve cin siyet yanlılığı yaratabilir.

23.3.4 PREDİKSİYON İÇİN MODELLERİ YORUMLAMANIN PRATİK D EĞERİ OLABİLİR

İlk ilkemizde bir tahmine nasıl ulaştığınızın, nedensel çıkarımda oldu ğundan çok daha az önemli olduğunu belirtirken, burada tahminleri açı klama yeteneğinin pratik avantajları olabileceğine dair bir uyarı sunuyo ruz. Tahminlerin sonuçları olduğu alanlarda, örneğin dış politika veya tı p gibi, karar vericiler, bir dizi girdi alıp belirsiz bir şekilde bir tahmin üre ten algoritmalara şüpheyle yaklaşabilirler. Tahminlerden etkilenenler, ö rneğin kredi puanlamasında veya yasal yapay zeka bağlamında, neden belirli bir tahmin aldıklarını bilmek isteyebilirler; Avrupa Birliği'nin buna 'açıklama hakkı' dediği şeydir (Goodman ve Flaxman, 2017).

Yaptığımız noktanın - tahminlerin yorumlanabilir olmasının pratik ava ntajları olduğu - algoritmik şeffaflık etrafındaki tartışmalarda yapılanlard an çok farklı bir nokta olduğunu belirtmekteyiz. Bu tartışma, sonuçları et kileyen kararların opak algoritmik işleyişe dayanarak alınıp alınamayacağ ı ile ilgilidir. Bu tartışmanın önemli olduğunu düşünsek de, burada yaptığ ımız argüman, analistlerin tahminler yaparken algoritmaların açıklamalar ının pratik bir değer taşıdığıdır; bu, etik gereklilik olmasa bile, kamu, kara r vericiler ve uzmanlar genellikle tahminleri, temel bileşenlerini anlamad an önce şüpheyle karşılarlar.

23.3.5 TAHMİNİ POLİTİKA YAPIMINA UYGULAMAK ZOR OLABİLİ R

Politika yapıcılar, politika kararları almak için giderek daha fazla tahmine da yalı makine öğrenimi modelleri kullanıyor; bu, polislikten (Perry, 2013), eğitime (Williamson, 2016), göçmenliğe (Bansak ve diğerleri, 2018) ve gıda denetimine kadar uzanıyor. Denetimli makine öğrenimi, tahminler yaparken büyük miktar da veriyi kullanabilen güçlü bir araçtır, ancak politika tuzaklarından muaf değil dir. Politika yapımında tahminlerin kullanılmasının zorlukları vardır.

Doclingo https://www.doclingo.ai

O’Neil (2016) tarafından popüler bir şekilde ele alınmıştır, ancak bilgisayar bilimive ekonomi alanındaki akademisyenler tarafından da (Athey, 2017).

Öncelikle, bir politikayı uygulamak için bir tahmin modeli kullanmak,bu politikanın etkisini değerlendirmekle karıştırılmamalıdır. Athey (2017), bir tahmin modelininhangi binaların denetim için hedeflenmesi gerektiğini tahmin etme örneğiyle bu noktayıvurgulamaktadır—hangi binaların bir bina denetimini geçme olasılığının yüksek olduğunuöngörmek, bakım gerektiren binaları ortaya çıkardığı takdirde faydalı olabilir. Ancak,bu binaların denetlenmesinin bina güvenliği üzerinde en büyük etkiye sahip olacağı anlamınagelmez. Denetimi geçme olasılığı en yüksek olan binaların, onarılması en zor olanlar daolabilir. Bu durumda, hem denetimi geçecek hem de onarımı kolay olan binaları hedeflemek,çok daha maliyet etkin bir strateji olabilir, ancak bu tahmin algoritması tarafındanortaya konulmaz.

İkincisi, tahmin modellemesine dayalı bir politikayı uygulamak, ilgili aktörlerin teşviklerini, modelin kendisini zayıflatacak şekilde değiştirmektedir. Bu, politikadan etkilenen bireylerin, tahminlerini etkileyecek bir şeyebüyük kaynaklar yatırmalarına yol açabilir, ancak bu durum gerçekte daha iyi sonuçlargetirmeyebilir. (Öğrenciler için daha iyi olmayabilecek politikalara yatırım yapmaları içinkolejleri yönlendiren kolej derecelendirme sistemi hakkında bir tartışma için O’Neil (2016)bakınız.) Ayrıca, algoritmanın kendisini de zayıflatabilir; örneğin, sahipler binalarınındenetim şansının düşük olduğunu biliyorlarsa, bu durum onları binayı güncellemeyi atlamayateşvik edebilir (Athey, 2017).

Politika yapımında tahminleri tanıtma çabalarını daha da karmaşık hale getiren, veri toplamanın uygulanan politikaların bir sonucu olabileceği olasılığıdır; bu da modeli bozleyebilir ve zayıflatabilir. Lum ve Isaac (2016), tahmine dayalı polislikten kaynaklanan “geri bildirim döngüleri”ni tanımlamaktadır; burada tahmine dayalı modeller, polisin belirli bir alanı devriye gezmesi için bilgi verir. Polis bu alanlarda daha fazla bulunma olasılığına sahip olduğundan, bu alanlarda daha fazla tutuklama yapılabilir. Bu veriler modele geri beslenir ve polisin bu alanlarda bulunması gerektiği tahminini yeniden doğrular. Belirli koşullar altında bu geri bildirim döngülerini hafifletmek için adımlar atılabilse de (Ensign ve diğ., 2018), politika için tahmine dayalı modellerin naif bir şekilde uygulanması, bu bölümde tartışılan herhangi bir tuzağa düşebilir.

Tahmin araçları güçlüdür ve araştırmacının istemediği şekillerde kullanılabilir. Örneğin, Chancellor ve diğ. (2019), kullanıcıların sosyal medya paylaşımlarından mental sağlık durumlarını tahmin etmek için araçlar oluşturmanın etik boyutlarını ele almaktadır. Bu araçlar, ihtiyaç duyan insanlara kaynaklar sağlarken, aynı zamanda gizlilikle ilgili endişeleri de gündeme getirir ve kötü niyetli taraflar (örneğin, reklamcılar veya tacizciler) tarafından kullanılabilir. İzin meselesinin dışında, bunu Bölümde tartıştık.

Doclingo https://www.doclingo.ai

3, araştırmacılar yaratmayı düşündükleri öngörü araçlarının potansiyel zararlarından daha fazla fayda sağlayıp sağlamadığını düşünmek için zaman harcamalı ve araştırmayı sürdürüp sürdürmeyeceklerine ve araçlarını kamuya açık hale getirip getirmeyeceklerine karar vermek için yukarıdaki bağlam bilgilerini ve Kurumsal İnceleme Kurulu ile yapılan danışmalardan öte bilgilerini kullanmalıdır.

Özetle, burada özetlenen ilkeler aracılığıyla iletmeyi umduğumuz şey, öngörünün basit bir egzersiz olmaktan çok uzak olduğudur. Eğitim verileriyle temsil edilmeyen sonuçları tahmin etmeye çalışmak, çapraz doğrulamanın faydasını zayıflatabilir. İlk başta öngörünün açık bir değerlendirmesi gibi görünen doğruluk, öngörü performansını değerlendirmek için ideal bir ölçüt olmayabilir. Ve öngörüleri politikaya uygulamak sadece doğrulama gerektirmekle kalmayabilir, aynı zamanda beklenmedik sonuçlara da yol açabilir. Aşağıdaki bölümlerde metne dayalı öngörü örneklerini incelerken bu ilkelere atıfta bulunuyoruz.

Doclingo https://www.doclingo.ai

23.4 Metni Öngörü İçin Veri Olarak Kullanma: Örnekler

Bu önemli ilkeleri akılda tutarak, metni öngörü için kullanma örneklerini gözden geçiriyoruz. Öngörü için kullanılan birçok modeli zaten Bölüm 19'da ele aldığımızdan, burada öngörü ve ölçüm bağlamları arasındaki bulanık çizgiyi göstermeye odaklanıyoruz. Metni veri olarak kullanarak öngörüleri dört kategoriye ayırıyoruz (bunlar ne birbirini dışlar ne de kapsamlıdır): Kaynak Tahmini—metni yazan kişinin veya kişinin özelliklerini tahmin etme; Dilsel Tahmin—bir kişinin ne söyleyeceğini veya bir sonraki ne söyleyeceğini öngörme; Sosyal Tahmin—metni bir girdi olarak kullanarak savaş, yasaların geçişi veya pazarın bir sonraki ne yapacağını tahmin etme gibi toplumsal olguları tahmin etme; ve Şu An Tahmini—metni, şu anda meydana gelen sosyal olguları ölçmek için kullanma, örneğin grip, işsizlik veya tüketici güvenini ölçmek.

23.4.1 KAYNAK TAHMİNİ

Sosyal dünyamız metinle dolu—haberler, e-postalar, mektuplar, kitaplar, sosyal medya ve birçok farklı insan tarafından yazılmış ve çoğu bilinmeyen kaynak veya kökenlere sahip makaleler. Metnin tahmin için kullanıldığı birincil yollarından biri, bazı metinlerin kaynağını veya kaynağın özelliklerini anlamaktır. Bu geleceğe yönelik bir tahmin içermese de, analistin metinde bulunan bilgilerle (kaynak) metnin dışındaki bilgileri tahmin etmeyi umduğu için bunu bir tahmin problemi olarak değerlendiriyoruz.

Kaynak tahmini bu kitapta birkaç farklı bağlamda daha önce ele alınmıştır. Bölüm 3'te, bilinen yazarları olan Federalist Belgeleri'nin metnini kullanarak bilinmeyen yazarları olan Federalist Belgeleri'ni kimin yazdığını tahmin eden Mosteller ve Wallace (1963) ile ilgili konuştuk. Doldurucu kelimeleri kullanarak, yazarlar bilinmeyen yazarları olan belgelerin Madison tarafından yazıldığını tahmin ettiler. Airoldi, Fienberg ve Skinner (2007) daha sonra benzer teknikler kullanarak Başkan Ronald Reagan'ın radyo konuşmalarının yazarını belirlediler.

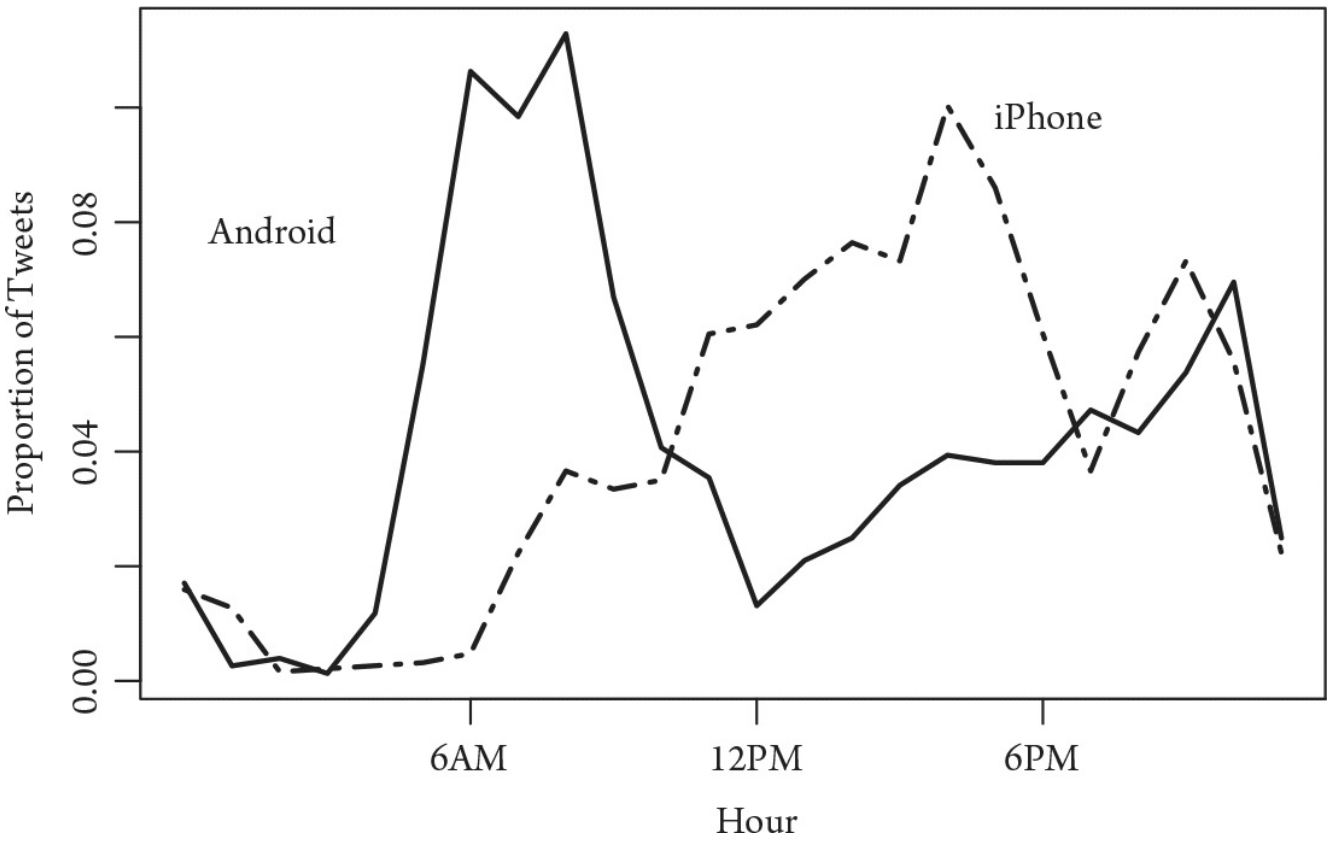
Dolandırıcılık tahmini, bir e-posta gibi bir kaynağın, büyük bir sayıda insana aldatma veya para kazanma amacıyla gönderilip gönderilmediğini tahmin etmeye çalışan bir örnektir. Kaynak tahmini, kötü niyetli web siteleri (Ma ve diğ., 2009), botlar (Ferrara ve diğ., 2016), sahte incelemeciler (Li ve diğ., 2014) ve çevrimiçi propagandacılar (King, Pan ve Roberts, 2017) dahil olmak üzere internet üzerindeki kötü aktörleri tespit etmek için sıklıkla kullanılır.

Bu aynı teknikler, yazarın kimliğini açığa çıkarmasa bile, yazarın özelliklerini öğrenmek için de uygulanabilir. Metinler, yazarın kişiliğini tahmin etmek için kullanılır (Tausczik ve Pennebaker,

Doclingo https://www.doclingo.ai

2010; Pennebaker ve Graybeal, 2001) ve yazarın gerçeği söyleyip söylemediğin i (Mihalcea ve Strapparava, 2009), ya da yazarın metninin popülaritesini tahmi n etmek için (Yano, Cohen ve Smith, 2009). Metin, daha yakın zamanda yazarın temel depresyon seviyesini tahmin etmeye çalışmak için kullanılmıştır (De Cho udhury ve diğ., 2013; Resnik, Garron ve Resnik, 2013).

Bu bölümde kaynak tahminini açıklıyoruz ve David Robinson taraf ından yazılan bir blog yazısından ilham alıyoruz.3 Robinson'un yazıs ı, 2016'daki ABD başkanlık kampanyası sırasında yazılmıştır ve Twitte r'dan elde edilen verilerin, o zamanki aday Donald Trump'ın tweetler inin, Donald Trump'ın kendisi mi yoksa Donald Trump'ın ekibi mi tar afından atıldığını ayırt edebileceğini göstermektedir. Sır, Donald Tru mp'ın genellikle bir Android cihazdan tweet atması, ekibinin ise bir i Phone cihazından tweet atmasıydı. Android cihazdan gelen tweetler genellikle sabahın erken saatlerinde veya gece geç saatlerde geliyor du, bu da Trump'ın programıyla tutarlıdır; oysa iPhone cihazından g elen tweetler genellikle gün ortasında geliyordu, bu da ekibinin prog ramıyla tutarlıdır; bkz. Şekil 23.1. Robinson'un yazısı, iPhone'daki tw eetlerin metni ile Android'deki tweetlerin metni arasındaki sistemati k farklılıkları göstermeye devam ediyor; Android'den gelenlerin tonu nun daha olumsuz olma eğiliminde olduğunu da içermektedir.



Şekil 23.1. Trump'ın Android ve iPhone'dan attığı tweetlerin saat başına oranı. http://varianceexplained.org/r/trump-tweets/ adresinden yeniden oluşturulmuştur.

Doclingo https://www.doclingo.ai

Bazen 2017, Başkan Trump bir iPhone'dan tweet atmaya başladı, bir Android cihazından. Daha önce Trump ve ekibi ayırt edilebiliyordu, ancak şimdi ayırt edilemiyordu. Ancak, mesajın içeriğine dayanarak hangi tweetlerin Trump'tan ve hangi tweetlerin ekibinden geldiğini tahmin etmeye çalışmak için kampanya Twitter hesabından öğrendiklerimizi kullanabilirdik. Bu, bilinen bir kaynağa dair bilgileri kullanarak gelecekteki kaynağı tahmin etmenin klasik bir örneğidir.

Örnek vermek gerekirse, Robinson tarafından sağlanan Trump'ın kampanyasından alınan 1.390 tweetlik bir veri seti kullandıkve yalnızca tweet içindeki kelimeleri kullanarak Android'den gelen tweetlerive iPhone'dan gelen tweetleri tahmin eden bir model eğittik. Birçokafarklı sınıflandırıcı uyarlanabilir; örnek olarak, metindeki tweetlerinkelimelerini özellikler olarak kullanarak detaylı olarak tartıştığımız Naive Bayessınıflandırıcısını uyarladık. Nihai model ile, bir hassasiyet elde ettik 0.82 ve 0.75 geri çağırma (çapraz doğrulama ile tahmin edilmiştir), tarihsel verilerde iyimodel performansını göstermektedir. Tablo 23.1'de, tarihsel verilerdeki bir Android tweet'i vebir iPhone tweet'i için en öngörücü 20 kelimeyi gösteriyoruz. Trump'ın tweet'leri,win, hillary ve crooked gibi kelimelerle ilişkilidir. Personel tweet'leri ise bağlantılar,teşekkürler ve #makeamericagreatagain ve #trump2016 gibi etiketlerle ilişkilidir.

Tablo 23.1. Tarihsel verilerdeki iPhone ve Android tweet'leri için en öngörücü kelimeler.

	iPhone	Android
1	...	”
2	teşekkür	:
3	#trump2016	@realdonaldtrump
4	,	hillary
5	#makeamericagreatagain	eğri
6	amper	koz
7	&	cruz
8	;	.
9	!	ted
10	katıl	-
11	büyük	kazan
12	vergi	clinton
13	yeni	bernie
14	demokratlar	@cnn
15	amerika	kötü
16	%	iş
17	yakında	söyledi
18	haber	medya
19	/	al

Doclingo https://www.doclingo.ai

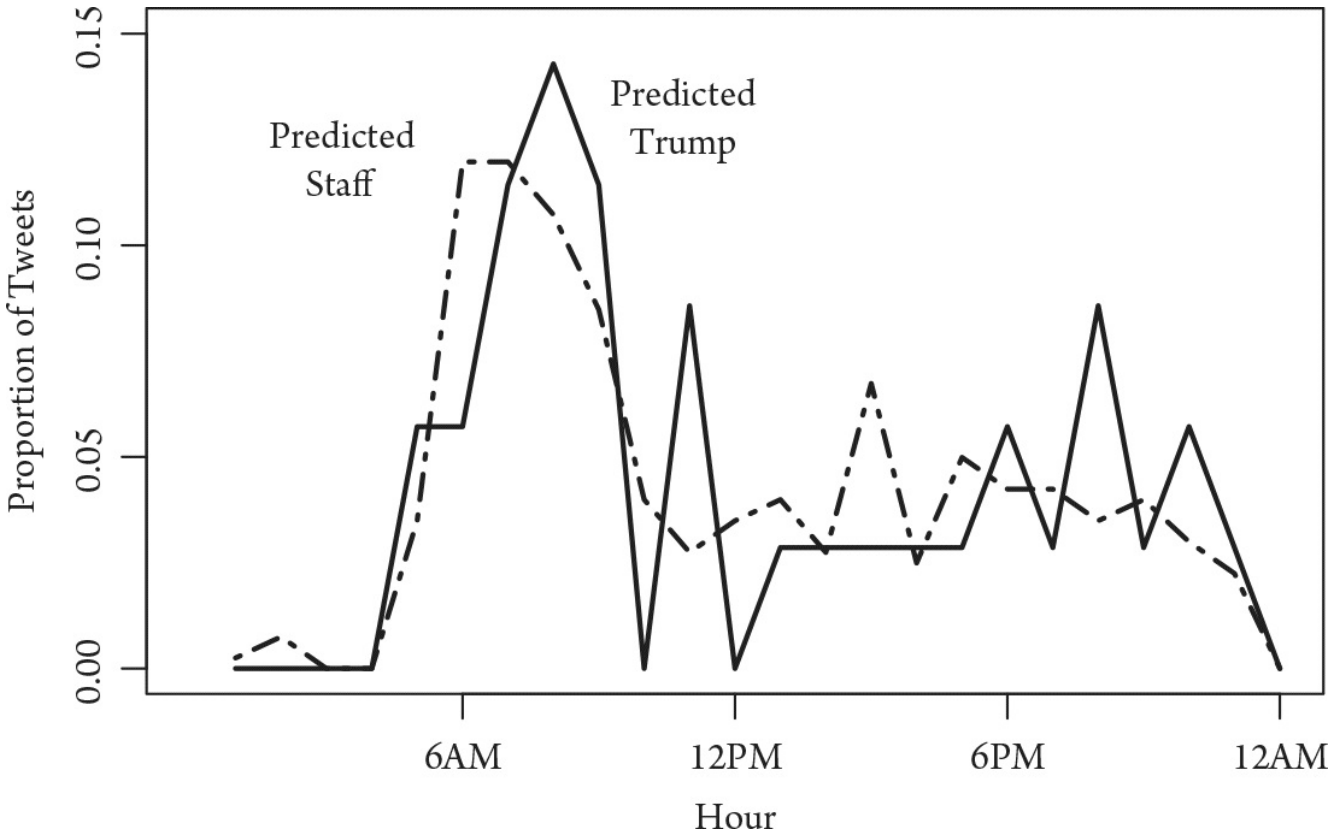
Daha sonra Trump'ın hesabından 471 tweet topladık.[5] Oluşturduğumuz modeli kullandık, 471 tweetten hangisinin Trump'tan hangisinin ekibinden geldiğini tahmin ettik. Bu bölümün başındaki ilkelerde tartıştığımız gibi, tar ihi verilerde tatmin edici bir hassasiyet ve geri çağırma elde etmemize rağ men, mevcut verilerde yüksek hassasiyet ve geri çağırma elde edeceğimiz kesin değildir. Hem Trump'ın hem de ekibinin tweet attığı konular değişti; hem farklı güncel olaylar hem de Trump ekibinin kampanyadan yönetime geçiş stratejisinin değişmesi nedeniyle. Modelimizin gerçekten Trump tara fından yazılan tweetleri ve ekibi tarafından yazılanları tahmin etmede ne ka dar iyi olduğunu kesin olarak bilemesek de, burada modelin Trump'ın Twit ter davranışı hakkında bildiklerimizle tutarlı sonuçlar üretip üretmediğini g örmek için bazı doğrulamalar yapıyoruz.

Öncelikle, Trump'ın ekibi tarafından yazılması yüksek olasılıkla tahmin edi len tweetlere bakıyoruz. Tablo 23.2, Trump'ın ekibinden gelmesi en olası beş tweeti ve Trump'tan gelmesi en olası beş tweeti göstermektedir. Algoritma, ekibin olaylar veya yeni raporlar hakkında duyurular yaptığını, oysa Trump'ın IŞİD, Temsilciler Meclisi'ndeki oylamalar ve haber kapsamı hakkında tweet a ttığını tahmin ediyor. Bunları okuduğumuzda, telefon türüne göre beklentile rimize uygun olduğunu görüyoruz.

Tablo 23.2. Trump'ın personeli tarafından yazıldığı tahmin edilen Tweetler ile Trump.

Tahmin Edilen Personel Tweetleri	Tahmin Edilen Trump Tweetleri
Amerikalılar gelişmek, yenilik yapmak ve refah içinde yaşamak için özgür olduğunda,hiçbir zorluk çok büyük, hiçbir görev çok ağır değildir, ve hiç birgö... https://t.co/FaGl53u1Db	Son zamanlarda bana Çarpık Hillary Clinton'ın2020'de ad ay olup olmayacağı soruldu? Cevabım, “Umarım!” oldu.
Bu hafta, Senato, Orman ile birlikteorta sınıf aileleri için güçl ü bir duruş sergileyebilir ki bunlar omurgayı oluşturuyor... https://t.co/ILfhlLOkSE	‘Trump Mitingi: Hisseler 2017'yi rekorlar kitabına soktu’ https://t.co/0foQGaFjMh
Tarihin en büyük vergi tasarısı ve vergi indirimleri Senato'dan geçti. Şimdi bu harika Cumhuriyetçiler f... https://t.co/5hPQSNDZV3	Rapor: ‘ANTI-TRUMP FBI AJANICLINTON E-POSTA SO RUŞTURMASINA ÖNCÜLÜK ETTİ’ Artık her şeyanlam kazan maya başladı!
Temsilciler Meclisi Demokratları, çok popüler olan, yeni geçen vergi indirimlerinden dikkatleri dağıtmak için tatillerde bir KAPANMA istiyor. ... https://t.co/NRQRR8w3pp	Bernie Sanders destekçilerinin, Crooked Hillary tarafınd an Dem ön seçimlerinin tamamen çalınmasına karşı öfkeli o lmaya hakları var!
Hiç kimse, Cumhuriyetçilerin ve Demokratların Şubat ayına kadar DACA konusunda bir anlaşmaya varıp varamayacaklarını kesin olarak bilmiyor. 8, ama her... https://t.co/2qBHLtCo1u	... Buna dayanarak, Ordu son iki günde IŞİD'e “çok da ha sert” vurdu. Bizim üzerimize yapılan her saldırı için b üyük bir bedel ödeyecekler!

Doclingo https://www.doclingo.ai



Şekil 23.2. Şubat 2018'de saat başına Trump'tan geldiği tahmin edilen ve personelden geldiği tahmin edilen tweetlerin oranı.

İkinci olarak, Trump'ın personeli tarafından yazıldığı tahmin edilen tweetlerinsaatlik zamanl amasına ve Trump tarafından yazıldığı tahmin edilen tweetlere bakıyoruz. Şekil 23.2, Trump tar afından yazıldığı tahmin edilen vepersoneli tarafından yazıldığı tahmin edilen tweetlerin her sa at gönderilen oranını göstermektedir. Şaşırtıcı bir şekilde, tahmin edilen Trump ve personel twe etlerinin saatlerininbirbirine yaklaştığını görüyoruz, bu Şekil 23.1'de gösterilmektedir. Tweetleme kalıbı, tarihsel verilerdeki beklentimizden sapmaktadır. Bu, Trump'ı npersonelinin programının değişmesinden mi kaynaklanıyor, yoksa modelin m etne dayanarakyanlış tahmin yapmasından mı? Bu dönemdeki tweetler için ge rçek etiketler olmadan,bunu asla bilemeyebiliriz. Ancak, model bize başkanın s osyal medya davranışınındevam eden bir tahminini veriyor, hatta tweetleri ayrı ayrı tanımlanamadığında bile.

23.4.2 DİLSEL TAHMİN

Göz önünde bulundurduğumuz ikinci metin tahmin kategorisi dilsel tahmindir — metin verilerini kullanarak sonraki metin verilerini tahmin etmek. Birinin sonraki ne söyleyeceğini veya birinin ne demek istediğini tahmin edebilir miyiz? Bu kategori, olası sonuçların alanı genellikle çok daha yüksek olduğu için kaynak tahmininden daha zordur. Sadece Trump'ın veya personelinin bir tweet atıp atmadığını tahmin etmek istemiyoruz, bir sonraki tweeti, bir tweet içindeki bir sonraki kelimeyi veya belirli bir tweetin nasıl çevrileceğini tahmin etmek istiyoruz.

Doclingo https://www.doclingo.ai

Dilsel tahmin, insanların her gün kullandığı birçok pratik uygulamada gör ünmektedir. Otomatik düzeltme, hangi kelimeleri yanlış yazdığınızı ve hangil erini değiştirmek istediğinizi tahmin eden bir tahmin biçimidir. Arama, metin mesajlaşma ve e-posta'daki otomatik tamamlama, yazmadan önce ne yazm ayı planladığınızı tahmin eder. Bu dilsel tahmin biçimlerinin her biri, bireyin d aha önce yazdığı veya aradığı şeyleri kullanarak, o bireyin sonrasında ne de mek istediğini tahmin etmeyi geliştirmek için özelleştirilebilir.

Soru yanıtlama, algoritmanın kullanıcının sorduğu bir soruya en faydalı cevabın ne olacağını tahmin ettiği başka bir dilsel tahmin türüdür. Genellik le, metni sıfırdan oluşturmak yerine, bilgisayar, en alakalı olduğunu tahmi n ettiği bir veya bir dizi sonucu bulmak için olası cevapların bir veritabanını arar ve ardından bu cevapları kullanıcıya döner. Bu tür soru yanıtlama, alg oritmanın kullanıcıya ilgili olduğunu tahmin ettiği bilgileri geri getirmeye ç alıştığı daha büyük bir bilgi retrieval görevleri sınıfının bir örneğidir. Ünlü s oru yanıtlama programları arasında IBM'in Watson'ı ve Apple'ın Siri'si bulu nmaktadır.

Makine çevirisi, algoritmanın aynı metnin farklı bir dilde nasıl ifa de edileceğini tahmin ettiği başka bir dilbilgisel tahmin türüdür. M akine çevirisi yapmanın en basit yolu, bir cümledeki her kelimeyi alı p, her kelimeyi bir sözlükte arayarak hedef dile doğrudan çevirmek tir; bu işleme doğrudan çeviri denir (Jursfsky ve Martin, 2009, Bölü m 25).

Ancak, dillerin yapıları geniş ölçüde farklılık gösterdiğinden, doğrudan keli me kelime çeviri genellikle akıcılıktan yoksundur ve tamamen anlaşılamaz hale gelebilir.

İki dile özgü doğrudan çeviriyi daha akıcı hale getirebilen determi nistik algoritmalar bulunsa da, makine çevirisine yönelik istatistiksel yaklaşımlar daha başarılı olmuştur. Makine çevirisine yönelik birçok i statistiksel yaklaşımın temel fikri, çevirinin sadakati ile çevirinin akıcıl ığı arasında bir denge olduğu yönündedir. Bu nedenle, makine çevir ileri genellikle diller arasındaki çeviri kalitesi metriğini ve nihai sonuc un akıcılık seviyesini ortak olarak optimize eder (Jursfsky ve Martin, 2009, Bölüm 25).

Makine öğrenimi, makine çevirisi yapmak için giderek daha fazla tercih edilen bir yaklaşım haline gelmektedir. Bir yaklaşım, her biri birkaç uzman çevirisi olan metinleri alıp, kaynak metinden en yakın uzman çevirisini üreten modeller öğren mektir (Koehn, Och ve Marcu, 2003). Daha yakın zamanda, araştırmacılar, metni n A Dili'nden B Dili'ne çevrildiği ve ardından tekrar A Dili'ne çevrildiği geri çeviri y öntemini daha yaygın bir şekilde kullanmaya başlamışlardır (Sennrich,

Doclingo https://www.doclingo.ai

Haddow ve Birch 2016). Model, ardından minimize etmeye çalışır metnin orijinal versiyonu ile geri çevrilenmetin versiyonu arasında ki fark.

23.4.3 SOSYAL TAHMİN

Şu ana kadar metnin kaynağını tahmin etme ve otomatik olarak metin oluşturm a konularını ele aldık. Ancak doğal dil işleme kullanan analistler, metinde kodlanmı ş bilgileri kullanarak toplumda neler olacağını tahmin etme gibi daha yüksek hedef lere de ulaşmayı amaçlamışlardır. Bu bölümde, bu tür tahminlerin sadece birkaç ör neğini tartışıyoruz ki buna *sosyal tahmin* diyoruz.

Metin tahmini için finansal olarak kârlı bir alan, dili kullanarak piyasala rı tahmin etmektir. İş haberlerinden, mesaj panolarından, Twitter'dan ve şirket web sitelerinden çıkarılan özellikler, S&P 500'den Tayvan borsa bor sasına kadar borsa piyasasının nasıl bir performans göstereceğini tahmin etmek için kullanılmıştır (bir inceleme için bkz. Nassirtoussi ve diğ. (2014)). Diğerleri, belirli bir şirketi özellikle tahmin etmek için şirketlerin 10-K ra porlarını (Kogan ve diğ., 2009) veya belirli bir şirketi özellikle belirten hab er hikayelerini (Tetlock, Saar-Tsechansky ve Macskassy, 2008). İlgili olarak, araştırmacılar sosyal medyayı satış performansını tahmin etmek için kullandıla r (Liu ve diğ., 2007), gişe hasılatını (Asur ve Huberman, 2010) ve tüketici güvenini (O'Connor ve diğ., 2010) tahmin etmek için kullandılar.

Siyasi alanda, araştırmacılar metni siyasi sonuçları tahmin etmek için kulla ndılar. Aletras ve diğ. (2016), Avrupa insan hakları mahkemesi davalarında ta nımlanan gerçekleri kullanarak bu davaların kararlarını tahmin ediyorlar. Rei lly, Richey ve Taylor (2012), yerel seçimlerde hangi oy pusulası önlemlerinin " roll-off" veya insanların oy verdikleri diğer önlemler veya adaylar olmasına ra ğmen oy vermekten kaçındıkları önlemler olma olasılığını belirlemek için oy pusulası önlemlerinin adı ve konusu için Google aramalarındaki eğilimleri ta nımlıyorlar. Nay (2017), Kongre'ye önerilen tasarıların nihayetinde yasa halin e gelme olasılığını tahmin ediyor ve tahmin için tasarının metnini veri olarak kullanıyor.

Metni tahmin için kullanmak, kamu yararını artıran tahminler sağlama potansiyeline de sahiptir. Tkachenko, Jarvis ve Procter (2017), gelecekte selin olası olduğu yerleri tah min etmek için doğayla ilgili Flickr etiketlerini kullanıyorlar. Kang ve diğ. (2013), Yelp inc elemelerinden özellikler kullanarak daha düşük hijyen puanlarına sahip olma olasılığı y üksek restoranları işaretliyorlar ve bunun kamu güvenliğini sağlamak için restoranları d aha verimli bir şekilde denetlemek için kullanılabileceğini öneriyorlar.

Şimdi sosyal tahmine daha yakından bakıyoruz ve Beauchamp (2017) üzerinde detaylı bir incelem e yapıyoruz; bu çalışma, eyalet düzeyindeki anketleri tahmin etmek için Twitter verilerini kullanıyor.

Doclingo https://www.doclingo.ai

Amerika Birleşik Devletleri ve dolayısıyla eyalet düzeyindeki seçim sonuçları. Beauchamp (2017), sadece gelecekteki eyalet düzeyi anketlerini tahmin etmekle kalmayıp, aynı za manda tarihi anketleri enterpole ederek, çok az anket yapan eyaletler için anket tahminleri yapma yı ve yerel düzeydeki görüşlerdeki keskin değişimleri tanımlamayı da ilgi alanı olarak belirtiyor. Beauchamp (2017), sosyal medya ile tahmin yapmanın dört "dersini" ortaya koyuyor ve bu dersler yaklaşımının geliştirilmesine rehberlik ediyor:

- İstatistikler: Tahmin, başarı için istatistiksel ölçütler gerektirir ve bu neden le Beauchamp (2017), istatistiksel yaklaşımlar kullanarak etkili bir şekilde d oğrulamak için yeterli referans verisinin olması gerektiğini vurguluyor.
- Kıyaslar: Tahminin başarısı bir kıyaslama temelinde değerlendiril melidir. Bu, tahminin, naif veya rastgele tahminlere kıyasla en iyi alternatif yaklaşımla karşılaştırılması gerektiği anlamına gelir.
- Eğitim: Proxy'lere (anket tahmini için aday anmaları vb.) güvenmek yerine, model, bağımlı değişkenlerin gerçek değerleriyle (örneğin, t arihi anketler) veriler üzerinde eğitilmelidir.
- Örnek Dışı: Beauchamp (2017), test verilerinin gerçekten örnek dışı olması ve ide al olarak zaman içinde ileriye doğru olması gerektiğini vurguluyor.

Bu dersleri akılda tutarak, Beauchamp (2017) bir dizi politik ana htar kelime içeren Twitter API'sinden veri toplar. Toplamda, onun k oleksiyonu 120 milyon tweet, 2012 başkanlık seçimi öncesindeki iki ayda. Bu tweetlerin coğrafyasını coğrafi etiketl eme ve kullanıcı profilindeki yer tanımının serbest metin açıklaması kullanarak çıkarır. Bu tweetleri metindeki ilk 10.000 unigram ile temsil eder ve bunları eya let-gün düzeyine toplar.

Beauchamp (2017) daha sonra bu metin verisini 1.200 eyalet düzeyi an ketle birleştirir; burada, ilgi sonucu olarak Obama'ya olan destek oranını çıkarır. Eğitim için, yukarıda tanımlanan Twitter verileri aralığında en az 1 5 anket olan eyaletlere odaklanır. Bu, ona yalnızca 50 eyaletin 24'ünde m odeli tahmin etme imkanı bırakır. Beauchamp (2017) üç standart modeli —bir elastic net, destek vektör makineleri ve rastgele orman—uygular. Ayrıca, zaman eğilimleri ve sabit etkilerin dahil edilmesine olanak tanıyan ek bir model—bir ansambl yaklaşımı—uygular.

Beauchamp (2017) modelinin üç örnek dışı testini kullanır. İlk olarak, sa dece tweetlerin metni ile modelin, örnek içindeki 24 eyalet için seçim günü sonuçlarını anketlerle karşılaştırarak nasıl tahmin ettiğini değerlendirir. Burada, metin modelinin anketler kadar iyi sonuçlar verdiğini buluyor. İkincisi, met in modelinin, modeli eğitmek için kullandığı 24 eyalet dışındaki eyaletlerdeki seçim sonuçlarını nasıl tahmin ettiğini karşılaştırıyor. Bu test gerçekten örnek dışıdır ve

Doclingo https://www.doclingo.ai

diğer eyaletlere genelleme yapmaktadır. Bu testte, eyalet düzeyinde çok az anket olmasına rağmen, şaşırtıcı derecede iyi bir doğruluk buluyor.

Son testinde, metin modelinin zaman eğilimleri ve sabit etkilerin dahil edilmesiyle, bir sonraki günün anketlerini tüm dönem boyunca öngörürken anketlerle nasıl karşılaştırıldığını değerlendiriyor. Burada, metnin anket temelinin üzerinde ve ötesinde, anketlerdeki kısa vadeli değişiklikleri tanımlamada ve anketler arasında enterpolasyon yapmada öngörü gücü eklediğini buluyor.

Beauchamp (2017) daha sonra Obama'ya destek ile Romney'e destek için en öngörücü özelliklerin neler olduğunu görmek istiyor. İlginç bir şekilde, adayların kendilerine ait anmalar, modellerdeki en öngörücü özellikler arasında değildir. Bunun yerine, Obama'ya destekteki değişiklikleri öngören şaşırtıcı özellikler var; örneğin, Beauchamp'ın dış bilgilere bağlantılar olarak yorumladığı https, Obama'ya artan destek öngörürken, rt veya retweetler, Romney'e destek öngörüyor.

Beauchamp (2017) örneği, sosyal tahminin birkaç önemli unsurunu vurgulamaktadır. Öncelikle, bir olguyu tahmin edebilmek için onun tekrar eden ölçümlerine ihtiyacımız var. Bu, sosyal tahmin yaklaşımlarını nadiren meydana gelen olaylar için kullanmanın zor olacağı anlamına geliyor. Beauchamp (2017) tarafından tahmin edilmek istenen sonuçlardan biri olan seçim sonuçları bile nadiren meydana gelir ve bu nedenle modeli eğitmek için anketleri vekil olarak kullanmak zorundadır.
İkincisi, örnek dışı veriler, modelimizin iyi performans gösterdiğini garanti etmenin tek yoludur. Sosyal medya ile anketler ve seçimler gibi sonuçlar arasındaki ilişki sürekli değiştiğinden, modelimizin gerçekten eğittiğimiz coğrafyalar ve zaman dilimleri dışındaki veriler için tahmin yapıp yapmadığını ancak bu şekilde anlayabiliriz. Son olarak, Beauchamp (2017), ölçümlerimizin mevcut yaklaşımlardan daha iyi tahmin yapması gerektiği önemli noktasını vurgulamaktadır. Beauchamp (2017), tahminlerinin rastgele tahminlerden daha iyi olduğunu göstermek için kolaylıkla bir yol bulabilir, ancak yalnızca bazı modelleri, anketleri kullanma konusundaki mevcut yaklaşımlardan daha iyi tahmin yapmaktadır.

23.4.4 ŞİMDİ GÖRME

Sosyal tahminleri uzun bir süreye yaymak, tahminlerin zamanla hızlı bir şekilde değişen faktörlerden etkilendiği durumlarda zor olabilir. Genellikle, tahmin için kullanılan veriler ile tahmin edilen davranış arasındaki zaman farkı ne kadar büyükse, tahmin doğruluğunun düşük olma olasılığı o kadar yüksektir. Bazı durumlarda, örneğin sivil çatışmayı tahmin etmek (Mueller ve Rauh, 2017), tahminler genellikle bir veya iki yıl önceden yapıldıkları için yanlış olma olasılığı yüksektir ve bu tür olguların nedenleri karmaşık ve dinamiktir.

Doclingo https://www.doclingo.ai

Diğer durumlarda, örneğin oy pusulalarının geçişini veya hisse senedi dalgalanma sını tahmin etmek gibi, tahminler bir olaydan bir ila iki gün önce yapılır ve analistle rin tahmin yapmak için daha güncel bilgileri kullanmalarına olanak tanır.

Şimdi görme, tahmin ile tahmin edilen olay arasındaki zamanı sı fıra indiren belirli bir sosyal tahmin türüdür; tahmin yapıldığı anda gerçekleşen olayları "tahmin eder". İlk bakışta bunun pratik bir değ eri yokmuş gibi görünse de, mevcut olan olayları ölçmek genellikle zordur ve bu tür olaylarla ilgili resmi verilerin olay gerçekleştikten günler veya hatta aylar sonra ortaya çıkması olası değildir.

Nowcasting, gelecekte yalnızca yayımlanacak olan mevcut ölçümleri tahmin etm ek için alternatif verilerin kullanılması sürecidir.

Metin verileri, sosyal medya ve haberlerden gelen metinlerin, genellikle te mel olguları yansıtan, dünyaya dair sürekli bir veri akışı sağladığı için nowcas ting için son derece faydalıdır. Sosyal medya verileri, bireylerin kendi geçim k aynakları ve ekonomi hakkındaki algılarını sıklıkla yansıttığı için, tüketici güve ni ve işsizlik gibi konuları nowcast etmek için kullanılmıştır (O'Connor et al., 2 010; Askitas ve Zimmermann, 2009). Nowcasting ayrıca, ekonomik faaliyet se viyesini, örneğin mal, ev ve araba satışlarını tahmin etmek için Google arama verilerini—kullanıcıların Google'daki arama içeriklerini ve sıklığını—sıklıkla k ullanır (Choi ve Varian, 2012).

Akademisyenler, hızlı bir yanıt gerektiren büyük olayları ele almak için nowcas ting için sosyal medyayı kullanma üzerinde çalışıyorlar. Bazı çalışmalar, kasırgala r (Preis et al., 2013), gıda zehirlenmesi (Nsoesie, Kluberg ve Brownstein, 2014) gi bi devam eden olayları izlemeye ve veri toplamaya çalışmıştır ve doğal veya insa n yapımı felaketlerin ardından göçlerin etkilerini incelemiştir (Bengtsson et al., 2011).

Belki de en ünlüsü, nowcasting'in grip aktivitesinin gerçek zamanlı bir ölçüsü olar ak kullanılmasıdır. Ginsberg et al. (2009), kullanıcı arama verilerini kullanarak Amerik a Birleşik Devletleri'ndeki grip ile ilgili doktor ziyaretlerinin sayısını tahmin eden "Goo gle Grip Trendleri"ni oluşturdu—bu, Google ile ABD Hastalık Kontrol ve Önleme Merk ezleri arasında bir işbirliğidir. Ginsberg ve meslektaşları, grip ile ilgili doktor ziyaretle ri ile en yüksek korelasyona sahip 45 aramayı bulmak için tarihsel kullanıcı grip verile rini kullandılar. Daha sonra, bu 45 aramanın yaygınlığına dair verileri kullanarak gele cekteki grip ile ilgili doktor ziyaretlerini tahmin ettiler.

Başlangıçta Google Grip Eğilimleri (GFT) algoritması, grip ile ilgili doktor ziyaretlerini çok iyi tahmin ediyordu ve ABD ve diğer ülkelerde bir referans olarak mevcuttu. 2008,[6] algoritmanın doğruluğu azaldı

zamanla önemli ölçüde değişti. 2009'da, araştırmacılar GFT'nin domuz gribi salgınını ta hmin etmede iyi çalışmadığını keşfettiler (Cook ve ark., 2011). 2013 yılına gelindiğinde,

Doclingo https://www.doclingo.ai

GFT'nin grip seviyeleri tahminleri, gerçek grip oranlarının neredeyse iki katıydı (Butler, 2013). Diğer araştırmacılar, GFT'nin tahminlerinin faydasının zayıf olduğunu gösterdi—geçmiş grip verilerini kullanarak mevcut grip verilerini tahmin etmek neredeyse eşit derecede iyi performans gösterdi ve algoritmanın pratik avantajlarının az olduğunu öne sürdü (Goel ve ark., 2010).

Neden GFT, arama sonuçlarını kullanarak grip tahmininde uzun vadede daha başarılı olamadı? Bunun başlıca nedenlerinden biri, 2008'de anlık tahmin yapmak için eğitilmiş bir modelin, 2009'da da doğru olabilmesi için sürekli güncellenmesi gerektiğidir, yoksa 2009'daki domuz gribi salgınının medya kapsamı, grip konusunda çok farklı bir kamu ilgisi yarattı ve bu, arama sonuçlarının kalıplarını değiştirmiş olabilir (Cook ve diğ., 2011; kahya, 2013). Ayrıca, Google'dır arama algoritmalarını sürekli güncelleyerek, kullanıcı arama davranışını ve arama sonuçlarını etkiler(Lazer ve diğ., 2014). Tahmin için kullanılacak bu kadar çok veri ile—GFT, insanların aradığı 50 milyon kelime ve ifadeyle başladı—vebu tahminin sonucu olarak kullanılacak çok az veri ile, GFT,grip mevsimiyle yalnızca tesadüfen ilişkili olan arama terimlerini bulabilirdi (Lazer ve diğ., 2014). Bu bölümün ilkelerinin daha genel olarak tartışıldığı gibi,online aramalar ile grip arasındaki ilişkinin kayması,grip tahmin etme yeteneğini sürekli denetim ve algoritmanınayarlarıyla aşabilir.[7]

Doclingo https://www.doclingo.ai

23.5 Sonuç

Metin verisi, kaynak özelliklerini, gelecekteki metni, sosyal sonuçları ve mevcut ölçümleri tahmin etme konusunda bize yeni fırsatlar sunar. Dünya, neredeyse gerçek zamanlı olarak metin ürettiğinden, bu bilgiyi kullanmak,bize yarının nasıl görüneceğine dair daha doğru bir resim sa ğlayabilir.

Yine de, tahmin zor bir problemdir. Dilsel tahminde, birinin ne yazmak i stediğini tahmin etmek içinbir yazım denetleyici kullanmak veya bir arama dizesinin sonlarını tahmin etmek nispeten basit olabilir,bir konuşmayı veya diğer daha karmaşık metinsel etkileşimleri tahmin etmek hala çok zordur. Toplumsal tahminlerde, tahmin girdilerinin ardından günler, aylar veya yıllar s onra gerçekleşecek bir sonucun tahmininin, verilere daha yakın gerçekleşen ta hminlerden daha az doğru olması muhtemeldir. Ve şimdi tahmin etmede, tah min ediciler ile sonuç arasındaki sürekli kayma, daha önce oldukça doğru olan modelleri yanlış hale getirebilir. Bölümün son kısmında, gerçek zamanlı verilerl e sürekli doğrulamanın bir modelin doğruluğunun en doğru ölçüsü olacağını v e çapraz doğrulamadan daha doğru olacağını vurguluyoruz.

Bu bölümde, tahmin kullanmanın potansiyel tuzaklarını da vurgul adık. Sonucu etkileyen değişkenlerin her zaman en öngörücü olmay abileceğinden bahsettik. Nedensel çıkarımın her zaman öngörü güc ünün iyi bir ölçüsü olmayabileceğini ve doğruluğun yanlış sınıflandır ma maliyetlerini dikkate alması gerekebileceğini tartıştık. Ayrıca, poli tika yapımında tahmin kullanmanın potansiyel tuzaklarını da ele aldı k. Özellikle, politika yapımında tahmin kullanımının etkisi, potansiyel geri bildirim döngüleri, katılımcıların stratejilerindeki değişiklikler v e ayrımcılık eğilimini dikkate alarak tahminden ayrı olarak değerlend irilmelidir.

Sonraki bölümde, nedensel çıkarıma geçiyoruz. Tahminle, ne olacağı na odaklanırken, nedensel çıkarımda, çıkarımsal sorun ne olabileceğini tahmin etmektir. Bu, model içinde dahil edebileceğimiz bilgi türlerinde daha az esneklik sağlar, ancak daha doğrudan politika sonuçları olabilir . Tahmin görevinin diğer sosyal bilimsel görevlerden nasıl farklılaştığını anlamak, metin verilerini her bir özel problem için en iyi şekilde nasıl ku llanacağımızı anlamak açısından önemlidir ve nedensel çıkarım ile tahm in arasındaki farkları bir sonraki bölümde vurguluyoruz.

Doclingo https://www.doclingo.ai

Bu y i genellikle tahminin diğer yönlerini belirten ek indeksler içerecektir. Örneği n, y i'yi t + 1 zamanında veya coğrafyada g'de tahmin etmek isteyebiliriz. Bu durum da, görev y i , g , t + 1'i tahmin etmek olabilir. Şimdilik, uygulamaya genel tutacağız ve tahmin etmekle ilgilendiğimiz miktarı y i olarak belirteceğiz.

“Gıda Denetimi Tahmini,” Chicago Şehri, URL: https://chicago.github.io/food-inspections-evaluation/

Robinson, David. “Trump’ın tweetlerinin metin analizi, yalnızca (daha öfkeli) Android yarısının yazdığını doğruluyor.” Variance Explained. http://varianceexplained.org/r/trump-tweets/

[4]Diğerleri de bu çalışmayı yaptı; McGill, Andrew. “Gerçekten Donald Trump'ın tweet attığını söyleyebilen bir bot.” *The Atlantic*. 28 Mart 2017. URL: https://www.theatlantic.com/politics/archive/2017/03/a-bot-that-detects-when-donald-trump-is-tweeting/521127/ ve Twitter hesabı TrumporNot.

[5]Verilerin toplandığı 16 Şubat 2018'deki en son 471 tweet bunlardı.

[6]Moisse, Katie. “‘Google Grip Trendleri’ CDC Gözetim Verileri ile Neredeyse Eşit Bulundu.” *Scientific American.* 17 Mayıs 2010. https://www.scientificamerican.com/article/google-flu-trends-on-par-with-cdc-data/

[7]Bazıları, Twitter'dan gelen veriler gibi diğer tür gerçek zamanlı metin verilerinin grip eğilimlerini tahmin etmede arama verilerinden daha iyi olabileceğini savundu (Broniatowski, Paul, ve Dredze, 2013). Yine de, bu verilerin arama eğilimleriyle aynı kayma sorunlarından muzdarip olması muhtemeldir (Lazer ve diğ., 2014).

Doclingo https://www.doclingo.ai

BÖLÜM 24

Nedensel Çıkarım

Son yirmi yılda, bilgisayar bilimcileri ve istatistikçiler doğal dili analiz etmek için yöntemler üretme ve geliştirme konusunda büyük ilerlemeler kaydettiler. Bu modellerin çoğunun amacı, son bölümde ele aldığımız bir sonucu tahmin etme ktir. Örneğin, spam tanımlamak, bir web sitesinin kullanıcısının tıklayabileceği reklamları tahmin etmek veya bir kullanıcıya arama yoluyla ilgili bağlantılar su nmak için tahmin edici modeller geliştirilmiştir. Bu modeller, tahmin ediciler ile sonuç arasındaki ilişkiyi öğrenmek için etiketlenmiş bir veri seti kullanarak kar arlar almak amacıyla geliştirilmiştir.

Öngörü, bireylere belirli içerikler sunmak için yararlı olsa da, sosyal bili mciler genellikle sosyal politikaları bilgilendiren sorular sormakla ilgilenir ler—politika yapıcıları bilgilendiren kararlar almak için. Örneğin, sosyal bi limciler, kampanya stratejisindeki bir değişikliğin—örneğin, kampanya re klamlarında "negatif gitmek"—bir aday için genel destek üzerinde nasıl b ir etkisi olabileceğini anlamakla ilgilenebilirler. Ya da sosyal medyadaki ya nlış bilgilendirmenin seçim adaletine dair kamu algılarını nasıl etkilediğiyl e ilgilenebilirler. Bu sorular, geleceği doğru bir şekilde tahmin etmeye od aklanmaz—ne olacağına—aksine, dünyanın farklı bir versiyonu altında n e olabileceğini tahmin etmeye odaklanır.

Doğal dili analiz etme yöntemleri genellikle nedensel çıkarım için ta sarlanmadığından, sosyal bilimciler bu yöntemleri sosyal fenomenleri incelemek için uyarlamaya başladıklarında, önce bu teknikleri keşif ve ölçüm için tanımlayıcı amaçlarla uyguladılar; bu görevleri önceki bölü mlerde tanımladık. Örneğin, sosyoloji ve psikolojide, bu yöntemler AB D hükümetinin sanat ve kültürle ilgili tartışmalarını takip etmek için ku llanıldı (DiMaggio, Nag ve Blei, 2013) ve dilin nasıl yansıdığını kişilik ve sosyal etkileşim (Schwartz et al., 2013). Siyaset bilimi alanında,metin yöntemleri, Federal Reserve'deki tartışmayı ölçmek için kullanıldı(Bailey ve S chonhardt-Bailey, 2008), bir metnin yazarının ideolojisiniçalışmak için (Slapin ve Proksch, 2008; Benoit ve Laver, 2003; Lowe, 2008) vesosyal medya paylaşı mlarının duygusunu değerlendirmek için (Hopkins ve King, 2010).

Sosyal bilimlerde, keşif ve ölçüm için veri olarak metin kullanan bazı ilk çalışmalar, açıkça meta verileri ölçüm modeline dahil etti

Doclingo https://www.doclingo.ai

ölçümdeki varyasyonu keşfetmek için çeşitli veri alt kümleri arasın da. Örneğin, Grimmer'ın(2010) İfade Edilen Gündem Modeli, bir gr up gönderinin yazarına dair bilgileri açıkçabir konu modeline ente gre eder, bir konunun ne kadar konuşulduğunu her bireysel yazar bazında değiştiğini tahmin eder. Grimmer (2013*b*) bu modeli, ABD Kongresiüyelerinin, kendi bölgelerinin rekabetçiliği gibi özelliklerin e bağlı olarak,seçmenleriyle konuşurken farklı konulara nasıl odakl andıklarını keşfetmek için genişletir.Quinn ve diğerleri (2010), konu ların zamanla nasıl değiştiğini ölçebilen dinamik bir konu modeliol uşturur ve bunu, ABD Senatosu'ndaki tartışmalardaki değişiklikleri yedi yıl boyuncaçalışmak için kullanır. Bu modeller, ölçüm modeller inde metinle birlikte meta verilerinkullanımını araştıran geniş bir bi lgisayar bilimi literatürü ile birlikte geliştirilmiştir,örneğin, Mimno v e McC
allum (2008) ve Eisenstein, Ahmed ve Xing (2011).

Meta verilerin ölçüm modeline dahil edilme yeteneği, metin verisi y öntemlerinin nedensel çıkarımlarla birlikte nasıl kullanılabileceğini ara ştıran daha fazla araştırmaya ilham verdi. Eğer meta veriler bir metin ölçüm modeline dahil edilebiliyorsa, o zaman bir deneyde tedavi ve k ontrol koşulunun bir göstergesi de tedavinin bir metin sonucundaki e tkisini tahmin etmek için dahil edilebilir mi? Roberts ve ark. (2014) ve Roberts, Stewart ve Airoldi (2016), meta verilerin metne dahil edilmesi için incelediğimiz genel bir modeli, Bölüm 13, Yapısal Konu Modeli'ni araştırıyor ve modelin metnin sonuç olduğu bir deneyde tedavi etkiler ini tahmin etmek için nasıl kullanılabileceğini gösteriyor. Gill ve Hall (2 015), rastgele bir tedavinin bir metin sonucundaki etkisini test etmek i çin nasıl permütasyon testlerinin kullanılabileceğini gösteriyor. Bu ma kaleler, deneylerin yapılandırılmamış metinle birlikte
kullanılmasına yönelik sorunu tanımlamak ve zorluğu ele almak için ilk adımları attı.

Bu bölümde, metnin bir tedavi, sonuç veya karıştırıcı değişkenlerin öl çüsü olduğu durumlarda nedensel çıkarımlar yapmak için gerekli araştı rma süreçlerini ve varsayımlarını açıkça tanımlamak için bir sonraki adı mı atıyoruz. Metinle nedensel çıkarımlar yapma sorununu tanımlayan ö nceki çalışmalardan yararlanarak, metni nedensel analizlerde kullanma nın fırsatlarını ve metin gibi yüksek boyutlu verilerle nedensel çıkarımla r yapmanın zorluklarını açıkça ortaya koyuyoruz.

Bu bölüme nedensel çıkarımın kısa bir genel görünümünü sunarak ba şlıyoruzve tahmin, ölçüm ve nedensel çıkarım arasındaki farkları tekrar g özden geçiriyoruz. Ardından, nedensel çıkarım ile metin verisi kullanmanı n beş rehber ilkesini tanıtıyoruzve bu ilkelere bölümün geri kalanında det aylı olarak döneceğiz. Daha sonra, nedensel çıkarımın temel sorununu ve

Doclingo https://www.doclingo.ai

metin verisinin nedensel çıkarım için ortaya koyduğu zorluklar ve bu sorunlara çöz ümler önermektedir. Bölüm 25 ve 26 metni deneylerde bir sonuç ve bir tedavi olar ak kullanma konusunda birkaç örnek sunmaktadır. Ayrıca Bölüm 27' de gözlemsel çalışmalarda metin üzerinde koşullandırmayı da araştırıyoruz. Bölümümüz, sosyal bilimlerde deneylerle birlikte metin verisi kullanma konusundaki önceki çalışmalar a ve Egami ve diğerleri gibi yardımcı belgelere geniş ölçüde dayanmaktadır. (2018), Fong ve Grimmer (2021), ve Roberts, Stewart ve Nielsen (2020).

Doclingo https://www.doclingo.ai

24.1 Nedensel Çıkarım Giriş

Bu bölüme nedensel çıkarımın temel bir tanımıyla başlıyoruz. Nedensel çıkarımın amacı, bir tedavi değişkeni t i'nin bir sonuç değişkeni y i üzerinde ki etkisini belirlemektir. Bu çerçeve, sosyal bilimlerde birçok farklı nedensel sürece uygulanacak kadar genel; bir kampanya sırasında kullanılan olums uz reklamların bir adayın oy payı üzerindeki etkisinden, bir araştırma katılı mcısının politik görüşleri üzerindeki partizan haber tüketiminin etkisine ka dar. t, birkaç farklı durumdan birini alabilir; diğer bir deyişle, farklı tedaviler vardır ve farklı tedavilerle tedavi edilen birimlerin sonuçları arasındaki fark ı y tahmin etmek istiyoruz. Burada başvurduğumuz mükemmel bir nedens el çıkarım tanımı için Morgan ve Winship (2015) eserine bakın.

En basit örnekle başlıyoruz ve t i'nin yalnızca iki durumu alabilec eğini söylüyoruz—tedavi ve kontrol. Deneysel veya gözlemsel olara k, birinin tedavi aldığı ve diğerinin kontrol aldığı iki grup bireyi gözl emliyoruz. Nedensel çıkarım anlayışını yönlendiren kavram, bir biri min tedavi veya kontrol alıp almadığına bakılmaksızın, her gözlemi n iki *potansiyel sonucu*, ya da sonuç değişkeni y i'nin potansiyel de ğerleri olduğu: tedavi almış olsaydı ne olacağı ve kontrol almış olsa ydı ne olacağıdır. Genellikle, bu potansiyel sonuçları $y_i(1)$ ve $y_i(0)$ olarak belirtiriz, ya da birey i tedavi almış olsaydı ($t_i = 1$), ya da birey i kontrol almış olsaydı ($t_i = 0$) sonuçlarıdır.

Nedensel çıkarımın amacı, potansiyel sonuçlar arasındaki farkları tanımlamaktır—birim i için tedavi altındaki sonucun kontrol altında ki sonuçtan nasıl farklı olacağını. Her birey için, tedavi t i'nin nedens el etkisi, farklı t durumları altındaki potansiyel sonuçlar arasındaki fa rktır, $y_i(1) - y_i(0)$. Ancak, her birey yalnızca bir tedavi alabilir. Bu nedenle, yalnızca $y_i(1)$ ve $y_i(0)$'dan birini gözlemleyebiliriz. Gözlemlediğimiz sonuç genellikle gerçek olarak bilinir ve gözlemlemediği miz sonuç genellikle karşıt gerçek olarak bilinir. Nedensel çıkarımın temel problemi, yalnızca gerçek olanı gözlemleyebilmemizdir ve karşıt gerçeği gö zlemleyememezdir (Holland, 1986). Bu nedenle, bireysel nedensel etkile ri doğrudan gözlemleyemeyiz.

Buna rağmen, tedavi alan bir grup ve kontrol grubunu gözlemliy oruz. Bazı koşullar altında, bu iki grubu nedensel etkiyi anlamak içi n kullanabiliriz. Öncelikle, ilgi miktarını ortalama nedensel etki olar ak değiştiriyoruz: $\bar{y}_T - \bar{y}_C$, burada $\bar{y}_T = \frac{1}{N}\sum_{i=1}^{N} y_i(1)$ ve $\bar{y}_C = \frac{1}{N}\sum_{i=1}^{N} y_i(0)$. $\bar{y}$'yi tahmin edemeyiz.

Doclingo https://www.doclingo.ai

T veya ȳ C doğrudan çünkü y i (1) veya y i (0) için tüm *i*'yi gözlemlemiyoruz. Ancak, ortalama nedensel etki ȳ T − ȳ C'yi, sahip olduğumuz verileri yansıtan bileşenlere ayırabiliriz. p T'nin tedavi edilen gruptaki örneğimizin oranı olduğ unu varsayalım, *T* tüm tedavi edilen birimleri toplar ve *C* tüm kontrol biriml erini toplar; o zaman:

ȳ T − ȳ C = p T (ȳ i ∈ T T − ȳ i ∈ T C) ⏟ Tedavi Edilen Üzerindeki Ortalama Etki + (1 − p T) (ȳ i ∈ C T − ȳ i ∈ C C) ⏟ Kontrol Üzerindeki Ortalama Etki = p T ȳ i ∈ − p T) ȳ i ∈ C C ⏟ gözlemlenen terimler + (1 − p T) ȳ i ∈ ⏟ unobserved

ȳ i ∈ T T'yi veya tedavi edilen grubun ortalama sonucunu ve ȳ i ∈ C C' yi veya kontrol grubundaki kontrol ortalama sonucunu gözlemliyoruz. ȳ i ∈ T C veya ȳ i ∈ C T'yi, yani bu grupların her biri için karşı faktörleri gözle mlemiyoruz.

Bu ayrıştırma, sahip olduğumuz verilerle sahip olmadığımız verileri tahmin etmek için ne yapabileceğimizi ortaya koyuyor. Gözlemlenebilir verilerimizle ȳ T − ȳ C'yi, yani ȳ i ∈ T T − ȳ i ∈ C C'yi tahmin etmek isteseydik, bu yalnızca ȳ i ∈ T T = ȳ i ∈ C T ve ȳ i ∈ T C = ȳ i ∈ C C olduğunda işe yarar. Başka bir deyişle, tedavi grubunun tedavi durumundaki gözlemlenen sonuçlarını, kontrol grubu nun tedavi durumundaki eksik sonuçları için ikame edebiliyorsak ve bunun ter si kontrol durumu için geçerliyse, o zaman eksik potansiyel sonuçlar olmadan ortalama nedensel etkiyi tahmin edebileceğiz.

ȳ i ∈ T T = ȳ i ∈ C T ve ȳ i ∈ T C = ȳ i ∈ C C ne zaman gerçekleşecek? Bu , potansiyel sonuçların bir bireyin tedaviye atanıp atanmadığıyla ilişkili olm adığı durumlarda gerçekleşecektir; yani, ȳ i ∈ C T'nin kontrol grubuna uyg ulandığı için ȳ i ∈ T T'den sistematik olarak farklı olmadığı durumlarda.

Ne yanlış gidebilir? Öncelikle, sunduğumuz notasyon, her bir birim için iki potansiyel sonucun olduğu fikr ine dayanıyor (her bir tedavi durumu altında bir tane). *Kararlı birim tedavi değeri varsayımı* (SUTVA), bu varsayımı, belirli bir tedavi durumunda bir sonucun gözlemlenmesi durumunda, o birim için o tedavi dur umu ile karşıfaktörü yansıttığını belirterek resmileştirir. Örneğin, SUTVA, birimler arasında etkileşimi dışl ar - bir birimin tedavisi, başka bir birimin yanıtını etkilemez. Ayrıca, tedavinin birimler arasında tutarlı old uğunu varsayar - bir grup, başka bir gruptan farklı bir tedavi türü almamaktadır. Eğer SUTVA geçerli değ ilse, o zaman bir grubun sonuçları diğerinin tedavilerini yansıtabilir, bu da ortalama nedensel etkiyi alışıldı k şekilde tahmin edemeyeceğimiz anlamına gelir. Örneğin, bir haber hikayesinin bir siyasi adaya destek üzerindeki etkisini merak ediyorsak, tedavi edilen bir grupla sosyal medyada haber hikayesini paylaşıyor uz, ancak kontrol grubuyla paylaşmıyoruz. Ancak daha sonra tedavi edilen grup, haber hikayesini paylaşı r, böylece kontrol grubunun üyeleri de onu görür. Kontrol grubu artık tedavi edilen grup için iyi bir karşıf aktör değildir, çünkü artık tedavi edilen grubun hikayeyi görmemiş olsaydı ne olacağını yansıtmamaktadır.

Doclingo https://www.doclingo.ai

Siyasi bir adaya destek üzerindeki etkisini merak ediyorsak, tedavi edilen bir grupla sosyal medyada haber hikayesini paylaşıyoruz, ancak kontrol grubuyla paylaşmıyoruz. Ancak da ha sonra tedavi edilen grup, haber hikayesini paylaşır, böylece kontrol grubunun üyeleri d e onu görür. Kontrol grubu artık tedavi edilen grup için iyi bir karşıfaktör değildir, çünkü a rtık tedavi edilen grubun hikayeyi görmemiş olsaydı ne olacağını yansıtmamaktadır.

İkincisi, atama mekanizması *karışık* olabilir. Yani, tedavi ile sonuç arasındaki ilişki sadece nedensel etkiyi değil, aynı zamanda bazı ned ensel olmayan ilişkileri de yansıtabilir. Kontrol grubu, potansiyel son uçlarla ilgili bir şekilde tedavi edilen gruptan farklıysa, o zaman kont rol ataması altındaki kontrol grubunun sonuçları, kontrol ataması alt ındaki tedavi grubunun sonuçları için tahmin olarak kullanılamaz. G özlemlenen verilerle ortalama nedensel etkiyi tahmin edebilmek için *göz ardı edilebilirlik* gereklidir veya potansiyel sonuçların tedavi ata masından bağımsız olması gerekir: $(y_i(1), y_i(0)) \perp t_i$. Örneğin, araştırmacının insanlara haber hikayelerini alma seçeneği sunma sı durumunda, bu nedenle siyasete ilgi duyan kişilerin tedaviye katılması sa ğlanır. Tedavi edilen grup ve kontrol grubu artık karşılaştırılabilir değildir (t edavi edilen grup baştan daha politik bir yapıya sahipti) ve tedavi (haber hi kayelerini alma kararı) potansiyel sonuçlarla ilişkilidir.

Bilim insanlarının karışıklıkla başa çıkmanın özellikle güçlü bir yo lu, tedavi atamasının rastgeleleştirilmesidir. Eğer tedavi ve kontrol grubu rastgele bir sayı üreteci temelinde atanmışsa, o zaman dene yler genelinde tedavi grubu kontrol grubuna benzer olacak ve birin in sonuçları diğerinin potansiyel sonuçları için yer değiştirebilir. Rastgeleleştirme altında, tedavi grubu ve kontrol grubunun sonuçl a ilişkili sistematik bir şekilde farklılık göstermesi olası değildir. Rastgeleleştirme, tedavi atamasının potansiyel sonuçlardan bağımsız olması nı sağlar, çünkü birimler tedaviye seçilemez.

SUTVA ve göz ardı edilebilirlik koşulları sağlandığında, basit bir doğrus al regresyondaki parametreler ortalama tedavi etkisine karşılık gelir.1*y* on *t* regresyonu aşağıdaki denklemi verir:

$$y_i = \beta_0 + \beta_1 t_i + \varepsilon_i .$$

Bu regresyondan, ortalama tedavi etkisinin bileşenleri şunlardır:

$$\bar{y}_i \in TT = E[y_i \mid t_i = 1] = \beta_0 + \beta_1 + E[\varepsilon_i \mid t_i = 1] \; \bar{y}_i \in CC = E[y_i \mid t_i = 0] = \beta_0 + E[\varepsilon_i \mid t_i = 0] .$$

$\bar{y}_i \in TT - \bar{y}_i \in CC$ yalnızca tedavi etkisi β_1'e eşit olacaktır.

Doclingo https://www.doclingo.ai

Hatalar tedavi durumu ile ilişkisiz olduğunda, bu, tedavi atamasını n potansiyel sonuçlarla ilişkisiz olduğu anlamına gelir.

Kausel çıkarım için deneyler kullanan araştırmacılar genellikle ortalama nedensel etki yi tahmin etmek için regresyon kullanır.

Doclingo https://www.doclingo.ai

24.2 Tahmin ve Ölçüm ile Kausal Çıkarım Arasındaki Benzerlikler ve Farklılıklar

Kausal çıkarımın amacını tanımlamak için şimdiye kadar yaptığımız tüm kavramsal çalışmalara rağmen, basit bir doğrusal regresyon ile sonuçlandık; bu, ölçüm bölümünde ve tahmin bölümünde tanımladığımız yaklaşıma oldukça benzer. Gerçekten de, ölçüm ve tahmin bölümlerinde tanımlanan denetimli öğrenme probleminde, y i'nin ilgi kategorisi veya tahmini olduğu ve W i'nin o kategoriyi veya sonucu tahmin etmek için kullandığımız belgede bulunan kelimeler olduğu basit bir doğrusal regresyon ile başladık.

Nedensel çıkarımda, bir veya bir dizi bağımsız değişken değişmiş olsaydı ne olacağına veya neyin farklı olacağına ilgi duyarız. Ne olacağına dair—karşıfaktüel—ve ne olduğuna dair—sonuç—fark, ilgi alanındaki nedensel tahmindir ve bunu önyargısız bir şekilde tahmin etmek isteriz. Tahminle karşılaştırıldığında, modelimizin sonucu ne kadar doğru tahmin ettiğini çok da önemsemeyiz çünkü sonucu gözlemliyoruz; bunun yerine, potansiyel sonucu tahmin etmek isteriz veya bağımsız değişkenlerden birinin veya bir setinin farklı olsaydı ne olacağına dair en iyi tahminimizi yapmak isteriz.

Nedensel çıkarım ve tahmin görevleri arasındaki farklılıkların her durumda verilerle ne yaptığımız üzerinde önemli etkileri vardır. Gerçekten de, nedensel çıkarım ve tahmin konusundaki birçok karışıklığın, bunların birbirleriyle karıştırılmasından kaynaklandığına inanıyoruz. Tahminde, bir önceki bölümde tartıştığımız gibi, modelin içine ne girdiğiyle çok da ilgilenmiyoruz, yeter ki modelin tahmin edilen sonucu doğru olsun. Tahminde, modeldeki katsayıların önyargı içermesini kabul edebiliriz, yeter ki bu tahmin gücümüzü artırsın. Ancak nedensel çıkarımda, modele giren her değişkenin nedensel süreçteki rolü konusunda çok dikkatli olmalıyız, böylece ne olacağını tahmin ettiğimizden emin olabiliriz; bu, önemli ölçüde tedavi sonrası önyargıyı önleyerek ve potansiyel karıştırıcıları hesaba katarak yapılmalıdır.

Aynı şekilde, hem nedensel çıkarım hem de tahmin için bir bölünmüş örnek yaklaşımını önerirken, bölünmüş örnek her durumda farklı bir şekilde kullanılmaktadır. Tahminde, bölünmüş örneği hata oranını tahmin etmek ve modeli ayarlamak için kullanıyoruz. Yani, test verilerindeki genelleme hatasını minimize edene kadar modeli yeniden ayarlamak için tekrar gözden geçiriyoruz. Nedensel çıkarımda ise durum böyle değildir; burada bölünmüş örnek, tanımlama için ve tedavi etkisi veya ilgi katsayısı etrafındaki belirsizliği doğru bir şekilde karakterize ettiğimizden emin olmak için kullanılmaktadır. Tahmin ve nedensel çıkarım arasındaki ayrımın bu kadar önemli olduğunu düşündüğümüz için, bu temaya bölüm boyunca geri döneceğiz.

Doclingo https://www.doclingo.ai

Nedensel çıkarımın temel sorunları, metinle çalışırken bile devam etmektedir.

Doclingo https://www.doclingo.ai

24.3 Metin ile Nedensel Çıkarımın Temel İlkeleri

24.3.1 METİN İLE ÇALIŞIRKEN NEDENSEL ÇIKARIMIN TEMEL SORU NLARI DEVAM ETMEKTEDİR

Metin verisi kullanmanın, nedensel çıkarım ile ilgili temel zorluklardan bi zi kurtardığına dair hiçbir şey yoktur. Metin gibi yeni verilerle bile, nedensel çıkarımın temel problemiyle karşılaşıyoruz: bireysel bir gözlem için farklı bi r tedavi koşulunda ne olacağını gözlemleyememizdir (Holland, 1986). K arşıt durumu doğru bir şekilde tahmin etmek için - dünyanın durumu farklı olsaydı bir sonucun değeri - iyi bir nedensel çıkarım için gereken aynı tem el bileşenlere ihtiyacımız var. İyi bir tasarıma sahip olmalıyız, çalıştığımız ör neğe dikkat etmeliyiz ve gözlemlenebilirler üzerindeki seçim varsayımına g üvenirken dikkatli olmalıyız. Karıştırma, ters nedensellik ve gözlemler arası ndaki bağımlılık, metin verisine sahip olduğumuz durumlarda da, sahip ol madığımız durumlarda olduğu kadar olasıdır ve bu ve diğer çıkarım tehditl erine karşı dikkatli olmalıyız.

24.3.2 TEDAVİ VE SONUÇLARIMIZIN KAVRAMSALLAŞTIRILMASI, ME TİNLE İLGİLİ NEDENSELLİK ÇIKARSAMALARINDA KRİTİK BİR BİLEŞEN OLARAK KALIR

Keşif bölümünde, analistin metin verilerinden yeni kavramlar keşfede bileceğini, metnin farklı temsillerini keşfederek gösterdik. Ölçüm bölümü nde, araştırmacıların belirli bir kavramı metinde ölçekli olarak ölçmek için denetimli makine öğrenimini nasıl kullanabileceklerini açıkladık. Bu bölü mde, bu kavramları nedensel çıkarımlar yapmak için nasıl kullanabileceği mizi gösteriyoruz. Ancak, önceki bölümlerden farklı olarak, kavramsallaşt ırmamıza nasıl ulaştığımız konusunda özellikle dikkatli olmamız gerekiyor —özellikle kavramsallaştırmamızı geliştirirken tedavi ve kontrol hakkında bilgi kullanıp kullanmadığımız konusunda. Nedensel çıkarım çerçevesind e kavramlar geliştirirken ve keşfederken iki büyük riski vurgulayacağız. İl k risk tanıdık gelmeli—metni aşırı uyum sağlama konusunda endişeliyiz. Yani, bir risk, metnin sistematik olmayan yönlerini yakalayan bir kategorilendirm e şeması geliştireceğimizdir; bu, belgelerde geçici gürültüyü açığa çıkarmak anla mına gelir. Ölçüm veya keşif sırasında bu olduğunda, dikkatimizi son derece nadi r ve diğer örneklerde görünmesi olası olmayan kategorilere ayırma riski vardır. Nedensel çıkarımda aşırı uyum sağlama, daha da zararlıdır, çünkü müdahaleleri n sistematik bir etkisi olduğu sonucuna varmamıza neden olabilirken, aslında bö yle bir etki yoktur.

İkinci risk, Nedenselliğin Temel Problemi olarak adlandırdığımız bir sorundur.

Doclingo https://www.doclingo.ai

Gizli Değişkenlerle Çıkarım (FPCILV) (Egami ve diğ., 2018). FPCILV, analis tin deneydeki tedavi sonucuna atıfta bulunarak haritalama fonksiyonun u geliştirerek birimler arasında bağımlılık oluşturduğunda meydana gel ir. Haritalama fonksiyonu, nihai analizde kullanılan verilerle geliştirilirse , o zaman bir birimin tahmin edilen potansiyel sonucu, diğer birimlerin tedavi durumuna bağlı olacaktır çünkü haritalama fonksiyonu diğer biri mlere bağlıdır. Bu bağımlılık, nedensel çıkarım için gerekli koşullardan biri olan SUTVA'yı ihlal eder. Bu bölümde aşırı uyum ve FPCILV'yi daha a yrıntılı olarak açıklayacağız.

24.3.3 METİNLE NEDENSAL ÇIKARSAMALAR YAPMANIN ZORLUKLARI, SIRALI BİLİMİN GEREKENİ VURGULAMAKTADIR

Sosyal bilim, toplumsal kalıpları açıklayan veya tahmin eden gen elleştirilebilir bilgi yaratma sürecidir. Sosyal bilimdeki en iyi nedens el çıkarımlar veya açıklamalar, teori ile dikkatli ampirik kanıtlar aras ındaki yakın ilişkiden ortaya çıkar. Bu etkileşim sıralıdır; teori, dene ylerden öğrendikçe güncellenir ve yürüttüğümüz deneyler teori tar afından yönlendirilir. Bu etkileşim sıralı olduğundan, kanıt edinimi asla tamamen tamamlanmaz ve hiçbir deney tamamen belirleyici d eğildir. Farklı zaman dilimlerinde veya farklı popülasyonlarda dene ylerin tekrarı, daha doğru teoriler çıkarabileceğimiz kanıt tabanımı zı genişletir. Bu teoriler, bir sonraki deneyleri önermektedir.

Deneyler ve teori arasındaki etkileşim nedeniyle, birçok kişi bir d eney yapılmadan önce deneydeki tüm parametrelerin, deneyin inc eleyeceği değişkenler, bu değişkenlerin nasıl ölçüleceği ve deneyin rapor etmesi gereken nihai testler dahil olmak üzere, belirlenmesi gerektiğini önermiştir (Humphreys, Sanchez de la Sierra ve Van de r Windt, 2013). Bu kitabın sözleriyle, haritalama fonksiyonu deney yapılmadan önce belirtilmelidir. Bu önerinin arkasındaki sezgi, eğe r bir deney önceden bilinen bir teoriyi gerçekten test ediyorsa, den ey başladıktan sonra değişmemesi gerektiği ve önceden düşünülm üş araştırma tasarımı dışında sonuçların rapor edilmesinin analizi z ayıflatabileceğidir. Birçok kişi, araştırmacıların deneylerini gerçekle ştirmeden önce ön kayıt yaptırmalarını, böylece araştırmacıların ve ri toplama ve analizi değiştiremeyecekleri bir *ön analiz planı* (PAP) oluşturmalarını önermiştir.

Bununla birlikte, verilerin analizindeki bu tür bir esneklik, belirli bağlamlar da çok faydalı olabilir; aşağıda açıklayacağımız gibi, kullanmayı düşündüğüm üz değişkenler hakkında büyük bir kesinliğe dayanır, bu değişkenlerin nasıl

Doclingo https://www.doclingo.ai

ölçülen ve incelediğimiz verilerin özellikleri. Deneyin beklenmedik aksaklıklar olmadan sorunsuz bir şekilde yürütülmesine dayanır. El bette, bir deney yapmadan önce tüm bu bilgilere sahip olmamız na dirdir veya uygulama sırasında beklenmedik olayların araştırma ta sarımını değiştirmesi. Bu, metin gibi yüksek boyutlu verilerle uğraş ırken özellikle doğrudur; araştırmacılar, katılımcılar tarafından ifad e edilecek konuları ve duyguları öngöremeyebilirler. Deneyin nasıl geçeceğini öngörmedeki zorluklar, PAP'ın garip uygulamalarına ve etkinliğini azaltan kurumların yaratılmasına yol açabilir. Örneğin, a rtık PAP'ların yeni verileri içerecek şekilde değiştirildiği veya ortak k uruluşlarla yaşanan deneyimlerden sonra değiştirildiği yaygındır. V e bir PAP ile ilgili tüm sorunları öngörmek imkansız olduğundan, ar aştırmacılar sapmalarla karşılaştıklarında standart işletim prosedür leri geliştirmeye çalışıyorlar.

Biraz değiştirebildiğimizde, PAP'ların en iyi şekilde savunabildiği bi rçok aynı suistimale kapı açarız.

Potansiyel sapmaları araştırma tasarımında tahmin etmek için mükem mel bir öngörüye güvenmek yerine, her deneyde teori ve deney arasında ki etkileşimi yürütmeyi savunuyoruz. Yani, araştırma tasarımlarımız kulla nıcıları metinleri ve diğer verileri rastgele bir eğitim ve test setine ayırma ya teşvik ediyor. Bu bölme, makine öğreniminde yaygın olarak bilinir ve k itap boyunca kullanılır, ancak burada farklı nedenlerle kullanıyoruz. İlk ol arak, elimizde bir eşleme fonksiyonu varsa, eğitim setini kullanarak bekle diğimiz veri toplama çabalarımızdan herhangi bir sapmayı dışlayabiliriz. Ölçmeyi amaçladığımız şeyin gerçekten ölçüldüğünü doğrulayabiliriz. Bu nu yaptıktan sonra, iyi tanımlanmış bir PAP yazabilir ve test verilerini anal iz edebiliriz. İkincisi, eşleme fonksiyonunu önceden bilmediğimizde, eğiti m verilerini kullanarak bunu keşfedebiliriz, verilerimizi keşfederek veri se timize yararlı bir kodlama şemasını ortaya çıkardığımızdan emin olabiliriz . O kodlama şemasına sahip olduğumuzda, test verilerine kolayca uygula nabilen net bir kural seti tanımlayabiliriz, beklenmedik aksaklıklar olmad an.Örnek bölme kullanımı, bu bölümde göstereceğimiz gibi, FPCILV soru nlarından kaçınmamızı sağlar, aşırı uyum sağlama fırsatımızı sınırlar ve a raştırmacıların özgürlük derecelerini güvenilir bir şekilde kısıtlamamıza y ardımcı olur. Verilerin toplanmasından önce bir ön analiz planı yürütmekt en daha az israf olduğunu savunuyoruz, çünkü bu, araştırmacıların verile r için en yararlı ölçümleri tanımlamasına, beklenmedik kalıpları keşfetme sine ve deneyin gerçek uygulamasını dikkate almasına olanak tanır, aynı zamanda verilerden yapılan nihai çıkarımların güvenilir olmasını sağlar.

Bu son iki ilkenin tartışmasında merkezi olan, haritalamafonksiyonu—onu nasıl keşfettiğimiz ve nedensel çıkarım yapmak için ne zaman sabitlediğimizdir. Çünkü

Doclingo https://www.doclingo.ai

Bir sonuç olarak, bu bölüme bu fonksiyonu gözden geçirerek başlıyoruz - neden buna ihtiyac ımız var, nasıl keşfettiğimiz ve sahip olmasını istediğimiz özellikler nelerdir.

Doclingo https://www.doclingo.ai

24.4 Haritalama Fonksiyonu

3. Bölüm: Keşif ve 4. Bölüm: Ölçüm'ün merkezi görevi, metni daha d üşük boyutlu bir özetine eşlemekti. Egami ve diğerleri (2018) tarafından g olarak adlandırılan bu eşleme fonksiyonu, metni veri olarak kullanma nın temelidir çünkü metnin karmaşık ve yüksek boyutlu doğasını, araştı rma sorumuzun merkezinde yer alan metnin özünün düşük boyutlu bir damıtmasına indirger. Bu eşleme, ölçümümüzü diğer değişkenlerle ilişk ilendirdiğimiz sonraki analizleri gerçekleştirmemizi sağlar.

Bu kitapta şimdiye kadar, haritalama fonksiyonunun birçok biçim aldığını gördük. Catalinac (2016*a*), Japonya'daki seçim manifestolarını, adayların dış po litika konusundaki dikkatini ölçen bir haritalama oluşturmak için Late nt Dirichlet Allocation konu modelini kullandı. Gillion (2016), başkanlık ve Kongre konuşmalarını girdi olarak alan denetimli bir sınıflayıcı ile s iyasette ırk ile ilgili söylemi ölçmektedir. Nielsen (2017) ise, cihad için din adamı desteğini ölçmek amacıyla Naive Bayes sınıflayıcısına dayan an bir ölçek kullanarak bir haritalama fonksiyonu oluşturmak için Müs lüman din adamları tarafından yazılmış metinleri kullanmaktadır. Bu haritalama fonksiyonları oldukça çeşitlidir; el ile kodlamadan, sözlük y öntemlerine, denetimli yöntemlere, denetimsiz yöntemlere ve ölçekle me yöntemlerine kadar çeşitli araçlar kullanılarak haritalama fonksiyo nlarının geliştirilmesine tanık olduk. Bu fonksiyonlar tarafından oluştu rulan ölçümler bazen sürekli, bazen de kateg
orik olmuştur. Ancak her durumda, fonksiyon metni bir ilgi ölçüsüne basitleştirmektedir.

Metinden ölçümler oluşturmanın doğası gereği metinden bir ba sitleştirmeye geçiş gerektirdiğini vurguluyoruz; çeşitli haritalama f onksiyonları neredeyse her araştırma çalışmasında, metin kullanm ayanlarda bile görünmektedir. Örneğin, bir ülkenin ne kadar demo krasi olduğunu ölçmek için Polity İndeksi gibi bir indeks kullandığı mızda, bir ülkenin kurumları hakkında çok fazla bilgiyi tek bir sayıy a - "Polity" - indirgemiş oluyoruz. Demokrasi kavramını nicel bir an alizde kullanmak, boyutunu bir miktar azaltmadan zor olsa da, ölçü mlerimizin gerçekten ilgilendiğimiz kavramları ne kadar yansıttığın ı anlamaya her zaman çalışmalıyız.

Metin analizine yönelik agnostik yaklaşımımızda, belirli bir metin se tinin tek bir doğru organizasyonu olmadığını vurguladık; aksine, meti nlerin damıtılması, araştırmacının amacına özgü olmalıdır. Ürettiğimiz haritalama fonksiyonu, corpus'umuzdaki bireylerin metni nasıl üretti ğine dair bir model değil, araştırma sorusuyla yönlendirilen bir ilgi ölç üsü üretmek için bir araçtır. Bu agnostik yaklaşım nedeniyle, Bölüm 3:

Doclingo https://www.doclingo.ai

Keşif, araştırmacıları verilerini keşfetmeye teşvik ettik, metnin yeni organiz asyonlarını araştırarak, onları yeni fikirlere ve dolayısıyla yeni kavramlara v e ölçümlere götürecek farklı haritalama fonksiyonları uygulayarak. Bölüm 4: Ölçüm, araştırmacıları ölçümlerini bir yineleme sürecinde gelişti rmeye teşvik ettik, en iyi şekilde ölçmek istedikleri kavramı yakala mak için el ile kodlama ve denetimli öğrenme için sınıflandırıcılar g eliştirdiler. Bu iki bölümde de nihai ölçümün kapsamlı bir şekilde d oğrulanmasının önemini vurguladık.

Kitap boyunca metinden ilgi alanındaki kavrama haritalar keşfetmeyi ve öğrenmeyi savunmuş olsak da, bir haritalama fonksiyonu geliştirme süreci nedensel çıkarım yapmayı karmaşık hale getirebilir. Bu bölümde, önce Ega mi ve diğerleri (2018) ile birlikte yukarıdaki nedensel çıkarım notasyonuna haritalama fonksiyonunu tanıtıyoruz. Egami ve diğerleri (2018) gibi, harital ama fonksiyonuna *g* diyoruz. Ardından, *g* 'yi keşfetme ve aynı analizde *g* k ullanarak nedensel bir etki tahmin etme ile ilgili sorunları tanımlıyoruz. So n olarak, bu sorunu ele almak için bir örnek ayırma prosedürü içeren bir iş akışı tanıtıyoruz.

24.4.1 NEDENSEL ÇIKARSAMA *g*

24.1. Bölümde tartıştığımız gibi, ortalama tedavi etkisini belirlemek için birkaç önemli varsayımda bulunuyoruz.İlk olarak, her bir birimin potansiye l sonuçlarının başka bir birimin tedavi durumundan etkilenmediğini gerekt iren Stabil Birim Tedavi Değeri Varsayımını (SUTVA) yapıyoruz. İkincisi, her bir birimin potansiyel sonuçlarının tedavi atamasından bağımsız olduğunu varsayıyoruz. Ve son olarak, tüm birimlerin tedavi alma olasılığının en azın dan bir miktar olduğunu varsayıyoruz. Tedavi için olası değerler kümesine $\mathcal{T}$ adını vereceğiz.

Varsayım 1 (SUTVA) *Tüm bireyler i*, $y_i(t) = y_i(t_i)$.

Varsayım 2 (Görmezden Gelme) $y_i(t) \perp t_i$ ***için*** $t \in \mathcal{T}$.

Varsayım 3 (Pozitiflik) $Pr(t_i = t) > 0$ *için* $t \in \mathcal{T}$.

Bir nedensel çıkarım için g'nin yarattığı zorlukları açıklamak amacıyl a, g'yi nedensel çıkarım notasyonuna dahil ediyoruz. Hem metin olan sonuçları hem de tedavileri dikkate almak için iki farklı uygulamayı ele alıyoruz: 1) tedavinin ikili olduğu ve metnin ölçümlerini yaptığı yer sonuç değişkeni, “metin sonuç olarak” adını verdiğimiz ve 2) tedavinin me tin olduğu ve sonuç değişkeninin bir skalar olduğu, “metin tedavi olarak” adını verdiğimiz durumdur. İlk durumda, sonuç y_i çok boyutludur ve ikin ci durumda, tedavi t_i çok boyutludur. Belirli konuları ele alıyoruz.

Doclingo https://www.doclingo.ai

bu durumların her birinin daha ayrıntılı örnekleri Bölüm 25 ve 26.

Şu anda her durumda—metin tedavi olarak ve metin sonuç olara k—eşleme fonksiyonu *g* biliniyor varsayalım. Yani, analizimiz için kul lanacağımız metninsıkıştırmasını zaten belirlemişizdir. Bu metin sıkı ştırmasına π i (i = 1 , … , N) diyoruz, bu da *π* ünitesi için değeridir *i*. Bu sıkıştırma[æ] alanında değerler alır. Sıkıştırma, bu kitapta şimdiye kada r tartıştığımız herhangi bir metin temsilini alabilir—el ile kodlanmış belge lerin kategorilerini, bir konu modelinden bir belgenin konu oranlarını vey a bir sözlük ya da denetimli öğrenme algoritması tarafından üretilen bir ölçeği temsil edebilir. Metin sonuç olarak alındığında, *g* maps *y* to[æ] , g: [ı] →[æ] y, ve g (y i) = π i. Metin tedavi olarak alındığında, *g* maps *t* to *R*, g: [ð] →[æ] t, ve g (t i) = π i. Kavramsal kolaylık açısından, genellikle[æ] metin ted avi durumu için *K* ikili özellik vektörleri kümesi olarak düşünürüz (Fong v e Grimmer, 2016; Egami ve diğerleri, 2018; Fong ve Grimmer, 2021).

g kullanarak, Bölümde tanımladığımız ortalama tedavi etkisini yeniden yazabiliriz 24.1, ancak bu sefer *g*'yi dahil edin. Öncelikle metni *g* ile bir *K* kategorisine haritalanan bir sonuç durumu olarak düşünün. Sonuçları, tedavi altında g (y i (1)) = π i (1) ve kontrol altında g (y i (0)) = π i (0) olarak yeniden tanımlayabiliriz; burada π i (1) tedavi altında s onucun olacağı *K* kategorisinin bir vektörüdür. π i k (1)'yi tedavi altında *k* kategorisi için potansiyel sonuç olarak tanımlıyoruz. Ortalama tedavi et kisi şu şekilde yeniden yazılabilir:

$$\mathrm{ATE}\ k = \mathrm{E}\left[g(y_i(1))_k - g(y_i(0))_k \right] \quad (24.4.1) = \mathrm{E}\left[\pi_{ik}(1) - \pi_{ik}(0) \right].$$

24.4.2 TANIMLAMA VE AŞIRI UYUM

Önceki bölümde, *g* 'nin araştırmacı tarafından zaten oluşturulduğunu hayal ediyorduk. Ancak, bu kitabın çoğu boyunca, sadece *g*'yi keşfetme v e oluşturma sürecini tanımlamakla kalmadık, aynı zamanda *g* üzerinde k eşif ve yineleme yapmayı da teşvik ettik. Ancak, nedensel çıkarım bağlam ında, *g* 'yi keşfetmek ve aynı analizde tahmin etmek sorunlu olabilir. Egami ve ark. (2018), nedensel etkileri tahmin ederken *g* 'nin keşfi ile ilgili iki a na sorun tanımlamaktadır: tanımlama—Egami ve ark. (2018) tarafından “Gizli Değişkenlerle Nedensel Çıkarımın Temel Problemi” (FPCILV) olarak adlandırıla n—ve aşırı uyum.

Gizli Değişkenlerle Nedensel Çıkarımın Temel Problemi

SUTVA'nın (Varsayım 1) geçerli olabilmesi için, her bir birimin potansiyel sonuçları

Doclingo https://www.doclingo.ai

diğer birimlerin tedavi durumuna bağlı olmamalıdır. Ancak, verileri bir *g* keşf etmek için kullandığımızda, *g* haritalama fonksiyonu tüm birimlerin metnine bağlıdır. Örneğin, bir konu modelinde, belgeler arasındaki benzerlikleri kull anarak metinler içinde birlikte görünme eğiliminde olan kelime gruplarını bu luruz. Denetimli öğrenme yönteminde, algoritma farklı etiketlere sahip belg eler arasındaki farkları öğrenmek için tüm metni kullanır. El ile kodlama yapa rken bile, belgeler içinde gördüğümüz farklılıklara dayalı bir kodlama şeması geliştiririz.

Bu, metinler farklı olsaydı, muhtemelen farklı bir eşleme fonksiyonu k eşfedeceğimiz anlamına geliyor. Uzantı olarak, her belge için π i de tüm d iğer birimlerin metnine bağlıdır. Metin sonuç durumu olarak, bu, her bir birimin potansiyel sonuçlarının π i (1) = g (y i (1)) ve π i (0) = g (y i (0)) tedavi atamalarının diğer birimlerin tedavi atamalarından etkilendiği a nlamına gelir çünkü bunlar *g*'ye bağlıdır. Metin tedavi durumu olarak, bu, tedavilerin kendilerinin eşleme fonksiyonu aracılığıyla birbirlerini etkiledi ği anlamına gelir. Her iki durumda da, bu, potansiyel sonuçların diğer biri mlere atıfta bulunmadan tanımlanamayacağı için nedensel çıkarım için t emel bir sorun yaratır. Sorunun daha teknik bir açıklaması Egami ve ark. (2018)'de mevcuttur.

Aşırı uyum sağlama

Bir analize aynı anda *g* bulmak ve bir nedensel etkiyi tahmin etmek, araştır macının genelleştirilemeyen ilişkileri keşfetmesine neden olabilecek aşırı uyu m ile sonuçlanabilir. Aşırı uyum, herhangi bir araştırma tasarımında bir sorun olabilir, ancak metin çok yüksek boyutlu olduğu için metinle daha belirgindir; b urada keşfedilebilecek birçok olası g vardır. Sonuç olarak metni ele alalım; bur ada araştırmacı, tedavinin metnin duygusu üzerindeki etkisini ölçmek istemekt edir. Tamamen şans eseri, tedavi edilen metinlerin orantısız bir sayısının güne şli kelimesini kullandığını hayal edin. Araştırmacı, bu kelimeyi önceden belirlen miş olumlu duygu sözlüğüne dahil etmemiş olabilir, ancak *g*'leri ararken, bunu n tedavi ile ilişkili olduğunu düşünerek heyecanlanabilir ve bu nedenle onu bir ölçüm olarak seçebilir; bu bir tür avlanma (Simmons, Nelson ve Simonsohn, 2011). Ya da araştırmacı bunu sözlüğe dahil edebilir anlamı nedeniyle, sonuçla olan ilişkisini bilmese bile. Her iki durum da da, bulgu veri kümesinin dışına genelleştirilemez çünkü güneşli olma durumu tedavi ile şansa bağlıydı, sistematik olarak değil. Met in verileri gibi birçok özellik olduğunda, bunların en az bir kısmı ted avi ile şansa bağlı olacaktır, bu da araştırmacıların aşırı uyum sağla maktan kaçınmaları için özellikle önemlidir.

Doclingo https://www.doclingo.ai

24.5 Metin ile Nedensel Çıkarımlar Yapma İş Akışları

Bu bölümde, yukarıda belirtilen iki endişeyi - FPCILV ve aşırı uyum sağlamayı - ele alan metin ile nedensel çıkarımlar yapmanın farklı yaklaşımlarını tanıtıyoruz. Aşağıdaki her bir yaklaşımda, önemli özellik, g'yi keşfetmeyi nedensel etkiyi tahmin etmekten ayırmaktır.

24.5.1 Belgeleri İncelemeye Başlamadan Önce g'yi Tanımlayın

g'yi nedensel etkinin tahmininden ayırmanın en basit yolu, g'yi önceden tanımlamaktır. Örneğin, 16. Bölümde tartıştığımız gibi, araştırmacılar mevcut bir sözlüğü g olarak kullanabilirler. Ya da, 18. Bölümde tartıştığımız gibi, araştırmacılar kendi sözlüklerini tanımlamak yerine mevcut bir kod kitabı kullanabilirler. Bu durumların her birinde, metni sonuç veya metni tedavi örneği olarak kullanarak nedensel etkiyi doğrudan tahmin edebiliriz.

Ancak, bu yaklaşımın dezavantajlarını bu kitap boyunca da belirtmiş bulunuyoruz. 16. Bölümde, bir korpus üzerinde geliştirilmiş hazır sözlüklerin başka birine iyi genelleşmeyebileceğini açıkladık; Loughran ve McDonald (2011) örneğinde olduğu gibi. Bu, hazır kod kitapları için de geçerlidir. Boydstun (2013) örneğini ele alalım; mevcut Politika Gündemleri Kod Kitabını kullanarak gazete makalelerini kodladı, bunu 18. Bölümde açıkladığımız gibi. Mevcut bir kod kitabı olmasına rağmen, kod kitabını güncelledi ve belgelerine doğru bir şekilde uygulanabilmesi için notlar ekledi. Güncelleme olmadan, gazete makaleleri için etiketleri nihayetinde daha az doğru olacaktı.

Gerçekten de, mevcut hazır ölçümleri kullanmak, metni veri olarak görme vaadinin çoğunu feda etmektedir. Bu kitap boyunca tanımladığımız kavramlar ve ölçümler, eşifleri keşfetmek ve geliştirmekten gelmiştir. Her analizde *g* önceden belirleyerek, önemli bulguları ve keşifleri kaçırırız. Önceden ne tür bir kavramı ölçmek istediğimize dair bir fikrimiz olsa bile, veriye bakmadan önce bu ölçümü *g* ile operasyonelleştirmek, ilgi alanındaki gerçek kavramın tatmin edici bir proxy'sine ulaşmamıza neden olabilir.

24.5.2 BİR EĞİTİM/TEST AYIRIMI KULLANIN

Alternatif bir yaklaşım, örneği iki sete ayırmaktır—bir set *g* keşfetmek ve geliştirmek için, diğeri ise nedensel etkiyi tahmin etmek için. Bu yaklaşım Fong ve Grimmer (2016) ile Egami ve ark. (2018) tarafından önerilmektedir. Örnek ayrımı, potansiyel sonuçların test setinde tanımlanması nedeniyle FPCILV sorununu ele alır—test setinde, *g* herhangi bir birimin tedavi durumuna bağlı değildir. Ayrıca, eğitim setinde keşfedilen herhangi bir ilişkinin test setine genelleşmesini sağlayarak aşırı uyum sorununu da ele alır.

Doclingo https://www.doclingo.ai

Bu, eğitim setini keşfetmek ve *g* geliştirmek için kullanabilmemiz a vantajını sağlar; çünkü test setimizde nihai ATE'yi tahmin ederek aş ırı uyumdan korunabileceğimizi bilerek hareket ederiz.

İş akışı şu şekildedir:

1. Örneği böl. Deney yapıldıktan sonra, araştırmacı önceörneği iki par çaya böler, biri keşif için (eğitim seti) vebiri nedensel etkiyi tahmin et mek için (test seti). Eğitim setine ve test setine ne kadar veri konulac ağı,keşfetmek ve *g* üzerinde ince ayar yapmak için gereken veri ilek esin bir etki tahmin etmek için gereken veri arasındaki dengeye bağl ı olacaktır. Hangi bölmeyi seçeceğikesinlikle uygulama spesifik olaca ktır, ancak hangi bölme kullanılırsa kullanılsın,eğitim belgelerinin ra stgele seçilmesini öneriyoruz.

   Önemli olarak, test seti *g* tahmin edilene kadarhiçbir şekilde dokunul mayan veya görüntülenmeyen bir yere konulmalıdır. Test seti yalnızca b ir kez kullanılabilir—nedensel etkiyi tahmin etmek için. Bu eğitim/test b ölmesi versiyonu,bu nedenle, bir sınıflandırıcıyı eğitmek için çapraz doğ rulama kullanmaktan oldukça farklıdır,bunu Bölüm 20'de tartıştık. Bu d urumda çapraz doğrulama,birçok farklı ölçüm (her kat için bir tane) üret ecek veölçümler seti boyunca FPCILV'yi ihlal edecektir. Bunun yerine, bu rada önerdiğimiz prosedür, Bölüm 21'de tanımladığımız eğitim/test böl mesine daha benzer,test setinin yalnızca bir kez—son ölçüm için kullanıl dığı yer.
2. Keşfet *g*

   araştırmacı keşfetme ve *g*

   Burada, bu kitapta tanımlanan tüm yöntemleri kullanarak keşfetmek, bulmak , ölçmek ve kullanmak istediğimiz kavramları doğrulamak için kullanabiliriz. A raştırma sorusuna yararlı olacak, ancak aynı zamanda genelleştirilebilir bir öl çüm bulmayı umuyoruz - eğitim verileri dışında diğer veri setlerinde bulma ve ölçme olasılığımız olan bir ölçüm.
3. Doğrulama *g*. Bir *g* üzerinde karar kıldıktan sonra, bunu doğrulamamız gereki r, bu da Bölüm 3: Keşif ve Bölüm 4: Ölçüm'de açıklandığı gibi, özellikle Bölümler 12, 20, ve 21. Doğrulama, gerçekten ölçtüğümüz kavramı ölç tüğümüzü ve doğruluğumuzun yüksek olduğunu garanti eder. Doğrulama genellikle eğitim setini parçalara ayırmayı gerektirecektir, çapraz doğrulama sürecinde (Bölüm 20) veya bir ölçüm için kullanılan denetimsiz yöntem (Bölüm 21).
4. **Test set'e uygulayın ve yeniden doğrulayın. Çünkü yalnızca testi kullanabiliriz**

Doclingo https://www.doclingo.ai

bir kez ayarladıktan sonra, test setini açmadan önce, *g* ile mutlu olduğumuzda n emin olmalıyız ve *g* 'nin tüm yönlerinin iyi tanımlandığından emin olmalıyız, b u da test setindeki metni nasıl temsil edeceğimizi ve etiketleri elde etmek için h aritalama fonksiyonunu nasıl uygulayacağımızı içerir. Bu noktada, ATE'yi (Gerbe r ve Green, 2012; Humphreys, Sanchez de la Sierra ve Van der Windt, 2013; Blai r ve diğ., 2019) hesaplamak için bir planımız olduğundan emin olmak için bir ön analiz planı yazabilir veya tasarımımızı açıklayabiliriz.

Test set'ine *g* uyguluyoruz ve ortalama nedensel etkiyi tahmin ediyoruz. Ancak henüz işimiz bitmedi, *g*'yi yeniden doğrulamamız gerekiyor. Eğer model eğitim setinde aşırı uyum sağladıysa veya eğitim seti çok küçük y a da temsil edici değilse, *g* test setinde tamamen farklı bir yorum alabili r. *g* 'nin test setinde benzer doğruluk seviyeleri elde ettiğinden ve yoru munun istediğimiz gibi olduğundan emin olmak için test setinde doğrul uğu değerlendirmeliyiz. Eğer *g* test setinde iyi uyum sağlamıyorsa, ne y azık ki eğitim verilerine geri dönemez veya *g*'yi değiştiremeyiz.

Ancak, başarısız bir test seti doğrulaması bile gelecekteki deneyleri mizde ölçümlerimizi nasıl geliştirebileceğimiz hakkında önemli bilg iler sağlar.

Örneklemi bölmek önemli bir denge sunar—ATE'yi hesaplamak için daha az v eriye sahip olmanın verimlilik kaybı. Bu, eğitim setinde ne kadar veriye ihtiyacımı z olduğunu bilmememizle karmaşıklaşır—bu, “keşif için ihtiyaç duyduğumuz güc ü” ifade etmek gibidir (Egami ve diğ., 2018). Bu alandaki gelecekteki çalışmaların, kavramları rafine etmek ve tedavi etkilerini hesaplamak için verileri en etkili şeki lde nasıl bölümlendireceğini ele almasını umuyoruz.

24.5.3 SIRALI DENEMELER YAPMA

Metin verileri ile nedensel çıkarımlar yapmak için tanıttığımız son iş akışı, sıralı d eneyler yapmaktır. Bu tasarımda, araştırmacı ilk deneyden elde edilen verileri kulla narak g\’yi geliştirir, ardından bu deneyden elde edilen verileri atar ve g\’nin metni bir tedavi veya sonuca eşleştirmek için kullanıldığı bir takip deneyini gerçekleştirir. Bu tasarım, pilot çalışmanın verilerinin g\’yi tanımlamak için kullanıldığı bir pilot çal ışma yürütmeye benzer. Bu durumda pilot, yalnızca anketi veya rastgele kontrol de nemesini tasarlamakla kalmaz, aynı zamanda analizi düzeltmeye de yardımcı olur.

Sıralı deneyler, araştırma bulgusunun genelleştirilebilirliğini test etmek için örnek bölmel erden daha güçlü bir test sağlar. Sıralı deneyler arasında sonuçları çoğaltmak, yalnızca g\’nin başka bir veri kümesine genelleşmesini gerektirmekle kalmaz, aynı zamanda nedensel etkin in biraz farklı bir zaman dilimi ve nüfusa genelleşmesini de gerektirir. Ortalama bir rastgele eğitim/test bölmesi, aynı ATE’yi yansıtacaktır, ancak sıralı deneyler arasındaki ATE değişebilir.

Doclingo https://www.doclingo.ai

Sıralı deneyler bu nedenle genelleştirilebilirliği test etmek için ideal dir, ancak uygulamak için daha fazla kaynak ve zaman alır. Bunun daha genel bir versiyonu, sıralı deneyin belirli bir çalışmanın içinde değil, bilim insanları topluluğunun bir parçası olarak gerçekleştirild iği bağlamlar ve araştırmacılar arasında çalışmaların çoğaltılmasıdı r.

Doclingo https://www.doclingo.ai

24.6 Sonuç

Bu bölümde, öncelikle nedensel çıkarımın temel ilkelerine bir göz attık. Tahmin, ölçüm ve nedensel çıkarım arasındaki benzerlikleri ve farklılıkları tartıştık ve metinle nedensel çıkarım kullanmanın bazı ilk elerini tanıttık. Ardından, aynı veri kümesinde nedensel çıkarımlar ya pma sorununu, haritalama fonksiyonu g'yi keşfetmekle birlikte tanı mladık ve Gizli Değişkenlerle Nedensel Çıkarımın Temel Problemi'ni (Egami ve ark., 2018) ve aşırı uyum sorununu. Son olarak, biz bunu ele almak için bazı iş akışlarını tanımladı, bunlar arasında mevcut bir haritalama fonksiyonu kullanmak, verileri bölmek ve ardışık deneyler yapmak yer alıyor.

Elbette, bu iş akışları teoride iyi çalışıyor, ancak pratikte uygulaması daha zordu r.Sonraki iki bölümde, metni sonuç olarak (Bölüm 25) ve metni tedavi olarak (Bölüm 26) kullanmak için nedensel çıkarım yapmak üzere araştırma tasarımlarına örne kler sunuyoruz. Bölüm 27'de, metin ve nedensel çıkarım konusundaki tartışmamızı , metnin gözlemsel bir çalışmada bir karıştırıcı olduğu durumları dikkate alacak şek ilde genişletiyoruz. Bu tartışma boyunca, nedensel çıkarımda metin verilerinin kull anımının yeni, heyecan verici ve sürekli gelişen bir alan olduğunu belirtmekteyiz. Burada gelecekteki çalışmalar için bir temel sağlamayı umuyoruz.

---

[1]Önemli bir şekilde, bu, ek kovaryantlar için kontrol etmediğimiz özel bir durum aya rıdır ve tedavi ikilidir. Böylece, regresyon etkili bir şekilde ortalamalar arasındaki farkı hesaplamaktadır.

Doclingo https://www.doclingo.ai

BÖLÜM 25

Sonuç Olarak Metin

Sonuç olarak metin ayarı analitik olarak basittir. Özellikle, g, şimdi *y* olarak adlandırılan metni - çalışılan sonuç olarak vurgulamak için - ilgi alanındaki daha düşük boyutlu sonuca, π, eşleştirmektedir. Belirli bir *g* varsayarak, ortalama tedavi etkisini (ATE) tahmin etmek istiyoruz. Bölüm 24'te tartıştığımız eğitim/test ayırma yaklaşımını kullanarak, *g* eğitim belgeleri üzerinde geliştirilmiştir, bunu *I* ile alt simgeleyerek gösteriyoruz. Ancak ATE, test seti *O* üzerinde tahmin edilmektedir, bunu alt simge *O* ile gösteriyoruz. SUTVA, göz ardı edilebilirlik ve pozitiflik varsayımlarını (Bölüm 24'ten Varsayımlar 1-3) ve Egami ve diğerleri (2018) notasyonunu varsayarak, ATE'yi şöyle tanımlayabiliriz:

$$\mathrm{ATE\hat{}} = \sum i \in O\, I(t_i = 1)\, g_I(y_i(1)) \sum j \in O\, I(t_j = 1) - \sum i \in O\, I(t_i = 0)\, g_I(y_i(0)) \sum j \in O\, I(t_j = 0).$$

Diğer bir deyişle, eğitim belgeleri *I* üzerinde *g* öğrenerek, bunu *O* içindeki verilerin sabit bir dönüşümü olarak ele alıyoruz ve tahmin yapıyoruz. Egami ve diğerleri (2018) bir tanımlama kanıtı sunmaktadır.

Bu bölümde, metni sonuç olarak kullanmanın iki örneğini gözden geçiriyoruz. İlk olarak, Egami ve ark. (2018) tarafından gerçekleştirilen göçmenlik konusundaki tutumlar üzerine bir anket deneyini tartışıyoruz. İkinci olarak, başkanlık konuşmalarının medya kapsamı üzerindeki etkisini tahmin eden Franco, Grimmer ve Lim (2018) çalışmalarını vurguluyoruz. Her iki durumda da yazarlar, g'yi keşfetmek için eğitim/test ayrımını kullanıyor, ardından nedensel etkiyi sırasıyla tahmin ediyorlar. Ayrıca, Egami ve ark. (2018) nihayet ATE'yi tahmin etmeden önce g'yi yinelemeli olarak rafine etmek için ardışık deneyler kullanıyorlar.

Doclingo https://www.doclingo.ai

25.1 Göçmenlik Üzerine Bir Deney

Egami ve ark. (2018), bir bireyin suç geçmişinin göçmenlik konusund aki tutumları nasıl etkilediğini bir anket deneyini kullanarak inceliyorlar. Cohen, Rust ve Steen (2004) tarafından yapılan daha eski bir çalışmadan yo la çıkarak, anket katılımcılarını iki farklı varsayımsal senaryoyu okumaları iç in rastgele atıyorlar. Her iki durumda da kişi, Amerika Birleşik Devletleri'ne yasadışı olarak girmiştir. Ancak, bir durumda senaryo, kişinin suç geçmişin e sahip olduğunu tanımlıyor.

Uygulama vinyeti şu şekildeydi:

> "28 yaşında, bekar bir adam, başka bir ülkenin vatandaşı, Amerik a Birleşik Devletleri'ne yasadışı olarak girmekten mahkum edildi. Bu suçtan önce, her biri bir yıldan fazla süren iki önceki hapis cez ası almıştı. Bu önceki cezalardan biri şiddet içeren bir suçtu ve ülk esine geri deport edilmiştir."

Kontrol vigneti aşağıdaki gibiydi:

> "28 yaşında, bekar bir adam, başka bir ülkenin vatandaşı, Amerika Birleşik De vletleri'ne yasadışı olarak girmekten mahkum edildi. Bu suçtan önce, daha ön ce hiç hapse girmemişti."

Katılımcılara, bu durumda ABD hükümetinin ne yapması gerektiği ni tanımlamalarını isteyen açık uçlu bir soru soruldu.

> "Bu suçlu hapse gönderilmeli mi?" (cevaplar: evet, hayır, bilmiyorum) ancak a rdından "Neden veya neden olmasın? Lütfen açıklayın." şeklinde sorulmalıdır. en az iki cümle Bu kişiyle ilgili olarak ABD hükümetinin alması ger eken eylemler nelerdir ve neden?

Analizin amacı, katılımcıların ABD hükümetinin hangi eylemleri gerçekleşt irmesi gerektiği konusundaki yazılarında vignette'in etkisini tahmin etmektir. Bunu tahmin etmek için yazarların, açık uçlu yanıtların metnini kullanılabili r bir ilgi miktarına dönüştüren bir *g* fonksiyonu geliştirmeleri gerekiyor.

Doclingo https://www.doclingo.ai

Egami ve ark. (2018), g'yi keşfetmek ve nedensel etkiyi tahmin etmek için bir eği tim/test bölme ve ardışık deneyler kombinasyonu kullandılar. Öncelikle, Cohen, Ru st ve Steen (2004) tarafından sağlanan verileri, Bölüm 13'te (Roberts ve ark., 2014) t anımlanan Yapısal Konu Modeli'ni kullanarak analiz ettiler. Ardından, bu deneyi Te mmuz 2017'de Mechanical Turk deneyinde birkaç tasarım değişikliği ile tekrar ettil er. Son olarak, deneyi Eylül 2017'de yeniden tekrarladılar. Her durumda, g'yi gelişti rmek için bir eğitim/test bölmesi kullandılar ve yalnızca test setinde ATE'yi tahmin ettiler.

Öncelikle, gerçekleştirdikleri son deneyin sonuçlarını gösteriyoruz. Tablo 25.1 her 11 konu için en olası kelimeleri, Egami ve ark. (2018) tarafından verile n konu etiketlerini ve tahmin edilen etki büyüklüğünü ve güven aralığını göste rmektedir. Gördüğünüz gibi, konular deportasyon savunusundan (Konular 2 ve 3) davayla ilgili daha fazla bilgi talep etme (Konu 5). Açıkça, tedavi, yanıt veren tarafından yazılan konular üzerinde bir etkiye sahiptir. Göç menin bir suç geçmişine sahip olduğu söylendiğinde, yanıt verenin dep ortasyon hakkında yazdığı miktar artmakta ve yanıt verenin kişinin ülke de kalması gerektiğini savunma olasılığı azalmaktadır.

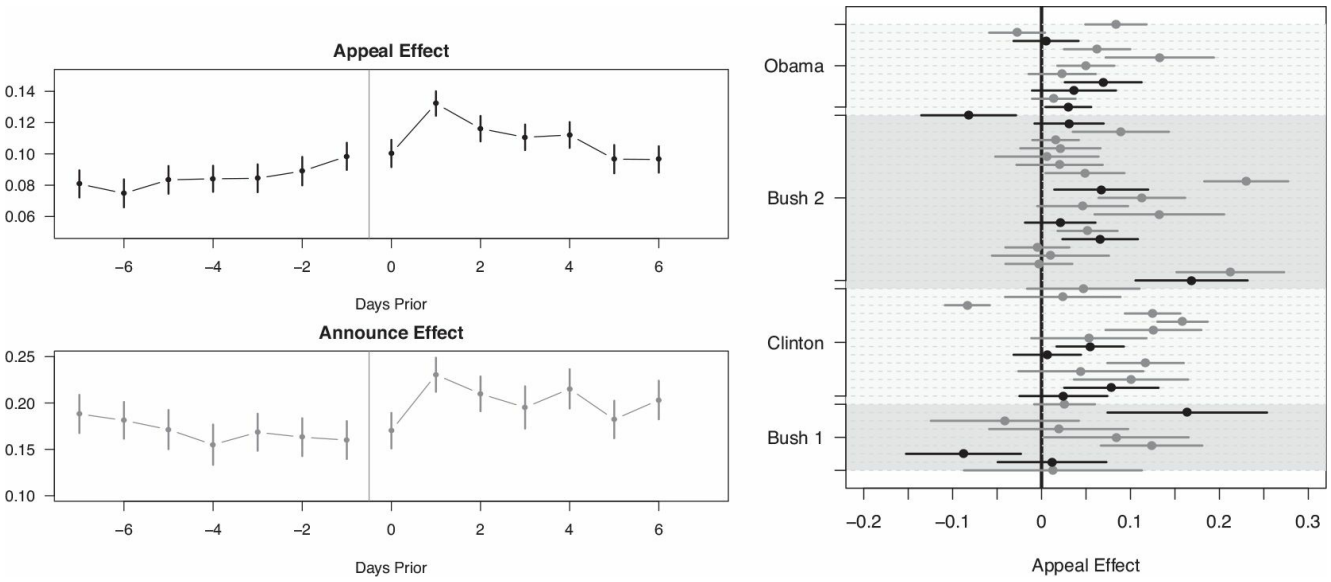
Egami ve ark. (2018), orijinal Cohen, Rust ve Steen (2004) çalışması nın ve çalışmanın ilk tekrarının analizlerinde benzer sonuçlar buluyorl ar, her durumda kullanılan g biraz farklı olsa da.

Tablo 25.1. Konu başlıkları, en yüksek olasılıklı kelimeler ve tahmin edilen etkileretkiler ine göre sıralanmış tedavi etkileri, Egami ve ark. (2018) Deney 3'ten.

	Etiket	En Yüksek Olasılıklı Kelimeler	Etki	ORADA
Konu 3	Paranın yüzünden sınır dışı etme	sadece, geri, gönder, ülke, ha pishane,gel, cezaevi, zarar, para	0.032	(0.015, 0.049)
Konuyu 7	Yasanın tam kapsamıyla cezalandırmak	suç, şiddet, kişi, yasa,mahkum, işle mek, sınır dışı etmek, yasadışı,cezalandı rmak, suç işlemek	0.024	(0.01, 0.037)
Konuyu 4	Koşullara bağlıdır	ilk, ülke, zaman, geldi, hapis,adam, düşünmek, sebep, yönetim, koymak	0.012	(0, 0.026)
Konuyu 1	Ülkede kalmak için sınırlı ceza, sistem hakkında şikayetler göç sistemi	yasal, yol, göç, tehlike,insanlar, izin vermek, gelmek, ülke, olabilir,gir mek	0.01	(−0,005, 0.029)
Konu 11	Tekrar suç işleyen, topluma tehlike	inan, ülke, ihlal, suç, person, y asa, sınır dışı et, hapishane, kullanıcı, birey	−0.002	(−0,004, 0.001)
Konu 9	Hapishane yok, sınır dışı etme	sınır dışı et, hapishane, olacak, ki şi, ülke, adam, yasadışı, hizmet, süre , hüküm	−0.002	(−0,014, 0.009)
Konu 10	Geri gönderilmelidir	gönderildi, geri, ülke, hapishane, ev, düşün, öde, köken, yasadışı, zaman	−0.003	(−0,012, 0.007)
Konu 2	Sınır Dışı Etme	sınır dışı et, düşün, hapishane, suç,	−0.003	(−0,009,

Doclingo https://www.doclingo.ai

		zaten, hapsedil, yasadışı, beri, hizmet,za man		0.001)
Konu 8	Kalmasına izin ver, hapishane yok, rehabilite et, muhtemelen başka bir açıklama	yapma, suç, düşün, dene, o, offens, daha iyi, durum, bil, yap	−0.015	(−0,028, −0,001)
Konu 6	Suç, az miktarda hapis cezası, ardından deportasyon.	girmek, ülke, yasadışı, kişi, hapis, deport, zaman, uygun, hapsedil, belirle	−0.024	(−0,04, −0,003)
Konu 5	Daha fazla bilgiye ihtiyaç var, eğer şiddetliy sehapset	eyalet, birim, hapishane, suç, göç, illeg, al, suçlu, basitçe, koy	−0.024	(−0,042, −0,006)



Şekil 25.1. Başkanlık kamu çağrılarının medya kapsamı. Şekil 8, Grimmer ve Lim (2018)

Doclingo https://www.doclingo.ai

25.2 Başkanlık Kamu Çağrılarının Etkisi

İkinci örneğimizde, metni bağımlı bir değişken olarak kullanarak, Franco, Grimmer ve Lim (2018), başkanların prime time televizyonunda kamuya çağrılar yapmasının sonraki medya kapsamı üzerindeki etkisini incelemektedir. Büyük bir literatür, başkanların kamuoyunu etkileme yeteneği ve haberlerde nasıl kapsandıkları hakkında karışık sonuçlar sunmaktadır. Karışık sonuçların bir nedeni, önceki çalışmaların başkanlık çağrılarının etkisini değerlendirmek için farklı araştırma dizaynları ve değişen kanıt türleri kullanmasıdır. Çağrıların etkisini izole etmek için, Franco, Grimmer ve Lim (2018), prime time televizyon kapsamı sırasında yapılan başkanlık kamu açıklamalarıyla sınırlı kalmaktadır. Daha sonra, konuşmadan önceki ve sonraki hafta boyunca başkanın en iyi on gazetedeki kapsamını toplar ve aynı zaman dilimindeki yayın haber transkriptlerini de toplar. Sonuç, başkanın kamuya çağrıları boyunca toplanan, başkanı anan yaklaşık 160.000 hikayeden oluşan bir koleksiyondur.

Franco, Grimmer ve Lim (2018) bu verileri, başkanların medyadan aldı kları haber türü üzerindeki etkisini sormak için kullanıyor. Bu değerlendir meyi yapmak için Franco, Grimmer ve Lim (2018) bir Yapısal Konu Modeli kullanarak bir dizi konuyu tahmin ediyor, haber hikayelerinin %10'unu ve transkriptleri bir eğitim seti olarak ve geri kalan %90'ını bir test seti olarak kullanıyor. Bu ayrım, eğitim setinde belirgin konuları keşfetmek için yeterli bilgi ve test setinde bir tedavi etkisi olup olmadığını çıkarsamak için yeterli içerik olmasını sağlıyor.

Bu konu uyumunu göz önünde bulundurarak, Franco, Grimmer ve Lim (2018) her başkanlık kamu çağrısının belirgin konusunu tanımlıyor. Bu tanımlanan belirgin konu yu kullanarak, başkanın konuşmasının bu belirgin konu üzerindeki etkisini sonraki ha ber medyası içinde tahmin ediyorlar.

Şekil 25.1'deki sol grafik, başkanın konuşmasının konu kapsamı üze rindeki etkisini iki farklı durumda gösteriyor: 1) başkan Kongre'ye bir ç ağrı yaptığında (siyah, üst çizgiler) ve 2) başkanın bazı büyük dünya ol aylarının gerçekleştiğini ileten bir duyuru yaptığında (gri, alt çizgi). Bu yüzdeleri kullanarak, Franco, Grimmer ve Lim (2018) konuşmanın etki sini, konuşmanın yapıldığı günün hemen öncesi ve sonrası arasındaki kapsam payını karşılaştırarak çıkarıyorlar.

Sol grafikte, başkanların kamuya yaptığı çağrıların, haber kapsamını önemli ölçüde artırd ığı gösterilmektedir. Kongreye yapılan bir çağrının ardından, başkanlar konu hakkında konuş madan hemen önceki orana kıyasla 3.4 yüzde puanı daha fazla haber kapsamı alıyorlar. Alt g rafikte, başkanın büyük bir dünya olayını duyurduktan sonra başkanlık konuşmasının etkisini değerlendirmenin neden sorunlu olabileceği gösterilmektedir. Başkan bir olayı duyurduktan sonra, başkanın bahsedildiği makalelerde o konunun kapsamındaki artış yedi

Doclingo https://www.doclingo.ai

yüzde puanı olmaktadır. Elbette, bu artışın bir kısmı, başkanın kon uşmasından ziyade meydana gelen olaya atfedilebilir, bu nedenle t ahmin, başkanın konuşmasını o olayın ek kapsamıyla birleştirmekt edir.
Belki de şaşırtıcı değil, duyuruların artan kapsamının çağrılardan d aha uzun sürdüğünü görüyoruz.

Franco, Grimmer ve Lim (2018) ayrıca, çağrıların sonraki haber kapsamı üzerindeki etkisine dair konuşma bazında tahminler sunmaktadır. Şekil 25.1'de, duyurular (gri) ve çağrılar (siyah) için bir konudaki kapsam artışı göste rilmektedir. Bu şekil, başkanın bir dünya olayıyla ilgili bir duyuru yaptığında ha ber kapsamının daha fazla arttığını gösteriyor; ancak bu, büyük haber hikayesi nin başkanın konuşmasının dışındaki ek kapsamı sonuçlandırmasından kaynak lanıyor olabilir. Ayrıca, bu şekil, başkanların medya kapsamını etkileme konusu nda başkanlıkları boyunca daha iyi hale gelmediğini göstermektedir; şeklin üst kısmına daha yakın olan daha sonraki konuşmalar, şeklin alt kısmındaki daha önceki konuşmalardan daha etkili değildir.

Doclingo https://www.doclingo.ai

25.3 Sonuç

Bu bölümde, metni sonuç olarak kullanmanın iki örneğini incele dik. Egami ve diğerleri (2018) göç deneyinde, ardışık deneylerin eği tim/test ayrımı ile birleştirilmesinin faydasını vurguladık. Deneyleri n 15 yıllar, o örnek göreceli olarak gösterir suç geçmişine ilişkin algılar ile ABD anketi katılımcılarının ABD hükümeti politikası üzerindeki görüşleri arasındaki ilişkiyi istikrarlı hale getirme. Franco, Grimmer ve Li m (2018) örneği aracılığıyla, metnin bir sonuç olarak nasıl kullanılabileceğini kesinti li zaman serisi tasarımında başkanlık açıklamalarının medya kapsamı üzerindeki et kisini tahmin etmek için gösterdik, yine g'yi keşfetmek için eğitim/test bölme tasarı mını kullanarak. Bir sonraki bölümde, tedavi olarak metin örneklerine geçiyoruz.

Doclingo https://www.doclingo.ai

BÖLÜM 26

Metin olarak Tedavi

Son bölümde, metni sonuç olarak kullanmanın iki örneğini tanımladık. Bu bölümde, nedensel çıkarımda metnin biraz daha karmaşık bir biçimi ne geçiyoruz - metni tedavi olarak kullanma. Fikirleri netleştirmek için, kampanya reklamlarının seçmenlerin katılım kararları üzerindeki etkisiy le ilgilenen geniş literatürü düşünelim. Bir kampanyanın olumsuz rekla mıyla karşılaşmanın - rakibe saldırı içermeyen bir reklama kıyasla - bire yin seçimde katılım olasılığı üzerindeki etkisiyle ilgileniyor olabiliriz. Ted avi, reklamın metnidir - tedavi olduğunu vurgulamak için t i ile gösteril mektedir. Potansiyel sonuçlar y i (t i), katılımcı i'ın reklam t i'yi izledikte n sonraki katılım kararını yansıtır.

Seçim katılımını etkileyen t i'nin etkisini tahmin etmenin bir yolu, iki farkl ı reklamın etkisini karşılaştırmaktır. Bu, birçok kişinin endüstri ortamlarınd a kullanımından aşina olduğu A/B test çerçevesidir. Ancak, genellikle sosya l bilimciler, metnin altında yatan gizli değerinin sonucu nasıl etkilediğini an lamakla ilgilenirler. Bu bağlamda, bir reklamın rakibe yönelik olumsuz bir s aldırı içerip içermediği gizli bir değişkendir—olumsuz bir saldırı, reklam içi nde birçok farklı biçimde kendini gösterebilir, ancak bu saldırıları bir saldırı içerip içermediği kategorik değişkenine eşleyebiliriz. Bu bölümde ele aldığ ımız A/B testine alternatif bir yaklaşım, araştırmacının birçok farklı kampan ya reklamını katılımcılara atamasıdır; bunların bir kısmı olumsuz saldırıyı iç erebilir. Burada, Egami ve ark. (2018) izinden giderek, ilgi tedavisini π i = g (t i) olarak belirtebiliriz; bu, reklam metni ile reklamın olumsuz bir saldırı iç erip içermediği veya başka bir ilgi özelliği arasında bir eşlemedir. Ortalama Tedavi Etkisi (ATE) şöyle olacaktır:(2018), ilginin ele alınmasını π i = g (t i) r eklam metni ile reklamın olumsuz bir saldırı veya başka bir ilgi çekici özellik içerip içermediğine ilişkin bir değişken arasındaki eşleme olarak tanımlaya biliriz. OrtalamaTedavi Etkisi (ATE) şu şekilde olacaktır:

$$\hat{ATE} = \sum i \in O\, I(\pi i = g\, I(t i) = 1)\, y i(1)) \sum j \in O\, I(\pi j = g\, I(t j) = 1) - \sum i \in O\, I(\pi i = g\, I(t i) = 0)\, y i(0)) \sum j \in O\, I(\pi j = g\, I(t j) = 0). \quad (26.0.1)$$

25. Bölümde olduğu gibi, g I'nin g'nin geliştirilmiş olduğunu belirtmek için kullanıldığını gösteriyoruz.

Doclingo https://www.doclingo.ai

eğitim setinde ve O'nun ATE'nin test setinde tahmin edildiğini yansıtmak için kullanıldığını belirtmek için.

Ancak, metni tedavi olarak kullandığımızda, yalnızca ilgili özelliği n ilgi tedavisi olduğu metinler tasarlamak nadiren mümkün olacak tır. Daha ziyade, metinlerde genellikle mevcut olan başka tedaviler olacaktır. Kampanya reklamları yalnızca olumsuz saldırılardan dah a fazla yön içerir; aynı zamanda adaylar hakkında bilgi içerebilir, ek onomiyi vurgulayabilir, ton veya hatta metin formatında değişiklik gösterebilir. Bu nedenle, tedavi çok boyutlu olacaktır. Çok boyutlu t edaviler durumunda, tedaviyi temsil etmek için bir konu modeli kul lanmak zordur çünkü konu alanı bir simplex'tir—her π_i toplamı 1'd ir. Bu bölümün amaçları doğrultusunda, metni tedavi olarak temsil etmek için Fong ve Grimmer (2016) ile Egami ve diğerleri (2018) izl enecektir. Yani, g, metni t'yi K uzunluğunda bir vektöre haritalayan bir modelden öğrenilecektir; burada her eleman π_{ik}, birim i'nin te davi k'yi içerip içermediğinin bir göstergesidir. Toplamda, bu nede nle, 2 K olası tedavi vektörü olacaktır.

Bu ek, gözlemlenmemiş tedavileri ele almak için, Fong ve Grimmer(2021) t i'yi açıkça temsil edilmeyen ikili tedavi vektörüne eşleyen ikinci bir fonksiyon *h* tanıtmaktadır. $h(t_i) = b_i$ değerlerini $b_i \in \mathcal{B}$ ile tem sil edeceğiz. g ve *h* tedavilerin deterministik fonksiyonları olmasına r ağmen, belgelerin rastgele atanması, gözlemlenen ve gözlemlenmey en tedaviler arasında bir ortak dağılım yaratır ki bunu $p(\pi_i, b_i)$ ile g östereceğiz.

Metnin yalnızca gözlemlenen ve gözlemlenmeyen tedaviler aracılığ ıyla yanıtları etkilediğini varsayan bir *dışlama* kısıtlaması yapacağız. Özellikle, $y_i(t_i) = y_i(g(t_i), h(t_i), t_i) = y_i(g(t_i), h(t_i))$ oldu ğunu varsayacağız. Tedavilerin bu tanımını kullanarak ve yalnızca bir ikili tedavi $g(t_i) = \pi_i \in \{0, 1\}$ ile ilgilendiğimizi varsayarak, Fong ve Grimmer (2021) Ortalama Tedavi Etkisini tanımlar.

$$\mathrm{ATE} = \sum_{b \in \mathcal{B}} E[y_i(\pi_i = 1, b_i = b)] - E[y_i(\pi_i = 0, b_i = b)] \Pr(b_i = b).$$

Bu daha genel ortamda gizli tedavilerin nedensel etkisini belirle mek için, metin sonuç ayarı ile karşılaştırıldığında ek bir varsayıma ihtiyacımız var. Metin sonuç durumunda tedaviyi doğrudan manip üle edebilirken, metin tedavi durumu gizli bir tedavi ile ilgileniyoru z. Üçüncü bölümde ek olarak 24 ve 25—SUTVA, Görmezden gelme ve Pozitiflik[1]—Fong ve Grimmer (2021), ATE'nin tanı mlanmasını sağlayan iki yeterli varsayımı karakterize eder.

Doclingo https://www.doclingo.ai

Varsayım 1 (Yeterlilik) ***Diyelim ki ya:***

1) Ölçülen ve ölçülmeyen tedaviler bağımsızdır.

Resmi olarak, $p(\pi, b) = p(\pi)\,p(b)$.

2) Ölçülmemiş tedaviler, ortalama olarak sonuca bağlı değildir

$E[y_i(\pi, b)] = E[y_i(\pi, b')]$ *herhangi bir* $b, b' \in \mathcal{B}$.

Bu iki koşul, araştırmacıların gözlemsel araştırma yaparken yaygın olarak yaptığı varsayımlara benzer. İlk varsayım, ölçülen tedavilerin ölçülmeyen tedavilerden bağımsız olduğunu varsayar. Gözlemsel araştırma için bu varsayım, ilgi alanındaki nedensel etkinin ölçülmeyen karıştırıcılardan bağımsız olduğu yaygın bir varsayıma benzer. İkinci varsayım, ölçülmeyen tedavilerin sonuç üzerinde ortalama olarak hiçbir etkisi olmadığıdır. Gözlemsel araştırmadaki analoji, bir karıştırıcının sonuca ilişkili olmamasıdır. Fong ve Grimmer (2021) ile Fong ve Grimmer (2016) bir tanımlama kanıtı sunmaktadır.

Varsayım 4, metinlerin tedavi olarak kullanılması durumunda, metinlerin rastgeleleştirilmesinin tek başına nedensel etkileri belirlemek için yeterli olduğunu göstermektedir. Ayrıca, ilgi alanındaki tedavilerimizin, belgede gözlemlenmeyen tedavilerle nasıl ilişkili olduğuna dair güçlü varsayımlara ihtiyacımız var. Süregelen örneğimizde, eğer olumsuz reklamcılığın bir seçmenin katılım kararına etkisiyle ilgileniyorsak, reklamın diğer özelliklerinin - sağlanan diğer bilgiler, tartışılan konular veya kullanılan yazı tipi - ya diğer aday hakkında olumsuz bilgi ile bağımsız olduğunu ya da sonuca etkisi olmadığını varsaymalıyız. Analistler belgelerin içeriği üzerinde doğrudan kontrol sahibi olduklarında, örneğin vignette deneylerinde, bu varsayımı tatmin etmek zor olabilir.

Metinde tedavi durumu olarak neden-sonuç etkilerini tanımlamak için gerekli varsayımları belirledikten sonra, şimdi metni tedavi olarak kullanmanın iki örneğini tartışmaya geçiyoruz. İlk örnek olarak, Fong ve Grimmer (2021)'in, Başkan Trump'ın tweet'lerinin anket katılımcılarının tepkilerini etkileyen yönlerini keşfetmek için metni tedavi olarak kullanma tasarımını ele alıyoruz. İkinci örnekte ise, Fong ve Grimmer (2016)'dan, anket katılımcılarının bu adaylara yönelik değerlendirmelerini etkileyen aday biyografilerinin özelliklerini keşfeden bir uygulamayı vurguluyoruz.

Doclingo https://www.doclingo.ai

26.1 Trump’ın Tweet’lerini Kullanan Bir Deney

Bu bölümde, Fong ve Grimmer (2021)’in eski Başkan Donald Trump’ın Twitter p aylaşımlarını tedavi olarak kullanma uygulamasını tartışıyoruz. Donald Trump’ın tw eet’leri, başkanlık dönemi boyunca medyada geniş bir şekilde tartışılmakla kalmam ış, aynı zamanda büyük bir siyaset bilimi literatürü de başkanlık konuşmasının kam uoyu üzerindeki etkisini araştırmaktadır. Fong ve Grimmer (2021), sadece konuşm anın genel etkisini değil, aynı zamanda konuşmanın en büyük etkiye sahip yönlerin i keşfetmeyi amaçlamaktadır. Bunu yapmak için, Fong ve Grimmer (2021), katılımcı lardan Başkan Trump’ın Twitter mesajlarının rastgele bir setini “Harika,” “İyi,” “Tam am,” “Kötü” veya “Berbat” olarak değerlendirmelerini isteyen 2017 YouGov anketin den veriler kullanmaktadır.

Fong ve Grimmer (2021), Trump'ın tweetleri ve derecelendirmelerinin ko mbinasyonundan gizli tedavileri keşfetmek için Fong ve Grimmer (2016) tara fından geliştirilen denetimli Hindistan Büfesi Süreci'ni (SIBP) kullanmaktadır. SIBP, ilgi alanındaki sonuçlarla ilgili konuları tanımlamayı amaçlayan deneti mli bir konu modelidir - bu durumda yanıtın zamanlaması. Önemli olarak, LD A'daki gibi konu oranlarını tahmin etmek yerine, SIBP her belgede bir konun un dahil olup olmadığını gösteren ikili bir konu vektörü tanımlar.

Yazarlar daha sonra verileri üçte birini eğitim setinde ve üçte ikisini test setinde kullanarak böler. Örnek bölünmesi, yazarların sonunda m emnun kaldıkları bir tedavi ölçüsüne karar vermeden önce birçok fark lı model üzerinde arama yapmalarını sağlar. Tablo 26.1, karar verdikle ri model için tedavilerdeki en olası kelimeleri özetleyen Fong ve Grim mer (2021) tarihli tablonun bir kopyasını üretmektedir. Tedavi 1, Hillar y Clinton ve medyayı hedef alan tweetlerin yönlerini ifade etmektedir. Tedavi 2, güçlü ekonomik performansla, tedavi 3, Uygun Fiyatlı Bak ım Yasası'nın iptali ve değiştirilmesiyle, tedavi 4, İlk Hanım ve NFL ulusal marş protestoları üzerindeki tartışmayla, tedavi 5 ise borsa v e Kuzey Kore ile ilişkilerle ilgilidir.

Fong ve Grimmer (2021) daha sonra test setini kullanarak tedavilerin anket tarafınd an üretilen derecelendirmeler üzerindeki etkisini tahmin eder. Bunu yapmak için, her te davinin Cumhuriyetçiler, Demokratlar ve Bağımsızlar arasındaki olumlu görüş üzerinde ki etkisini tahmin ederler (Tablo 26.2). Sonuçlar bazı şaşırtıcı bulgular üretmektedir. Başkan Trump'ın Clinton ve haber medyasına yönelik saldırıları, üç grup arasında d a olumsuz bir şekilde değerlendirilmektedir. Buna karşılık, Trump'ın ekonomiyi öv mesi (tedavi 2 ve 4) üç grup arasında da olumlu bir şekilde değerlendirilmektedir.

Doclingo https://www.doclingo.ai

Tablo 26.1. Tedavilerle en güçlü şekilde ilişkilendirilen kelimeler. Fong ve Grimmer (2021) den Tablo 5.

Tedavi 1	Tedavi 2	Tedavi 3	Tedavi 4	Tedavi 5
sahte	kesintiler	obamacare	flotus	başbakan
haber	garip	senatörler	adına	bakan
medya	vergi	iptal etme	marş	kore
cnn	luther	sağlık hizmetleri	melanya	kuzey
seçim	hisse	değiştirmek	nfl	hisse
hikaye	pazar	cumhuriyetçi	bayrak	pazar
nbc	alabama	oy	dualar	çin
hikayeler	reform	cumhuriyetçiler	kutlamak	yürütme
hillary	kayıt	senato	hazır	dualar
clinton	yüksek	kuzey	oyuncular	sıra

Tablo 26.2. Tweet beğenilebilirliğinin gizli özellikler üzerindeki regresyonu. Fong ve Grimmer (2021) tarafından Tablo 6.

	Demokratlar		Bağımsızlar		Cumhuriyetçiler	
	1	2	3	4	5	6
Kesme	− 76.57	− 88.50	2.32	− 6.33	98.52	91.73
	(1.67)	(2.16)	(1.32)	(1.71)	(1.06)	(1.38)
Tedavi 1	− 45.22	− 33.83	− 31.75	− 27.27	− 18.91	− 15.28
	(5.18)	(5.02)	(4.03)	(3.94)	(3.27)	(3.20)
Tedavi 2	10.59	8.18	10.89	9.21	16.45	15.09
	(8.91)	(8.55)	(7.02)	(6.78)	(5.63)	(5.45)
Tedavi 3	− 35.93	− 34.42	− 25.69	− 24.73	− 10.27	− 9.41
	(4.78)	(4.58)	(3.74)	(3.61)	(3.02)	(2.92)
Tedavi 4	18.14	18.98	22.66	23.41	16.89	17.37
	(8.37)	(8.02)	(6.48)	(6.25)	(5.29)	(5.11)
Tedavi 5	34.11	33.32	18.84	18.32	7.84	7.39
	(7.4)	(7.09)	(5.82)	(5.62)	(4.68)	(4.52)
Pos. Cümle		23.74		17.23		13.5
		(2.89)		(2.29)		(1.84)
N	752		752		752	

Yazarlar, metin tedavisi için gerekli varsayımların örneklerinde geçerli olup olmadığını kapsamlı bir şekilde tartışmaktadır. SUTVA, katılımcının çalışmada sunulan tweetler dışında başka tweetlerden etkilenmesi durumunda ihlal edilebilir. Bu, katılımcıların 2017'de Başkan Trump tarafından yapılan diğer tweetlerle karşılaşmış olabileceği göz önüne alındığında olasıdır. Ancak, rastgele atama daha olası bir şekilde sağlanmıştır. YouGov çalışmayı tasarladığı için, tweetlerin katılımcılara atanması üzerinde kontrol sahibi olmuştur.

SUTVA ve rastgeleleştirme dışında, Fong ve Grimmer (2021) de

Doclingo https://www.doclingo.ai

ölçülmemiş tedavilerle ilgili iki varsayıma ihtiyacım var Varsayım 4 tutmak. Bu varsayım, keşfedilen tedavilere bağlı olan ve sonucu etkileyen ölçülmemiş herhangi bir yönün olmadığını öngörmektedir. Fong ve Grimmer (2021), bu varsayımın deneylerinde ihlal edilebileceği olasılığını araştırıyor - belki de tedavi 1 ve 3, diğer tedavilere göre daha olumsuz bir duyguya sahiptir. Eğer katılımcılar esasen olumsuz duyguya tepki veriyorlarsa ve duygu tedavilerle ilişkiliyse, bu varsayımın ihlali olur. Bir duygu sözlüğü kullanarak, Fong ve Grimmer (2021) gerçekten de duygunun tedavilerle ilişkili olduğunu buluyor. Ancak, duygu ölçümünü bir karıştırıcı olarak dahil etmek, Tablo 26.2 sonuçları değiştirmiyor.

Doclingo https://www.doclingo.ai

26.2 Bir Aday Biyografisi Deneyi

Başka bir örnekte, Fong ve Grimmer (2016) bir metni tedavi çerçevesi olarak k ullanarak adayların biyografilerinin seçmen değerlendirmelerini etkileyen özellik lerini incelemektedir. Siyasi bilimde geniş bir literatür, seçmenlerin ofis için aday olan kişilerin özelliklerini nasıl değerlendirdiğini sormaktadır (Canon, 1990; Popkin, 1994; Bartels, 2002; Carnes, 2012; Campbell ve Cowley, 2014). Örn eğin, son çalışmalar, seçilmiş ofislerde avukatların aşırı temsilini incelemek tedir (Bonica ve Sen, 2017). Adayların nasıl
kişisel tarihlerin seçim desteğini nasıl etkilediğini anket deneyleri ile inc eliyoruz. Bu deneylerde, araştırmacılar metnin bazı özelliklerini değiştir erek, bireylerin belirli bir bilgi parçasına nasıl tepki verdiğini belirlemeyi umuyorlar. Örneğin, bir bireyin mesleğini değiştiren bir biyografi oluşt urabiliriz. Ya da, adayın geçmişinin birkaç özelliğini değiştiren bir birleşi k çalışma yapabiliriz.[2]

Tablo 26.3. sIBP'nin keşfettiği 10 tedavi için en iyi kelimeler. Fong ve Grimmer (201 6) kaynaklı.

Tedavi 1	Tedavi 2	Tedavi 3	Tedavi 4	Tedavi 5
atanmış	kardeşlik	yönetmen	alındı	seçildi
mezun_oldu	seçkin	üniversite	washington_üniversitesi	ev
vali	savaş_ii	alındı	yıllar	demokratik
çalıştı	bölüm	başkan	ölüm	koltuk
yaşlı	hava kuvvetleri	sanat yüksek lisansı	şirket	cumhuriyetçi
hukuk bürosu	fi	doktora	eğitim	hizmet etti
seçildi	yedek	politika	askeri	komite
büyükbaba	delta	kamusal	dahil	atanmış
ofis	hava	usta	george_washington	yenildi
hukuki	eyaletler_hava	işler	lisans_diploması_kazandı	ofis
Tedavi 6	**Tedavi 7**	**Tedavi 8**	**Tedavi 9**	**Tedavi 10**
birleşik_devletler	cumhuriyetçi	yıldız	hukuk	savaş
askeri	demokratik	bronz	okul_hukuku	askere alınmış
mücadele	seçildi	almanya	hukuk_okulu	birleşik_devletler
rütbe	atanmış	sanat yüksek lisansı	hukuk doktoru	atanmış
deniz kuvvetleri	üye	verilmiş	öğrenci	ordu
madalya	görevdeki	oynadı	kazanılmış_yetki	hava
seçkin	siyasi	yale	hukuk	eyalet ordusu
hava kuvvetleri	baba	futbol	hukuk bürosu	yıl
eyaletler_hava	hizmet etti	anne	üniversite okulu	hizmet
hava	eyalet	bölüm	başkan	görevli

Fong ve Grimmer (2016), aday biyografilerinin etkisini değerlendirmek için farklı bir yaklaşım benimsemektedir.

Doclingo https://www.doclingo.ai

Aday biyografilerinin, seçmenlerin çekici bulduğu adayların geçmiş özelliklerini keşfetmek için bir koleksiyonunu kullanıyorlar. Seçmenl erin duyarlı olduğu aday biyografi özelliklerini ortaya çıkarmak için, Wikipedia'dan 1,246 Kongre adayı biyografisi topluyorlar. Fong ve G rimmer (2016) daha sonra biyografileri anonim hale getiriyorlar—isi mleri değiştirerek ve diğer tanımlayıcı bilgileri kaldırarak—katılımcıy a sunulan tek bilginin metinde açıkça mevcut olmasını sağlamak için .

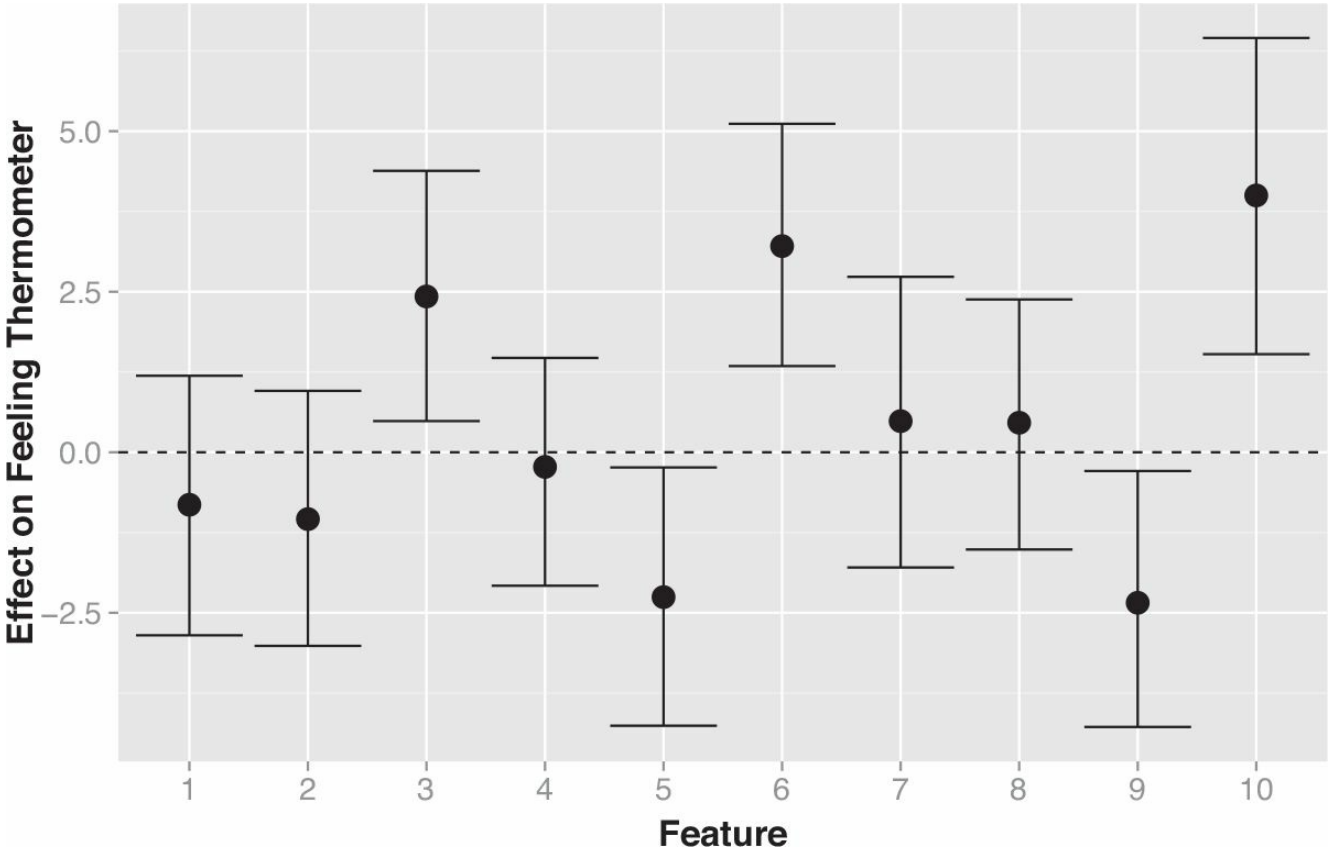
Bu deneyin gizli tedavileri ortaya çıkarması için bir koşul, her tedavi vekt örünün sıfırdan farklı bir olasılığa sahip olmasıdır. Bu, tedavilerin hiçbirinin *taklit edilmediğini* veya mükemmel bir şekilde korelasyonlu olduğunu var saymakla eşdeğerdir (Hainmueller, Hopkins ve Yamamoto, 2014). Taklit et me, deneyimize katılımcılara sunulan yalnızca birkaç farklı metin varsa dah a olasıdır. Bu nedenle, Fong ve Grimmer (2016) her değerlendirme turund aki her katılımcıya farklı bir aday biyografisi atar. İstatistiksel gücü artırmak için, katılımcılardan dört farklı aday biyografisini değerlendirmeleri istenir ve bu da her katılımcının değerlendirmesine yol açar. 2.8 biyografiler ortalama.[3] Katılımcılara bir adayın biyografisini sunduktan sonra, her katılı mcıdan adayı bir *duygu termometresi* kullanarak değerlendirmeleri istenir: katılımcının adaya “soğuk” olduğu durumda 0'dan, adaya “sıcak” olduğu d urumda 100'e kadar giden iyi bilinen bir sosyal bilimler ölçeği.

Fong ve Grimmer (2016), çevrimiçi bir anket platformu olan Survey Sampling Int ernational (SSI) kullanarak 1,886 katılımcıdan oluşan bir örnek topladı. Örnek, cinsi yet, yaş, ırk ve eğitim açısından ABD demografisini yansıtacak şekilde nüfus sayımı ile eşleştirilmiştir. Örnek kullanılarak toplam 5,303 gözlem bulunmaktadır. Onlar 2,651 yanıtı eğitim setine ve 2,652 yanıtı test setine atarlar. Daha sonra sIBP sü recini eğitim verilerine uygularlar. Modeli uygulamak için, duygu termometresi ni ortalaması sıfır ve standart sapması 1 olacak şekilde standartlaştırırlar. K\ de ğerini, *K* üzerinde nicel ve nitel bir arama yansıtan nispeten düşük bir değere (K = 10) ayarlarlar. Son modeli seçerken parametreleri değiştirir ve CE puanını d eğerlendirirler.

Tablo 26.3, sIBP'nin eğitim setinde keşfettiği on tedavi için en iyi kelimeler i sağlamaktadır. Fong ve Grimmer (2016), sIBP'den gelen rehberlik, CE puanl arı kullanarak yapılan değerlendirme ve modellerin kendi niteliksel değerlen dirmesinin bir kombinasyonunu kullanarak on tedavi seçtiler (Grimmer ve St ewart, 2013). Tedaviler, Kongre'nin belirgin özelliklerini kapsamaktadır. analiz ettiğimiz dönemden biyografiler. Örneğin, tedavi 6 ve 10 bir adayın askeri deneyimini yakalar. Tedavi 5 ve 7 önceki siyasi deneyimle ilgilidir ve tedaviler 3 ve 9 birine atıfta bulunmak

Doclingo https://www.doclingo.ai

adayın eğitim deneyimi. Açıkça, burada bir adayın geçmişine dair bir çok özellik eksik, ancak keşfedilen tedaviler, seçmenlerin bir adayın geçmişine nasıl yanıt verdiğini değerlendirmek için yararlı bir boyut seti sağlar.



Şekil 26.1. Keşfedilen etkiler için %95 güven aralıkları tedaviler. Hissetme termometresinin ortalama değeri 62.3. Fong ve Grimmer (2016) tarafından hazırlanan Şekil 2.

Modeli eğitim seti üzerinde eğittikten sonra, Fong ve Grimmer (2016)biografilerdeki tedavileri çıkarmak için test setine uygularlar. Tedaviler arasındaetkileşim olmadığını varsayarak etkilerini tahmin ederler.[4] Şekil 26.1 , metinlerden tedavileri çıkarmada belirsizliği v e bu tedaviler iletepki arasındaki ilişkiyi dikkate alan nokta tahmini ni ve %95 güven aralıklarını göstermektedir.

Tedavi etkileri, katılımcı değerlendirmelerini etkileyen aday biyografil erinin sezgisel, ancak ilginç özelliklerini ortaya koymaktadır. Örneğin, Şekil 26.1, siyasi ve hukuki deneyime karşı bir hoşnutsuzluğu ortaya koymaktadır - büyük bir kısmı Kongre adaylarının önceki siyasi deneyime ve bir hukuk diplomasın a sahip olmasına rağmen. Adayın önceki siyasi deneyimini tanımlayan Tedavi 5, his termometresi değerlendirmesinde 2.26 puanlık bir azalmaya neden olmaktadır

Doclingo https://www.doclingo.ai

(%95 güven aralığı, [−4.26, −0.24]). Benzer şekilde, tedavi 9, katılımcıların av ukatları sevmediğini göstermektedir; hukuki deneyimin varlığı, his termom etresinde 2.34 puanlık bir azalmaya neden olmaktadır (%95 güven aralığı, [−4.28, −0.29]). Ancak avukatlara karşı bir hoşnutsuzluk, eğitime karşı bir ho şnutsuzluk değildir. Tedavi 3, ileri düzeydeki diplomaları tanımlayan bir tedavi, his termometresi değerlendirmelerinde 2.43 puanlık bir ar tışa neden olmaktadır (%95 güven aralığı, [0.49, 4.38]).

Buna karşılık, Şekil 26.1, askeri deneyim için tutarlı bir bonus olduğunu göstermektedir. Bu, siyasi gözlemcilerin kamuoyunun gazileri desteklediği yönündeki sezgileriyle tutarlıdır. Örneğin, tedavi 6, bu bir adayın askeri kaydını tanımlar, bir 3.21 puanlık bir artışa neden olur termometre derecelendirmesi (yüzde 95 güven aralığı, [1.34, 5.12]) ve tedavi 10, 4.00 puanlık bir artışa neden olur (yüzde 95 güven aralığı, [1. 5 3 , 6 . 4 5]).

Bu deney, metinlerin çeşitlendirilmesinin sonuçlar üzerindeki etkisi hakkında sezgisel, ancak yine de faydalı içgörüler sağlayabileceğini ortaya koymaktadır. Bir sonraki bölümü müzde,metnin sayısal bir tedavi ile sonuç arasındaki karışıklığı ortadan kaldırmak için nası l kullanılabileceğini ele alıyoruz.

Doclingo https://www.doclingo.ai

26.3 Sonuç

Bu bölümde, metni tedavi olarak ele aldık. Sonuç olarak metin durumunun aksine, tedavi olarak metin durumundaki amaç, gizli tedavileri tanımlamak ve bunların bir sonuç üzerindeki etkilerini tahmin etmektir. Daha sonra, Trump t weet'lerinin partizan değerlendirmeleri nasıl etkilediğini ve aday biyografilerini n aday değerlendirmelerini nasıl etkilediğini anlamak için iki örneği ayrıntılı ola rak açıkladık. Şu ana kadar, metni sonuç ve metni tedavi olarak ele aldık. Bir so nraki bölümde, nedensel çıkarımda metnin üçüncü bir kullanımına geçiyoruz: karışıklığı ölçmek ve koşullamak için metin kullanmak.

---

[1]Bu durumda pozitiflik, tüm tedavilerin mümkün olduğu anlamına gelir: $f(\pi_i) > 0$ için tüm $\pi_i \in \text{Range } g(\cdot)$ (Egami et al., 2018)

[2]Bu bölümün bir kısmı Fong ve Grimmer (2016) çalışmalarından alınmıştır.

[3]Aday biyografilerinin çoklu değerlendirilmesi, deneyimizin turlarında taşma ol duğunda sorunludur. Bir aday biyografisini gözlemlemenin, sonraki turlardaki ya nıtı sistematik olarak etkileyeceğine dair pek bir nedenimiz yok.

[4]Burada önerdiğimiz çerçeve için bu varsayım gerekli değildir. Etkileşim etki leri modellenebilir, ancak bu, Imai ve Ratkovic (2013) gibi heterojen tedaviler i çin çok daha güçlü parametrik varsayımlar yapmamızı gerektirir.

Doclingo https://www.doclingo.ai

BÖLÜM 27

Metin Karıştırıcı Olarak

Metin, deneylerde bir sonuç veya müdahale olarak kullanılabileceği gibi, gözlemsel a nalizlerde değişkenleri kontrol etmek için de kullanılabilir. Burada, metnin nedensel analizlerde nasıl bir karıştırıcı olabileceğini ve bu tür karıştırmaları kontrol etmek için metin analizini nasıl kullanabileceğimizi açıklamak için Roberts, Stewart ve Nielsen (2 020) çalışmalarına atıfta bulunuyoruz.[1]

Metin, sosyal bilim uygulamalarında sıkça karıştırıcı bir değişken olarak orta ya çıkar. Bir örnek vermek gerekirse, Maliniak, Powers ve Walter (2013), Ulusla rarası İlişkilerde kadınlar tarafından yazılan makalelerin, yazarın algılanan cinsi yeti nedeniyle erkekler tarafından yazılan makalelere göre daha az alıntılandığı na dair kanıt sunmaktadır. Yazarlar, akademik yeterlilikler, okulun kadrosu ve r ütbesi gibi faktörleri ve yayın yeri, konu, perspektif ve makale yaşı gibi makale düzeyindeki değişkenleri hesaba kattıklarında bile bu ilişkiyi bulmaktadırlar.

Bir kadın yazarın makalesinin, bir erkek yazarın makalesine göre daha az alıntı yapılma olasılığı var mı? Bu durumda, yazarın cinsiyeti tedavi ve s onuç ise alıntı sayılarıdır. Ancak, cinsiyet rastgele atanmadığı için, erkekle r ve kadınlar arasındaki alıntıların ortalama farkını cinsiyetin alıntılar üzer indeki nedensel etkisinin tahmini olarak almayız. En önemlisi, kadınlar Ul uslararası İlişkilerde erkeklerden farklı konular hakkında yazıyorlar. Maka lenin metinsel içeriği hem tedavi (algılanan cinsiyet) hem de sonuç (alıntıl ar) ile ilişkili olabilir; bu nedenle makalenin metni cinsiyet ile alıntılar arası ndaki ilişkiyi karıştırmaktadır. Sonuç olarak, Maliniak, Powers ve Walter (2 013) bu durumu, makale içeriğini kontrol değişkenleri olarak tanımlayan elle kodlanmış kategoriler kullanarak açıklamak için çalışmanın büyük bir kısmını harcıyorlar.

Metin bir karıştırıcı olarak sosyal verilerin analizinde şaşırtıcı bir şekild e sıkça görünmektedir. Yasama tasarılarının içeriği, veto tehditleri ile Kon gre'deki yeniden konumlanma arasındaki ilişkiyi karıştırabilir. Öğrencileri n üniversite kabul profilleri veya tavsiye mektupları, hem ırkları veya cinsi yetleri hem de üniversiteye kabul edilme olasılıkları ile ilişkili olabilir. Ulus lararası anlaşmaların içeriği, ticaret ile uluslararası işbirliği arasındaki iliş kiyi karıştırabilir.

Sayısal değişkenleri kontrol etmek oldukça basittir—

Doclingo https://www.doclingo.ai

araştırmacılar, temel doğrusal regresyon veya eşleştirme kullanarak karıştırıcı üz erinde koşul oluşturabilirler. Ancak, bir metnin içeriğini kontrol etmek çok daha z ordur. Araştırmacılar, makaledeki her benzersiz kelimeyi eşleştirmeye veya regre syona dahil edemezler çünkü muhtemelen gözlem sayısından çok daha fazla keli me vardır. Ayrıca, araştırmacılar metnin tamamını tamamen kontrol etmek istem ezler; ideal olarak, tedavi ile sonuç arasında karışıklık yaratan kelimeleri veya keli me kümelerini ayarlamak isterler.

Metin gibi yüksek boyutlu bir kovaryantı kullanarak karıştırıcıları ayarla mak, "boyutlanma laneti" sorununu ortaya çıkarır. Metin üzerinde koşullan dırmanın zorluğu, metnin hangi yönlerinin dahil edilmesi gerektiğini ve me tnin hangi unsurlarının koşullandırılmaması gerektiğini belirlemektir. Sıklıkla, araştırmacılar metnin hangi yönlerinin hem tedavi hem de son uçla ilişkili olduğunu hemen bilemezler. Kadınların ve erkeklerin Uluslar arası İlişkilerde konuları nasıl farklı şekilde tartıştıklarını ve bu farklılıkla rın hangi yönlerinin atıf sayılarıyla ilişkili olabileceğini bilmeyebilirler. Bu nedenle, bu durumlarda araştırmacılar metnin ilişkiyi karmaşıklaştır an yönlerini tahmin etmelidir.

Matematiksel olarak, karmaşıklaştırma probleminin yapısı aşağıdaki gibidir. 2 4. Bölümde olduğu gibi, N birimi içeren bir veri seti ile başlıyoruz. Her bir birim i, tedavi t i ile atanır; bu, tedavi edilen birimler için 1 ve kontrol için 0 değerini alır. Potansiyel sonuçlar çerçevesinde, sonuç değişkeni y i, birim i tedavi edildiği nde y i (1) değerini alır ve birim i kontrol olduğunda y i (0) değerini alır.

Verilerimizin gözlemsel olduğu durumları dikkate aldığımız için, t i rast gele atanmaz ve tedavi edilen ve kontrol grupları karşılaştırılabilir olmaya bilir. Yaygın bir uygulama, tedavi ve kontrol grupları içindeki kovaryatları n dağılımındaki benzerliği artırmak için N gözlemimizdeki P ön tedavi kov aryatları üzerinde eşleştirme yapmaktır; bu duruma denge denir.

X tüm karmaşıklaştırma kaynaklarını içerdiğinde, dengeyi sağlamak için eşleştirme kullan abiliriz (X i $\perp\!\!\!\perp$ t i), bu da tedavi edilenler üzerindeki ortalama tedavi etkisinin tarafsız bir şe kilde tahmin edilmesini sağlar.

Çoğu eşleştirme uygulamasında, X düşük boyutludur, P $\ll$ N'dir. Gözlemleneb ilirler üzerinde bir seçim stratejisi alarak, koşullu göz ardı edilebilirlik varsayımını kabul ediyoruz: t i $\perp\!\!\!\perp$ y i (0), y i (1) | X i. Bu varsayım altında, gözlemlenen kovary atların X dağılımını tedavi grupları arasında dengelemek, ilgi alanındaki nedensel etkiyi tahmin etmenin bir yolunu sağlar. Bazı ortamlarda, gözlemlenebilirler üze rinde seçim yapılacak P değişkenleri, tedavi atama mekanizması şeffaf olduğu içi n araştırmacı tarafından bilinmektedir.

Ancak, yalnızca üzerinde koşullandırmak istediğimiz durumlarda dikkate aldığımız durumlarda *X*, ancak aynı zamanda belge terim matrisinde *W*, bu ikisinin boyutları

Doclingo https://www.doclingo.ai

matrisler birleştirildiğinde, P + J, çok büyüktür. Bu durumda, *J*, korpusun keli me dağarcığı, *N*, gözlem sayısından çok daha büyük olabilir. Ayrıca, *W* 'nin h angi yönlerinin tedavi ve sonuçla ilişkili olduğunu kesin olarak bilmiyoruz. M etindeki bazı kelimelerin tedaviyi etkilediğine inanıyoruz, ancak hangilerinin olduğunu bilmiyoruz. Tüm kelimelerle eşleştirmeye çalışırsak, iki metin *aynı* kelime frekanslarına sahip olmadıkça herhangi bir eşleşme tanımlayamayız; bu olasılık, *W* 'nin boyutu büyüdükçe giderek küçülmektedir.

Bizim yaklaşımımız, değişkenlerin düşük boyutlu bir özetini tahmin etmektir *Karıştırıcıları ele almak için kullanabileceğimiz bir g fonksiyonu, tedavi ye rine ve sonuç olarak daha önce olduğu gibi. Metin eşleştirme bu nedenle aşağıdakileri gerektirir:*

Varsayım 1 (SUTVA) *Tüm bireyler i*, y i (t) = y i (t i) .

Varsayım 2 (Koşullu Görünmezlik) t i ⊥⊥ (y i (0) , y i (1)) | g (W i ,).

Varsayım 3 (Pozitiflik) *Tüm bireyler i için* P r (t i = t) > 0 *her* t ∈ ◦

.[2]

Bu bölümde, metin verileri kullanarak karıştırıcıları ayarlamak için doğru gulma nın birkaç farklı yöntemini inceliyoruz—hem regresyon tabanlı hem de eşleştirme t abanlı ayarlamalar. Sadece birkaç basit yaklaşım üzerinde duruyor olsak da, bunun hızla gelişen bir alan olduğunu belirtmekte fayda var. Roberts, Stewart ve Nielsen (2020) metin eşleştirme üzerine makalelerini ilk olarak yayınladıklarında 2015, metin karıştırmalarını ayarlamada yeni gelişmeler hızla takip etti. Mozer ve ark. (2020), metinleri eşleştirmek için kullanılan temsil ve mesafe ölçütünü de ğiştirerek yüzlerce farklı metin eşleştirme yöntemini değerlendirmektedir. Veitch, Wang ve Blei (2019) ise karıştırmayı ayarlamak için kelime gömme yöntemini kullanan bir yön tem geliştirmiştir. Bir inceleme için Keith, Jensen ve O'Connor (2020) bakınız.

Bölüm boyunca, Uluslararası İlişkiler (IR) disiplininde cinsiyet temelli atıf önya rgısını inceleyen Maliniak, Powers ve Walter (2013) örneğini kullanıyoruz. IR'de k adın akademisyenlere karşı atıf önyargısının en güçlü kanıtı, kadınların erkeklerl e aynı makaleleri yazdığı ancak daha az atıf aldığı durumlarda ortaya çıkacaktır. Ancak, erkekler ve kadınlar IR içinde farklı konular hakkında yazma, farklı yönte mler kullanma ve farklı epistemolojik taahhütlere sahip olma eğilimindedir. Bu faktörlerin atıf sayılarını etkileyebileceği göz önüne alındığında, kadınları n daha düşük atıf sayılarının belirli konulara ve yaklaşımlara karşı bir önyargı yı yansıttığı, kadınlara karşı değil, olabileceği mümkündür. Maliniak, Powers ve Walter (2013) bu zorluğu, her makalenin geniş alt alanını, ele alınan konu alanlarını, genel metodolojiyi, paradigma ve epistemolojiyi kontrol etmek içi n TRIP Dergi Makale Veritabanı'ndan bilgi kullanarak ele almaktadır. Bu

Doclingo https://www.doclingo.ai

uygulama, bu karmaşayı ele almak için el ile kodlama yerine otomatik yöntemler kullanmaya çalışıyoruz.[5]

JSTOR'un Veri Araştırma Programı'nın yardımıyla, Roberts, Stewart ve Nielsen (2020) 1980'den bu yana IR literatüründe yer alan 3,201 makalenin tam metnini elde etmiştir; bunlardan 333'ü yalnızca kadınlar tarafından yazılmıştır. Aşağıda, R oberts, Stewart ve Nielsen (2020) tarafından toplanan verileri kullanarak, makale lerin metni üzerinde koşullandırma için farklı yöntemleri keşfedeceğiz ve cinsiyet in alıntılar üzerindeki etkisini inceleyeceğiz. Bu yöntemlerin her birinin dezavanta jlarını ve avantajlarını aşağıda tartışacağız.

Doclingo https://www.doclingo.ai

27.1 Metin Karıştırıcıları için Regresyon Ayarlamaları

Toplumsal bilim verilerinde karıştırıcıları ayarlamanın en yaygın yolu, karıştırıcı değişkeni bir regresyona dahil etmektir. Bu nedenle, metin gi bi yüksek boyutlu bir değişkenle karıştırıcıları ayarlamanın en basit uza ntısı, bunu bir regresyona dahil etmek, ancak uygulama için en iyi regre syon alt kümesini seçmek üzere bir küçültme yöntemi kullanmaktır. Böl ümde tartışıldığı gibi 19, Ridge gibi ceza uygulanmış regresyon tahmincileri regresyon ve Lasso, sonuca yüksek derecede öngörüde bulunan kovaryatları seç ebilir, daha az önemli olan kovaryatları küçülterek veya ortadan kaldırarak. Eğer bu tahmin ediciler, karıştırıcılarla ayarlamak için ilgili kelimeleri seçerse, o zaman metin karıştırıcıları için ayarlamakta kullanabiliriz.

Bu ilk çok basit yaklaşımı, cinsiyetin etkisini tahmin etmek için makalelerin me tni üzerinde koşullandırma yapmak amacıyla alıyoruz. Her makalenin alıntılarını, makalelerin terim-belge matrisine ve Maliniak, Powers ve Walter (2013) tarafında n analizlerinde dahil edilen diğer tüm değişkenlere, makale yaşı, görev süresi ve dergi gibi, regresyon yaparak bir Lasso tahmini yapıyoruz. Ayrıca, makalenin yal nızca kadın yazarlar tarafından yazılıp yazılmadığını gösteren bir tedavi gösterge si değişkeni de ekliyoruz. Tedavi katsayısı üzerinde bir ceza eklemiyoruz, çünkü b u ilgi katsayısıdır. Kalan katsayılar için optimal cezayı seçmek üzere çapraz doğru lama kullanıyoruz. Ardından, alıntıları tahmin eden bir doğrusal regresyonda Las so modeli tarafından seçilen kelimeleri dahil ediyoruz.

Umudumuz, Lasso modelinin sonucu yüksek derecede tahmin eden önemli kelim eleri ve değişkenleri seçmesi ve bu nedenle ilgi çekmeyen birçok kelimeyi elememize olanak tanımasıdır. Şekil 27.1, modelde nihayetinde yer alan ve dolayısıyla alıntıları y üksek derecede tahmin eden kelimeleri göstermektedir; bunlar arasında Minerva gib i finansmanla ilgili kelimeler, neden-sonuç ve zskor gibi metodolojiyle ilgili kelimeler ve surgenc ve democ gibi maddeyle ilgili kelimeler bulunmaktadır. Belirli yazarların al ıntıları da, örneğin weingast ve shepsl gibi, alıntıları tahmin etmede önemli görünme ktedir. Model ayrıca Maliniak, Powers ve Walter (2013) tarafından kodlanan belirli de ğişkenlerin önemli olduğunu önermektedir; bunlar arasında makalenin Amerikan der gisinde yayımlanıp yayımlanmadığı gibi değişkenler bulunmaktadır.
Politik Bilimler Dergisi—birincil politik bilimler mekanı—veya makalenin pozitivist b ir çerçeveye sahip olup olmadığı, her ikisi de daha yüksek alıntılar öngörmektedir. Kadın yazarlık üzerine tahmin edilen katsayı negatiftir, bu da Lasso tarafından seçil en kelimeler ve diğer karıştırıcılar için ayarlama yapıldığında, kadın yazarlığın alıntıl arla negatif bir ilişkiye sahip olduğunu göstermektedir.

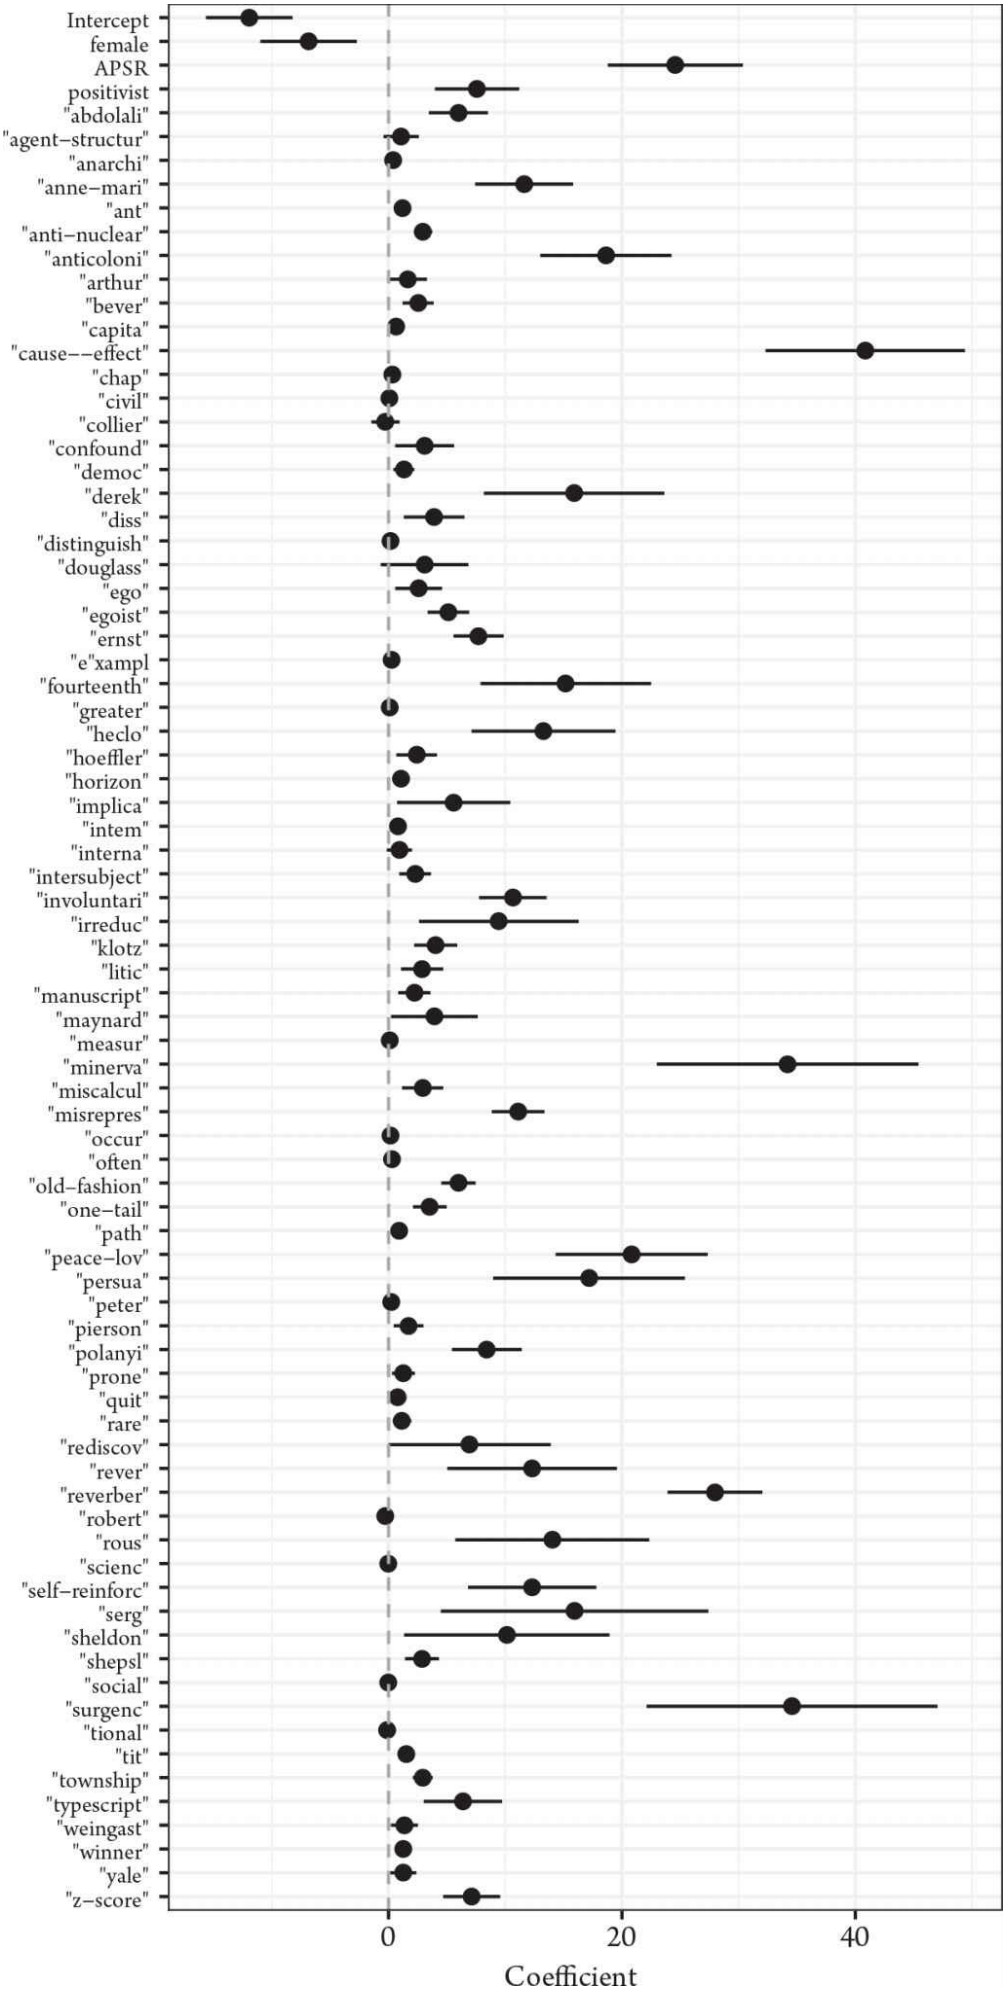
Lasso kullanmak, bir metin regresyonunda bir kelime seti seçmenin nispe ten basit bir yoludur, ancak bunun bazı önemli dezavantajları vardır ki bunlar

Doclingo https://www.doclingo.ai

yüksek boyutlu karıştırıcılarla nedensel çıkarım yapmanın karmaşıklıkları nı göstermektedir. İlk dezavantaj, karıştırıcılar için ayarlama yapma yeten eğimizin, seçtiğimiz metin temsili (kelime sayısı) ve lineer modelin kombi nasyonu ile sınırlı olmasıdır. Örneğin, bu, kelimeler arasındaki etkileşimle ri dışlar, ancak minerva'nın demokrasi gibi kelimelerle kullanıldığında çok sayıda alıntı üretebileceği, ancak otokrasi ile kullanıldığında çok az alıntı üretebileceği anlamına gelebilir. İkinci dezavantaj, potansiyel olarak karış tırıcı değişkenlerin yüksek boyutluluğunu ele almak için Lasso düzenlen miş regresyonunun kullanılmasından kaynaklanmaktadır. Belloni, Chern ozhukov ve Hansen (2014) açıklamaktadır ki, Lasso iyi tahmin ediciler ola n değişkenleri seçerken, en iyi karıştırıcıları seçmeyebilir.[7] Bu, diğer ama çlar için tasarlanmış araçları ithal ederken, bunları ilgi alanındaki göreve uyarlamak için dikkat edilmesi gereken genel noktamızın bir başka örneğ idir.Belloni, Chernozhukov ve Hansen (2014), bir sonucu tahmin eden ve bir tedaviyi tahmin eden iki farklı Lasso regresyonunu içeren alternatif bi r strateji önermektedir ve ardından seçilen değişkenlerin b irleşimini kullanarak son bir regresyon ayarlaması yapılmaktadır.

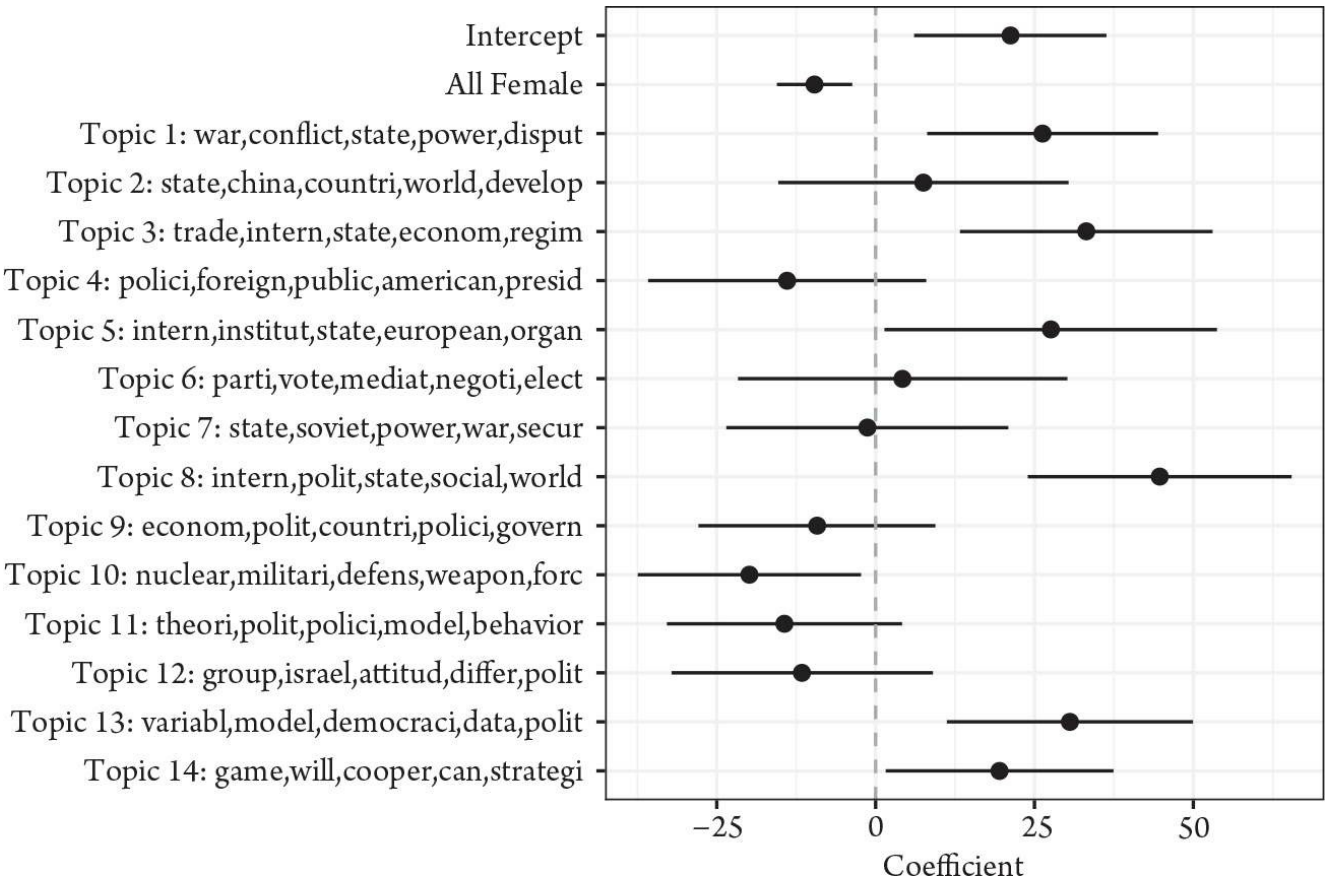
Alternatif bir yaklaşım, metnin daha düşük boyutlu bir temsilinde çalış maktırve bu durumda böyle bir düzenleme o kadar gerekli değildir. Örne ğin, her belgeyikonuların bir kombinasyonu olarak temsil etmek için bir k onu modeli kullanabiliriz.Daha sonra, konusal içeriği kontrol ederek, cinsi yetin alıntılar üzerindeki etkisinitahmin edebiliriz. Eğer konular, karıştırıcı yı yakalamak için yeterliyse, bu stratejiboyutların genellikle kelime dağar cığından çok daha düşük olduğu için çok dahaverimli olacaktır. Bu stratej ideki olası verimlilik kazançları, varsayımlar geçerliolduğunda Naive Baye s'in (Bölüm 19) faydalarına benzer.

Doclingo https://www.doclingo.ai



Doclingo https://www.doclingo.ai

Şekil 27.1. Cinsiyete göre alıntıların regresyonu, kelimeler ve Lasso modeli tarafından seçilen kovaryantlar.



Şekil 27.2. Konu oranlarını kontrol ederek cinsiyete göre alıntıların regresyonu.

Şekil 27.2 , her belgedeki tahmin edilen konu oranlarına bağlı olarak cinsiyete regrese edilmiş alıntıların regresyon çıktısını göstermektedir. Konulardan birçoğu siyasi bilimciler tarafından tanınabilir olmalıdır—yazarlar savaş, ekonomik gelişim yabancı politika gibi konuları tartışmaktadır. Konu 13, niceliksel modellerle ilişkili olarak, Sovyetler Birliği ve askeri ile ilişkil i konu 7'den genel olarak daha yüksek atıf sayısına sahiptir.Kadın katsa yısı, konu kontrol edildiğinde, kadınların hala erkeklerden daha az atıf a ldığını gösteren Lasso'daki ile benzerdir.

Verilerin daha düşük boyutlu temsillerini kontrol etmek için birç ok yaklaşım vardır ve analistler, tedavi ile sonuç arasındaki ilişkiyi k arıştıran en önemli olduğunu düşündükleri yaklaşımı seçmek istey eceklerdir. Örneğin, temel bileşenler analizi (PCA) veya tekil değer ayrıştırması (SVD), belgelerdeki varyansı açıklayan kelime kümeleri ni kontrol etmek için konuların yerini alabilir.

Ancak, PCA, SVD ve hatta temel konu modelleme yaklaşımlarının, metnin aza ltılmasını oluştururken sonuç veya tedaviden yararlanmadığını unutmayın.

Doclingo https://www.doclingo.ai

Örneğin, Şekil 27.2'deki konulardaki en olası kelimeler, bu kelimenin atıfları yüksek bir şekilde tahmin etmesine rağmen minerva kelimesini içermemektedir. Ko-variyatları seçerken sonuç veya tedavi hakkında bilgi dahil etmek, modelin karıştırıcıları yakaladığından emin olmak için faydalı olabilir.

Doclingo https://www.doclingo.ai

27.2 Metin için Eşleştirme Ayarlamaları

Bir regresyon ayarlaması kullanmanın bir alternatifi, benzer konular hakkında yaz an veya benzer kelimeler kullanan tedavi ve kontrol birimleri arasında eşleşmeler bul mak için metin analizini kullanmaktır. Roberts, Stewart ve Nielsen (2020), eşleştirmen in avantajının, karşılaştırılabilir birimlerin daha kolay incelenebilmesi olduğunu savun uyor—eşleştirme, kullanıcıların eşleştirme yönteminin benzer olarak değerlendirece ği belgeleri bulmasına, okumalarına ve bu gözlemlerin birbirleri için iyi bir karşıfaktör olup olmadığını değerlendirmelerine olanak tanır. Metin modelleri başarısız olabilir, bu nedenle bu kitap boyunca vurguladığımız gibi, bu yaklaşım analiste eşleşen biriml erin tedavi atamasının muhtemelen "rastgele gibi" olup olmadığını değerlendirme im kanı tanır. Bu manuel doğrulama, genellikle eşleştirmede kullanılan diğer resmi den ge kontrollerini tamamlar.

Tablo 27.1. Eşleştirilmiş belge çiftlerine örnek. Sol sütun, tüm kadın yazar ekipl erinden örnekler içermektedir. Roberts, Stewart ve Nielsen (2020) Ek Materyaller i'nden Tablo 4.

Tedavi Edilen Belge	Eşleştirilmiş Kontrol Belgesi
"Demokratik Sinerji ve Savaşta Zafer, 1816-1992." Ajin Choi. 2004. *Uluslararası Çalışmalar Dergisi*. Özet: "Bu çalışma, demokrasilerin neden savaşları kazanma olasılığının daha yüksek olduğunu araştırmaktadır. Ben, yönetimlerin şeffaflığı ve tercihlerin bir kez belirlendiğinde istikrarı nedeniyle, demokrasilerin savaşların yürütülmesinde ortaklarıyla işbirliği yapma konusunda daha iyi bir yeteneğe sahip olduğunu ve bu nedenle savaşları kazanma olasılıklarının daha yüksek olduğunu savunuyorum. Argümanımı desteklemek için, bu çalışmadaki ana bulgular, diğer şeyler eşit olduğunda, bir devletin sahip olduğu demokratik ortakların sayısı ne kadar büyükse, kazanma olasılığının o kadar yüksek olduğunu göstermektedir; ayrıca, demokratik devletlerin savaşlar sırasında demokratik ortaklara sahip olma olasılığı daha yüksektir. Bu sonuçlar, demokrasilerin savaşlarda galip gelme olasılığının yüksek olduğu mevcut literatürdeki bulgularla çelişmektedir; bu literatür, bir yandan demokratik devletlerin askeri yeteneklerini güçlendirme konusundaki üstün kapasitelerini, diğer yandan ise kazanma şanslarının yüksek olduğu savaşları seçme konusundaki yeteneklerini vurgulamaktadır."	"Üçüncü Taraf Müdahaleleri ve İç Savaşların Süresi." Patrick M. Regan. 2002. *Çatışma Çözümü Dergisi*. Özet: "Son araştırmalar, dış müdahalelerin iç savaşların süresindeki rolüne odaklanmaya başlamıştır. Müdahalelerin bir çatışma yönetimi biçimi olduğu varsayıldığında, ex ante beklentiler, bunların bir çatışmanınbeklenen süresini azaltacağı yönündedir. Dış müdahalelerin türü ve zamanlaması ile sivil çatışmaların süresi arasındaki ilişkileri test eden hipotezler bulunmaktadır. Veriler, 1945'ten itibaren 150 çatışmayı içermektedir. 1999, 101'inin dış müdahaleleri vardı. Bir tehlike analizi kullanarak, sonuçlar üçüncü taraf müdahalelerinin beklenen sürelerini kısaltmak yerine uzatma eğiliminde olduğunu önermektedir. Müdahale stratejisinin, bir çatışmanın önümüzdeki ay sona erme olasılığını azaltan tek yönü, ya muhalefet ya da hükümet lehine taraflı olmasıdır. Etkili bir şekilde, tarafsız müdahaleler taraflı olanlardan daha az etkilidir.
"Şu Anı Prolog Olarak: Avrupa ve Tiyatro Nükleer Modernizasyonu." Catherine McArdle Kelleher. 1981. *Uluslararası Güvenlik*. Giriş: "Resmi İttifak kararından bir yıldan fazla bir süre sonra, NATO'nun yeni uzun menzilli tiyatro nükleer kuvvet (LRTNF) konuşlandırmaları için planı etrafında hala tartışmalar sürüyor. Tartışma, hem içeriğe hem de süreç odaklanıyor. Washington'daki ve diğer yerlerdeki destekçiler, bu kararı bir İttifak başarısı olarak görüyor ve süreci gelecekteki karar alma için bir model olarak değerlendiriyor. İttifak, artık yeni Sovyet zorluklarıyla başa çıkabileceğini göstermiştir; kapsamlı danışma prosedürleri, içsel siyasi risklere rağmen gerçekten bilgilendirilmiş bir NATO mutabakatına yol açtı. Sovyet LRTNF yetenekleriyle eşleşmek üzere tasarlanmamış olsalar da, yerden fırlatılan seyir füzeleri (GLCM'ler) ve Pershing II'ler, genel Doğu-Batı askeri dengesinde yeni bir unsur sağlamaktadır. Ayrıca, Amerikan stratejik bağlantısının güçlendirilmesi ve LRTNF üzerinde Doğu-Batı sınırlamaları için fırsatların peşinden koşulması konularında ölçülü bir ortak dikkat gösterilmiştir.	"Karşı Güç: Bir Panzehir İllüzyonu." Henry A. Trofimenko. 1981. *Uluslararası Güvenlik*. Giriş: "Son yıllarda, Amerikan askeri gücü kötü bir döngüye girmiştir. Washington'un Sovyetler Birliği'ni stratejik silahlar konusunda geride bırakma arzusunun yarattığı çıkmazdan kurtulamamıştır ve bu amaca ulaşmanın pratik olarak imkansızlığı söz konusudur. Sovyetler Birliği, Amerika Birleşik Devletleri'nin gerisinde kalmama ya ve böyle bir ABD üstünlüğüne izin vermemeye kararlıdır. Bu stratejik döngünün son kanıtı, ABD stratejisini karşı güç nükleer hedefleme kavramlarına geri döndüren Carter Yönetimi'nin Yönergesi No. 59 ile sağlanmıştır. Bu politika, Amerikalıları sözde bir Sovyet karşı gücü ve "savaş kazanma" tehdidi ile korkutmayı amaçlayan ABD medyası ve akademik basındaki uzun kampanyayı sonlandırmaktadır."

Doclingo https://www.doclingo.ai

dağıtımları."	
"Küresel Politik Ekonomide "Otorite"yi Bulmak." A. Claire Cutler. 1999. *Uluslararası Çalışmalar Dergisi*. Özet: "Bu makale, küresel politik ekonomide "otorite"nin problematik doğasını ele almakt adır. Bugün küresel kapitalizmin hukuki koşullarının bir p arçasını oluşturan uluslararası ticari ilişkileri yöneten kur allara odaklanarak, politik otoritenin yeri ve yapısının tari hsel olarak spesifik olduğu savunulmaktadır. Farklı tarihs el blokların ortaya çıkmasıyla ve buna bağlı olarak devlet -toplum ilişkilerindeki değişikliklerle birlikte değişmiştir." Makale, özel kurumsal gücün küresel siyasi ekonomi ve hegemonik otorite ilişkilerinin inşasındaki önemini vur gulamaktadır. Ancak, özel otoritenin önemi belirsizdir v e uluslararası ilişkiler öğrencileri tarafından pek anlaşıl mamaktadır. Bu durum, ulusal, alt ulusal ve uluslararas ı etkileri içeren küresel otoritenin analizi için tarihsel m ateryalist bir yaklaşım benimsemenin analitik ve norma tif gerekçelerini doğurmaktadır.	"Güney Kore ve Tayvan Gelişimi ve Yeni Kurumsal Ekonomi." David C. Kang. 1995. *Uluslararası Organizasyon*. Giriş: "Alice Amsden ve R obert Wade tarafından yayımlanan kitaplar, Doğu Asya ge lişimi üzerine çalışmalara yansımak için uygun bir an sun maktadır. Başlangıçta ilgi dalgasının başladığı bir dönemde 1970'lerde, alan bir platoya ulaştı ve akademisyenler son zamanl arda alanı genişletmenin yollarını aramak için geniş bir ağ kurdul ar. Doğu Asya'nın yeni sanayileşmiş ülkelerinin (NIC'ler) ekonomi k gelişimi ile ilgili "en son durum"u değerlendirirken, bu incelem e üç temayı ele alacaktır. İlk olarak, devletler ile pazarlar arasında ki odaklanmanın bayatladığını ve akademik ilginin ekonominin ar kasındaki siyasette yattığını savunacağım. İkincisi, siyaset bilimcil erin Kore ve Tayvan kapitalizminin tarihsel kökenlerini yeterince araştırmadığını ve bu tür bir dikkatin hem teorileri hem de gelişi m açıklamalarını güçlendirme vaadi taşıdığını savunuyorum. Üçü ncüsü, uluslararası sistemin Doğu Asya'da gelişimi teşvik etmede "ilk dalga"da tanınandan daha önemli olduğunu savunuyorum.

Metin karıştırıcıları üzerinde koşullandırma bağlamında kullanılabilecek y üzlerce eşleşme yaklaşımı vardır; her birinin güçlü ve zayıf yönleri bulunmakt adır. Roberts, Stewart ve Nielsen (2020), istenen eşleşme stratejilerinin iki öz elliğini entegre eden bir yaklaşım geliştirmiştir: tedavi atamasını modelleme ve kaba hale getirme. Bunu yapmak için, konuları ortak olarak tahmin etmek için Yapısal Konu Modeli (STM) kullanarak kelime gruplarını konu gruplarına ayırır ve her belgenin ne kadar muamele gördüğünü göstermek için belge d üzeyinde puanlar tahmin ederler. STM modelinde tedaviyi bir konusal içerik kovaryatı olarak kullanarak, hem konuları hem de belge düzeyindeki puanlar ı ortak olarak tahmin edebilirler. Daha sonra tahmin edilen konular ve belge düzeyindeki puanlar üzerinde eşleşirler.

Tedavi atamasını modellemek için, TIRM, tedavi olasılığı hakkınd a kelime sayılarındaki bilgilerin yeterli bir azaltımını tahmin ederek eğilim puanı eşleştirmesine bir benzerini oluşturur. Taddy (2013) iz leyerek, Roberts, Stewart ve Nielsen (2020), tedavi hakkında kelime sayılarında bulunan bilginin yeterli bir azaltımını türetirler. Bir kon u modelinin bağlamında bu belge düzeyindeki puanı tahmin edere k, projeksiyon, konularda taşınmayan tedavi bilgilerini temsil eder.

Konuların kaba gruplarında eşleşmek için, Roberts, Stewart ve Nielsen(2020) STM modelind en belgelerin konusal içeriğini çıkarmaktadır. Birufak karmaşa, konu-tedavi etkileşimleri mevcu t olduğunda ortaya çıkmaktadır çünkütedavi bir içerik kovaryatı olarak dahil edildiğinde, aynı ko nu altında tedavi vekontrol için farklı tahmin edilen kelime dağılımları olabilir. Yazarlar,konuları n karşılaştırılabilir olmasını sağlamak için STM'ye son bir tahmin adımıekleyerek tüm kontrol ko nularının konu oranlarını, sanki tedavi edilmiş gibi,yeniden tahmin etmektedirler.

Doclingo https://www.doclingo.ai

Tedavi/kontrol farklılıkları açısından karşılaştırılabilir olmalarını sağlamak için,STM'ye son bir tahmin adımı ekleyerek tüm kontrol konularının konu oranlarını,sanki tedavi edilmiş gibi yeniden tahmin etmektedirler. Bu seçim, *tedavi*üzerindeki (yerel) ortalama tedavi etkisi olan bir tahminle tutarlıdır. Daha sonra,hem STM projeksiyonu hem de STM'den tahmin edilen konu oranları üzerinde eşleşirler,bu da eşleşmelerin hem konusal olarak benzer hem de tedavi açısından konu içindekiolasılıkların benzer olmasını sağlar.

Roberts, Stewart ve Nielsen (2020), Maliniak, Powers ve Walter (2013)üzerine TIRM uygulayarak, geniş konuları geri kazanmak için algoritmanın STMkısmında 15 konu belirlemektedir. Karşılaştırma için, yalnızca projeksiyonu veyalnızca konuları kullanarak eşleşmiş örnekler de oluşturmaktadırlar. Daha sonra,TIRM eşleşmiş örneğini kullanarak Maliniak, Powers ve Walter (2013) modelleriniyeniden tahmin etmekte ve atıflardaki cinsiyet farklılıklarının, başlangıçtarapor edilenlerden daha belirgin olduğunu bulmaktadırlar. Kadınlar tarafındanyazılan makalelere, erkekler veya karma cinsiyet grupları tarafından yazılanmümkün olduğunca benzer makalelere kıyasla ortalama 6.5 daha az atıfbulmaktadırlar. Şekil 27.1 , farklı tedavi durumuna sahip benzer makalelerinörnek eşleşmiş çiftlerini içermektedir.

Doclingo https://www.doclingo.ai

27.3 Sonuç

Metin, birçok sosyal olguyu ölçmektedir, ancak şu anda nedensel çıkarımlar yapmak için analizlerde nadiren kullanılmaktadır. Bu kitabın bu bölümünde, metni nedensel çıkarımlarda nasıl kullanacağımızı düşünmek için bir çerçeve geliştirdik ve araştırmacıların metni bir tedavi, sonuç veya kontrol değişkeni olarak kullanırken karşılaşabilecekleri potansiyel tuzakları açıkladık. Sosyal bilimlerde nedenselliği incelemek için metni kullanmanın ne kadar geniş bir potansiyele sahip olduğunu göstermek için bölüm boyunca nedensel çıkarımda metin kullanma örnekleri ekledik.

Elbette, nedensel tanımlama zordur ve nedensel analizlerde metin kullanmak, nedensel çıkarımın temel sorunlarından hiçbirini çözmez. Aksine, nedensel çıkarım için metin kullanmak daha fazla, daha az karmaşıklık ekleyebilir. Daha önce nedensel çıkarım çalışmamışlarsa, okuyucuları bu alandaki geniş literatürden yararlanmaya teşvik ediyoruz (Morgan ve Winship, 2015; Imbens ve Rubin, 2015; Hernán ve Robins, 2020). Ayrıca, analistlerin her deney içinde çoğaltmayı simüle etmek için eğitim/test bölümlerinden yararlanmalarını ve mümkün olduğunca sık, deneylerini yeni popülasyonlar ve zaman dilimlerinde tekrarlamalarını öneriyoruz.

---

[1]Bu bölümün bir kısmı Roberts, Stewart ve Nielsen (2020) kaynaklıdır.

[2]D'Amour ve ark. (2021), yüksek boyutlu bağlamda pozitifliğin yeniden değerlendirmesini sunmakta ve bu varsayımın sıklıkla başarısız olabileceğini göstermektedir. Bu, yüksek boyutlu verilerin mevcut eşleştirme yaklaşımları için bir zorluk oluşturduğu bir diğer yoldur.

[3]Kadınlar tarafından sıklıkla sürdürülen işin değersizleştirilmesinin ciddi bir sorun olduğunu vurgulamakla birlikte, Maliniak, Powers ve Walter (2013) için ilgi alanı, yazarın algılanan cinsiyetinin alıntılar için önemli olup olmadığıdır. Bu nedenle, ideal karşılaştırma, iki farklı isim eklenmiş aynı metindir.

[4]Uluslararası İlişkiler alanındaki akademik çalışmalar bazen "paradigmalar" veya uluslararası ilişkileri açıklamak için en kritik faktörler hakkında düşünce okulları olarak organize edilmektedir. Baskın paradigmalar Realizm, Liberalizm ve Yapısalcılıktır, ancak başka paradigmalar da mevcuttur.

[5]Maliniak, Powers ve Walter (2013) tarafından yapılan el ile kodlama, yaklaşımımızı doğrulama konusunda ek bir fayda sağlamaktadır.

[6]TRIP veritabanı 2013'ten bu yana daha fazla makale kodladığı için, Maliniak, Powers ve Walter (2013)'den daha fazla makale analiz etmektedirler. Ancak, JSTOR'un veri setinde bulunmadıkları için Maliniak, Powers ve Walter (2013) tarafından kullanılan birkaç makale için verileri eksiktir.

[7]Lasso regresyonlarında, iki yüksek derecede korele olmuş tahminci olduğunda, birinin sıfırlanması muhtemeldir. Bu durumda, bu, yüksek derecede korele olmuş tahmincileri sıfırlayacaktır.

Doclingo https://www.doclingo.ai

tedavi, ancak bunlar en önemli karıştırıcılar olabilir! Ayrıca, düzenleme parametresini s eçme şeklimiz öngörü hatasını minimize eder, ancak bu, ilgi alanındaki nedensel etkini n hatasını minimize edecek parametreyle aynı olmak zorunda değildir.

Doclingo https://www.doclingo.ai

BÖLÜM VI

Sonuç

Doclingo https://www.doclingo.ai

BÖLÜM 28

Sonuç

Kitabımız, sosyal bilimlerde metni veri aracı olarak kullanma kılavuzudur. Metn in sosyal bilimlerde veri olarak ortaya çıkması, sosyal bilimciler için yeni bir boll uk ve fırsatlar dönemiyle örtüşmektedir. Büyük miktarda metni analiz etme yet eneği ile sosyal bilimciler, daha önce imkansız olan bir ölçekte içgörüler elde e debilmektedir. Aynı zamanda, yeni istatistiksel modellerin ve hesaplama araçla rının çokluğu, bu büyük yeni veri setlerini analiz etmeyi her zamankinden daha kolay hale getirmektedir.

Bu sonuç bölümünde önce kitabımızın temel argümanını gözden geçiriyo ruzve bu ilkeleri nasıl genişleteceğimiz konusunda rehberlik sağlıyoruz. Sosy albilimlerde, veri yöntemleri en iyi sosyal bilim görevlerine odaklandıklarında kullanılır. Bu nedenle, metni veri olarak analiz ederken kullandığımız birçoky öntemin bilgisayar bilimlerinden kaynaklandığına rağmen, bu yöntemlerinso syal bilimlere uygulandığında yeniden yapılandırılması gerektiğini savunuyor uz.Ve kritik olarak, bu yöntemleri değerlendirme şeklimizin sosyal bilimsorun larına uygulandığında farklı olacağını da belirtiyoruz. Ayrıca, metni veriolarak çıkarımların en iyi şekilde iteratif ve ardışık yapıldığında gerçekleştirildiğinis avunuyoruz. Sosyal bilimciler genellikle tümdengelimli bir yaklaşımbenimses eler de, metin verileriyle yapılan çıkarımların, veri setlerimizdenindüktif olara k kanıt tabanımızı oluşturduğumuzda daha iyi hale geldiğinisavunuyoruz. Ve ardışık çalıştığımızda tanımladığımız kavramları,aldığımız ölçümleri ve nihay etinde verilerimizden yaptığımız çıkarımlarıiyileştirebileceğimizi düşünüyoru z.Sonunda, makine öğrenimi modelleri ile çalışırken, doğru veri üretim sürec i hakkında bir temel şüphecilik—agnostisizm—gütmemiz gerektiğini savunu yoruz. Kullandığımız modeller, karmaşık metin verilerinin belirgin özetlerini s ağlama konusunda değer taşımaktadır. Ancak metin verilerinin nasıl temsil e dildiği ile dilin nasıl çalıştığı arasındaki karmaşık ilişki nedeniyle, doğru mode le sahip olduğumuzu varsaymamıza dayanan doğrulamaları kaçınılmaz olara k reddediyoruz. Bunun yerine, ilgi alanımızdaki temel görevimize odaklanan doğrulamaların, modellerin sosyal bilim görevleri için iyi performans gösteri p göstermediğini değerlendirmek için gerekli olduğunu savunuyoruz.

Metne odaklanmış olsak da, bu kitabın temel ilkeleri yalnızca me tin verisiyle sınırlı değildir. Aslında, metni veri olarak ele alma yakla şımımızı birçok diğer yeni veri kaynağına—görüntüler,

Doclingo https://www.doclingo.ai

ses ve video dahil—genel olarak uygulanabilir olarak görüyoruz. Metinler gibi, bu veri kaynaklar ının sosyal bilimlerde niteliksel çalışmalarda kullanılmasına dair uzun bir geçmişi vardır. Ancak, bu verilerle büyük ölçekte çalışmak zor olmuştur. Bilgisayar biliminde geliştirilen yeni hesaplam a araçları, bu veri kaynaklarıyla büyük ölçekte çalışmayı çok daha kolay hale getiriyor.

Aynı sorunlar ortaya çıkıyor. Bilgisayar bilimcilerinin görüntüler, video ve sesle çalış ırken odaklandıkları görevler, sosyal bilimcilerin ilgi alanındaki görevlerle aynı değil dir. Çerçevemiz, bu yeni araçları sosyal bilim çıkarımları yapmak için nasıl uygulaya cağınız konusunda bir rehber sunmaktadır.

Metin verisi yöntemleri ve daha genel olarak makine öğrenimi, sosyal bilimcil er için büyük bir ilerleme sağladığı iddia edilmektedir. Ve birçok açıdan, buna kat ılıyoruz. Yeni veri kaynakları ve yöntemler, araştırmacıların daha önce ölçekli olar ak inceleyemediğimiz sosyal etkileşimler hakkında sorular sormasını ve yanıtlam asını sağlıyor. Bu yöntemler bir panzehir değildir. Sosyal bilim problemlerini çöz mek için bir gümüş mermi olabileceğinden şüpheliyiz. Yeni yöntemler ne kadar e tkileyici olursa olsun, sosyal bilimciler hâlâ nedensel çıkarım, tahmin ve ölçüm içi n kavramları dikkatlice tanımlama gibi zorlu zorluklarla karşılaşacaklardır. Bu kit abı, yeni yöntemler geliştirirken alçakgönüllülüğün neden önemli olduğunu tartı şarak bitiriyoruz; bu, aşırı vaatlerin getirdiği hayal kırıklığını önlemek için gerekli dir.

Doclingo https://www.doclingo.ai

28.1 Sosyal Bilimlerde Metni Veri Olarak Kullanma

28.1.1 SOSYAL BİLİM GÖREVLERİNE ODAKLANMA

Metnin sosyal bilimlerde veri olarak hızlı bir şekilde genişlemesi, bilgisayar bili mi, istatistik ve dilbilim alanlarından gelen büyük ve son derece başarılı bir literat üre dayanmaktadır. Bu yöntemler son derece faydalıdır, ancak sosyal bilimlerdek i sorunları çözmek için hedeflenmemiştir. Örneğin, denetimsiz metin veri yönte mleri, bir iğneyi samanlıkta bulmak gibi bilgi retrieval görevleri için geliştirilmişti r; burada birincil hedef, saklanan verilerin tahmin doğruluğu açısından değerlen dirilen bir görevdir. Ancak sosyal bilimciler, iğneyi bulmak yerine tüm samanlığı karakterize etmek isterler ve denetimsiz metinler için tahminin bir ölçütü olarak nadiren ilgilenirler. Aslında, tahmin konusunda daha iyi performans gösteren m odellerin bazen sosyal bilimsel içgörüler sağlama konusunda daha kötü olduğu ortaya çıkmaktadır. Bu nedenle, bu yöntemleri uygulayacağımız sosyal bilimsel n edenler etrafında yöntemleri organize ediyoruz.

Sosyal bilimcilerin görevleri, araştırma projelerinin seyrini takip eder. Ar aştırma projelerinin başlangıcında, temel kalıplara dair içgörüler elde etme k için metinlerin yeni kavramsallaştırmalarını belirleyerek keşif yaparız. Bu organizasyonları göz önünde bulundurarak, gözlemleri kategorilere atama veya ölçüm yaparız. Ve nihayetinde, belirli bir müdahalenin ne etkisi olaca ğını sorduğumuz nedensel çıkarım veya verilerimize dayanarak örnek dışı bir tahmin yaptığımız tahmin ile çıkarımda bulunuruz.

Bu görev temelli yaklaşım, metin dışındaki veri çalışmaları için de faydalıdır. Aslın da, bu tür görevler etrafında çalışmayı açıkça yönlendirmeyi, üretken araştırma günd emlerine katkıda bulunduğuna inanıyoruz. Lisansüstü öğrencilere ciddi araştırmalar a nasıl yaklaşacakları konusunda tavsiyelerde bulunduğumuzda, araştırmayı bu aşa malara ayırmanın, göz korkutucu araştırma projelerini çok daha yönetilebilir hale get irebileceğini gördük. Ayrıca, mevcut projeleri dekompoze etmek, çıkarımları neyin yö nlendirdiğini anlamaya yardımcı olur.

Ayrıca, kitabımızın teoriyi açıkça ele alan bir bölümü olmadığını belirtmek istiyor uz; sosyal bilimler teorisini araştırma sürecinin ayrılmaz bir bileşeni olarak görüyor uz. Teori, kavramsallaştırmalar önerebilir, ölçüm motivasyonu sağlayabilir ve nede nsel etkilerin yorumlanmasında yardımcı olabilir. Bazıları büyük verinin çağının teo rinin sonunu göstereceğini öne sürse de, bunun tersinin doğru olduğunu düşünüy oruz. Teori, istatistiksel modellerin sonuçlarını yorumlamak için gereklidir ve daha f azla veriye sahip olduğumuzda, çıkarımlarımızı birleştirme ve modeller oluşturmak için daha stilize edilmiş gerçeklere sahip olma fırsatına sahibiz.

28.1.2 SOSYALIN İTERATİF VE SIRASAL DOĞASI

Doclingo https://www.doclingo.ai

Verilerimizden en çok öğrenmenin, çıkarımlarımızın yinelemeli ve ardışık olduğu zaman gerçekleştiğini savunduk. Bunun doğru olduğunu düşündüğümüz temel nedenler var. Verilerimizden yinelemeli olarak inşa etmek, modellerimizin belirli bir bağlamda nasıl uygulandığını daha iyi anlamamızı sağlar ve özellik temsilini ve diğer model özelliklerini belirli uygulamamıza göre ayarlamamıza olanak tanır. Ardışık çalışmak, araştırmacıların çalışmalar arasında kanıt biriktirmesine olanak tanır. Bir analiz gerçekleştirirken geliştirdiğimiz hipotezler olduğunda, ardışık düşünmek, bu hipotezleri yeni verilerle ve bir sonraki araştırma tasarımıyla test edebileceğimiz anlamına gelir.

Analistlere sağladığı faydaların ötesinde, ardışık yaklaşımın araştırmanın gerçekte nasıl yapıldığı konusunda daha dürüst olduğunu düşünüyoruz. Akademisyenlerin fikirlerin sanki tümdengelimle yaratıldığı gibi makaleler yazması yaygın olsa da, deneyimimiz bunun nadiren böyle olduğunu gösteriyor. Aksine, fikirler yinelemeli ve ardışık olarak geliştirilmektedir. Araştırma süreci hakkında daha net olmak, araştırmanın önceki çabalara nasıl dayandığını ve gelecekteki çalışmaların mevcut makaleden nasıl yararlanabileceğini daha açık hale getirecektir.

Ayrıca, araştırmaya iteratif ve sıralı bir yaklaşımın “balık tutma” sorunlarını ele almaya yardımcı olduğunu düşünüyoruz. Deneylerin kullanımındaki en büyük endişe, araştırmacıların gerçek farkın sıfır olduğu durumlarda istatistiksel olarak anlamlı bir sonuç izlenimi yaratmak için analizlerinde kararlar vermesidir. Bunu ele almanın bir yolu ön kayıt olmaktadır. Elbette, bu faydalı olabilir. Ancak, araştırmacıların önemli sonuçlarla makaleler yayınlama teşviklerini ele almakta pek bir şey yapmaz. Bunun yerine, araştırmaya sıralı bir yaklaşımın, araştırmacıların bulgularını çoğaltmaları için teşvikler yaratabileceğini düşünüyoruz (ve diğer araştırmacıların da bulgularını çoğaltmalarını sağlayabilir).

28.1.3 MODEL ŞÜPHECİLİĞİ VE MAKİNE ÖĞRENİMİNİN SOSYAL BİLİMLERE UYGULAMASI

Metin verileriyle çalıştığımızda, doğru modele sahip olduğumuza dair şüpheci olmamız gerektiğini düşünüyoruz. Dil son derece karmaşıktır ve dilin temsilinin bile kapsamlı basitleştirme varsayımları gerektirdiği açıktır. Sonuç olarak, kitap boyunca kullandığımız modeller açıkça yanlıştır, ancak bazıları faydalıdır. Bu, modellerin ilgi alanındaki miktarları ölçmek, yeni kavramsallaştırmalar önermek ve hatta nedensel çıkarımları kolaylaştırmak için faydalı olabileceği anlamına gelir.

Ancak bu, model seçimine girdiğimizde yalnızca model uyum istatistiklerine odaklanmamamız gerektiği anlamına geliyor. Bunun nedeni, model uyumunun sosyal bilimcilerin modeli kullanma biçimlerine nadiren optimize edilmesidir. Aksine, biz

Doclingo https://www.doclingo.ai

en faydalı modelleri seçmek için, modelin nasıl kullanılacağıyla yakından ilişkili ol an doğrulamalara katılmak istediğimizi savundu. Ve bu genellikle, modelleri değ erlendirmek için “insanları döngüde” tutmayı içerir. İnsanları döngüde tutmak, öl çümlerimizin geçerli olduğundan ve modellerin anlamlı olduğundan emin olmak için önemli olduğu kadar, kitabın her yerinde vurguladığımız gibi, modelleri uygu lamak ve araştırmaları pratik ve etik bir şekilde yürütmek için bağlam ve içerik bil gilerini kullanmak adına da önemlidir; metinleri yazanların da insanlar olduğunu, sadece veri noktaları olmadıklarını sürekli akılda tutarak.

Doclingo https://www.doclingo.ai

28.2 Metin Verisinin Ötesinde İlkelerimizi Uygulamak

Kitabımızda metni veri olarak ele aldık, ancak argümanımız çok daha genel olar ak diğer veri kaynaklarına da uygulanmaktadır. Aslında, yeni veri kaynakları mevcu t oldukça ve diğer alanlardan yeni yöntemler getirildikçe, bu yöntemlerin siyaset bi limi alanında nasıl kullanılacağını sormanın gerekli olduğunu düşünüyoruz. Düşünmek, sosyal bilimcilerin bu yeni veri kaynaklarını en iyi şekilde nasıl kullanabi lecekleri, sosyal bilimlerde en verimli kullanımlarına yol açacaktır.

İlgili yeni verilerde inanılmaz bir ilerleme kaydedilmiştir. Örneğin, giderek daha fa zla akademisyen, görüntü verilerinden sosyal bilim çıkarımları yapmak için makine ö ğrenimi tekniklerini kullanmaktadır. Örneğin, Torres (2019), protestocuların basında ki fotoğraflarda nasıl tasvir edildiğini incelemektedir. Daha genel olarak, akademisye nlerin görüntülerin sosyal etkileşimler için gücünü uzun zamandır tanıdığını düşünüy oruz. Görüntüleri incelemek için makine öğrenimi yaklaşımları, grupların nasıl tasvir edildiğini ölçekli bir şekilde inceleme fırsatı sunar ve bu tasvirlerin kamuoyunu nasıl etkilediğini anlamaya yardımcı olur.

Benzer şekilde, ölçekli olarak gerçek siyasi konuşmaları inceleyen inanılmaz çalı şmalar yapılmıştır. Elbette, söylenme şeklinin önemli olduğunu düşünüyoruz. Dem okratlar, Barack Obama'nın etkileyici konuşmalar yapma yeteneğini, retoriğine hay at katan bir ritim ve ton ile geniş çapta övmektedir. Benzer şekilde, Ronald Reagan, en önemli mesajların rahat, samimi ve eğlenceli bir şekilde iletimiyle muhafazakârl arı etkilemiştir. Sosyal bilimciler, sosyal etkileşimlerde konuşmanın rolünü analiz et mede önemli ilerlemeler kaydetmiştir. Örneğin, Kaufman, Kraft ve Sen (2019), Yüks ek Mahkeme yargıçlarının nasıl konuştuğunun bir davada nasıl karar vereceklerini tahmin edebileceğini göstermiştir ve Knox ve Lucas (2021), konuşma içeriğini çözü mlemek için genel bir yöntem sunmaktadır.

Videolar, bireylerin tedavilere nasıl tepki verdiği konusunda ayrıntılı çıkarımla r yapmak için kullanılabilir. Örneğin, Dietrich ve Sands (N.d.) New York City'deki t rafik kameralarını, bireylerin farklı kimliklere sahip rastgele yerleştirilmiş insanla ra nasıl tepki verdiğini ölçmek için kullanıyorlar. Ancak hala mevcut olan büyük miktarda video var ve sürekli video bilgisi akışının - televizyon ve internet üzerind eki - toplum üzerindeki etkileri hakkında sorulması gereken büyük sorular var.

Tüm bu örneklerde aynı temel ilkeler geçerlidir. Ve birçok durumda, benzer modeller kullanılabilir. Kısacası, kitabımızın faydasının yalnızca metin verileriyl e sınırlı olmadığını düşünüyoruz.

Doclingo https://www.doclingo.ai

28.3 Sosyal Bilim Metodolojisinde Yaratım ve Yıkım Döngüsünden K açınma

Kitabımızı yeni yöntemlerin yaratımında alçakgönüllülük çağrısıyla son landırıyoruz. Sosyal bilim metodolojisinde sıkça bir patlama-düşüş döngü sü olduğu görülüyor. Bazı yeni yöntemler veya tahminciler tanıtılıyor ve e n zor problemleri çözebilecek bir atılım olarak övülüyor. Destekleyenler, y öntemin devrim niteliğinde olduğunu iddia ediyor ve araştırmacılar en so n teknolojiyi kullanarak geçmiş ampirik iddiaları yeniden değerlendirmek için acele ediyor. Ancak yeni yöntemler, kaçınılmaz olarak, bu büyük ve g erçekçi olmayan vaatleri yerine getirmekte başarısız oluyor. Bu, bir yönte min destekçilerinin vaatleri ile gerçekten sunabileceği şeyler arasındaki b oşluğu işaret eden birçok akademisyenin ortaya çıkmasına yol açıyor. Bu değişimden çıkan fazla karamsar sonuç, yeni yöntemin baştan itibaren p ek de faydalı olmadığı ve akademisyenlerin yeni istatistiksel teknolojinin gerçekten de sorunları için pek de faydalı olmadığı sonucuna varmasıdır. Sonuç olarak, yeni yöntemler bir kenara atılıyor, oysa hala iyi bir şekilde y erine getirebilecekleri bazı dar görevler için faydalı olabilirler.

Veri olarak metin kullanmanın benzer bir patlama ve çöküş döngüsüne maruz kalm a riski vardır - metin olarak veri yöntemleri bu kaderden büyük ölçüde kaçınmış olsa da. Bunun kısmen, metin olarak veri konusundaki erken makalelerin, ne sunabileceği konu sunda aşırı vaatlerde bulunmaktan kaçınmasından kaynaklandığını düşünüyoruz. Metin , çalışması zor bir şeydir ve yeni metin yöntemleri son derece faydalıdır. Ancak bu yeni y öntemler, metin olarak veri ile ilgili tüm sorunlara birleştirilmiş ve kapsamlı bir yaklaşım sunamayabilir.

Sosyal bilimlerdeki yeni istatistiksel modeller benzer bir dizi gerçek ile karşı karşıyadır. Yeni araştırma tasarımları ve makine öğrenimi yöntemleri kesinlikle çıkarımları mızı geliştirebilir. Ancak hiçbir hesaplama gücü veya “büyük veri”, sosyal bilimi n temel zorluklarını çözemez. Araştırmacılar, hâlâ kavramsallaştırmalar geliştir mek ve bu organizasyonlara göre ölçüm yapmak zorunda kalacaklardır.
Ve elbette, bir veri setinin birçok satırı olsa bile, nedensel çıkarımın temel sorunu devam etmektedir. Hiçbir yöntem bu sorunları ortadan kaldıramasa da, yeni yön temler ve yaklaşımlar, araştırma sürecinin her aşamasındaki çalışmaları geliştire bilir.

Bu kitap, sosyal bilimlere heyecan verici yeni metin olarak veri yöntemlerini en iyi şekilde nasıl uygulayacağımızı açıklamak ve sosyal bilimlerdeki en zor sorunlar üzeri nde araştırmayı geliştirmek için mütevazı katkımız olmuştur.

Doclingo https://www.doclingo.ai

Teşekkürler

Bu kitap üzerinde bir süredir çalışıyoruz. Bitirmeye bir yıl kadar uzak olduğumuzu hissetmek, yaklaşık beş yıldır böyle. Bu süre zarfında, makine öğrenimi ve sosyal bilimler kesişiminde çalışan harika bir akademik topluluktan faydalandık. Bu kitabı bu hale getiren tüm muhteşem insanları listelemek imkansız olurdu, ama kesinlikle deneyeceğiz.

Öncelikle, geçmişte metin verisi projeleri üzerinde bizimle çalışan ve süreçte farklı aşamalarda kitap veya ilgili projeler hakkında geri bildirimde bulunan John Ahlquist, Edo Airoldi, Anthony Anderson, Chris Bail, Pamela Ban, Kathryn Baragwanath Vogel, Nick Beauchamp, Clark Bernier, Lisa Blaydes, Dave Blei, Sarah Bouchat, Amber Boydstun, Amy Bridges, Elizabeth Bruch, Dan Butler, Amy Catalinac, Allison Chaney, Keng-Chi Chang, Scott de Marchi, Scott Desposato, Paul Di Maggio, Mitch Duneier, Naoki Egami, Jacob Eisenstein, Barbara Engelhardt, James Evans, Chris Felton, Kevin Flannagan, Annie Franco, Christian Fong, Maggie Frye, Daniel Gillion, Amarnath Gupta, Will Hobbs, Geoffrey Hoffman, Jiying Jiang, Rebecca Johnson, Megan Kang, Patrick Lam, Chloe Lim, Chris Lucas, Ben Liebman, Ian Lundberg, Alison McQueen, Kennedy Middleton, Juan Pablo Micozzi, David Mimno, Jacob Montgomery, Burt Monroe, Cambria Naslund, Laura Nelson, Rich Nielsen, Brendan O'Connor, Jennifer Pan, Gregoire Phillips, David Robinson, Pedro Rodríguez, Luke Sanford, Thomas Scherer, Cheryl Schonhardt-Bailey, Nicholas Smith, Rachel Stern, Brian Tsay, Hannah Waight, Hanna Wallach, Bertrand Wilden, Adam Wu, Xiaohan Wu, Luwei Ying, Eddie Yang, Young Yang, Leo Yang, Yin Yuan, Simone Zhang ve Yile Zhang. Bazı yerlerde, diğer akademisyenler tarafından sağlanan tekrar veri setlerinden faydalandık ve bu verileri erişilebilir kıldıkları için onlara en içten teşekkürlerimizi sunuyoruz.

2017 kitap konferansımıza katılan Naoki Egami, Christian Fong, James Fowler, Erin Hartman, Arthur Spirling, Yiqing Xu ve Teppei Yamamoto'a iki gün boyunca bize zaman ayırdıkları için özellikle teşekkür ederiz.

Doclingo https://www.doclingo.ai

San Diego'da mükemmel geri bildirimde bulundular ve bu, el yazmasını büy ük ölçüde geliştirdi. Kitap konferansını destekleyen UC San Diego Sosyal Bili mler Bölümü'ne ve etkinliği organize etme konusundaki yardımları için DeAn na Barrett'a teşekkür ederiz. Yıllar sonra, Princeton University Press için üç a nonim hakem, el yazmasının erken bir versiyonu hakkında bize içgörülü yoru mlar sağladı ve bu, kitabın nihai yönünü büyük ölçüde şekillendirdi.

Son on yılda, özellikle 2009'da Harvard'da Peter Bol, Kevin Quinn ve Stuart Shieber tarafından düzenlenen Metin Analizi için Yeni Yö nler başlıklı konferansla başlayan yıllık Metin Veri Konferansı'ndaki etkileşimlerimizden faydalandık. Bu konferansın yıllar içindeki orga nizatörlerine ve bu topluluğu oluşturma sürecine dahil olan Ken Be noit, Amber Boydstun, Michael Colaresi, Will Lowe, David Mimno, K evin Quinn, Philip Resnik, Noah Smith, Arthur Spirling ve Hanna W allach gibi kişilere teşekkür ederiz. Bu konferanslar, yöntemler, uyg ulamalar ve araştırma tasarımı hakkında fikirlerin paylaşılması için entelektüel bir altyapı sağladı. Bu çalışmayı mümkün kılan yazılım altyapısını oluşturan ve serbestçe dağıtan insan grubu da aynı der ecede önemlidir. Ken Benoit'a ve quanteda'yı geliştiren ve sürdüre n ekibe, tm'yi oluşturan Ingo Feinerer'a, tidytext'i yaratan Julia Silg e ve David Robinson'a ve metin veri ekosistemini mümkün kılan di ğer tüm paketlere derin bir minnet duyuyoruz.Tüm bu paketler, R dilinin geliştiricileri ve bakımını yapanların yorulmak bilmeyen çaba ları sayesinde çalışmaktadır.

Princeton, Stanford, Chicago ve UC San Diego'daki sınıflarımızda ve dü nya genelindeki birçok daha küçük atölye ve sınıfta bulunan öğrencilerim ize minnettarız. Bu öğrenciler, metin üzerindeki geri bildirimleri ve sorula rı ile bizi daha fazla düşünmeye ve daha net iletişim kurmaya zorlayarak, el yazmasını doğrudan şekillendirdiler. Ayrıca, kitabın el yazmasını kendi derslerinde kullanan ve hem öğrencilerinden hem de bir eğitmen perspe ktifinden bize geri bildirim sağlayan Elliott Ash ve Alexandra Siegel'e de t eşekkür ederiz.

John Wilkerson'a metin olarak veri yöntemlerinin savunucusu olduğu ve yıllar b oyunca hepimize destek olduğu için teşekkür ederiz. 2010'daki atölyesi, Phil Schro dt ile birlikte Washington Üniversitesi'nde düzenlenen "Metin için Araçlar: Siyasi Bil im Araştırmaları için Notlama Yöntemleri", Brandon'ın metin olarak veri yöntemleri ni öğretme fırsatı bulduğu ilk etkinlikti. Mike Alvarez, Justin ve Brandon'ın 2013 tari hli "Metin Olarak Veri" makalesinin orijinal fikrini önerdiği için özel takdiri hak ediy or. Son olarak, Matt Salganik kitabın çeşitli bölümlerinin birçok taslağını okudu ve her zaman içgörülü ve cesaretlendirici geri bildirimde bulundu, sadece

Doclingo https://www.doclingo.ai

“Hey, kitabın nasıl gidiyor?” diye sorarak başladık.Üçümüz de lisans üstü okulda metin verisi üzerinde çalışmaya başladık vetezlerimizde ilgili materyallere sahip olduk. Jeff Frieden, Claudine Gay, D. Sunshine Hillygus, Elizabeth Perry,Kevin Quinn ve Beth Simmons gibi inanılmaz danışmanlardan faydalandık. Dustin Tingley,Molly’nin ve Brandon’ın komitelerinin bir üyesi olarak hem geri bildirim hem de destek için özel birşekilde anılmayı hak ediyor, ayrıca Yapısal Konu Modeli ve ilgili projelerdeki işbirliği için de.Metin verisi yöntemlerinin uygulanması hakkında sayısız konuşma aracılığıyla, Dustin bu kitabınher yerinde yer alan birçok içgörünün sorumlusudur. Son olarak, Gary King, üç tezimizin de başkanıydıve mezuniyetimizden buyana yorulmak bilmeyen bir mentor olmaya devam etti. Onun geri bildirimi ve içgörüleri,görüşlerimizi muhtemelen bildiğimizden daha fazla şekillendirdi.

Kitabın organizasyonu ve yönü hakkında bize birçok tur geri bildirim sağladığı için Princeton University Press’teki editörümüz Meagan Levinson’a teşekkür ederiz.Kitabın erken aşamalarında tartıştığımız Princeton University Press’teki Eric Crahan’a da özel teşekkürler.Kitap üzerindeki geri bildirimi ve notasyonun tutarlı hale getirilmesine yardımcı olduğu için Matthew Tyler’a teşekkür ederiz. Lisa McKay, erken taslakların düzenlenmesinde mükemmel bir yardım sağladı ve Bhisham Bherwani, en sonunda mükemmel bir kopya düzenlemesi yaptı.

Bu kitapta tartışılan çalışmalara cömert finansman desteği için, National Science Foundation RIDIR programına teşekkür ederiz, ödül numaraları 1738411 ve 1738288, ayrıca National Institutes of Health'in Eunice Kennedy Shriver Ulusal Çocuk Sağlığı ve İnsan Gelişimi Enstitüsü'neödül numarası P2CHD047879 için teşekkür ederiz.

Bu kitap, birkaç yerde, Grimmer ve Stewart’ın “Veri Olarak Metin: Politik Metinler için Otomatik İçerik Analiz Yöntemlerinin Vaadi ve Tuzakları” adlı makalemiz de dahil olmak üzere, birkaç makalemizden doğrudan metin kullanmaktadır; bu makale *Political Analysis* (2013); Fong ve Grimmer’ın “Metin Korpüsünden Tedavi Keşfi” adlı makalesi, *Proceedings of the 54. Yıllık Computational Linguistics Derneği Toplantısı* (2016); Roberts,Stewart ve Nielsen’ın “Metin Eşleştirmesi ile Karıştırmayı Ayarlama” adlı makalesi, *nal of Political Science* (2020); veGrimmer, Roberts ve Stewart’ın “Sosyal Bilimler için Makine Öğrenimi: Agnostik Bir Yaklaşım” adlı makalesi, *Annual Review of PoliticalScience* (2021) dergisinde yayımlanmıştır. Bu çalışmayı yeniden üretme izinleri için yayınevlerine teşekkür ederiz. Birkaç şekil, bizim çalışmalarımızdan ve diğerlerinden yeniden üretilmiştir. Bu figürleri yeniden üretmemize izin verdikleri için yayınevlerine ve yazarlara teşekkür ederiz.

Justin, bu kadar eğlenceli şeyler sağladıkları için Izzy, Eli ve Holden'a minnettardır.

Doclingo https://www.doclingo.ai

5.000, kazanan takım Fortnite zorlukları oynayarak yeniden enerji toplama fırsatları ve her zaman bir etiket oyunu oynamaya hazır olma. Ayrıca, hayal lerini takip etmesine olanak tanıyan sonsuz çabaları için ebeveynleri Karl v e Becky Grimmer'a minnettar. Ve en önemlisi, her günü bir öncekinden da ha iyi hale getiren Terese Grimmer'ın amansız sevgisi, sarsılmaz desteği ve derin sabrı için minnettar.

Molly, bu kitabı yazma sürecinde sonsuz sevgi ve eğlence sağlamak için z amanında sahneye çıkan Rae ve Theo'ya çok özel bir teşekkür sunuyor. Don ve Barbara Roberts ile Lisa ve Alan Fenning'e, 2020'nin çalkantılı yılı boyunca bu kitabı bitirmeyi mümkün kılmak için onlara (ve ona) bakmalarına yardımcı oldukları için teşekkür eder. Son olarak, David'e, kaosun ortasında bile onun için sessiz yazma zamanları yaratmadaki ustalığı, koşulsuz sevgisi ve desteği , ve işinin birçok yönü hakkında sağladığı paha biçilmez geri bildirim ve içgör üler için teşekkür eder.

Brandon, son birkaç yılda iş dışındaki hayatı neşeli kılan insanlara teşekkür ediyor: Alice, Carolina, Daniel, Luke ve Mary. Her biri, haftal ık yürüyüşler, yazma inzivaları ve geç saatlerdeki telefon görüşmeler i sırasında bu kitabı farklı detaylarda duydu. Olga, projeyi tamamlam a sürecinde sürekli destek ve cesaret verdi. Son olarak, ebeveynleri J erry ve Candi'ye, sarsılmaz destekleri ve nazik ve cömert bir insan ol manın ne anlama geldiği konusunda örnek oldukları için teşekkür e diyor.

Doclingo https://www.doclingo.ai

Kaynakça

Abello, James, Peter Broadwell ve Timothy R. Tangherlini. 2012. "Hesaplamalı folklor bilimi." *ACM İletişimleri* 55(7):60–70.

Achen, Christopher H. 2002. "Yeni bir siyasi metodolojiye doğru: Mikrotemeller ve SAN." *Siyasi Bilimler Yıllık İncelemesi* 5(1):423–450.

Adair, Douglass. 1944. "Tartışmalı Federalist Papers'ın yazarlığı." *The William and Mary Quarterly: Erken Amerikan Tarihi Dergisi* 1(2):97–122.

Adcock, Robert ve David Collier. 2001. "Ölçüm geçerliliği: Nitel ve nicel araştır malar için ortak bir standart." *Amerikan Siyasi Bilimler Dergisi* 95(3):529–546.

Aggarwal, Charu C. 2018. *Metin için Makine Öğrenimi*. Springer.

Ahmed, Amr ve Eric P. Xing. 2010. "Bilgilendirilmiş kalmak: Denetimli ve yarı denetimli çoklu görünüm ideolojik perspektif analizi." In *2010 Doğal Dil İşleme Üzerine Ampirik Yöntemler Konferansı*. Cambridge, MA: Hesaplamalı Dilbilim Derneği s. 1140–1150.

Airoldi, Edoardo M. ve Jonathan M. Bischof. 2016. "Konu modellerini ve diğer metin modellerini geliştirme ve değerlendirme." *Amerikan İstatistik Derneği Dergisi* 111(516):1381–1403.

Airoldi, Edoardo M., Stephen E. Fienberg ve Kiron K. Skinner. 2007. "Kimin fikirleri? Kimin sözleri? Ronald Reagan'ın radyo konuşmalarının yazarlığı." *PS: Siyasi Bilimler & Politika* 40(3):501–506.

Aletras, Nikolaos, Dimitrios Tsarapatsanis, Daniel Preoţiuc-Pietro ve Vasileios Lampos. 2016. "Avrupa İnsan Hakları Mahkemesi'nin yargı kararlarını tahmin etmek: Doğal Dil İşleme perspektifi." *PeerJ Bilgisayar Bilimleri* 2:e93.

Anderson, Chris. 2008. "Teorinin Sonu: Veri Selinin Bilimsel Yöntemi Geçersiz Kılması." *Wired* . URL: *https://www.wired.com/2008/06/pb-theo*

Andrzejewski, David, Xiaojin Zhu ve Mark Craven. 2009. "Konu modellemesine alan bilgisini Dirichlet orman öncelikleri ile dahil etme." In *Makine Öğrenimi Üzeri ne 26. Yıllık Uluslararası KonferansınBildiri Kitabı*. ACM s. 25–32.

Ansolabehere, Stephen ve Shanto Iyengar. 1995. *Negatif Olmak: Siyasi Reklamlar Seçmenleri Küçültür ve Kutuplaştırır*. Simon & Schuster.

Arnold, Taylor ve Laura Tilton. 2017. "R'de Temel Metin İşleme." *The Programming Historian* 6.

Aronow, Peter M. ve Benjamin T. Miller. 2019. *Agnostik İstatistiklerin Temelleri*. Cambridge Üniversitesi Yayınları.

Arora, Sanjeev, Rong Ge, Yonatan Halpern, David Mimno, Ankur Moitra, David Sontag, Yichen Wu ve Michael Zhu. 2013. "Konu modelleme için pratik bir algoritma ile

Doclingo https://www.doclingo.ai

kanıtlanabilir garantiler." *Makine Öğrenimi Üzerine Uluslararası Konferans*. s. 280–288.
Arora, Sanjeev, Yingyu Liang ve Tengyu Ma. 2017. "Basit ama yenilmesi zor bir cümle gömme için temel. *5. Uluslararası Öğrenme Konferansı Temsiller, ICLR 2017, Toulon, Fransa, 24-26 Nisan 2017, Konferans Takımı Bildiri*.
Arora, Sanjeev, Yuanzhi Li, Yingyu Liang, Tengyu Ma ve Andrej Risteski. 2018. "Kelimelerin anlamlarının lineer cebirsel yapısı, çok anlamlılığa uygulamaları ile birlikte." *Hesaplamalı Dilbilim Derneği İşlemleri* 6:483–495.
Arthur, David ve Sergei Vassilvitskii. 2007. "K-Means++: Dikkatli tohumlamanın avantajları." In *On Sekizinci Yıllık ACM-SIAM Ayrık Algoritmalar Sempozyumu*. SODA '07 ABD: Endüstriyel ve Uygulamalı Matematik Derneği s. 1027–1035.
Askitas, Nikolaos ve Klaus F Zimmermann. 2009. "Google ekonometrisi ve işsizlik tahmini." *Uygulamalı Ekonomi Çeyrek Dergisi* 55(2):107–120.
Asuncion, Arthur, Max Welling, Padhraic Smyth ve Yee Whye Teh. 2009. "Açık konu modelleri için düzleştirme ve çıkarım." *Yirmi Beşinci Yapay Zeka'da Belirsizlik Konferansı*. AUAI Press s. 27–34.
Asur, Sitaram ve Bernardo A Huberman. 2010. "Sosyal medya ile geleceği tahmin etmek." In *Web Intelligence and Intelligent Agent Technology (WI-IAT), 2010 IEEE/WIC/ACM Uluslararası Konferansı*. Cilt. 1 IEEE s. 492–499.
Athey, Susan. 2017. "Tahminin ötesinde: Politika problemleri için büyük veriyi kullanmak." *Bilim* 355(6324):483–485.
Bafumi, Joseph ve Michael C. Herron. 2010. "Sıçrama temsili ve aşırılık: Amerikan seçmenleri ve Kongre'deki üyeleri üzerine bir çalışma." *Amerikan Siyasi Bilimler Dergisi* 104(3):519–542.
Bagozzi, Benjamin E. 2015. "Sıfır şişirilmiş sayım modelleri ile sivil çatışmayı tahmin etme." *İç Savaşlar* 17(1):1–24.
Kefaletle, Christopher. 2014*a*. *Korkmuş: Nasıl anti-Müslüman marjinal organizasyonlar haline geldi ana akım*. Princeton University Press.
Bail, Christopher A. 2012. "Marjinal etki: Sivil toplum kuruluşları ve medya söyleminin evrimi İslam hakkında 11 Eylül saldırılarından bu yana." *Amerikan Sosyolojik İnceleme* 77(6):855–879.
Bail, Christopher A. 2014*b*. "Kültürel çevre: Kültürü büyük verilerle ölçmek." *Teori ve Toplum* 43(3–4):465–482.
Bail, Christopher Andrew. 2016. "Doğal dil işleme ve ağ analizi kombinasyonu ile savunuculuk organizasyonlarının sosyal medyada nasıl konuşma başlattığını incelemek." *Ulusal Bilimler Akademisi Bildirileri* 113(42):11823–11828.
Bailey, Andrew ve Cheryl Schonhardt-Bailey. 2008. "FOMCpara politikası yapımında tartışmanın önemi var mı? Volcker Devrimi 1979." *Siyasi Analiz* 16(4):404–427.
Baker, Collin F., Charles J. Fillmore ve John B. Lowe. 1998. "Berkeley FrameNet projesi." In *36. Yıllık Bilgisayarla Dilbilim Derneği Toplantısı ve 17. Uluslararası Hesaplamalı Dilbilim Konferansı, Cilt 1*. s. 86–90.
Ball, Geoffrey H. 1965. "Sosyal bilimlerde veri analizi: Detaylar ne olacak?" In *30 Kasım - 1 Aralık 1965, Sonbahar Ortak Bilgisayar Konferansı Tutanağı, Bölüm I*. s. 533–559.
Bamman, David ve Gregory Crane. 2009. "Çok Dilli Metin Yeniden Kullanımını Keşfetmek"

Doclingo https://www.doclingo.ai

Edebi Metinler." *Perseus Dijital Kütüphanesi*.
Bamman, David ve Noah A. Smith. 2014. "Metinden biyografik yapıların deneti msiz keşfi." *Hesaplamalı Dilbilim Derneği İşlemleri* 2:363–376.
Banerjee, Arindam, Inderjit Dhillon, Joydeep Ghosh ve Suvrit Sra. 2005. "Birim hipersfer üzerinde von Mises-Fisher dağılımları kullanarak kümeleme." *Makine Öğrenimi Araştı rmaları Dergisi* 6:1345–1382.
Banerjee, Arindam, Srujana Merugu, Inderjit S. Dhillon ve Joydeep Ghosh. 2005. "Bregman sapmaları ile kümeleme." *Makine Öğrenimi Araştırmaları Dergisi* 6:1705–1749.
Bansak, Kirk, Jeremy Ferwerda, Jens Hainmueller, Andrea Dillon, Dominik Hangartn er, Duncan Lawrence ve Jeremy Weinstein. 2018. "Veri odaklı algoritmik atama yoluyla mülteci entegrasyonunu geliştirme" Bilim 359(6373):325–329.
Barberá, Pablo, Amber E. Boydstun, Suzanna Linn, Ryan McMahon ve Jonathan Nagler. 2021. "Haber Makalelerinin Otomatik Metin Sınıflandırması: Pratik Bir Kılavuz." *Polit ik Analiz* 29(1):19–42.
Barberá, Pablo. 2014. "Aynı tüyden kuşlar birlikte tweet atar: Twitter verileri kullanarak Bayesian ideal nokta tahmini." *Politik Analiz* 23(1):76–91.
Barberá, Pablo ve Gonzalo Rivero. 2015. "Twitter kullanıcılarının politik temsiliyetini a nlama." *Sosyal Bilimler Bilgisayar İncelemesi* 33(6):712–729.
Baroni, Marco, Georgiana Dinu ve Germán Kruszewski. 2014. "Sayma, tahmin etme! Bağla m sayma ile bağlam tahmin etme anlamsal vektörlerinin sistematik karşılaştırması." In *Derleme 52. Yıllık Toplantısı Hesaplamalı Dilbilim Derneği (Cilt 1: Uzun Makaleler)*. s. 238–247.
Bartels, Larry M. 2002. "Aday özelliklerinin Amerikan başkanlık seçimlerinde etkisi." *Liderlerin Kişilikleri ve Demokratik Seçimlerin Sonuçları* s. 44–69.
Baumer, Eric P. S., David Mimno, Shion Guha, Emily Quan ve Geri K. Gay. 2017. "Temellendirilmiş teori ve konu modellemesini karşılaştırmak: Aşırı ayrışma mı yoksa olası yakınsama mı?" *Bilgi Bilimi ve Teknolojisi Derneği Dergisi* 68(6):1397–1410.
Baumgartner, Frank R., Bryan Jones ve Michael C. MacLeod. 1998. "Siperlerden dersler: Kalite, güvenilirlik ve kullanılabilirlik yeni bir veri kaynağında." *Siyasi Metodolog* 8(2):1–11.
Beauchamp, Nicholas. 2017. "Eyalet düzeyi anketleri tahmin etme ve enterpolasyon yapma Twitter metin verilerini kullanarak." *Amerikan Siyasi Bilimler Dergisi* 61(2):490–503.
Beauchamp, Nick. 2011. "Metin kullanarak, bilgilendirici olmayan oylama ile yasama organlarını ölçeklendirme." New York Üniversitesi Çalışma Raporu.
Beieler, John. 2016. "Gerçek zamanlı, yeniden üretilebilir bir olay veri seti oluşturma." *arXiv ön baskısı arXiv:1612.00866*.
Beieler, John, Patrick T. Brandt, Andrew Halterman, Philip A. Schrodt ve Erin M. Simpson. 2016. "Siyasi olay verilerini neredeyse gerçek zamanlı olarak üretmek." In *Hesaplamalı Sosyal Bilim*, ed. R Michael Alvarez. Cambridge University Press s. 98–120.
Belloni, Alexandre, Victor Chernozhukov ve Christian Hansen. 2014. "Yüksek boyu tluyöntemler ve yapısal ile tedavi etkileri üzerine çıkarım." *EkonomikPerspektif ler Dergisi* 28(2):29–50.
Bengio, Yoshua, Réjean Ducharme, Pascal Vincent ve Christian Jauvin. 2003. "Bir sinir

Doclingo https://www.doclingo.ai

olasılık dil modeli." *Makine Öğrenimi Araştırmaları Dergisi* 3(Şub):1137–1155.

Bengtsson, Linus, Xin Lu, Anna Thorson, Richard Garfield ve Johan Von Schreeb. 2011. "Mobil telefon ağı verileri ile nüfus hareketlerini takip ederek felaketlere ve salgınlara daha iyi yanıt: Haiti'de bir deprem sonrası coğrafi çalışma." *PLoS Tıp* 8(8):e1001083.

Benjamin, Ruha. 2019. *Teknoloji Sonrası Irk: Yeni Jim Kodu için İptal Araçları*. Wiley.

Benoit, Kenneth, Drew Conway, Benjamin E Lauderdale, Michael Laver ve SlavaMik haylov. 2016. "Kitle kaynaklı metin analizi: Yeniden üretilebilir ve çevik siyasi veri üretimi." *American Political Science Review* 110(2):278–295.

Benoit, Kenneth ve Michael Laver. 2003. "İrlanda parti politika pozisyonlarını tahmin etme bilgisayar kelime puanlaması kullanarak: 2002 seçimleri—Bir araştırma notu." *İrlanda Siyasi Çalışmaları* 18(1):97–107.

Benoit, Kenneth, Kevin Munger ve Arthur Spirling. 2019. "Siyasi sofistikasyonu m etinsel karmaşıklıküzerinden ölçme ve açıklama." *Amerikan Siyasi Bilimler Der gisi* 63(2):491–508.

Benoit, Kenneth, Michael Laver ve Slava Mikhaylov. 2009. "Kelimeleri veri olarak hata ile el e alma:Politika pozisyonlarının metin ifadelerindeki belirsizlik." *Amerikan Siyasi Bilimler Dergisi* 53(2):495–513.

Berinsky, Adam J., Gregory A. Huber ve Gabriel S. Lenz. 2012. "Deneysel araştırmalar için çevrimiçi iş pazarlarını değerlendirme: Amazon.com 20(3):351–368.

Berliner, Daniel ve Aaron Erlich. 2015. "Şeffaflık için rekabet: Siyasi rekabet ve Meksika eyaletlerindeki kurumsal reform." *Amerikan Siyasi Bilimler İncelemesi* 109(1):110–128.

Berry, Christopher R. ve Anthony Fowler. 2016. "Kardinal mi yoksa din adamı mı? Kongre komiteleri ve domuz etinin dağıtımı." *Amerikan Siyasi Bilimler Dergisi* 60(3):692–708.

Berry, David M. ve Anders Fagerjord. 2017. *Dijital Beşerî Bilimler: Bilgi ve Eleştiri Dijital Çağda*. Polity Press.

Biber, Douglas. 1991. *Konuşma ve Yazımda Varyasyon*. Cambridge University Press.

Bischof, Jonathan ve Edoardo M. Airoldi. 2012. "Konu içeriğini kelime sıklığı ve özgüllük ile özetleme." *29. Uluslararası Makine Öğrenimi Konferansı Tutanakları*. s. 201–208.

Bishop, Christopher. 2006. *Desen Tanıma ve Makine Öğrenimi*. Springer.

Blackwell, David ve James B. MacQueen. 1973. "Ferguson dağılımları Pólya urn şemaları aracılığıyla." *İstatistik Dergisi*1(2):353–355.

Blair, Graeme, Jasper Cooper, Alexander Coppock ve Macartan Humphreys. 2019. "Araştırma tasarımlarını ilan etme ve teşhis etme." *Amerikan Siyasi Bilimler Dergisi* 113(3):838–859.

Blaydes, Lisa, Justin Grimmer ve Alison McQueen. 2018. "Prensler ve sultanlar için ay nalar: Ortaçağ Hristiyan ve İslam dünyalarında yönetim sanatı üzerine tavsiyeler." *Siyaset Dergisi*80(4):1150–1167.

Blei, David M. 2012. "Olasılıksal konu modelleri." *ACM İletişimleri* 55(4):77–84.

Blei, David M. 2014. "İnşa et, hesapla, eleştir, tekrar et: Gizli değişkenlerle veri analizi"

Doclingo https://www.doclingo.ai

modelleri." *İstatistik ve Uygulamaları Yıllık İncelemesi* 1(1):203–232.
Blei, David M., Andrew Y. Ng ve Michael I. Jordan. 2003. "Gizli Dirichlet tahsisi." *Makine Öğrenimi Araştırmaları Dergisi* 3:993–1022.
Blei, David M. ve John D. Lafferty. 2006. "Dinamik konu modelleri." In *Proceedings of the 23. Uluslararası Makine Öğrenimi Konferansı*. ACM s. 113–120.
Blei, David M. ve John D. Lafferty. 2007. "Bilim için ilişkili bir konu modeli." *The Uygulamalı İstatistikler Dergisi* 1(1):17–35.
Bojanowski, Piotr, Edouard Grave, Armand Joulin ve Tomas Mikolov. 2017. "Alt kelime bilgisi ile kelime vektörlerini zenginleştirme." *Hesaplamalı Dilbilim Derneği İşlemleri* 5:135–146.
Bolukbasi, Tolga, Kai-Wei Chang, James Zou, Venkatesh Saligrama ve Adam Kalai. 2016. "Erkek, bilgisayar programcısına; kadın ise ev hanımına mı? kelimegömme önyargılarını giderme." In *Proceedings of the 30. Uluslararası Sinirsel Konferansı Bilgi İşleme Sistemleri*. s. 4356–4364.
Bond, Robert ve Solomon Messing. 2015. "Sosyal medyanın politik alanını nicelleştirmek: Facebook'ta kamuya açıklanan tercihlerden ideolojiyi tahmin etme." *Amerikan Siyasi Bilimler Dergisi* 109(1):62–78.
Bonica, Adam. 2013. "Politik pazardaki ideoloji ve çıkarlar." *Amerikan Siyasal Bilimler Dergisi* 57(2):294–311.
Bonica, Adam ve Maya Sen. 2017. "Barodan yargıç seçme politikası: Hukuk mesleği ve yargı seçiminde ideolojiyi tanıtma yönündeki partizan teşvikler." *Hukuk ve Ekonomi Dergisi* 60(4):559–595.
boyd, danah ve Kate Crawford. 2012. "Büyük veri için kritik sorular: Kültürel, teknolojik ve akademik bir fenomen için provokasyonlar." *Bilgi, İletişim & Toplum* 15(5):662–679.
Boyd-Graber, Jordan, David Mimno ve David Newman. 2014. "Konu Modellerinin Bakımı ve Beslenmesi: Problemler, Tanılamalar ve İyileştirmeler." *Karışık Üyelik Modelleri ve Uygulamaları El Kitabı*, ed. Edoardo M. Airoldi, David Blei, Elena A. Erosheva ve Stephen E. Fienberg. CRC Modern İstatistiksel Yöntemler El Kitapları Boca Raton, Florida: CRC Press.
Boyd-Graber, Jordan, Yuening Hu ve David Mimno. 2017. "Konu modellerinin uygulamaları." *Bilgi Elde Etme Temelleri ve Eğilimleri* 11(2-3):143–296.
Boydston, Michelle D. 1991. "Basın sansürü ve Pers Körfezi Savaşı sırasında erişim kısıtlamaları: Birinci Değişiklik analizi." *Loy. LAL Rev.* 25:1073.
Boydstun, Amber E. 2013. *Haberi Yapmak: Politika, Medya ve Gündem Belirleme*. Chicago Üniversitesi Yayınları.
Bradley, Margaret M. ve Peter J. Lang. 1999. "İngilizce kelimeler için duygusal normlar(ANEW): Kullanım kılavuzu ve duygusal derecelendirmeler." Teknik rapor C-1, psikofizyoloji araştırma merkezi.
Brandt, Patrick T., John R. Freeman ve Philip A. Schrodt. 2011. "Gerçek zamanlı, zaman serisi öngörüsü ile eyaletler arası ve içi siyasi çatışma." *Çatışma Yönetimi ve Barış Bilimi* 28(1):41–64.
Breiger, Ronald L., Robin Wagner-Pacifici ve John W. Mohr. 2018. "Yakalama metin verilerini işlerken ayrımlar: metin analizi için düşük teknolojili bir formalleşmeye doğru. *Şiirbilim* 68:104–119.
Broderick, Tamara, Brian Kulis ve Michael Jordan. 2013. "MAD-Bayes: MAP tabanlı asemptotik türevler Bayes'ten." In *Uluslararası Makine Öğrenimi Konferansı*.

Doclingo https://www.doclingo.ai

ss. 226–234.
Broniatowski, David A., Michael J. Paul ve Mark Dredze. 2013. “Ulusal ve yerel influenza gözetimi Twitter aracılığıyla: bir analiz 2012-2013 grip salgını.” *PloS One* 8(12):e83672.
Brown, Tom, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared D Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, Sandhini Agarwal, Ariel Herbert-Voss, Gretchen Krueger, Tom Henighan, Rewon Child, Aditya Ramesh, Daniel Ziegler, Jeffrey Wu, Clemens Winter, Chris Hesse, Mark Chen, EricSigler, Mat eusz Litwin, Scott Gray, Benjamin Chess, Jack Clark, Christopher Berner,Sam McCandlish, Al ec Radford, Ilya Sutskever, ve Dario Amodei. 2020. “DilModelleri Az Sayıda Örnekle Öğrenen lerdir.” In *Advances in Neural Information Processing Sistemler*, ed. H. Larochelle, M. Ranzato, R. Hadsell, M. F. Balcan ve H. Lin. Cilt. 33 Curran Associates, Inc. s. 1877–1901.
Budak, Ceren, Sharad Goel ve Justin M. Rao. 2016. “Adil ve dengeli mi? Medya yanlılığını kitle kaynaklı içerik analizi ile nicelleştirme.” *Kamuoyu Dergisi* 80(S1):250–271.
Buhrmester, Michael, Tracy Kwang ve Samuel D. Gosling. 2011. “Amazon’un Mechanical Turk: Uygun fiyatlı, ancak yüksek kaliteli, veri için yeni bir kaynak mı?” *Psikolojik Bil im Üzerine Perspektifler* 6(1):3–5.
Buolamwini, Joy ve Timnit Gebru. 2018. “Cinsiyet tonları: Ticari cinsiyet sınıflandırmasındaki kesişimsel doğruluk eşitsizlikleri.” *Adalet, Hesap Verebilirlik ve Şeffaflık Konferansı*. s. 77–91.
Burden, Barry ve Joseph Sanberg. 2003. “1952’den 2000’e başkanlık kampanyalarında bütçe retoriği.” *Siyasi Davranış* 25(2):97–118.
Burgess, Matthew, Eugenia Giraudy, Julian Katz-Samuels, Joe Walsh, Derek Wil lis,Lauren Haynes ve Rayid Ghani. 2016. “Yasal etki dedektörü: Eyalet yasala rında metin yeniden kullanımı bulma.” In *22. ACM SIGKDD Uluslararası Bilgi Keşfi ve Veri Madenciliği Konferansı*. s. 57–66.
Butler, Declan. 2013. “Google'un gripte yanıldığı zaman.” *Nature* 494(7436):155.
Caliskan, Aylin, Joanna J. Bryson ve Arvind Narayanan. 2017. “Dil korpuslarından ot omatik olarak türetilen anlamlar insan benzeri önyargılar içermektedir.” *Science* 356(6334):183–186.
Cameron, Charles M. 2000. *Veto Pazarlığı: Başkanlar ve Negatif Gücün Politikas ı*. Cambridge University Press.
Campbell, Rosie ve Philip Cowley. 2014. “Seçmenlerin istediği: Aday özelliklerine tepkiler bir anket deneyinde.” *Political Studies* 62(4):745–765.
Canes-Wrone, Brandice, David W Brady ve John F Cogan. 2002. “Adım adım, ofisten çıkmak : Seçim hesap verebilirliği ve Temsilciler Meclisi üyelerinin oylaması.” *American Political Science Review* 96(1):127–140.
Canon, David T. 1990. *Aktörler, Sporcular ve Astronotlar: Amerika Birleşik Devletleri Kongresi'nde ki Politik Amatörler*. University of Chicago Press.
Caporaso, James A. 1995. “İnceleme: Araştırma tasarımı, sahtecilik ve nitel-kanti tatif ayrım.” *American Political Science Review* 89(2):457–460.
Card, Dallas, Peter Henderson, Urvashi Khandelwal, Robin Jia, Kyle Mahowald ve Dan Jurafsky. 2020. “Az güçle büyük sorumluluk gelir.” In *Proceedings of the 2020 Doğal Dil İşleme (EMNLP) için Ampirik Yöntemler Konferansı*. Çevrimiçi: Hesaplamalı Dilbilim Derneği s. 9263–9274.

Doclingo https://www.doclingo.ai

Carley, Kathleen M. 1990. “İçerik analizi.” *Dil veDilbilim Ansiklopedisi* Press.

Carley, Kathleen M. 1997*a*. “Metin analizi yoluyla takım zihinsel modellerinin çıkarılması.” *Organizasyonel Davranış Dergisi* ss. 533–558.

Carley, Kathleen M. 1997*b*. “Ağ metin analizi: Kavramların ağ içindeki konumu.” *Sosyal Bilimler için Metin Analizi: Metinlerden ve Transkriptlerden İstatistiksel Çıkarım lar Yapma Yöntemleri*, ed. Carl W. Roberts. Routledge ss. 79–100.

Carlson, David ve Jacob M. Montgomery. 2017. “Siyasi metinlerin hızlı, esnek ve güvenil ir insan kodlaması için çift yönlü karşılaştırma çerçevesi.” *Amerikan Siyasi Bilimler D ergisi* 111(4):835–843.

Carnes, Nicholas. 2012. “Çalışan sınıfın kongrede sayısal olarak temsil edilmemesi önemli mi?” *Legislative Studies Quarterly* 37(1):5–34.

Catalinac, Amy. 2016*a*. *Seçim Reformu ve Ulusal Güvenlik Japonya'da: Domuz Etinden Dı ş Politika'ya*. Cambridge University Press.

Catalinac, Amy. 2016*b*. “Domuz etinden politikaya: Japon seçimlerinde programatik kampanyanın yükselişi.” *Siyaset Dergisi* 78(1):1–18.

Celebi, M. Emre, Hassan A. Kingravi ve Patricio A. Vela. 2013. “k-means kümeleme algorit ması için etkili başlatma yöntemlerinin karşılaştırmalı bir çalışması.” *Uzman Sistemler ile Uygulamalar* 40(1):200–210.

Chadefaux, Thomas. 2017. “Çatışma tahmini ve sınırları.” *Veri Bilimi* 1(1-2):7–17.

Chancellor, Stevie, Michael L. Birnbaum, Eric D. Caine, Vincent M.B. Silenzio ve Munmun De Choudhury. 2019. “Sosyal medyadan zihinsel sağlık durumları nı çıkarırken etik gerilimlerin bir taksonomisi.” *Adalet, Hesap Verebilirlik ve Şeffaflık Konferansı Bildirileri*. s. 79–88.

Chang, Charles ve Michael Masterson. 2020. “Siyasi metin sınıflandırmasında kelime sırasını kullanma” uzun kısa vadeli bellek modelleri ile.” *Siyasi Analiz* 28(3):395–411.

Chang, Jonathan, Sean Gerrish, Chong Wang, Jordan L. Boyd-Graber ve David M. Blei. 2009. “Çay yapraklarını okumak: İnsanların konu modellerini nasıl yorumladığı.” *Sinirsel Bil gi İşleme Sistemleri'nde İlerlemeler*. s. 288–296.

Chatman, Jennifer A. ve Francis J. Flynn. 2005. “Tam döngü mikro-organizasyon” davranış araştırması.” *Organizasyon Bilimleri* 16(4):434–447.

Chen, Jidong, Jennifer Pan ve Yiqing Xu. 2016. “Otoriterliğin kaynakları duyarlılık: Çin'de bir alan deneyi.” *Amerikan Siyasi Bilimler Dergisi* 60(2):383–400.

Chiba, Daina ve Kristian Skrede Gleditsch. 2017. “Gelecek şeylerin şekli?” Olay verileri ile iç savaş tahminleri için eşitsizlik ve şikayet modelini genişletmek. *Barış Araştırmaları Dergisi* 54(2):275–297.

Choi, Hyunyoung ve Hal Varian. 2012. “Google Trends ile mevcut durumu tahmin etme.” *Ekonomik Kayıt* 88(s1):2–9.

Chuang, Jason, Christopher D. Manning ve Jeffrey Heer. 2012. “Önemsiz kelimelerin ka rmaşası olmadan, metin görselleştirmesi için tanımlayıcı anahtar ifadeler.” *ACM İns an-Bilgisayar Etkileşimi Dergisi* 19(3):1–29.

Chuang, Jason, Margaret E. Roberts, Brandon M. Stewart, Rebecca Weiss, Dustin Tingley, Justin Grimmer ve Jeffrey Heer. 2015. “Konu Kontrolü: Etkileşimli Hizalama için Konu Modeli Kararlılığını Değerlendirme.” *2015 Kuzey Amerika Hesaplamalı Dilbilim Derneği Konferansı: İnsan Dili Teknolojileri* Bildirileri. Denver, Colorado: Hesaplamalı Dilbilim Derneği, s. 175–

Doclingo https://www.doclingo.ai

184.
Chung, Cindy ve James W. Pennebaker. 2007. “İşlevselkelimelerin psikolojik işl evleri.” *Sosyal İletişim* 1:343–359.
Citron, Daniel T. ve Paul Ginsparg. 2015. “Bir bilimsel korpus içindeki metin yeniden kullanım desenleri.” *Ulusal Bilimler Akademisi Bildirileri* 112(1):25–30.
Cleveland, William S. 1979. “Sağlam yerel ağırlıklı regresyon ve dağılım grafikleri.” *Amerikan İstatistik Birliği Dergisi* 74(368):829–836.
Clinton, Joshua, Simon Jackman ve Douglas Rivers. 2004. “Oylama verilerinin istatistik sel analizi.” *American Political Science Review* 98(02):355–370.
Cohen, Mark A., Roland T. Rust ve Sara Steen. 2004. “Amerika Birleşik Devletleri'nd e uygun hapis cezalarının algılarını ölçme, 2000. ICPSR versiyonu. Nashville, TN: Vanderbilt University, 2000.” *Ann Arbor, MI: Siyasi ve Sosyal Araştırmalar için Üniversiteler Arası Konsorsiyum*.
Cook, Samantha, Corrie Conrad, Ashley L. Fowlkes ve Matthew H. Mohebbi. 2011. “Amerika Birleşik Devletleri'nde Google grip eğilimleri performansını değerlendirme” 2009 influenza virüsü A (H1N1) pandemisi.” *PloS One* 6(8):e23610.
Corbin, Juliet ve Anselm Strauss. 1990. “Temellendirilmiş teori araştırması: Prosedürler, kanunlar ve değerlendirme kriterleri.” *Niteliksel Sosyoloji* 13(1):3–20.
Cranmer, Skyler J. ve Bruce A. Desmarais. 2017. “Tahminsel modellemeden ne öğ renebiliriz?” *Siyasi Analiz* 25(2):145–166.
Cunha, Evandro, Gabriel Magno, Marcos André Gonçalves, César Cambraia ve Virgilio Almeida. 2014. “O oyu mu yoksa o mu oy veriyor? Twitter politik etiketlerinde kadın ve erkek söylem stratejileri.” *PloS One*
Da, Nan Z. 2019. “Hesaplamalı edebiyat çalışmalarına karşı hesaplamalı bir dava.” *Eleştirel Sorgulama* 45(3):601–639.
D’Amour, Alexander, Peng Ding, Avi Feller, Lihua Lei ve Jasjeet Sekhon. 2021. “Yüksek boyutlu kovaryantlarla gözlemsel çalışmalardaki örtüşme.” *Ekonomet rik Dergisi* 221(2):644–654.
Danzger, M. Herbert. 1975. “Çatışma verilerini doğrulama.” *Amerikan Sosyolojik Dergisi* 40(5):570–584.
Dawid, Alexander Philip ve Allan M. Skene. 1979. “EM algoritmasını kullanarak gözlemc i hata oranlarının maksimum olasılık tahmini.” *Kraliyet İstatistik Derneği Dergisi: Seri C (Uygulamalı İstatistik)* 28(1):20–28.
De Choudhury, Munmun, Michael Gamon, Scott Counts ve Eric Horvitz. 2013. “Sosyal medya aracılığıyla depresyonu tahmin etme.” *Uluslararası AAAI Ko nferansı Web ve Sosyal Medya* 7(1).
Deerwester, Scott, Susan T. Dumais, George W. Furnas, Thomas K. Landauer ve RichardHarshman. 1990. “Gizli anlamsal analiz ile dizinleme.” *Amerikan Bilg i Bilimi Derneği Dergisi* 41(6):391.
Dempster, Arthur P., Nan M. Laird ve Donald B. Rubin. 1977. “Eksik verilerden maksimum olasılık EM algoritması aracılığıyla.” *Kraliyet İstatistik Derneği Dergisi: Seri B (Metodolojik)* 39(1):1–22.
Denny, Matthew J. ve Arthur Spirling. 2018. “Denetimsiz öğrenme için metin ön işle me: neden önemlidir, ne zaman yanıltır ve bununla ne yapmalıyız.” *Siyasi Analiz* 26(2):168–189.
Devlin, Jacob, Ming-Wei Chang, Kenton Lee ve Kristina Toutanova. 2019. “BER T: Dil anlayışı için derin iki yönlü dönüştürücülerin ön eğitimi.” *Proceedings*

Doclingo https://www.doclingo.ai

Konferansı 2019 Kuzey Amerika Bölümü Derneği için Hesaplamalı Dilbilim: İnsan Dili Teknolojileri, Cilt 1 (Uzun ve Kısa Makaleler). Minneapolis, Minnesota: Hesaplamalı Dilbilim Derneği, s. 4171–4186.

Diermeier, Daniel, Jean-François Godbout, Bei Yu ve Stefan Kaufmann. 2012. "Kongrede Dil ve İdeoloji." *Britanya Siyasi Bilim Dergisi* 42(1):31–55.

Dietrich, Bryce ve Melissa Sands. Tarih yok. "Kamu Video Akışlarını Kullanarak Gruplarar ası Maruziyeti Anlamak." Teknik rapor Iowa Üniversitesi.

Dietrich, Bryce J., Ryan D Enos ve Maya Sen. 2019. "Duygusal uyarılma, ABD yüksek mahkem esinde oy vermeyi tahmin eder." *Siyasi Analiz* 27(2):237–243.

Difallah, Djellel, Elena Filatova ve Panos Ipeirotis. 2018. "Mekanik Turk işçilerinin demografisi ve dinamikleri." On Birinci ACM Uluslararası Web Arama ve Veri Madenciliği Konferansı Bildirileri'nde. s. 135–143.

DiMaggio, Paul. 2015. "Sosyal bilime (ve tersine) hesaplamalı metin analizini uyarlam ak." *Büyük Veri & Toplum* 2(2):1–5.

DiMaggio, Paul, Manish Nag ve David Blei. 2013. "Konu modelleme ile kültür üzerine sos yolojik bakış açısı arasındaki yakınlıkları kullanmak: ABD hükümetinin sanat finansma nına dair gazete kapsamına uygulama." *Poetics* 41(6):570–606.

Dodds, Peter Sheridan, Kameron Decker Harris, Isabel M. Kloumann, Catherine A. Bli ss ve Christopher M. Danforth. 2011. "Küresel bir sosyal ağda mutluluk ve bilgiye dair zamansal kalıplar: Hedonometrik ve Twitter." *PloS One* 6(12):e26752.

D'Orazio, Vito, Steven T. Landis, Glenn Palmer ve Philip Schrodt. 2014. "Buğdayı arp adan ayırmak: Destek vektör makineleri kullanarak otomatik belge sınıflandırma uygulamaları." *Siyasi Analiz* 22(2):224–242.

Downs, Anthony. 1957. "Bir demokraside siyasi eylemin ekonomik teorisi." *Politik Ekonomi Dergisi* pp. 135–150.

Duncan, Otis Dudley. 1984. *Sosyal Ölçüm Üzerine Notlar: Tarihsel ve Eleştirel*. Russell Sage Vakfı.

Duneier, Mitchell. 1999. *Kaldırım*. Macmillan.

Duneier, Mitchell. 2016. *Getto: Bir Yerinin İcadı, Bir Fikrinin Tarihi*. Macmillan.

Efron, Bradley ve Gail Gong. 1983. "Bootstrap, jackknife ve çapraz doğrulama üzerine r ahat bir bakış." *Amerikan İstatistikçisi* 37(1):36–48.

Egami, Naoki, Christian J. Fong, Justin Grimmer, Margaret E. Roberts ve Brandon M. Stewart. 2018. "Metinler kullanarak nedensel çıkarımlar nasıl yapılır." *arXiv ön baskısı arXiv:1802.02163*.

Eichstaedt, Johannes C., Hansen Andrew Schwartz, Margaret L. Kern, Gregory Park, Darwin R. Labarthe, Raina M. Merchant, Sneha Jha, Megha Agrawal, Lukasz A. Dziurzynski, Maarten Sap, Christopher Weeg, Emily E. Larson, Lyle H. Ungar, veMa rtin E.P. Seligman. 2015. "Twitter'daki psikolojik dil, ilçe düzeyindekalp hastalığı öl üm oranını tahmin ediyor." *Psikolojik Bilim* 26(2):159–169.

Eisenstein, Jacob. 2019. *Doğal Dil İşleme'ye Giriş*. MIT press.

Eisenstein, Jacob, Amr Ahmed, ve Eric P. Xing. 2011. "Metinlerin seyrek eklemeli üretken modelleri." In *28. Uluslararası Makine Öğrenimi Konferansı Tutanakları*. Omnipress s. 1041–1048.

Eisenstein, Jacob, Brendan O'Connor, Noah A. Smith ve Eric P. Xing. 2010. "Coğrafi leksi kal varyasyon için gizli bir değişken modeli." In *Proceedings of the 2010 Conference*

Doclingo https://www.doclingo.ai

on Empirical Methods in Natural Language Processing. Association for Computational Linguistics s. 1277–1287.

Elkan, Charles. 2006. “Dirichlet bileşik çoklu dağılımının üstel aile yaklaşımı ile belgeleri kümeleme.” In *Proceedings of the 23rd International Conference on Machine Learning*. ACM s. 289–296.

Elwert, Felix ve Christopher Winship. 2014. “Endojen seçim yanlılığı: Bir çarpan değişke nine koşullandırma problemi.” *Annual Review of Sociology* 40:31–53.

Ensign, Danielle, Sorelle A. Friedler, Scott Neville, Carlos Scheidegger ve Suresh Venkatasubramanian. 2018. “Tahmine dayalı polislikte kaçak geri bildirim döngüleri.” In *Conference on Fairness, Accountability and Transparency*. s. 160–171.

Eshbaugh-Soha, Matthew. 2010. “Yerel başkanlık haber kapsamının tonu.” *Political Communication* 27(2):121–140.

Eshima, Shusei, Kosuke Imai ve Tomoya Sasaki. 2020. “Anahtar kelime destekli konu modelleri.” *arXiv ön baskısı arXiv:2004.05964*.

Evans, James A ve Pedro Aceves. 2016. “Makine çevirisi: Metni sosyal teori için maden cilik.” Annual Review of Sociology 42:21–50.

Faruqui, Manaal, Jesse Dodge, Sujay Kumar Jauhar, Chris Dyer, Eduard Hovy ve Noah A. Smith. 2015. “Kelime vektörlerini anlamsal sözlüklerle yeniden uyarlama.” In *Proceedings of the 2015 Kuzey Amerika Hesaplama Dilbilimi Derneği Konferansı: İnsan Dili Tek nolojileri*. Denver, Colorado: Hesaplama Dilbilimi Derneği s. 1606–1615.

Faruqui, Manaal, Yulia Tsvetkov, Pushpendre Rastogi ve Chris Dyer. 2016. “Kelime Benzerliği Görevleri ni Kullanarak Kelime Gömme Değerlerinin Değerlendirilmesi ile İlgili Problemler.” In *Proceedings o fthe 1. Atölye, NLP için Vektör Alan Temsillerini Değerlendirme üzerine. Berlin,* Almanya: Hesaplamalı Dilbilim Derneği s. 30–35.

Feinerer, Ingo, Kurt Hornik ve David Meyer. 2008. “R'de metin madenciliği altyapısı.” *İstatistik Yazılımları Dergisi* 25(5):1–54.

Fenno, Richard F. 1978. *Ev Tarzı: Temsilciler Meclisi Üyeleri Bölgesinde*. HarperCollins.

Ferrara, Emilio, Onur Varol, Clayton Davis, Filippo Menczer ve Alessandro Flammini. 2016. “Sosyal botların yükselişi.” *ACM İletişimleri* 59(7):96–104.

Finkelstein, Lev, Evgeniy Gabrilovich, Yossi Matias, Ehud Rivlin, Zach Solan, GadiWolfman ve Eytan Ruppin. 2001. “Aramayı bağlamda yerleştirmek: Kavramın yeniden gözden geçirilm esi.”In *Dünya Çapında Web Üzerine 10. Uluslararası Konferansın Bildirileri*. s. 406–414.

Firth, John Rupert. 1957. *Dilsel Analiz Üzerine Çalışmalar*. Wiley-Blackwell.

Flood, Barbara J. 1999. “Tarihi not: Biyolojik Özetler'de bir durdurma listesinin başlangıcı.” *Bilgi Bilimi ve Teknolojisi Derneği Dergisi* 50(12):1066.

Fong, Christian ve Justin Grimmer. 2016. “Metin korpuslarından tedavi keşfi.” In *Derleme 54. Yıllık Hesaplamalı Dilbilim Derneği Toplantısı (Cilt 1: Uzun Makaleler)*. Cilt 1 s. 1600–1609.

Fong, Christian ve Matthew Tyler. 2020. “Makine öğrenimi tahminleri regresyon kovaryatları olarak.” *Siyasi Analiz* s. 1–18.

Fong, Christian J. ve Justin Grimmer. 2021. “Gizli Tedaviler ile Nedensel Çıkarım.” *Stanford Üniversitesi Mimeo*.

Forgy, Edward W. 1965. “Çok değişkenli verilerin küme analizi: Verimlilik ile sınıflandırmaların yorumlanabilirliği.” *Biometrics* 21:768–769.

Fort, Karën, Gilles Adda ve K Bretonnel Cohen. 2011. “Amazon Mechanical Turk: Altınmadeni mi y oksa kömür madeni mi?” *Computational Linguistics* 37(2):413–420.

Doclingo https://www.doclingo.ai

Foulds, James ve Padhraic Smyth. 2014. “Konu modellerinin değerlendirilmesi içi n tavlama yolları.” In *Yapay Zeka'da Belirsizlik Üzerine Otuzuncu Konferansın Bildirileri*. UAI’14 Arlington, Virginia, ABD: AUAI Press s. 220–229.

Fowler, Anthony ve B. Pablo Montagnes. 2015. “Kolej futbolu, seçimler ve gözle msel araştırmalardaki yanlış pozitif sonuçlar.” *Ulusal Bilimler Akademisi Bildi rileri* 112(45):13800–13804.

Fraley, Chris ve Adrian Raftery. 2002. “Model tabanlı kümeleme, ayrım analizi ve yoğunluk tahmini.” *Amerikan İstatistik Derneği Dergisi* 97(458):611.

Franco, Annie, Justin Grimmer ve Chloe Lim. 2018. “Başkanlık çağrılarının sınırlı etki si.” Çalışma Raporu Stanford Üniversitesi.

Frantzi, Katerina, Sophia Ananiadou ve Hideki Mima. 2000. “Çok kelimeli terimlerin otom atik tanınması: C-değeri/NC-değeri yöntemi.” *Dijital Kütüphaneler Üzerine Uluslarara sı Dergi* 3(2):115–130.

Franzosi, Roberto. 1989. “Kelimelerden sayılara: Metin verilerini toplamak için genelleştiril miş ve dilbilgisine dayalı bir kodlama prosedürü.” *Sosyolojik Metodoloji* 19:263–298.

Franzosi, Roberto. 2004. *Kelimelerden Sayılara: Anlatı, Veri ve Sosyal Bilim*. Cambridge Üniversitesi Yayınları.

Frey, Brendan J. ve Delbert Dueck. 2007. “Veri noktaları arasında mesajlar ile geçiş yaparak kü meleme.” *Science* 315(5814):972–976.

Gan, Zhe, Changyou Chen, Ricardo Henao, David Carlson ve Lawrence Carin. 2015. “Konu modelleme için ölçeklenebilir derin Poisson faktör analizi.” In *International Conference on Machine Learning*. s. 1823–1832.

Ganitkevitch, Juri, Benjamin Van Durme ve Chris Callison-Burch. 2013. “PPDB: Par afraz veritabanı.” In *Proceedings of the 2013 Conference of the North America nChapter of the Association for Computational Linguistics: Human LanguageT echnologies*. s. 758–764.

Garg, Nikhil, Londa Schiebinger, Dan Jurafsky ve James Zou. 2018. “Kelime gömme yöntemleri 100 yıl boyunca cinsiyet ve etnik stereotipleri nicelendiriyor.” *Proceedings of the National Academy of Sciences* 115(16):E3635–E3644.

Gava, Roy, Julien M. Jaquet ve Pascal Sciarini. 2021. “Yasa yapmak mı yoksa onaylamak mı? Metin yeniden kullanımı ile parlamentonun yasa yapma üzerindeki etkisini değerlendirme.” *European Journal of Political Research* 60:175–198.

Gelman, Andrew, John B. Carlin, Hal S. Stern, David B. Dunson, Aki Vehtari ve Donald B. Rubin. 2013. *Bayesian Data Analysis*. CRC press.

Gentzkow, Matthew, Bryan Kelly ve Matt Taddy. 2019. “Veri olarak metin.” *Ekonomi L iteratürü Dergisi* 57(3):535–74.

Gentzkow, Matthew ve Jesse M. Shapiro. 2010. “Medya eğilimini ne yönlendirir? ABD günlü k gazetelerindenkanıt.” *Econometrica* 78(1):35–71.

Gentzkow, Matthew, Jesse M. Shapiro ve Matt Taddy. 2019. “Grubu ölçmek yüksek boyutlu seçimlerdeki farklılıklar: Yöntem ve kongrekonuşmalarına uygul ama.” *Econometrica* 87(4):1307–1340.

Gerber, Alan S. ve Donald P. Green. 2012. *Alan Deneyleri: Tasarım, Analiz ve Yorumlama*. WW Norton.

Gerring, John ve Craig W. Thomas. 2005. “Karşılaştırılabilirlik: Araştırma tasarımında öneml i bir konu.” *Kavramlar ve Yöntemler Komitesi. Çalışma Raporu Serisi* 4:1–20.

Gerrish, Sean ve David M. Blei. 2011. “Metinden yasama oylamalarını tahmin etme.” İçinde *28. Uluslararası Makine Öğrenimi Konferansı Bildirileri*. s. 489–496.

Doclingo https://www.doclingo.ai

Gerrish, Sean ve David M. Blei. 2012. “Nasıl oy veriyorlar: Konu ayarlı modelleri yasama davranışı.” *Sinirsel Bilgi İşleme Sistemlerinde*. s. 2753–2761.

Gill, Michael ve Andrew B Hall. 2015. “Yargı kimliğinin hukukikarar metnini nasıl değiştirdiği.” Çalışma Raporu Stanford Üniversitesi.

Gill, Michael ve Arthur Spirling. 2015. “WikiLeaks'in ABD diplomatik belgeleri ifşasının ciddiyetini tahmin etme.” *Siyasi Analiz* 23(2):299–305.

Gillion, Daniel Q. 2016. *Kelimelerle Yönetmek: Amerika'da Irk, Kamu Politikası ve Eşitsizlik Üzerine Siyasi Diyalog*. Cambridge University Press.

Gimpel, Kevin, Nathan Schneider, Brendan O'Connor, Dipanjan Das, Daniel Mills, Jacob Eisenstein, Michael Heilman, Dani Yogatama, Jeffrey Flanigan ve Noah A. Smith. 2011. “Twitter için sözcük türü etiketleme: Notasyon, özellikler ve deneyler.” In *Derleme 49. Yıllık Toplantı, Hesaplamalı Dilbilim Derneği Dil Teknolojileri: Kısa Makaleler - Cilt 2*. HLT '11 ABD: Hesaplamalı Dilbilim Derneği s. 42–47.

Ginsberg, Jeremy, Matthew H. Mohebbi, Rajan S. Patel, Lynnette Brammer, Mark S. Smolinski ve Larry Brilliant. 2009. “Arama motoru sorgu verilerini kullanarak grip salgınlarını tespit etme.” *Nature* 457(7232):1012.

Glaser, Barney G. 2002. “Kavramlaştırma: Temellendirilmiş teori kullanarak teori ve teorileştirme üzerine.” *Uluslararası Niteliksel Yöntemler Dergisi* 1(2).

Glaser, Barney G. ve Anselm L. Strauss. 1967. *Temellendirilmiş Teori'nin Keşfi: Kalitatif Araştırma Stratejileri*. New York: Aldine De Gruyter.

Goel, Sharad, Jake M. Hofman, Sébastien Lahaie, David M. Pennock ve Duncan J. Watts. 2010. “Tüketici davranışını Web araması ile tahmin etme.” *Ulusal Bilimler Akademisi Bildirileri* 107(41):17486–17490.

Goertz, Gary. 2008. “Kavramlar, teoriler ve sayılar: Oluşturma için bir kontrol listesi değerlendirme ve kavramları veya nicel ölçümleri kullanma.” *The Oxford Handbook of Political Methodology*, der. J.M. Box-Steffensmeier, H.E. Brady ve D. Collier. Oxford University Press.

Goffman, Erving. 1959. *Gündelik Hayatta Kendini Sunma*. Doubleday.

Golder, Scott A. ve Michael W. Macy. 2011. “Günlük ve mevsimsel ruh hali, çeşitli kültürlerde iş, uyku ve gün uzunluğuna göre değişir.” *Science* 333(6051):1878–1881.

Goodfellow, Ian, Yoshua Bengio ve Aaron Courville. 2016. *Derin Öğrenme*. MIT Press.

Goodman, Bryce ve Seth Flaxman. 2017. “Algoritmik karar verme üzerine Avrupa Birliği düzenlemeleri ve bir 'açıklama hakkı'.” *AI Magazine* 38(3):50–57.

Granato, Jim ve Frank Scioli. 2004. “Bulmacalar, atasözleri ve omega matrisleri: The teorik modellerin ampirik sonuçlarının bilimsel ve sosyal önemi (EITM).” *Siyaset Üzerine Perspektifler* 2(2):313–323.

Griffiths, Thomas L. ve Mark Steyvers. 2004. “Bilimsel konuları bulmak.” *Ulusal Bilimler Akademisi Bildirileri* 101(suppl 1):5228–5235.

Griffiths, Thomas L. ve Zoubin Ghahramani. 2011. “Hindistan büfesi süreci: Bir giriş ve inceleme.” *Makine Öğrenimi Araştırmaları Dergisi* 12(Nisan):1185–1224.

Grimmer, Justin. 2010. “Siyasi metinler için Bayesyen hiyerarşik konu modeli: Senato basın bültenlerinde ifade edilen gündemleri ölçme.” *Siyasi Analiz* 18(1):1–35.

Grimmer, Justin. 2013*a*. “Temsilciler değil pozisyon alanlar: Seçim teşviklerinin kongre temsilindeki çarpıtıcı etkileri.” *Amerikan Siyasi Bilimler Dergisi* 57(3):624–642.

Doclingo https://www.doclingo.ai

Grimmer, Justin. 2013*b*. *Kongrede Temsil Tarzı: Yasama Organlarının Ne Dediği ve Ne den Önemli*. Cambridge University Press.
Grimmer, Justin ve Brandon M. Stewart. 2013. "Veri olarak metin: Siyasi metinler için ot omatik içerik analizi yöntemlerinin vaatleri ve tuzakları." *Siyasi Analiz* 21(3):267–297.
Grimmer, Justin ve Gary King. 2011. "Genel amaçlı bilgisayar destekli kümeleme ve kavramlaştırma." *Ulusal Bilimler Akademisi Bildirileri* 108(7):2643–2650.
Grimmer, Justin, Margaret E Roberts ve Brandon M Stewart. 2021. "Sosyal Bilimler içi n Makine Öğrenimi: Agnostik Bir Yaklaşım." *Siyasi Bilim Yıllık İncelemesi* 24.
Grimmer, Justin, Sean J. Westwood ve Solomon Messing. 2014. *Etki İzlenimi: Y asama İletişimi, Temsil ve Demokratik Hesap Verebilirlik*. Princeton Üniversitesi Yayınları.
Grün, Bettina ve Kurt Hornik. 2011. "topicmodels: Konu modelleri için bir R pa keti." *İstatistiksel Yazılım Dergisi* 40(13):1–30.
Gueorguiev, Dimitar D. ve Edmund J. Malesky. 2019. "Çin'de Danışma ve Seçici sansür." *Siyaset Dergisi* 81(4):1539–1545.
Gup, Ted. 2008. *Gizemler Ülkesi: Demokrasiye ve Amerikan Yaşam Tarzına Teh dit*. Anchor.
Hainmueller, Jens, Daniel J. Hopkins ve Teppei Yamamoto. 2014. "Birlikte analiz de nedensel çıkarım: Çok boyutlu seçimleri belirtilen tercih deneyleri aracılığı yla anlama." *Siyasi Analiz* 22(1):1–30.
Halterman, Andrew. 2017. "Mordecai: Tam metin coğrafi ayrıştırma ve olay coğrafi kodlama." *A çık Kaynak Yazılım Dergisi* 2(9):91.
Halterman, Andrew. 2019. "Metinlerde siyasi olayları coğrafi olarak belirleme." I n *Doğal Dil İşleme ve Hesaplamalı Sosyal Bilimler Üçüncü Atölyesi Bildirileri*. Minneapolis, Minnesota: Hesaplamalı Dilbilim Derneği s. 29–39.
Halterman, Andy. 2020. "Metinden siyasi olayları sözdizimi ve anlamlar." Teknik rapor MIT.
Handler, Abram, Matthew Denny, Hanna Wallach ve Brendan O'Connor. 2016. "Torbane? Metin analizi için basit isim öbeği çıkarımı." *NLP ve Hesaplamalı Sosyal Bilimler Üzerine İlkAtölye Çalışmaları*. Austin, Texas: Hesaplamalı Dil bilim Derneği, s. 114–124.
Harford, Tim. 2014. "Büyük veri: Büyük bir hata mı?" *Önem* 11(5):14–19.
Hart, R.P. 2000. *Diction 5.0: Metin Analiz Programı*. Thousand Oaks, CA: Sage-Scolari.
Hartigan, John A. ve Manchek A. Wong. 1979. "Algoritma AS 136: K-ortalama kümeleme algoritması." *Kraliyet İstatistik Derneği Dergisi. Seri C (Uygulamalı İstatistik)* 28(1):100–108.
Hastie, Trevor, Robert Tibshirani ve Jerome Friedman. 2013. *İstatistiksel Öğrenmenin Un surları*. Springer.
Healy, Andrew J., Neil Malhotra ve Cecilia Hyunjung Mo. 2010. "İlgisiz olaylar, seçm enlerin hükümet performansını değerlendirmelerini etkiler." *Ulusal Bilimler Aka demisi Bildirileri* 107(29):12804–12809.
Hernán, Miguel A. ve James M. Robins. 2020. *Nedensel Çıkarım: Ne Olursa*. Chapman & Hall/CRC.
Herrera, Yoshiko M. ve Devesh Kapur. 2007. "Veri kalitesini artırma: Aktörler, teşvikler,

Doclingo https://www.doclingo.ai

ve yetenekler." *Politik Analiz* ss. 365–386.
Hertel-Fernandez, Alexander. 2019. *Eyalet Ele Geçirme: Nasıl Muhafazakâr Aktivistler, Büyük İşletmeler ve Zengin Bağışçılar Amerikan Eyaletlerini ve Ulusunu Yeniden Şekillendirdi*. Oxford University Press, ABD.
Hertel-Fernandez, Alexander ve Konstantin Kashin. 2015. "Metin yeniden kullanımı ile eyaletler genelinde iş gücünü ele geçirmek." *Orta Batı Siyasi Bilimler Derneği Yıllık K onferansı, Chicago, Nisan*. ss. 16–19.
Hinton, Geoffrey E. 1986. "Kavramların dağıtılmış temsillerini öğrenme." *İnsan Bilimleri Derneği'nin Sekizinci Yıllık Konferansı Bildirileri*. Cilt 1 Amherst, MA s. 12.
Hofman, Jake M., Amit Sharma ve Duncan J. Watts. 2017. "Sosyal sistemlerde tahmin ve açıklama . *Bilim* 355(6324):486–488.
Hofmann, Thomas. 1999. "Olasılıksal gizli anlamsal analiz." In *Yapay Zeka'da Belirsizlik Üzerine On Beşinci Konferansın Bildirileri*. Morgan Kaufmann Yay ıncıları Inc. s. 289–296.
Hollanda, Paul W. 1986. "İstatistikler ve nedensel çıkarım." *Amerikan Dergisi İstatistiksel Dernek* 81:945–960.
Hopkins, Daniel J. ve Gary King. 2010. "Sosyal bilimler için otomatik parametrik olmaya n içerik analizi yöntemi." *American Journal of Political Science* 54(1):229–247.
Ev, Özgürlük. 2015. *İnternette Özgürlük 2015: Sansürü Özelleştirmek, Aşındırmak Gizlilik*. Freedom House.
Hu, Yuening, Jordan Boyd-Graber, Brianna Satinoff ve Alison Smith. 2014. "Etkileşimli topik modelleme." *Makine Öğrenimi* 95(3):423–469.
Huang, Haifeng. 2015. "Propaganda olarak sinyal verme." *Karşılaştırmalı Politika* 47(4):419–444.
Huff, Connor ve Dustin Tingley. 2015. "Bu insanlar kim?" MTurk anket katılımcılarının demografik özelliklerini ve politik tercihlerini değerlendirme." *Araştırma & Politika* 2(3):1–12.
Humphreys, Macartan, Raul Sanchez de la Sierra ve Peter Van der Windt. 2013. "Balık tutma, taahhüt ve iletişim: Kapsamlı bağlayıcı olmayan araştırma kaydı için bir öneri." *Politik Analiz* 21(1):1–20.
Hvitfeldt, Emil ve Julia Silge. 2021. *Metin Analizi için R'de Denetimli Makine Öğrenimi*. CRC Basın.
Imai, Kosuke ve Marc Ratkovic. 2013. "Rastgele program değerlendirmesinde tedavi et kisi heterojenliğini tahmin etme." *Uygulamalı İstatistik Dergisi* 7(1):443–470.
Imbens, Guido W. ve Donald B. Rubin. 2015. *İstatistik, Sosyal veBiyomedikal Bilimlerde Nedensel Çıkarım*. Cambridge University Press.
Jacobs, Abigail Z. ve Hanna Wallach. 2021. "Ölçüm ve adalet." In *Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency*. s. 375–385.
Jaidka, Kokil, Alvin Zhou ve Yphtach Lelkes. 2019. "Kısalık Twitter'ın ruhudur: Kı sıtlama, olanak ve politik tartışma." *İletişim Dergisi* 69(4):345–372.
Jansa, Joshua M., Eric R. Hansen ve Virginia H. Gray. 2019. "Kopyala ve yapıştır yasama: Eyaletlerde yasama profesyonelliği ve politika yeniden icadı." *Amerikan Siyaset Araştırması* 47(4):739–767.
Jaros, Kyle ve Jennifer Pan. 2018. "Çin'in haber yapıcıları: Resmi medya kapsamı ve Xi Ji nping dönemi siyasi değişimleri." *The China Quarterly* 233:111–136.

Doclingo https://www.doclingo.ai

Jerzak, Connor T., Gary King ve Anton Strezhnev. 2019. “Sosyal bilimler için otomatik parametrik olmayan içerik analizi için geliştirilmiş bir yöntem.” Yakında *Political Analiz*.

Joachims, Thorsten. 1998. “Destek vektör makineleri ile metin kategorilendirme: Birçok ilgili özellik ile öğrenme.” *Avrupa Makine Öğrenimi Konferansı*. Springers. 137–142.

Jockers, Matthew L. 2013. *Makroanaliz: Dijital Yöntemler ve Edebi Tarih*. Illinois Üniversitesi Yayınları.

Jones, Bryan, John Wilkerson, ve Frank Baumgartner. 2009. “Politika Gündemleri Projesi.” http://www.policyagendas.org.

Jursfsky, Dan ve James Martin. 2009. *Konuşma ve Doğal Dil İşleme: Doğal Dil İşleme, Hesaplamalı Dilbilim ve Konuşma Tanıma Giriş.* Upper Saddle River : Prentice Hall.

Justeson, John S. ve Slava M. Katz. 1995. “Teknik terminoloji: Bazı dilbilgisel ö zellikler ve metin içinde tanımlama için bir algoritma.” *Doğal Dil Mühendisliği* 1(1):9–27.

Kalla, Joshua L. ve David E. Broockman. 2018. “Genel seçimlerde kampanya te masının minimal ikna edici etkileri: 49 saha deneyinden kanıt.” *Siyasal Bilimler Dergisi* 112(1):148–166.

Kang, Jun Seok, Polina Kuznetsova, Michael Luca ve Yejin Choi. 2013. “Nerede yemek ye memeli? Çevrimiçi incelemeleri kullanarak hijyen denetimlerini tahmin ederek kamu politikasını iyileştirmek.”In *2013 Doğal Dil İşleme Üzerine Ampirik Yöntemler Konfera nsı Bildirileri*. s. 1443–1448.

Karell, Daniel ve Michael Freedman. 2019. “Radikalizmin Retorikleri.” *Amerikan Sosyolojik İnceleme* 84(4):726–753.

Kaufman, Aaron Russell, Peter Kraft ve Maya Sen. 2019. “Güçlendirilmiş karar ağaçları kullan arak Yüksek Mahkeme tahminlerini geliştirme.” *Siyasi Analiz* 27(3):381–387.

Keith, Katherine, Abram Handler, Michael Pinkham, Cara Magliozzi, Joshua McDuffie, v ve Brendan O’Connor. 2017. “Polis tarafından öldürülen sivil kişileri uzaktan denetimli varlık-olay çıkarımı ile tanımlama.” In *Proceedings of the 2017 Konferans hakkında Doğal Dil İşleme'deki Ampirik Yöntemler*. s. 1547–1557.

Keith, Katherine, David Jensen ve Brendan O’Connor. 2020. “Metin ve nedensel çıkarım: “Karmaşık etkileri nedensel tahminlerden çıkarmak için metin kullanımı üzerine bir inceleme.” *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*. Association for Computational Linguistics s. 5332–5344.

Kellstedt, Paul. 2000. “Medya çerçeveleme ve ırksal politika tercihlerinin dinamikleri.” *Amerikan Siyasi Bilimler Dergisi* 44(2):245–260.

Khan, Mohammad Emtiyaz ve Guillaume Bouchard. 2009. “Korelasyonlu konu modelleri içi n Varyasyonel EM algoritmaları.” Teknik rapor British Columbia Üniversitesi.

Khodak, Mikhail, Nikunj Saunshi, Yingyu Liang, Tengyu Ma, Brandon M. Stewart ve Sanje ev Arora. 2018. “A la carte embedding: Ucuz ama etkili anlamsal özellik vektörlerinin i ndüksiyonu.” In *Proceedings of the 56th Annual Meeting of the Association for Comp utational Linguistics (Volume 1: Long Papers)*. Melbourne, Avustralya: Association for Computational Linguistics s. 12–22.

Kim, In Song, John Londregan ve Marc Ratkovic. 2018. “Oylardan ve metinden ideal noktaları n tahmin edilmesi.” *Siyasi Analiz* 26(2):210–229.

King, G., R.O. Keohane, ve S. Verba. 1994. *Sosyal Araştırma Tasarımı: Bilimsel*

Doclingo https://www.doclingo.ai

Kalitatif Araştırmada Çıkarım. Princeton University Press.
King, Gary. 2009. "Sosyal bilim araştırmalarının değişen kanıt temeli." In *Siyaset Bili minin Geleceği: 100 Perspektif*, ed. Gary King, Kay Schlozman, ve Norman Nie. N ew York: Routledge Press.
King, Gary ve Will Lowe. 2003. "Otomatik bir bilgi çıkarım aracı için insan kodlayıcılar kadar iyi performans gösteren uluslararası çatışma verileri: Nadir olaylar evaluation design." *Uluslararası Organizasyon* 57(3):617–642.
King, Gary ve Ying Lu. 2008. "Birden fazla ölüm nedeni ile sözlü otopsi yöntemleri." *İstatistik Bilimi* 23(1):78–91.
King, Gary, Jennifer Pan ve Margaret E. Roberts. 2013. "Çin'deki sansürün hükümet eleştirisine nasıl izin verdiği ancak toplu ifadeyi nasıl susturduğu." *Amerikan Siyasi Bilimler Dergisi* 107(2):1–18.
King, Gary, Jennifer Pan ve Margaret E. Roberts. 2014. "Çin'deki sansürü tersine mühendislik yöntemiyle incelemek: Rastgele deney ve katılımcı gözlem." *Bilim* 345(6199):1251722–1251722.
King, Gary, Jennifer Pan ve Margaret E. Roberts. 2017. "Çin hükümetinin sosyal medya paylaşımlarını stratejik dikkat dağıtımı için nasıl uydurduğu, katılımcı tartışma değil." *Amerikan Siyasi Bilimler Dergisi* 111(3):484–501.
King, Gary, Patrick Lam ve Margaret E. Roberts. 2017. "Yapılandırılmamış metinden bilgis ayar destekli anahtar kelime vedoküman seti keşfi." *Amerikan Siyasi Bilimler Dergisi* 61(4):971–988.
Kiros, Ryan, Yukun Zhu, Russ R. Salakhutdinov, Richard Zemel, Raquel Urtasun, Antonio Torralba ve Sanja Fidler. 2015. "Atla-düşün vektörleri." *Sinirsel Bilgi İşleme Sistemleri* 28:3294–3302.
Kittur, Aniket, Ed H. Chi ve Bongwon Suh. 2008. "Mechanical Turk ile kullanıcı ç alışmalarıkitle kaynak kullanımı." In *İnsan Faktörleri Konferansı'nın SIGCHI Konferansı'nda* . ACM s. 453–456.
Knox, Dean ve Christopher Lucas. 2021. "Sosyal bilimler için dinamik bir konuşma m odeli." *American Political Science Review* 115(2):649–666.
Koehn, Philipp, Franz Josef Och ve Daniel Marcu. 2003. "İstatistiksel ifade tabanlı çevrimi." *2003 Kuzey Amerika Bölümü Konferansı'nda Hümanist Dil Teknolojileri Üzerine— Cilt 1*. Hesaplamalı Dilbilim Derneği, s. 48–54.
Kogan, Shimon, Dimitry Levin, Bryan R. Routledge, Jacob S. Sagi ve Noah A. Smith. 2009. "Finansal raporlardan risk tahmini yapmak için regresyon." In *Proceedings of Human Language Technologies: The 2009 Annual Conference of the North American Chapter of the Association for Computational Linguistics*. Association for Computational Linguistics pp. 272–280.
Kozlowski, Austin C., Matt Taddy ve James A. Evans. 2019. "Kültürün geometrisi: Sınıfın anlamlarını kelime gömme yoluyla analiz etmek." *Amerikan Sosyolojik Derlemesi* 84(5):905–949.
Kraft, Peter, Hirsh Jain ve Alexander M. Rush. 2016. "Bir gömme modeli için oylama oylarını tahmin etmek." *İşlemler 2016 Ampirik Konferansı Doğal Dil İşleme Yöntemleri*. s. 2066–2070.
Krehbiel, Keith. 1990. "Kongre komiteleri tercih dışı bireylerden mi oluşuyor?" *Amerikan Siyasi Bilimler Dergisi* 84(1):149–163.
Krehbiel, Keith. 1998. *Kritik Politika: ABD Yasama Teorisi*. Chicago Üniversitesi

Doclingo https://www.doclingo.ai

Basın.
Krippendorff, Klaus. 2012. *İçerik Analizi: Yöntemine Giriş*. Sage.
Kulis, Brian ve Michael I. Jordan. 2012. "k-means'i Yeniden Gözden Geçirme: Bayesian parametrik olmayan yeni algoritmalar." In *Proceedings of the 29. Uluslararası Konferans Uluslararası Makine Öğrenimi Konferansı*. ICML'12 Madison, WI, ABD: Omnipress s. 1131–1138.
Lampos, Vasileios ve Nello Cristianini. 2010. "Grip pandemisini sosyal webi izleyerek takip etme." In *2010 2. Uluslararası Bilişsel Bilgi İşleme Atölyesi. IEEE s. 411–416.*
Lampton, David M. 2015. "Xi Jinping ve Ulusal Güvenlik Komisyonu: Politika koordinasyonu ve siyasi güç." Çağdaş Çin Dergisi 24(95):759–777.
Lancichinetti, Andrea, M. Irmak Sirer, Jane X. Wang, Daniel Acuna, Konrad Körding ve Luís A Nunes Amaral. 2015. "Otomatik konu sınıflandırması için yüksek tekrar edilebilirlik ve yüksek doğrulukta yöntem." Fiziksel İnceleme X 5(1):011007.
Landis, J. Richard ve Gary G. Koch. 1977. "Birden fazla gözlemci arasında çoğunluk anlaşmasının değerlendirilmesinde hiyerarşik kappa türü istatistiklerin bir uygulaması." *Biometrikler* 33(2):363–374.
Larochelle, Hugo ve Stanislas Lauly. 2012. "Bir sinirsel otoregresif konu modeli." In *Sinirsel Bilgi İşleme Sistemleri Üzerine İlerlemeler*. s. 2708–2716.
Lauderdale, Benjamin E. ve Tom S. Clark. 2014. "Metinler ve oylar kullanarak politik olarak anlamlı boyutları ölçeklendirme." *Amerikan Siyasi Bilimler Dergisi* 58(3):754–771.
Lauretig, Adam M. 2019. "Bayesyen kelime gömme yöntemlerinde tanımlama ve çıkarım." In *Üçüncü NLP ve Hesaplamalı Sosyal Bilim Atölyesi Bildirileri*.
Laver, Michael ve John Garry. 2000. "Politik metinlerden politika pozisyonlarını tahmin etme." *Amerikan Siyasi Bilimler Dergisi* 44(3):619–634.
Laver, Michael, Kenneth Benoit ve John Garry. 2003. "Siyasi metinlerden politika pozisyonlarını veri olarak kelimeleri kullanarak çıkarmak." *Amerikan Siyasi Bilimler İncelemesi* 97(2):311–331.
Lazarsfeld, Paul Felix ve Neil W Henry. 1968. *Gizli Yapı Analizi*. Houghton Mifflin Co.
Lazer, David, Alex Sandy Pentland, Lada Adamic, Sinan Aral, Albert Laszlo Barabasi, Devon Brewer, Nicholas Christakis, Noshir Contractor, James Fowler, Myron Gutmann, Tony Jebara, Gary King, Michael Macy, Deb Roy ve Marshall Van Alstyne. 2009. "Ağda yaşam: Hesaplamalı sosyal bilimin geleneksel çağı." *Bilim* 323(5915):721.
Lazer, David, Ryan Kennedy, Gary King ve Alessandro Vespignani. 2014. "Google Gripinin hikayesi: Büyük veri analizindeki tuzaklar." *Bilim* 343(6176):1203–1205.
Le, Quoc ve Tomas Mikolov. 2014. "Cümlelerin ve belgelerin dağıtılmış temsilleri." In *31. Uluslararası Makine Öğrenimi Konferansı Bildirileri*,ed. Eric P. Xing ve Tony Jebara. Vol. 32 of *Makine Öğrenimi Araştırmaları Bildirileri* Pekin, Çin: PMLR s. 1188–1196.
Lee, Daniel D. ve H. Sebastian Seung. 2001. "Negatif olmayan matris faktörizasyonu için algoritmalar." In *Sinirsel Bilgi İşleme Sistemlerinde İlerlemeler*. s. 556–562.
Lee, Sophie J., Howard Liu ve Michael D Ward. 2019. "Uzayda kaybolmak: Olay verilerinde coğrafi konum." *Siyasi Bilimler Araştırma ve Yöntemler* 7(4):871–888.
Leskovec, Jure, Lars Backstrom ve Jon Kleinberg. 2009. "Meme-izleme ve haber döngüsünün dinamikleri." *15. ACM SIGKDD Uluslararası*

Doclingo https://www.doclingo.ai

Bilgi Keşfi ve Veri Madenciliği Konferansı. s. 497–506.
Levy, Omer ve Yoav Goldberg. 2014. "Sinirsel kelime gömme, örtük matris faktörizasyonu olarak." *Sinirsel Bilgi İşleme Sistemleri Üzerinde İlerlemeler* 27:2177–2185.
Levy, Omer, Yoav Goldberg ve Ido Dagan. 2015. "Dağıtım benzerliğini geliştir mekelime gömme derslerinden öğrenilenlerle." *Hesaplamalı Dilbilim Dern eği İşlemleri* 3:211–225.
Li, Huayi, Zhiyuan Chen, Bing Liu, Xiaokai Wei ve Jidong Shao. 2014. "Kolektif pozitif-etike tsiz öğrenme yoluyla sahteyorumları tespit etme." *Veri Madenciliği (ICDM), 2014 IEEE Uluslararası Konferansı'nda*. IEEE s. 899–904.
Li, Wei ve Andrew McCallum. 2006. "Pachinko tahsisi: Konu korelasyonlarının DAG-yapılı karışımmodelleri." *23. Uluslararası Makine Öğrenimi Konferansı Bildirileri'nde*. ACM s. 577–584.
Lieberman, Evan S. 2005. "Karşılaştırmalı araştırma için karma yöntem stratejisi olarak iç içe analiz." *Amerikan Siyasi Bilimler Dergisi* 99(3):435–452.
Linder, Fridolin, Bruce Desmarais, Matthew Burgess ve Eugenia Giraudy. 2020. "Metin olarak politika: Tasarı metni yeniden kullanımı yoluyla politika benzerliğini ölçme." *Politika Çalışmaları Dergisi* 48(2):546–574.
Liu, Yang, Xiangji Huang, Aijun An ve Xiaohui Yu. 2007. "ARSA: Blogları kullana rak satış performansını tahmin etmek için duygu-bilinçlibir model." *30. Yıllı k Uluslararası ACM SIGIR Araştırma ve Geliştirme Konferansı Bildirileri'nde*. ACM s. 607–614.
Liu, Yinhan, Myle Ott, Naman Goyal, Jingfei Du, Mandar Joshi, Danqi Chen, Omer Levy, Mike Lewis, Luke Zettlemoyer ve Veselin Stoyanov. 2019. "Roberta: Güçlü bir şekilde opti mize edilmiş bert ön eğitim yaklaşımı." *arXiv ön baskısı arXiv:1907.11692*.
Livermore, Michael A. ve Daniel N. Rockmore. 2019. \Hukuk Veri Olarak: Hesaplama, Metin, *& Hukuki Analizin Geleceği*. Santa Fe Institute Press.
Lloyd, Stuart. 1982. "PCM'de en küçük kareler kuantizasyonu." *IEEE Transactions on Bilgi Teorisi* 28(2):129–137.
Lo, Adeline, Herman Chernoff, Tian Zheng ve Shaw-Hwa Lo. 2015. "Neden önemli değişken ler otomatik olarak iyi tahmin ediciler değildir." *Proceedings of the National Academy of Sciences* 112(45):13892–13897.
Long, Hoyt ve Richard Jean So. 2016. "Edebi desen tanıma: Modernizm yakın okum a ile makine öğrenimi arasında." *Critical Inquiry* 42(2):235–267.
Lorentzen, Peter. 2014. "Çin'in stratejik sansürü." *American Journal of Political Science* 58(2):402–414.
Loughran, Tim ve Bill McDonald. 2011. "Bir yükümlülük ne zaman yükümlülük değildir? Me tin analizi, sözlükler ve 10-K'lar." *The Journal of Finance* 66(1):35–65.
Lowe, Will. 2008. "Kelimeleri Anlamak." *Siyasi Analiz* 16(4):356–371.
Lowe, Will ve Kenneth Benoit. 2013. "Metin verilerinden gizli özelliklerin tahminlerini insan yargısını bir kıyas olarak kullanarak doğrulama." *Siyasi Analiz* 21(3):298–313.
Lucas, Christopher, Richard A. Nielsen, Margaret E. Roberts, Brandon M. Stewart, Alex Storer ve Dustin Tingley. 2015. "Karşılaştırmalı siyaset için bilgisayar destekli me tin analizi." *Siyasi Analiz* 23(2):254–277.
Lucas, Robert E. 1976. "Ekonometrik politika değerlendirmesi: Bir eleştiri." *Carnegie-Rochester Kamu Politikası Konferansı Serisi* 1:19–46.
Luhn, Hans Peter. 1960. "Teknik literatür için anahtar kelime-bağlam dizini (kwic dizini)." *Amerikan Belgelendirme* 11(4):288–295.

Doclingo https://www.doclingo.ai

Lum, Kristian ve William Isaac. 2016. "Tahmin etmek ve hizmet etmek mi?" *Önem* 13(5):14–19.
Lundberg, Ian, Arvind Narayanan, Karen Levy ve Matthew J. Salganik. 2019. "Gizlilik, etik ve veri erişimi: Kırılgan Aileler Mücadelesi üzerine bir vaka çalışması." *Socius* 5:2378023118813023.
Lundberg, Ian, Rebecca Johnson ve Brandon M. Stewart. 2021. "Tahmininiz nedir? Hedef miktarın tanımlanması, istatistiksel kanıtı teoriye bağlar." *Amerikan Sosy olojik İncelemesi* 86(3):532–565.
Ma, Justin, Lawrence K. Saul, Stefan Savage ve Geoffrey M. Voelker. 2009. "Siyah listelerin ötesinde: şüpheli URL'lerden kötü niyetli web sitelerini tespit etmeyi öğrenmek." In *Derleme 15. ACM SIGKDD Uluslararası Bilgi Konferansı Keşif ve Veri Madenciliği*. ACM s. 1245–1254.
MacKinnon, Rebecca. 2008. "Daha düz bir dünya ve daha kalın duvarlar mı? Bloglar, sansür ve sivil söylem Çin'de." *Kamu Seçimi* 134(1-2):31–46.
MacQueen, James. 1967. "Çok değişkenli gözlemlerin sınıflandırılması ve analizi için bazı yöntemler." *Beşinci Berkeley Matematiksel İstatistik ve Olasılık Sempozyum u Bildirileri* 1(14):281–297.
MacRae, Duncan. 1965. "Mevzuat oylamalarından meseleleri ve fraksiyonları tanımlama yö ntemi." American Political Science Review 59(4):909–926.
Magnusson, Måns, Richard Öhrvall, Katarina Barrling ve David Mimno. 2018. "Uzak sağdan sesler: İsveç parlamento tartışmalarının metin analizi." *SocArXiv*.
Malesky, Edmund, Paul Schuler ve Anh Tran. 2012. "Güneş ışığının olumsuz etkile ri: Otoriter bir mecliste yasama şeffaflığı üzerine bir saha deneyi." *Amerikan Siyasal Bilimler Dergisi* 106(04):762–786.
Maliniak, Daniel, Ryan Powers ve Barbara F. Walter. 2013. "Uluslararası ilişkilerde cinsiyet atıf farkı." *Uluslararası Organizasyon* 67(04):889–922.
Manning, Christopher D., Mihai Surdeanu, John Bauer, Jenny Finkel, Steven J. Bethard ve David McClosky. 2014. "Stanford CoreNLP Doğal Dil İşleme Araç Takımı." *Hesaplamalı Dilbilim Derneği (ACL) Sistem Gösterimleri*. s. 55–60.
Marcus, Mitchell P., Mary Ann Marcinkiewicz ve Beatrice Santorini. 1993. "Büyük bir İngili zce anotasyonlu korpus oluşturma: Penn Treebank." *Bilgisayar. Dilbilim.* 19(2):313–330.
Maron, Melvin Earl ve John L. Kuhns. 1960. "İlgililik, olasılıksal indeksleme ve b ilgi erişimi üzerine." *ACM Dergisi (JACM)* 7(3):216–244.
Mason, Winter ve Siddharth Suri. 2012. "Amazon'un Mechanical Turk'ünde davranışsal araş tırma yürütme." *Davranış Araştırma Yöntemleri* 44(1):1–23.
Mayhew, David. 1974. *Seçim Bağlantısı*. New Haven: Yale University Press.
Mcauliffe, Jon D. ve David M. Blei. 2008. "Denetimli konu modelleri." *Sinir Bilgisi İşleme Sistemlerinde İlerlemeler*. s. 121–128.
McCants, William, Jarret Brachman ve Joseph Felter. 2006. "Militan İdeoloji Atlas: "Araştırma Derlemesi." Teknik rapor Askeri Akademi West Point NY Terörle Mücadele Merkezi.
McGhee, Eric, Seth Masket, Boris Shor, Steven Rogers ve Nolan McCarty. 2014. "Par tizanlığın birincil nedeni mi? Adaylık sistemleri ve yasama ideolojisi." *Amerikan Siyasal Bilimler Dergisi* 58(2):337–351.
McLachlan, Geoffrey ve David Peel. 2004. *Sonlu Karışım Modelleri*. John Wiley & Sons.
McQueen, Alison. 2018. *Apokaliptik Zamanlarda Politik Realizm*. Cambridge Üniversitesi

Doclingo https://www.doclingo.ai

Basın.
Melzer, Arthur M. 2014. *Satırların Arasındaki Felsefe*. University of Chicago Press.
Mihalcea, Rada ve Carlo Strapparava. 2009. "Yalan dedektörü: Keşifler aldatıcı dilin otomatik tanınması." *ACL-IJCNLP 2009 Konferansı Kısa Makaleleri*. Hesaplamalı Dilbilim Derneği, s. 309–312.
Mikolov, Tomás, Ilya Sutskever, Kai Chen, Greg S. Corrado ve Jeff Dean. 2013. "Dağıtılmış kelime ve ifade temsilleri ve bunların bileşenleri." *Sinirsel Bilgi İşleme Sistemleri 26*, der. C. J. C. Burges, L. Bottou, M. Welling, Z. Ghahramani ve K. Q. Weinberger. Curran Associates, Inc. s. 3111–3119.
Mikolov, Tomás, Kai Chen, Greg Corrado ve Jeffrey Dean. 2013. "Kelimelerin vektör uzayındaki temsillerinin verimli tahmini." *1. Uluslararası Öğrenme Temsilleri Konferansı, ICLR 2013, Scottsdale, Arizona, ABD, 2-4 Mayıs 2013, Atölye TakipProceedings*, ed. Yoshua Bengio ve Yann LeCun.
Mikolov, Tomás, Wen-tau Yih ve Geoffrey Zweig. 2013. "Sürekli uzay kelime temsillerindeki dilbilgisel düzenlilikler." *2013 Kuzey Amerika Hesaplamalı Dilbilim Derneği Konferansı: İnsan Dili TeknolojileriProceedings*. s. 746–751.
Miller, George A. 1995. "WordNet: İngilizce için bir leksikal veritabanı." *ACM İletişimleri*38(11):39–41.
Mimno, David, Hanna M. Wallach, Edmund Talley, Miriam Leenders ve Andrew McCallum. 2011. "Konu modellerinde anlamsal tutarlılığı optimize etme." *Doğal Dil İşleme Üzerine Ampirik Yöntemler KonferansıProceedings*. Hesaplamalı Dilbilim Derneği s. 262–272.
Mimno, David ve Andrew McCallum. 2008. "Dirichlet-multinomial regresyon ile keyfi özelliklere bağlı konu modelleri." *Yirmi Dördüncü Yapay Zeka Belirsizliği KonferansıProceedings*. AUAI Press s. 411–418.
Mitchell, Margaret, Simone Wu, Andrew Zaldivar, Parker Barnes, Lucy Vasserman, Ben Hutchinson, Elena Spitzer, Inioluwa Deborah Raji ve Timnit Gebru. 2019. "Modelkartları model raporlaması için." In *Adalet, Hesap Verebilirlik ve Şeffaflık KonferansıProceedings*. s. 220–229.
Mohr, John W., Christopher A. Bail, Margaret Frye, Jennifer C. Lena, Omar Lizardo, Terence E. McDonnell, Ann Mische, Iddo Tavory ve Frederick F Wherry. 2020. *Kültürü Ölçmek*. Columbia University Press.
Monroe, Burt ve Ko Maeda. 2004. "Konuşmak ucuz: Metin tabanlı retorik ideal noktalarının tahmini." 21. Yıllık Yaz Toplantısı Siyasi Metodoloji Derneği.
Monroe, Burt, Michael Colaresi ve Kevin Quinn. 2008. "Savaşan kelimeler: Lexical feature seçimi ve değerlendirmesi politik çatışmanın içeriğini tanımlamak için." *Siyasi Analiz* 16(4):372.
Montgomery, Jacob M., Brendan Nyhan ve Michelle Torres. 2018. "Posttreatment değişkenlerine şartlandırmanın deneyinizi nasıl mahvedebileceği ve bununla ne yapacağınız." *Amerikan Siyasi Bilimler Dergisi* 62(3):760–775.
Moretti, Franco. 2013. *Uzak Okuma*. Verso.
Morgan, Stephen L. ve Christopher Winship. 2015. *Karşıt Gerçekler ve Nedensel Çıkarım: Sosyal Araştırmalar için Yöntemler ve İlkeler*. Cambridge: Cambridge Üniversite Yayınları.
Mosteller, Frederick. 2010. *İstatistiklerin Zevkleri: Frederick*

Doclingo https://www.doclingo.ai

Mosteller'in Otobiyografisi. Springer Science & Business Media.
Mosteller, Frederick ve David L. Wallace. 1963. “Bir yazarlık problemi üzerine çıkarım: TartışmalıFederalist Belgeleri'nin yazarlarına uygulanan ayrım yöntemlerinin karş ılaştırmalı bir çalışması.” *Amerikan İstatistik Derneği Dergisi* 58(302):275–309.
Mozer, Reagan, Luke Miratrix, Aaron Russell Kaufman ve L. Jason Anastasopoulos. 2020. “Metin verileri ile eşleştirme: Belgeleri eşleştirme yöntemlerinin deneysel bir de ğerlendirmesive eşleşme kalitesinin ölçülmesi.” *Siyasi Analiz* 28(4):445–468.
Mueller, Hannes ve Christopher Rauh. 2017. “Satırların arasında okumak: Gazete metni kullanarak siyasi şiddetin tahmini.” *Amerikan Siyasi Bilimler Dergisi* ss. 1–18.
Mullainathan, Sendhil ve Jann Spiess. 2017. “Makine öğrenimi: Uygulamalı bir ekonometrik yaklaşım.” *Ekonomik Perspektifler Dergisi* 31(2):87–106.
Mulvenon, James. 2015. “Yuan burada duruyor: Xi Jinping ve ‘CMC Başkanlık Sor umluluk Sistemi’.” *China Leadership Monitor* 47:1–14.
Munger, Kevin. 2019. “Bilgi Çürür: Zamansal Geçerlilik ve Sosyal Bilimler Değişen Bi r Dünyada.” Çalışma Raporu Pennsylvania Eyalet Üniversitesi.
Murphy, Kevin P. 2021. *Olasılıksal Makine Öğrenimi: Bir Giriş*. MIT press.
Nassirtoussi, Arman Khadjeh, Saeed Aghabozorgi, Teh Ying Wah ve David Chek LingNgo. 2014. “Pazar tahmini için metin madenciliği: Sistematik bir inceleme.” *Expert Systems with Applications* 41(16):7653–7670.
Nay, John J. 2017. “Kelimeler vektörleri ve bir ansambl modeli ile yasa yapımını tahmin et me ve anlama.” *PloS One* 12(5):e0176999.
Nelson, Laura K. 2020. “Hesaplamalı temellendirilmiş teori: Bir metodolojik çerçeve.” *Sosyolojik Yöntemler & Araştırma* 49(1):3–42.
Neuendorf, Kimberly A. 2016. *İçerik Analizi Kılavuzu*. Sage.
Ng, Andrew, Michael Jordan ve Yair Weiss. 2001. “Spektral Kümeleme Üzerine: Analiz v e Bir Algoritma.” In *Advances in Neural Information Processing Systems 14: 2001 K onferansıProceeding*. s. 849–856.
Ng, Andrew Y. ve Michael I. Jordan. 2002. “Ayrıştırıcı ve üretici sınıflayıcılar üzerine: A karşılaştırma lojistik regresyon ve naif Bayes.” *Sinir Bilimleri Bilgi İşleme Sistemlerinde*. s. 841–848.
Nguyen, Viet-An, Jordan Boyd-Graber, Philip Resnik ve Kristina Miler. 2015. “Ev deki çay partisi: 112. Kongre'deki Cumhuriyetçi yasama organlarına uygula nan hiyerarşik ideal nokta konu modeli.” *Hesaplamalı Dilbilim Derneği'nin 53. Yıllık Toplantısı ve 7. Uluslararası Doğal Dil İşleme Konferansı (Cilt 1: Uzu n Makaleler)* . s. 1438–1448.
Nielsen, Richard A. 2017. *Ölümcül Din Adamları: Engellenmiş Hırs ve Cihad Yolları*. Cambridge Üniversitesi Yayınları.
Nigam, Kamal, Andrew Kachites McCallum, Sebastian Thrun ve Tom Mitchell. 2000. “Etiketli ve etiketsiz belgelerden EM kullanarak metin sınıflandırması.” *Makine Öğrenimi* 39(2-3):103–134.
Nissenbaum, Helen. 2020. *Bağlamda Gizlilik*. Stanford Üniversitesi Yayınları.
Nsoesie, Elaine O., Sheryl A. Kluberg ve John S. Brownstein. 2014. “Gıda kaynaklı hastalıklar ın çevrimiçi raporları, resmi gıda kaynaklı salgın raporlarında yer alan gıdaları yakalar.” *Önleyici Tıp* 67:264–269.
O’Connor, Brendan, Brandon M. Stewart ve Noah A. Smith. 2013. “Siyasi bağla mdan uluslararası ilişkileri çıkarmayı öğrenmek.” *51. Yıllık*

Doclingo https://www.doclingo.ai

Hesaplamalı Dilbilim Derneği Toplantısı (Cilt 1: Uzun Makaleler). Sofia, Bulgaristan: Hesaplamalı Dilbilim Derneği s. 1094–1104.

O'Connor, Brendan, Ramnath Balasubramanyan, Bryan R. Routledge ve Noah A. Smith. 2010. "Tweetlerden anketlere: Metin duygusunu kamuoyu zaman serilerine bağlama." *ICWSM* 11(122-129):1–2.

Olteanu, Alexandra, Carlos Castillo, Fernando Diaz ve Emre Kıcıman. 2019. "Sosyal data: Önyargılar, metodolojik tuzaklar ve etik sınırlar." *Büyük Veri Sınırları* 2:13.

O'Neil, Cathy. 2016. *Matematiksel Yıkım Silahları: Büyük Verinin Eşitsizliği Artırması ve Demokrasiyi Tehdit Etmesi*. Broadway Books.

Owoputi, Olutobi, Brendan O'Connor, Chris Dyer, Kevin Gimpel, Nathan Schne ider veNoah A Smith. 2013. "Çevrimiçi konuşma metni için kelime kümeleri i le geliştirilmiş sözcük türü etiketleme." In *2013 Kuzey Amerika Hesaplamal ı Dilbilim Derneği Konferansı: İnsan DiliTeknolojileri*. s. 380–390.

Paisley, John, Chong Wang, David M. Blei ve Michael I. Jordan. 2015. "İç içe hiyerarşik Dirichlet süreçleri." *IEEE Desen Analizi ve Makine Zekası Dergisi* 37(2):256–270.

Pan, Jennifer ve Kaiping Chen. 2018. "Yolsuzluğu gizlemek: Çinli yetkililerin çevrimiçi şikaye tlerin yukarıya raporlanmasını nasıl çarpıttığı." *The American Political Science Review* 112(3):602–620.

Paul, Michael ve Mark Dredze. 2012. "Faktöryel LDA: Seyrek çok boyutlu metin modelleri." In *Advances in Neural Information Processing Systems*

Pechenick, Eitan Adam, Christopher M. Danforth ve Peter Sheridan Dodds. 2015. "Google Books derlemesini karakterize etme: Sosyo-kültürel ve dilsel evrim çıkarımları nda güçlü sınırlamalar." *PloS One* 10(10):e0137041.

Pena, José M., Jose Antonio Lozano ve Pedro Larranaga. 1999. "Bir ampirik dört başlangıç yöntemi için k-ortalama algoritmasının karşılaştırması." *Desen Tanıma Mektupları* 20(10):1027–1040.

Pennebaker, James, Martha Francis ve Roger Booth. 2001. *Dilsel Sorgulama ve Kelime Sayımı: LIWC 2001*. Mahway, NJ: Erlbaum Yayıncıları.

Pennebaker, James W. ve Anna Graybeal. 2001. "Doğal dil kullanımının kalıpları: Açıklama, kişilik ve sosyal entegrasyon." *Psikolojik Bilimde Güncel Yöneliml er* 10(3):90–93.

Pennington, Jeffrey, Richard Socher ve Christopher D. Manning. 2014. "GloVe: Kelime temsili için küresel vektörler." In *2014 Doğal Dil İşleme Emprik Yönt emler Konferansı Bildirileri*. s. 1532–1543.

Perry, Patrick O ve Kenneth Benoit. 2017. "Metni sınıf yakınlık modeli ile ölçeklendirme." *arXiv ön baskısı arXiv:1710.08963*.

Perry, Walt L. 2013. *Öngörücü Polislik: Suç Tahmininin Hukuk Uygulamalarındaki Rolü*. Rand Corporation.

Peters, Matthew, Mark Neumann, Mohit Iyyer, Matt Gardner, Christopher Clark, Kenton Lee ve Luke Zettlemoyer. 2018. "Derin bağlamsal kelime temsilleri." In *2018 Kuzey Amerika Hesaplama Dilbilim Derneği Konferansı Bildirileri: İnsa n Dili Teknolojileri, Cilt 1 (Uzun Bildiriler)*. New Orleans, Louisiana: Hesaplama Dilbilim Derneği s. 2227–2237.

Doclingo https://www.doclingo.ai

Piper, Andrew. 2018. *Sayımlar: Veri ve Edebi Çalışma*. Chicago ÜniversitesiYayın evi.
Pitman, Jim ve Marc Yor. 1981. "Bessel süreçleri ve sonsuz bölünebilir yasalar." In *Stokastik İntegraller*. Springer s. 285–370.
Platt, John C. 2005. "Fastmap, MetricMap ve Landmark MDS hepsi Nyström algoritmalarıdır." *10. Uluslararası Yapay Zekave İstatistik Atölyesi Bildirileri*s s. 261–268.
Poole, Keith ve Howard Rosenthal. 1997. *Kongre: OylamaTarihinin Politik-Ekonomi k Tarihi*. Oxford University Press.
Poole, Keith T. ve Howard Rosenthal. 1985. "Meclis oylama analizi için bir mekans al model." *Amerikan Siyasi Bilimler Dergisi* 29(2):357–384.
Popkin, Samuel L. 1994. *Akıl Yürütme Seçmeni: İletişim ve İkna Başkanlık Kampanyaları*. Chicago Üniversitesi Yayınları.
Porter, Martin F. 1980. "Bir ek kesme algoritması." *Program* 14(3):130–137.
Powell, Eleanor Neff. N.d. *Para'nın Kongre'deki Önemi: Partilerin Nasıl Geliştiğine Dair Bir Pencere*. Cambridge University Press.
Preis, Tobias, Helen Susannah Moat, Steven R. Bishop, Philip Treleaven ve H. Eugene Stanley. 2013. "Hurricane Sandy'nin Flickr üzerindeki dijital izlerini nicelendirmenin yolları." *Bilimsel Raporlar* 3:3141.
Pritchard, Jonathan K., Matthew Stephens ve Peter Donnelly. 2000. "Çıkarım çoklu lokus genotip verilerini kullanarak nüfus yapısı." *Genetikler* 155(2):945–959.
Quinn, Kevin M., Burt L. Monroe, Michael Colaresi, Michael H. Crespin ve Dragomir R. Radev. 2010. "Siyasi dikkati en az varsayımlar ve maliyetlerle nasıl analiz edersiniz." *Amerikan Siyasi Bilimler Dergisi* 54(1):209–228.
Ranganath, Rajesh, Linpeng Tang, Laurent Charlin ve David Blei. 2015. "Derin üstel aileler." In *Yapay Zeka ve İstatistik*. s. 762–771.
Reilly, Shauna, Sean Richey, ve J. Benjamin Taylor. 2012. "Eyalet politikası araştırmaları için Google a rama verilerini kullanma: roll-off verileri kullanarak bir ampirik geçerlilik testi." *Eyalet Politikası &Politika Dergisi* 12(2):146–159.
Resnik, Philip, Anderson Garron, ve Rebecca Resnik. 2013. "Konu modellemesi k ullanarak üniversite öğrencilerinde nevrotiklik ve depresyon tahminini iyileşti rme." In *2013 Doğal Dil İşleme Ampirik Yöntemler KonferansıProceedings*. s. 1348–1353.
Rheault, Ludovic ve Christopher Cochrane. 2020. "Parlamento korpuslarında ideolojik y erleşim analizi için kelime gömme yöntemleri." *Politik Analiz* 28(1):112–133.
Ribeiro, Marco Tulio, Sameer Singh, ve Carlos Guestrin. 2016. "'Neden sana gü venmeliyim?' Herhangi bir sınıflayıcının tahminlerini açıklama." In *22. ACMS IGKDD Uluslararası Bilgi Keşfi ve Veri Madenciliği KonferansıProceedings*. s. 1135–1144.
Riffe, Daniel, Stephen Lacy, Brendan R. Watson, ve Frederick Fico. 2019. *Medya Mes ajlarını Analiz Etme: Araştırmada Nicel İçerik Analizi Kullanma*. Routledge.
Roberts, Margaret E., Brandon M. Stewart, Dustin Tingley, Christopher Lucas, Jetson Leder-Luis, Shana Kushner Gadarian, Bethany Albertson ve David G. Rand. 2014. "Açık uçlu anket yanıtları için yapısal konu modelleri." *Amerikan Siyaset Bili mi Dergisi* 58(4):1064–1082.
Roberts, Margaret E., Brandon M. Stewart, Dustin Tingley ve Edoardo M. Airoldi. 2013. "Yapısal konu modeli ve uygulamalı sosyal bilimler." *Sinirsel Bilgi İşleme Sistemleri Üzerine İlerlemeler*

Doclingo https://www.doclingo.ai

Konular Modelleri: Hesaplama, Uygulama ve Değerlendirme. Cilt 4 Harrahs ve Harveys, Lake Tahoe.

Roberts, Margaret E., Brandon M. Stewart ve Dustin Tingley. 2016. "Büyük verinin y erel modlarında gezinmek: Konu modelleri örneği." *Hesaplamalı Sosyal Bilim: Keşif ve Tahmin*, ed. R. Michael Alvarez. New York: Cambridge University Press bölüm 2, s. 51–97.

Roberts, Margaret E., Brandon M. Stewart ve Dustin Tingley. 2019. "stm: Yapısal kon u modelleri için bir R paketi." *İstatistiksel Yazılım Dergisi* 91(1):1–40.

Roberts, Margaret E., Brandon M. Stewart ve Edoardo M. Airoldi. 2016. "Sosyal bilimlerde deney yapmak için bir metin modeli." *Amerikan İstatistik Derneği Dergisi* 111(515):988–1003.

Roberts, Margaret E., Brandon M. Stewart ve Richard A. Nielsen. 2020. "Metin eşleş tirme ile karıştırmayı ayarlama." *Amerikan Siyasi Bilimler Dergisi* 64(4):887–903.

Rodman, Emma. 2020. "Zamanında bir müdahale: Değişen anlamların izlenmesi kelime vektörleri ile politik kavramlar." *Politik Analiz* 28(1):87–111.

Rodríguez, Pedro ve Arthur Spirling. N.d. "Kelime gömme: Ne işe yarar, ne işe yaramaz, ve uygulamalı araştırmalar için farkı nasıl anlayabilirsiniz." *Siyaset Dergisi*. Yakında yayımlanacak.

Rodríguez, Pedro L., Arthur Spirling ve Brandon M. Stewart. 2021. "Gömme Regresyon: Bağlama Özgü Tanım ve Çıkarım Modelleri." Çalışma Raporu Vanderbilt Üniversitesi.

Rosen-Zvi, Michal, Thomas Griffiths, Mark Steyvers ve Padhraic Smyth. 2004. "Yazarla r ve belgeler için yazar-konu modeli." In Proceedings of the 20th Conference on U ncertainty in Artificial Intelligence. AUAI Press s. 487–494.

Roweis, Sam T. ve Lawrence K. Saul. 2000. "Yerel lineer gömme ile doğrusal olm ayan boyut azaltma." *Bilim* 290(5500):2323–2326.

Kural, Alix, Jean-Philippe Cointet ve Peter S. Bearman. 2015. "Sözcüksel kaymalar, ma ddi değişiklikler ve Birlik Devletleri konuşmasındaki süreklilik, 1790–2014." *Ulusal Bilimler Akademisi Bildirileri* 112(35):10837–10844.

Rumelhart, David E., Geoffrey E. Hinton ve Ronald J. Williams. 1986. "Hataları geri yayarak öğrenme temsilcileri." *Nature*

Rybicki, Jan ve Maciej Eder. 2011. "Türler ve diller arasında daha derin Delta: Gerçekten en sık kullanılan kelimelere ihtiyacımız var mı?" *Edebi ve Dilbilimsel Hesaplama* 26(3):315–321.

Salakhutdinov, Ruslan ve Geoffrey Hinton. 2009. "Tekrarlanan Softmax: Yönsüz topik modeli." In *Proceedings of the 22. Uluslararası Sinir Bilgi İşleme Sistemleri*. NIPS'09 Red Hook, NY, ABD: Curran Associates Inc. s. 1607–1614.

Salam, Sayeed, Lamisah Khan, Amir El-Ghamry, Patrick Brandt, Jennifer Holmes, VitoD' Orazio ve Javier Osorio. 2020. "İspanyolca siyasi haber makaleleri için otomatik olay kodlama çerçevesi." In *2020 IEEE 6. Uluslararası Bulut Güvenliği Büyük Veri Konfera nsı, IEEE Uluslararası Yüksek Performans ve Akıllı Hesaplama Konferansı ve IEEEUlu slararası Akıllı Veri ve Güvenlik Konferansı*. IEEE s. 246–253.

Salganik, Matthew. 2018. *Bit by Bit: Dijital Çağda Sosyal Araştırma*. PrincetonÜniver site Yayınları.

Schnabel, Tobias, Igor Labutov, David Mimno ve Thorsten Joachims. 2015. "Denetims iz kelime gömme yöntemlerinin değerlendirilmesi." 2015 Doğal Dil İşleme Alanın da Ampirik Yöntemler Konferansı'nın Bildirileri'nde. s. 298–307.

Doclingo https://www.doclingo.ai

Schofield, Alexandra ve David Mimno. 2016. “Elmalarla elma karşılaştırmak: Kon u modelleri üzerindekistemmerların etkileri.” *Hesaplamalı Dilbilim Derneği İ şlemleri* 4:287–300.

Schofield, Alexandra, Måns Magnusson ve David Mimno. 2017. “Durdurucu unsurları çıkarma: “Konu modelleri için durak kelime kaldırma üzerine yeniden düşünme.” *15. Avrupa Hesaplamalı Dilbilim Derneği KonferansıKısa Makaleler: Cilt 2,Kısa Makaleler*. Cilt 2 s. 432–436.

Schonhardt-Bailey, Cheryl. 2013. *Amerikan Para Politikasını Tartışmak: Bir Metin Analizi*. MIT Press.

Schonhardt-Bailey, Cheryl. 2017. “Birleşik Krallık'ta sözel olmayan çatışma ve küçümseme mali ve para politikası üzerine parlamento denetim oturumları.” *Politika ve Hayat Bi limleri* 36(1):27–46.

Schrodt, Philip A. 1986. “Uluslararası olayları tahmin etmek.” *BYTE* 11(12):177–192.

Schrodt, Philip A. 2006. “Kansas olay verisi sistemi projesinin yirmi yılı.” *The Siyasal Metodolog* 14(1):2–8.

Schrodt, Philip A. 2012. “Önceki durumlar, ilerleme ve siyasal olay verilerindeki beklentiler.” *Uluslararası Etkileşimler* 38(4):546–569.

Schrodt, Philip A. ve Deborah J. Gerner. 1994. “Orta Doğu için makine kodlu bir olay v eri setinin geçerlilik değerlendirmesi, 1982–1992.” *Amerikan Siyasi Bilimler Dergisi* 38(3):825–854.

Schütze, Hinrich. 1993. “Kelime alanı.” *Sinirsel Bilgi İşleme Sistemlerinde İlerle meler*. s. 895–902.

Schwartz, H Andrew, Johannes C Eichstaedt, Margaret L Kern, Lukasz Dziurzynski, Stephanie M Ramones, Megha Agrawal, Achal Shah, Michal Kosinski, David Stillwell, Martin E.P. Seligman ve Lyle H. Ungar. 2013. “Kişilik, cinsiyet ve yaşın sosyal med ya dilindeki yeri: Açık kelime dağarcığı yaklaşımı.” *PloS One* 8(9):e73791.

Sebeok, Thomas A. ve Valdis J. Zeps. 1958. “Yapılandırılmış içeriğin analizi, psik odilbilimde elektronik bilgisayar araştırmalarının uygulanması.” *Dil ve Konuşma* 1(3):181–193.

Sennrich, Rico, Barry Haddow ve Alexandra Birch. 2016. “WMT 16 için Edinburgh sinirsel makine çeviri sistemleri.” *Makine Çevirisi Üzerine İlk Konferansın Bildiri leri: Cilt 2, Paylaşılan Görev Belgeleri*. s. 371–376.

Shank, Daniel B. 2016. “Sosyolojik araştırmalar için kitle kaynak kullanımı web siteleri: Ama zon Mechanical Turk örneği.” *The American Sociologist* 47(1):47–55.

Shannon, Claude E. 1949. *İletişimin Matematiksel Teorisi*. Urbana-Champaign: Illinois Üniversitesi Yayınları.

Shao, Li. 2018. “Eleştirinin ikilemi: Çin'deki medya sansürünün belirleyicilerini ayırmak.” *Journal of East Asian Studies* 18(3):279–297.

Sheng, Victor S., Foster Provost, ve Panagiotis G. Ipeirotis. 2008. “Başka bir etiket al?” Birden fazla, gürültülü etiketleyici kullanarak veri kalitesini ve veri madenciliğini iyileştirmek.” In *Proceedings of the 14th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. ACM pp. 614–622.

Shih, Victor. 2008. “Sadakat gösterilerinin mide bulandırıcı halleri: Çin'deki ideolojik kampany alar aracılığıyla fraksiyonel pazarlığı izlemek.” *The Journal of Politics* 70(04):1177–1192.

Shor, Boris ve Nolan McCarty. 2011. “Amerikan ideolojik haritalaması” yasama organları.” *Amerikan Siyasi Bilimler Dergisi* 105(3):530–551.

Silge, Julia ve David Robinson. 2017. *R ile Metin Madenciliği: Düzenli Bir Yaklaşım*. O’Reilly

Doclingo https://www.doclingo.ai

Medya, Inc.
Simmons, Joseph P., Leif D. Nelson ve Uri Simonsohn. 2011. “Yanlış pozitif psikoloji: Veri toplama ve analizinde açıklanmamış esneklik, her şeyi anlamlı olar ak sunmaya olanak tanır.” *Psikolojik Bilim* 22(11):1359–1366.
Slapin, Jonathan B. ve Sven-Oliver Proksch. 2008. “Metinlerden zaman serisi parti pozisyonlarını tahmin etmek için bir ölçekleme modeli.” *Amerikan Siyasi Bilimler Dergisi* 52(3):705–722.
Smith, David A., Ryan Cordell ve Elizabeth Maddock Dillon. 2013. “Bulaşıcı metinler: 19. yüzyıl gazetelerinde metin yeniden kullanımını modelleme.” In *2013 IEEE Uluslararara sı Büyük Veri Konferansı*. IEEE s. 86–94.
Snow, Rion, Brendan O’Connor, Daniel Jurafsky ve Andrew Y Ng. 2008. “Ucuz ve hızlı—ama iyi mi?: doğal dil görevleri için uzman olmayan notasyonları değerlendirme.” In *Doğal Dil İşleme Üzerine Ampirik Yöntemler Konferansı Bildirileri*. Hesaplamalı Dilbilim Derneği s. 254–263.
Snyder, David ve William R. Kelly. 1977. “Çatışma yoğunluğu, medya hassasiyeti ve gaz ete verilerinin geçerliliği.” *Amerikan Sosyolojik İnceleme* ss. 105–123.
Snyder Jr., James M. 1992. “Komite gücü, yapıdan kaynaklanan denge ve oyla ma.” *Amerikan Siyasi Bilimler Dergisi* 36(1):1–30.
Socher, Richard, Alex Perelygin, Jean Wu, Jason Chuang, Christopher D Manning, Andrew Ng, ve Christopher Potts. 2013. “Duygu ağaç bankası üzerinde anlamsal *bileşkenlik için yinelemeli derin modeller.” 2013 Doğal Dil İşleme Üzerine Ampi rik Yöntemler Konferansı'nınProceedings'inde. s. 1631–1642.*
Spirling, Arthur. 2012. “Amerikan Yerlileri ile ABD antlaşma yapma: Kurumsal değişim ve nispi güç, 1784–1911.” *Amerikan Siyasi Bilimler Dergisi* 56(1):84–97.
Stevens, S. S. 1946. “Ölçüm ölçekleri teorisi üzerine.” *Bilim* 103(2684):677–680.
Stewart, Brandon M. ve Yuri M. Zhukov. 2009. “Rusya'da güç kullanımı ve sivil–askeri ilişkiler: automatik içerik analizi.” *Küçük Savaşlar & İsyanlar* 20(2):319–343.
Strauss, Leo. 1952. *Persekuşyon ve Yazma Sanatı*. Free Press.
Strubell, Emma, Ananya Ganesh, ve Andrew McCallum. 2019. “NLP'de Derin Ö ğrenme için Enerji ve PolitikaDeğerlendirmeleri.” *57. Yıllık Toplantı'nın Proc eedings'indeHesaplamalı Dilbilim Derneği*. Floransa, İtalya: Hesaplamalı Dil bilim Derneği s. 3645–3650.
Taddy, Matt. 2013. “Metin analizi için çok terimli ters regresyon.” *Amerikan İst atistik Derneği Dergisi* 108(503):755–770.
Tatman, Rachael. 2017. “Cinsiyet ve lehçe yanlılığı YouTube'un otomatik altyazılarında.” In *Doğal Dil İşleme'de Etik Üzerine İlk ACL Atölyesi Bildirileri*. s. 53–59.
Tausanovitch, Chris ve Christopher Warshaw. 2017. “Kutuplaşmış bir kongrede adayların politik yönelimlerini tahmin etme.” *Politik Analiz* 25(2):167–187.
Tausczik, Yla R. ve James W. Pennebaker. 2010. “Kelimelerin psikolojik anlamı: LIWC ve bilgisayarla metin analizi yöntemleri.” *Dil ve SosyalPsikoloji Dergisi* 29(1):24–54.
Tavory, Iddo ve Stefan Timmermans. 2014. *Abduktif Analiz: Nitel Araştırmayı Teorileşti rme*. Chicago Üniversitesi Yayınları.
Tetlock, Paul C., Maytal Saar-Tsechansky ve Sofus Macskassy. 2008. “Sadece kelimelerden fazlası: Dil miktarını ölçmek için firmaların temellerini nicelleştirme.” *Finans Dergisi* 63(3):1437–1467.

Doclingo https://www.doclingo.ai

Teune, Henry ve Adam Przeworski. 1970. *Karşılaştırmalı Sosyal Araştırmanın Mantığı*. New York: Wiley-Interscience.
Thurstone, L.L. 1954. "Değerlerin ölçümü." *Psikolojik İnceleme* 61(1):47–58.
Thurstone, Louis L. 1927. "Karşılaştırmalı yargı yasası." *Psikolojik İnceleme* 34(4):273.
Timmermans, Stefan ve Iddo Tavory. 2012. "Nitel araştırmada teori inşası: "Temellendirilmiş teoriden çıkarımsal analize." *Sosyolojik Teori* 30(3):167–186.
Tkachenko, Nataliya, Stephen Jarvis ve Rob Procter. 2017. "Flickr etiketleriyle sel tahmi ni." *PloS One* 12(2):e0172870.
Torres, Michelle. 2019. "Görsel bir politik dünya: Görsel içeriğin belirleyicileri ve etkile ri." Çalışma Raporu Rice Üniversitesi.
Turney, Peter D. ve Michael L. Littman. 2003. "Övgü ve eleştiriyi ölçmek: Anlam yöneliminin çıkarımı." *ACM Bilgi Sistemleri Üzerine Dergi* 21(4).
Turney, Peter D. ve Patrick Pantel. 2010. "Frekansdan anlama: Anlamın vektör uzayı modelleri." *Yapay Zeka Araştırma Dergisi* 37:141–188.
Underwood, Ted. 2019. *Uzak Ufuklar: Dijital Kanıt ve Edebi Değişim*. Chicago Üniversitesi Yayınları.
Vafa, Keyon, Suresh Naidu ve David Blei. 2020. "Metin tabanlı ideal noktalar." In *Derleme 58. Yıllık Hesaplama Derneği Toplantısı Dilbilim*. Çevrimiçi: Hesaplamalı Dilbilim Derneği s. 5345–5357.
Van Atteveldt, Wouter, Jan Kleinnijenhuis ve Nel Ruigrok. 2008. "Hollanda gazete m akalelerinden anlamsal ilişkileri çıkarmak için sözdizimsel analizi kullanarak, söz dizimsel ağlar ve politik otorite." *Politik Analiz* s. 428–446.
van der Vaart, Aaad W., Sandrine Dudoit ve Mark J. van der Laan. 2006. "Oracle eşitsizlikleri çok katmanlı çapraz doğrulama için." *İstatistikler ve Kararlar* 24(3):351–371.
Bhaswani, Ashish, Naam Sarjie, Nicky Parmer, Jacob Ushyakreit, Leon Jones, Aiden Na. Gomez, Lukasz Kaiser ve Illia Polosukhin. 2017. "Dikkat, ihtiyacınız olan her şeydir." In *Sinirsel Bilgi İşleme Sistemlerinde İlerlemeler*. s. 5998–6008.
Veitch, Victor, Yixin Wang ve David Blei. 2019. "Ağlardaki gözlemlenmemiş karışıklı kları düzeltmek için gömme kullanma." In *Sinirsel Bilgi İşleme Sistemlerinde İle rlemeler*. s. 13792–13802.
Vikram, Sharad ve Sanjoy Dasgupta. 2016. "Etkileşimli Bayes hiyerarşik kümeleme." In *Uluslararası Makine Öğrenimi Konferansı*. s. 2081–2090.
Wainwright, Martin ve Michael Jordan. 2008. *Grafik Modeller, Üstel Aileler, ve Varyasyonel Çıkarım*. Now Publishers.
Wallach, Hanna M., David M. Mimno ve Andrew McCallum. 2009. "LDA'yı Yeniden Düşünmek: Önceliklerin önemi." In *Sinirsel Bilgi İşleme Sistemlerinde İlerlemeler*. s. 1973–1981.
Wallach, Hanna M., Iain Murray, Ruslan Salakhutdinov ve David Mimno. 2009. "Konu modelleri için değerlendirme yöntemleri." In *Makine Öğrenimi Üzerine 26. Yıllık Uluslararası Konferansın Bildirileri*. ACM s. 1105–1112.
Wallach, Hanna, Shane Jensen, Lee Dicker ve Katherine Heller. 2010. "Parametrik olmayan Bayesçi kümeleme için alternatif bir öncelik süreci." In *Proceedings of the ThirteenthInt ernational Conference on Artificial Intelligence and Statistics*. s. 892–899.
Wang, Chong ve David M. Blei. 2009. "Ayrık hiyerarşik Dirichlet sürecinde seyrek liği ve pürüzsüzlüğü ayırma." In *Advances in Neural Information Processing*

Doclingo https://www.doclingo.ai

Systems. s. 1982–1989.

Wang, Chong ve David M. Blei. 2013. "Eşleşmeyen modellerde varyasyonel çıkarım." *Journal of Machine Learning Research* 14(Nisan):1005–1031.

Ward Jr., Joe H. 1963. "Bir nesnel fonksiyonu optimize etmek için hiyerarşik gruplama." *Journal of the American Statistical Association* 58(301):236–244.

Wieting, John, Mohit Bansal, Kevin Gimpel ve Karen Livescu. 2016. "Charagram: Karakter n-gramları aracılığıyla kelimeleri ve cümleleri gömme." In *Proceedings of the 2016 Conference on Empirical Methods in Natural Language Processing*. Austin, Texas: Association for Computational Linguistics s. 1504–1515.

Wilkerson, John, David Smith ve Nicholas Stramp. 2015. "Politika fikirlerinin yasama organlarında ki akışını izleme: Bir metin yeniden kullanım yaklaşımı." *American Journal of Political Science* 59(4):943–956.

Wilkerson, John ve Andreu Casas. 2017. "Siyasi bilimde büyük ölçekli bilgisayar la metin analizi: Fırsatlar ve zorluklar." *Siyasi Bilim Yıllık İncelemesi* 20(1):529–544.

Williamson, Ben. 2016. "Dijital eğitim yönetimi: veri görselleştirme, öngörücü analitikler ve 'gerçek zamanlı' politika araçları." *Eğitim Politikası Dergisi* 31(2):123–141.

Williamson, Sinead, Chong Wang, Katherine A. Heller ve David M. Blei. 2010. "IB P bileşen Dirichlet süreci ve odaklanmış konu modellemesine uygulaması." In *Derleme 27. Uluslararası Konferans Makine Öğrenimi*. ICML'10 Madison, WI, ABD: Omnipress s. 1151–1158.

Wittgenstein, Ludwig. 1953. *Felsefi Soruşturmalar*. John Wiley & Sons.

Yano, Tae, William W. Cohen ve Noah A. Smith. 2009. "Politik blog yazılarına yanıtı tahmin etme konu modelleri ile." In *İnsan Dili Teknolojileri Bildirileri: The 2009 Kuzey Amerika Bölümü Derneği Yıllık Konferansı Hesaplamalı Dilbilim*. Hesaplamalı Dilbilim Derneği s. 477–485.

Yao, Limin, David Mimno ve Andrew McCallum. 2009. "Akış halindeki belge kole ksiyonlarında konu modelleme çıkarımı için verimli yöntemler." In *15. ACM SI GKDD Uluslararası Bilgi Keşfi ve Veri Madenciliği Konferansı Bildirileri*. ACM s. 937–946.

Ying, Luwei, Jacob M. Montgomery ve Brandon M. Stewart. 2019. "Kavramları konulardan çıkarma: Konu doğrulama prosedürlerine doğru." PolMeth XXXVI@ MIT, Cambridge, MA. Siyasi Metodoloji Derneği.

Genç, Daniel Taylor. 2012. "Anayasal bir anı nasıl ölçersiniz: Bruce Ackerman'ın ana yasal değişim teorisini değerlendirmek için algoritmik konu modellemesi kullan ma." *Yale Hukuk Dergisi* 122:1990.

Young, Lori ve Stuart Soroka. 2012. "Duygusal haberler: Politik metinlerde duygu otomatik kodlaması." *Siyasi İletişim* 29(2):205–231.

Zen G, diye bağırdı Jin. 2016. "İdeolojik bağlılıkları gösterme biçimlerinin değişimi "Deng sonrası Çin'deki kampanyalar." *Çağdaş Çin Dergisi* 25(100):547–562.

Zhang, Han ve Jennifer Pan. 2019. "CASM: Sosyal medyadan metin ve görüntü veriler i ile kolektif eylem olaylarını tanımlamak için derin öğrenme yaklaşımı." *Sosyolojik Metodoloji* 49(1):1–57.

Zhang, Yian, Alex Warstadt, Haau-Sing Li ve Samuel R. Bowman. 2021. "Milyon larca kelime ön eğitim verisine ne zaman ihtiyaç duyarsınız?" In *59. Yıllık Bil gisayarla Dilbilim Derneği Toplantısı*.

Doclingo https://www.doclingo.ai

Zhang, Yuchen, Xi Chen, Denny Zhou ve Michael I. Jordan. 2014. “Spektral yöntemler EM ile buluşuyor: Kalabalık kaynak kullanımı için kanıtlanmış optimal bir algoritma.” In *Sinirsel Bilgi İşleme Sistemlerinde*. s. 1260–1268.

Doclingo https://www.doclingo.ai

İndeks

Abello, James, 45
doğruluk: karışıklık matrisleri, 212 ; çapraz doğrulama, 213
paradoks, 246 ; eğitim seti, 186 ; doğrulama seti, 212
Achen, Christopher H., 13
yakınlık yayılımı, 135
AFGP. *Ateş Söndürücüler İçin Yardım Programı (AFGP) için bakınız*
Aggarwal, Charu C., 207
agnostik yaklaşım, 11, 18–20; veri olarak metin yöntemleri, 30; metin analizi yöntemleri, 29
Ahmed, Amr, 260
AIC. *Akaike Bilgi Kriteri (AIC) için bakınız*
Airoldi, Edoardo M., 158, 160, 260
Akaike Bilgi Kriteri (AIC), 141
alakart *döşemeler,* 85
Aletras, Nikolaos, 254
notlar, 11, 123, 172n2, 193, 194API'ler.
Bkz. Uygulama Programlama Arayüzleri (API'ler)Uygula
ma Programlama Arayüzleri (API'ler), 46
Arora, Sanjeev, 85n1, 227
el yapımı veriler, 25
İtfaiyecilere Yardım Programı (AFGP), 151
ATE. *Bkz.* ortalama tedavi etkisi (ATE)
Aynı, Susan
otomatik genelleme, 80
ortalama tedavi etkisi (ATE), 268 , 272, 277, 278; nedensel çı
regresyon, 262 ; STM modeli, 292

kelime torbası modeli, 48–49 ; varsayılan prosedür, 57–59
dil oluşturma ile, 61 ; karmaşıklığı azalt, 52–55
49–50
Kefalet, Christopher, 91, 169
Banerjee, Arindam, 133
Barberá, Pablo, 190, 191
temel fonksiyonlar, 204; uyarlanabilir, 205–206; sabit, 203–205
Baumgartner, Frank, 16
Bayes hiyerarşik modeli, 66 , 147
Bayes çıkarımı, 67 , 68; küme verisi, 141

Doclingo https://www.doclingo.ai

Bayes Bilgi Kriteri (BIC), 141
Bearman, Peter S., 38, 93, 169
Beauchamp, Nicholas, 183, 254–256
Belloni, Alexandre, 288
kıyaslar, 255
Bengio, Joshua, 82, 206
Berlinli, Daniel, 44
Berry, Christopher R., 108
sparsity ilkesine bahis, 205
merkezilik derecesi, 170
önyargı: teşvik, 44
BIC. *Bkz.* Bayes Bilgi Kriteri (BIC)
büyük veri, 24, 298, 301
bigrams, 51
Piskopos, Jonathan, 160
Bishop, Christopher, 207
Blaydes, Lisa, 25, 42, 157
Blei, David M., 60, 153, 155, 156, 157n5, 287
Bojanowski, Piotr, 84
Boydstun, Amber E., 192, 193, 269
Brachman, Jarret, 217
Broadwell, Peter, 45

Carlson, David, 195
Casas, Andreu, 228
Catalinac, Amy, 5–7, 41, 153, 224, 266
kategorik dağılım, 61
nedensel çıkarımlar, 15–17, 20–22, 234–238, 260–263; varsayımlar, 106; haritalama fonksiyonu, 266–269; *vs*. tahmin, 263
CBOW. *Bkz.* devam eden kelime torbası (CBOW) modeli
Şansölye, Stevie, 248
Chang, Charles, 206
Chang, Jonathan, 139, 142
Chen, Kai, 80
Chernozhukov, Victor, 288
Çin hükümeti sansürcüleri, sosyal medya, 20–22Hristiya
n toplulukları, 42
c Huang, Jason, \him93
Klasik Çok Boyutlu Ölçekleme (MDS), 167–169; uzantıları, 168; senato basın bültenl erine, 168–169
sınıflandırıcılar, 184
kümeleme algoritmaları, 12
yaklaşımlar, 127–143
136; insan tarafı, 144–145; *k*-ortalama kümelenme, 124–127; bölümlendirme kalitesi, 129–130;olasılıkçı kümelenme modelleri, 132–134; temsiller için, 127; stiller, 130–132k
odlayıcılar, 172, 190–192
Cohen, Mark A., 272, 273

Doclingo https://www.doclingo.ai

Cointet, Jean-Philippe, 38, 93, 169
Colaresi, Michael, 115, 116, 181
topluluk tespit algoritmaları, 169hesaplam
alı çıkarımsal analiz, 159koşullu göz ardı edi
lebilirlik, 286
karışıklık matris, 212
kongre kaydı, 185
bağlantılı öncelik, 67
muhafazakâr koalisyon, 106
bağlamsal bütünlük, 37
sürekli kelime torbası (CBOW) modeli, 83
yakınsayan geçerlilik, 214
Corrado, Greg S., 80
kosinüs mesafesi, 72–74
Courville, Aaron, 206
çapraz doğrulama, 213, 245

Da, Nan Z., 8–9
Danforth, Christopher M., 43, 180
Dean, Jeff, 80
çıkarımsal yaklaşım, 27
derin öğrenme devrimi, 206
Deerwester, Scott, 82
varsayılan prosedür, 57
    ön işleme, 58–59
Denny, Matthew J., 19, 228
bağımlılık ayrıştırma, 95–96
Devlin, Jacob, 88
DH. *Bkz.* dijital beşerî bilimler (DH)
Dhillon, Inderjit, 133
sözlük yöntemleri, 180–183; sınırlamaları ve doğrulamaları, 181–182
Diermeier, Daniel, 181
dijital beşerî bilimler (DH), 8–9
DiMaggio, Paul, 153
Dirichlet dağılımı, 66–69
keşif ilkeleri: bağlamın önemi, 103–104
    gerçek bir zemin yok, 104–105
tartışmalı yönetim, 185
dağıtılmış temsiller, 79
dağılımsal hipotez, 78
doc2vec, 86
belge-özellik matris, 55–57
    Analiz (LSA), 82
Dodds, Peter Sheridan, 43, 180
aşağı akış kovaryant modeli, 156du
mmy değişken, 61
Duneier, Mitchell, 179, 180

Doclingo https://www.doclingo.ai

Dinamik Ağırlıklı Nominal Üç Aşamalı Tahmin (DW-NOMINATE) algoritması, 107, 108

Egami,Naoki, 260, 266–269, 272, 273, 276–278
Eisenstein, Jacob, 90, 207, 260
EM algoritması. *Bkz.* Beklenti-Maksimizasyon (EM) algoritması
entropi, 112
Erlich, Aaron, 44
Öklid mesafesi, 74
Beklenti-Maksimizasyon (EM) algoritması, 133
ifade edilen ideoloji, 208
dışsal değerlendirmeler, 87

yüzeysel geçerlilik, 31
Farooqui, Manal, \:84
fastText \gömmeler, 84
Federalist belgeleri, 39–41
öngörü, 249
kelime sayıları, 64
Federal Açık Piyasa Komiteleri (FOMC), 44geri bil
dirim döngüleri, 248
Fields, Joseph, 217
feminist hareketler, 112
Fenno, Richard F., 108
hayali öngörü problemleri, 112, 116–118Savaşç
ı kelimeler, 111, 115–116
balıkçılık, 268, 299
düz *vs*. hiyerarşik kümeleme yöntemi, 132
FOMC. *Bkz*Federal Açık Piyasa Komiteleri (FOMC)
Fong, Christian, 209, 260, 269, 278, 279, 281–283
Dış İlişkiler, 38
Fauller, James, 225
bulunan veriler, 46, 195
Fowler, Anthony, 27, 108
FPCILV. *Bakınız* Gizli Değişkenlerle Nedensel Çıkarımın Temel Problemi (FPCILV)
Franco, Annie, 272, 275–276
Freedman, Michael, 104, 159
Bilgi Edinme Hakkı Yasası, 43–44
frekans ters belge frekansı ağırlığı, 75. *Ayrıca bakınız* tf-idf ağırlığı
FREX, 160
Friedman, Jerome, 205
Gizli Değişkenlerle Nedensel Çıkarımın Temel Problemi (FPCILV), 268
bulanık kümeleme, 131

g, 266–269
oyun teorik modeli, 13
Ganesh, Ananya, 88
Garg, Nikhil, 86

Doclingo https://www.doclingo.ai

Garry, John, 182, 183
genelleme hatası, 243
Gentzkow, Matthew, 117, 118
GFT algoritması. *Bkz.* Google Grip Eğilimleri (GFT) algoritması
ghetto, 179, 180
Ghosh, Joydeep, 133
ghost hikayeleri, 45
Gill, Michael, 43, 260
Gillion, Daniel Q., 185–188, 266
Ginsberg, Jeremy, 256
Eldiven, 83
Goertz, Gary, 214
altın standart veri, doğrulama olmadan: dış bilgiye karşılık, 215; uzman olmayan insan değerlendirmesi, 215; kısmi kategori çoğaltma, 215; vekil etiketler, 214–215
altın standart veri, doğrulama ile, 211–212; çapraz doğrulama, 213; önemi, 213–214; devam eden değerlendirmeler, 214; doğrulama seti, 212–213
Goodfellow, Ian, 206
Google Grip Eğilimleri (GFT) algoritması, 256
Google Ngrams derlemesi, 43
hükümet sansürü, 20
GPU'lar. *Bkz.* Grafik İşleme Birimleri (GPU'lar)
graf kesme algoritmaları, 136
Grafik İşleme Birimleri (GPU'lar), 88
gri alan, 214
temellendirilmiş teori, 14, 100, 104, 159

Hall, Andrew B, 43, 260
elle kodlama: güvenilirliği kontrol et, 192; kod kitabı, 191; belge seçimi, 191–192; kayma,tipleri, 192; *Haber Yapmak*, 192–193; kodlayıcıları yönet, 192; kodlayıcıları seç, 191
Hansen, Christian, 288
zararlı dil, 36
Hastie, Trevor, 205
Healy, Andrew J., 27, 28
Heer, Jeffrey, 93
Holland, Paul W., 236
Hopkins, Daniel J., 24, 206, 207
Hu, Yuening, 157
Hvitfeldt, Emil, 206
hipotez geçerliliği, 31, 215id

eal nokta, 107
ideolojik hakimiyet varsayımı, 221endü
striyel ölçekli problemler, 10
bilgi çıkarım görevleri, 96–97
Uluslararası İlişkiler (IR), 287
öz değerlendirmeler, 87

Doclingo https://www.doclingo.ai

IR. *Bkz.* Uluslararası İlişkiler (IR)IR
T. *Bkz.* öğe yanıt teorisi (IRT)
Isaac, William, 248
öğe yanıt teorisi (IRT), 220

Jaros, Kyle, 94, 95
Jarvis, Stephen, 254
Jerzak, Connor T., 207
Jones, Bryan, 16
Jordan, Michael, 201
Jursfsky, Dan, 90

Kang, Jun Seok, 254
Karell, Daniel, 104, 159
Kaufman, Aaron Russell, 300
Keith, Katherine, 96
Kelly, Bryan, 117
Keohane, R. O., 171, 176
Khodak, Mikhail, \:85
King, Gary, 20, 21, 24, 124, 127, 139, 145, 171, 176, 206–207, 219
k-ortalama kümeleme, 124–127
Knox, Dean, 300
Kraft, Peter, 300
Krippendorff, Klaus, 190
Kristensen, Evald Tang, 45

etiket sadakati, 32
etiketleme konu modelleri, 159–161
Lafferty, John D., 155, 157n5
dil modeli, 7
laplace düzeltmesi, 166
Gizli Dirichlet Tahsisi (LDA), 6, 7, 18, 147–153; içerik kovaryatları, 154–156; aşağı akış kovaryat modeli, 156; örnek, 149–151; yapıyı dahil etme, 153–154; yorumlama, 151–153; yaygınlık kovaryat konu modelleri, 154; yapı, ek kaynaklar, 157
gizli anlamsal analiz, 82
Laver, Michael, 182, 183
LDA. *Bakınız* Gizli Dirichlet Tahsisi (LDA)
Le, Quoc, 86
lemmatizasyon, 54, 58, 78
Lim, Chloe, 272, 275–276
doğrusal sınıflayıcı, 201–202
doğrusal regresyon, 60
dilsel tahmin, 242
kayıp fonksiyonu, 197, 202–204, 242
Loughran, Tim, 181, 269
U, ying, \him207
Lucas, Christopher, 155, 300

Doclingo https://www.doclingo.ai

Lum, Kristian, 248
Lundberg, Ian, 37

MacRae, Duncan, 106
Madison. Airoldi, 249
Maeda, Ko, 220
Malhotra, Neil, 27, 28
Maliniak, Daniel, 285, 287, 288, 292
Manning, Christopher D., 84, 93
haritalama fonksiyonu, 266–269
Martin, James, 90
Masterson, Michael, 206
Mayhew, David, 124, 126
Mcauliffe, Jon D., 156
McCallum, Andrew, 88, 153, 260
McCants, William, 217
McDonald, Bill, 181, 269
McGhee, Eric, 99
McQueen, Alison, 24, 25, 42, 157
MDS. *Bakınız* Klasik Çok Boyutlu Ölçekleme (MDS)
ortalama *v.s.*. mediods kümeleme yöntemi, 131–132
ölçüm, 9
ölçüm ilkeleri: net hedefler, 175
keşif ve, 176–177
175; doğrulama, 175
orta önyargı, 44–45
Dağınıklık, Süleyman, 151
Mikolov, Thomas, 80, 86
Mimno, David, 138, 153, 260
Minkowski mesafe metrikleri, 74
MNIR. *Bakınız* Çoklu Ters Regresyon (MNIR)
Mo, Cecilia Hyunjung, 27, 28
Monroe, Burt, 115, 116, 181, 220
Montagnes, B. Pablo, 27
Montgomery, Jacob M., 139, 195
Morgan, Stephen L., 260
Mosteller, Frederick, 39–41, 64, 65, 75, 249
Mozer, Reagan, 287
çoklu ters regresyon (MNIR), 121
çoklu dil modeli: Dirichlet dağılımı, 66–69; dil modeli, 63–66;
çoklu dağılım, 61–63
çoklu kümelenme modeli, 133
Murphy, Kevin P., 207
Müslüman toplumlar, 42
karşılıklı bilgi, 112–114

Nag, Manish, 153

Doclingo https://www.doclingo.ai

naif varsayım, 198
Naif Bayes (NB), 198–200
    temel fonksiyonlar, 203–205; üretken model, 200–201; doğrusal sınıflayıcı, 201–202; makine öğrenimi, 202–203
adlandırılmış varlık tanıma (NER), 94–95
Ulusal Futbol Ligi (NFL) oyunları, 27–28doğ
al dil işleme, 30, 34, 82, 87, 88, 94, 97, 254
Nay, John J., 254
NB. *Bkz.* Naif Bayes (NB)n
egatif reklam, 23
Nelson, Laura K., 104, 112, 113, 115, 116, 119–122
NER. *Bkz.* named-entity recognition (NER)
Neuendorf, Kimberly A., 190, 192
sinirsel kelime gömme, 82–84
Ng, Andrew, 201
n-gram yaklaşımı, 51
Nielsen, Richard A., 196, 207–210, 216–218, 260, 266, 285, 287, 290, 292
Nissenbaum, Helen, 37
metni temsil etmenin doğru bir yolu yo
k, 37değerlerden bağımsız bir korpus oluşturma y
ok, 36–37şu an tahmin süreci, 231, 256–2

57gözlemsel veriler, 21
OCR teknolojisi. Optik karakter tanıma (OCR) teknolojisine bakın
tek sıcak kodlama, 61
O'Neil, Cathy, 248
optik karakter tanıma (OCR) teknolojisi, 34
optimizasyon, 130
örnek dışı, 213, 235, 236, 239, 255, 298

Pan, Jennifer, 20, 21, 94, 95, 97
PAP. Ön analiz planına (PAP) bakın
bölüm kalitesi, 129–130
konuşma parçaları (POS) etiketleme, 90, 91–94
PCA. Temel bileşen analizi (PCA) için bakın
Pechenick, Eitan Adam, 43, 180
Pennington, Jeffrey, 84
politika gündemleri, 16
ilgi popülasyonu, 42–43POS etiketlem
e. Konuşma parçaları (POS) etiketleme için bakınpotansiyel son
uçlar, 261–264, 267–269, 278, 286
Powers, Ryan, 285, 287, 288, 292
pragmatik yaklaşım, 29
ön analiz planı (PAP), 265
sınıflandırıcının doğruluğu, 247
tahmin, 233–234
tahminler, 17, 26–27; temel görevi, 242–243; dilsel tahmin, 253–254; ve

Doclingo https://www.doclingo.ai

ölçüm, 243–244; ilkeleri, 244–248; sosyal tahmin, 254–256; görev, 184önceden eğitil
miş gömme vektörleri, 84
temel bileşen analizi (PCA), 162–167
yöntemler için, 164
öncelikli dağılım, 66
olasılıklı, yumuşak, ortalama bazlı ve düz kümeleme yöntemi (çok terimli karışım küme
leme modeli), 133
olasılıklı ve algoritmik kümeleme bağlantıları: model seçimi, 137–140; küme sa
yısı, 140–143; belgeleri okuma, 140
olasılıklı yaklaşımlar, 131olas
ılıklı kümeleme modelleri, 132–134olasılı
klı *vs*. algoritmik kümeleme yöntemi, 131
Procter, Rob, 254
Proksch, Sven-Oliver, 220, 221

nicel ölçüm, 206–207
ilgi alanları, 42–43soruya özel meti
n derleme, 35–36
Quinn, Kevin, 115, 116, 144, 153, 181, 260

nadir kelimeler, 84–85
ReadMe algoritması, 207
geri çağırma, karışıklık matrisleri, 212
karmaşıklığı azalt: eşdeğer sınıflar oluştur, 54–55; sıklığa göre filtrele, 55; küçük harf yap,
52; noktalama işaretlerini kaldır, 52–53; durak kelimeleri kaldır, 53–54
Reilly, Shauna, 254
temsilciler: etik sorunlar, 36
araştırma tasarımı, 22–24
kaynak yanlılığı, 43–44
geri alma yanlılığı, 45–46
yeniden yapılandırma, 84
Richey, Sean, 254
Riffe, Daniel, 190
Kural, Alix, 38, 93, 169
kural tabanlı algoritma, 91
Pas, Roland T., 272, 273

Buz, pişmiş, pişmiş
Schnabel, Tobias, 87
Schonhardt-Bailey, Cheryl, 44
Schrodt, Philip A., 189
Sebeok, Thomas A., 174
anlamsal geçerlilik, 215
Sen, Maya, 300
duyarlılık analizi, 236
Shapiro, Jesse M., 118
Silge, Julia, 206
benzerlik ölçütleri, 70–73. *Ayrıca bakınız* vektör uzayı modeli

Doclingo https://www.doclingo.ai

tekil değer ayrıştırması (SVD), 82, 290
skip-gram, 86
Slapin, Jonathan B., 220, 221
sLDA. *Bakınız* süpervizyonlu LDA (sLDA)
Smith, David, 91
Smyth, Padhraic, 225
Socher, Richard, 84
sosyal tahmin, 254
sosyal medya, 10
sosyal öngörü, 242
sosyal süreç: sistematik yönleri, 5
sosyal bilimler, 5–7
softmax sınıflayıcı, 201
yumuşak *vs.* sert kümeleme yöntemi, 131
SOTU. *Bakınız* Birlik Durumu (SOTU)kaynak ta
hmini, 241, 249–253
Spirling, Arthur, 19, 77, 228
Sra, Suvrit, 133
Birlik Durumu (SOTU), 38–39
Steen, Sara, 272, 273
köklendirme, 54, 55
STM. *Yapısal konu modellerine (STM) bakınızdurdu*
rma kelimeleri, 53, 54
Stramp, Nicholas, 91
Strejnev, Anton, kat 207
Strubell, Emma, 88
yapısal yaklaşım, 19
yapısal konu modelleri (STM), 157–159
denetimli sınıflandırma: performansı kontrol et, 187; belgeleri sınıflandır, 186; diskürrsif yönetişim, 185–186
denetimli LDA (sLDA), 156
denetimli öğrenme, 4, 21, 207–210; Cihad puanları, 207–209; makine öğrenimi, 202–207; Naive bayes, 198–202
Sutskever, Ilya, kat 80
SVD. *Tekil değer ayrıştırması (SVD) için bakınız*

Taddy, Matt, 117, 121
Tangherlini, Timothy R., 45
görev temelli yaklaşım, 29, 30, 298
Taylor, J. Benjamin, 254
test verisi, 177
metin analizi, ilkeleri: en iyi yöntem göreve bağlıdır, 29–30; sosyal bilim teorilerini o luşturma, geliştirme vetest etme, 26–28; temel ve teoriye bağlıdır, 30–32; sosyal bilim teorileri ve maddi bilgi, 22–24; metin analizi, 24–26; metin analiziyöntemle ri, 28–29
metin yeniden kullanı
mı, 90–91tf-idf ağırlığı, 75–77

Doclingo https://www.doclingo.ai

Thurstone, L. L., 195
Tibshirani, Robert, 205
Tingley, Dustin, 160, 227
Tkachenko, Natalia, kat 254
tokenizasyon, 50–52
konu: içeriği, 153; aynı şeyin farklı versiyonları, 153; yaygınlığı, 153kon
u modelleri: etiketleme konu modelleri, 159–161; Gizli Dirichlet Tahsisi (LDA), 147–153; yapısal konu modelleri, 157–159
Torres, Michelle, 300
eğitim, 86
eğitim verisi, 177
algoritması, 91
eğitim seti, kodlama: özellikleri, 190; kitle kaynak kullanımı, 193–195; elle kodlama, 190–193; bulunan verilerle denetim, 195–196
transfer öğrenimi, 79
üçlüler, 51
Twitter verisi, 36
Tyler, Matthew, 209, 260, 269, 278, 279, 281–283

unigramlar, 51, 92, 93, 124, 255
analiz birimi, 49–50
denetimsiz yöntemler, 79, 219–220; yeniden kullanımda endişeler, 225–229; modeli uyarlamak, 223; elle kodlama, 223–224; hipotez geçerliliği, 224; model tabanlı değerlendirmeler, 224–225;datanı n bölünmesi, 223; vekil etiketler, 224; test verisi ve yeniden doğrulama, 225; modeli doğrulama k, 223–225; yeniden kullanım için iş akışı, 221–225
akışkan kovaryant modelleri, 153
ABD Kongresi, 106–109

doğrulama yöntemleri, 9
ölçüm ilkeleri, 175
doğrulama seti, 212–213
varyasyonel çıkarım, 133
vektör uzayı modeli: mesafe ölçüleri, 74–75; benzerlik ölçüleri, 70–73; tf-idf ağırlıklandırması, 75–77
Veitch, Victor, 287
Kelimeler, S., 171, 176
bakir metinler, 183
söz dağarcığı, 50–52
, 158
von Mises-Fisher modeli, 129, 133–134

Wallace, David L., 39–41, 64, 65, 75, 249
Wallach, Hanna M., 25, 225
Walter, Barbara F., 285, 287, 288, 292
Wang, Yixin, 287
Westwood, Sean J., 151
Wilkerson, John, 16, 91, 228
Winship, Christopher, 260

Doclingo https://www.doclingo.ai

Wittgenstein, Ludwig, 79
word2vec, 83
kelime sayımı: sözlük yöntemleri, 180–183
kelime gömme tahmini: toplama, 86–87
81–82; örnekleme, 85–86; gizli anlamsal analiz, 82; sinirsel kelime gömmeleri, 82–
84; önceden eğitilmiş gömme vektörleri, 84; nadir kelimeler, 84–85; kendinden denetim içgörüsü, 81;
doğrulama, 87–88
Wordfish, 221
kelime puanları algoritması, 182–183
kelime segmentasyonu modeli, 50

Xing, Eric P., 260

Y IH, wen-τ, \his 80elaffuz e
dilen ying, l Uwei, \him 139\

NZ EPs, val ground SJ., ha 174el
affuz edilen Zhang, Han,
ha 97\NZ ihlali, Geoffrey, ha 80
χ2 test istatistikleri, 119–121

Doclingo https://www.doclingo.ai